

概率论引论

谢践生 编著

(2024 年 09 月校稿版)

序

与欧几里得几何的发展历史比起来，概率论的诞生和发展要晚得多，直到 17 世纪才有了 Fermat 和 Pascal 的书信讨论以及 Huygens 关于概率论的十几页¹的一本书。至于建立起概率理论公理化体系，最终使数学家们能够站在一个统一而无歧义的测度论的讨论平台，则更要等到 1933 年 Kolmogorov 的奠基性的著作了。我想主要原因是概率事件的概率和随机变量的期望的确是更抽象一些的吧；实际上，与理解长度和面积等物理度量这件事比起来，理解概率、期望等概念还是要更加高上一个层次。但不管我们是否能看清楚、想明白，概率的规则总是支配着我们的现实世界，无时不在，无处不在。

而概率论近期有一个非常迅速而突出的发展，固然是因为其在金融领域、数据科学、人工智能科学的大规模应用和由此而引起的金融风险的度量的迫切需要，也由于许多挑战性的数学问题的提出和解决。

谢践生教授的《概率论引论》是一个很接地气，而同时又保持了概率论公理系统内在逻辑的严密性的本科生概率论教材，对于培养本科生、研究生的数学素质，也是一本难得的好教材。本人在读这本教材时亦感到受益匪浅，可见作者在成书的过程中所注入的心血。本书的一个重要特点是给出了大量与我们现实世界有紧密联系、意义深刻的例子，这对于读者学习、应用和发展概率理论将会起到很大的作用。

概率论的一些深刻而重要的结果在初学时常会引起一些概念上的迷惑。谢践生教授在度过他的概率理论初学年代那么多年后，还能清楚地追忆起那同学少年的迷茫，并将之提取出来而做透彻的分析，使本书的读者能够更早、更快地走出迷津，这也是此书的一个难能可贵之处。

《概率论引论》的另一个重要特点是：作者在讲解到一些概率统计理论的重要结果的同时，也对相应结果的发现者，或相关领域的开创者本人予以介

¹据文献记载，在范·舒藤建议及亲自翻译下，Huygens 对概率论的讨论最早于 1657 年发表在范·舒藤用拉丁文撰写的《数学习题集》一书中，编排页码为 519—534；该书荷兰文版出版于 1660 年，英文版出版于 1692 年，德文版出版于 1899 年，法文版出版于 1920 年，意大利文版出版于 1984 年。本注记为编者在全书终稿时特意加注的文字，而非彭院士原始序文中文字，特做此说明。

绍。我很赞同这种风格，它大幅度地拉近了那些看似很抽象的数学定理与初涉概率论领域的读者之间的距离，真可能就点通了那位读者的灵犀。

我从小就喜欢爬山；后来发现，不少数学家都有这个爱好。如果你准备爬概率论这座山，你最好借助一张地图或一本地图册，以免迷失在大山里，而谢践生的《概率论引论》就是一本很好的地图册兼导游书。

彭实戈

2022 年 4 月 11 日

前言与导读

本讲义是我在 2021 年秋季学期为复旦大学数学科学学院的本科生主讲概率论荣誉课程的授课过程中逐渐整理而来。在此之前，我常年从事学院的多门概率论专业课程的教学工作，因此讲义中毫无疑问有众多内容来源于那些教学工作中积累的素材。特别是在开设本科生概率论荣誉课程之前，我刚好差不多完成了自己编撰的《现代概率论基础》课程的电子讲义的修订工作，这为本讲义的出现做了比较充分的准备。

从我本科阶段开始概率论方向的相关课程学习，直到自己成为教师来教授本科生概率论，所使用的教材总是或多或少让我感觉不舒服¹，有众多迷思：几乎所有的初等概率论教材对于为何（及为何如此模式地）引入相关的概念缺乏必要且令人信服的解说；而整体教材数学陈述上的逻辑严密性虽然通常没有什么大问题²，但有关内容材料组织的条理性、趣味性上总是让人感觉有所欠缺。比如说，为何自然语言中说 A, B 两个事件无关³，而概率论中则把这个“无关性”对应于概率术语“独立性”，并定义它为 $\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$ ？为何大多数教材讲完概率论的几条公理后，后续介绍随机变量时就不再明确说明随机变量赖以生存的样本空间了？一个取定了的概率空间怎么可能容纳源源不断在讨论的各式各样的随机变量？在实务工作中能用频率来代替概率的道理是什么？其他数学领域中的数学结构如线性空间、群、环、域、流形等有同构的概念，为啥概率论中概率空间作为一种概率结构不好好讲讲它的同构问题⁴？为什么

¹显然，编写本讲义的过程中，编者也从前人所编教材中吸取了它们的一些长处，借鉴了其中的一些有趣的例子与论述等；天道轮回，限于编者的个人能力，本讲义中毫无疑问同样可能有一些地方会给读者不舒服的阅读体验，那时可能也是新一代的读者变编者而进一步改进教材的时机。

²很多初等概率论教材在逻辑严密性上都或多或少有些小瑕疵，通常在高等概率论中能找到修正处理的方案；本讲义系统整理修正了这些编者已察觉的瑕疵。编者非常期待关于本讲义自身瑕疵的读者反馈，以利更正修缮。

³与此类似地，统计学的假设检验问题中也经常提两因素无关，实际也是指代表这两个因素的随机变量之间是相互独立的。

⁴在本讲义面世之前，国内外已出版的概率论教材或专著（包括“高等概率论”的教材或专著）中，也只有极少数书籍论述了这个问题。

数学期望、条件数学期望按照大多数初等概率论教材中的模式定义¹？明明到了概率论的高级课程中数学期望、条件数学期望又有另一套抽象定义，这两套定义怎么联系起来？初等概率论中，经典条件概率定义为 $\mathbb{P}(B|A) := \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)}$ ，它与条件数学期望又有何联系？另外，数学期望、条件数学期望定义出来到底是为了解决什么实际问题？总不能说是概率论学者们自娱自乐的数字计算游戏吧？在概率论中经常提分布律与条件分布律，那么到底什么是分布律与条件分布律？类似的问题还有很多。这一系列问题在我所见到的为初学者而准备的国内外初等概率论教材中很少有给出系统讨论的；那么作为教师，又应当如何从整体上理解、并在实际教学工作中安排和讲述初等概率论的有关内容呢？这些“为何”及“如何”的问题我最终从概率论的高级课程的教材等材料的字里行间揣摩到了我自己认可的答案，这也是本讲义的写作动机。

带着这些“为何”与“如何”的问题（起初一大部分问题已在前期的学习和科研路上摸索出自己的回答），我在复旦多年的本科生概率论教学实践中，几乎每一年的讲法都与上一年有所差别，其目的就是探索一种自己满意的（初等）概率论教学内容安排体系，使得学生们再次遇到我当初的困惑场景时，有关疑惑在这个教学体系下能够自然而然地如冬雪春融。这是一个教学的迭代、优化过程；这个过程反映在电子讲义上，我的《现代概率论基础》电子讲义草稿始于2012年，直到2021年才达到我基本满意的状态，但仍需少许修订，近乎十年磨一剑；如果加上前期的教学磨炼，则远超十年。这是一个把过往大多数初等概率论教材的教学内容次序推倒之后逐步重新构建的过程；当然概率论的理论还是那些理论，改变的是它们在课程中的出场次序以及介绍的模式；无疑，这需要勇气、决心与大量的付出。这也是一个痛并快乐的过程。痛，除了来源于这个探索过程中自身的精神折磨，还来源于外界。众所周知，在较长时期里，国内高校学界的生态状况是重视科研远远重于教学；近些年虽然管理层从文件精神上要求重视本科生、研究生教学，但因为教学上投入的时间和心血难量化比较等原因，从政策的实际落实角度来看，从在很多院校兢兢业业服务于教学一线的教师朋友们的吐槽反馈看，实际状况并没有得到特别大的改善。鉴于有关“游戏规则”，朋友们互相劝慰，在教学中的投入还是对得起自己的良心就算了；教材之类的就等老了、退休有精力再说，毕竟基础学科专业教材的编写费时费力，即使出版后得到好评也就那样。这些酸楚我都能理解，毕竟

¹对于数学期望概念，在编者看来，大多数传统初等概率论教材给出的定义实际上只是限于离散随机变量和连续随机变量两种情形的数学期望计算公式，是一种仅限于直观理解的狭窄定义（这在高中课程中是适宜的），初入门的读者即使学有余力也很难借此升华而推导出概率论的高级教程中给出的一般的数学期望计算公式，更别提用统一的逻辑体系去理解更复杂的条件数学期望，从而有关教材的整体逻辑体系在此给编者一种如鲠在喉的感觉，这是促使编者在之前多年的概率论学习与教学中反复探索的一个重要原因。

我们都是这个体系中的感同身受者；我也没有放弃科研，但我更享受科研与教学的相互融合与促进：融入科研体悟的教学和通过教学促进科研这两种快乐的体会我都真真切切地感受过。真正的痛是在教学过程中的不被学生理解，尽管这种状况不多。在我多年的教学过程中，有两次被学生投诉的历史（其中一次投诉原因让人哭笑不得，在此也不细说），还好两次投诉院系领导通融理解，没有最终升级成教学事故而进一步造成悲剧；在某次课程中介绍数学期望、条件数学期望的公理化定义这部分内容¹时，也曾有同学询问我，“为啥课程中要讲那么难的内容，反正我们也学不懂，最后考试也不考”云云，让我略感愤慨，而联想到与此密切关联的教学管理等如今的大环境又有点无言以对。我由于主要为本院的学生讲授专业课程，总体来说师生对数学的价值取向与品味趋同，我的授课方式还是能被大多数同学理解；身边一些为外院系开设数学课程的同事、朋友在教学中发生的类似故事（甚至是事故）更多。这里把这些事情写出来，只为呼吁同学们理解那些在教学一线兢兢业业服务的老师们，特别是青年教师。教学经验是在教学实践的磨练中逐步提高的；我清清楚楚记得自己在职业生涯的早期有过一次“挂黑板”的经历；至于授课过程中的口误或笔误，应该说只要继续从事教学我就无法向各位保证能避免。同时，我也呼吁管理层对于学生们的教学投诉审慎应对与处理。

除了中学阶段的初步积累，我的一点点物理学理论底子始于北大的理科实验班的“攀登计划”（现如今似乎已改名为“元培实验班”或“元培计划”），后来再跟从钱敏先生，并在刘培东教授实际指导下从事随机动力系统研究的过程中，逐步积攒了点统计力学、热力学的理论基础，也因受钱敏先生影响对物理学发生更多的兴趣。到复旦大学开始概率论课程的教学工作后，为了更好地讲授这门课程，这才又逐渐开始去追寻概率论发展的历史²。在反复阅读、思考的过程中注意到 Hilbert（希尔伯特）在他倡导的公理化运动中，把概率和力学的公理化置于物理学的公理化的范畴内，大受震撼；但直到 2021 年秋季的某天，才突然感觉自己摸索到了完成前述重建我心目中的初等概率论教学体系任务的钥匙：把概率论中所有的概念和理论置于概率空间是对现实中的随机现象（或随机试验）进行的概率建模这一构想下来进行论述；当然有关论述最好能与学科发展的史实交叉融合。如今的讲义就是在这样的指导精神下组织相关材料，逐步展开有关理论论述的。个人感觉，这种组织材料的方式或许可以给读者呈现概率理论是如何从模糊的直观中自然而然地萌芽并生长的。Newton（牛顿）本人发展他的力学理论体系似乎也是如此；有关史料给我的感觉是：他对微积分理论的创建，只是在力学理论构建过程中出于解决有关问题的实际

¹即本书第六、七章的有关内容。

²在国内外的大多数概率论教材中，对于概率论发展历史的介绍是严重缺失的。

需要,在前人如 Archimedes (阿基米德)、Galileo (伽利略)、Pascal (帕斯卡) 等的工作基础上顺手而为而已;在职业生涯的早期他自己也并没觉得有多了不起,相反他更看重基于直观和简单物理现象来发展力学理论体系的哲学思想及与之对应的数学原理¹;到了职业生涯的后期他才被迫卷入微积分发明的优先权之争。

在此我们介绍一下全书的框架结构。

在前述“概率建模”的观点和指导精神下,考虑到教学的具体安排,我们把全书正文内容分成 12 章。

第一章用于引出概率论关心的随机现象与随机事件(以及可能隐藏在背后的随机试验),并简单回顾概率论的发展历史。第二章论述了初学者最容易理解和接受的两类满足等可能性假设的概率模型:古典概率模型和几何概率模型。注意到在几何概率模型中,并不是所有的事件都能谈论概率,因此在古典概率模型和几何概率模型的基础上升华出公理化的概率模型对于今天的我们来说显得很自然且并不难理解,尽管这一点在概率论学科的实际发展进程上整整耗费了 100 多年:从 Laplace (拉普拉斯)在 1812 年发表《分析概率论》而涵盖古典概率模型和几何概率模型开始,到 Kolmogorov (柯尔莫哥洛夫)集前人工作之大成,在 1933 年发表德文著作《概率论基础》^[62]而发展出完备的公理化概率模型,期间总共耗费了 121 年。

第三章是全书中一个极其特殊的章节,介绍了经典条件概率与事件独立性,是编者的“概率建模”观点在全书中的第一次重要落实²。我们基于古典概率模型,导出了古典概率模型中条件概率的概念,并把这一概念外推至一般的公理化概率模型;同样基于古典概率模型(及几何概率模型)讨论了如何为使用两套赌博道具的复杂赌博进行概率建模,由此导出了公理化概率论框架下概率空间的乘积空间这一概念,并在此基础上自然而然地引出了多个事件的相互独立性这一概念。如此方式引出独立性概念的好处是严谨而清晰地建立了自然语言中事件的“无关”(irrelevance)和概率语言中事件的“相互独立”(independence)之间非常自然而本质的对应关系,这在所有国内外概率论教材中当属首创;在应用层面,只有基于乘积空间的技术手段,我们才能用精确的数学语言来实现 Bernoulli 重复试验³的概率建模。这种相对新颖的论述方式也很自然地回答了《测度论》中为何要讨论乘积可测空间与乘积测度空间、为何

¹Newton 的经典著作是《自然哲学的数学原理》(Philosophiae Naturalis Principia Mathematica)。

²但毫无疑问这并不是整个概率论发展历史中的第一次;编者的个人意见是,古典概率模型的建立可以认为是第一次虽然粗浅但也完美的“概率建模”,它第一次把模糊的自然语言中的概率在最容易理解的情况下予以了数学的精确化定义。

³大多数初等概率论教材在此处论述时通常仅使用自然语言语焉不详地含糊带过。

要探讨测度扩张问题，同时乘积空间也是初等概率论的后续课程中有关随机过程的轨道构造等理论探讨的必备手段；我们的讲义作为初学者的教材，在这些地方只能简单引用《测度论》等的相关结论，而把这些结论的略微细致论述统一放在了下一章，即第四章¹，至于更深入的讨论则要求读者阅读本讲义的附录A或其他专门的《测度论》教科书等材料。最后，在本章我们通过介绍小概率原理还进一步讨论了现实世界与概率（统计）建模之间的接口，这为初学者借助生活中锻炼出的直觉来学习、理解和应用概率（及统计）理论给出了总纲性的指导。

历史上，概率论的发展，特别是其中有关随机变量及其数学期望的公理化定义等现代理论框架的形成，受到同时期其他多个数学分支发展的影响与推动：例如微积分、测度论、泛函分析，特别是 Lebesgue（勒贝格）积分理论等的发展对概率论有深远的影响。为此我们在全书中插入了另一个特殊的、分析味道浓重的章节作为第四章，用于介绍 20 世纪才发展起来的 Lebesgue 积分理论；除了传统的欧氏空间中的 Lebesgue 积分理论，该章节顺带介绍了一般测度的抽象 Lebesgue 积分理论。其中，欧氏空间中的 Lebesgue 积分理论主要是为连续型随机变量²的密度函数的定义、分布律的计算等做铺垫，一般测度的抽象 Lebesgue 积分理论主要是为数学期望、条件数学期望的定义做技术准备。

概率论中引进随机变量概念的一大目的是在概率建模中更方便、更精确地描述有关复杂的随机现象与随机事件，而这些随机现象与随机事件的概率计算、独立性的刻画或判断等都可以归结到随机变量的分布律的演算。在随机变量概念引入后也很自然有随机变量的相互独立性、随机变量的“平均值”与“条件平均值”（数学期望与条件数学期望）等直观中容易理解的概念³，这些由随机变量诱导出来的概念在计算公式上也同样可以归结到随机变量的分布律的演算。因此随机变量及其分布律是初等概率论的一个核心内容。综合考虑全书理论陈述的条理性和教学的便利性，我们把随机变量的介绍拆分成三个不连贯的章节进行：第五章先介绍随机变量及其分布律和随机变量的独立性的概念，之后介绍随机变量中最容易理解的离散型随机变量的概念以及常见的离散型分布。第八章先介绍连续型随机变量及其密度函数的概念，之后介绍概率微元法用于解决光滑可逆（或分片光滑可逆）变换下连续型随机变量的密度函数的计算问题，最后介绍常见连续型分布及它们的密度函数。第九章介绍了

¹这类知识的教学似乎置于《测度论》之类的课程更为适合，在本课程的教学由于教学时间等原因建议对该章内容只做介绍而不展开详细的论证与讨论。

²现代概率论中更严谨的术语是绝对连续型随机变量，本讲义中一律简称连续型随机变量。

³这些概念的数学定义在现代概率论中都做了抽象化处理，以便涵盖足够广泛的应用场景的同时又确保整体逻辑体系的严密性与自治性。

一般分布函数的性质、随机变量的实现问题以及次序统计量的一些初步结果；这个章节中还特别介绍了一个奇异（连续）型随机变量的例子并讨论了随机变量的分布分类的问题，介绍了随机变量分布的三种纯型——这是为了避免学生们学完初等概率论课程后形成“随机变量只有离散型和连续型两种类型（或纯型）”这一非常普遍的错误观念。在第五章，通过一个自然而又令人信服的例子，我们特别指出：随机变量的定义应当在可测函数的认同基础上施行一个“补丁程序”；这与我们“概率建模”的精神是一致的。

在第六、七章，我们分别介绍了概率论中两个重要的工具：数学期望与条件数学期望。在第六章的论述中，我们通过回顾历史上 Huygens（惠更斯）提出的期望收益的概念，给出严谨的数学期望的定义，并通过引入保测映射的观点最终给出数学期望的计算公式；而保测映射观点的进一步引申，就自然而然地回答了前述如何定义概率空间同构的问题。第三章定义的经典条件概率结合第六章刚刚定义的数学期望概念，在第七章中进一步发挥，导出了经典条件概率对应的经典条件数学期望，这个概念进一步拓广成更一般的条件数学期望的概念，由此引出更抽象的条件概率的定义；特别地，我们进一步可以探讨所谓的条件分布律，基于此我们最终给出了概率论中常用的一个随机变量关于另一个随机变量的条件数学期望的计算公式；这些内容请参见第七章的有关论述。

以上章节中多处概念的论述都遵循了物理学或数学中拓广概念的原则，并且介绍这些概念时都是尽力先从最容易理解的情形开始的。

本书正文最后三章是全书的高潮。

在介绍了随机变量的几种收敛性概念后，第十章基于 Chebyshev（契比雪夫）不等式系统介绍了 Borel-Cantelli 第一、第二引理等论证强大数律的重要工具¹，进而讨论了强、弱大数律，这是对本书第一章中“频率稳定性”现象的呼应；另外，该章中 Chebyshev 不等式的一个推论也给出了前述随机变量概念的“补丁程序”的一种有效率的落实方法。

第十一章介绍了特征函数理论及其重要应用，其中理论部分重点介绍了特征函数的三大定理：唯一性定理、连续性定理和刻画定理，而应用部分则重点介绍了中心极限定理。

为了呼应我们“概率建模”的观点，在正文最后一章即第十二章中，我们分两节给出了两部分的讨论：（I）公理化概率论观点下“经验的总结与外推”；（II）基于大样本理论的对模型的检验。在（I）部分中，我们首先用两个简单模型讨论了第一章习题中介绍的赌徒佯谬与热手效应（涉及“经验的总结”与“经验的外推”）；之后讨论了在公理化概率论观点下的“经验的总结”，

¹特别地，在第十章我们还分别给出了 $\mathbb{P}(\{A_n\}_n \text{ i.o.}) = 0$ 和 $\mathbb{P}(\{A_n\}_n \text{ i.o.}) = 1$ 的等价刻画，如此完整而系统的论述在所有现存的国内外（本科生及研究生）概率论教科书中当属首次。

见定理12.1.1 (Lanford 定理), 其中涉及的极限分布律恰好是热力学中的 Gibbs (吉布斯) 态。在 (II) 部分中, 我们给出了可以借助大样本数据来检验模型准确性的如下几个定理:

- (1) 作为统计学基本定理的 Glivenko-Cantelli 定理; 实务上我们可以基于这个理论, 利用大样本数据作 P-P 图或 Q-Q 图, 形象 (或者说“定性”) 地检验样本是否来自于某个具体的分布。
- (2) Kolmogorov 定理; 这个定理由于其证明需要更高级的技巧, 在本书中就仅在附录C中提供了在初等概率论范围内能大致理解的一个粗线条的证明框架。实务上我们可以基于这个定理, 构建 Kolmogorov 检验, “定量”地检验大样本是否来自于某个分布函数连续的分布。
- (3) Pearson 定理; 实务上, 基于 Pearson 定理, 我们可以构建拟合优度检验, “定量”地检验大样本是否来自于某个简单的离散型分布。
- (4) Pearson-Fisher 定理。实务上, 基于这个定理, 我们可以构建关于独立性的列联表检验, 基于大样本数据“定量”地判断“二维”数据之间是否具有独立性。

当然, 以上四个定理只做到了对初等概率论中最重要的随机变量的分布律与独立性的 (大样本) 检验。虽然在概率与统计等方向学者们几百年的研究积累下, 现代概率论与现代统计学的理论已经非常丰富, 发展得比较成熟, 但贴近我们关心的一些更复杂的随机现象的概率建模理论以及对这样的概率模型的检验理论这两个方面仍然可能有待读者们去探索和发展。

正如分析学中极限概念的引入与探讨是初等数学与高等数学之间的分水岭, 我们特地以第十、十一章节作为初等概率论课程的两个收尾章节, 用以介绍在整个概率论中都占据核心地位的两个经典理论与研究范式——大数律和中心极限定理。而第十二章, 最后一个收尾章节, 则可视作我们“概率建模”观点下对数理统计课程和“高等”概率论课程的广告: 除了该章节介绍的模型检验的理论, 更多的对模型的检验问题留待读者在统计学的有关课程中去学习和研究; 但另一方面, 我们也不难看到, 要论证上述 Kolmogorov 定理, 需要随机过程的语言以及泛函中心极限定理等更高端的概率理论, 而在定理12.1.1的证明过程中, 大偏差理论起到了核心的作用。因此这也是对随机过程、大偏差等“高等”概率论课程的广告。

为了全书的相对自封性, 我们还准备了三个附录章节: 附录 A 用来补充探讨全书中因教学安排的原因未能详尽展开的有关单调类定理、乘积 (概率) 测

度的存在唯一性和随机变量相互独立性的刻画定理等的证明细节。附录 B 用来继续讨论在特殊场合能刻画随机变量的分布律的两种统计特征——矩和分布函数/分布测度的 Laplace 变换。附录 C 用来提供前述 Kolmogorov 定理的粗线条的证明框架，其中顺带介绍了泛函中心极限定理等密切相关的内容。

在全书各章编者都配备了相应的习题；这些习题大部分来源于众多参考文献，少部分是自编习题，另有少部分来源于知乎社区等网络渠道¹。考虑到习题的难度以及讲义本身的厚度，对于部分较难（或较有意思）的习题我们在网络上提供参考答案或提示信息，读者可以通过扫描习题章节末的二维码获取该章习题的对应数字电子资源。通常建议读者自行思考一段时间而确无头绪时才去翻看有关参考答案或提示。

全书行文中，除了通常的人物信息方面的注记（我们使用“ 注”标识）和对有关理论结果的注记（我们使用“ 注记”标识）外，书中定理、引理、命题、推论等也各自使用了不同的符号标识，依次为 、、、。在全书的最后，我们还提供了一个基于分类思想（而不是完全基于拼音顺序）的索引。

编者希望全书如此的结构安排和论述方式能够激发初学者学习概率论课程的兴趣与热情，提高学习的效率。当然，这样一来，全书虽有主线，但内容还是比较繁杂的²，对于学生的自学和教师的教学都提出了挑战。本书对学生的数学基础有较高的要求³，相对而言更适合专业方向、特别是已有 Lebesgue 积分理论基础的学生学习。我的建议是：学生初次学习时要学会抓住主线，忽略一些对数学基础要求较高的证明细节，在学习概率论发展历史和概率理论体系的构建方法的过程中去学习、体会和掌握有关理论⁴；在数学基础提高后宜再次学习，补上当初忽略的那些理论细节。对教师的具体授课而言，就需要教师朋友们根据实际需要调整教学内容。这里给出三种教学方案作为参考。方案 A 是基于每周 3 学时、总计约 51 学时的实际教学时间。在此方案下，只重点选择第一章至第九章作为教学内容，其中第四章内容基本跳过，第六、七章内容只做蜻蜓点水式的介绍，但其中数学期望与条件数学期望的计算公式要求初学者记住并逐步学会应用（但暂且忽略相关证明）。方案 B、C 是基于每周 4 学

¹书中全部人物图片、部分其他图片资源也来源于各种网络渠道，在正文的行文中将不再一一注明出处，特此说明并向分享方（万维百科、知乎社区及社区用户等）致谢。

²但这是概率论学科本身特点的一部分，并不是编者以难为学生取乐而故意如此编写讲义。王小波说，“人生在世，就如一本打开的书，我们更希望这本书的主题始终如一，不希望它在中途改变题目”；编者也希望全书没有偏离主题。

³与国内大多数兄弟院校的教学安排不同，大致从 2002 年起，复旦大学数学科学学院的初等概率论课程通常是安排在三年级上学期；那时大多数学生已经修习或正在修习《实变函数》课程，已有一定的 Lebesgue 积分理论的基础。

⁴在一定程度上，正如 John von Neumann (冯·诺依曼; 1903—1957) 所言, “In mathematics you don’t understand things, you just get used to them.”

表 1: 课程的三种参考教学方案（表格中数据是大致教学时长安排）

课程章节	方案 A 3 学时/周，约 17 周	方案 B 4 学时/周，约 16 周	方案 C 5 学时/周，约 16 周
第一、二章	7	6	6
第三章	10	9	9
第四章	0	0	2
第五章	8	8	8
第六、七章	4	6	8
第八章	10	9	10
第九章	4	6	7
第十章	0	4	8
第十一章	0	6	10
习题课	8	10	12
总计	51	64	80

时或 5 学时、总计约 64 学时或 80 学时的实际教学时间。此两方案是在前一方案的基础上简略介绍第四章内容，并继续讲述第十、十一章的内容。三种方案下，第十二章的大部分内容通常都不专门讲述，留给学生们自行探索；表1给出了三种方案对应的参考教学时长安排。在编者自己的实际教学中，英才班的教学大致对应于方案 C¹；此时，第四章内容虽然也不专门讲述，但其中几个分析学中的大结果，如 Levi 单调收敛定理、Fatou 引理、Lebesgue 控制收敛定理，特别是 Fubini 定理，在概率论框架下重新陈述于第六章，并穿插于有关概率问题中展示其应用，让学生们在概率论的应用中熟悉和掌握这些大结果；其他一些章节（如第七、九、十、十一章）的内容也是根据课程时间进度和学生们的讲义内容的掌握情况有所筛选地进行课程的讲授的。全书中的例题在授课过程中亦是如此处理的。由于全书内容丰富，考虑到教学时长的限制，建议教师施行 PPT 结合板书教学的策略，以节约教学时间。编者认为，本讲义的第一到九章的内容（其中第四章可作为概率论初学者的参考阅读章节，不做修读要求）已经覆盖了传统的初等概率论课程中最核心的有关概念与理论，其他章节读者（或教师）可根据实际情况与需要有所选择与侧重地进行修读（或讲授）。因此，应出版社姚莉丽老师的建议，在本篇“前言与导读”的文后我们附上了第一到九章的推荐学习流程图（其中实框推荐选择，虚框代表可选），并在

¹ 编者在 2024 年春季学期的《概率论》课程由于教学总时长限制基本按照方案 A 施行。

第二至十二章的章末均添加了“本章小结与学习建议”，以便更好地服务读者。

很庆幸一路走来获得了一些经济援助，结识了一些尊敬可爱的师友，温暖了内心；因为内心有爱，这才能在如今的教学岗位上做到持续用心与坚守底线。我大学阶段是一名来自农村的贫困生，幸得“晨兴助学金”资助，又得彼时舍友与同学的照顾介绍勤工俭学机会，稍解彼时困顿。彼时的老师们在生活上大多看淡物质享受与物质利益，却又能理解，并在力所能及时，纾解学生们生活中的困苦；在科研上他们重视对未知的探索过程中的严谨与求真、求实；在教学上则一丝不苟、兢兢业业，讲到自己熟悉领域时神采飞扬，与学生的讨论中平等相处。所有这些风貌让我产生了以后要成为这样的教师的冲动。研究生阶段钱敏平教授开朗、乐观的个性感染了作为学生的我，并从她那里学到了“敝帚自珍”，珍视自己于黑暗中摸索出的各种收获；而刘培东教授在指导我论文的过程中表现出来的严谨与细致让我暗下决心，日后亦当如是。钱敏先生则被我自己视作精神教父，其为人、行事及在教育 and 科研上的表现与相关思想时常被我用来回忆观照己身；斯人已逝，唯记忆永存心底，怀念时不时涌现脑海。勇士屠恶龙的童话小说中，勇士成为英雄后由于种种原因成为另一条恶龙；生活中的挫折、苟且多了，你也可能忘记你的诗与远方。我党提出要“不忘初心”；而我也时常心心念念提醒自己，至少不要成长为自己当初厌弃的模样。说实话，走上科研和教育的道路，对于在老家农村的老母及兄姐是有无数歉疚的，因为只能成为一个无法承担更多家庭责任的自了汉了。感恩家人的理解，感恩从事慈善事业的各界人士，感恩一路走来师友的教育、提携、理解与帮助！

讲义中的内容借鉴了众多师长的材料，如我的同学王岩华向我分享的何书元教授的《概率论》PPT 资料，我自己学生时代向钱敏平¹（《概率论》）、陈家鼎（《测度论》）、程士宏（《高等概率论》）等教授学习概率论相关课程的笔记。在复旦的教学过程中较长时期参考了我院同事应坚刚教授的《概率论》（与何萍教授合著），其他参考过的教材资料此处就不一一细说，见参考文献。而浙大的朋友赵敏智老师提供的分享以及与她的相关讨论尤为珍贵。在书稿临近完成时，通过与钱紘教授交流讨论有关学术问题，我获益很多，直接导致了第十二章中第一节内容的出现。我的老师钱敏平教授及我的师兄刘勇教授都为本讲义提出了不少重要的、建设性的修改意见。在本讲义基本定稿前，我特别邀请了戴捷博士帮忙审阅，他的诸多修改建议进一步提升了讲义的严谨性和可读性；在此期间我的同学黄涛教授应我统计学历史方面的咨询，特地为我提供了文献^[21,41,45,50,51,93-95,99]，后续叶华军、曾焰两位老同学也提供了其他一

¹ 本讲义中介绍的概率微元法就是编者基于钱敏平老师所教授的对对应内容进行符号体系改进而来的。

些文献与建议，而其他一些老同学如李稚、毛颖、吴增涛、张昕海等也针对这个讲义给出了让我振奋与鼓舞的评价意见；同事兼好友许明宇在与我讨论中也指出了随机变量的第二种补丁程序，参见第五章；曾经的学生、现在的朋友沈伊南博士以及其他一些专家朋友如李英博士等也曾给出一些修改意见；还有很多朋友指出了草稿中的一些细节性的打印错误等，此处就不一一列出。尽管在咨询有关图片版权问题的过程中未能直接达成预期目标，校友蒋庆军、曾华等为之而做的努力还是让我特别感动；网友 Snorri 也为此向我建议了有关替代解决方案。科学出版社的编辑老师逐字逐句地审校了书稿，提出了更细致的修改建议，其认真负责的态度让我钦佩和感动。特在此向所有这些良师益友致谢！

对于这个讲义来说，如果没有教学的讲台，没有讲台下学生们的宽容与理解，或许它就不会诞生、即使诞生也可能夭折。因此也感谢学院提供了这个教学舞台，感谢迄今为止的多个学期中参加我概率论课程的所有本科生或研究生同学！特别感谢曾经向我提出课程讲义的细致修改意见或有关讨论的多位同学与课程助教（按姓氏字母顺序）：董谨豪、杜心怡、方皓楠、高睿君、管闻捷、李晓宇、厉茗、沈嘉玮、王赢、吴楷彦、谢洪乐、章俊鑫、周瑞松等，抱歉此处由于个人记忆力原因而不完整的名单可能遗漏了一些同学的名字。

虽经多次修改才基本定稿，又经 2022、2023 年两个秋季学期及 2024 年春季学期再次作为讲义¹使用，并在专业编辑的审校意见下得以进一步修饰、润色讲义而形成如今的终稿，本讲义无疑仍然会包含一些疏漏或不当之处，敬请各位同学、同行与朋友持续批评指正；也欢迎你们提出建议，分享有关有趣的案例资料等，以利适当机会继续修订²。

在本讲义的概率建模观点下，概率论中的 Glivenko-Cantelli 定理、Kolmogorov 定理、Pearson 定理、Pearson-Fisher 定理和 Lanford 定理等告诉我们，尽管我们对世界的探索与认知是盲人摸象的模式，但最终我们人类能贴近世界的真相。由此，在编者看来，我们的讲义，甚至整个概率统计学科都可视为 Hilbert 名言“我们必须知道，我们必将知道”的完美注脚：

Wir müssen wissen. Wir werden wissen!

谨以此作为讲义前言与导读。

谢践生


2024 年 9 月 9 日

复旦大学数学科学学院

¹在此也再次对参加本书编者主讲的 2021—2023 年三个秋季学期概率 H 课程、2024 年春季学期概率论课程的所有同学以及助教表示衷心的感谢！

²关于讲义的批评意见等欢迎发至邮箱：jsxie@fudan.edu.cn。

附：第一至九章学习路径推荐（虚框、虚箭头表示可选内容与路径）¹



¹此处的“学习路径”图片由我的研究生方皓楠帮忙制作，特此感谢！

目录

序	iii
前言与导读	v
附：第一至九章学习路径推荐	xvi
第一章 随机现象与概率论	1
1.1 随机现象、随机事件与随机试验	1
1.2 频率与概率	4
1.3 概率论简史	7
习题 1	19
第二章 从古典概率模型、几何概率模型到概率论的公理	25
2.1 事件与集合	26
2.2 古典概率模型	30
2.2.1 古典概率模型简介	30
2.2.2 计数方法简介	31
2.2.3 古典概率模型应用实例：(1) Pólya 坛子模型	33
2.2.4 古典概率模型应用实例：(2) 同生日问题	35
2.2.5 古典概率模型应用实例：(3) 唱票问题与反射原理	36
2.2.6 古典概率模型应用实例：(4) 图论中的染色问题	38
2.3 几何概率模型	40
2.3.1 几何概率模型简介	40
2.3.2 几何概率模型应用实例	41
2.3.3 Bertrand 悖论	43
2.4 公理化的概率模型及其性质	46
2.4.1 概率的公理	46

2.4.2	概率的基本性质	48
2.4.3	Jordan 公式	49
2.5	本章小结与学习建议	51
习题 2		52
第三章	经典条件概率与事件独立性	63
3.1	条件概率空间与经典条件概率的定义	63
3.2	乘积概率空间与事件独立性	70
3.2.1	乘积概率空间	71
3.2.2	事件独立性的定义	73
3.3	经典条件概率与事件独立性的简单应用	77
3.3.1	应用 1: 乘法公式	77
3.3.2	应用 2: 全概率公式	79
3.3.3	应用 3: Bayes 公式	86
3.3.4	应用 4: (无穷) 重复试验与条件试验	93
3.4	讨论: 事件的概率、条件概率及其概率值大小	97
3.4.1	易混淆概念: 特定语境中的概率与条件概率	97
3.4.2	小概率原理及现实世界与概率(统计)建模之间的接口	98
3.5	本章小结与学习建议	104
习题 3		104
第四章	Lebesgue 积分理论简介	113
4.1	可测集与可测函数	113
4.1.1	Borel 可测集与一般可测集	113
4.1.2	Borel 可测函数与一般的可测映射	114
4.2	Lebesgue 测度与一般可测空间中的非负测度	116
4.2.1	测度、符号测度、预测度与外测度的定义	116
4.2.2	符号测度的 Hahn 分解与 Jordan 分解	119
4.2.3	Carathéodory 扩张与 Lebesgue 测度	122
4.2.4	乘积测度空间	128
4.3	欧氏空间中的 Lebesgue 积分	128
4.3.1	Lebesgue 积分的定义	128
4.3.2	Lebesgue 积分与极限的交换	130
4.3.3	Lebesgue 积分与 Riemann 积分	133
4.3.4	微积分基本定理的探讨	138

4.3.5	重积分与累次积分—Fubini 定理	140
4.4	抽象测度的 Lebesgue 积分	142
4.4.1	抽象测度的 Lebesgue 积分的定义	142
4.4.2	抽象测度的 Lebesgue 积分的极限交换问题	143
4.4.3	微积分基本定理的推广: Radon-Nikodym 定理	144
4.5	本章小结与学习建议	148
习题 4		148
第五章	随机变量及其分布律 (I)	151
5.1	随机变量、随机向量及其分布律	152
5.1.1	随机变量与随机向量的定义	152
5.1.2	随机变量与随机向量的分布律	156
5.1.3	随机变量/向量之间的相互独立性	158
5.2	离散型分布	161
5.2.1	离散型随机变量的定义	161
5.2.2	常见离散型分布	162
5.3	离散型分布的应用	167
5.3.1	应用 (I): 真假随机性的判断	167
5.3.2	应用 (II): 两个极大似然估计的例子	170
5.4	本章小结与学习建议	171
习题 5		172
第六章	数学期望与分布律	177
6.1	数学期望的定义	177
6.2	数学期望的性质与简单应用	183
6.2.1	数学期望的基本性质及有关极限交换定理	183
6.2.2	常见数学期望不等式	184
6.2.3	数学期望的简单应用	186
6.3	基于分布律的数学期望计算公式	189
6.3.1	数学期望的计算公式 (I)	189
6.3.2	概率空间的同态、同构及其应用	192
6.3.3	数学期望的计算公式 (II)	196
6.4	矩与无偏估计	197
6.4.1	方差、协方差与独立性	197
6.4.2	统计量与无偏估计简介	199

6.5 本章小结与学习建议	201
习题 6	201
第七章 条件数学期望与条件分布律	209
7.1 条件数学期望的定义	209
7.1.1 数学期望的一个性质	210
7.1.2 从经典条件概率到经典条件数学期望	211
7.1.3 抽象的条件数学期望的定义	213
7.1.4 从条件数学期望 $\mathbb{E}[\cdot \mathcal{G}]$ 到条件概率 $\mathbb{P}(\cdot \mathcal{G})$	217
7.2 条件数学期望的基本性质与常见不等式	218
7.2.1 条件数学期望的基本性质	218
7.2.2 条件数学期望的常见不等式	220
7.3 条件数学期望的计算	221
7.3.1 条件数学期望的积分变换公式	221
7.3.2 条件分布律与条件数学期望的计算公式	222
7.3.3 条件数学期望与独立性	227
7.4 条件数学期望的应用	229
7.5 本章小结与学习建议	231
习题 7	232
第八章 随机变量及其分布律 (II)	235
8.1 连续型随机变量的有关基本概念	235
8.1.1 连续型分布与密度函数的定义	235
8.1.2 连续型随机变量的数学期望计算公式	237
8.1.3 边缘密度、条件密度与条件分布函数	238
8.2 概率微元法	240
8.2.1 光滑可逆变换情形	240
8.2.2 分片光滑可逆变换情形	241
8.3 常见连续型分布	243
8.4 本章小结与学习建议	259
习题 8	259
第九章 随机变量及其分布律 (III)	265
9.1 分布函数的刻画与随机数发生器的构造	265
9.1.1 分布函数的刻画	265

9.1.2 随机数发生器的构造	267
9.2 次序统计量	270
9.3 阅读材料: 随机变量的分类	273
9.4 本章小结与学习建议	275
习题 9	276
第十章 随机变量列的收敛与大数律	283
10.1 Chebyshev 不等式	283
10.2 随机变量列的收敛性	286
10.2.1 各种收敛性的定义	286
10.2.2 几种收敛之间的关系	287
10.2.3 阅读材料: 随机序与随机控制收敛定理	291
10.3 大数律简介	293
10.3.1 Borel-Cantelli 第一、第二引理	293
10.3.2 从 Bernoulli 弱大数律到 Borel 强大数律	301
10.3.3 从 Khintchine 弱大数律到 Kolmogorov 强大数律	304
10.3.4 在二阶矩条件下 Kolmogorov 强大数律的加强	308
10.4 应用举例	309
10.5 本章小结与学习建议	314
习题 10	314
第十一章 特征函数及其应用	325
11.1 特征函数与分布测度	325
11.2 特征函数的三大定理	328
11.2.1 特征函数的唯一性定理	329
11.2.2 特征函数的连续性定理	332
11.2.3 特征函数的刻画定理	336
11.3 特征函数的几个重要应用	337
11.3.1 应用 1: Khintchine 弱大数律	337
11.3.2 应用 2: 中心极限定理	338
11.3.3 应用 3: 随机变量的对称化方法简介	342
11.4 本章小结与学习建议	344
习题 11	344

第十二章 概率建模的有关讨论与检验	353
12.1 概率论视角下的“经验总结与外推”	354
12.1.1 关于赌徒谬与热手效应的讨论	354
12.1.2 Gibbs 分布与 Gibbs 条件概率	357
12.2 大样本数据下模型的检验问题	363
12.2.1 对（一维）简单样本总体分布律的检验	363
12.2.2 对（“二维”简单样本总体两维度间）独立性的检验	367
12.3 本章小结与学习建议	373
习题 12	374
附录 A 单调类定理与乘积概率测度的存在唯一性及其应用	377
A.1 集合类简介	377
A.2 单调类定理	380
A.3 乘积概率测度的存在唯一性	381
A.3.1 概率测度的有限乘积	381
A.3.2 概率测度的可列无穷乘积	383
A.3.3 概率测度的任意无穷乘积	387
A.4 随机变量相互独立性的刻画定理的补充证明	388
习题 A	388
附录 B 矩问题与 Laplace 变换	389
B.1 矩问题	389
B.1.1 Hausdorff 矩问题	390
B.1.2 Hamburger 矩问题：可解的条件	390
B.1.3 Hamburger 矩问题：解的唯一性与不唯一性	392
B.1.4 矩问题有关理论的应用	394
B.2 Laplace 变换	395
B.2.1 Laplace 变换的定义与基本性质	395
B.2.2 Laplace 变换的唯一性定理	398
B.2.3 Laplace 变换的连续性定理	399
B.2.4 Laplace 变换的刻画定理	399
B.2.5 Laplace 变换的 Tauber 定理	400
习题 B	404

附录 C Kolmogorov 定理的“证明”	407
C.1 Brown 运动、Brown 桥及其特征函数刻画	407
C.2 概率测度的弱收敛与泛函中心极限定理	409
C.2.1 欧氏空间与一般度量空间中概率测度的弱收敛	409
C.2.2 相对紧与胎紧: Prokhorov 定理	411
C.2.3 泛函中心极限定理	412
C.3 Kolmogorov 定理的“证明”	413
习题 C	415
参考文献	415

第一章 随机现象与概率论

现代人衣食住行的方方面面充斥着“概率”、“几率”、“机会”、“把握”、“可能性”、“随机”等字眼。每天早晨起床，天气预报会告知你，今天是晴天还是阴天，降水**概率**是多少；学生们期末考试后会估计自己获得 A 类成绩的**几率**有多大；求职的时候，人们也会估计自己被录用的**机会**有多大，是否有较高**把握**获得高薪岗位？在农作物收获前，农民们有时会提前估计自己农田高产的**可能性**有多高。走在大街上，当你和朋友不知道去哪家饭店吃饭时，你可能会掏出一枚硬币，让它“**随机**”地为你挑选一家。我们自然语言中的“概率”、“几率”、“机会”、“把握”、“可能性”等通常认为是同义词¹，而“随机”则认为是“确定”的反义词。那么到底什么是概率，什么是随机？在本章，我们无法完整回答这个问题；但我们希望学完本书，读者对此问题已有自己的答案与体悟。

几乎所有的概率论教科书都告诉我们，概率论是研究随机现象的数量规律的数学分支学科。那么什么是随机现象？我们通常所说的某个随机事件发生的概率又是什么含义呢？

1.1 随机现象、随机事件与随机试验

在自然界和社会生活中，我们经常遇到两类现象：一类是确定性现象，它的结果是单一而确定的；一类是不确定性现象，它的结果是不唯一的，并且通常每种结果都有可能发生。

例 1.1. 以下一些现象或事件是确定的（即一定发生或一定不发生）：

- （在地球上观察）太阳东升西落；
- （地球上的）学校操场上向上抛出的帽子最终会掉落；

¹在英文、法文等外语中，“probability”（概率，法文是“probabilité”）一词的拉丁词根是“probare”和“habilis”；前者的意思是“去试验、去证明”，或者是“去批准”，后者表示“才能、技术和能力”。在后来的使用中，“probable”一词才渐渐有了“可能的、合理的”这一层意思，这才跟随机性产生了联系。

- (地球上, 1 个标准大气压下) 25°C 的纯水持续冷却到 0°C 时会结冰, 持续加热到 100°C 时会沸腾。

以下一些现象或事件是不确定的 (即不一定发生, 也不一定不发生, 具有偶然性或随机性):

- 打靶, 击中靶心;
- 抛掷一枚硬币, 有头像的一面 (正面) 朝上;
- 买本期中国福利彩票, 中特等奖;
- 昨收盘买入一只股票, 今日收盘涨停。

我们所关心的随机现象通常可以认为来自于某个“随机试验”。在概率论中, 为了通过数学建模来研究所关心的随机现象, 我们对随机试验及其试验结果做了一些理想化的抽象处理, 即认为: 随机试验具有可重复性; 随机试验的一个可能的“试验结果”称为“基本结果”¹, 而所谓的随机现象则是“基本结果”的一种分类结果 (亦即若干“基本结果”所成集合). 具体来说, 随机试验是针对某一随机现象所做试验的统称, 我们要求它具有如下三个特点:

- ◆ 随机试验的所有可能的“基本结果”是试验之前就己知的, 并且全部可能的“基本结果”的总数 ≥ 2 ;
- ◆ 在进行一次随机试验之前无法预知该次试验的“基本结果”, 亦即试验之前不确定该次试验完成时会出现哪一个试验结果;
- ◆ 在相同条件下随机试验可重复进行, 且前后多次随机试验的“基本结果”之间是互不影响、没有关联性。

因此, 所有可能的“基本结果”未知的试验不是我们的概率论课程中讨论的“随机试验”; 所有可能的“基本结果”已知, 但只有唯一“基本结果” (从而是确定性) 的试验也不是我们的概率论课程中讨论的“随机试验”。

在初等概率论的教学中, 特别在本讲义中, 我们将经常提起如下三种典型的随机试验 (以及由它们的类似物组合而成的复合随机试验): ²

- (1) “抛掷一枚 (均匀) 硬币一次, 记录所获得的硬币朝上面的信息”的随机试验; 它的“基本结果”只有两个: ³有“头像”的一面 (称为“正面”) 朝上、无“头像”的一面 (称为“反面”) 朝上。

¹此处, “基本结果”是更底层、更基本、能用来清晰地描述所关心的随机现象的 (抽象的) “试验结果”。

²请读者思考此处这些随机试验中的理想化假设可能有哪些?

³我国央行发行的硬币正面通常是阿拉伯数字与汉字标明的面值信息, 反面则是花卉图案, 见图1.1.

- (2) “投掷一枚（均匀）骰子一次，记录所获得的骰子点数”的随机试验；它的“基本结果”则有六个：出现点数 1、2、3、4、5、6 这六种情况之一。
- (3) “从 b 个黑球、 r 个红球的坛子中摸出一个球”的随机试验。它的“基本结果”就更复杂些：如果认为这些球带有编号，比如 1 至 b 号球是黑球， $b+1$ 至 $b+r$ 号球是红球，并且试验中记录球的编号（由此而获知球的颜色），则可认为“基本结果”是摸出球的编号，共有 $b+r$ 种；如果认为这些球除了颜色之外是不可区分的，且摸出的球只能记录颜色这个信息，则这个随机试验的“基本结果”只有两个¹：“黑球”、“红球”。

本讲义将基于概率建模的观点来阐述有关概率理论。这里，一个**随机试验**就可建模成一种**概率模型**，亦即后文中将介绍的**概率空间**：通常，随机试验的“基本结果”的全体被建模成**样本空间**，一个“基本结果”也建模成样本空间中的一个点（称为**样本点**）；而随机试验中的**随机事件**或**随机现象**则对应于概率空间中特定的集合（有时也直接称为**事件**）。从上面的论述中我们也清晰地看到，在概率建模中如何选择“基本结果”的表示，既与实际问题中关心的随机现象或随机事件有关，更与随机试验本身对应的概率模型的模型假设有关；为了借助概率建模在理论上完备地刻画一个随机试验，我们在不同模型假设下的概率建模完全可能对应于不同的“基本结果”表示。在第二章我们将对此展开详细论述。

在自然语言中，我们有时会把“**（随机）现象**”和“**事件**”作为同义词而不加区分；但通常我们认为“现象”是可能重复发生/出现的，而很多时候有些事件（比如同一个人类个体的出生、初恋、第一次结婚、死亡）是不可能重复发生的，重复发生的其实仅仅是其中的某种特定现象（比如同一个人类个体的恋爱、结婚或不同个体的出生、恋爱、结婚、死亡）。因此，在本书中，为了精确地研究随机现象、随机事件，我们在对有关随机试验进行概率建模时，对“现象”与“事件”两个术语会略作区分：在同一个概率模型中，“现象”与“事件”在不引起歧义时不做区分；但在两个不同又互相关联的概率模型（其中一个概率模型认为是另一个的子概率模型）中，有时我们会把其中“小”模型中的 A 事件在另一个“大”的模型中说成是 A 现象；而观测到某特定现象就认为对应的特定事件发生了。

例 1.2. 在投掷一枚（均匀）硬币一次的随机试验（称为“单次试验”）中，考虑获得硬币正面这个事件/现象 A ；在重复投掷这枚硬币 n 次的“复合试验”（称为“ n 次重复试验”）中就应把 A 事件看成是 A 现象。这时可以讨论：

¹当 $b \neq r$ 时，此处对应随机试验不满足等可能性假设。

- (1) A 现象在 n 次重复试验中总共发生了/观察到多少次?
- (2) A 现象在 n 次重复试验中总共发生了/观察到 k 次的可能性有多大?
- (3) 在无穷次重复试验中, 如果 A 现象发生了, 最早发生/观察到该现象的那次试验是第几次?
- (4) 在无穷次重复试验中, 为了获得首次 A 现象的发生/观察, 平均而言需要做多少次重复试验?

使用概率论的术语, 我们知道: 上述第一、第三个问题各定义了一个“随机变量”; 第二个问题问的是第一个“随机变量”的具体取值概率; 第四个问题问的是第二个“随机变量”的“数学期望”(自然语言中的“平均值”). 对于上述这些涉及的概念, 我们将逐步在数学上予以精确的定义, 见第五、六章; 而为了很自然地实现重复试验这类“复合试验”的概率建模, 我们也不得不在讲义中介绍“概率空间的乘积”这一技术手段(见第三章). 这样的处理在现存的国内外初等概率论教材中是不多见的, 但显然又是非常自然的选择.

例 1.3. 除了例 1.2 中提到的硬币(参见图 1.1), 日常生活中用于产生随机性的道具还有骰子(参见图 1.2)、扑克牌(参见图 1.3)等.



图 1.1: 硬币



图 1.2: 六枚骰子



图 1.3: 一副扑克牌

1.2 频率与概率

在中文词汇中, “机会”、“几率”、“把握”、“概率”等都是“可能性”的同义词. 而“可能性”高或低的判断, 很多时候是人对同样条件下某种(可重复发生的)现象可能发生的频繁程度的主观感受, 其中可能包含了他/她对此现象所收集的一些客观数据与经验. 这个主观感受里面包含的客观数据与正确经验越多, 判断所依据的推理理论越有严谨逻辑, 则所下的判断就越准确、可

靠；反之，主观感受中主观情绪等占比越多，错误经验越多，判断的准确性与可靠性就越差。这也是赌徒谬误、幸存者偏差等诸多影响判断准确性的错误认知时有发生的原因。而本课程的学习将有助于在占有相同（甚至更少¹）的已有数据的基础上²，通过严谨的推理，形成更正确的直觉（经验），得到更准确、可靠的判断，从而减少不必要的错误认知，进而减少不必要的损失或人际、社会冲突。



图 1.4: 随机事件的概率的粗略解释

从认知上来讲，关于某事件中可反复观察到的客观现象发生可能性高低的判断，如果没有其他理论指导，人通常是通过已经累积的历史事实（可能是个人的积累，也可能是他人的积累等），先感受、总结这类现象发生的频繁程度（精确地数量化后，称为频率，它是所观察现象的实际发生次数与实际观察次数的比值），之后再据此判定具体某事中该现象发生的可能性高低。此处，这个可能性高低程度的数量化，在本课程中就称为**概率**：有些事件是一定会发生的，我们称它们是**必然事件**，说它们发生的概率为 1；有些事件是不可能发生的，我们称它们是不可可能事件，说它们发生的概率为 0。其余一些事件在量度它们发生的可能性大小时，就让它们的概率取值介于 0 与 1 之间：事件发生的可能性越高，其概率值就越靠近 1；事件发生的可能性越低，其概率值就越靠近 0。必然事件和不可能事件有时又称为**确定性事件**；其余事件通常称为（狭义的）**随机事件**（或**随机现象**）；广义的随机事件也包含确定性事件。

¹统计学有关理论的应用有助于更准确、有效地收集和分析数据。历史上一个著名的案例是 1936 年关于美国总统大选的预测：当时，George Gallup（盖洛普，1901—1984）基于美籍波兰裔统计学家 Jerzy Neyman（内曼，1894—1981）发展的结合了分层抽样与目的选择的统计抽样方法，仅通过 3000 份民意调查问卷就成功地预测到富兰克林·罗斯福会再次当选，而《文学文摘》在 1000 万份民意调查问卷的基础上做出的预期却是阿尔弗雷德·兰登将击败罗斯福当选总统。

²此处，我们特意提一下：在概率论与数理统计学两个学科发展的初期，二者的发展是并轨、甚至混为一体的（一个辅助证据是文献^[50]的标题与内容）；甚至近现代的统计学专家，例如后文第十二章中将提及的 Ronald A. Fisher（费雪；1890—1962；英国）、Jerzy Neyman、W. G. Cochran（科克伦）等，一般也是概率学专家，反之亦然；当今的两本学术期刊，概率年刊（Annals of Probability）和统计年刊（Annals of Statistics），就是在 1973 年由数理统计年刊（Annals of Mathematical Statistics）分拆而来。目前通常认为概率论是数理统计学的重要基础。

对于可以重复发生的某些随机现象/事件，比如抛掷单枚硬币时出现“正面朝上”，人们能够且已经通过随机试验的方式累积了很多次试验的历史数据；但这些现象发生的概率值在理论上通常仍然是未知且难以精确计算的，在实际应用中人们就经常采用以频率代概率的办法来估计它。这样做的一个原因就是，人们在实验次数足够多的重复试验中经常观察到（或感受到）一种关于试验数据的特定性质——“频率稳定性”现象。这一现象后来被 Bernoulli 通过概率建模给予了严格的数学证明，见下例中论述。

例 1.4. *Jacob Bernoulli*¹（雅各布·伯努利，1654—1705；瑞士，原籍比利时）是第一个理论上证明了“频率稳定性”现象的数学家。借用投掷硬币的重复试验模型的语言可陈述如下：设单次投掷硬币时，正面朝上这一事件 A 发生（也称此时试验成功）的概率为 $p_A = \mathbb{P}(A)$ ，记 n 次重复投掷硬币的试验中总共获得了 n_A 次正面，则此 n 次重复试验成功的频率为 $f_n(A) := n_A/n$ ，它满足：

$$\lim_{n \rightarrow \infty} f_n(A) = p_A.$$

上式中收敛的精确数学含义是依概率收敛，此概念将在本讲义第十章中介绍。

历史上有不少数学家进行过投掷硬币的试验，见表 1.1；需要注意的是，这些不同试验者投掷的显然是不同的硬币，其物理特性（材质的均匀性）存在细微差别，数据间不太具有直接可比性，因此表格中数据只有一定的参考价值。

表 1.1: 历史上一些著名的投掷硬币的试验

试验者	投币次数	正面次数	反面次数	正面频率
G. Buffon (1701—1788; 法国)	4040	2048	1992	50.69 %
De Morgan (1806—1871; 印度/英国)	2048	1061	987	51.81 %
De Morgan	4092	2048	2044	50.05 %
Karl Pearson (1857—1936; 英国)	12000	6019	5981	50.16 %
Karl Pearson	24000	12012	11988	50.05 %
Romanovsky (1879—1954; 苏联)	80640	39699	40941	49.23 %
W. Feller (1906—1970; 美籍克罗地亚裔)	10000	4979	5021	49.79 %
Vini	30000	14994	15006	49.98 %

Bernoulli 证明的“频率稳定性”被称为 **Bernoulli (弱) 大数律**，它是概率论中第一个极限定理。在很长时期内，这被认为是概率的一种古典解释（称为

¹在一些文献中，Jacob Bernoulli 也经常被写作 Jakob Bernoulli.

“频率解释”¹⁾，甚至在早期的一些概率论教材中作为概率的定义。在统计学中，这个大数律派生出了信奉大样本理论的频率学派。

法国数学家 H. Poincaré (庞加莱, 1854—1912) 说过, “若想预见数学的将来, 正确的方法是研究它的历史和现状。”秉承此理念, 接下来我们拟简单介绍概率论的发展历史²⁾。

1.3 概率论简史

从人类起源开始, 人们无时无刻需要面对和处理随机现象、甚至利用随机现象做决策。远古时期的人类就有利用动物的跖骨、距骨或贝壳、龟壳等道具进行占卜来做决策的记载。文献^[119]告诉我们: 在公元前 3000 年前的美索不达米亚就有所谓的“20 方块”的随机游戏 (又称为“乌尔的国王游戏”); 公元前 2000 多年的埃及古墓中, 已有正立方体的骰子。在 Aristotle (亚里士多德, 公元前 384—前 322; 古希腊) 时代, 人们已经认识到随机性/不确定性在客观世界中的普遍性。然而, 一方面, 由于技术上的障碍, 这些古代的道具, 也就是现代科学观点下的“随机数发生器”, 材质上通常不是充分均匀和对称的, 从而人们难以通过观察和累积使用这类道具的试验数据而得出科学的统计规律; 更重要的是另一方面, 由于观念上的制约, 古人经常把偶然的结果 (随机结果) 归结为“神的意志”, 于是很自然不相信这些随机结果可能是完全的偶然、进而放弃寻找随机事件发生的稳定频率等科学规律。

直到 15、16 世纪前后, 由于科技的发展、观念的进步以及现实问题的实际需求, 人们才开始定量地研究随机性/不确定性, 并尝试从中发现客观规律。历经几个世纪学者们的探索, 特别是 20 世纪在数学公理化的潮流下, 概率论发展成为一门严谨的数学分支学科。1926 年玻恩³⁾对薛定谔⁴⁾方程中波函数的概

¹⁾除了“频率解释”, 历史上对概率还有基于等可能性假设的古典解释 (通常也视作“客观概率解释”) 以及基于信念的“主观概率解释”等; 本讲义不特意强调这些解释。对这些概率解释感兴趣的读者可以参见文献^[25]的 Sect. 1.2 或文献^[27]等。

²⁾由于我们的讲义定位为初等概率论教材, 虽然也涉及部分统计理论, 统计学的发展历史等的简略论述就置于讲义正文末章第十二章的最后两个注记中, 更多、更详细的统计学的发展历史介绍就留给读者从一些专业的统计类书籍文献中去探索。

³⁾Max Born (玻恩, 1882—1970) 是德国犹太裔理论物理学家、量子力学奠基人之一, 因对量子力学的基础性研究尤其是对波函数的概率诠释而获得 1954 年的诺贝尔物理学奖。

⁴⁾Erwin Schrödinger (薛定谔, 1887—1961) 是奥地利物理学家, 量子力学奠基人之一, 他还发展了分子生物学。他因发展了原子理论, 和 Paul Dirac (狄拉克, 1902—1984; 英国) 共获 1933 年诺贝尔物理学奖, 又于 1937 年荣获马克斯·普朗克奖章。

率诠释¹被物理学界接受后,改变了人们自牛顿力学建立以来长期形成的确定性认知观念和思维方式,随机的思想逐渐盛行;特别是1933年Kolmogorov完成概率论的公理化以后,概率论得到蓬勃发展和广泛应用,并逐渐走向成熟。时至今日,概率论已成为人们在探索未知世界(自然世界、人文社会,乃至精神世界)奥秘时非常有必要掌握的精确数学建模语言与锋利分析工具。

回顾学科发展历史,根据有关文献资料,概率论的发展大致可以分为以下5个阶段(此处的阶段划分纯属编者的个人观点,与大多数文献的分法不完全相同):

概率论的萌芽时期(15世纪到1654年前) 这一时期,环地中海地带商业往来频繁;概率论的萌芽在当时的经济强国意大利发端,代表性人物有L. Pacioli(帕乔利,1447—1517;意大利)、G. Cardano(卡尔丹诺,1501—1576;意大利)、Galileo Galilei(伽利略,1564—1642;意大利)等。

我们知道,在14世纪到17世纪的欧洲发生了一场反映新兴资产阶级要求的思想文化运动,史称“文艺复兴”,它是西欧近代三大思想解放运动(文艺复兴、宗教改革与启蒙运动)之一;文艺复兴最先在意大利各城邦兴起,以后扩展到西欧各国,于16世纪达到顶峰,带来一段科学与艺术的革命时期,揭开了近代欧洲历史的序幕,被认为是中古时代与近代的分界。

根据史料记载,1494年Pacioli在威尼斯出版《算术书》²,其中提出所谓的“赌金分配问题”:两人决定赌博若干局,事先约定谁先赢得6局便算赢家,赢家获得全部赌金。如果在一个人赢5局,另一个人赢3局³时因故终止赌博,应如何分配赌金才合理?Pacioli给出的答案是按照5:3分;这个答案引起诸多争议。

半个多世纪后,Cardano潜心研究赌博不输的方法,1564年左右写了《赌博之书》⁴,在书中他提出:投掷两枚骰子,以点数和的猜测准确与否作输赢,那么压几点的赢面最大?Cardano认为7点最好;他对“赌金分配问题”也进行了讨论,给出了正确思路,但未能给出正确答案。书中论证了把几率定义为有利结局数目与不利结局数目之比的功效,为后来概率的古典定义做了铺垫。

Galileo考虑了投掷三枚骰子的问题,计算出点数和10、11出现的机会相同,均有27种情形导致该点数和;点数和9则有25种情形导致该结果。

¹但需要着重指出的是,尽管某种意义上微观的量子世界具有天然的不确定性,本课程的概率理论并不探究这种量子不确定性。事实上,量子世界的概率理论还在发展中;对此感兴趣的读者可以在P. Whittle的著作^[100]的Chapter 20中找到相关简短讨论,亦可查阅以非交换概率论(non-commutative probability theory)为相关主题的更现代文献。

²即 *Summa de arithmetica, geometria: Proportioni et proportionalita.*

³也有文献说,另一人赢2局。

⁴即 *Liber de ludo aleae*, 1663年才正式出版。

这一时期的概率论研究通常以数据统计为主要手段，主要研究保险、赌博、占卜等实际问题。



图 1.5: Pacioli(1447-1517)



图 1.6: Cardano(1501-1576)



图 1.7: Galileo(1564-1642)

古典概率论形成时期（1654—1713） 一般认为，作为一门学科的概率论诞生于 17 世纪中叶，标志性的事件是 B. Pascal（帕斯卡，1623—1662；法国）和 P. de Fermat（费马，1601—1665；法国）在 1654 年左右关于赌徒分配赌金问题（亦即“**赌金分配问题**”¹）的若干次通信讨论²；而最初向 Pascal 提出这个问题的原名 Antoine Gombaud 的赌徒、业余数学家 Chevalier de Méré（1607—1684；法国）也因此而留名史册。在他们的讨论中，虽未明确给出概率的定义，但明确了赌徒获胜的机会是赢的情况数与所有可能情况数的比例，用多种方法对“赌金分配”问题给出了正确解答。

1655 年秋在巴黎游学的青年 C. Huygens（惠更斯，1629—1695；荷兰数学家、物理学家）听说他们的讨论后，也开始做与之相关的一些研究；他通过朋友与 Fermat 在 1656 年建立通信联系，并在 1657 年发表《论赌博中的计算》³，书中第一次给出了加法定理、乘法定理以及数学期望的定义（由此暗含概率的古典定义）。该书一经出版，立即得到学术界的认可与重视，在欧洲作为概率论的标准教材长达 50 余年。

1713 年，J. Bernoulli（雅各布·伯努利，1655—1705；瑞士）的遗著《猜度术》⁴在他大侄子 Nicolaus I Bernoulli（尼古拉一世·伯努利，1687—1759；瑞士）的帮助下得以出版。其中 J. Bernoulli 建立了概率论中第一个极限结果——Bernoulli(弱)大数律；由此他认为，事件的**概率**应该定义为事件发生的**极限频**

¹Pascal 和 Fermat 讨论了两个问题，一个称为 Problem of dice，一个称为 Problem of points（亦即赌金分配问题）。后一问题的实际讨论版本为：两个赌徒一者胜 3 局，一者胜 1 局；约定谁先赢满 5 局谁获得全部赌金。问因不可抗力停止赌博后应如何公平地分配赌金？

²Pascal 向 Fermat 发的第一封信已经遗失；其余通信记录参见文献^[27]中提供的网络链接 <https://www.york.ac.uk/depts/maths/histstat/pascal.pdf>。

³即 *Tractatus de ratiociniis in aleae ludo*（1692 年被 John Arbuthnot 译成英文 *Of the Laws of Chance*）。

⁴即 *Ars Conjectandi*。最近的英文译本为 2006 年 Edith Dudley Sylla 翻译加注的 *The Art of Conjecturing*。

率。《猜度术》的出版，是把概率论建立在稳固的数学基础上的首次尝试，标志着概率论成为一门独立的数学分支学科，因此 J. Bernoulli 也成为公认的概率论的奠基人。

这一时期的概率学家们主要研究离散型随机变量，研究手段以排列组合方法为主。

注 1.1. Blaise Pascal (帕斯卡, 1623—1662) 生于克莱蒙费朗 (Clermont-Ferrand)、卒于巴黎, 法国数学家、物理学家、哲学家、散文家。他有两个姐姐, 大姐 Gilberte、二姐 Jacqueline。他父亲是一个小贵族, 1631 年之前担任克莱蒙费朗的地方法官的职务、1639 年担任鲁昂 (Rouen) 税务局局长, 是一位数学家 (发现了 Pascal 螺线) 和拉丁语学者。Pascal 从小体质虚弱, 四岁丧母, 五年后老 Pascal 辞去了法官职务 (实际上是出售该职位, 所得收入共 65,665 磅投资于国家债券, 但到 1638 年政府违约, 财富缩水为不超过 7,300 磅), 全家搬到巴黎。由于发现自己的几个孩子 (特别是 B. Pascal) 都很聪明, 老 Pascal 亲自对他们进行教育, 并经常带小 Pascal 参加巴黎的科学家集会 (特别是“梅森学院”的沙龙活动) 以开阔眼界。此时的 Pascal 也在数学上表现出很高的天赋, 11 岁时就写了一篇关于振动与声音的关系的文章, 这使得他的父亲担心儿子对数学的投入会影响希腊语和拉丁文的学习, 于是禁止他在 15 岁前学习数学。一天, 他父亲发现 Pascal (当时 12 岁) 用一块煤在墙上独立证明三角形各角和等于两个直角; 从那时起, Pascal 被允许学习 Euclid 几何。他 16 岁时发现著名的 Pascal 六边形定理: 内接于一条二次曲线的六边形的三对边的交点共线; 17 岁时写成《圆锥曲线论》(1640 年); 1642 年为减轻父亲在税务计算上的劳动, 他设计并制作了一台能自动进位的加减法计算装置, 被认为是世界上第一台数字计算器, 为以后的计算机设计提供了基本原理。1654 年他开始研究几个方面的数学问题: 在无穷小分析上深入探讨了不可分原理, 得出求不同曲线所围面积和重心的一般方法, 并以积分学的原理解决了摆线问题, 于 1658 年完成《论摆线》; 他计算了三角函数和正切的积分, 最早引入了椭圆积分。他的论文手稿对 G. Leibniz (莱布尼茨, 1646—1716; 德国) 建立微积分学有很大启发。在研究二项式系数性质时, 写成《算术三角形》向巴黎科学院提交, 后收入他的全集, 并于 1665 年发表; 其中给出的二项式系数展开后人称为“帕斯卡三角形” (在我国称“杨辉三角形”或“贾宪三角”)。在与 Fermat 的通信中讨论赌金分配问题, 对早期概率论的发展颇有影响。他还制作了水银气压计 (1646 年), 写了液体平衡、空气的重量和密度等方向的论文 (1651—1654)。自 1655 年隐居修道院, 写下《思想录》(1658 年) 等经典著作。



图 1.8: Pascal (1623-1662)



图 1.9: Fermat (1601-1665)

Pierre de Fermat (费马, 1601—1665) 生于博蒙德洛马涅 (Beaumont-de-Lomagne)、卒于喀斯特 (Castres)。他是法国律师、业余数学家, 被誉为“业余数学家之王”。他独立于 R. Descartes (笛卡尔, 1596—1650; 法国) 发现了解析几何的基本原理, 1630 年用拉丁文撰写了仅有八页的论文《平面与立体轨迹引论》, 在 Fermat 去世 14 年以后才出版; Descartes 是从运动轨迹来寻找它的方程, 而 Fermat 则是从方程出发来研究运动轨迹的, 这正是解析几何基本原则的两个相对的方面。Fermat 建立了求切线、求极大值和极小值以及定积分的方

法，对微积分做出了重大贡献。*Fermat* 与 *Pascal* 通信讨论赌金分配问题，对概率论发展做出了贡献。他在数论中也有诸多贡献，最著名的是 *Fermat* 的最后定理；在我国一般称为 *Fermat* 大定理，最终由 *A. Wiles*（怀尔斯，1953—；英国）在 1995 年给出了证明。他还在光学中提出最小作用原理，也叫最短时间作用原理。

注 1.2. *Christiaan Huygens*（惠更斯，1629—1695）是荷兰物理学家、天文学家、数学家，生于海牙（*Hague*）、卒于海牙。他是介于 *Galileo Galilei*（伽利略，1564—1642；意大利）与 *Isaac Newton*（牛顿，1643—1727；英国）之间一位重要的物理学先驱，是历史上最著名的物理学家之一，他对力学的发展和光学的研究都有杰出的贡献，在数学和天文学方面也有卓越的成就，是近代自然科学的一位重要开拓者。他建立向心力定律，提出动量守恒原理，并改进了计时器。他在概率论和微积分方面也有成就。



图 1.10: Huygens (1629-1695)



图 1.11: J. Bernoulli (1654-1705)




图 1.12: Bernoulli 家族（不完全）谱系图；蓝底色表示数学家

Jacob Bernoulli（雅各布·伯努利，1654—1705；瑞士，原籍比利时）生于巴塞尔（*Basel*）、卒于巴塞尔，是 *Bernoulli* 家族代表人物之一、该家族第一个数学家，是公认的概率论先驱之一。他在数学上的贡献涉及微积分、微分方程、无穷级数求和、解析几何、概率论以及变分法等领域；他是最早使用极坐标系的数学家之一，积分一词也是 1690 年他首先使用，此外 $e = \lim_{n \rightarrow \infty} (1 + \frac{1}{n})^n$ 也是他发现的。*Bernoulli* 出身于商人世家。他毕业于巴塞尔大学，1671 年获艺术硕士学位，后来遵照父亲的意愿又取得神学硕士学位，但他却不顾父亲的反对，自学了数学和天文学。他在 1678 年、1681 年两次遍游欧洲，这使他接触到当时的许多一流数学家、

科学家,其中包括 *G. W. Leibniz* (莱布尼茨, 1646—1716; 德国); 这丰富了他的知识、拓宽了他的兴趣。1682 年他重返巴塞尔, 开始教授力学; 1687 年成为巴塞尔大学数学教授, 直至逝世。除进行数学研究工作外, 他还广交学友, 所写书信卷帙浩繁, 是当时欧洲科学界一位颇有影响的人物。1699 年, *Bernoulli* 当选为巴黎科学院外籍院士; 1701 年被柏林科学协会 (后为柏林科学院) 接纳为会员。许多数学成果与 *Bernoulli* 的名字相联系。例如悬链线问题 (1690 年)、曲率半径公式 (1694 年)、“*Bernoulli* 双纽线” (1694 年)、“*Bernoulli* 微分方程” (1695 年)、“等周问题” (1700 年) 等。

值得一提的是, *Bernoulli* 家族是一个数学家辈出的家族。除了 *Jacob Bernoulli* 外, 三代 *Bernoulli* 家族共产生了 8 位数学家 (据说在 17—18 世纪期间总共有 11 位)。其中比较著名的还有他的弟弟 *Johann Bernoulli* (约翰·伯努利, 1667—1748)¹ 和侄子 *Daniel Bernoulli* (丹尼尔·伯努利, 1700—1782)。这个家族中还有许多在其他非数学的学术/艺术领域的知名人物。

Jacob Bernoulli 培养的知名学生有: *Johann Bernoulli* (1667—1748; 瑞士), *Jacob Hermann* (赫曼, 1678—1733; 瑞士), *Nicolaus I Bernoulli* (尼古拉一世·伯努利, 1687—1759; 瑞士)。

古典概率论发展时期 (1713—1812) 这一时期, 首先是 *A. de Moivre* (棣莫弗, 1667—1754; 法国-英国) 于 1718 年发表《机遇论》², 首次陈述了独立事件的“乘法定理”, 基于二项分布 $B(n, \frac{1}{2})$, 发现了新的概率极限定理—中心极限定理³, 开辟了概率论的新的研究方向; 书中也明确提出了条件概率的概念, 并为概率论发展了一套较为普遍的符号体系。这本书在概率论发展史上起着承前启后的作用, 为后来 *Laplace* 提出分析概率论做了铺垫。

之后, *T. Bayes* (贝叶斯, 1701—1761; 英国) 在他的两篇遗作 (分别于 1764、1765 年出版) 中给出了著名的 *Bayes* 公式, 提出了 *Bayes* 假设的概念; 如今统计学中的 *Bayes* 方法和 *Bayes* 统计就发源于这个简单的公式中蕴含的思想。

G. Buffon (蒲丰, 1707—1788; 法国) 则提出 *Buffon* 投针问题, 据说发表在 1777 年的著作《偶然性的算术实验》⁴ 中。他的投针试验法可以利用多次随机投针试验算出 π 的近似值, 因此特别引人瞩目; 这也是最早的几何概率问题, 同时这个计算 π 的近似方法也可视作如今的 *Monte-Carlo* 方法的鼻祖。

另外 *Daniel Bernoulli* (丹尼尔·伯努利, 1700—1782; 瑞士) 在 1738 年首次将概率论用于研究人口统计 (天花接种对死亡率的影响); 他还给出了圣彼得堡悖论的一种解决方案。*L. Euler* (欧拉, 1707—1783, 瑞士) 也对机遇游戏的概率计算和超几何级数进行了研究。

这一时期, 随着 *I. Newton* (牛顿, 1643—1727; 英国) 和 *G. W. Leibniz*

¹ *Johann Bernoulli* 的儿子 *Daniel* 和大数学家 *Leonhard Euler* (欧拉, 1707—1783; 瑞士)、*G. de l'Hôpital* (洛必达, 1661—1704; 法国) 等都是 *Johann Bernoulli* 的学生。

² 即 *The Doctrine of Chances*。

³ *Central Limit Theorem* (中心极限定理), 这个英文名词是 *George Pólya* (波利亚, 1887—1985; 美籍匈牙利裔) 第一个提出的, 用以强调 *De Moivre* 及后来的 *Laplace*、*Lyapunov* 等发现的这类概率极限定理在概率论及统计学中的核心地位。

⁴ 在维基百科上说是 *Sur le jeu de franc-carreau* (*On the game of fair-square*), 发表年代约为 1732—1734。

(莱布尼茨, 1646—1716; 德国) 发明的微积分在欧洲的深入传播和广泛使用, 分析的手段也渐渐融入到概率论的研究中, 概率学家们也逐渐开始尝试研究连续型随机变量。

注 1.3. *Abraham de Moivre* (棣莫弗, 1667—1754; 法国-英国) 生于法国香槟-阿登大区的维特里勒弗朗索瓦 (*Vitry le François*), 卒于英国伦敦。1685 年, 棣莫弗与许多信仰新教的教友一道参加了震惊欧洲的宗教骚乱; 在这场骚乱中, 他与许多人一起被监禁起来。正是在这一年, 保护加尔文教徒的南兹敕令被撤销。随后包括棣莫弗在内的许多有才华的学者由法国移居英国。据教会的材料记载, 棣莫弗一直被监禁至 1688 年才获释, 并于当年移居伦敦。但据 20 世纪 60 年代发现的一份当时的材料, 1685 年时棣莫弗已经到了英国。随后棣莫弗一直生活在英国。他对数学的所有贡献全是在英国做出的, 在那里他成为 *Isaac Newton*、*Edmond Halley*、*James Stirling* 等的朋友。他以 *De Moivre* 公式和最早提出中心极限定理以及他的专著《机遇论》而知名。



图 1.13: De Moivre (1667-1754)



图 1.14: Bayes (1701-1761)

Thomas Bayes (贝叶斯, 1701—1761; 英国) 生于伦敦、卒于肯特郡的坦布里奇韦尔斯 (*Tunbridge Wells*)。他 1719 年入学爱丁堡大学, 学习逻辑和神学; 1722 年回到伦敦, 成为时任神父的父亲的手助; 1734 年搬到肯特郡的坦布里奇韦尔斯, 担任 *Mount Sion* 教堂的神父, 直至 1752 年; 1742 年他成为英国皇家学会会员。他是英国神学家、数学家、数理统计学家和哲学家。他在数学方面的主要贡献是, 首创将归纳推理法用于概率的基础理论, 并提出了 *Bayes* 公式; 他对统计推理的主要贡献是使用了“逆概率”这个概念, 并把它作为一种普遍的推理方法提出来。他的这些工作大部分是他死后在 1763 年由 *Richard Price* (1723—1791; 威尔士道德哲学家、新教传教士、数学家) 整理发表在一本书¹中。

Georges-Louis Leclerc Buffon (蒲丰, 1707—1788) 是法国数学家、自然科学家, 生于蒙巴尔 (*Montbard*)、卒于巴黎。他是几何概率的开创者, 并以蒲丰投针问题闻名于世。

Daniel Bernoulli (丹尼尔·伯努利, 1700—1782) 是瑞士数学家、物理学家, *Bernoulli* 家族代表人物之一, 被认为是该家族最著名的数学家之一。他生于荷兰格罗宁根 (*Groningen*)、卒于瑞士的巴塞尔。他是 *Johann Bernoulli* 的儿子, *Jacob Bernoulli* 的侄子; 他有一个哥哥 *Nicolaus II Bernoulli* (尼古拉二世·伯努利, 1695—1726; 瑞士)、一个弟弟 *Johann II Bernoulli* (约翰二世·伯努利, 1710—1790; 瑞士)。Daniel 的父亲最初要求他学习商科、后又要求他学习医科, Daniel 虽然退让了, 但要求他父亲私下亲自教他数学 (最后结果是他父亲和哥哥都教了他数学)。1715 年他入学巴塞尔大学, 后又到海德堡大学 (1718)、斯特拉斯堡大学 (1719) 学习。1721 年获得解剖学和植物学方面的博士学位。1725 年他与他的哥哥在彼得大帝的邀请下到彼得堡科学院工作 (但 8 个月后他哥哥染病发烧, 1726 年去世), 被任命为生理学院士和数学院士; 1727 年, *L. Euler* 在他

¹ 即 *An Essay towards Solving a Problem in the Doctrine of Chances*.



图 1.15: Buffon (1707-1788)



图 1.16: D. Bernoulli (1700-1782)

的导师 *Johann Bernoulli* 的请求下也来到彼得堡科学院工作，成为 *Daniel* 的助手。1733 年 *Daniel* 回到了巴塞尔大学，先任解剖学和植物学教授，后任物理学和哲学教授。1738 年出版著作《流体力学》。1750 年被选为英国皇家学会会员。*Daniel* 的研究工作几乎对当时的数学和物理学的前沿问题都有所涉及，特别突出的是他的数学在力学上的应用（尤其是流体力学）以及他在概率和数理统计领域所做的先驱性工作。

近代分析概率论形成与发展时期（1812—1889） 到 1812 年，P. S. Laplace（拉普拉斯，1749—1827；法国）出版了划时代的巨著《分析概率论》¹，以强有力的分析工具处理概率论的基本内容，使以往零散的结果系统化，实现了从组合技巧向分析方法的过渡，开辟了概率论发展的新时期，标志着分析概率论正式形成。在该书中，Laplace 对一般的独立同分布 Bernoulli 随机变量列证明了 De Moivre-Laplace 中心极限定理，显示了正态分布²的特殊地位。正是在这部书里，Laplace 明确给出了概率的古典定义：事件 A 的概率 $\mathbb{P}(A)$ 等于一次试验中有利于事件 A 的可能结果数与该试验中所有可能结果数之比，以此涵盖古典概率模型和几何概率模型中概率的定义。

之后 S. D. Poisson（泊松，1781—1840；法国）在 1837 年发表著作《关于刑事案件和民事案件审判概率的研究》³。他提出了 Poisson 分布，论证了适当

¹即 *Théorie analytique des probabilités*.

²De Moivre 中心极限定理中就涉及了正态分布；其后历史上^[1]Thomas Simpson、Laplace、Daniel Bernoulli 等人进行了误差分布的理论探索，但直到 1809 年 C. F. Gauss（高斯，1777—1855；德国）才通过形式演算“论证”了正态分布是合理的误差分布，后来 Lyapunov（李雅普诺夫，1857—1918；俄国）进一步论证了正态分布作为误差的极限分布律在通常情形下的普适性（Normality）。特别地，Gauss 在概率统计上最有影响力的贡献是（基于正态分布的）最小二乘法，他在 1801 年把该理论成功应用于天文学，指导德国天文爱好者奥伯斯在 1801 年 12 月 31 日发现了谷神星。由此正态分布有时也称为 Gauss 分布或 Gauss-Laplace 分布，后者还涵盖了一些退化的分布。而正态分布（Normal Distribution）一词的使用据说^[10]源于 Poincaré（庞加莱，1854—1912；法国）的提议，并随着 Karl Pearson 对“正态曲线”（Normal Curve）一词的使用而传播开来。

³即 *Recherches sur la probabilité des jugements en matières criminelles et matière civile*.

条件下二项分布收敛到 Poisson 分布；这个结果当时被称为小数定律¹。另外，他还陈述了 Poisson 大数律。

注 1.4. *Pierre Simon Laplace* (拉普拉斯, 1749—1827) 是法国数学家、物理学家。他生于法国西北部卡尔瓦多斯的博蒙昂诺日 (*Beaumont-en-Auge*)、卒于巴黎。1816 年 *Laplace* 被选为法兰西学院院士, 1817 年任该院院长。1812 年他发表了《分析概率论》一书, 在该书中总结了当时整个概率论的研究, 论述了概率在选举审判调查、气象等方面的应用, 导入“*Laplace* 变换”等。1799—1825 年出版 5 卷 16 册巨著《天体力学》; 在这部著作中第一次提出天体力学这一名词, 是经典天体力学的代表作。因此他被誉为法国的牛顿和天体力学之父。*Laplace* 有一句堪称经典的格言: “生活中最重要的问题, 绝大部分其实只是概率问题”。

Laplace 培养的知名学生有: *S. D. Poisson* (1781—1840; 法国) 和 *Napoleon Bonaparte* (拿破仑·波拿巴, 1769—1821; 法国); 前者是他的教子, 后者在一个时期是他的君主。



图 1.17: Laplace (1749-1827)



图 1.18: Poisson (1781-1840)

Siméon Denis Poisson (泊松, 1781—1840) 是法国数学家和物理学家。他生于皮蒂维耶 (*Pithiviers*)、卒于索镇 (*Sceaux*)。1798 年 *Poisson* 以第一名成绩考入巴黎综合理工学院深造, 很快受到 *Laplace* 和 *J.-L. Lagrange* (拉格朗日, 1736—1813; 法国) 的赏识。入学不到两年, 他已经发表了两本备忘录, 一本关于 *E. Bézout* (裴蜀, 1730—1783; 法国) 的消去法, 另外一本关于有限差分方程的积分的个数; 后一结果经 *S.-F. Lacroix* (拉克鲁瓦, 1765—1843; 法国) 和 *A.-M. Legendre* (勒让德, 1752—1833; 法国) 审查, 建议将它发表于 *Recueil des savants étrangers*。*Poisson* 在 1800 年毕业后留校任教, 1802 年任副教授, 1806 年任教授。1808 年任法国经度局天文学家。1809 年巴黎理学院成立, 任该校数学教授。1812 年当选为巴黎科学院院士。*Poisson* 对积分理论、行星运动理论、热物理、弹性理论、电磁理论、位势理论和概率论都有重要贡献。有句名言通常归于他名下: “人生只有两样美好的事情—发现数学和教数学”。

Poisson 培养的知名学生有: *Michel Floréal Chasles* (查斯勒, 1793—1880) 和 *Joseph Liouville* (刘维尔, 1809—1882)。

从 *J. Bernoulli* 开始, 早期的概率学家们都信奉所谓的不充分理由原理: 如果因为无知, 使得我们没有办法判断哪种“基本结果”会比另外一种“基本结果”更容易出现时², 那么应该给予它们相同的概率。比如硬币, 由于不清楚硬币的哪一面更容易出现, 那么应该给予正面、反面相同的概率, 即都是 $1/2$;

¹现代概率论中, 还有一个“小数定律”, 它是 *Amos Tversky* (特沃斯基) 和 *Daniel Kahneman* (卡纳曼) 对“赌徒谬误”总结的“人们倾向于将基于大样本得到的结论错误地移植到小样本中”这种现象, 这并不是一个真正的数学结果。

²此时, 在物理上有关随机问题通常体现为具有某种对称性。

比如骰子,我们不清楚骰子的哪一面更容易出现时,那么应该赋予每一面相同的概率,即都是 $1/6$. 尽管 Laplace 在他的书中已经尝试对概率论中的一些基本概念(特别是事件的概率这一重要概念)给出定义,但自从 Buffon 提出几何概率模型后,人们发现了一些概率悖论。其中最著名的几何概率模型悖论是法国学者 J. Bertrand(贝特朗,1822—1900)于 1889 年提出的,称为 Bertrand



图 1.19: Bertrand (1822-1900)

悖论:在半径为 r 的圆内随机选择弦,计算弦长超过圆内接正三角形边长的概率;根据“随机选择”的不同意义,可以得到几种不同答案。

这类悖论的矛头直指概率的概念本身;特别地, Laplace 的古典概率定义开始受到猛烈批评。此时,无论是概率论的实际应用还是其自身发展,都要求对概率论的逻辑基础作出更严格的考察。1900 年 D. Hilbert(希尔伯特,1862—1943;德国)在巴黎召开的国际数学家大会提出了一系列问题(Hilbert 的 23 个问题),其中第六个问题是物理学的公理化,首当其冲的是概率和力学的公理化。在这个公理化的潮流下,人们开始了概率的严谨化,特别是公理化的尝试。

现代概率论形成与发展时期(1889—) 俄国数学家¹S. N. Bernstein(伯恩斯坦,1880—1968;他的导师是 C. E. Picard 和 D. Hilbert)、奥地利犹太裔数学家 R. E. von Mises(冯·米西斯,1883—1953;样本空间概念的提出者)最早尝试对概率论进行严格化,他们都提出一些公理来作为概率论的前提,但他们的公理理论都是不完善的。

作为测度论的奠基人之一,法国数学家 E. Borel(博雷尔,1871—1956)在 1905 年首先将测度论方法引入概率论重要问题的研究,并在 1909 年建立了 Borel 强大数律;他的工作激发了数学家们沿这一崭新方向做出一系列探索,其中俄罗斯(或前苏联)的数学家有突出贡献。俄罗斯圣彼得堡学派的缔造者和代表人物是 P. L. Chebyshev(切比雪夫,1821—1894),该学派重要成员有 A. A. Markov(马尔科夫;1856—1922)、A. Lyapunov(李雅普诺夫;1857—1918)等;19 世纪末 20 世纪初俄罗斯的另一学派是以函数论研究为主(后期转向拓扑学)的莫斯科学派²,其中 A. Y. Khintchine(辛钦;1894—1959)是

¹也有文献说是乌克兰数学家。

²莫斯科学派早期的代表性人物有 Egorov(叶戈罗夫,1869—1931)和 Luzin(鲁金,1883—1950;)等。Luzin 在一些文献也写作 Lusin。

该学派的重要成员。这些数学家在概率论方向发展出了一系列理论结果，如各种弱大数律、强大数律、重对数律等概率极限定理，提出特征函数方法、截断手术等理论方法，拓展出马氏链等新的研究领域。

莫斯科学派的超级巨星、前苏联数学家 A. Kolmogorov (柯尔莫哥洛夫, 1903—1987) 集前人研究之大成, 最终完成概率论的公理化, 其结果是 1933 年以德文出版的经典著作《概率论基础》¹。他在这部著作中建立起集合测度与事件概率的类比、积分与数学期望的类比、函数正交性与随机变量独立性的类比等等, 这种广泛的类比终于赋予了概率论以演绎数学的特征。他提出了 6 条公理 (三条关于 σ -代数, 三条关于概率测度), 整个概率论大厦可以从这 6 条公理出发建筑起来。这些公理本身在纯数学的测度论领域已经建立, Kolmogorov 的贡献在于发现无需添加更多的公理进入概率论中^[42]; 因此 Kolmogorov 的公理体系很快获得了数学家们的普遍承认。由此概率论成为了一门严格的演绎学科, 取得了与其他数学分支同等的地位, 并通过集合、函数等桥梁与其他数学分支密切地联系着。



图 1.20: Kolmogorov (1903-1987)

注 1.5. A. Kolmogorov (柯尔莫哥洛夫, 1903—1987) 是前苏联数学家, 生于坦博夫。他 1925 年毕业于莫斯科大学, 1930 年开始任莫斯科大学教授, 1935 年获物理数学博士学位, 导师是 Nikolai Luzin (鲁金, 1883/12/09—1950/01/28; 苏联/俄罗斯数学家, 以 Luzin 定理、Luzin 空间、Luzin 集等闻名)。1939 年他被选为苏联科学院院士, 1966 年当选苏联教育科学院院士。他是 20 世纪最有影响的苏联数学家之一, 是现代概率论的开拓者。1925 年以后他与 Khintchine (辛钦, 1894—1959) 共同把实变函数论的方法应用于概率论, 建立了测度论基础上的概率论公理化体系, 不仅解决了概率论中的一系列难题, 而且奠定了近代概率论的基础; 1930 年以后, 他着重研究了应用于具有连续时间变量的 Markov 过程的解析方法, 发展了 Markov 过程的理论。他在数理逻辑 (结构逻辑方面)、拓扑学 (下同调理论)、力学 (涡动性的静态理论)、微分方程、泛函分析、信息论等多方面做出了重要贡献。他关心数学教育, 积极参与高等和中等学校数学教材的编写工作。由于概率论、调和分析及动力系统方面的出色工作, 他荣获 1980 年的数学终身成就奖——Wolf 奖。在他的带领和影响下, 20 世纪苏联涌现出一大批优秀的数学家。

Kolmogorov 直接培养的学生有 (按年龄排列): S. Nikolsky (尼科爾斯基; 1905—2012; 俄罗斯数学家, 在泛函分析、函数逼近等多个方向有奠基性贡献), B. Gnedenko (格涅坚科; 1912—1995; 苏联数学家, 以概率论、特别是极值理论中的研究成果著称, 例如 Fisher-Tippett-Gnedenko 定理, 1958 年爱丁堡国际数学家大会特邀报告人), I. Gelfand (盖尔范德; 1913—2009; 苏联数学家, 以群论、表示论、泛函分析方面的重要贡献闻名于世), A. Obukhov (奥布霍夫; 1918—1989; 俄罗斯物理学家、应用数学家, 以湍流和大气物理学

¹即 *Grundbegriffe der Wahrscheinlichkeitsrechnung (Foundations of the Theory of Probability)*。

方面的统计理论研究著称, 以他姓氏命名的结果有: *Monin-Obukhov* 相似性理论和 *Monin-Obukhov* 长度等), *A. Yaglom* (亚格洛姆; 1921—2007; 苏联-俄罗斯物理学家、数学家、统计学家、气象学家, 以湍流的统计理论和随机过程理论方面的研究著称), *A. Monin* (莫宁; 1921—2007; 俄罗斯物理学家、应用数学家、海洋学家, 以湍流和大气物理学方面的统计理论研究著称), *E. Dynkin* (邓肯; 1924—2014; 苏联-美国数学家), *G. Barenblatt* (巴伦布拉特; 1927—2018; 俄罗斯数学家), *R. Dobrushin* (多布鲁申; 1929—1995; 苏联-俄罗斯数学家, 在概率论、数学物理、信息论等方面有重要贡献), *Y. Prokhorov* (普罗霍罗夫; 1929—2013; 俄罗斯数学家, 以度量空间上测度族的胎紧性和列紧性关系的研究成果著称), *V. Uspensky* (乌斯本斯基; 1930—2018, 俄罗斯数学家、语言学家、作家, 他首创了俄罗斯的语言学教育改革), *R. Minlos* (闵洛斯; 1931—2018; 苏联-俄罗斯数学家, 在概率论和数学物理方面有重要贡献), *A. Vitushkin* (维图什金; 1931—2004; 苏联数学家, 盲人, 以解析容度和其他数学分析方面的研究工作闻名), *V. Alekseev* (阿列克谢耶夫; 1932—1980; 俄罗斯数学家, 研究方向为天体力学和动力系统; 1970 年 *Nice* 国际数学家大会邀请报告人), *A. Shiryayev* (施利亚耶夫; 1934—; 苏联-俄罗斯数学家, 以概率论、统计、金融数学方向的研究成果著称, 俄罗斯科学院院士), *Y. Sinai* (西奈; 1935—; 俄罗斯数学家, 以动力系统方向的研究成果闻名于世, 1997 年获 *Wolf* 奖), *V. Arnold* (阿诺德; 1937—2010; 苏联-俄罗斯数学家, 最知名结果是 *Kolmogorov-Arnold-Moser* 定理, 1957 年就解决了 *Hilbert* 第 13 问题, 2001 年获 *Wolf* 奖), *E. Khazen* (哈赞), *P. Martin-Löf* (马丁-勒夫; 1942—; 瑞典逻辑学家、哲学家、数理统计学家, 斯德哥尔摩大学教授, 以概率、统计、数理逻辑、计算机科学方面的基础研究而知名), *L. Levin* (莱文; 1948—; 苏联-美国数学家、计算机科学家, 波士顿大学教授, 以计算、算法复杂性中的随机性、平均复杂性方面的研究著称, 与 *Stephen Cook* 独立地发现了 *NP* 完全问题的存在性), *S. N. Artemov* (阿特莫夫; 1951—; 俄罗斯-美国数学家, 专长为逻辑及其应用, 现为纽约城市大学教授) 等。

概率论公理化完成以来, 在诸多学者的贡献下, 概率论在蓬勃发展的过程中逐步完善, 关于随机变量独立和的强/弱大数律、中心极限定理、重对数律等经典理论到 1960 年前后发展成熟; 除了这些经典研究范式, 概率学家们又发展出不少新的研究领域和新的理论成果。局限于概率论在 20 世纪三四十年代以来发展出来的新的重大理论工具, 囿于编者学识, 无法提供周全且准确的描述, 只能略举若干重大事例如下:

- (1) 由于概率论的公理化, 随机过程的研究获得了严格的理论基础和新的起点, 成为现代概率论的一个重要研究主题。在 *Markov* 的工作基础上, 随机过程理论蓬勃发展: 1931 年 *Kolmogorov* 用分析方法奠定了一般**马氏过程**的理论基础、1934 年 *A. Khintchine* (辛钦, 1894—1959; 前苏联) 提出了**平稳过程**的有关理论、1948 年 *P. Lévy* (莱维, 1886—1971; 法国) 提出并发展**平稳独立增量过程**(即 *Lévy 过程*); 其中**随机游动**的研究尤其受到概率界的密切关注和长时间的推动。在此过程中, 鞅论在 *J. L. Doob* (杜布, 1910—2004; 美国) 等的奠基性工作下也得到蓬勃发展和广泛应用。

- (2) 在 1827 年英国生物学家 R. Brown (布朗; 1773 — 1858) 观察到水面上花粉粒子的 Brown 运动/布朗运动、1905 年 A. Einstein (爱因斯坦, 1879 — 1955; 德国, 犹太裔物理学家) 建立 Brown 运动的物理机制模型、N. Wiener (维纳, 1894 — 1964; 美国) 等人完善 Brown 运动的数学定义等工作的基础上, 1942 年日本数学家 K. Itô (伊藤清, 1915 — 2008) 引进随机积分与随机微分方程, 创立了随机分析理论。
- (3) 在 Beurling (贝林) 和 Deny (迪奈) 1958、1959 年工作以及前人经典位势理论工作的基础上, 1971 年日本的 M. Oshima、Y. Fukushima 首次利用有穷维空间的正则狄氏型 (Dirichlet Form) 构造了与之相联系的 Hunt 过程, 使得狄氏型这个纯分析工具与随机分析建立了联系, 并获得不少应用。之后诸多学者合作发展狄氏型理论。日本的 M. Oshima 和 Y. Fukushima、美国的 R. Gettoor、德国的 M. Röckner 和 S. Albeverio 以及我国的马志明院士 (1948 —) 等在这方面有突出贡献, 是该领域世界知名的专家。
- (4) 在 H. Cramér (克莱默, 1893 — 1985; 瑞典)、F. O. Lundberg (伦德伯格, 1876 — 1965; 瑞典) 关于保险数学的研究工作基础上, 1966 年 S. R. S. Varadhan (瓦拉丹, 1940 —; 印度-美国) 创立了大偏差理论。在大偏差原理的框架被引入概率论中后, 20 世纪七八十年代, Donsker-Varadhan 提出了关于马氏过程经验测度的大偏差理论, Freidlin-Wentzell 提出了含随机扰动系统的轨道大偏差理论。这两大辉煌成就, 让大偏差理论迅速成为概率论的主流分支之一。
- (5) P. Malliavin (马利亚万, 1925 — 2010; 法国) 把确定性函数的变分拓展到随机过程上, 创立了 Malliavin 分析理论。这是一个新兴的研究领域, 联系着调和分析、泛函分析、概率、微分几何等多个数学分支。
- (6) 我国的彭实戈院士 (1947 —) 与 E. Pardoux (巴赫杜, 1947 —; 法国) 在 1990 年合作, 发展了非线性期望理论, 创立了倒向随机微分方程理论, 在控制理论、金融数学等多个方向得到应用和发展。

上面提及的有关概率理论在物理、化学、生物等多个学科中得到广泛应用, 在人类探索、认识世界和改造世界的过程中持续发挥着作用。我们期待读者在学习了概率论的有关理论后也能为我国的科技发展贡献力量。

习 题 1

习题 1.1. *Pacioli* 在《算术书》中提出所谓的“分赌金问题”: 两人决定赌博若干局, 事先约定谁先赢得 6 局便算赢家, 从而获取全部赌金。如果在一个人赢

5局，另一个人赢2局时因故终止赌博，应如何分配赌金才合理？他给出的答案是按照5:2分，也就是说按照赌徒实际已经赢下的局数比例来分配赌金。为什么这样的分配原则不合理？试举极端情况的例子来说明。

习题 1.2.（幸存者偏差） 本题内容源自知乎社区一位作者的文章，目的是让读者了解幸存者偏差（*Survivorship Bias*）这一逻辑推理上的误区。1940年左右，在英国和德国进行的空战中，双方都损失了不少轰炸机和飞行员。因此当时英国军部研究的一大课题就是：在轰炸机的哪个部位装上更厚的装甲，可以提高本方飞机的防御能力，减少损失？由于装甲很厚，会极大地增加飞机的重量，不可能将飞机从头到尾全都用装甲包起来，因此研究人员需要做出选择，在飞机最易受到攻击的地方加上装甲。




图 1.21: 习题1.2配图

当时的英国军方研究了那些从欧洲大陆空战中飞回来的轰炸机。如图1.21所示，飞机上被打到的弹孔主要集中在机身中央，两侧的机翼和尾翼部分。因此研究人员提议，在弹孔最密集的部分加上装甲，以提高飞机的防御能力。这一建议被美国军队统计研究部的统计学家 *Abraham Wald* 否决。*Wald* 连续写了8篇研究报告，指出这些百孔千疮的轰炸机是从战场上成功飞回来的“幸存者”，因此它们机身上的弹孔对于飞机来说算不上致命。要想救那些轰炸机飞行员的性命，更正确的方法应该是去研究那些被打中并坠毁的轰炸机。只有研究那些没有成功返航的“倒霉蛋”，才能有的放矢，找到这些飞机最脆弱的地方并用装甲加强。*Wald* 的建议后来被英国军方采纳，挽救了成千上万的飞行员性命。

你认同 *Wald* 的分析吗？你还知道哪些有关幸存者偏差的故事？

习题 1.3.（三枚银币骗局） 某人在街头设一赌局。他向观众出示了放在帽子里的三枚银币（记为甲、乙、丙），银币甲的两面涂了黑色，银币丙的两面涂了红色，银币乙一面涂了黑色，另一面涂了红色。游戏规则是：他让一个观众从帽

子里任意取出一枚银币放到桌面上（这里不用“投掷银币”是为了避免暴露银币两面的颜色），然后由设局人猜银币另一面的颜色，如果猜中了，该参与者付给他 1 元钱，如果猜错了，他付给该参与者 1 元钱。试问：这一赌局是公平的吗？从直觉上看，无论取出的银币所展示的一面是黑色或红色，另一面是红色或黑色的概率都是 $1/2$ ，这一赌局似乎是公平的，但实际上不公平。为什么？

习题 1.4. (Monty Hall 问题) 本题出自美国的一个电视游戏节目，问题的名字来自该节目的主持人蒙提·霍尔，20 世纪 90 年代曾在美国引起广泛和热烈的讨论。假定在台上有三扇关闭的门，其中一扇门后面有一辆汽车，另外两扇门后面各有一只山羊。主持人是知道哪扇门后面有汽车的。当竞猜者选定了一扇门但尚未开启它的时候，节目主持人去开启剩下两扇门中的一扇，露出的是山羊。主持人会问参赛者要不要改猜另一扇未开启的门。问题是：改猜另一扇未开启的门是否比不改猜赢得汽车的概率要大？

习题 1.5. (赌徒佯谬) 本题的目的是介绍赌徒佯谬 (*Gambler's Fallacy*)。据说，有些参加俄罗斯轮盘赌的赌徒有这样的一种策略：记录下每次轮盘转下来的结果（红色或者黑色）。如果遇到连续多次是一个颜色（比如连续五次都是红色），那么赌徒就会果断出手，在下一把押上重注赌另一个颜色（比如黑色）。赌徒们认为，他们这样做的道理是 *Bernoulli* 已经论证过的“频率稳定性” (*Bernoulli* 弱大数律)，也就是说频率具有某种回归性。你觉得有道理吗？

习题 1.6. (热手效应) 与“赌徒佯谬”相对应的，另一个很多人容易犯的行为学错误叫做“热手效应” (*Hot Hand Fallacy*)。“热手效应”源于篮球运动。在篮球比赛中，有时候会发生这样的情况：某一位球员连续投中几个三分球。这时候其队友和教练都会认为这位球员的状态来了，即他的手开始“热”了。于是大家都会主动把球传给这位球员，好趁他手“热”的时候抓紧时间多投几个，为球队涨点分。“热手效应”在赌场里也很常见。比如在 21 点桌上，如果有一个玩家连续赢了庄家几把，那么在边上围观“飞苍蝇”的群众可能会产生这位玩家“手气非常好”的错觉，在接下来的时间里把更多的筹码赌在这位玩家上。问题在于，这种所谓的“热手效应”有可能更多的只是大家的感觉而已，并没有可靠的证据支持（赌场中的）“热手效应”的存在。你对此有何看法呢？

习题 1.7. (圣彼得堡悖论) 本题的目的是介绍圣彼得堡悖论；它是决策论中的一个悖论。数学家丹尼尔·伯努利 (*Daniel Bernoulli*) 的堂兄尼古拉一世·伯努利 (*Nicolaus I Bernoulli*) 在 1738 年提出了一个概率期望值悖论。设有如下一个需要付费 c 元参加的游戏：设定掷出（均匀）硬币的正面（或者反面）为成功，游戏者如果第一次投掷时取得成功，领取奖金 2 元，游戏结束；第一次

投掷若不成功，继续投掷，第二次投掷时取得成功则领取奖金 4 元，游戏结束；这样，游戏者如果投掷不成功就反复继续投掷，直到，比如说，第 n 次投掷时取得成功，领取奖金 2^n 元，游戏结束。按照概率期望值的计算方法，将每个可能结果的得奖值乘以该结果发生的概率即可得到该结果对应收益的期望值。通常认为，合理的收费 c 就是游戏的收益的期望值，它是所有可能结果对应收益的期望值之和。随着 n 的增大，以后的结果虽然概率很小，但是其奖值越来越大，每个结果对应收益的期望值均为 1，所有可能结果对应收益的期望值之和，即游戏的收益的期望值，它是“无穷大”。按照概率的理论，多次试验的结果的平均收益将会接近于其数学期望，也就是说合理的收费 $c = \infty$ ！但是正如 1980 年 *Hacking* 所说：“没有人愿意花 25 元去参加一次这样的游戏。”这就出现了计算的期望值与实际情况的“矛盾”，问题出在哪里？这个游戏的实际合理收费应该是多少？决策理论的期望值准则在这里还成立吗？这是不是给“期望值准则”提出了严峻的挑战？正确认识和解决这一矛盾对于人们认识随机现象、发展决策理论和指导实际决策无疑具有重大意义。你对此如何理解？历史上，*Daniel Bernoulli* 在提出这个问题的的时候就给出一种解决办法，感兴趣的读者请参考文献^[57]的 13.2 节或其他相关文献。

习题 1.8.（辛普森悖论）当人们尝试探究两种变量（比如新生录取率与性别）是否具有相关性的时候，会分别对之进行分组研究。然而，在分组比较中都占优势的一方，在总评中有时反而是失势的一方。该现象于 20 世纪初就有人讨论，但一直到 1951 年，*E. H. Simpson*（辛普森）在他发表的论文中阐述此一现象后，该现象才算正式被描述与解释，后来就以他的名字命名此悖论。20 世纪 70 年代加州大学伯克利分校就曾经被人以研究生院的男女录取比例数据作为在研究生项目中对女性申请人的“性别歧视”证据而被起诉¹。本题通过下面的虚拟案例介绍辛普森悖论，资料来源于百度百科。

表 1.2: 某院校各专业研究生项目录取情况

学院	女生 申请	女生 录取	女生 录取率	男生 申请	男生 录取	男生 录取率	合计 申请	合计 录取	合计 录取率
商学院	100	49	49 %	20	15	75%	120	64	53.3%
法学院	20	1	5%	100	10	10%	120	11	9.2%
总计	120	50	42%	120	25	21%	240	75	31.3%

“校长，不好了，有很多男生在校门口抗议，他们说今年研究发现女生录

¹加州大学伯克利分校“性别歧视”案的具体介绍见文献^[114]；本习题中的相关数据纯属虚构，并非真实数据。

取率 42% 是男生 21% 的两倍，我们学校遴选学生有性别歧视”，校长满脸疑惑地问秘书：“我不是特别交代，今年要尽量提升男生录取率以免落人口实吗？”

秘书赶紧回答说：“确实有交代下去，我刚刚也查过，的确是有注意到，今年商学院录取率是男性 75%，女性只有 49%；而法学院录取率是男性 10%，女性为 5%。两个学院都是男生录取率比较高。校长，表 1.2 是我的调查报告。”

“秘书，你知道为什么个别录取率男皆大于女，但是总体录取率男却远小于女吗？”

此例就是统计上著名的辛普森悖论 (Simpson's Paradox). 作为读者的你能理清这里悖论出现的原因吗？

习题 1.9. (概率的相容性) 本题借鉴了文献^[27]第 24–25 页的论述。设想对于明天发生的一些关心的事件在今天都有合约：明天可能发生的事件 A 对应有“ A 合约”，持有该合约的人有权在明天 A 事件发生时向“银行”领取 1 元；但当 A 事件不发生时，该“ A 合约”就是废纸一张；很自然，这样的合约在今天应该有某个价格；“银行”对于等效合约容许免费兑换。设张三对明天的一些事件发生概率的评估（或揣测）都是以“合约”的形式进行，他所认可的“ A 合约”的价格就是他所认定的“明天 A 事件发生的概率” $\mathbb{P}(A)$ 。现在，他认为“明天晴天”的“概率”是 0.6，亦即他认可“晴天合约”的价格 0.6 元；而同时，他认为“明天下雨”的“概率”是 0.1，却认为“明天晴天或下雨”的“概率”为 0.9。那么此处张三对明天天气的概率评估是不相容的，其他人可以利用这一点获得无风险的套利如下：你可以用 0.7 元总价格买下张三的“晴天合约”和“下雨合约”各一张，这两个合约捆绑在一块，等效于一张“晴天或下雨合约”（我们假定晴天就不会下雨，下雨就不算晴天），从而可以从“银行”兑换一张“晴天或下雨合约”；接着，你就可以 0.9 元的价格向张三售卖“晴天或下雨合约”了。如此你就在当天实现了 0.2 元的无风险套利；而这时的张三就被认为收了“智商税”。试设想一下，张三对于明天可能要发生的事件族 $\{A_\alpha\}_\alpha$ 应当如何设置概率评估体系（即如何确保不同事件的概率之间的相容性），以免在今天就被收“智商税”？

习题 1.10. 上题从经济学/博弈论角度讨论了“概率评估体系”对相容性的要求，即合理的“概率评估体系”（概率建模）应当不存在无风险套利；对于条件概率也可如此思考，感兴趣的读者请参看文献^[27]第 27–31 页或文献^[24]还有一种有风险套利—统计套利，也是应当避免的：“合约”、“银行”如上题设置；假定张三对于某种试验中的现象 A 非常关心，该实验可以重复进行。每次试验前都有一份“ A 合约”需要签订，合约价格被张三定为 C 元，其中 C 是张三认为的“单次试验中观察到 A 现象的概率”。那么当价格 C 过大或过小时就

都有“统计套利”的存在。这是因为，在承认“频率稳定性”现象的存在性时，设 $\mathbb{P}(A)$ 是单次试验中观察到 A 现象的真实概率，如果 $C > \mathbb{P}(A)$ ，则每次试验前我们都向张三以价格 C 卖出“ A 合约”，长期进行下去我们就会有“统计套利”存在；如果 $C < \mathbb{P}(A)$ ，我们则从张三处买入该合约，长期进行下去同样可以获得“统计套利”；只有 $C = \mathbb{P}(A)$ 时才没有统计套利。请读者学完全书后务必再回过头来思考本题中结论成立的原因。

习题 1.11. (二战期间的梅毒检测方法) 第二次世界大战期间，数千万的美国应征者在入伍前都进行了梅毒检测，预计有几千人感染了这种病。化验血样是一个耗时且昂贵的过程；哈佛大学经济学家 *Robert Dorfman* 建议把所有人分成若干群组，把每组所有人的血样混合成一份血样进行检测：如果混合血样检测阴性，则这一群组的人都是健康的；而当混合血样检测阳性时才对该群组的成员一一进行检验。这种检测方法可以大大节省检测的时间和费用；如今的大范围检测罕见疾病的案例（比如目前新型冠状病毒的人群大范围排查性检测）中普遍使用这一方法。假设该疾病的人群患病率为 p （一个小概率值）， n 个人作为一个分组。最合理的 n 应当如何确定？请读者学习到数学期望的定义章节时务必思考本习题。

第二章 从古典概率模型、几何概率模型到概率论的公理

从本章起，我们将基于集合论¹来对关心的随机试验或随机现象进行概率建模。如我们在第一章中所述，历史上人们最早进行研究的是在等可能性假设下的两类模型：**古典概率模型**和**几何概率模型**。关于它们的研究取得了诸多成果，解决了许多现实问题；之后人们在几何概率模型中发现了 **Bertrand 悖论**，由此引发了人们对概率论的严谨化，特别是公理化的探索，最终总结出了更一般的 **Kolmogorov 公理化概率模型**。

法国数学家 A. Weil（韦伊，1906—1998）说，“在课堂上干巴巴地讲述知识远不如阐述隐藏在这些知识背后的主要思想来得重要”。^[112]而相关的学科史无疑浓缩了该学科方向的主要思想与发展脉络；“一个将历史知识和数学研究结合得最了不起的例子”^[112]是 C. L. Siegel（西格尔，1896—1981；德国）在 1930 年左右通过考证研究 G. F. B. Riemann（黎曼，1826—1866；德国）有关解析数论的著作（包括他去世那年未尽的论文散页）而发现了如今称为 **Riemann-Siegel 公式**的两个公式。秉承此理念，接下来我们按照概率论发展的实际历史进程，依次介绍古典概率模型、几何概率模型和更一般的 **Kolmogorov 公理化概率模型**及其相关的应用问题，力图在一定程度上复现概率论学科的螺旋上升式的发展历程，着力于阐述先辈隐藏在概率论的概念与理论背后的思想。

在前述诸概率模型中都需要使用集合论的数学语言。为此我们先介绍概率建模观点下的（随机）事件与集合。

¹对于集合论，数学上通常选用 ZFC 公理系统，亦即 ZF 公理系统 + 选择公理，其中 Z 代表 E. F. F. Zermel（策梅洛，1871—1953；德国），F 代表 A. A. Fraenkel（弗伦克尔，1891—1965；德国），C 代表选择公理（Choice 的首字母）；在本讲义的教学中，我们只需要使用 Cantor（康托尔，1845—1918；德国）的朴素集合论。

2.1 事件与集合

我们对随机试验或随机现象的概率建模通常离不开德国数学家 Cantor (康托尔, 1845—1918) 发展的集合论。在讨论某个随机事件或随机现象 A 时, 我们总是认为 (或假想) 相关的试验已经完成, 一个 (试验开始时无法预知的) 试验结果——“基本结果”——已经出现了。在概率建模上, 我们总是把事件 A 对应于某个特定空间 Ω (称为样本空间) 的子集 (仍记作 A , 其中 $A \subset \Omega$)。此处样本空间 Ω 一般建模成所有可能的“基本结果”的全体¹。其中, 我们总假设代表“基本结果”的未知变量 ω (也称为样本点变元) 能刻画所研究的随机事件的有必要关心的一切细节, 特别是涉及随机性的那部分细节²。这是合理、有效的概率建模的基本要求; 而所谓的事件 A 或现象 A 只不过是具有特定的性质 A 的“基本结果”的全体³, 亦即满足关系 $\omega \in A$ 的所有样本点 ω 的全体。也就是说, 我们有如下自然语言与集合论方式概率建模的基本对应:

$$A \text{ 事件发生} \Leftrightarrow \omega \in A. \quad (2.1)$$

(2.1)右端的 ω 理解为对随机试验或随机现象进行概率建模时就 (认为或假想) 已经出现的某个 (“试验开始”时未知的) “基本结果”, 亦即 “试验完成”时的 “试验结果” (从而不再发生变化)。当 “试验完成”, “试验结果” 已经出现时, 就是我们通常所说的 “靴子落地”、“尘埃落定”, 对于已经发生了的 “试验结果” (“基本结果”) 本身, 在已经知道它的具体结果时再去谈它发生的可能性大小已经没有意义。因此, 只有这个试验 “基本结果” 还未知的时候, 我们才去谈论它导致某种现象 A 发生的可能性大小。我们所有的 “试验开始” (甚至 “试验完成”) 时的不确定性感受就来源于这个将要出现 (或已经出现) 的 “基本结果” 的无法预知性。随机事件 A 发生的可能性大小 (不确定性感受) 通过一定方法量化赋值, 就被认为是 A 事件发生的概率。因此, 所谓概率实际上可以认为是在 “试验开始” 时 (至少是在试验 “基本结果” 还未测定出来时) 的一种对随机事件发生可能性大小的量化形式的预判。我们的概率论课程就是想介绍人类历史上逐步总结探索出来的对随机试验进行数学建模、合理推断随机事件发生的概率等统计规律的一种数学理论与数学方法。毫无疑问, 虽然这种理论与方法仍然在应用中持续发展, 它在今天已经被发展得严谨而系统、经受

¹注意, 由于每个人对所关心的随机现象观察角度等各方面的差别, 样本空间 (及相应的概率空间) 的建模是不唯一的。由此我们确有在后续章节中讨论概率空间的同构问题的必要性。

²关于概率建模应能刻画所有有必要关心的细节, 第三章中例3.2与例3.3的不同解答值得读者好好品味。

³有些教材中还有所谓 “基本事件” 的说法: 一个基本事件就是一个只包含了单个 “基本结果” 的事件。本讲义中我们不刻意引入和使用基本事件这个概念, 因为有了 “基本结果” 这一底层概念就足以讲清楚随机事件这一概念; 同时存在 Kolmogorov 公理化概率模型使得某些 (甚至全部) “基本事件” 并不能谈论概率。

了考验，从而被大众广泛接受。需要指出的是，概率论在研究随机事件发生的概率等统计规律时，不关心“试验结果”（亦即“基本结果”）的具体出现过程，从而进行对应的数学建模时通常忽略这方面的细节。

这里自然而然有两个特殊事件：必然事件 Ω 与不可能事件 $\emptyset$. 整个样本空间 Ω 是一个必然发生的事件：此时 $\omega \in \Omega$ 总成立，因此 Ω 也称为**必然事件**，建模时总赋予必然事件发生的概率值为1；空集 $\emptyset$ 对应于一个必然不发生的事件：此时 $\omega \in \emptyset$ 总是不可能成立，因此 $\emptyset$ 也称为**不可能事件**，建模时总赋予不可能事件发生的概率值为0. 其他事件发生的可能性如果能讨论，在建模时就认为它能够谈论概率，并赋予它发生的概率值介于0与1之间：越靠近1的概率值，表示对应事件发生的可能性越高；越靠近0的概率值，表示对应事件发生的可能性越低。

虽然对随机事件的概率赋值从现在来看具有很大的自由度，但实际上真正逻辑自洽的赋值最起码应该满足我们本章最后介绍的概率的公理¹；至于哪种逻辑自洽的概率赋值更合理，则需要结合实际问题进行讨论或通过实践来进行检验。本课程的重心放在探讨对随机试验的概率空间建模、特别是在概率空间建模完成后如何来解答关心的随机事件的概率等问题上，只在少数场合展开了对于概率建模的合理性与检验方面的讨论；最后一类问题是《统计学》的一个核心问题。




图 2.1: 事件的运算或关系的文氏图 (Venn 图) 演示

在本书中，关于集合之间的复合运算，我们将使用记号“ $\cup$ ”、“ $\cap$ ”、“ c ”，分别表示集合的“并”、“交”、“补”运算；另外，我们也定义 $A \setminus B := A \cap B^c$ ，有时也记 $A - B := A \setminus B$. 在对应关系(2.1)下，以下自然语言中的复合事件与建模中的相应集合的复合运算之间的对应关系也就很自然了：

¹ 习题1.9给出了有关概率的公理/性质在经济学上的一种有趣解释；更多细节请参见文献.[27]

- 必然事件 = Ω , 不可能事件 = $\emptyset$;
- A 的对立事件 = A^c ;
- A, B 两事件同时发生的复合事件 = $A \cap B$;
- A, B 两事件至少发生其一的复合事件 = $A \cup B$;
- A, B 两事件只发生其一的复合事件 = $A \Delta B := (A \setminus B) \cup (B \setminus A)$.

其中 $A \cap B$ 有时也简单写作 AB , 即 $AB := A \cap B$. 如果 $A \cap B = \emptyset$, 则称 A, B 两事件互斥或不交, 此时也改记 $A \cup B$ 为 $A \uplus B$, 以强调并运算中集合的两两不交性. 如果一族集合 $\{A_\alpha \subset \Omega\}_{\alpha \in I}$ 满足:

$$A_\alpha \cap A_\beta = \emptyset, \forall \alpha, \beta \in I, \alpha \neq \beta,$$

就称 $\{A_\alpha\}_{\alpha \in I}$ 是两两不交的或互不相交的; 此时, 如果 $I \subset \mathbb{N}$, 我们就称 $\{A_n\}_{n \in I}$ 为互不相交集列 (简称不交集列). 在概率论中, 互不相交的事件列也经常被称为互斥的事件列, 其含义就是它们不会两两同时发生. 我们希望读者在学习本课程的过程中有意识地锻炼自己在自然语言和数学语言之间自由切换的能力; 这个能力有助于我们利用生活中形成的直观来学习本课程, 也有助于我们利用本课程学习的概率理论来理解、进而解决有关实际问题.

这里, 我们提醒读者: 在集合论中, 集合的多个并运算之间满足交换律和结合律, 集合的多个交运算之间也满足交换律和结合律, 交、并两种运算混合满足分配律, 补运算与并运算、补运算与交运算之间满足对偶律 (也称 **De Morgan 律**); 有关准确论述, 见下面的命题.

♣ **命题 2.1.1.** 集合的交、并、补运算具有如下一些性质:

- (1) 交换律: $A \cup B = B \cup A, A \cap B = B \cap A$;
- (2) 结合律: $(A \cup B) \cup C = A \cup (B \cup C), (A \cap B) \cap C = A \cap (B \cap C)$;
- (3) 分配律: $(A \cup B) \cap C = (A \cap C) \cup (B \cap C), (A \cap B) \cup C = (A \cup C) \cap (B \cup C)$;
- (4) **De Morgan 律**: 对任意指标集 I ,

$$\left(\bigcup_{\alpha \in I} A_\alpha\right)^c = \bigcap_{\alpha \in I} A_\alpha^c, \quad \left(\bigcap_{\alpha \in I} A_\alpha\right)^c = \bigcup_{\alpha \in I} A_\alpha^c. \quad (2.2)$$

此外, 映射与集合运算之间有以下的一些结论.

♣ **命题 2.1.2.** 设 $f: \Omega_1 \rightarrow \Omega_2$ 是一个映射, I 是一个指标集.

(1) 如果对任意 $\alpha \in I$, $A_\alpha \subset \Omega_1$, 那么

$$f\left(\bigcup_{\alpha \in I} A_\alpha\right) = \bigcup_{\alpha \in I} f(A_\alpha), \quad f\left(\bigcap_{\alpha \in I} A_\alpha\right) \subset \bigcap_{\alpha \in I} f(A_\alpha);$$

(2) 如果对任意 $\alpha \in I$, $B_\alpha \subset \Omega_2, B \subset \Omega_2$, 那么

$$\begin{aligned} f^{-1}\left(\bigcup_{\alpha \in I} B_\alpha\right) &= \bigcup_{\alpha \in I} f^{-1}(B_\alpha), & f^{-1}\left(\bigcap_{\alpha \in I} B_\alpha\right) &= \bigcap_{\alpha \in I} f^{-1}(B_\alpha), \\ f^{-1}(B^c) &= f^{-1}(B)^c, & f^{-1}(B_1 \setminus B_2) &= f^{-1}(B_1) \setminus f^{-1}(B_2). \end{aligned}$$

另外, 我们给出集合列的极限概念如下。

定义 2.1.1. 设 $\{A_n\}_{n=1}^\infty$ 是空间 Ω 中子集列, $A \subset \Omega$.

- (i) 设 $\{A_n\}_{n=1}^\infty$ 为单调上升的集合列, 即 $A_n \subset A_{n+1}, \forall n \geq 1$. 称 $\{A_n\}_{n=1}^\infty$ 的 (单调上升) 极限为 A , 记作 $A_n \nearrow A$, 如果 $A = \bigcup_{n=1}^\infty A_n$;
- (ii) 设 $\{A_n\}_{n=1}^\infty$ 为单调下降的集合列, 即 $A_{n+1} \subset A_n, \forall n \geq 1$. 称 $\{A_n\}_{n=1}^\infty$ 的 (单调下降) 极限为 A , 记作 $A_n \searrow A$, 如果 $A = \bigcap_{n=1}^\infty A_n$;
- (iii) 称 $\{A_n\}_{n=1}^\infty$ 的上极限集 (简称为上限集) 为 A , 记作 $A = \overline{\lim}_{n \rightarrow \infty} A_n$, 如果 $A = \bigcap_{N=1}^\infty \bigcup_{n=N}^\infty A_n$; 注意到此时恰好有

$$\overline{\lim}_{n \rightarrow \infty} A_n = \left\{ \omega : \sum_{n=1}^\infty 1_{A_n}(\omega) = \infty \right\},$$

故在概率论中也经常简写为 $\{\{A_n\}_n \text{ i.o.}\} := \overline{\lim}_{n \rightarrow \infty} A_n$, 此处 i.o. 是英文 *infinitely occur* (或 *infinite often*) 的缩写¹. 这里, 对任意 $A \subset \Omega$, 1_A 称为集合/事件 A 的示性函数, 它的定义为

$$1_A(\omega) := \begin{cases} 1, & \text{当 } \omega \in A \text{ 时} \\ 0, & \text{当 } \omega \notin A \text{ 时} \end{cases}; \quad (2.3)$$

- (iv) 称 $\{A_n\}_{n=1}^\infty$ 的下极限集 (简称为下限集) 为 A , 记作 $A = \underline{\lim}_{n \rightarrow \infty} A_n$, 如果

$$A = \bigcup_{N=1}^\infty \bigcap_{n=N}^\infty A_n;$$

¹ 概率论中还有 $\{\{A_n\}_n \text{ f.o.}\} := \{\omega : \sum_{n=1}^\infty 1_{A_n}(\omega) < \infty\}$ 的写法, f.o. 是英文 *finitely occur* (或 *finite often*) 的缩写. 显然, $\underline{\lim}_{n \rightarrow \infty} A_n = \{\{A_n^c\}_n \text{ f.o.}\}$. 用概率的语言来说, 即: 上限集是事件列中有无穷多个发生的复合事件; 下限集是事件列中只有有限多个不发生的复合事件。

(v) 称 $\{A_n\}_{n=1}^{\infty}$ 的极限为 A , 记作 $A = \lim_{n \rightarrow \infty} A_n$, 如果 $A = \overline{\lim}_{n \rightarrow \infty} A_n = \underline{\lim}_{n \rightarrow \infty} A_n$.

利用示性函数的概念, 上、下极限集可以简单总结如下:

$$\begin{aligned} \underline{\lim}_{n \rightarrow \infty} A_n &:= \{\omega : \sum_{n=1}^{\infty} 1_{A_n^c}(\omega) < \infty\} \\ &\subset \{\omega : \sum_{n=1}^{\infty} 1_{A_n}(\omega) = \infty\} =: \overline{\lim}_{n \rightarrow \infty} A_n. \end{aligned} \quad (2.4)$$

因此我们实际上有 $(\underline{\lim}_{n \rightarrow \infty} A_n)^c = \overline{\lim}_{n \rightarrow \infty} A_n^c$.

2.2 古典概率模型

本节我们先简单介绍古典概率论中等可能性假设下最经典而自然的概率模型: **古典概率模型**, 之后介绍与之密切相关的计数技巧, 最后介绍古典概率模型的一些经典的应用实例。

2.2.1 古典概率模型简介

我们通常把一个类似于投掷均匀硬币或骰子的“随机试验”建模为一个“古典概率模型”。在古典概率模型中, 我们要求:

- ◆ 随机试验的所有可能的“基本结果”的数量是有限多个;
- ◆ 这些“基本结果”是具有同等可能性发生的。

此时, 我们把所有可能的“基本结果”的全体建模成一个有限集合 Ω , 称为**样本空间**; 每个“基本结果”对应于 Ω 中的一个点 ω , 称为**样本点**。

显然, 古典概率模型对应的样本空间 Ω 的元素个数有限: $\#(\Omega) = |\Omega| < \infty$; 而任一事件 A 在建模下是样本空间的子集 $A \subset \Omega$, 它的**概率**定义为 A 与 Ω 的元素个数之比:

$$\mathbb{P}(A) := \frac{|A|}{|\Omega|}. \quad (2.5)$$

上述概率的定义是在 **Pascal** 和 **Fermat** 的通信讨论中暗含, 而由 **Huygens** 最早明确提出的。在上述模型中, 样本空间 Ω 的所有子事件 $A \subset \Omega$ 都可以谈论概率, 即可以谈论概率的事件的全体 (也称为事件域) 是

$$\mathcal{F} = 2^{\Omega} := \{A : A \subset \Omega\}.$$

容易知道, 在古典概率模型中, 概率 $\mathbb{P} : \mathcal{F} \rightarrow \mathbb{R}$ 具有如下简单性质:

- (i) (非负性) $\mathbb{P}(A) \geq 0, \forall A \in \mathcal{F}$;
- (ii) (平凡性) $\mathbb{P}(\emptyset) = 0$;
- (iii) (归一性) $\mathbb{P}(\Omega) = 1$;
- (iv) (有限可加性)¹ 设 $\{A_n\}_{n=1}^N \subset \mathcal{F}$ 互斥, 则 $\mathbb{P}(\biguplus_{n=1}^N A_n) = \sum_{n=1}^N \mathbb{P}(A_n)$;
- (v) $\mathbb{P}(A^c) = 1 - \mathbb{P}(A), \forall A \in \mathcal{F}$.

显然, 性质 (v) 可由性质 (iii)、(iv) 导出。

例 2.1. 投掷一枚 (外形规则、质地均匀的) 骰子, 请问获得偶数点的概率?

参考解答: 我们可以取骰子投掷出的点数作为基本结果, 于是取

$$\Omega := \{1, 2, 3, 4, 5, 6\}$$

作为样本空间, 并认为此时等可能性成立; 此时 “投掷一枚骰子获得偶数点” 这一事件为 $A := \{2, 4, 6\}$, 因此所求概率为 $\mathbb{P}(A) = \frac{|A|}{|\Omega|} = \frac{3}{6} = \frac{1}{2}$. $\square$

我们看到, 在古典概率模型中经常需要计算一些特定集合中的元素个数, 因此我们在下一小节中展开这方面的讨论²。

2.2.2 计数方法简介

在中学阶段, 我们已经学习过关于计数的两个基本原理—**加法原理**与**乘法原理**, 自然语言的表述如下:

- ◆ **加法原理** (又称**分类加法计数原理**) 完成某件事有 $r \geq 2$ 类方法³, 记第 i 类中有 n_i 种方法 ($i = 1, \dots, r$), 则完成该事总共有 $N = n_1 + \dots + n_r$ 种方法;
- ◆ **乘法原理** (又称**分步乘法计数原理**) 完成某件事有 $r \geq 2$ 个步骤, 设第 i 个步骤有 n_i 种方法 ($i = 1, \dots, r$) 实现, 则完成该事总共有 $N = n_1 \cdot n_2 \cdots n_r$ 种方法。

¹这个结果最早是 De Moivre 明确陈述的, 称之为全概率定理 (theorem of total probability) 或加法定理 (addition theorem)。

²虽然古典概率模型的理论既基础又重要, 但它毕竟只是整个概率理论中最简单的部分, 因而我们在此处提醒读者: 在整个初等概率论的学习过程中, 不要因为偏爱组合计数技巧的原因而过多追求复杂的计数理论与实例, 以致影响其他部分概率理论的学习。

³这里要求不同类之间没有交叉, 不会出现既是 A 类又是 B 类的情况。

在学习了映射的概念之后, 我们也有通过映射来计数的办法; 这同时也是 Cantor 研究集合的势/基数 (cardinality) 的出发点, 只不过此处我们仅重点考虑了元素个数有限的集合。

♠ **定理 2.2.1.**¹ 设 $f: A \rightarrow B$ 是一个映射, 其中 A, B 都是 (有限) 集合。那么

(1) 当 f 是单射时, $|A| \leq |B|$;

(2) 当 f 是满射时, $|A| \geq |B|$;

(3)² 当 f 是双射时, $|A| = |B|$ 。

在上述映射的计数方法观点下, 之前的加法原理与乘法原理也可以借助集合论的语言简练而精确地表述为如下定理。

♠ **定理 2.2.2.** (加法原理与乘法原理)

(1) **加法原理:** 当 $A \cap B = \emptyset$ 时, $|A \uplus B| = |A| + |B|$;

(2) **乘法原理:** $|A \times B| = |A| \cdot |B|$, 其中 $A \times B := \{(x, y) : x \in A, y \in B\}$ 。

以下几个例子中的结论在有关计数问题中非常有用。

例 2.2. 我们有以下一些排列组合计数的简单实例:

(a) (直线) 排列: 从 $1, 2, \dots, n$ 中选出 $m \leq n$ 个数, 排成一行 (亦即形成一个 m 维有序数组/向量) 的方法数是 $A_n^m = \frac{n!}{(n-m)!}$;

(b) 组合: 从 $1, 2, \dots, n$ 中选出 $m \leq n$ 个数形成一个 m 元的 (无序) 集合的方法数是 $C_n^m = \binom{n}{m} := \frac{n!}{m!(n-m)!}$;

(c) 圆排列: $1, 2, \dots, n$ 这 n 个数排成一圈的方法数是 $(n-1)!$; 这里, 排列 $a_1, a_2, \dots, a_n$ 和 $a_i, a_{i+1}, \dots, a_n, a_1, \dots, a_{i-1}$ 被认为是同一个排列。

例 2.3. (二项式系数与多项式系数) 设 $n \in \mathbb{N}$. $(1+x)^n$ 的二项式展开式为

$$(1+x)^n = \sum_{k=0}^n \binom{n}{k} x^k,$$

组合数 $\binom{n}{k}$ 是 x^k 的系数, 因此又称为二项式系数。

¹ 这一结果在文献^[56]中也被称为 Schröder-Bernstein 定理。

² 此处的一个推论是实分析中的 Cantor 定理: A 与其幂集 2^A 总是具有不同的势 (或基数)。

又设 $r \geq 2$ 是自然数, 多项式 $(x_1 + \cdots + x_r)^n$ 的展开式为

$$(x_1 + \cdots + x_r)^n = \sum_{\substack{k_1 \geq 0, \dots, k_r \geq 0 \\ k_1 + \cdots + k_r = n}} \frac{n!}{k_1! \cdots k_r!} \cdot x_1^{k_1} \cdots x_r^{k_r}.$$

$\frac{n!}{k_1! \cdots k_r!} =: \binom{n}{k_1 \cdots k_r}$ 是 $x_1^{k_1} \cdots x_r^{k_r}$ 的系数, 称为多项式系数。

例 2.4. 考虑未知数 $x_1, \dots, x_r$ 的不定方程 (其中 $r \geq 2, n, r \in \mathbb{N}$ 为已知数)

$$x_1 + \cdots + x_r = n. \quad (*)$$

令 $t_j := x_1 + \cdots + x_j, j = 1, \dots, r-1$. 则不定方程 $(*)$ 的正整数解满足:

$$1 \leq t_1 < t_2 < \cdots < t_{r-1} \leq n-1,$$

且 $(x_1, \dots, x_r)$ 与 $(t_1, \dots, t_{r-1})$ 之间一一对应, 因此

- (i) 不定方程 $(*)$ 的正整数解个数为 $\binom{n-1}{r-1}$;
- (ii) 不定方程 $(*)$ 的非负整数解个数为 $\binom{n+r-1}{r-1}$.

把一些计数问题的求解转化为类似于上述不定方程在适当约束下解的数目的计算, 这样的观点与思想方法有时会给计数带来便利, 读者应当学会掌握。

接下来我们介绍古典概率模型的一些经典的应用实例。

2.2.3 古典概率模型应用实例: (1) Pólya 坛子模型

我们首先介绍有放回的 Pólya 坛子模型。

例 2.5. Pólya 坛子模型 (有放回) 坛内有 b 个黑球, r 个红球, 每次随机地取一球, 观察记录球的颜色后放回坛中。记 B_j 为“第 j 次取球时取到黑球”, $R_j = B_j^c$ 为“第 j 次取球时取到红球”, 则:

- (1) $\mathbb{P}(B_j) = \frac{b}{b+r} =: p, \quad \mathbb{P}(R_j) = \frac{r}{b+r} =: q = 1 - p, \forall j$;
- (2) $\mathbb{P}(\text{连续 } n \text{ 次取球, 恰共取得 } k \text{ 个黑球}) = \binom{n}{k} p^k q^{n-k}, 0 \leq k \leq n$.

参考解答: 如果要使用古典概率模型来计算上述有关事件的概率, 我们实际上无法通过只建立一个 (有限个样本点的) 样本空间就一劳永逸地解决上述所有事件 $\{B_j, R_j\}_{j=1}^\infty$ 的概率计算。

(1) 为了计算 $\mathbb{P}(R_j)$ 和 $\mathbb{P}(B_j)$, 我们可以如下方式建模: 假想我们给黑球和红球编号为 $1, \dots, b+r$; 记 $B = \{1, \dots, b\}, R := \{b+1, \dots, b+r\}$. 约定:

编号 x 的球是黑球 $\Leftrightarrow x \in B$; 编号 x 的球是红球 $\Leftrightarrow x \in R$.

设第 k 次取球所得编号是 x_k . 于是下面的样本空间 Ω_j 设置能穷尽从第一次直到第 j 次取球的所有有必要关心的细节: 令 $\Sigma := \{1, \dots, b+r\}$, 并设置

$$\Omega_j := \Sigma^j = \{x = (x_1, \dots, x_j) : x_k \in \Sigma, k = 1, \dots, j\}.$$

这样设置的样本空间也符合我们的有放回规则下的“随机取球”的等可能性假定. 于是在上述建模下

$$B_j = \Sigma^{j-1} \times B, \quad R_j = \Sigma^{j-1} \times R.$$

因此 $\mathbb{P}(B_j) = \frac{|B_j|}{|\Omega_j|} = \frac{b}{b+r} =: p$, $\mathbb{P}(R_j) = \frac{|R_j|}{|\Omega_j|} = \frac{r}{b+r} =: q = 1 - p$;

(2) 为了计算 $\mathbb{P}$ (连续 n 次取球, 恰共取得 k 个黑球) (此处不妨设 $1 \leq k \leq n$, $k=0$ 的情形可以类似处理), 使用样本空间 Ω_n , 并对任意 $1 \leq j_1 < \dots < j_k \leq n$, 记

$$A_{j_1, \dots, j_k} := \{x \in \Sigma^n : x_{j_\ell} \in B, \ell = 1, \dots, k, x_i \in R, \forall i \notin \{j_1, \dots, j_k\}\},$$

它代表第 $j_1, \dots, j_k$ 次均取得黑球、其余 $n-k$ 次取得红球这一复杂事件, 则 $|\Omega_n| = (b+r)^n$, 且

$$|A_{j_1, \dots, j_k}| = |A_{1, \dots, k}| = |B^k \times R^{n-k}| = b^k r^{n-k}.$$

于是

$$\begin{aligned} & \mathbb{P}(\text{连续 } n \text{ 次取球, 恰共取得 } k \text{ 个黑球}) \\ &= \sum_{1 \leq j_1 < \dots < j_k \leq n} \mathbb{P}(A_{j_1, \dots, j_k}) \\ &= \sum_{1 \leq j_1 < \dots < j_k \leq n} \frac{b^k r^{n-k}}{(b+r)^n} = \binom{n}{k} p^k q^{n-k}. \end{aligned}$$

于是这里自然而然地出现了以后第五章将介绍的二项分布的概率分布列. $\square$

现在我们介绍无放回的 Pólya 坛子模型。

例 2.6. Pólya 坛子模型 (无放回) 坛内有 b 个黑球, r 个红球; 每次随机地取走一球, 观察记录球的颜色后并不再放回坛中. 记 B_j 为第 j 次取到黑球, $R_j = B_j^c$ 为第 j 次取到红球, 则:

$$(1) \mathbb{P}(B_j) = \frac{b}{b+r}, \mathbb{P}(R_j) = \frac{r}{b+r}, 1 \leq j \leq b+r;$$

$$(2) \mathbb{P}(\text{连续 } n \text{ 次取球, 恰共取得 } k \text{ 个黑球}) = \frac{\binom{b}{k} \binom{r}{n-k}}{\binom{b+r}{n}}, \quad (n-r)^+ \leq k \leq b \wedge n.$$

参考解答: (1) 在无放回的规则下, 我们的概率空间设置略有差别。此处, Σ, B, R 的定义同上。但修改设定

$$\Omega_j := \{x = (x_1, \dots, x_j) \in \Sigma^j : \text{其中 } x_1, \dots, x_j \text{ 两两不同}\}.$$

此时在上述建模下

$$B_j = \{x \in \Omega_j : x_j \in B\}, \quad R_j = \{x \in \Omega_j : x_j \in R\}.$$

于是 $|\Omega_j| = \binom{b+r}{j} \cdot j!$, $|R_j| = \binom{r}{1} \binom{b+r-1}{j-1} \cdot (j-1)!$, 从而 $\mathbb{P}(R_j) = \frac{|R_j|}{|\Omega_j|} = \frac{r}{b+r}$, 进而 $\mathbb{P}(B_j) = 1 - \mathbb{P}(R_j) = \frac{b}{b+r}$.

(2) 的解答留给读者; 其中的概率值跑遍 $(n-r)^+ \leq k \leq b \wedge n$ 时对应于后续第五章中将介绍的超几何分布的概率分布列。□

上例中结论 (1) 也说明了我们日常生活中用抓阄的方法来实现分配不充足的资源的“程序公平性”¹, 见下例中讨论。

例 2.7. (抓阄的公平性) 假设有 r 项奖品, 共有 $n \geq r$ 个人来共同分配 (每人不允许获得两项及以上的奖品), 因此采取抓阄的方式来实现: 用 r 个红球代表奖品, 用 $b = n - r$ 个黑球代表无奖品, 然后采用无放回的方式取球 n 次。这种抓阄方式是“程序公平”的: 抓阄次序不影响分配的等可能性。

在第三章的例 3.12 中, 我们将用条件概率的方法再次给出上述抓阄的公平性的证明。

2.2.4 古典概率模型应用实例: (2) 同生日问题

例 2.8. (同生日问题) 为方便计算, 我们假定一年有 $N = 365$ 天; 说两个人同一天生日, 如果他们出生的日子是同一个 (公历) 月的同一天。现在假定某班级共有 $n = 50$ 位同学, 请问该班级中有同学同一天生日的概率有多大?

参考解答: 我们认为每个人的生日等可能性地出现在 $N = 365$ 天中的任意一天。用 A_n 表示班级的 n 人中至少有两人同生日。那么容易知道

$$p_n := \mathbb{P}(A_n) = 1 - \mathbb{P}(A_n^c) = 1 - \frac{n! \binom{N}{n}}{N^n} = 1 - \frac{N!}{(N-n)! N^n}.$$

在此基础上我们通过编程计算, 得到一张 p_n 的简单表格, 见表 2.1.

¹ 此处所说的公平性只是局限于单次分配来讲的“程序公平性”, 即分配中抓阄次序是无关紧要的。对于尽管单年度而言不充足、但常年都会稳定出现的资源的分配, 每年都采用同样的抓阄模式直观上给人感觉也未必是公平或合理的: 有正概率 (通常也是相对小的概率) 发生同一人连续年度获得该不充足的资源; 当这种“小概率”事件真实发生时, 有关分配程序在现实世界中的公平性就可能被质疑。

表 2.1: 同生日问题中的同生日概率值数列 (部分)

n	20	21	22	23	25	30	35	40
p_n	0.4114	0.4437	0.4757	0.5073	0.5687	0.7063	0.8144	0.8912
n	45	50	55	60	65	70	75	80
p_n	0.9410	0.9704	0.9863	0.9941	0.9977	0.9992	0.9997	0.9999

表2.1告诉我们：如果班级人数超过 23 人，就有超过一半的概率有人同生日；到了 50 人的大班级，有两人同生日的概率已经高达 97%；到了 80 人的超大班级，这个概率已经非常接近 1，可以认为有两个人同生日是近乎必然的事情了。 □

这里，上述问题的答案有点反直觉的一个原因可能是：概率的直观来源于人们对频率的认识；在少于 80 人的团体中成对同生日人的“总体占比”确实不高(比如 50 人的团体中,平均约有 3.36 对同生日,“占比”约为 $3.36/50 \approx 6.72\%$,请读者参见习题6.33)，而人们的大脑容易混淆同生日人的对数的人群占比和人群中同生日现象发生的概率/频率这两个不同的量。

📌 笔记 2.1. 结合上面计算公式与表格，不难感受到，在一个只有 30 人的中小型班级里，有两人生日至多相差一天的概率也会非常高。建议有兴趣的读者给出这个概率的计算公式，用计算机编程得出实际计算结果，并在自己所在的小团体中进行这方面的社会调查。这是一个不难但有意思的问题。

现在，假设正在上这门初等概率论课程的老师想知道他/她的班上是否有学生与老师自己的生日是同一天，假定这个班上有 $n = 50$ 个学生。或许有人在学习过上一例题后会把有学生与任课老师同一天生日这一事件（记作 B_n ）类比于上例中的事件 A_n ，认为 B_n 发生的概率也很高，这是否对呢？

实际上此处 A_n, B_n 是完全不同的事件， B_n 的概率计算与上一例中 A_n 的概率计算是完全不同；这里，任课老师的生日是一年中的特定的一天，因此（同样取一年的天数为 365）

$$\mathbb{P}(B_n) = 1 - (1 - \frac{1}{365})^n.$$

当 $n = 50$ 时， $\mathbb{P}(B_{50}) = 1 - (1 - \frac{1}{365})^{50} \approx 12.82\%$ ，这是一个不算大的概率。即使教师任教的班级规模达到 $n = 365$ ，仍然有 36.74% 的概率使得任课老师找不到与其同生日的学生，这一概率值接近于 $\frac{1}{e} \approx 36.79\%$ 。

2.2.5 古典概率模型应用实例：(3) 唱票问题与反射原理

例 2.9. (唱票问题) 某项公开选举中有且仅有甲、乙两个候选人，已知甲获得

了 m 票, 乙获得了 n 票, 其中 $m > n$. 假定这 $m+n$ 张选票均匀混合, 那么唱票过程中, 甲的票数始终严格领先的概率有多大?

参考解答: 取 $\Sigma := \{+1, -1\}$. 对任意 $x = (x_1, \dots, x_{m+n}) \in \Sigma^{m+n}$, 以 $x_k := +1$ 表示第 k 张票是支持甲的, 否则 $x_k := -1$. 于是

$$S_k = S_k(x) := x_1 + \dots + x_k \quad (2.6)$$

代表了到第 k 张选票唱完后甲领先乙的票数; 在《随机过程》课程中, 这样定义的序列 $\{S_k\}_{k=1}^\infty$ 称为 $\mathbb{Z}$ 上随机游动, $x_k := +1$ 表示代表随机游动在第 k 步时向右走 1 单位长度, $x_k := -1$ 表示做随机游动的粒子在第 k 步时向左发生 1 单位长度的位移, 而 S_k 则代表该粒子在 k 步后相对原始位置的位移. 我们可以建立如下的古典概率模型的样本空间:

$$\Omega = \Omega_{m,n} := \{x \in \Sigma^{m+n} : S_{m+n} = m - n\}.$$

容易知道, $|\Omega| = |\Omega_{m,n}| = \binom{m+n}{m} = \frac{(m+n)!}{m!n!}$. 我们所关心事件是

$$A := \{x \in \Omega : S_k > 0, k = 1, 2, \dots, m+n\}.$$

现在, 问题的关键在于如何计算出 $|A|$.

事件 A 过于复杂. 简单点, 定义

$$A_1 := \{x \in \Omega : S_1 > 0\} \supset A.$$

则 $A_1 = \{x \in \Sigma^{m+n} : x_1 = 1, S_{m+n} = m - n\} = \{1\} \times \Omega_{m-1,n}$, 由此

$$|A_1| = |\Omega_{m-1,n}| = \frac{(m+n-1)!}{(m-1)!n!}.$$

现在来看 $B := A_1 \setminus A = \{x \in A_1 : \exists j \in (1, m+n), S_j \leq 0\}$, 不难知道

$$B = \{x \in A_1 : \exists j \in (1, m+n), S_j = 0\}.$$

我们想计算 $|B|$, 为此构造一个合适的一一映射:

$$f : B \rightarrow f(B),$$

就会有 $|B| = |f(B)|$, 当然我们希望后者容易计算。

我们用反射的方法来实现。首先对任意 $x \in B$, 定义

$$\tau = \tau(x) := \inf\{k > 0 : S_k = 0\}.$$

容易知道 $1 < \tau < m+n$, 并且此时 $S_{\tau(x)}(x) = 0, \forall x \in B$. 之后, 我们定义映射 $\{S_j\}_{j=1}^{m+n} \mapsto \{\tilde{S}_j\}_{j=1}^{m+n}$ 如下: 约定 $\tilde{S}_0 := 0$, 并记

$$\tilde{S}_k := \begin{cases} S_k, & 1 \leq k \leq \tau, \\ -S_k, & \tau < k \leq m+n. \end{cases}$$

进而再由此定义 $\tilde{x}_k := \tilde{S}_k - \tilde{S}_{k-1}, k = 1, \dots, m+n$. 这样我们就给出了映射

$$x \in B \xrightarrow{f} \tilde{x} = (\tilde{x}_1, \dots, \tilde{x}_{m+n}) \in \Sigma^{m+n}.$$

不难知道 f 是单射, 并且

$$f(B) = \{x \in \Sigma^{m+n} : x_1 = 1, S_{m+n} = n-m, \exists j \in (1, m+n), S_j = 0\}.$$

注意到 $x \in f(B)$ 时, $S_1 = 1 > 0, S_{m+n} = n-m < 0$, 因此实际上有

$$f(B) = \{x \in \Sigma^{m+n} : x_1 = 1, S_{m+n} = n-m\} = \{1\} \times \Omega_{n-1, m}.$$

从而 $|B| = |f(B)| = |\Omega_{n-1, m}| = \frac{(m+n-1)!}{(n-1)!m!}$. 于是

$$\begin{aligned} |A| &= |A_1 \setminus B| = |A_1| - |B| \\ &= \frac{(m+n-1)!}{(m-1)!n!} - \frac{(m+n-1)!}{(n-1)!m!} \\ &= \frac{(m+n-1)!}{m!n!} \cdot (m-n). \end{aligned}$$

结合 $|\Omega| = \frac{(m+n)!}{m!n!}$, 立即得到 $\mathbb{P}(A) = \frac{|A|}{|\Omega|} = \frac{m-n}{m+n}$. $\square$

上述问题的解答中通过构造反射来实现计数, 该思想方法被称为**反射原理**。在概率论的一些高级课程中, 读者将学习研究随机游动和 Brown 运动相关的一些更复杂的问题, 在那里这个方法发挥了重要作用。




图 2.2: 反射原理示意图

2.2.6 古典概率模型应用实例: (4) 图论中的染色问题

Paul Erdős (埃尔德什, 1913—1996; 匈牙利籍犹太裔) 首创把概率论应用于图论问题, 他与 Rényi (雷尼) 的工作开创了随机图这一概率论与图论的交

叉研究方向,对当今的复杂网络等研究方向有重要影响。下面的完全图的边染色问题,又称 Ramsey (拉姆塞) 问题,就来源于 Erdős 关于 Ramsey 数的下界估计的工作。

例 2.10. (Ramsey 问题) 给定两个自然数 p, n , 其中 $3 \leq p < n$. 如果

$$\binom{n}{p} < 2^{\binom{p}{2}-1}, \quad (2.7)$$

那么存在一种把完全图 K_n 的所有边染成红、蓝二色的染色方案,使得染色后的完全图 K_n 中找不到单色的完全子图 K_p . 亦即,二染色的 Ramsey 数¹ $r_2(p, p)$ 满足

$$r_2(p, p) \geq \inf\{n : \binom{n}{p} \geq 2^{C_p^2-1}\},$$

从而 $r_2(p, p) \geq 2^{\frac{p}{2}}$.

参考解答: 把完全图 K_n 的边编号为 $1, 2, \dots, N := \binom{n}{2}$; 定义 $\Omega := \{0, 1\}^N$. 如果 i 号边染成红色, 则记 $\omega_i = 1$, 否则记 $\omega_i = 0$. 于是任意

$$\omega := (\omega_1, \dots, \omega_N) \in \Omega$$

就是一种染色方案; 这里核心的思想是, 为了说明具有特定性质 A 的染色方案存在 (即 $A \neq \emptyset$, 其中 A 表示具有特定性质 A 的染色方案的全体), 我们只需要证明存在某个概率测度 $\mathbb{P}$ 使得 $\mathbb{P}(A) > 0$.

我们将把一种染色方案 $\omega \in \Omega$ 视作一个映射

$$\omega : \{1, \dots, N\} \rightarrow \{0, 1\}, \quad i \mapsto \omega_i.$$

考虑以 Ω 为样本空间的古典概率模型². 设事件 A 为染色后的完全图 K_n 中存在单色的完全子图 K_p . 对于任一给定的 K_p 子图 B , 记它的边的序号形成的集合为 $\tilde{B}$, $B \mapsto \tilde{B}$ 是一一对应; 记 K_p 子图的全体为 $\mathcal{G}_{n,p}$, 显然 $|\mathcal{G}_{n,p}| = \binom{n}{p}$. 对任意 $B \in \mathcal{G}_{n,p}$, B 是单色子图这一事件为

$$\hat{B} := \{\omega \in \Omega : \omega|_{\tilde{B}} \equiv 0 \text{ 或 } \omega|_{\tilde{B}} \equiv 1\},$$

¹此处 $r_2(p, q)$ 代表一个完全图 K_n 为了在边的任意红、蓝二染色方案下都有红色完全子图 K_p 或蓝色完全子图 K_q 的最小顶点数目 n , 显然 $r_2(p, q) = r_2(q, p)$; 据说目前仅已知 9 个精确的 Ramsey 数 $r_2(p, q)$, $p \leq q$: $r_2(3, 3) = 6, r_2(3, 4) = 9, r_2(3, 5) = 14, r_2(3, 6) = 18, r_2(3, 7) = 23, r_2(3, 8) = 28, r_2(3, 9) = 36, r_2(4, 4) = 18, r_2(4, 5) = 25$. 其他 $r_2(p, q)$ 有的能知道粗略取值范围, 例如 $43 \leq r_2(5, 5) \leq 49$.

²借助第三章介绍的独立性术语, 这个古典概率模型也可解释成每边等可能性地独立于其他边染两种颜色之一的随机染色模型。

它满足 $\mathbb{P}(\hat{B}) = 2 \cdot \left(\frac{1}{2}\right)^{\binom{p}{2}} = 1/2^{\binom{p}{2}-1}$. 注意到 $A = \bigcup_{B \in \mathcal{G}_{n,p}} \hat{B}$, 我们有

$$\mathbb{P}(A) = \mathbb{P}\left(\bigcup_{B \in \mathcal{G}_{n,p}} \hat{B}\right) \leq \sum_{B \in \mathcal{G}_{n,p}} \mathbb{P}(\hat{B}),$$

于是在条件(2.7)下, $\mathbb{P}(A) \leq \binom{n}{p} / 2^{\binom{p}{2}-1} < 1$, 即 A^c 非空, 从而存在一种染色方案, 使得染色后的完全图 K_n 中找不到单色的完全子图 K_p . $\square$

《数学天书中的证明》一书还提供了 Erdős 贡献的更多与图染色有关问题的概率解答, 见文献^[2]第 261—268 页.

2.3 几何概率模型

本节我们介绍古典概率论中另一个自然的等可能性概率模型: **几何概率模型**. 我们先给出它的定义与性质, 之后介绍它的一些应用实例, 最后介绍非常重要的 **Bertrand 悖论**. 这个悖论的出现是导致 1889—1933 那段时期概率学家们去努力追寻概率公理化的一个重要因素.

2.3.1 几何概率模型简介

有些复杂的“随机试验”可以建模为“几何概率模型”. 在几何概率模型中, 我们要求:

- ◆ 随机试验的所有可能的“基本结果”的数量是不可数的无穷多个;
- ◆ 认为这些“基本结果”是具有同等可能性发生的;
- ◆ 所有可能的“基本结果”的全体可以建模成某个欧氏空间 $\mathbb{R}^d$ 中的一个“体积”有限区域 Ω , 称为**样本空间**; 每个“基本结果”对应于 Ω 中的一个点 ω , 称为**样本点**.

此时,

- (1) 样本空间 $\Omega \subset \mathbb{R}^d$ 是一个“体积”有限的区域: $0 < |\Omega| < \infty$, 这也意味着 Ω 必须是 $\mathbb{R}^d$ 中的可测集 (通常是 **Borel** 可测集);
- (2) 样本空间 Ω 中元素 ω 称为样本点, 认为不同样本点具有同等大小的可能性发生;

(3) 事件 $A \subset \Omega$ 并不是都可以谈论概率, 能谈论概率的事件全体可取为

$$\mathcal{F} := \Omega \cap \mathcal{B}^d,$$

其中 $\mathcal{B}^d$ 代表 $\mathbb{R}^d$ 上的 Borel σ -代数 (参见第四章 §4.1), 它是 Ω 的 Borel 可测子集的全体;

(4) $A \in \mathcal{F}$ 时, A 事件发生的概率定义为“区域” A 的“体积”与 Ω 的“体积”之比

$$\mathbb{P}(A) := \frac{|A|}{|\Omega|}. \quad (2.8)$$

这是 (2) 中自然语言所陈述的性质对应的精确数学表达。

不难知道, 之前在古典概率模型中陈述的几条性质对于几何概率模型仍然成立, 我们再次陈述如下。对几何概率模型, $\mathbb{P}: \mathcal{F} \rightarrow \mathbb{R}$ 具有以下一些性质:

(i) (非负性) $\mathbb{P}(A) \geq 0, \forall A \in \mathcal{F};$

(ii) (平凡性) $\mathbb{P}(\emptyset) = 0;$

(iii) (归一性) $\mathbb{P}(\Omega) = 1;$

(iv) (有限可加性) 设 $\{A_n\}_{n=1}^N \subset \mathcal{F}$ 互斥, 则 $\mathbb{P}\left(\biguplus_{n=1}^N A_n\right) = \sum_{n=1}^N \mathbb{P}(A_n);$

(v) $\mathbb{P}(A^c) = 1 - \mathbb{P}(A), \forall A \in \mathcal{F};$

特别是在几何概率模型中, 我们有更强的 σ -可加性 (即可数可加性) 成立:

(iv') (σ -可加性) 设 $\{A_n\}_{n=1}^{\infty} \subset \mathcal{F}$ 互斥, 则 $\mathbb{P}\left(\biguplus_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mathbb{P}(A_n).$

在古典概率模型中 (iv') 当然也成立, 只不过那时 $\mathcal{F} = 2^\Omega$ 中元素个数是有限的, 该性质只是平凡性与有限可加性的简单而平凡的结合。

2.3.2 几何概率模型应用实例

例 2.11. (约会问题) 甲乙二人约定在 11:00-12:00 之间到某商场碰面, 先到者等后来者 20 分钟, 如果没有等到就自行离去。请问此二人约会成功的概率?

参考解答： 为方便，以 $x, y \in [0, 60]$ 表示甲、乙的到场时间（表示他们分别在 11 点过 x 分、 y 分的时候到达商场）。于是可设置约会问题的样本空间为

$$\Omega := [0, 60]^2 = \{(x, y) : x, y \in [0, 60]\}.$$

则根据题设，“约会成功”这一事件 A 可以表示为

$$A := \{(x, y) \in [0, 60]^2 : |x - y| \leq 20\}.$$

容易看到， $|\Omega| = 60^2, |A^c| = 40^2$ ，于是

$$\mathbb{P}(A) = 1 - \mathbb{P}(A^c) = 1 - \frac{|A^c|}{|\Omega|} = 1 - \frac{40^2}{60^2} = \frac{5}{9}.$$

□




图 2.3: 约会问题（例2.11）示意图

例 2.12. (Buffon 投针问题) 在地面上有无数条等间隔的平行线（设间隔为 L ），某人拿着一个材质均匀的短针（其长度记作 ℓ ）随机地投向地面，请问短针与这组平行线相交（只需要与平行线中任意一条相交，我们就说针与这组平行线相交）的概率？（为方便，此处假设 $0 < \ell < L$ ）

参考解答： 落在地面时，短针的中点 M 与最近的平行线的距离 $d \in [0, L/2]$ 、短针与平行线的夹角 $\theta \in [0, \pi]$ 这两个参数能完整描述短针落在两条相邻平行线之间的相对位置。因此，我们不妨设样本空间为




图 2.4: Buffon 投针问题（例2.12）示意图

$$\Omega := \{(d, \theta) : d \in [0, L/2], \theta \in [0, \pi]\}.$$

短针与最近的平行线相交这一事件 A 可以表达为

$$A := \{(d, \theta) \in \Omega : d / \sin \theta \leq \ell / 2\}.$$

显然 $|\Omega| = \frac{L}{2} \cdot \pi = \frac{\pi L}{2}$ ， $|A| = \int_0^\pi \frac{\ell}{2} \sin \theta d\theta = \ell$ 。于是

$$\mathbb{P}(A) = \frac{|A|}{|\Omega|} = \frac{2\ell}{\pi L}.$$

□

📌 注记 2.2. Buffon 投针问题具有如下特殊的历史地位与意义：

(1) 历史上第一个几何概率问题；

表 2.2: 历史上用蒲丰投针实验估计圆周率的实验记录

实验者	时间	投掷次数	相交次数	圆周率估计值	ℓ/L 的推算值
Buffon	1777 年	2212	704	3.142	0.500
Wolf	1850 年	5000	2532	3.1596	0.800
Smith	1855 年	3204	1218.5	3.1554	0.600
De Morgan	1860 年	600	382.5	3.137	1.000
Fox	1884 年	1030	489	3.1595	0.750
Lazzerini	1901 年	3408	1808	3.1415929	0.833
Reina	1925 年	2520	859	3.1795	0.542

(2) 记短针与平行线相交概率为 p ，则圆周率有表达式： $\pi = \frac{2\ell}{pL}$ 。因此，历史上自 Buffon 开始就有许多人通过做投针实验，以短针与平行线相交的频率 $\hat{p}$ 来代替概率 p 的方式，测算圆周率 $\pi \approx \frac{2\ell}{\hat{p}L}$ ，并且发现在大样本下该方法确实具有一定的精度，参见表格 2.2（注意，不同实验者的数据之间没有可比性；Buffon 的实验除外，表格中最后一列参数 ℓ/L 是我们根据前人的表单反推算出来的）；

(3) 上述众多实验事实（见表 2.2）印证了前述投针问题的几何概率建模的合理性。因此，Buffon 投针问题的理论与实践两个方面很好地印证了我国马克思主义理论界提出的“实践是检验真理的（唯一）标准”¹这一哲学理论；

(4) 上述通过做随机试验的办法来计算确定性数学量或物理量等的方法，与计算机技术结合，被发展为如今著名的 Monte-Carlo（蒙特卡洛）方法。因而，Buffon 投针实验可以认为是 Monte-Carlo 方法的鼻祖。

在本章后面的例 2.16 及习题 2.61 中我们进一步讨论了投掷各种形态的小“针”的 Buffon 投针问题，最后的结论是：平面凸多边形的小“针”与间隔 L 的平行线相交的概率为

$$\text{相交概率} = \frac{\text{“小针”的“周长”}}{\pi L}.$$

在第六章引入数学期望概念后，我们将给出 Buffon 投针问题的另一种解答，巧妙地“证明”²了上面的结论，参见例 6.1.

2.3.3 Bertrand 悖论

Bernoulli 在总结前人关于古典概率模型的研究时，提出了不充分理由原理（Insufficient Reason Principle）：如果因为无知，使得我们没有办法判断哪

¹ “社会实践是检验真理的唯一标准”的原话，是毛泽东最先在 1963 年 11 月提出来的。之后，1978 年 5 月 10 日中央党校内部刊物《理论动态》发表经胡耀邦审阅定稿的文章《实践是检验真理的唯一标准》，同年 5 月 11 日《光明日报》再次以特约评论员名义发表、并受到新华社转发。

² 其中需要承认相交概率对小“针”形状连续依赖性。

种（基本）结果会比另一种（基本）结果更容易出现，那么应该给予它们相同的概率。比如¹

- (1) 硬币：由于不清楚硬币哪一面更容易出现，应当给予硬币的正面、反面相同的概率，即 $\frac{1}{2}$ ；
- (2) 骰子：由于不清楚骰子不同点数的面哪一面更容易出现，应当给予骰子的每一面相同的概率，即 $\frac{1}{6}$ 。

1812 年 Laplace 在他的著作中进一步把不充分理由原理的使用范围扩充到几何概率模型中，提出“未知的概率均为等概率”，依此原则建立了他的分析概率论，并且这一理论确实取得了辉煌的成绩。因此整个 19 世纪人们都对此原则确信无疑，直至 Bertrand 于 1889 年在他的著作《Calcul des probabilités》中提出了以他姓氏冠名的悖论²。

例 2.13. (Bertrand 悖论) 在单位圆上随机地取一条弦，求此弦长超过圆的内接正三角形边长的概率？（至少有三种对随机取弦的理解，从而有至少三个不同的答案。）

Bertrand 悖论中“随机地取一条弦”的三种理解

- (1) 随机地在单位圆周上取两点，从而确定一条弦；
- (2) 在单位圆内随机地选一点，把它作为弦的中点，从而确定一条弦；
- (3) 在单位圆上随机地选一条直径，之后在这条直径上随机地选一个点作为弦的中点，从而确定一条弦。




图 2.5: Bertrand 悖论（例2.13；红线长于正三角形边长，蓝线短于正三角形边长）

Bertrand 悖论的解答 (1): 我们在单位圆周上选定一点 P 后，可以在单位圆周上找到另外两点 P_2, P_3 ，使得 P, P_2, P_3 三点按逆时针顺序等间距地落在单位

¹这里通常默认所讨论的硬币或骰子是材质均匀、形状规则的。

²也有文献说 Bertrand 悖论是在 1888 年提出的。另，在文献^[90]中也提及 Bertrand 提出的另两个与几何概率模型无关的悖论。

圆周上。此时再随机选另一点 Q ，弦 PQ 要大于单位圆的内接正三角形边长的充要条件是： Q 落在圆弧 $\widehat{P_2P_3}$ 的内部（记作事件 A ），这部分圆弧占单位圆周总弧长的 $1/3$ 。因而所求概率为 $\mathbb{P}(A) = \frac{1}{3}$ 。□

Bertrand 悖论的解答（2）： 单位圆内弦长大于单位圆的内接正三角形边长的充要条件是：弦的中点落在与单位圆同心， $1/2$ 为半径的同心圆的内部（记作事件 A ）。于是所求概率为 $\mathbb{P}(A) = (\frac{1}{2})^2 = \frac{1}{4}$ 。□

Bertrand 悖论的解答（3）： 在先随机取直径，之后再随机地在直径上取一点作为弦中点的情况下，弦长大于单位圆的内接正三角形边长的充要条件是：弦的中点落在选定的直径上的与单位圆心距离不超过 $1/2$ 的线段内部（记作事件 A ）。因此所求概率为 $\mathbb{P}(A) = \frac{1}{2}$ 。□

后人还类似地构造出了 Bertrand 悖论的其他版本。下面例子取自知乎社区的“马同学”关于 Bertrand 悖论的回答。

例 2.14. 有一家锯木厂，它会把木头切成不同的木方，木方的截面都是正方形，边长会在 $1 \sim 3$ 尺之间浮动¹；那么根据几何概率，该锯木厂生产出来的正方形边长在 $1 \sim 2$ 尺之间的概率为多少？

两种不同概率值的回答： 这里，木方的长度和面积都是未知的。

如果对“长度”来运用“不充分理由原理”，也就是认同“长度”上的等可能性假设，则所求概率为

$$\frac{2-1}{3-1} = \frac{1}{2}.$$

如果对“面积”来运用“不充分理由原则”，也就是认同“面积”上的等可能性假设，则所求概率为

$$\frac{2^2-1^2}{3^2-1^2} = \frac{3}{8}.$$

本问题中悖论出现的根源就在于对自然语言中“等可能性”（通常也对应“随机”这一字眼）的不同解读。□

📌 笔记 2.3. (*Bertrand 悖论的历史地位与意义*) Bertrand 悖论的提出，促使人们开始认真思考概率这一概念本身，并严谨地检查概率论的理论基础。1900 年 Hilbert 提出他的 23 个数学问题，并倡导公理化运动，此后概率论方向的先贤也开始了概率的公理化的探索。

1933 年 Kolmogorov 完成概率论的公理化后，这个悖论也自然消失，不成其为悖论，而被认为是由于自然语言对随机理解的歧义的原因造成了某种意义上互相矛盾的多个答案。

¹原回答的问题陈述中，此处用词是“随机浮动”，特修改为“浮动”，去掉了“随机”字眼。

2.4 公理化的概率模型及其性质

仅仅是古典概率模型和几何概率模型不足以实现对所有可能的“随机试验”进行数学建模，因而显然需要发展更宽泛的概率模型来完成这一任务。

另一方面，在几何概率模型内部发现了 Bertrand 悖论，这引发了 19 世纪末的学者们对概率理论基础的思考：解决这个悖论的一种思路是对概率这个概念进行公理化的处理，从而实现对更宽泛的概率模型的公理化定义。

2.4.1 概率的公理

20 世纪初 Hilbert 的公理化运动提出并在许多学科方向展开后，由于大部分数学分支在很早之前就已经完成了公理化，概率论的公理化就显得更为迫切。历史上，有多人参与了概率论的公理化进程（见第一章），最终由大数学家 Kolmogorov 集前人工作之大成，在 1933 年完成了概率论的公理化。他提出了总计 6 条公理，其中前三条本质上只是用来界定能谈论概率的事件之全体（即事件域或 σ -代数）。因此在现代概率论中关于概率的公理化一般会如下表述。

定义 2.4.1. 设 Ω 是一个非空集。 $\mathcal{F}$ 是 Ω 的一些子集形成的集族，它称为 Ω 上的事件域或 σ -代数，如果它满足：

(i) $\Omega \in \mathcal{F}$;

(ii) 补运算封闭：如果 $A \in \mathcal{F}$ ，则 $A^c \in \mathcal{F}$;

(iii) 可列并运算封闭：如果 $A_n \in \mathcal{F}, n \in \mathbb{N}$ ，则 $\bigcup_{n \in \mathbb{N}} A_n \in \mathcal{F}$ 。

上面的三条性质都有相应的概率解释： $\emptyset$ 代表不可能事件、 Ω 代表必然事件，因此都是可以谈论概率的（即 $\emptyset, \Omega \in \mathcal{F}$ ）；如果事件 A 可以谈论概率（即 $A \in \mathcal{F}$ ），那么它的对立事件 A^c 也应当可以谈论概率（即 $A^c \in \mathcal{F}$ ）；如果事件列 $\{A_n\}_1^\infty$ 都可以谈论概率（即 $A_n \in \mathcal{F}, \forall n \geq 1$ ），那么事件列 $\{A_n\}_1^\infty$ 中至少发生其中某一个的复合事件也应当可以谈论概率（即 $\bigcup_{n=1}^\infty A_n \in \mathcal{F}$ ）。

当 $\mathcal{F}$ 是 Ω 上的 σ -代数时，二元组 $(\Omega, \mathcal{F})$ 也被称为一个可测空间或可测结构；有时也把 σ -代数 $\mathcal{F}$ 称为 Ω 上的一个可测结构。

给定指标集 I ，如果对任意 $\alpha \in I$ ， $\mathcal{F}_\alpha$ 都是 Ω 上的 σ -代数，那么不难证明

$$\bigcap_{\alpha \in I} \mathcal{F}_\alpha := \{A : A \in \mathcal{F}_\alpha, \forall \alpha \in I\} \quad (2.9)$$

也是一个 σ -代数。因此, 任给 Ω 上的子集族 $\mathcal{E}$, 存在唯一的一个包含 $\mathcal{E}$ 的最小 σ -代数, 我们称这个包含 $\mathcal{E}$ 的最小 σ -代数为由 $\mathcal{E}$ 生成的 σ -代数, 记作 $\sigma(\mathcal{E})$ (为了强调生成 σ -代数时取的全空间为 Ω , 有时也记作 $\sigma_{\Omega}(\mathcal{E})$)。

概率的公理 设 Ω 是一个非空集, $\mathcal{F}$ 是其上的 σ -代数, $\mathbb{P}: \mathcal{F} \rightarrow \mathbb{R}$ 是一个函数, 我们称 Ω 为样本空间, 称 $\omega \in \Omega$ 为样本点, 称 $\mathcal{F}$ 为事件域, 称 $A \in \mathcal{F}$ 为事件, 称 $\mathbb{P}(A)$ 为事件 A 的概率, 相应地称 $\mathbb{P}$ 为概率测度, 称 $(\Omega, \mathcal{F}, \mathbb{P})$ 为概率空间 (有时也说它是一个概率结构), 如果三元组 $(\Omega, \mathcal{F}, \mathbb{P})$ 满足如下三条公理:

公理 1. (非负性) $\mathbb{P}(A) \geq 0, \forall A \in \mathcal{F}$;

公理 2. (归一性) $\mathbb{P}(\Omega) = 1$;

公理 3. (σ -可加性) 设 $\{A_n\}_{n=1}^{\infty} \subset \mathcal{F}$ 互斥, 则 $\mathbb{P}(\bigcup_{n=1}^{\infty} A_n) = \sum_{n=1}^{\infty} \mathbb{P}(A_n)$.

整个现代概率论的大厦就是在事件域的定义及其上述三条概率公理基础上通过逻辑演绎方式发展出来, 它是一套系统地用于理解和处理现实生活中各种随机试验和随机现象的数学建模理论与数据分析方法。

📌 笔记 2.4. 上述概率测度的公理中, 如果公理 2 去掉, 仅保留公理 1 (非负性) 和公理 3 (σ -可加性), 同时附加要求 $\emptyset$ 的测度值为 0, 对应的数学对象称为 (非负) 测度 (只不过一般容许全空间的测度值取无穷值); 此时的三元组 $(\Omega, \mathcal{F}, \mathbb{P})$ 称为测度空间 (有时也说它是一个测度结构), 详见第四章的定义 4.2.1. 另外, 在概率论及测度论中, 我们一般约定 $0 \cdot \infty := 0$, 这个约定通常仅限于测度及积分的计算中。

📌 笔记 2.5. 如前所述, *Bertrand* 悖论可以认为是导致概率先贤开启追寻概率公理化之旅的直接原因。但其实还有另一些原因。读者从一些文献中可以知道, 关于概率的定义或解释历史上有诸多争议¹。*Euclid* 几何学的成功发展经验是概率论的公理化选择的主要借鉴: 在 *Euclid* 几何学中, 点、线、面的定义固然来自于我们在现实生活所处的三维欧氏空间中形成的直觉, 但在经过公理化的抽象处理后, *Euclid* 几何学通过形式逻辑演绎把古代的几何学成就整理成一个宏伟壮观的理论体系, 由此发展成为现代数学的重要根基, 并获得许多重要的实际应用, 而在这些具体应用中如何解释点、线、面人们是有较大自由度的。现代概率论通过 *Kolmogorov* 公理化也做到了搭建统一的测度论的数学平台, 进而基于这个数学平台进行相关的形式逻辑演绎推理, 而把如何解释概率的问题留到具体应用场景中去解决²。这当然不代表有关概率解释的工作不重要——恰恰相反, 在应用场景中这部分工作是非常重要的, 就如同在经济学问题中有关经济学阐释是解决问题的重要环节一样; 只不过这部分工作及其评价没有非常客观且统一的标准。正因为通过公理化形成了统一且严谨的测度论的数学工作平台, 概率论在此后得到迅猛发展, 建立了强/弱大数定律、中心极限定理、重对数律、大偏差理论等一

¹但在古典概率模型场景下, 概率的直观定义基本可以认为是共识。

²在现实世界中基于公理化概率论来进行概率解释这方面的一般性原则, 读者可以参见本讲义 §3.4 中有关“小概率原理及现实世界与概率 (统计) 建模之间的接口”的论述。

系列经典理论与研究范式，开辟了众多新的理论研究领域与应用方向，并与其他学科交织形成大量交叉学科方向，在现代科学的发展中发挥着越来越显著的作用。

2.4.2 概率的基本性质

概率的公理告诉我们，概率测度 $\mathbb{P}$ 具有下面三条性质：

(P1) (非负性) $\mathbb{P}(A) \geq 0, \forall A \in \mathcal{F}$;

(P2) (归一性) $\mathbb{P}(\Omega) = 1$;

(P3) (σ -可加性) 设 $\{A_n\}_{n=1}^{\infty} \subset \mathcal{F}$ 互斥，则

$$\mathbb{P}\left(\biguplus_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mathbb{P}(A_n).$$

上述性质 (P3) 有时也称为可列可加性或可数可加性。在 (P3) 中，取 $A_n = \emptyset, n \geq 1$ ，由 $\mathbb{P}(\emptyset) \in \mathbb{R}$ 及 $\mathbb{P}(\emptyset) = \sum_{n=1}^{\infty} \mathbb{P}(\emptyset)$ ，易知

(P4) (平凡性) $\mathbb{P}(\emptyset) = 0$;

在 (P3) 中，取 $A_{n+k} = \emptyset, k \geq 1$ ，根据 (P4) 及 $\Omega = A \uplus A^c$ ，我们有

(P5) (有限可加性) 设 $n \in \mathbb{N}$ ，若 $\{A_k\}_{k=1}^n \subset \mathcal{F}$ 互斥，则

$$\mathbb{P}\left(\biguplus_{k=1}^n A_k\right) = \sum_{k=1}^n \mathbb{P}(A_k).$$

特别地， $\mathbb{P}(A^c) = 1 - \mathbb{P}(A), \forall A \in \mathcal{F}$;

在上面性质 (P5) 中，注意到 $A \subset B$ 时， $B = A \uplus (B \setminus A)$ ，我们有

(P6) (单调性) 若 $A, B \in \mathcal{F}$ 且 $A \subset B$ ，则 $\mathbb{P}(B \setminus A) = \mathbb{P}(B) - \mathbb{P}(A)$ 。特别地， $A, B \in \mathcal{F}$ 且 $A \subset B$ 蕴含了 $\mathbb{P}(A) \leq \mathbb{P}(B)$;

如果诸 $A_n \in \mathcal{F}$ ，取 $B_1 := A_1$ 及 $B_n := A_n \setminus \bigcup_{k=1}^{n-1} A_k \subset A_n$ ，则 $\{B_n\}_{n=1}^{\infty}$ 是

互斥事件列，且 $\bigcup_{n=1}^{\infty} A_n = \biguplus_{n=1}^{\infty} B_n$ 。利用 (P3)、(P6)，我们就得到下面的

(P7) (次可列可加性) 若诸 $A_n \in \mathcal{F}$ ，则

$$\mathbb{P}\left(\bigcup_{n=1}^{\infty} A_n\right) \leq \sum_{n=1}^{\infty} \mathbb{P}(A_n);$$

进一步, 如果诸 $A_n \in \mathcal{F}$ 且 $A_n \uparrow A$, 则 $A = \bigcup_{n=1}^{\infty} A_n \in \mathcal{F}$, 此时

$$\{B_n := A_n \setminus A_{n-1}\}_{n=1}^{\infty}$$

是互斥事件列 (约定 $A_0 := \emptyset$), 并且 $A_n = \biguplus_{k=1}^n B_k, A = \biguplus_{n=1}^{\infty} B_n$. 于是由 (P3)、(P5), 我们还有

(P8) (下连续性) 若诸 $A_n \in \mathcal{F}$ 且 $A_n \uparrow A$, 则 $A \in \mathcal{F}$, 并且

$$\mathbb{P}(A) = \mathbb{P}(\lim_{n \rightarrow \infty} A_n) = \lim_{n \rightarrow \infty} \mathbb{P}(A_n); \quad (2.10)$$

最后, 注意到 $(\lim_{n \rightarrow \infty} A_n)^c = \lim_{n \rightarrow \infty} A_n^c$, 利用 (P5)、(P8) 我们得到

(P9) (上连续性) 若诸 $A_n \in \mathcal{F}$ 且 $A_n \downarrow A$, 则 $A \in \mathcal{F}$, 并且

$$\mathbb{P}(A) = \mathbb{P}(\lim_{n \rightarrow \infty} A_n) = \lim_{n \rightarrow \infty} \mathbb{P}(A_n); \quad (2.11)$$

特别地, $\mathbb{P}$ 在 $\emptyset$ 处上连续: 若诸 $A_n \in \mathcal{F}$ 且 $A_n \downarrow \emptyset$, 则

$$\lim_{n \rightarrow \infty} \mathbb{P}(A_n) = 0.$$

以上这些概率的基本性质非常重要, 读者应当认真学习掌握, 并在之后的课程学习中通过例题、习题等方式锻炼自己, 努力达到熟练掌握、灵活应用的程度。

2.4.3 Jordan 公式

设 $A, B \in \mathcal{F}$. 利用上一节导出的概率的基本性质, 注意到

$$A = (A \cap B) \uplus (A \setminus B), B = (A \cap B) \uplus (B \setminus A)$$

以及 $A \cup B = (A \setminus B) \uplus (A \cap B) \uplus (B \setminus A)$, 我们得到

$$\begin{aligned} \mathbb{P}(A) &= \mathbb{P}(A \cap B) + \mathbb{P}(A \setminus B), \\ \mathbb{P}(B) &= \mathbb{P}(A \cap B) + \mathbb{P}(B \setminus A), \\ \mathbb{P}(A \cup B) &= \mathbb{P}(A \cap B) + \mathbb{P}(A \setminus B) + \mathbb{P}(B \setminus A). \end{aligned}$$

于是如下公式成立

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B). \quad (2.12)$$

一般地, 设 $\{A_k\}_{k=1}^n \subset \mathcal{F}$, 我们有下面的 Jordan 公式 (有些文献也称为 Poincaré 恒等式或容斥原理公式)

$$\mathbb{P}\left(\bigcup_{k=1}^n A_k\right) = \sum_{r=1}^n (-1)^{r-1} \sum_{1 \leq j_1 < \dots < j_r \leq n} \mathbb{P}\left(\bigcap_{p=1}^r A_{j_p}\right). \quad (2.13)$$

上述公式的证明可以借助数学归纳法给出, 此处从略。以下给出几个应用。

例 2.15. (Bernoulli-Euler 信封问题¹) 某人写了 n 封信与 n 个信封, 黑暗中信与信封曾散落在地后重新收起; 他在黑暗中完成了把信逐一装入信封的工作。请问: 这些信全部装错的概率有多大?

参考解答: 记 A_k 为第 k 封信装对了信封, 则关心的事件为 $B_n := \left(\bigcup_{k=1}^n A_k\right)^c$. 容易知道, 给定 $1 \leq r \leq n$ 及 $1 \leq j_1 < \dots < j_r \leq n$

$$\mathbb{P}\left(\bigcap_{p=1}^r A_{j_p}\right) = \frac{(n-r)!}{n!}.$$

于是根据 Jordan 公式

$$\begin{aligned} \mathbb{P}(B_n) &= 1 + \sum_{r=1}^n (-1)^r \sum_{1 \leq j_1 < \dots < j_r \leq n} \mathbb{P}\left(\bigcap_{p=1}^r A_{j_p}\right) \\ &= 1 + \sum_{r=1}^n (-1)^r \binom{n}{r} \cdot \frac{(n-r)!}{n!} = \sum_{r=0}^n \frac{(-1)^r}{r!}. \end{aligned}$$

上述计算给出了这些信全部装错的概率。

很显然, 当 $n \rightarrow \infty$ 时 $\mathbb{P}(B_n) \rightarrow \frac{1}{e} \approx 0.367879$, 即当信的数量充分多时, 信全部装错仍然有不小的概率。□

例 2.16. (投针问题续)² 在地面上有无数条等间隔的平行线 (设间隔为 L), 某人拿着一个材质均匀的半圆形塑料薄片 (其直径记作 ℓ) 随机地投向地面, 请问该塑料薄片与这组平行线相交的概率? (为方便, 此处假设 $0 < \ell < L$.)

参考解答: 设题中的半圆形塑料片为“甲片”, 设另有一完全相同的半圆形塑料片称为“乙片”, 它们拼装成一个完整的圆形塑料片。考虑投掷这个圆形塑料片。分别以 A 、 B 表示“甲片”、“乙片”与平行线相交的事件。于是 $A \cup B$ 就是圆形塑料片与平行线相交这一事件。而 $A \cap B$ 则是“甲片”、“乙片”都与平行线相交这一事件; 此时“甲片”、“乙片”的公共部分一直径与平行线相

¹ 此处的 Bernoulli 是 Nicolaus I Bernoulli.

² 本例的一个直接来源是文献.^[118]

交, 也就是说, $A \cap B$ 恰好是长为 ℓ 的“针”与平行线相交. 于是由例2.12我们知道 $\mathbb{P}(A \cap B) = \frac{2\ell}{\pi L}$.

以下计算 $\mathbb{P}(A \cup B)$. 以 d 表示圆心到最近的平行线的距离. 此时可取样本空间为 $\Omega = \{d : d \in [0, \frac{L}{2}]\}$. 在此建模下, $A \cup B = \{d : d \in [0, \frac{\ell}{2}]\}$. 因此 $\mathbb{P}(A \cup B) = \frac{\ell}{L}$. 显然 $\mathbb{P}(A) = \mathbb{P}(B)$. 于是

$$\mathbb{P}(A) = \frac{\mathbb{P}(A \cup B) + \mathbb{P}(A \cap B)}{2} = \frac{(\frac{\pi}{2} + 1)\ell}{\pi L}. \quad \square$$

注意, 上例所求概率的表达式中, 分子 $(\frac{\pi}{2} + 1)\ell$ 恰好是半圆形塑料片的周长; 原始 Buffon 投针问题中针与平行线相交的概率值 $\frac{2\ell}{\pi L}$ 的分子 2ℓ 则是“针”的周长; 圆形塑料薄片与平行线相交的概率值为 $\frac{\ell}{L} = \frac{\pi\ell}{\pi L}$, 后一分式中分子 $\pi\ell$ 也是圆形塑料薄片的周长. 把形体不太的凸图形的均匀塑料薄片当作投针投掷时, 它与平行线相交的概率是否也是“图形的周长: πL ”形式呢? 答案是肯定的. 对此我们就不展开详细讨论了, 读者可以通过考察三角形塑料薄板的投掷问题(见习题2.61)结合本题中的思想方法以及归纳法来完成有关计算与论证.

基于概率方法, 我们也可以对一些确定性的数学结果(某些现象)给出存在性的非构造性证明; 其核心思想如同例2.10的参考解答中所陈述, 如果某事件/现象 A 在某概率测度 $\mathbb{P}$ 下满足 $\mathbb{P}(A) > 0$, 则该现象就存在: $A \neq \emptyset$.

例 2.17. (握手问题) 某次大型会议, 其中参会者(超过 5 人)每人都至少与比例为 p 的人群握过手¹, 其中 $p > 2/3$. 求证: 其中一定能找到四个人, 他们互相都握过手.

参考解答: 把参会者编号为 $1, 2, \dots, n$, 其中 n 为全部参会者的总数, 考虑以 $\Omega := \{1, \dots, n\}$ 为样本空间的古典概率模型, 记 A_i 为与 i 号参会者握过手的参会者的编号集合, 于是 $\mathbb{P}(A_i) \geq p > 2/3, \forall i$.

注意到习题2.25的结论, 取 $a \in A_1$, 有 $\mathbb{P}(A_1 \cap A_a) \geq 2p - 1 > 0$, 从而存在 $b \in A_1 \cap A_a$. 进一步, $\mathbb{P}(A_1 \cap A_a \cap A_b) \geq 3p - 2 > 0$, 从而存在 $c \in A_1 \cap A_a \cap A_b$. 现在来看 $1, a, b, c$ 四个编号对应的参会者, 显然他们互相都握过手. $\square$

2.5 本章小结与学习建议

本讲义始终秉承“概率空间是对所关心的随机试验或随机现象的概率建模”这一理念来进行有关论述. 在编者的观念中, 古典概率模型和几何概率模型是初学者直观上容易理解的概率模型, 同时也是整个概率论理论大厦最

¹这里, 某参会者的握手比例是指与该参会者握手的参会人数(不含他自己)和参会总人数的比值.

为基础的砖石，是我们在学习概率论的过程中需要反复回顾审视的经典模型；Kolmogorov 公理化概率模型就是在这两个经典模型的基础上升华而来。因此本章是全书最基础的一个章节，编者在此处重点介绍了古典概率模型、几何概率模型以及 Kolmogorov 公理化概率模型。读者应当熟练掌握这三种模型的定义与基本性质，特别是 Kolmogorov 公理化概率模型中概率测度的性质 (P1) — (P9) 以及 Jordan 公式(2.13)，这样我们在后续章节中才能借助经典模型的直观来逐步引入各种概念与技术手段而构建公理化概率论的理论大厦，并以此为工具来解决各种现实问题。

特别需要指出的是，我们的“概率建模”本质上是基于集合论进行的，因此读者在学习全书的过程中应努力学习并熟练掌握“概率建模”中模糊的自然语言与严谨的集合论语言及概率语言的对应关系。在本章的学习过程中，适当学习掌握一些基本的计数技巧是有必要的，但不应过于沉迷一些复杂的计数问题；通过适当的练习建立正确的概率直观，并借助这些概率直观来帮助我们实现概率论入门，进而理解、应用、发展有关概率论理论，这才是我们学习本课程的目的。

习 题 2

习题 2.1. 设有 A_1, A_2, A_3 三个事件。请用集合表达下述复合事件：

- (i) 三个事件中，仅 A_1 发生；
- (ii) 三个事件中，仅 A_3 没有发生；
- (iii) 三个事件都发生；
- (iv) 三个事件中至少有一个发生；
- (v) 三个事件中至少有两个发生；
- (vi) 三个事件中仅有一个发生；
- (vii) 三个事件中仅有两个发生；
- (viii) 三个事件中不多于两个事件发生。

习题 2.2. 证明：当 $A_n \nearrow A$ (或 $A_n \searrow A$) 时， $\overline{\lim}_{n \rightarrow \infty} A_n = \lim_{n \rightarrow \infty} A_n = A$.

习题 2.3. 我们可以用函数极限的观点来看待集合的极限问题。求证：

$$(1) A_n \nearrow A \Leftrightarrow 1_{A_n} \nearrow 1_A, A_n \searrow A \Leftrightarrow 1_{A_n} \searrow 1_A;$$

$$(2) \overline{\lim}_{n \rightarrow \infty} 1_{A_n} = 1 \lim_{n \rightarrow \infty} A_n, \text{ 且 } \omega \in \overline{\lim}_{n \rightarrow \infty} A_n \Leftrightarrow \sum_{n=1}^{\infty} 1_{A_n}(\omega) = \infty;$$

$$(3) \underline{\lim}_{n \rightarrow \infty} 1_{A_n} = 1 \lim_{n \rightarrow \infty} A_n, \text{ 且 } \omega \in \underline{\lim}_{n \rightarrow \infty} A_n \Leftrightarrow \sum_{n=1}^{\infty} 1_{A_n^c}(\omega) < \infty;$$

$$(4) A_n \rightarrow A \Leftrightarrow 1_{A_n} \rightarrow 1_A;$$

$$(5) (\overline{\lim}_{n \rightarrow \infty} A_n) \setminus (\lim_{n \rightarrow \infty} A_n) = \overline{\lim}_{n \rightarrow \infty} (A_n \Delta A_{n+1});$$

$$(6) \overline{\lim}_{n \rightarrow \infty} \{f_n \geq C\} \subset \{\overline{\lim}_{n \rightarrow \infty} f_n \geq C\}, \quad \overline{\lim}_{n \rightarrow \infty} \{f_n \leq C\} \subset \{\underline{\lim}_{n \rightarrow \infty} f_n \leq C\},$$

$$\underline{\lim}_{n \rightarrow \infty} \{f_n \geq C\} \subset \{\underline{\lim}_{n \rightarrow \infty} f_n \geq C\}, \quad \underline{\lim}_{n \rightarrow \infty} \{f_n \leq C\} \subset \{\overline{\lim}_{n \rightarrow \infty} f_n \leq C\}.$$

习题 2.4. 设 T_n 是集合 $\Sigma_n := \{1, 2, \dots, n\}$ 的不同划分 (或分割; *Partition*) 的数目 (本质上它是 Σ_n 上所有不同的 σ -代数的数目, 因为对于离散的样本空间, 一个分割对应生成一个 σ -代数; 反之亦然).

(1) 易知 $T_1 = 1, T_2 = 2$. 记 $T_0 := 1$, 证明: T_n 满足递推公式:

$$T_{n+1} = \sum_{k=0}^n \binom{n}{k} \cdot T_k;$$

(2) 定义以美国数学家 *A. G. Bell* (贝尔) 姓氏命名的 *Bell* 数 (列) 如下: $B_0 := 1$,

$$B_n := e^{-1} \sum_{k=1}^{\infty} \frac{k^n}{k!}, \forall n \geq 1.$$

上述方程被称为 *Dobinski* 公式. 请证明: $T_n = B_n, \forall n \geq 0$, 并且 B_n 具有 “指数母函数” $B(x) := \sum_{n=0}^{\infty} \frac{B_n}{n!} \cdot x^n = e^{e^x - 1}$.

习题 2.5. 令 $\Sigma := \{0, 1\}$, $A := \{x = (x_1, \dots, x_n) \in \Sigma^n : \sum_{i=1}^n x_i \geq k\}$, 其中 $1 \leq k \leq n$. 计算 A 中元素个数 $|A|$.

习题 2.6. 现有 $r \geq 2$ 种颜色的球共有 $n := n_1 + \dots + n_r$ 个, 其中第 i 色球有 $n_i \geq 1$ 个, $i = 1, \dots, r$; 这些同色球都是不可区分的. 请问:

(1) 这些球排成一行, 理论上有多少种互不相同的行?

(2) 这些球排成一圈, 理论上有多少种互不相同的圈?

习题 2.7. 考虑 n^2 个人分成不带编号的 n 组, 每组 n 人, 借此证明: $(n^2)!$ 能被 $(n!)^{n+1}$ 整除.

习题 2.8. 证明: 一个只有有限个元素的 σ -代数一定恰有 2^n 个元素, 其中 n 为某非负整数。此时该 σ -代数中可以找到一个全空间的分割, 它恰有 n 个元素, 并且这个分割生成这个 σ -代数。

习题 2.9. 若 Ω 为无穷集, 则 $\mathcal{E} := \{A \subset \Omega : A \text{ 可数或 } A^c \text{ 可数}\}$ 是 σ -代数。

习题 2.10. 设 Ω 为非空集合。令 $\mathcal{E} := \{\{\omega\} : \omega \in \Omega\}$. 证明: 由 $\mathcal{E}$ 生成的 σ -代数为 $\mathcal{F} := \{A \subset \Omega : A \text{ 或 } A^c \text{ 为可数集}\}$.

习题 2.11. 当 Ω 是不可数集时, 证明上一习题中的 σ -代数 $\mathcal{F}$ 不是可数生成的, 即不存在可数个集合 $A_n \in \mathcal{F}, n \geq 1$, 使得 $\mathcal{F} = \sigma(\{A_n : n \geq 1\})$.

习题 2.12. 设 $\mathcal{B}_1, \mathcal{B}_2$ 是空间 Ω 上的两个 σ -代数, 问以下两个集系

$$\mathcal{B}_1 \cap \mathcal{B}_2 := \{A : A \in \mathcal{B}_1 \text{ 且 } A \in \mathcal{B}_2\}, \quad \mathcal{B}_1 \cup \mathcal{B}_2 := \{A : A \in \mathcal{B}_1 \text{ 或 } A \in \mathcal{B}_2\}$$

是否是 σ -代数?

习题 2.13. 设 I 是一个非空指标集, 对任意 $\alpha \in I, \mathcal{F}_\alpha$ 都是 Ω 上的 σ -代数, 请证明方程(2.9)定义了一个 σ -代数。

习题 2.14. 设 $\mathcal{B}_1, \mathcal{B}_2$ 分别是空间 Ω_1, Ω_2 上的 σ -代数(假定其中 $\mathcal{B}_1, \mathcal{B}_2$ 都有超过 2 个元素, 即不是平凡的 σ -代数), 问集系 $\mathcal{B}_1 \times \mathcal{B}_2 := \{A_1 \times A_2 : A_1 \in \mathcal{B}_1, A_2 \in \mathcal{B}_2\}$ 是否是 σ -代数?

习题 2.15. 称集合 $A \subset \mathbb{N}$ 具有渐近密度 d , 如果 $\lim_{n \rightarrow \infty} \frac{|A \cap (0, n]|}{n} = d$. $\mathbb{N}$ 中具有渐近密度的集合全体记作 $\mathcal{E}$. 它是 σ -代数吗?

习题 2.16. 设 $\{A_1, A_2, \dots, A_n\}$ 为 Ω 的一个覆盖, $\mathcal{F}$ 是这个覆盖生成的 σ -代数, 试证明: $|\mathcal{F}| \leq 2^{2^n - 1}$.

习题 2.17. 给定 $\mathcal{E}$ 为 Ω 上集族及一个非空集 $\Omega_0 \subset \Omega$. 记 $\Omega_0 \cap \mathcal{E} := \{\Omega_0 \cap A : A \in \mathcal{E}\}$. 它是 Ω_0 上的集族, 它在 Ω_0 上生成的 σ -代数记作 $\sigma_{\Omega_0}(\Omega_0 \cap \mathcal{E})$. 那么 $\sigma_{\Omega_0}(\Omega_0 \cap \mathcal{E}) = \Omega_0 \cap \sigma_\Omega(\mathcal{E})$. 请证明此结论。

习题 2.18. 设 $\mathcal{E}$ 为 $\Omega_0 \subset \Omega$ 上的代数。你能给出 $\sigma_\Omega(\mathcal{E})$ 与 $\sigma_{\Omega_0}(\mathcal{E})$ 的联系吗?

习题 2.19. 在概率空间中证明概率测度的次可加性、下连续性与上连续性, 即本讲义中的性质 (P7)、(P8)、(P9)。

习题 2.20. 在概率空间中证明:

$$\mathbb{P}(\lim_{n \rightarrow \infty} A_n) \leq \lim_{n \rightarrow \infty} \mathbb{P}(A_n) \leq \overline{\lim}_{n \rightarrow \infty} \mathbb{P}(A_n) \leq \mathbb{P}(\overline{\lim}_{n \rightarrow \infty} A_n).$$

习题 2.21. 设 A, B 为概率空间中的两个事件, 试证明:

$$|\mathbb{P}(A \cap B) - \mathbb{P}(A)\mathbb{P}(B)| \leq \frac{1}{4}.$$

习题 2.22. 设 A, B 为两事件, “对称差” $A \Delta B := (A \setminus B) \cup (B \setminus A)$ 表示了事件 “ A, B 中有且仅有其中一者发生”。证明 “对称差” 运算满足交换律、结合律及与 “交运算” 结合的分配律: $A \Delta B = B \Delta A$, $(A \Delta B) \Delta C = A \Delta (B \Delta C)$, $(A \Delta B) \cap C = (A \cap C) \Delta (B \cap C)$, 并且

$$\mathbb{P}(A \Delta B) = \mathbb{P}(A) + \mathbb{P}(B) - 2\mathbb{P}(A \cap B).$$

习题 2.23. 设 A, B, C 为概率空间中的事件, 试证明如下 “三角不等式”:

$$\mathbb{P}(A \Delta B) \leq \mathbb{P}(A \Delta C) + \mathbb{P}(C \Delta B).$$

习题 2.24. 在概率空间的事件域中定义 $d(A, B) := \frac{\mathbb{P}(A \Delta B)}{\mathbb{P}(A \cup B)} \cdot 1_{\{\mathbb{P}(A \cup B) > 0\}}$. 求证: $d(A, B) \leq d(A, C) + d(C, B)$.

习题 2.25. 证明: $\mathbb{P}(A \cap B \cap C) \geq \mathbb{P}(A) + \mathbb{P}(B) + \mathbb{P}(C) - 2$, 并用归纳法证明:

$$\mathbb{P}\left(\bigcap_{i=1}^n A_i\right) \geq \sum_{i=1}^n \mathbb{P}(A_i) - (n-1).$$

习题 2.26. 给定事件 $A_1, \dots, A_n$, 记 $N_A := \sum_{k=1}^n 1_{A_k}$. 令 $S_0 := 1$,

$$S_r := \sum_{1 \leq k_1 < k_2 < \dots < k_r \leq n} \mathbb{P}(A_{k_1} \cap \dots \cap A_{k_r}), \quad 1 \leq r \leq n.$$

(1) $\{N_A = m\}$ 为事件 “ $A_1, \dots, A_n$ 中有且仅有其中 m 件发生”。于是

$$\mathbb{P}(N_A = m) = \sum_{r=m}^n (-1)^{r-m} \binom{r}{m} \cdot S_r.$$

上式在文献^[48]中被称为 *Waring's theorem*, 亦即 *Waring* (华林) 定理。特别地, $\{N_A = 0\} = (A_1 \cup \dots \cup A_n)^c$ 的概率为

$$\mathbb{P}(N_A = 0) = \sum_{r=0}^n (-1)^r S_r;$$

(2) $\{N_A \geq m\}$ 为事件 “ $A_1, \dots, A_n$ 中至少有其中 m 件发生”, 其概率为

$$\mathbb{P}(N_A \geq m) = \sum_{r=m}^n (-1)^{r-m} \cdot \binom{r-1}{m-1} \cdot S_r.$$

特别地, $\{N_A \geq 1\} = A_1 \cup \cdots \cup A_n$ 为事件 “ $A_1, \cdots, A_n$ 中至少有其中一件发生”, 其概率为

$$\mathbb{P}(A_1 \cup \cdots \cup A_n) = \sum_{r=1}^n (-1)^{r-1} S_r.$$

上式被称为 *Poincaré* 恒等式或 *Jordan* 恒等式, 而下面三个不等式

$$\mathbb{P}(A_1 \cup \cdots \cup A_n) \leq \sum_{i=1}^n \mathbb{P}(A_i),$$

$$\mathbb{P}(A_1 \cup \cdots \cup A_n) \geq \sum_{i=1}^n \mathbb{P}(A_i) - \sum_{1 \leq i < j \leq n} \mathbb{P}(A_i \cap A_j),$$

$$\mathbb{P}(A_1 \cup \cdots \cup A_n) \leq \min_{1 \leq j \leq n} \left\{ \sum_{i=1}^n \mathbb{P}(A_i) - \sum_{1 \leq i \leq n, i \neq j} \mathbb{P}(A_i \cap A_j) \right\},$$

分别称为 *Boole* 不等式、*Bonferroni* 不等式和 *Kounias* 不等式;

$$(3) \text{ Fréchet 不等式: } \frac{S_{r+1}}{\binom{n}{r+1}} \leq \frac{S_r}{\binom{n}{r}}, \quad r = 0, 1, \cdots, n-1;$$

$$(4) \text{ Gumbel 不等式: } \frac{\binom{n}{r+1} - S_{r+1}}{\binom{n-1}{r}} \leq \frac{\binom{n}{r} - S_r}{\binom{n-1}{r-1}}, \quad r = 1, \cdots, n-1;$$

$$(5) \Delta_{i=1}^n A_i = \{N_A \equiv 1 \pmod{2}\}, \text{ 且 } \mathbb{P}(\Delta_{i=1}^n A_i) = \sum_{r=1}^n (-2)^{r-1} S_r.$$

习题 2.27. 设 A, B 为概率空间中的事件, 如果 $\mathbb{P}(A \cap B) = 0$ 则称 A, B 几乎互不相交/几乎互斥; 称事件列 $\{A_n\}_{n=1}^\infty$ 几乎互不相交/几乎互斥, 如果存在事件 Γ 使得 $\mathbb{P}(\Gamma) = 0$ 且事件列 $\{A_n \setminus \Gamma\}_{n=1}^\infty$ 互不相交. 试证明: 如果事件列 $\{A_n\}_{n=1}^\infty$ 两两几乎互不相交, 那么它们几乎互不相交, 并且这也是

$$\mathbb{P}\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mathbb{P}(A_n)$$

成立的充分必要条件。

习题 2.28. 设 $\{A_k\}_{k=1}^n$ 为 $n \geq 3$ 个事件, 具有如下性质: (1) 三个及以上事件不可能同时发生; (2) 单个事件不可能单独发生. 试证明:

$$\mathbb{P}(A_1 \cup \cdots \cup A_n) = \frac{1}{2} \cdot [\mathbb{P}(A_1) + \cdots + \mathbb{P}(A_n)].$$

习题 2.29. 设 $\{A_k\}_{k=1}^n$ 为 $n \geq 3$ 个事件, 具有如下性质: (1) 至少有一个事件发生; (2) 三个及以上事件不可能同时发生; (3) $\mathbb{P}(A_i) = p, \mathbb{P}(A_i \cap A_j) = q, i \neq j$. 试证明: $p \geq \frac{1}{n}, q \leq \frac{2}{n(n-1)}$.

习题 2.30. 给定 $n \geq 3$ 及事件列 $\{A_k\}_{k=1}^n$, 记

$$V_k := \bigcup_{\substack{j \neq k \\ 1 \leq j \leq n}} A_j, \quad \Omega_n := \bigcup_{j=1}^n A_j.$$

证明:

$$\mathbb{P}(A_n \cap V_n) \leq \sum_{k=1}^{n-1} \mathbb{P}(A_k \cap V_k).$$

上面不等式的等号成立当且仅当 $\{A_k\}_{k=1}^{n-1}$ 是几乎互斥事件列。在上述取等条件下, 我们有 $\mathbb{P}(\Omega_n) = \mathbb{P}(A_n) + \sum_{k=1}^{n-1} \mathbb{P}(A_k \setminus V_k)$.

习题 2.31.¹ 水平桌面上放有四张边长分别为 2、3、4、5 (单位: 厘米) 的正方形纸片 $A_1, \dots, A_4$ (它们互相间可能有重叠), 它们覆盖了一定的面积。若分别取走 A_1, A_2, A_3, A_4 中的一张, 则剩下的三张纸片覆盖的面积相比原来四张纸片分别减少了 2、3、4、5 (单位: 平方厘米)。那么原来四张纸片覆盖的面积是多少平方厘米?

习题 2.32. 从 $0, 1, \dots, 9$ 这 10 个数字中不重复地取 4 个数字, 组成一个四位数。请问这个四位数是偶数的概率有多大?

习题 2.33. 随机选取一个四位数。请问这个四位数是偶数的概率有多大?

习题 2.34. 试确定一个数 $1 \leq n \leq 100$, 使得: 当随机从 $1, \dots, 100$ 中选取一个数 d 时, d 有最大的概率是 n 的约数。

习题 2.35. 某人随身带了 6 把钥匙, 其中 2 把是大门钥匙; 但他忘记了哪 2 把才是大门钥匙, 只好采用不放回的方式随机试开。请问能 3 次内打开大门的概率有多大?

习题 2.36. 国内住校的大学生通常是 4 人共用一个宿舍。请计算一年中某宿舍 4 位同学中至少有一对同学在同一个月份过生日的概率。

习题 2.37. 本题讨论一副扑克牌的五张牌组合出现的概率问题; 此处容许 *Ace* 当作一点。所有五张牌的组合, 由大至小排序为如下不同牌型²:

(i) 大同花顺 (*Royal Flush*): 最高为 *Ace* 的同花顺, 如 $A\spadesuit K\spadesuit Q\spadesuit J\spadesuit 10\spadesuit$;

¹ 本题来源于学而思培优教研中心编著的《数学思维训练汇编》(小学奥数四年级; ISBN978-7-121-17637-1) 第 16 讲的第 19 题。上一习题本质上也是编者基于本题的解答改编而成。

² 现实生活中五张牌比较大小时, 除了牌型确定的序, 还会叠加花色的序: 首先牌型的序优先, 数字 (字典) 序其后 (同牌型中数字大的五张牌更大), 最后是花色序 (同牌型、同数字的五张牌, $\spadesuit > \heartsuit > \clubsuit > \diamond$)。

- (ii) 同花顺 (StraightFlush) : 同一花色、顺序的牌, 如 $Q\heartsuit J\heartsuit 10\heartsuit 9\heartsuit 8\heartsuit$;
- (iii) 四条 (Four of a Kind) : 有四张同一点数的牌, 如 $4\clubsuit 4\diamondsuit 4\heartsuit 4\spadesuit 9\heartsuit$;
- (iv) 满堂红 (Fullhouse) : 三张同一点数的、加一对其他点数的牌, 如 $8\clubsuit 8\diamondsuit 8\heartsuit K\heartsuit K\spadesuit$;
- (v) 同花 (Flush) : 五张同一花色的牌, 如 $K\heartsuit J\heartsuit 8\heartsuit 4\heartsuit 3\heartsuit$;
- (vi) 顺子 (Straight) : 五张顺连的牌, 如 $5\diamondsuit 4\heartsuit 3\clubsuit 2\diamondsuit A\heartsuit$;
- (vii) 三条 (Three of a kind) : 仅有三张同一点数的牌, 如 $7\clubsuit 7\heartsuit 7\spadesuit K\diamondsuit 2\heartsuit$;
- (viii) 两对 (Two Pairs) : 两个不同点数恰好出现该点数的两张牌, 如 $A\clubsuit A\diamondsuit 8\heartsuit 8\spadesuit Q\heartsuit$;
- (ix) 一对 (One Pair) : 两张相同点数的牌, 如 $9\heartsuit 9\spadesuit A\clubsuit J\heartsuit 4\heartsuit$;
- (x) 无对 (No Pair) : 非以上组合的牌, 以点数决定大小, 如 $A\diamondsuit 10\diamondsuit 9\heartsuit 5\clubsuit 4\clubsuit$.

请在不使用百搭牌的情况下, 计算以上牌型组合 (i) — (x) 各自出现的概率。

习题 2.38. 目前我国的福利彩票游戏“双色球”由中福彩中心发行和组织销售, 由各省福彩机构在所辖区域内销售。采用计算机网络系统发行, 在各省福彩机构设置的销售网点销售, 每周二、周四、周日开奖。双色球投注区分为红色球

奖等	奖金	中奖条件
一等奖	浮动	●●●●●●●●
二等奖	浮动	●●●●●●●●
三等奖	3,000元	●●●●●●●●
四等奖	200元	●●●●●●●●
五等奖	10元	●●●●●●●●
六等奖	5元	●●●●●●●●

图 2.6: 双色球中奖条件与奖金对应表

号码区和蓝色球号码区, 红色球号码区由 1-33 共三十三个号码组成, 蓝色球号码区由 1-16 共十六个号码组成。投注时选择 6 个红色球号码和 1 个蓝色球号码组成一注进行单式投注, 每注金额人民币 2 元。中奖条件如下: (i) 一等奖: 投注号码与当期开奖号码全部相同 (顺序不限, 下同), 即中奖; (ii) 二等奖: 投注号码与当期开奖号码中的 6 个红色球号码相同, 即中奖; (iii) 三等奖: 投注号码与当期开奖号码中的任意 5 个红色球号码和 1 个蓝色球号码相同, 即中奖; (iv) 四等奖: 投注号码与当期开奖号码中的任意 5 个红色球号码相同, 或与任意 4 个红色球号码和 1 个蓝色球号码相同, 即中奖; (v) 五等奖: 投注号码与当期开奖号码中的任意 4 个红色球号码相同, 或与任意 3 个红

色球号码和 1 个蓝色球号码相同, 即中奖; (vi) 六等奖: 投注号码与当期开奖号码中的 1 个蓝色球号码相同, 即中奖。图 2.6 给出了“双色球”的中奖条件与奖金的对应简表。某人随机生成了该“双色球”游戏的一组号码并投了一注该号码, 求他获得“双色球”的各等级奖项的概率。

习题 2.39. 从 n 双不同的鞋中随机选取 $2r$ 只。请问:

- (1) 不能配成 1 双鞋的概率;
- (2) 恰好配成一双的概率;
- (3) 恰好配成 r 双的概率。

习题 2.40. 从 n 双相同款式与尺寸的鞋中随机选取 $2r$ 只。请问:

- (1) 不能配成 1 双鞋的概率;
- (2) 恰好配成一双鞋的概率;
- (3) 恰好配成 r 双鞋的概率。

习题 2.41. 从 n 双不同的袜子 (不区分左右脚) 中随机选取 $2r$ 只。请问:

- (1) 不能配成 1 双袜子的概率;
- (2) 恰好配成一双袜子的概率;
- (3) 恰好配成 r 双袜子的概率。

习题 2.42. n 个不同编号的球随机地放入 m 个不同编号的盒子中 ($2 \leq m \leq n$), 每个盒子的容量不限。求:

- (1) 恰有一个空盒的概率;
- (2) 没有空盒的概率。

习题 2.43. 赌徒还曾向 *Pascal* 提出以下概率大小的比较问题, 请你思考:

- (1) 投掷 4 次骰子至少得到一个 6 的概率, 与投掷两个骰子 24 次至少得到一次一双 6 的概率, 哪个大?
- (2) 投掷 $6n$ 个骰子得到至少 n 个 6 的概率, 与投掷 $6(n+1)$ 个骰子得到至少 $n+1$ 个 6 的概率, 哪个大?

习题 2.44. 10 男 5 女随机站一排, 求女士们互相都不相邻的概率。

习题 2.45. 10 男 5 女随机站一圈, 求女士们互相都不相邻的概率。

习题 2.46. 有 n 对夫妇列席参加一个会议, 求下列两种不同情况下恰有 k 对夫妇的夫妻座位相邻的概率、至少有 k 对夫妇的夫妻座位相邻的概率:

- (1) 所有 $2n$ 个座位排成一排;
- (2) 所有 $2n$ 个座位排成一圈, 形成圆桌会议。

习题 2.47. 全班有 40 人。其中有 26 人喜欢打网球; 28 人喜欢打羽毛球; 有 20 人同时喜欢打网球、羽毛球。随机选班里一位同学, 他/她喜欢打网球或羽毛球的概率是多少?

习题 2.48. 已知 100 件产品中有 3 件次品。

- (1) 从中随机取两件, 求其中有次品的概率;
- (2) 先从中随机取 10 件, 之后再从中随机取两件, 分别求其中 (10 件中及两件中) 有次品的概率。

习题 2.49. 有穿过长管道的六根长绳, 绳子的头尾分别露在管道的两端。小明抓住它们的头, 两两配对共打 3 个死结; 小军抓住它们的尾, 也两两配对打 3 个死结。请问, 最终六根长绳形成一个环的概率?

习题 2.50. 运用例 2.10 中方法, 证明: 当 $\binom{n}{p} < 3\binom{p}{2}^{-1}$ 时, 存在对完全图 K_n 的一种边三染色方案, 使得染色后其中找不到单色子图 K_p 。

习题 2.51. 以下考虑对完全图进行随机染色, 计算相关事件的概率。

- (1) 对完全图 K_4 的边进行随机二染色, 求其中能找到单色子图 K_3 的概率;
- (2) 对完全图 K_5 的边进行随机二染色, 求其中能找到单色子图 K_3 的概率。

习题 2.52. 从正方体的 8 个顶点中随机选 3 个顶点组成一个三角形。

- (1) 求组成直角三角形的概率;
- (2) 求组成等腰直角三角形的概率;
- (3) 求组成等边三角形的概率。

习题 2.53. 从正方体的 6 个面的中心点中随机选 3 个顶点组成一个三角形。

- (1) 求组成直角三角形的概率;

(2) 求组成等腰直角三角形的概率;

(3) 求组成等边三角形的概率。

习题 2.54. (Banach 火柴问题) 某烟民身上起初有两盒火柴, 每盒都是 n 根。他每次使用时都是从此两盒中随机抓一盒, 从中取一根。问: 在使用过程中, 发生摸到一个空火柴盒而此时另一盒剩 r 根的现象的概率?

习题 2.55. (本题来源于文献^[118]) 在唱票问题中 (见例2.9), 试讨论唱票过程中甲乙二人曾经打成过平手的概率。

习题 2.56. 假定动物园门票是 50 元/人, 有 $m+n$ 人排队买票, 其中 $m \geq n$. 我们只知道排队买票的人中有 m 人只持有单张 50 元的纸币, 另 n 人只持有单张 100 元的纸币, 没有其他支付手段, 且动物园售票处在开始售票时也并没有零钱。试求这 $m+n$ 人依次只为自己买 1 张票, 最后所有人购票成功、都没有发生找零困难的概率。

习题 2.57. 在一条线段上随机地取两点, 把该线段分成了三段。求这三段子线段能组成三角形的概率。

习题 2.58. 在正方形的四条边上随机选三个点。求它们能组成三角形的概率。

习题 2.59. 两人相约在 11:00—12:00 之间会面。如果两人在期间是等可能性到达约定地点。求其中一人至少要等另一人半小时的概率。

习题 2.60. 设地面有无穷多等间距的水平方向平行线和竖直方向平行线, 它们形成正方形网格, 假定这些正方形网格的边长都是 L . 向这样的地面投掷一枚直径为 ℓ 的均匀硬币 (其中 $0 < \ell < L$), 问硬币与网格相交的概率?

习题 2.61. 设地面有无穷多等间距的水平方向平行线, 假定间距都是 L . 现在有一块三角形塑料薄板, 它的三边长分别是 ℓ_1, ℓ_2, ℓ_3 (其中 $0 < \ell_1 \leq \ell_2 \leq \ell_3 < L$) . 向地面投掷这一块三角板, 问三角板与平行线相交的概率? 基于此进一步去论证例2.16的参考解答中提出的投掷凸边形塑料薄片而得到的与平行线相交的概率计算公式。

习题 2.62. 设地面有无穷多等间距的水平方向平行线, 假定间距都是 L . 向这样的地面投掷一枚长为 ℓ 的均匀细长针 (其中 $\ell > L$, 针的直径忽略不计), 问细长针与平行线相交的概率?

习题 2.63. 本题来源于文献 [120, pp. 375]. 证明: 在自然数集 $\mathbb{N} := \{n \in \mathbb{Z} : n \geq 1\}$ 上不存在概率测度 $\mathbb{P}$, 使得 $\mathbb{P}(a\mathbb{N}) = \frac{1}{a}, \forall a \in \mathbb{N}$, 此处 $a\mathbb{N}$ 表示自然数中是 a 的倍数的元素全体。

习题 2.64. 把单位圆周染成红白二色，其中白色比重为 q . 试证明：如果 $q < \frac{1}{4}$ ，那么不论如何染色，总能在染色后的圆周上找到均为红色的四点，它们构成单位圆的内接正方形。

第三章 经典条件概率与事件独立性

自本章开始，我们总假设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是一个足够丰富、能够容纳所讨论的随机现象的概率空间（未必是古典概率模型或几何概率模型），并且在无特殊必要的场合将不再申明这一点；至于为何我们可以在概率建模时作此假设，请参见本章注记3.1. 我们将通过逻辑演绎与类比，引入一些新的概念，逐步展开介绍概率的有关理论。

我们在日常生活中经常会遇到涉及条件概率或事件独立性的场景，相信大多数人对此已形成一定的直观经验。在本章，我们将借助生活中形成的朴素直观，基于容易理解的古典概率模型和几何概率模型来探讨如何在数学上严谨地定义所谓的经典条件概率与事件独立性。实际上这两个重要概念在概率论的公理化完成之前早已在前人文献中给出过定义；本章的有关论述只是前人的工作在公理化概率论框架下的重新梳理，其目的是确保定义的严谨性与整体论述的逻辑自洽性。

3.1 条件概率空间与经典条件概率的定义

在现实生活中，一件事情发生后，总是或多或少能提供给我们一些信息，这些信息会导致我们对其他事件发生的可能性大小的判断发生变化：空中飘来乌云（积雨云）后我们通常会认为天将下雨的可能性高于原来晴空万里、乌云未至的情况下预判的天将下雨的可能性；原来装有 2 个黑球、2 个白球的袋子中，摸走一个黑球后，接下来再次摸球，则摸中黑球的概率就相比最初的时候降低了。这些都是我们生活中的经验和朴素直观就能感知的结论。事件 A 发生的条件下，另一事件 B 发生的概率，我们称为**条件概率**，符号上记作 $\mathbb{P}(B|A)$ ¹，它的取值通常应该与不知道 A 是否发生的时候给出的无条件概

¹记号 $\mathbb{P}(B|A)$ 据说是 Harold Jeffreys 在著作《Scientific Inference》(1931) 中引进的；之前，Felix Hausdorff 在 1901 年把条件概率记作 $\mathbb{P}_A(B)$ ，并称之为“给定 A 后 B 的相对概率” (relative probability of B given A)；更早期则直接称此为“若 A 发生， B 的概率” (probability of B if A happens). 参见文献^[90]中论述。

率 $\mathbb{P}(B)$ 有所区别。问题是，我们该如何合理地在数学上精确定义“条件概率”这一自然语言中的模糊概念而使之成为数学上的精确概念并确保它符合我们的朴素直观呢？

为了借助直观来理解上面提出的问题，我们有必要来看看最简单的古典概率模型 $(\Omega, \mathcal{F}, \mathbb{P})$. 此时 Ω 是一个具有有限个样本点的样本空间，其中诸样本点具有等可能性作为一个基本结果出现，能谈论概率的事件全体为事件域 $\mathcal{F} = 2^\Omega$ ，等可能性假设意味着 $\mathbb{P}(\{\omega\}) = \frac{1}{|\Omega|}, \forall \omega \in \Omega$. 当事件 $A \subset \Omega$ 发生时，我们拟推断另一事件 $B \subset \Omega$ 发生的条件概率：显然，当我们谈论事件 $A \subset \Omega$ 发生时，一个（一般情况下未知的）“基本结果” $\omega \in A$ 已经出现，如果我们还要求事件 $B \subset \Omega$ 发生（此时 $\omega \in B$ ），则本质上我们要求 $\omega \in A \cap B$ ，即事件 $A \cap B$ 发生，它是 A 事件的子事件；很明显，我们应该考虑以 A 作为样本空间的一个新的概率空间（此处假定 $\mathbb{P}(A) > 0$ ），某个非常自然的“子概率空间” $(\Omega_A, \mathcal{F}_A, \mathbb{P}_A)$ ，其中应有

$$\Omega_A := A, \quad \mathcal{F}_A = A \cap \mathcal{F} := \{A \cap B : B \in \mathcal{F}\}. \quad (3.1)$$

问题：我们该如何定义 $\mathbb{P}_A$ 使得 $\mathbb{P}_A(A \cap B)$ 可认同为条件概率 $\mathbb{P}(B|A)$ ？




图 3.1: 概率空间与条件概率空间

由于我们认为概率空间 $(\Omega_A, \mathcal{F}_A, \mathbb{P}_A)$ 是大的概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 的非常自然的子空间，大空间满足等可能性假设，理所当然地我们认为小的“子概率空间” $(\Omega_A, \mathcal{F}_A, \mathbb{P}_A)$ 也满足等可能性假设，这是一种非常合理的遗传性或继承性；于是 $(\Omega_A, \mathcal{F}_A, \mathbb{P}_A)$ 也是古典概率模型，

$$\mathbb{P}(B|A) := \mathbb{P}_A(A \cap B) = \frac{|A \cap B|}{|A|} = \frac{|A \cap B|/|\Omega|}{|A|/|\Omega|} = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)}.$$

上述简单易理解情形的讨论立即诱使我们给出一般的概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 中条件概率的定义：当 $A, B \in \mathcal{F}$ 满足 $\mathbb{P}(A) > 0$ 时，我们以 $\mathbb{P}(B|A)$ 表示事件 A 发

生的条件下事件 B 发生的**条件概率**，它定义为如下数值

$$\mathbb{P}(B|A) := \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)}. \quad (3.2)$$

上述讨论的方式、方法是人们在自然科学（特别是物理学）的研究中借助容易理解的特例中的已知概念、具体性质而引入更一般的抽象概念的常见套路，读者应自行多多体悟。这里我们指出：在古典概率模型情形条件概率定义为 $\mathbb{P}(B|A) := \frac{|A \cap B|}{|A|}$ ，这是 Bernoulli 的贡献，见文献^[27]第 11 页中评论。

以上讨论也给出了一般的概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 的**子概率空间** $(\Omega_A, \mathcal{F}_A, \mathbb{P}_A)$ 的合理定义（其中 $A \in \mathcal{F}$ 满足 $\mathbb{P}(A) > 0$ ），即此时可测结构 $(\Omega_A, \mathcal{F}_A)$ 按照(3.1)定义，且 $\mathbb{P}_A(\cdot) := \mathbb{P}(\cdot|A)$ 由(3.2)给出。请读者验证如上定义的 $(\Omega_A, \mathcal{F}_A, \mathbb{P}_A)$ 确实是一个概率空间。由此， $(\Omega_A, \mathcal{F}_A, \mathbb{P}_A)$ 也可称为**条件概率空间**。在第七章探讨条件数学期望、条件概率时，我们将会再次涉及此处的这个条件概率空间。

下面我们结合几个具体例子来理解条件概率这一概念。

例 3.1. 原来装有 2 个黑球、2 个白球的袋子中，第一次摸走一个黑球后，再次摸一个球，请问第二次能摸中黑球的概率是多少？

参考解答： 在原来装有 2 个黑球、2 个白球的袋子中，第一次摸走一个黑球后，袋子中剩下 1 个黑球、2 个白球，从而第二次摸一个球，能摸中黑球的概率很自然是 $\frac{1}{3}$ ；这是直观就能简单理解的。

因为袋子中总共有 4 个球，在无放回取球的规则下，我们现在故意用连续摸 4 次球的概率建模观点来看这个问题。把黑球编号为 1, 2 并记 $B = \{1, 2\}$ ，白球编号为 3, 4 并记 $W := \{3, 4\}$ 。把一般样本点记作 $\omega := (\omega_1, \dots, \omega_4)$ ，其中 ω_i 代表第 i 次取球得到的球的编号， $i = 1, 2, 3, 4$ 。这时候可以把概率空间建模为样本空间如下的古典概率模型

$$\Omega := \{\omega := (\omega_1, \dots, \omega_4) : \omega_1, \dots, \omega_4 \text{ 是 } 1, 2, 3, 4 \text{ 的一个排列}\}.$$

此时， $A_1 := \{\omega_1 \in B\}$ 代表第一次摸走了一个黑球¹， $A_2 := \{\omega_2 \in B\}$ 代表第二次摸走了一个黑球。容易算出 $|\Omega| = 4! = 24$ ， $|A_1| = 12$ ， $|A_1 \cap A_2| = 4$ 。于是 $\mathbb{P}(A_1) = \frac{12}{24} = \frac{1}{2}$ ， $\mathbb{P}(A_1 \cap A_2) = \frac{4}{24} = \frac{1}{6}$ ，

$$\mathbb{P}(A_2|A_1) = \frac{\mathbb{P}(A_1 \cap A_2)}{\mathbb{P}(A_1)} = \frac{1/6}{1/2} = \frac{1}{3}. \quad \square$$

读者也可尝试建立连续摸 2 次球的古典概率模型来解答上例中问题。

¹这里， $A_1 := \{\omega_1 \in B\}$ 是概率论中常见的偷懒记号，它的准确写法是 $A_1 := \{\omega := (\omega_1, \dots, \omega_4) \in \Omega : \omega_1 \in B\}$ 。这种偷懒写法在概率论中会大量出现，读者要逐渐习惯，并在要求精确的场合能够写成对应的不偷懒写法。

例 3.2. 某夫妇有且仅有两个孩子，且已知其中至少有一个女孩。请问该夫妇的两个孩子都是女孩的概率有多大？（假定小孩出生时，其男、女性别是等概率的。）

参考解答： 由于假设生儿、育女是等概率的，我们可以取样本空间为

$$\Omega = \{(\text{男}, \text{男}), (\text{男}, \text{女}), (\text{女}, \text{男}), (\text{女}, \text{女})\},$$

用以表示两个孩子按照老大、老二的性别排列形成的组合全体。于是已经发生的事件 A 是“老大或老二是女孩”，即 $A = \Omega \setminus \{(\text{男}, \text{男})\}$ ；关心的事件 B 是“老大、老二都是女孩”，即 $B = \{(\text{女}, \text{女})\}$ ，关心的概率其实是条件概率 $\mathbb{P}(B|A)$ ，其中 $A \cap B = B$ 。因此

$$\mathbb{P}(B|A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)} = \frac{1/4}{3/4} = \frac{1}{3}. \quad \square$$

下面的问题看似与上例差不多，但其中大有蹊跷。

例 3.3. 某夫妇有且仅有两个孩子。某次外出活动中，该夫妇仅带出来其中一个孩子，是女孩。请问该夫妇的另一个孩子也是女孩的概率有多大？（假定小孩出生时，生儿、育女是等概率的。）

估计不少人会认为，上例解答给出的概率值 $\frac{1}{3}$ 就是本例的答案。但是，仔细思考上述解答，如果把它作为本例的解答，则其中概率建模实际上应该认为有一些缺陷，它并不能完全刻画对应问题中所有有必要关心的细节。实际上，除了该夫妇的家庭结构这部分由于未知性而带来了随机性（或不确定性）外，夫妇选择带两个孩子中的哪一个出门也具有随机性；作为概率建模，那对夫妇带出的小孩的“基本结果”刻画，除了知道是男孩、女孩的信息，理应知道：带出的小孩到底是老大还是老二？因此以上述解答作为本例的回答是有大争议的。从信息量的角度讲，“带出来其中一个孩子，是女孩”确实能蕴含两个孩子中“至少有一个女孩”，但还有一个信息是“两个孩子中的一个女孩带出门了”，因此两个问题（例3.2与例3.3）并不等价。下面给出的解答就显得更为细致，给出了一个完全不同的概率值，请读者仔细品味思索¹。

例3.3的参考解答： 为了详细描述该夫妇的二孩结构和他们带其中一个孩子出门的行为，我们用三个坐标分量构成的点 $\omega := (x_1, x_2, \tau)$ 来进行表达，前两个

¹有些学者认为例3.3中问题是 ill-defined，编者并不认可这一意见。问题的表述“其中一个...，另一个...”代表提问者实际上对问题中的两个孩子贴了可识别的标签；编者认为，合理的概率建模及其解释应当反映由此带来的随机性。标签的存在与否通常是会影响问题的答案的，一个非常典型的例子就是后续的 Littlewood “无穷”悖论，见例3.7。

分量 x_1, x_2 用于表达该夫妇的二孩结构 ($x_1, x_2 \in \{\text{男}, \text{女}\}$, 分别表达二孩中老大、老二的性别), 最后一个分量 τ 用于表达带出的孩子是老大 (对应 $\tau = 1$) 还是老二 (对应 $\tau = 2$). 由于对这两部分信息的无知, 我们按照不充分理由原理, 取样本空间为

$$\Omega = \{(x_1, x_2, \tau) : x_1, x_2 \in \{\text{男}, \text{女}\}, \tau \in \{1, 2\}\},$$

并认为其中样本点具有等可能性出现。于是已经发生的事件 A 是“观察到被带出门的孩子是女孩”, 即

$$A = \{(\text{男}, \text{女}, 2), (\text{女}, \text{男}, 1), (\text{女}, \text{女}, 1), (\text{女}, \text{女}, 2)\};$$

关心的事件 B 是“老大、老二都是女孩”, 即

$$B = \{(\text{女}, \text{女}, 1), (\text{女}, \text{女}, 2)\};$$

关心的概率其实是条件概率 $\mathbb{P}(B|A)$, 其中 $A \cap B = B$. 因此

$$\mathbb{P}(B|A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)} = \frac{2/8}{4/8} = \frac{1}{2}. \quad \square$$

例 3.4. (*Monty Hall 问题*, 又称*三门问题*¹、*山羊汽车问题*) 以下是第一章习题中就提及的 *Monty Hall 问题*². 假设你正在参加一个游戏节目, 你被要求在三扇门中选择一扇: 其中一扇后面有一辆车; 其余两扇后面则是山羊。你选择了一扇门, 假设是一号门, 然后知道门后面有什么的主持人蒙提·霍尔 (*Monty Hall*), 开启了另一扇后面有山羊的门, 假设是三号门。他然后问你: “你想选择二号门吗?” 转换你的选择是否能够增加你获得汽车奖品的概率?

三门问题的错误解答: 按两羊一车在三门中的排列是等可能性的假定

$$\begin{aligned} \mathbb{P}(\text{主持人打开的三号门} = \text{羊}) &= \frac{2}{3}, \\ \mathbb{P}(\text{一号门} = \text{车}, \text{主持人打开的三号门} = \text{羊}) &= \frac{1}{3}, \end{aligned}$$

因此

$$\mathbb{P}(\text{一号门} = \text{车} | \text{主持人打开的三号门} = \text{羊})$$

¹与此完全类似的一个问题是“三囚问题” (three prisoners problem), 它 1959 年出现在马丁·加德纳的《数学游戏》专栏中; 亦可参见文献^[47]的 1.4 节。有人说, 三囚问题更早的来源是 Bertrand 所著的 *Calcul des probabilités* 一书 (1889 年), 那里此问题也被称作“Bertrand 箱子悖论” (Bertrand's Box Paradox), 其表现形式类似于第一章习题中的三枚银币骗局。

²此处的 *Monty Hall 问题* 的叙述是 Steve Selvin 于 1975 年 2 月寄给 *American Statistician* 杂志的叙述的改编版本, 它来自 Craig F. Whitaker 于 1990 年寄给 *Parade Magazine* (《展示杂志》) Marilyn vos Savant (玛丽莲·沃斯·莎凡特) 专栏的信件。

$$= \frac{\mathbb{P}(\text{一号门} = \text{车}, \text{主持人打开的三号门} = \text{羊})}{\mathbb{P}(\text{主持人打开的三号门} = \text{羊})} = \frac{1}{2}.$$

这表明换不换的（条件）概率都是 $\frac{1}{2}$. $\square$

但上述乍看貌似道理满满的解答其实是对问题的误读。在这个问题中，对于主持人打开某扇门的行爲，我们通常应该解读为，他/她（主持人）总是打开剩下两门中对应山羊的其中某一扇门。这样事件“主持人打开的三号门 = 羊”在你选了一号门后，可以解读为确定性事件，它发生的概率是 1！也就是说在这种理解下，上述条件概率

$$\mathbb{P}(\text{一号门} = \text{车} | \text{主持人打开的三号门} = \text{羊}) = \frac{1}{3} < \frac{1}{2}.$$

因此，应该转换选择。

我们给出另外两种解释来说明应该转换选择。

三门问题的一种直观解答¹： 实际上，你选了一扇门后，剩下的 2 扇门中总是至少有一扇对应于山羊；这个步骤可以理解为由你来指派把三个门分成 1 个门和 2 个门的两组。问题转化为：为了更高的概率获得汽车奖品，你该选择 1 个门的组还是 2 个门的组？毫无疑问应该是后者，并且对应汽车奖品概率是 $2/3$ ，而原选择对应汽车奖品概率为 $1/3$ ；主持人打开剩下两扇门中对应山羊的（某个或唯一一个）门的行爲只不过更方便你更换选择后直接去兑换汽车奖品（如果中奖的话）而已。

总而言之，换门赢的概率等于一开始选错的概率，即 $2/3$. $\square$

三门问题的另一种概率解答： 此处通过穷尽几种情况分析，并呈现为图片的形式来给出解答。

见图 3.2（图片来自维基百科）。 $\square$

在提供了三门问题的上述两种解答后，在实际教学中，经常有同学询问：如果我们要使用（古典）概率模型来进行建模解答，应当如何建模呢？此处即使是编者本人也曾犯过迷糊：相信也有同学或老师尝试过把样本空间选作




图 3.2: 三门问题的图示解答

$$\Omega := \{(\omega_1, \omega_2, \omega_3; \tau_1, \tau_2) : \omega_1, \omega_2, \omega_3 \text{ 中有两“羊”一“车”,} \\ \tau_1, \tau_2 \text{ 是 } 1, 2, 3 \text{ 中的两个不同号码}\}$$

¹本解答是本书作者对知乎社区关于三门问题的一个回答的改编。

吧？前面的参数 $(\omega_1, \omega_2, \omega_3)$ 用于描述三个门对应的奖励的描述，而后两个参数 (τ_1, τ_2) 用于节目参加者和主持人选择的门的号码的描述。乍看这个建模也很合理，能够描述问题中所有有必要关心的细节，但按照此建模算出的换门中奖概率是 $\mathbb{P}(\omega_{\tau_1} = \text{羊} | \omega_{\tau_2} = \text{羊}) = \frac{1}{2}$ （请读者自行验证这一点）。问题出在哪呢？仔细体悟，不难发现：这个建模中实际上引入了不必要的随机性。作为概率建模者，我们应当站在“上帝视角”来考虑建模问题：在三门问题的游戏开始时，哪个号码的门对应于“车”是确定的，并且在游戏进行中是不再改变的，这部分信息在建模中不应当带来随机性；游戏中所有的随机性仅来源于节目参加者和主持人在选择号码上的随机性。基于此观点，我们重新建模如下：不妨设 1 号门对应于“车”，其余门对应于“羊”，恰如图 3.2 中的设置。同样设置参数 (τ_1, τ_2) 用于描述节目参加者和主持人选择的门的号码。则可取

$$\Omega := \{(\tau_1, \tau_2) : \tau_1, \tau_2 \text{ 是 } 1, 2, 3 \text{ 中的两个不同号码}\}.$$

但需要注意，从三门问题的游戏描述来看，此处主持人的选择 τ_2 是受节目参加者的选择 τ_1 影响的，简单来说

$$\mathbb{P}(\tau_1 = 1) = \mathbb{P}(\tau_1 = 2) = \mathbb{P}(\tau_1 = 3) = \frac{1}{3},$$

但，记 $E = \{2, 3\}$ 为无奖品号码集（即 2、3 号门对应于山羊，1 号门对应于汽车），我们应有

$$\mathbb{P}(\tau_2 \in E | \tau_1 = 1) = \mathbb{P}(\tau_2 \in E | \tau_1 = 2) = \mathbb{P}(\tau_2 \in E | \tau_1 = 3) = 1.$$

特别地， $\mathbb{P}(\tau_2 \in E) = 1$ ，由此我们要设置的上述概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 并不是古典概率模型！进而

$$\text{换门中奖概率} = \mathbb{P}(\tau_1 \in E | \tau_2 \in E) = \mathbb{P}(\tau_1 \in E) = \frac{2}{3}.$$

在三门问题的“一种直观解答”中我们已经看到：有时候通过合理的想象结合自然语言的解释与推理，有关概率问题可能可以非常简单地得出正确的答案，而使用严谨的数学符号语言来进行推理计算反而可能非常啰唆。下面就是另一个这种类型的有趣案例。

例 3.5. (乘客就座问题) 一架飞机上有 100 个座位，编号是从 1 到 100. 现在编号为 1 到 100 的乘客依次坐上飞机。编号为 1 的乘客比较皮，上了飞机之后是随机（等概率地）选座位坐的。其余乘客依次序上飞机后按如下规则就座：如果这位乘客编号为 $k \geq 2$ ，他先观察有没有人坐在 k 号位上。如果 k 号位空置，他就在那儿就座；否则他在剩下的空置位子里随机（等概率地）挑选一个就座。我们的问题是，第 100 号乘客能坐在第 100 号位子上的概率有多大？

自然语言的巧妙解答¹： 我们称没有对号落座的乘客为“犯错”乘客。如果 1 号乘客落座 $k \geq 2$ 号位置，那么明显 k 号乘客不能对号落座了，如此链式反应进行下去，将会有很多位“犯错”乘客出现。我们把 100 号乘客上飞机前的最后一位“犯错”乘客称为“伪 1 号乘客”；这个过程我们可以想象为坐错位置的乘客与本应落座此座位的乘客（他们成为新的“犯错”乘客）交换他们手里的号码牌，从而 1 号牌始终在这些“犯错”乘客按次序接力传递；每次接力传递完成后，之前已落座的“犯错”的乘客就可以认为已经修正为对号入座了。如果 1 号乘客就座 1 号位置，则按照就座规则，其余所有乘客都会对号落座；此时为了方便，我们仍然把 1 号乘客就视作“伪 1 号乘客”。不难知道，“伪 1 号乘客”其实只有两个位置可以挑选：1 号位置和 100 号位置；落座这两个位置之一后就不会被他之后、100 号乘客之前的其他乘客“驱赶”。根据乘客的就座规则，很明显，对于“伪 1 号乘客”来说，1 号位置和 100 号位置是对称的。于是我们清楚地看到第 100 号乘客能对号落座的概率就是“伪 1 号乘客”落座在 1 号位置的概率，即 $\frac{1}{2}$ 。 $\square$

下面我们讨论“条件概率的条件概率”。在概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 中，设 $A, B, C \in \mathcal{F}$, $\mathbb{P}(A) > 0, \mathbb{P}(B) > 0$, 且 $\mathbb{P}(A \cap B) > 0$. 作认同 $\mathbb{P}_A(\cdot) = \mathbb{P}(\cdot|A)$, 它仍然是概率测度。此时

$$\begin{aligned}\mathbb{P}_A(C|B) &= \frac{\mathbb{P}_A(B \cap C)}{\mathbb{P}_A(B)} = \frac{\mathbb{P}(B \cap C|A)}{\mathbb{P}(B|A)} \\ &= \frac{\mathbb{P}(A \cap B \cap C)}{\mathbb{P}(A \cap B)} = \mathbb{P}(C|A \cap B).\end{aligned}$$

也就是说，我们总有下列式成立：

$$\mathbb{P}_A(C|B) = \mathbb{P}(C|A \cap B) = \mathbb{P}_B(C|A). \quad (3.3)$$

在很多场合， $\mathbb{P}(C|A_1 \cap \cdots \cap A_n)$ 也简单写作 $\mathbb{P}(C|A_1, \cdots, A_n)$.

3.2 乘积概率空间与事件独立性

两个及多个事件的相互独立性概念是概率论中非常特别，也非常重要的概念。为了更好地理解这一概念，我们从乘积概率空间讲起；在明白了乘积概率空间后，事件独立性的定义也就可以顺理成章地给出了。如此论述的一个好处是，自然语言中的两个事件“无关”就非常自然而又本质性地对应于概率语言中的两个事件“相互独立”！

¹本解答借鉴了知乎社区对应问题的讨论。

3.2.1 乘积概率空间

古典概率论起源于古人关于赌博的数学建模探讨。一个公理化的概率模型（比如古典概率模型）可以想象为使用某种赌博道具一次的赌博（也视作一个随机试验）的概率建模。但现实生活中，很多时候人们赌博未必只使用一种赌博道具，比如人们可以同时使用骰子和扑克牌或麻将等道具进行赌博；即使使用同一种赌博道具，赌博中也未必只使用一次，比如我们有时会投掷一枚硬币多次来进行一些复杂的随机决策。这意味着我们有必要探讨：如何对同时（或先后）使用两种赌博道具（通常这两种赌博道具之间或同一种赌博道具的前后使用之间没有关联性）进行的“复杂赌博”做概率建模？探讨的结果表明，我们应当使用概率空间的“乘积”的手段，也就是用两个概率空间的乘积概率空间这一工具来进行概率建模。

我们把问题重新陈述如下。

问题：假定 $(\Omega_k, \mathcal{F}_k, \mathbb{P}_k)$ 是对使用道具 k 一次的赌博的概率建模，其中 $k = 1, 2$ 。假定这两种赌博道具的各自使用之间没有关联性，即：使用道具 1 得到的结果不会影响使用道具 2 得到的结果，反之亦然。那么我们应当如何利用前述概率建模 $\{(\Omega_k, \mathcal{F}_k, \mathbb{P}_k)\}_{k=1,2}$ ，实现对先后（或同时）使用道具 1、道具 2 各一次的“复杂赌博”进行概率建模？

这里最困难的部分是如何用精确的数学语言（概率论语言）来刻画“这两种赌博道具的各自使用之间没有关联性”这种含糊的自然语言描述的假定。

为了解决上述问题，我们先考虑最简单的情形，也就是两个概率模型 $\{(\Omega_k, \mathcal{F}_k, \mathbb{P}_k)\}_{k=1,2}$ 都是古典概率模型（或几何概率模型）的情形；注意，此时这两个概率模型都满足等可能性假设。需要铭记于心的是，我们的目标是借助最简单情形的直观理解来处理一般情形。

这时，为了实现对先后使用道具 1、道具 2 各一次的复杂结果的详尽刻画，很自然我们应当考虑乘积空间 $\Omega_1 \times \Omega_2$ ，其中的点 $(\omega_1, \omega_2) \in \Omega_1 \times \Omega_2$ 就能描述清楚：使用道具 1 得到的“基本结果”是 ω_1 ，使用道具 2 得到的“基本结果”是 ω_2 ；并且我们认为 ω_1, ω_2 是两个自由变量或独立变量，这一点也契合“两种赌博道具之间没有关联性”的自然语言描述的假定。由此可以取 $\Omega := \Omega_1 \times \Omega_2$ 作为先后使用道具 1、道具 2 各一次的“复杂赌博”的样本空间。这诱导我们去发展概率空间的（独立）乘积这一概念。

形式地，我们可以把先后使用道具 1、道具 2 各一次的“复杂赌博”建模为“乘积”概率空间（这种“乘积”在符号上本书将用“ $\otimes$ ”来表示）

$$(\Omega, \mathcal{F}, \mathbb{P}) := (\Omega_1, \mathcal{F}_1, \mathbb{P}_1) \otimes (\Omega_2, \mathcal{F}_2, \mathbb{P}_2).$$

现在问题转化为：我们该如何在新的“样本空间” $\Omega = \Omega_1 \times \Omega_2$ 上合理地定义能够谈论概率的事件的全体 $\mathcal{F}$ 以及对应的概率测度 $\mathbb{P} : \mathcal{F} \rightarrow \mathbb{R}$ 呢？

我们先来看乘积空间 $\Omega = \Omega_1 \times \Omega_2$ 中能够谈论概率的事件；如果原始假定是古典概率模型的假定，自然应当选择 $\mathcal{F} = 2^\Omega$ ，无法借此看出一般情形该如何处理，因此此处我们基于几何概率模型的假定来进行讨论。对 $k = 1, 2$ ，设 $A_k \in \mathcal{F}_k$ 是概率空间 $(\Omega_k, \mathcal{F}_k, \mathbb{P}_k)$ 中能够谈论概率的一个具体事件。很自然，“在使用道具1、道具2各一次后 A_1 事件和 A_2 事件都发生了”这样描述的复杂事件应该是能够谈论概率的，而这一复杂事件在上述数学建模中对应于 $\Omega_1 \times \Omega_2$ 中事件 $A_1 \times A_2$ ，这种形态的事件在概率论或测度论中被称为可测矩形。可测矩形的全体是下面的集族：

$$\mathcal{F}_1 \times \mathcal{F}_2 := \{A_1 \times A_2 : A_1 \in \mathcal{F}_1, A_2 \in \mathcal{F}_2\}. \quad (3.4)$$

容易知道，上述集族 $\mathcal{F}_1 \times \mathcal{F}_2$ 一般而言不是 σ -代数。因此我们可以取上述集族生成的 σ -代数

$$\mathcal{F}_1 \otimes \mathcal{F}_2 := \sigma(\mathcal{F}_1 \times \mathcal{F}_2) \quad (3.5)$$

作为 $\Omega = \Omega_1 \times \Omega_2$ 上的事件域 $\mathcal{F}$ ，即 $\mathcal{F} := \mathcal{F}_1 \otimes \mathcal{F}_2$ （注意，这也是实变函数课程中高维欧氏空间中的Borel σ -代数的定义方式）；不难知道， $2^{\Omega_1} \otimes 2^{\Omega_2} = 2^{\Omega_1 \times \Omega_2}$ ，也就是说，这个选择即使是在古典概率模型假定下也是合理的。上述 $\mathcal{F}_1 \otimes \mathcal{F}_2$ 称为乘积 σ -代数¹，亦即我们有下面的乘积可测空间（或乘积可测结构）

$$(\Omega_1 \times \Omega_2, \mathcal{F}_1 \otimes \mathcal{F}_2) = (\Omega_1, \mathcal{F}_1) \otimes (\Omega_2, \mathcal{F}_2). \quad (3.6)$$

现在我们来定义所谓的乘积概率测度 $\mathbb{P} = \mathbb{P}_1 \otimes \mathbb{P}_2$ 。由于我们已经假定 $(\Omega_k, \mathcal{F}_k, \mathbb{P}_k), k = 1, 2$ 都是古典概率模型（或几何概率模型），满足等可能性假设，很自然应该认为新的概率空间 $(\Omega, \mathcal{F}, \mathbb{P}) = (\Omega_1 \times \Omega_2, \mathcal{F}_1 \otimes \mathcal{F}_2, \mathbb{P}_1 \otimes \mathbb{P}_2)$ 仍然满足等可能性，也是古典概率模型（或几何概率模型）。也就是说，对任意 $A_1 \in \mathcal{F}_1, A_2 \in \mathcal{F}_2$

$$\begin{aligned} \mathbb{P}_1 \otimes \mathbb{P}_2(A_1 \times A_2) &= \frac{|A_1 \times A_2|}{|\Omega_1 \times \Omega_2|} = \frac{|A_1| \cdot |A_2|}{|\Omega_1| \cdot |\Omega_2|} \\ &= \frac{|A_1|}{|\Omega_1|} \cdot \frac{|A_2|}{|\Omega_2|} = \mathbb{P}_1(A_1) \cdot \mathbb{P}_2(A_2). \end{aligned}$$

因此，乘积概率测度 $\mathbb{P}_1 \otimes \mathbb{P}_2$ 在可测矩形 $A_1 \times A_2$ 上的合理赋值是

$$\mathbb{P}_1 \otimes \mathbb{P}_2(A_1 \times A_2) := \mathbb{P}_1(A_1) \cdot \mathbb{P}_2(A_2), \quad A_1 \in \mathcal{F}_1, A_2 \in \mathcal{F}_2. \quad (3.7)$$

¹读者应自行验证习题3.1的结论。

幸运的是, 上述乘积概率测度 $\mathbb{P}_1 \otimes \mathbb{P}_2$ 在可测矩形的全体 $\mathcal{F}_1 \times \mathcal{F}_2$ 上的赋值方式就唯一确定了它在乘积 σ -代数 $\mathcal{F}_1 \otimes \mathcal{F}_2$ 上的取值; 此处我们不展开乘积概率测度 $\mathbb{P}_1 \otimes \mathbb{P}_2$ 的存在唯一性的进一步论述, 对此感兴趣的读者请移步第四章去学习和应用 Carathéodory 定理 (见定理4.2.2) 而自行完成论证, 亦可参见附录A中给出的证明。读者也可以去参考学习其他《测度论》教材的对应内容。

通过以上论述, 我们在 $(\Omega_k, \mathcal{F}_k, \mathbb{P}_k), k = 1, 2$ 都是古典概率模型 (或几何概率模型) 的假定下给出了乘积概率空间的合理定义。由此外推至一般的概率空间 $(\Omega_k, \mathcal{F}_k, \mathbb{P}_k), k = 1, 2$, 我们定义乘积概率空间 (有时也称为独立乘积概率空间、乘积概率结构)

$$(\Omega, \mathcal{F}, \mathbb{P}) = (\Omega_1, \mathcal{F}_1, \mathbb{P}_1) \otimes (\Omega_2, \mathcal{F}_2, \mathbb{P}_2)$$

如下: 样本空间取 $\Omega := \Omega_1 \times \Omega_2$; 事件域取 $\mathcal{F} := \mathcal{F}_1 \otimes \mathcal{F}_2 = \sigma(\mathcal{F}_1 \times \mathcal{F}_2)$, 其中可测矩形的全体 $\mathcal{F}_1 \times \mathcal{F}_2$ 的定义见(3.4); 概率测度取 $\mathbb{P} := \mathbb{P}_1 \otimes \mathbb{P}_2$, 其中 $\mathbb{P}_1 \otimes \mathbb{P}_2$ 由(3.7)决定, 有时也称 $\mathbb{P}_1 \otimes \mathbb{P}_2$ 为 $\mathbb{P}_1$ 与 $\mathbb{P}_2$ 的独立乘积。亦即

$$(\Omega_1, \mathcal{F}_1, \mathbb{P}_1) \otimes (\Omega_2, \mathcal{F}_2, \mathbb{P}_2) := (\Omega_1 \times \Omega_2, \mathcal{F}_1 \otimes \mathcal{F}_2, \mathbb{P}_1 \otimes \mathbb{P}_2). \quad (3.8)$$

以上探讨了两个概率空间的“独立乘积”的定义 (其间也本质上给出了两个可测结构的乘积可测结构的定义)。原则上可类似定义任意多个概率空间 (或可测结构、测度结构) 的“独立乘积”, 也有相应的存在唯一性问题需要解决, 同样请对此感兴趣的同学移步学习附录A中 §A.3提供的证明或其他《测度论》教材中的有关论述。而既然有乘积概率空间的概念, 自然也对应应有因子概率空间的概念, 此处亦不再赘述。

📌 注记 3.1. 在我们发展出了乘积概率空间的技术后, 原则上我们就可以通过乘积的手段构建足够丰富的概率空间用以容纳所关心的各种随机现象。因此几乎所有的概率论教材在介绍完公理化的概率空间后, 都采纳如下做法: 除非确有必要指出样本空间、事件域、概率测度等的具体构造的场合, 一般情形下总是默认概率空间已经给定、却又不指明, 然后在此基础上直接进行有关随机事件、随机现象 (包括后续将介绍的随机变量) 的陈述, 并通过逻辑推理与计算给出关心的概率问题的解答或讨论。

3.2.2 事件独立性的定义

在上一小节的讨论中, 我们给出了乘积概率空间

$$(\Omega, \mathcal{F}, \mathbb{P}) := (\Omega_1, \mathcal{F}_1, \mathbb{P}_1) \otimes (\Omega_2, \mathcal{F}_2, \mathbb{P}_2)$$

的合理定义。在那里, 容易看到: 概率空间 $(\Omega_1, \mathcal{F}_1, \mathbb{P}_1)$ 中的 A_1 事件 ($A_1 \in \mathcal{F}_1$) 应该对应于概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 中的 $\tilde{A}_1$ 事件, 其中 $\tilde{A}_1 := A_1 \times \Omega_2$; 概率空间

$(\Omega_2, \mathcal{F}_2, \mathbb{P}_2)$ 中的 A_2 事件 ($A_2 \in \mathcal{F}_2$) 应该对应于概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 中的 $\tilde{A}_2$ 事件, 其中 $\tilde{A}_2 := \Omega_1 \times A_2$. 显然 $A_1 \times A_2 = \tilde{A}_1 \cap \tilde{A}_2$, 即它代表 $\tilde{A}_1$ 、 $\tilde{A}_2$ 两事件同时发生这一复合事件. 此时

$$\begin{aligned}\mathbb{P}(\tilde{A}_1 \cap \tilde{A}_2) &= \mathbb{P}_1 \otimes \mathbb{P}_2(A_1 \times A_2) = \mathbb{P}_1(A_1) \cdot \mathbb{P}_2(A_2) \\ &= \mathbb{P}_1 \otimes \mathbb{P}_2(A_1 \times \Omega_2) \cdot \mathbb{P}_1 \otimes \mathbb{P}_2(\Omega_1 \times A_2) = \mathbb{P}(\tilde{A}_1) \cdot \mathbb{P}(\tilde{A}_2).\end{aligned}$$

这两个事件 $\tilde{A}_1$ 、 $\tilde{A}_2$ 本质来源于两个相互不关联的概率模型 (或赌博问题). 在自然语言中, 这两个事件之间是“互不关联”、“无关”、“风马牛不相及”的; 而用概率语言来定量描述, 可以表述为: 当 $\tilde{A}_1$ 、 $\tilde{A}_1^c$ 都是正概率事件时, $\tilde{A}_1$ 事件是否发生的已知信息, 并不会影响我们对 $\tilde{A}_2$ 事件发生 (或不发生) 及其发生 (或不发生) 的 (条件) 概率的推断, 亦即

$$\mathbb{P}(\tilde{A}_2 | \tilde{A}_1) = \mathbb{P}(\tilde{A}_2), \quad \mathbb{P}(\tilde{A}_2 | \tilde{A}_1^c) = \mathbb{P}(\tilde{A}_2).$$

我们把同一个概率空间中的两事件 $\tilde{A}_1$ 、 $\tilde{A}_2$ 之间的上述关系提炼为概率论中特有的事件独立性这一概念¹.

定义 3.2.1. 给定概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 中两事件 $A, B \in \mathcal{F}$. 称它们**相互独立** (或 A 与 B **独立**), 记作 $A \perp\!\!\!\perp B$, 强调概率测度时则记作 $A \perp\!\!\!\perp_{\mathbb{P}} B$, 如果

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B). \quad (3.9)$$

当 A, B 不满足上述方程时, 就称 A, B **不独立**² (记作 $A \not\perp\!\!\!\perp B$).

容易看到, 对于 $A, B \in \mathcal{F}$, 如果 $\mathbb{P}(A) > 0$, 那么 A 与 B 独立当且仅当

$$\mathbb{P}(B | A) = \mathbb{P}(B). \quad (3.10)$$

亦即, 两事件的相互独立性也等价于: “条件概率”就是“无条件概率”; 用自然语言来说就是: A 事件的发生 (这个信息) 并不会影响我们后续对 B 事件发生概率的推断. 注意, 当 A, B 相互独立时, 我们并不能说事件 A 的发生对事件 B 的发生没有影响! 部分概率论教材中是采纳性质(3.10)作为两事件 A, B 相互独立的定义, 但这要求事件 A 是正概率事件; 更多的概率论教材直接采用(3.9)作为两事件 A, B 相互独立的定义而几乎不作“为何概率论中两事件的独立对应于自然语言中两事件的无关”的解说。

¹在第六章中我们进一步借助概率空间的同态概念说明了独立事件列本质上可以视作来源于乘积概率空间的诸因子空间中对应的诸“互不关联”事件; 于是自然语言中的“两个事件无关”就本质性地对应于概率论中的“两个事件相互独立”。

²事件 A, B 不独立时, 有些文献也称 A, B 是相依的。

我们指出：几乎不可能事件（或几乎必然事件）总是与任何事件都相互独立的。这是因为，如果 $A \in \mathcal{F}$ 是几乎不可能事件，那么对任意事件 $B \in \mathcal{F}$

$$\mathbb{P}(A \cap B) \leq \mathbb{P}(A) = 0,$$

进而(3.9)的左右两端都是 0，“=”自然成立。 $A \in \mathcal{F}$ 是几乎必然事件时， $A^c \in \mathcal{F}$ 就是几乎不可能事件，由此仍然可以证明(3.9)总成立。

以下我们讨论多个事件之间的“相互独立性”。同样设想有 $2 \leq N < \infty$ 个概率空间 $\{(\Omega_k, \mathcal{F}_k, \mathbb{P}_k)\}_{k=1}^N$ ，它们各自对应于使用某种赌博道具进行赌博的概率建模。而同时使用这些（相互不关联的）赌博道具进行的复杂赌博的概率建模为

$$(\Omega, \mathcal{F}, \mathbb{P}) := (\Omega_1, \mathcal{F}_1, \mathbb{P}_1) \otimes \cdots \otimes (\Omega_N, \mathcal{F}_N, \mathbb{P}_N).$$

同样可以考察“子概率空间” $(\Omega_k, \mathcal{F}_k, \mathbb{P}_k)$ 中的事件 $A_k \in \mathcal{F}_k$ 在大概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 中的对应物 $\tilde{A}_k := \{\omega = (\omega_1, \dots, \omega_N) : \omega_k \in A_k\}$. 不难证明大概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 中的事件列 $\{\tilde{A}_k\}_{k=1}^N$ 具有如下性质：对任意 $2 \leq n \leq N$ 及 $1 \leq i_1 < i_2 < \cdots < i_n \leq N$ ，总有

$$\mathbb{P}\left(\bigcap_{r=1}^n \tilde{A}_{i_r}\right) = \prod_{r=1}^n \mathbb{P}(\tilde{A}_{i_r}).$$

我们同样把上述性质提炼为多个事件之间的“相互独立性”，具体定义如下：

定义 3.2.2. 给定事件族 $\{A_\alpha\}_{\alpha \in I}$ ，其中 $A_\alpha \in \mathcal{F}, \forall \alpha \in I$ ，且 $N := \#(I) \geq 2$. 称事件族 $\{A_\alpha\}_{\alpha \in I}$ **相互独立**，如果对任意自然数 $2 \leq n \leq N$ 及 I 中任意 n 个互不相同的指标 $\alpha_1, \dots, \alpha_n \in I$ ，总有

$$\mathbb{P}\left(\bigcap_{r=1}^n A_{\alpha_r}\right) = \prod_{r=1}^n \mathbb{P}(A_{\alpha_r}). \quad (3.11)$$

更一般地，我们可以如下定义子 σ -代数之间的相互独立性。

定义 3.2.3. 设 $\mathcal{G}_1, \mathcal{G}_2$ 都是 $\mathcal{F}$ 的子 σ -代数。称 $\mathcal{G}_1$ 与 $\mathcal{G}_2$ 相互独立，如果

$$\mathbb{P}(A_1 \cap A_2) = \mathbb{P}(A_1) \cdot \mathbb{P}(A_2), \forall A_1 \in \mathcal{G}_1, A_2 \in \mathcal{G}_2.$$

同样， $n \geq 2$ 个子 σ -代数 $\mathcal{G}_i \subset \mathcal{F}, i = 1, \dots, n$ 称为相互独立，如果

$$\mathbb{P}\left(\bigcap_{i=1}^n A_i\right) = \prod_{i=1}^n \mathbb{P}(A_i), \quad \forall A_i \in \mathcal{G}_i, i = 1, \dots, n. \quad (3.12)$$

不难证明: A 与 B 相互独立, 当且仅当 $\sigma(A)$ 与 $\sigma(B)$ 相互独立; 此处 $\sigma(A)$ 代表由 A 生成的 σ -代数, 即: 当 $A \neq \emptyset, \Omega$ 时, $\sigma(A) = \{\emptyset, A, A^c, \Omega\}$. 一般地, 事件列 $\{A_k\}_{k=1}^N$ 相互独立, 当且仅当子 σ -代数列 $\{\sigma(A_k)\}_{k=1}^N$ 相互独立。

事件独立性带来的好处是, 有关复合事件的概率可以有比较简便的计算公式。例如, 当 $\{A_i\}_{i=1}^n$ 相互独立时, 我们有下面的计算公式:

$$\mathbb{P}\left(\bigcap_{i=1}^n A_i\right) = \prod_{i=1}^n \mathbb{P}(A_i), \quad \mathbb{P}\left(\bigcap_{i=1}^n A_i^c\right) = \prod_{i=1}^n [1 - \mathbb{P}(A_i)], \quad (3.13)$$

$$\mathbb{P}\left(\bigcup_{i=1}^n A_i\right) = 1 - \prod_{i=1}^n [1 - \mathbb{P}(A_i)], \quad \mathbb{P}\left(\bigcup_{i=1}^n A_i^c\right) = 1 - \prod_{i=1}^n \mathbb{P}(A_i). \quad (3.14)$$

例 3.6. (三枚特殊骰子) 在第一章习题 1.3 中我们提到了三枚银币骗局。这里给出一个类似的程序上看似公平的游戏¹。假设有 A, B, C 三枚特殊的 (均匀材质的) 骰子, 它们的六个面刻数字情况如下:

A 骰子: 1, 1, 5, 5, 5, 5;

B 骰子: 3, 3, 3, 4, 4, 4;

C 骰子: 2, 2, 2, 2, 6, 6.

拥有这三枚骰子的张三邀请李四来与他进行投掷骰子的游戏, 李四先挑选这三枚骰子之一, 之后张三从剩下的骰子中挑选一枚, 两人使用挑选好的骰子进行投掷, 得到的点数结果大的人获胜。请问这个游戏公平吗?

参考解答: 简单起见, 使用 A, B, C 三枚骰子投掷所得数字也对应分别记作 A, B, C . 如果 A 骰子出现的数字大于 B 骰子出现的数字, 我们就把此事件记作 $\{A > B\}$, 其他记号作类似理解。很容易算出

$$\begin{aligned} \mathbb{P}(A > B) &= \mathbb{P}(A = 5) = \frac{2}{3}, \\ \mathbb{P}(B > C) &= \mathbb{P}(C = 2) = \frac{2}{3}, \\ \mathbb{P}(C > A) &= \mathbb{P}(A = 1 \text{ 或 } (A = 5, C = 6)) \\ &= \mathbb{P}(A = 1) + \mathbb{P}(A = 5)\mathbb{P}(C = 6) = \frac{5}{9}. \end{aligned}$$

这里提醒读者, 上面的计算中使用了骰子 A, C 分别出现数字 5、6 这两个事件之间的独立性。以上计算结果说明, 张三可以根据李四挑选的骰子, 对应选择合适的骰子, 确保胜率 $\geq \frac{5}{9} > \frac{1}{2}$, 从而这是一个后手有优势的不公平游戏。□

¹ 见文献^[114]的第 193–194 页。

上述特殊骰子的游戏实际上告诉我们：对于现实生活中的石头剪刀布的划拳游戏，如果你知道了某人在三种手势中的偏好后，你就可以针对性地设计自己的划拳策略，使得游戏略微有利于自己；请读者自行思考如何做到这一点。

3.3 经典条件概率与事件独立性的简单应用

3.3.1 应用 1：乘法公式

根据(3.2)，对任意 $A, B \in \mathcal{F}$ ，当 $\mathbb{P}(A) > 0$ 时，我们有如下两个事件同时发生的概率的一个计算公式：

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B|A). \quad (3.15)$$

上述公式称为**乘法公式**，它最早是由 De Moivre 提出的。

下面有趣的例子来自文献^[86]；这提供了条件概率的乘法公式和概率测度的上连续性的一个很好的应用，同时也提供了我们对涉及“无穷”的问题的一种合理的理解方式。

例 3.7. (Littlewood “无穷”悖论问题) 假设有一个无限大的空坛子以及无限个分别带有编号 1、2、3、... 的相同材质的球。考虑以下试验①：在差 1 分到 12 点钟的时候（我们称之为第 1 步），将 1 至 10 号球放入坛中，并把 10 号球取出（总假设放球、取球不花费时间）；在差 $\frac{1}{2^1}$ 分到 12 点钟的时候（我们称之为第 2 步），将 11 至 20 号球放入坛中，并把 20 号球取出；在差 $\frac{1}{2^2}$ 分到 12 点钟的时候，将 21 至 30 号球放入坛中，并把 30 号球取出；一般地，在差 $\frac{1}{2^n}$ 分到 12 点钟的时候（我们称之为第 $n+1$ 步），将 $10*n+1$ 至 $10*(n+1)$ 号球放入坛中，并把 $10*(n+1)$ 号球取出；...

问题 1：在试验 ① 中，到 12 点钟整的时刻，坛子里有多少个球？

问题 1 的答案很明显，那时坛子中将有无多个球，因为所有编号的球，除了 10 的倍数编号的球外，都在 12 点钟之前放入，并一直呆在坛子中而没有再次取出。

现在对上述放球、取球方案进行调整，称为试验 ②：一般地，对任意 $n \geq 0$ ，总是在差 $\frac{1}{2^n}$ 分到 12 点钟的时候（第 $n+1$ 步），将 $10*n+1$ 至 $10*(n+1)$ 号球放入坛中，并把 $n+1$ 号球取出。

问题 2：在试验 ② 中，到 12 点钟整的时刻，坛子里有多少个球？

令人惊讶的是，问题 2 的答案是：到 12 点钟整的时刻，坛子里一个球也

没有!¹理由是:任何编号为 n 的球都在第 n 步中被取出,并且从此之后再也没有被重新放入坛子里。读者需要设法理清这里反直觉的现象出现的原因。

最后我们设计另外一种放球之后再进行随机取球的方案,称为试验③:一般地,对任意 $n \geq 0$,总是在差 $\frac{1}{2^n}$ 分到 12 点钟的时候(第 $n+1$ 步),将 $10*n+1$ 至 $10*(n+1)$ 号球放入坛中,并在把坛内的球(此时坛内有 $9*(n+1)+1$ 球)混合均匀后随机地从中取出一球。

问题 3: 在试验③中,到 12 点钟整的时刻,坛子里有多少个球?

问题 3 的解答: 我们将证明:最后坛子里一个球也没有;数学上,我们是通过证明“到 12 点钟整的时刻,坛中有球”这一事件 F 是几乎不可能事件来实现这个说理的。具体来说,我们将证明,对任意编号为 k 的球,它在坛子中的概率是 0。此处推理的一般化手段见习题 3.5 (2.a),而习题 10.65 给出了本例的推广模型与结论²。

记 $F_n^{(k)}$ 表示“在第 n 步的放球、取球动作完成后, k 号球仍然在坛子中”这一事件。记 $F_\infty^{(k)}$ 为“到 12 点钟时 k 号球仍然在坛子中”这一事件。于是

$$F = \bigcup_{k=1}^{\infty} F_\infty^{(k)}.$$

先考虑 $k=1$ 号球。容易知道

$$\mathbb{P}(F_n^{(1)}) = \frac{9}{10} \cdot \frac{18}{19} \cdots \frac{9n}{9n+1} = \left[\prod_{k=1}^n \left(1 + \frac{1}{9k}\right) \right]^{-1},$$

并且 $F_\infty^{(1)} = \bigcap_{n=1}^{\infty} F_n^{(1)}, F_n^{(1)} \searrow F_\infty^{(1)}$. 由概率的上连续性

$$\begin{aligned} \mathbb{P}(F_\infty^{(1)}) &= \mathbb{P}\left(\bigcap_{n=1}^{\infty} F_n^{(1)}\right) = \lim_{n \rightarrow \infty} \mathbb{P}(F_n^{(1)}) = \lim_{n \rightarrow \infty} \left[\prod_{k=1}^n \left(1 + \frac{1}{9k}\right) \right]^{-1} \\ &\leq \lim_{n \rightarrow \infty} \left[1 + \sum_{k=1}^n \frac{1}{9k} \right]^{-1} = 0. \end{aligned}$$

现在对任意 $k \geq 2$, 仿照上面方法可以证明总有 $\mathbb{P}(F_\infty^{(k)}) = 0$. 于是

$$\mathbb{P}(F) \leq \sum_{k=1}^{\infty} \mathbb{P}(F_\infty^{(k)}) = 0.$$

¹这被 J. Littlewood (1885—1977; 英国) 称为 an infinity paradox, 见文献^[69]; 因此我们称之为 Littlewood “无穷”悖论。

²相应结论需要使用第十章中的 Chebyshev 不等式来论证, 因此该推广模型被置于习题 10.65 中讨论。

因此, 到 12 点钟时, 事件 F 发生 (坛中最终有球) 的概率为 0, 亦即坛子几乎必然最终是空的。□

注意, 在例 3.7 中, 如果所有球都不带标签, 并且它们无法区分, 则 3 个试验给我们呈现的图景都是: 每步先从外部取 10 个相同材质、不可区分的球放入坛中, 之后从坛中取出 1 个球; 很自然, 这种情形下的问题的答案显然与例 3.7 的问题 2、3 的答案不同。因此在现实问题的概率建模中, 要特别注意对应问题中是否需要考虑可识别的标签等细节。

3.3.2 应用 2: 全概率公式

现在假设有两两互斥的事件组 $\{A_k\}_{k=1}^N \subset \mathcal{F}$ (其中 $N \leq \infty$) 满足

$$\Omega = \biguplus_{k=1}^N A_k.$$

我们称此事件组 $\{A_k\}_{k=1}^N$ 为**完备事件组** (也称为**分割**)。此时, $\forall B \in \mathcal{F}$

$$B = B \cap \left(\biguplus_{k=1}^N A_k \right) = \biguplus_{k=1}^N (A_k \cap B).$$

于是 $\mathbb{P}(B) = \sum_{k=1}^N \mathbb{P}(A_k \cap B) = \sum_{k=1}^N \mathbb{P}(A_k) \cdot \mathbb{P}(B|A_k)$. 因此我们有下面的定理。

♠ **定理 3.3.1. (全概率公式)** 如果 $\{A_k\}_{k=1}^N$ 是完备事件组, 那么对任意 $B \in \mathcal{F}$

$$\mathbb{P}(B) = \sum_{k=1}^N \mathbb{P}(A_k) \cdot \mathbb{P}(B|A_k). \quad (3.16)$$

注意, 对于两两互斥的事件组 $\{A_k\}_{k=1}^N \subset \mathcal{F}$, 如果 $B \in \mathcal{F}$ 满足

$$\mathbb{P}(B \setminus \biguplus_{k=1}^N A_k) = 0,$$

则上述**全概率公式**(3.16)仍然成立。习题 3.2 给出了(3.16)成立的更宽松条件。

以下我们通过一些实例展示全概率公式的应用。

例 3.8. 考虑 *Pólya* 坛子模型, 设坛子中有 $b \geq 2$ 个黑球, 有 $r \geq 1$ 个红球。 B_1 代表第一次摸出一个黑球; B_2 代表第二次摸出一个黑球。

(1) 在有放回的摸球规则下, 两事件 B_1, B_2 相互独立吗?

(2) 在无放回的摸球规则下, 两事件 B_1, B_2 相互独立吗?

参考解答： 此处我们仅用条件概率的观点来讨论独立性，有兴趣的读者亦可仿照例2.5、例2.6使用建立古典概率模型的方法来进行讨论。

(1) 对于有放回的 Pólya 坛子模型，在完成第一次摸球并放回所摸球后，坛内球的结构又恢复到初始状况，因此 $\mathbb{P}(B_2|B_1) = \mathbb{P}(B_1)$, $\mathbb{P}(B_2|B_1^c) = \mathbb{P}(B_1)$. 基于此二式以及全概率公式，我们导出

$$\mathbb{P}(B_2) = \mathbb{P}(B_1)\mathbb{P}(B_2|B_1) + \mathbb{P}(B_1^c)\mathbb{P}(B_2|B_1^c) = \mathbb{P}(B_1),$$

进而 $\mathbb{P}(B_2|B_1) = \mathbb{P}(B_2)$. 从而两事件 B_1, B_2 在有放回的 Pólya 的坛子模型下看是相互独立的。

(2) 对于无放回的 Pólya 坛子模型，在完成第一次摸球得到黑球并不再把此黑球放回坛子后，坛内球的结构变成了 $b-1$ 个黑球、 r 个红球，因此 $\mathbb{P}(B_2|B_1) = \frac{b-1}{b+r-1}$. 但根据例2.6, $\mathbb{P}(B_1) = \mathbb{P}(B_2) = \frac{b}{b+r} \neq \mathbb{P}(B_2|B_1)$, 从而两事件 B_1, B_2 在无放回的 Pólya 坛子模型下看是不相互独立的。□

例 3.9. (选举得票率问题) 本问题来源于文献.^[107] 假设美国某中学的一个学生团体即将进行选举，有特雷茜和保罗两个候选人。民调显示，在左撇子和右撇子这两类选民（假定仅有这两类选民）中，对两位候选人的支持率存在重大差异。可能是特雷茜大力提倡教室里的左手桌政策的缘故，左撇子选民中，75% 支持特雷茜，只有 25% 支持保罗。然而右撇子选民并不信服：在这些选民中，60% 支持保罗，只有 40% 支持特雷茜。假设左撇子占投票人数的 20%，那么谁会赢得选举？用不同（但却等价的）方式来表述该问题：如果你随机地找到一个投票的人，他/她投票给特雷茜的概率有多大？

参考解答： 我们采纳下面的记号

$L =$ 左撇子, $R =$ 右撇子, $T =$ 投票特雷茜, $P =$ 投票保罗,

由全概率公式

$$\begin{aligned}\mathbb{P}(T) &= \mathbb{P}(L)\mathbb{P}(T|L) + \mathbb{P}(R)\mathbb{P}(T|R) \\ &= 20\% \times 75\% + (1 - 20\%) \times 40\% = 47\%.\end{aligned}$$

从而 $\mathbb{P}(P) = 1 - \mathbb{P}(T) = 53\%$, 即特雷茜得票率为 47%, 比保罗的得票率低 6%, 民调结果表明保罗将赢得选举。□

在上例的民调中，特雷茜输掉选举的原因是，左撇子选民在整体选民中的比例小，她提倡的政策吸引的选民受众面太窄；为了赢得选举，她还应当设法在占大多数的右撇子选民中扩大影响、提升支持率。假设左撇子选民占比由 20% 变动至 40%，其他数据不变，请读者通过计算判断谁会赢得选举。

例 3.10. (敏感性调查问题) 设某校想要对研究生论文抄袭现象进行社会调查。如果直接就此问题进行问卷调查, 就是说, 要被调查者直说是否发生过抄袭, 即使这样的调查是无记名的, 也会使被调查者感到尴尬, 从而难以得到如实的回答。现在设计如下方案可使被调查者更乐意作出真实的回答: 在一个箱子里放进 1 个红球和 1 个白球。被调查者在摸到球后记住颜色并立刻将球放回, 然后根据球的颜色是红和白分别回答第一个问题或第二个问题: (1) 你的生日是否在 7 月 1 日以前? (2) 你做论文时是否有过抄袭行为? 回答时只要在一张预备好的白纸上打 $\checkmark$ 或打 $\times$, 分别表示是或否。假定被调查者有 150 人, 统计出有 45 个 $\checkmark$ 。我们的问题是: 该校研究生论文中有抄袭行为的比率大概是多少?

参考解答: 注意到生日在 7 月 1 日以前的人群比例大致是 50%, 我们使用简略易懂的记号可以把题设中的已知条件表述为:

$$\begin{cases} \mathbb{P}(\text{红}) = \mathbb{P}(\text{白}) = 0.5, \\ \mathbb{P}(\checkmark|\text{红}) = \mathbb{P}(\times|\text{红}) = 0.5, \\ \mathbb{P}(\checkmark) = \frac{45}{150} = 0.3. \end{cases}$$

根据全概率公式: $\mathbb{P}(\checkmark) = \mathbb{P}(\text{白})\mathbb{P}(\checkmark|\text{白}) + \mathbb{P}(\text{红})\mathbb{P}(\checkmark|\text{红})$, 我们所求为

$$\begin{aligned} \mathbb{P}(\checkmark|\text{白}) &= \frac{\mathbb{P}(\checkmark) - \mathbb{P}(\text{红}) \cdot \mathbb{P}(\checkmark|\text{红})}{\mathbb{P}(\text{白})} \\ &= \frac{0.3 - 0.5 \cdot 0.5}{0.5} = 0.1. \end{aligned}$$

因此, 此社会调查估计的抄袭行为比例约为 10%.

□

📌 笔记 3.2. 对于涉及隐私等私密性、敏感性问题的社会调查的调查问卷的设计, 上述敏感性调查问题给出了一个极其聪明的调查设计方案, 是统计调查领域的经典案例。

下面另一个类似的经典案例是 Ross 著作^[86]中的 Example 3h.

例 3.11. (同卵双生问题) 双胞胎可能是同卵双生或异卵双生的。同卵双生也叫单卵双生, 是由一个受精卵分裂成为两个完全一样的部分发育而来, 因而同卵双胞胎含有相同的基因。异卵双生又叫二卵双生, 是由两个受精卵植入子宫发育而来。异卵双胞胎就像不同时间出生的兄弟姐妹一样, 基因多少是有些不一样的。为了知道双胞胎中同卵双胞胎的比例, 加利福尼亚州洛杉矶市指派了一位统计学家来研究该问题。这位统计学家最初要求该市每家医院对双胞胎做记录, 同时对是否同卵双生做标记。然而, 医院告诉他, 要判断一个新生儿是否是同卵双生并不是一件简单的事, 这关系到父母是否愿意自费给孩子做这项复杂而又昂贵的 DNA 检验。经过一番思考之后, 统计学家只让医院提供标记

着双胞胎是否是相同性别的所有双胞胎数据列表。当数据表明，约有 64% 的双胞胎是性别相同时，统计学家就宣称：约有 28% 的双胞胎是同卵双生的。他是如何得到这个结论的？

参考解答： 由生物学的结论，同卵双生的双胞胎总是同性别的；而异卵双生的双胞胎就相当于普通的兄弟姐妹，因此他们性别相同的概率为 $1/2$ 。我们使用简略易懂的记号可以把题设中的已知条件表述为：

$$\begin{cases} \mathbb{P}(\text{同性}|\text{同卵}) = 1, \\ \mathbb{P}(\text{同性}|\text{异卵}) = 0.5, \\ \mathbb{P}(\text{双生同性}) = 0.64, \end{cases}$$

根据全概率公式

$$\begin{aligned} \mathbb{P}(\text{双生同性}) &= \mathbb{P}(\text{同卵})\mathbb{P}(\text{同性}|\text{同卵}) + \mathbb{P}(\text{异卵})\mathbb{P}(\text{同性}|\text{异卵}) \\ &= \mathbb{P}(\text{同卵}) + [1 - \mathbb{P}(\text{同卵})] \cdot 0.5 \\ &= 0.5 + 0.5 * \mathbb{P}(\text{同卵}). \end{aligned}$$

于是所求为

$$\mathbb{P}(\text{同卵}) = \frac{\mathbb{P}(\text{双生同性}) - 0.5}{0.5} = \frac{0.64 - 0.5}{0.5} = 28\%.$$

因此，同卵双生在双胞胎中的比例为 28%。

□

上述两个例子都是基于全概率公式¹

$$\mathbb{P}(B) = \mathbb{P}(A) \cdot \mathbb{P}(B|A) + \mathbb{P}(A^c) \cdot \mathbb{P}(B|A^c)$$

进行估算，只不过一者估算的是条件概率

$$\mathbb{P}(B|A) = \frac{\mathbb{P}(B) - \mathbb{P}(A^c) \cdot \mathbb{P}(B|A^c)}{\mathbb{P}(A)}, \quad (3.17)$$

另一者估算的是无条件概率²

$$\mathbb{P}(A) = \frac{\mathbb{P}(B) - \mathbb{P}(B|A^c)}{\mathbb{P}(B|A) - \mathbb{P}(B|A^c)}. \quad (3.18)$$

下面我们利用条件概率的概念结合全概率公式来讨论之前第二章就已经讨论过的抓阄的公平性问题（见例2.7）。

¹在这两例（特别是例3.10）中，许多人误以为是用了本章即将要讲述的 Bayes 公式。

²此处估算的无条件概率实际应该是在 A, B 不相互独立的条件下才成立的，否则分母就等于 0 了。

例 3.12. (抓阄的公平性) 假设有 r 项奖品, 共有 $n \geq r$ 个人来共同分配 (每人不允许获得两项及以上的奖品), 因此采取抓阄的方式来实现: 用 r 个红球代表奖品, 用 $b = n - r$ 个黑球代表无奖品, 然后采用无放回的方式取球 n 次。则这种抓阄方式是公平的, 抓阄的次序不会影响公平性。

参考解答: 记初始 b 个黑球, r 个红球时考虑的无放回取球问题对应概率测度为 $\mathbb{P}_{b,r}$, 以 R_j 表示第 j 次取到红球这一事件。于是容易知道

$$\mathbb{P}_{b,r}(R_1) = \frac{r}{b+r}, \quad \mathbb{P}_{b,r}(R_1^c) = \frac{b}{b+r}, \quad \forall b, r \geq 0, b+r \geq 1.$$

以下使用数学归纳法证明: 只要 $b+r \geq 1$ 和 $1 \leq j \leq b+r$, 就有

$$\mathbb{P}_{b,r}(R_j) = \frac{r}{b+r}, \quad \mathbb{P}_{b,r}(R_j^c) = \frac{b}{b+r}.$$

事实上, $j=1$ 的情形已经证明。而当 $j+1 \leq b+r$ 时, 不妨设 $b \geq 1, r \geq 1$, 则

$$\begin{aligned} \mathbb{P}_{b,r}(R_{j+1}) &= \mathbb{P}_{b,r}(R_1) \cdot \mathbb{P}_{b,r}(R_{j+1}|R_1) + \mathbb{P}_{b,r}(R_1^c) \cdot \mathbb{P}_{b,r}(R_{j+1}|R_1^c) \\ &= \frac{r}{b+r} \mathbb{P}_{b,r-1}(R_j) + \frac{b}{b+r} \mathbb{P}_{b-1,r}(R_j) \quad (\text{模型假定}) \\ &= \frac{r}{b+r} \cdot \frac{r-1}{b+r-1} + \frac{b}{b+r} \cdot \frac{r}{b+r-1} \quad (\text{归纳假设}) \\ &= \frac{r}{b+r}. \end{aligned}$$

进而 $\mathbb{P}_{b,r}(R_{j+1}^c) = 1 - \mathbb{P}_{b,r}(R_{j+1}) = \frac{b}{b+r}$. 由此最终结论成立。□

上例中, 通过考虑第一步/第一次 (取球) 的所有可能, 建立对应的全概率公式, 进而建立递推公式的思想非常自然, 也非常有用。历史上, **Pascal** 和 **Fermat** 对于赌金分配问题的讨论中给出了若干种解答, 其中就有这种建立递推公式的解答思路, 我们介绍如下。

例 3.13. (赌金分配问题) 设甲、乙两赌徒进行公平的赌博 (即二人单局获胜概率相同; 假定没有平局)。事先约定谁先赢得 6 局便算赢家, 赢家获得全部赌金。如果甲赢 5 局, 乙赢 3 局时因故终止赌博, 应如何分配赌金才合理?

参考解答: 令 $f_6(x, y) := \mathbb{P}_{x,y}$ (甲先赢得 6 局) 表示甲、乙分别赢了 x 局和 y 局时继续赌下去甲最终先赢得 6 局的条件概率。通过考虑后续的第一局的胜负情况, 建立 $f_6(x, y)$ 的递推公式如下: (以下 $x, y \in \mathbb{Z}_+$)

$$f_6(x, y) = \frac{1}{2}[f_6(x+1, y) + f_6(x, y+1)], \quad 0 \leq x, y \leq 5.$$

注意到

$$f_6(x, 6) = 0, \quad f_6(6, x) = 1, \quad \forall 0 \leq x \leq 5,$$

并由对称性得到 $f_6(x, x) = \frac{1}{2}, \forall 0 \leq x \leq 5$. 由此我们可以计算 $f_6(5, 3)$ 如下

$$\begin{aligned} f_6(5, 3) &= \frac{1}{2}[f_6(6, 3) + f_6(5, 4)] \\ &= \frac{1}{2} + \frac{1}{4}[f_6(6, 4) + f_6(5, 5)] \\ &= \frac{1}{2} + \frac{1}{4} + \frac{1}{8} = \frac{7}{8}. \end{aligned}$$

进而甲、乙两赌徒赌金分配比例为 $f_6(5, 3) : [1 - f_6(5, 3)] = 7 : 1$.

如果令 $g_6(x, y) := \mathbb{P}_{x,y}(\text{乙先赢得 } 6 \text{ 局})$ 表示甲、乙分别赢了 x 局和 y 局时继续赌下去乙最终先赢得 6 局的条件概率, 也可以类似计算 $g_6(5, 3)$, 结果是一致的, 计算效率略高些. 请读者自行尝试. $\square$

作为一个对应的练习, 请读者移步研究本章习题3.19探讨的赌金分配问题的变种问题——赌徒破产模型.

例 3.14. (Pólya 坛子模型: 推广模型 A) 坛内有 b 个黑球, r 个红球, 每次随机地取走一球, 观察取出的球的颜色并放回坛内与之同色的球 $a + 1 \geq 0$ 个, 则 $a = -1$ 时相当于无放回模型, $a = 0$ 时相当于有放回模型, $a \geq 1$ 时就是每次增加同色球 a 个的模型 (有些文献称此时的 Pólya 坛子模型为传染病模型). 根据首次取球的颜色, 利用全概率公式, 归纳法容易证明:

- $\mathbb{P}(B_j) = \frac{b}{b+r}, \mathbb{P}(R_j) = \frac{r}{b+r}, \forall j$ 满足 $b + r + ja \geq 0$;
- $\mathbb{P}(\text{连续 } n \text{ 次取球, 恰取得 } k \text{ 个黑球}) = \frac{[b+(k-1)a]!_{a,k} [r+(n-k-1)a]!_{a,n-k}}{[b+r+(n-1)a]!_{a,n}}$, 其中, $n!_{a,k} := n(n-a) \cdots [n-(k-1)a]$; 此处对 b, r, a, n, k 有一些要求: 乘积中分母不出现 0 和负数, 分子不出现负数.

上例中结论的证明留给读者去完成.

例 3.15. (Pólya 坛子模型: 推广模型 B) 坛内有 b 个黑球, r 个红球, 每次随机地取走一球, 记录下取出的球的颜色 (黑色记录为 $I = 0$, 红色记录为 $I = 1$) 并放回坛内黑、红球各 $b_I + (1-I), r_I + I$ 个 ($I = 0, 1$). 当 $b_0 = r_1 = a, b_1 = r_0 = 0$ 时, 此模型就变成上例中的模型. 本推广模型中相关事件的概率计算可以通过条件概率的方法实现, 只不过计算及结果的表达更为复杂, 此处从略.

例 3.16. (秘书问题¹) 某公司需要招聘秘书一名, 共有 n 人应聘. n 较大 (假定 $n > 10$), 因此从面试安排的时间成本、经济成本出发, 公司拟按如下策略逐一安排应聘人选的面试, 希望能从中招聘到最佳人选: 对前 $K = K_n$ 个面试

¹ 本例来源于文献^[118], 略有改动.

者, 记录其面试表现, 但不录用; 从第 $K+1$ 个面试者开始, 只要发现面试者比他之前所有的已面试者都好, 就直接录用他, 招聘工作就到此结束; 如果这样的人选一直找不到, 我们就认为招聘失败了¹. 请问, 为了成功招聘到 n 人中的最佳人选的概率达到最大, 该如何设置参数 K_n ?

参考解答: 记 A 为成功招聘到 n 人中的最佳人选这一事件; 记 B_j 为此 n 人中的最佳人选的实际面试序号为 j 这一事件. 由于没有先验知识, 我们自然应当认为 $\mathbb{P}(B_j) = \frac{1}{n}, j = 1, \dots, n$. 根据招聘策略, 有

$$\mathbb{P}(A|B_j) = 0, j = 1, \dots, K.$$

另外, 当 $n \geq j \geq K+1$ 时, 在 B_j 发生的条件下招聘能够成功落实的充要条件是, 前 $j-1$ 个面试者中的“最优秀者”(我们称他/她为“次最优秀者”)被安排在前 K 个面试者行列了(否则那位“次最优秀者”先于 j 号面试而被招聘, 导致 j 号没有获得面试机会). 因此

$$\mathbb{P}(A|B_j) = \frac{K}{j-1}, j = K+1, \dots, n.$$

于是由全概率公式

$$\mathbb{P}(A) = \sum_{j=1}^n \mathbb{P}(B_j) \mathbb{P}(A|B_j) = \frac{K}{n} \sum_{j=K+1}^n \frac{1}{j-1} =: f_n(K). \quad (3.19)$$

对于调和级数的部分和, 我们有下列的结果(其中 $\gamma = 0.57721\dots$ 为欧拉常数, $1 - \frac{20}{21n^2} \leq \theta_n \leq 1$, 参见文献^[120]第9页的习题7):

$$\sum_{k=1}^n \frac{1}{k} = \ln n + \gamma + \frac{1}{2n} - \frac{1}{12n^2} + \frac{\theta_n}{120n^4}. \quad (3.20)$$

当 K 充分大(从而 $n \geq K+1$ 也充分大)时, $\sum_{j=K+1}^n \frac{1}{j-1} \approx \ln \frac{n}{K}$, 此时

$$\mathbb{P}(A) \approx \frac{K}{n} \ln \frac{n}{K} = -\frac{K}{n} \ln \frac{K}{n}.$$

注意到函数 $g(x) = -x \ln x, x \in (0, 1]$ 的最大值点在 $x = \frac{1}{e} \approx 0.36788$ 处取到, 我们得到 K 的一个合理取法是

$$K = K_n \approx \frac{n}{e}.$$

¹当前 $n-1$ 次面试都不成功时, 有时也采取招聘最后一位面试者的做法, 以避免最终招聘不成功。

基于(3.19)与(3.20), 记 $\beta_n = 1 - \frac{\theta_n}{10n^2}$, 容易得到

$$f_n(K+1) - f_n(K) = \frac{1}{n} \left[\ln \frac{n}{eK} - \frac{1}{2} \left(\frac{1}{K} + \frac{1}{n} \right) + \frac{1}{12} \left(\frac{\beta_K}{K^2} - \frac{\beta_n}{n^2} \right) \right].$$

由此, 理论上能够严谨说明 $\mathbb{P}(A) = f_n(K)$ 确实在 $K_n = \lfloor \frac{n}{e} \rfloor$ 或 $K_n = \lfloor \frac{n}{e} \rfloor + 1$ 达到最大值¹, 但需要多费一些功夫; 有关计算与论证细节留给读者。当 n 充分大时, 该招聘策略只有 $\frac{1}{e} \approx 0.36788$ 左右的成功率。□

在招聘实务工作中, 通常负责招聘的人事专员应是有多多年行业经验的从业人员, 他们有自己的招聘标准与招聘流程; 特别地, 一般而言招聘工作也不必在面试当场就给出是否录用的答复。因此以上秘书问题的讨论只具有理论参考价值。

3.3.3 应用 3: Bayes 公式

现在假定有完备事件组 $\{A_k\}_{k=1}^N \subset \mathcal{F}$ 以及满足 $\mathbb{P}(B) > 0$ 的事件 $B \in \mathcal{F}$. 在现实生活中, 这个完备事件组 $\{A_k\}_{k=1}^N$ 代表我们对于事物的“因”层次的完整分类, 而事件 B 则视作一种已知结果。一般而言我们假定“由因及果”的规律 (即 $\{\mathbb{P}(B|A_k)\}_{k=1}^N$) 是已知的; 我们想做的是“由果溯因”: 计算 $\mathbb{P}(A_i|B)$ 的概率大小, 如果这个概率很大, 我们就可以把结果 B 主要归因于“因素” A_i . 此时根据条件概率的定义、乘法公式以及全概率公式




图 3.3: Bayes 公式

$$\mathbb{P}(A_i|B) = \frac{\mathbb{P}(A_i \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(A_i) \cdot \mathbb{P}(B|A_i)}{\sum_{k=1}^N \mathbb{P}(A_k) \cdot \mathbb{P}(B|A_k)}.$$

于是我们有下面的 Bayes 公式:

♠ **定理 3.3.2.** (Bayes 公式) 若 $\{A_k\}_{k=1}^N$ 是完备事件组, 且 $\mathbb{P}(B) > 0$, 则

$$\mathbb{P}(A_i|B) = \frac{\mathbb{P}(A_i) \cdot \mathbb{P}(B|A_i)}{\sum_{k=1}^N \mathbb{P}(A_k) \cdot \mathbb{P}(B|A_k)}. \quad (3.21)$$

概率论中, 不确定性通常可以认为有两种来源: 一种是随机性导致的偶然不确定性 (aleatoric uncertainty); 另一种是无知导致的认知不确定性 (epistemic

¹ 大部分情况下, 最大值点 $K = K_n$ 可以表示为 $K_n^* := \lfloor (n - 0.5)/e + 0.5 \rfloor$. 编程计算表明, 在 $5 \leq n \leq 10^5$ 内仅两个例外: $K_{97} = 35$, $K_{97}^* = 36$ 和 $K_{24586} = 9044$, $K_{24586}^* = 9045$. 可以进一步修正公式为 $K_n = \lfloor (n - 0.5)/e + 0.5 - \frac{1}{12n} \rfloor$, 以在 $5 \leq n \leq 10^5$ 范围内包含这两个例外。

uncertainty). 在上述 Bayes 公式(3.21)中, 我们可以认为: $\mathbb{P}(A_i)$ 对应于我们先于获得试验数据时就抱有的对现实世界中引起某现象的多种可能“原因”的认知上的不确定性感受, 因此把 $\mathbb{P}(A_i)$ 称为**先验概率**, 把 $\{\mathbb{P}(A_k)\}_{k=1}^N$ 称为**先验分布(列)**; 而 $\mathbb{P}(B|A_k)$ 则对应于随机现象 B 的一种偶然不确定性, 它是由给定“原因” A_k 而导致的随机现象 B (即试验“结果” B , 但这一般不是试验的“基本结果”)发生的不确定性; 最后, $\mathbb{P}(A_i|B)$ 代表由于试验“结果” B 出现后而导致的对“原因” A_i 出现可能性大小的判断信息 (由此形成新的认知), 因此我们把 $\mathbb{P}(A_i|B)$ 称为**后验概率**, 把 $\{\mathbb{P}(A_k|B)\}_{k=1}^N$ 称为**后验分布(列)**。由此, Bayes 公式告诉了我们, 当有了新的“证据” B 后, 我们应当如何合理更新对现实世界认知上的不确定性 (即获得后验概率)。在其他学科中 Bayes 公式或许还有其他的解释, 为避免过多偏离讲义主题, 此处不再继续展开这方面的论述。

Bayes 公式虽然简单, 但它的应用非常广泛, 特别是对当今的人工智能领域有重要影响。另外, 基于 Bayes 公式中的思想, 在概率与统计的有关问题的研究过程中, 与频率学派相对应的, 从学者群体中进一步派生出了所谓的 Bayes 学派, 对现代统计学产生了深远的影响。

例 3.17. 此处我们借助 Bayes 公式的观点对例3.3再次进行讨论。在例3.3中, 已知两孩中其中一孩子是女孩, 则该夫妇的两孩结构只能是 (男, 女)、(女, 男)、(女, 女) 三者之一。在承认“观察到该二孩家庭有孩子是女孩”这一信息获得后导出的“该夫妇的二孩结构是 (男, 女)、(女, 男)、(女, 女) 三种情形之一”的等可能性 (在例3.2中实际可以证明这一点) 的基础上,

- (i) 如果认为该夫妻在带小孩出门的事情上有性别偏好, 总是只带女孩出门 (在两孩均女孩时则随机带一女孩出门), 则可以算出另一孩子也是女孩的 (条件) 概率就确实是例3.2的参考解答中给出的概率值:

$$\frac{\frac{1}{3} \cdot \frac{1}{2} + \frac{1}{3} \cdot \frac{1}{2}}{\frac{1}{3} \cdot 1 + \frac{1}{3} \cdot 1 + (\frac{1}{3} \cdot \frac{1}{2} + \frac{1}{3} \cdot \frac{1}{2})} = \frac{1}{3}.$$

但假定“该夫妻总是只带女孩出门 (在两孩均女孩时则随机带一女孩出门)”的合理性是值得质疑的。

- (ii) 如果认为该夫妻在带小孩出门的事情上既无性别偏好, 又无年龄偏好, 亦即两夫妇是等可能地带老大或老二出门而导致被观察到“带出门的孩子

是女孩”¹，则相应的另一个孩子也是女孩的概率就将变为

$$\frac{\frac{1}{3} \cdot 1}{\frac{1}{3} \cdot \frac{1}{2} + \frac{1}{3} \cdot \frac{1}{2} + \frac{1}{3} \cdot 1} = \frac{1}{2}.$$

- (iii) 如果认为该夫妻在带小孩出门的事情上无性别偏好，但有年龄偏好：他们总是以 f 的概率带老大出门（以 $1-f$ 的概率带老二出门），则可以算出另一孩子也是女孩的（条件）概率仍然是 $\frac{1}{2}$ ，不依赖 f 的具体取值。

以上论述表明在例3.3中，“另一孩子也是女孩的概率是 $\frac{1}{2}$ ”的说法更为合理。

在上例中，请读者进一步思考：假设该夫妻在带小孩出门的事情上既有性别偏好又有年龄偏好，在老大是女孩时他们总是以 $f_{1,1}$ 的概率带老大出门（以 $f_{1,2} = 1 - f_{1,1}$ 的概率带老二出门），在老大是男孩时他们总是以 $f_{2,1}$ 的概率带老大出门（以 $f_{2,2} = 1 - f_{2,1}$ 的概率带老二出门），请问此时在已知带出门的孩子是女孩的条件下，另一个孩子也是女孩的概率是多少？

以下我们提供 Bayes 公式的更多应用案例，以便加深读者对此的理解。

例 3.18. (选举得票率问题后续) 本例是例3.9的后续。考虑两个后续问题：

问题 A: 假设你在一个自助厅，观察到坐在对面的人（他/她是选民）用左手拿勺子，并据此推断出他/她是左撇子。那么他/她支持特雷茜的概率有多大？

问题 B: 假设你在一个自助厅，观察到坐在对面的人（他/她是选民）带有一个印着“我 ♥ 特雷茜”的徽章，并据此推断出他/她支持特雷茜。那么他/她是左撇子的概率有多大？

参考解答： 问题 A 的答案根据例3.9中数据应该是 $\mathbb{P}(T|L) = 75\%$ 。我们知道问题 B 实际上在问 $\mathbb{P}(L|T) = ?$ ；在给出答案之前，我们要指出这两个问题并不是同一个问题，即一般而言

$$\mathbb{P}(T|L) \neq \mathbb{P}(L|T).$$

认为这两个概率值相同是人们在估计概率时非常容易犯的错误。

现在我们根据 Bayes 公式来计算

$$\mathbb{P}(L|T) = \frac{\mathbb{P}(L)\mathbb{P}(T|L)}{\mathbb{P}(T)} = \frac{20\% \times 75\%}{47\%} \approx 31.9\%.$$

这比 $\mathbb{P}(T|L) = 75\%$ 小得多。

□

¹这是信息“观察到该二孩家庭有孩子是女孩”的获得方式。

例 3.19. (常规赛表现与季后赛问题) 文献^[107]的三位作者在 2012 年某周的报纸上阅读到一位在线专栏的作家在哀叹 (美国职业橄榄球比赛) 该赛季达拉斯牛仔队常规赛 1:4 的糟糕开局的评论: “只有 4% 的季后赛球队在常规赛中以 1:4 开局, 这意味着牛仔队只有 1/25 的概率进入季后赛”; 作者察觉出了在线专栏作家犯的错误, 你们察觉出来了吗? 这正是上一例题中我们指出的那些人们在估计概率时非常容易犯的错误: 用 A 代表 “球队常规赛中前 5 局只赢 1 局”, 用 M 代表 “球队进入季后赛”, 一般而言 $\mathbb{P}(M|A) \neq \mathbb{P}(A|M)$. 文献^[107]的作者们告诉我们, 那时总共有 32 支 NFL 球队, 其中有 12 支进入季后赛, 但没有再去查阅更多有关比赛的历史资料, 从而按照等可能性假设得到一般情况下一支球队进入季后赛的概率: $\mathbb{P}(M) = \frac{12}{32} = \frac{3}{8}$. 为了估算牛仔队进入季后赛的概率 $\mathbb{P}(M|A)$, 三位作者首先按下面的方式估算了 $\mathbb{P}(A)$: 假定每场比赛按照投掷硬币的方式来决定输赢 (这当然是对问题的一种简化, 但有一定合理性), 那么一支球队在常规赛前五场比赛中只赢一场的概率为

$$\mathbb{P}(A) = \binom{5}{1} \left(\frac{1}{2}\right)^5 = \frac{5}{32}.$$

我们已知 $\mathbb{P}(A|M) = 4\% = \frac{1}{25}$, 因此牛仔队进季后赛的概率可以估计为

$$\mathbb{P}(M|A) = \frac{\mathbb{P}(M) \cdot \mathbb{P}(A|M)}{\mathbb{P}(A)} = \frac{\frac{3}{8} \cdot \frac{1}{25}}{5/32} = 9.6\%$$

这是三位作者对于专栏作家犯的错误的一种纠正方案, 作者们在书中吐槽道, “牛仔队并没有 (专栏作家估计得) 这么糟”, 尽管 “事实上, 他们的确很糟糕...”。□

Bayes 公式某种意义上有由果溯因的意味, 这在医学诊断领域有重要应用价值: 我们经常有根据临床检查的结果来诊断病理、进而给出治疗建议与方案的需求。

例 3.20. (医学诊断问题) 本例来源于网络上的一篇博文。张某为了解自己患上了 X 疾病的可能性, 去医院作常规血液检查。其结果居然为阳性, 他赶忙到网上查询。根据网上的资料, 血液检查试验是有误差的, 这种试验有 “1% 的假阳性率和 1% 的假阴性率” (真的患病者检查得到阴性结果称为假阴性, 未患病的人检查得到阳性结果称为假阳性). 即在得病的人中做试验, 有 1% 的概率是假阴性, 99% 是真阳性。而在未得病的人中做试验, 有 1% 的概率是假阳性, 99% 是真阴性。于是张某根据这种解释, 估计他自己得了 X 疾病的概率为 99%. 张某的推理是, 既然只有 1% 的假阳性率, 那么, 99% 都是真阳性, 那我已被感染 X 病的概率便应该是 99%. 张某咨询了医生, 医生说: “99%? 哪有

那么大的感染几率啊。99% 是测试的准确性，不是你得病的概率。你忘了一件事：这种 X 疾病的正常比例是不大的，1000 个人中只有一个人有 X 病。” 张某不放心，又做了一个尿液检查，进一步检查他患上了 X 疾病的可能性，其结果仍然为阳性，尿液检查的试验有“5% 的假阳性率和 5% 的假阴性率”。

- a) 张某初始计算感染 X 病的概率是 99%，问题出在哪？
- b) 张某在血液检查之后感染 X 病的概率是多少？
- c) 张某在血液和尿液检查之后得 X 病的概率是多少？
- d) 假设根据张某的家族遗传信息，他得 X 病的概率是 1%，请问结合血液和尿液检查结果，张某得 X 病的概率是多少？

参考解答： a) 在这个例子中，张某由于没有认识到 X 疾病在人群中的患病率对自己患病率的影响，从而得出了错误的结论。换言之，虽然题中“真阳率 + 假阳率 = 100%”（这是题中数据的巧合，不是必然如此），不代表“假阳性”没发生，就意味着“真阳性”，也不代表得到阳性检验后患 X 病的条件概率就是“真阳率”。张某的错误在于没理解“假阳性”和“假阴性”的真实含义，产生了两点误会：其一是误以为总有“真阳率 + 假阳率 = 100%”（再次向读者强调一下，这仅仅是题中数据的巧合，不是必然如此）；其二是不了解

$$\text{真阳率} := \mathbb{P}(\text{阳}|\text{患}), \quad \text{假阳率} := \mathbb{P}(\text{阳}|\text{不患}), \quad (3.22)$$

误以为“真阳率 = $\mathbb{P}(\text{患}|\text{阳})$ ，假阳率 = $\mathbb{P}(\text{不患}|\text{阳})$ ”。更数学化地说，一般而言， $\mathbb{P}(B|A) \neq \mathbb{P}(A|B)$ 。

b) 此处，使用 Bayes 公式计算，得到

$$\begin{aligned} \mathbb{P}_{\text{血}}(\text{患}) &:= \mathbb{P}(\text{患}|\text{血阳}) = \frac{\mathbb{P}(\text{患})\mathbb{P}(\text{血阳}|\text{患})}{\mathbb{P}(\text{患})\mathbb{P}(\text{血阳}|\text{患}) + \mathbb{P}(\text{不患})\mathbb{P}(\text{血阳}|\text{不患})} \\ &= \frac{\frac{1}{1000} * 99\%}{\frac{1}{1000} * 99\% + \frac{999}{1000} * 1\%} \approx 9\%. \end{aligned}$$

c) 在上一步血检阳性的条件下，张某

患病 : 不患病

的先验分布已经由原来的 $\frac{1}{1000} : \frac{999}{1000}$ 变成了后验分布 9% : 91%。在进一步做尿检为阳性的条件下，前述后验分布成为此处的先验分布；特别注意，由于

血检和尿检是两种不同的检测手段，应有 $\mathbb{P}_{\text{血}}(\text{尿阳}|\text{患}) = \mathbb{P}(\text{尿阳}|\text{患}) = 95\%$ ， $\mathbb{P}_{\text{血}}(\text{尿阳}|\text{不患}) = \mathbb{P}(\text{尿阳}|\text{不患}) = 5\%$ 。因而

$$\begin{aligned}\mathbb{P}_{\text{血}}(\text{患}|\text{尿阳}) &= \frac{\mathbb{P}_{\text{血}}(\text{患})\mathbb{P}_{\text{血}}(\text{尿阳}|\text{患})}{\mathbb{P}_{\text{血}}(\text{患})\mathbb{P}_{\text{血}}(\text{尿阳}|\text{患}) + \mathbb{P}_{\text{血}}(\text{不患})\mathbb{P}_{\text{血}}(\text{尿阳}|\text{不患})} \\ &= \frac{9\% * 95\%}{9\% * 95\% + 91\% * 5\%} \approx 65\%.\end{aligned}$$

b)、c) 两步的计算过程/迭代过程可以用图3.4—3.5表示。

有好奇心的同学应当去考虑先根据尿检阳性的报告推断患病的条件概率，再在此基础上计算根据血检、尿检均为阳性的检验报告而给出的最终患病的条件概率，看看两种不同次序的迭代路径下最终获得的概率值是否相同，然后思考其中的道理。




图 3.4: 血检




图 3.5: 基于血检后的尿检




图 3.6: 基于遗传信息后的血检 + 尿检

d) 在此步骤中，由于检查了张某的家族遗传信息，对他的疾病诊断不应

该再使用广大人群患病的先验分布 $\frac{1}{1000} : \frac{999}{1000}$ ，而应该使用 $\frac{1}{100} : \frac{99}{100}$ 作为先验分布。此时重复 b)、c) 两步的计算如下：

$$\begin{aligned}\mathbb{P}_{\text{血}}(\text{患}) &:= \mathbb{P}(\text{患} | \text{血阳}) = \frac{\mathbb{P}(\text{患})\mathbb{P}(\text{血阳} | \text{患})}{\mathbb{P}(\text{患})\mathbb{P}(\text{血阳} | \text{患}) + \mathbb{P}(\text{不患})\mathbb{P}(\text{血阳} | \text{不患})} \\ &= \frac{1\% * 99\%}{1\% * 99\% + 99\% * 1\%} = 50\%,\end{aligned}$$

$$\begin{aligned}\mathbb{P}_{\text{血}}(\text{患} | \text{尿阳}) &= \frac{\mathbb{P}_{\text{血}}(\text{患})\mathbb{P}_{\text{血}}(\text{尿阳} | \text{患})}{\mathbb{P}_{\text{血}}(\text{患})\mathbb{P}_{\text{血}}(\text{尿阳} | \text{患}) + \mathbb{P}_{\text{血}}(\text{不患})\mathbb{P}_{\text{血}}(\text{尿阳} | \text{不患})} \\ &= \frac{50\% * 95\%}{50\% * 95\% + 50\% * 5\%} = 95\%.\end{aligned}$$

上述计算过程可以用图3.6表示。

□

📌 笔记 3.3. 我们再次分析一下上述医学诊断问题。容易知道

$$\begin{aligned}\mathbb{P}(\text{患} | \text{阳}) &= 1 / \left[1 + \frac{1 - \mathbb{P}(\text{患})}{\mathbb{P}(\text{患})} \cdot \frac{1 - \mathbb{P}(\text{阴} | \text{不患})}{\mathbb{P}(\text{阳} | \text{患})} \right] \\ &= 1 / \left[1 + \frac{1 - \text{人群发病率}}{\text{人群发病率}} \cdot \frac{1 - \text{真阴率}}{\text{真阳率}} \right].\end{aligned}\tag{3.23}$$

也就是说，如果某疾病的人群发病率很低，那么必须检测手段的灵敏度、精确度极高才能确保最终诊断时阳性报告对应于高概率患病的诊断结论。

在公共卫生领域一般建议医生不要对普通人群进行罕见疾病的普查，因为此时即使检测结果呈阳性，极有可能只是假阳性。例如，除非有很强的家族遗传史之类的原因，医生不建议 20 多岁或 30 多岁的女性进行乳房 X 光检查以检测乳腺癌。随着人们开始普遍认识到假阳性的问题，2004 年日本停止了对婴儿进行神经母细胞癌的全民检查¹。

Bayes 公式用于刑事或民事等案件的研究已有较长历史，比如我们在第一章就提到 1837 年 Poisson 的著作《关于刑事案件和民事案件审判概率的研究》。下面的例子来源于 Ross 著作^[86]，见其中的 Chapter 3, Example 3g.

例 3.21. (是否作弊问题) 1965 年 5 月，在阿根廷的首都布宜诺斯艾利斯举行的世界桥牌锦标赛上，英国一对著名的桥牌手 Terrence Reese 和 Boris Schapiro 被指控作弊，说是他们用手指作暗号暗示他们红桃的张数；两位选手都否认这一指控。事后，英国桥牌协会举行了一个听证会，听证会按法律的程序进行，既包含控方，也包含辩方，双方都有目击证人。在接下来的调查过程中，控方

¹本段落引自文献^[107]，略有改动。

检查了 Reese 和 Schapiro 打的几乎牌，并声称他们的打法与通过作弊已知了红桃张数的打法是吻合的。针对这一观点，辩方律师指出，他们的打法也同样与标准打法一致。然而，控方指出，既然他们的打法与其作弊的假设是一致的，那么就应该是支持这种假设。你如何理解控方的理由？

参考解答：这是一个新的证据（在本例中是“选手对特定情况下桥牌的打法”，我们记作 E ）如何影响某个特定假设（在本例中是“选手作弊”，我们记作 H ）成立的概率的问题。与上述注记类似， H 相当于那里的“患病”假设， E 相当于那里的“阳性报告”证据，因此

$$\mathbb{P}(H|E) = \frac{\mathbb{P}(H)}{\mathbb{P}(H) + [1 - \mathbb{P}(H)] \cdot \frac{\mathbb{P}(E|H^c)}{\mathbb{P}(E|H)}}. \quad (3.24)$$

我们关心有了新证据后，何时可以推断 $\mathbb{P}(H|E) > \mathbb{P}(H)$ ，因为这表示新证据倾向于支持假设成立。根据上面方程，假定 $\mathbb{P}(H) \in (0, 1)$ ，很容易知道：

$$\mathbb{P}(H|E) > \mathbb{P}(H) \Leftrightarrow \mathbb{P}(E|H) > \mathbb{P}(E|H^c).$$

因此，在本例中，除非在“选手作弊”假设（即 H ）下这种打法（即 E ）的可能性大于“选手没作弊”假设（即 H^c ）下这种打法（即 E ）的可能性，“选手的打法”（证据 E ）支持“他们是作弊的”（假设 H ）这一结论就不应当认为成立。但显然，从控方与辩方关于证据的陈述中，可以知道， $\mathbb{P}(E|H) > \mathbb{P}(E|H^c)$ 不成立，因而控方关于新证据（“选手的打法”）支持作弊的假设这一断言是无效的。□

我们定义事件 A 的**优势比**为 $\frac{\mathbb{P}(A)}{\mathbb{P}(A^c)}$ 。容易知道，在有新的证据 E 后，假设 H 的优势比也会发生如下的变化：

$$\frac{\mathbb{P}(H|E)}{\mathbb{P}(H^c|E)} = \frac{\mathbb{P}(H)}{\mathbb{P}(H^c)} \cdot \frac{\mathbb{P}(E|H)}{\mathbb{P}(E|H^c)}. \quad (3.25)$$

这意味着，如果证据支持假设，那么有了证据后的优势比就会大于原来的优势比。因此比值 $\mathbb{P}(E|H) : \mathbb{P}(E|H^c)$ 可以视作证据 E 对假设 H 的支持强度：比值越大，就认为证据支持假设的强度越大；当这个比值不超过 1 时，就应认为证据不支持假设。

3.3.4 应用 4：（无穷）重复试验与条件试验

我们假定单个（随机）试验对应的概率模型是 $(\Omega, \mathcal{F}, \mathbb{P})$ 。此处我们关心两个（随机）事件 $A, B \in \mathcal{F}$ ；在下面即将介绍的（无穷）重复试验或条件试验场景，我们将分别称它们为 A, B （随机）现象。

所谓**无穷重复试验**就是这样一个复杂试验：在同样的试验条件下，与过往试验独立/不关联地去反复做无穷次试验，并记录下各次试验的“基本结果”作为这个复杂试验的“基本结果”。在概率建模上，“无穷重复试验”这个复杂试验对应于概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 的无穷多次独立乘积空间 $(\tilde{\Omega}, \tilde{\mathcal{F}}, \tilde{\mathbb{P}}) := (\Omega, \mathcal{F}, \mathbb{P})^\infty$. 此时 $\tilde{\omega} = (\omega_1, \omega_2, \dots) \in \tilde{\Omega} = \Omega^\infty$ 是各次试验的试验记录结果的序列。当每次试验只关心某现象 A 是否发生，从而试验记录也只记录 A 现象是否发生这一信息时，此时的无穷重复试验又称为 **Bernoulli 试验**；本书第一章中提及的频率稳定性就是 **Bernoulli** 针对此处介绍的 **Bernoulli** 试验这种模型论证的，这将在第十章中进一步详细介绍。有限重复试验及其概率建模可类似定义；在本讲义中，重复试验通常就代表有限重复试验。

所谓 **A -条件试验**，则是无穷重复试验中，试验结果首次出现 A -现象的那个单次试验，试验记录也只记录那个单次试验的试验结果；此处我们假定 $p := \mathbb{P}(A) > 0$. A -条件试验的实际试验序号为

$$\tau_A = \tau_A(\tilde{\omega}) := \inf\{n \geq 1 : \omega_n \in A\}. \quad (3.26)$$

此时 A -条件试验的试验记录就是 ω_{τ_A} . 不难知道， $\tilde{\mathbb{P}}(\tau_A = n) = pq^{n-1}, \forall n \in \mathbb{N}$, 其中 $q := 1 - p$, 进而 $\tilde{\mathbb{P}}(\tau_A = \infty) = 0$.

现在我们可以给出概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 中条件概率 $\mathbb{P}(B|A)$ 的一种无条件概率解释了，见下例¹。

例 3.22. 计算 $I := \tilde{\mathbb{P}}(A\text{-条件试验中观察到 } B \text{ 现象})$ 如下：

$$\begin{aligned} I &= \tilde{\mathbb{P}}(\omega_{\tau_A} \in B) = \sum_{n=1}^{\infty} \tilde{\mathbb{P}}(\tau_A = n, \omega_{\tau_A} \in B) \\ &= \sum_{n=1}^{\infty} \tilde{\mathbb{P}}(\omega_j \notin A, \forall 1 \leq j < n, \omega_n \in A \cap B) \\ &= \sum_{n=1}^{\infty} \left[\prod_{j=1}^{n-1} \tilde{\mathbb{P}}(\omega_j \notin A) \right] \cdot \tilde{\mathbb{P}}(\omega_n \in A \cap B) \\ &= \sum_{n=1}^{\infty} q^{n-1} \cdot \mathbb{P}(A \cap B) = \frac{\mathbb{P}(A \cap B)}{1 - q} \\ &= \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)} = \mathbb{P}(B|A). \end{aligned}$$

这告诉我们， A 条件试验中观察到 B 现象的概率恰好是条件概率 $\mathbb{P}(B|A)$. 上述解释也是第九章中随机数发生器构造的 *Rejection Method* 的底层原理。

¹例3.22来源于浙江大学的赵敏智老师分享的资料，此处有所改写。特作此说明并致谢。

在第一章中，我们回顾概率论发展历史的时候曾经说，材质均匀的“随机数发生器”的制造难度是直到 15 世纪前后才出现概率论萌芽的部分原因。现在我们说，在概率论得到较成熟的发展后，基于上述条件概率的解释，即使是使用材质不均匀的“随机数发生器”，我们也有办法实现严格精确的等可能性，见下面的例题。

例 3.23. 假设甲、乙二人需要等概率地分配一张电影票的所有权，手边只有一枚不知道是否均匀的硬币。如何设计分配方案以做到公平合理？

参考解答¹: 假设投掷硬币的记录用正/反来表达得到的是正面或反面；连续两次投掷的结果，如果第一次正面，第二次反面，就记作 (正, 反)；其他记号类似理解。显然有 $\mathbb{P}((\text{正}, \text{反})) = \mathbb{P}((\text{反}, \text{正}))$ ，进而

$$\mathbb{P}((\text{正}, \text{反}) | (\text{正}, \text{反}) \text{ 或 } (\text{反}, \text{正})) = \frac{1}{2}.$$

根据上例中条件概率的解释，我们两次、两次地投掷这枚硬币，直到出现 (正, 反) 或 (反, 正) 的结果为止；约定出现 (正, 反) 记录把电影票分配给甲，出现 (反, 正) 记录则把电影票分配给乙。这就是一个公平的分配方案。 $\square$

对于随机试验，有时我们需要了解重复多少次试验才能保证有较大概率出现某特定现象。下面就是与此有关的一个有趣的例子。

例 3.24. 某网络游戏中击杀一次怪物 M 有可能掉落 4 种装备 $A_1, \dots, A_4$ 中的一种（或不掉落任何装备）；简单起见，设掉落 A_i 的概率均为 $p = 10\%$ ，不掉落任何装备的概率为 60%。收集齐这 4 种装备各一件就可以合成一件套装。求 n 次杀怪后能合成一件套装的概率 p_n ，其中 $n = 10, 20, 30, 40$ 。




图 3.7: 数列 $\{p_n\}_{n=1}^{\infty}$ 的示意图（例3.24，纵坐标单位为 %）

¹据文献^[114]第 16–17 页的介绍，J. von Neumann 曾提出此处解答中的解决方案，我们不知道 Neumann 是否是最早提出这种公平性解决方案的人。




图 3.8: 概率分布列 $\{f_n\}_{n=1}^{\infty}$ 的示意图 (例3.24, 纵坐标单位为 %)

参考解答: 对 $i = 1, \dots, 4$ 以及 $1 \leq k \leq n$, 记 $A_i^{(k)}$ 为第 k 次杀怪掉落装备 A_i 这一事件。又记 B_i 为 n 次杀怪都没有掉落 A_i 装备这一事件。 n 次杀怪后能合成一件套装这一事件为 $K_n = \bigcap_{i=1}^4 B_i^c$. 由 Jordan 公式,

$$p_n := \mathbb{P}(K_n) = 1 + \sum_{r=1}^4 (-1)^r \sum_{1 \leq i_1 < \dots < i_r \leq 4} \mathbb{P}\left(\bigcap_{k=1}^r B_{i_k}\right).$$

显然对 $r = 1, 2, 3, 4$ 及 $1 \leq i_1 < \dots < i_r \leq 4$

$$\mathbb{P}\left(\bigcap_{k=1}^r B_{i_k}\right) = \mathbb{P}\left(\bigcap_{j=1}^n \left(\bigcup_{k=1}^r A_{i_k}^{(j)}\right)^c\right) = (1 - rp)^n.$$

代入数据计算得到:

$$p_n = 1 - 4 \times 0.9^n + 6 \times 0.8^n - 4 \times 0.7^n + 0.6^n, \quad n \geq 0.$$

而恰好在第 n 次杀怪后才能首次集齐装备的概率 $f(n) := p_n - p_{n-1}$ 为

$$f(n) = 4 \times 0.1 \times 0.9^{n-1} - 6 \times 0.2 \times 0.8^{n-1} + 4 \times 0.3 \times 0.7^{n-1} - 0.4 \times 0.6^{n-1},$$

其中 $n \geq 1$. 数列 $\{p_n\}_{n=1}^{\infty}$ 的图像见图3.7; f 的图像见图3.8. 两图的横坐标都是杀怪次数, 纵坐标单位为 %.

计算得到 $p_{10} \approx 14.26\%$, $p_{20} \approx 57.97\%$, $p_{30} \approx 83.78\%$, $p_{40} \approx 94.17\%$. $\square$

网络游戏对于普通人来说, 主要功能是通过这种休闲娱乐来进行精神上压力的释放; 类似于杀怪的爆率这类型的游戏参数, 游戏公司自然应当要合理设置。而青少年们在成长阶段也应学会适度控制, 避免沉迷于各种网络游戏。

3.4 讨论：事件的概率、条件概率及其概率值大小

本节我们拟对自然语言中的概率与条件概率及零概率、小概率与大概率事件进行一些介绍与讨论；特别地我们将基于小概率原理讨论现实世界与概率（统计）建模之间的接口问题。

3.4.1 易混淆概念：特定语境中的概率与条件概率

1992 年 12 月¹，一架小型客机在瑞典首都斯德哥尔摩靠近布罗马机场的居民区坠落，所幸没有造成任何居民的伤亡。但这使已经饱受交通拥堵和机场扩张折磨的居民们又多了一个顾虑。为了平抚民众，机场总经理在接受电视采访时说道，“从统计学上说人们应当感到更安全，因为再发生一次的概率相比之前已经小得多了”。文献^[114]的作者在报刊上驳斥了总经理的这个说法。实际上，这位机场经理犯的错误是相当普遍的；这里我们卖个关子，请读者思考经理所犯是何错误。另一方面，在实际生活中，如果告诉你连续投掷一枚均匀材质的正常的硬币 9 次都获得了正面朝上的结果后，很多人会认为下一次获得反面的概率会更大些，这是我们将在第十二章中讨论的赌徒谬误。

上述论述中，人们普遍混淆了两个概念：一个事件（或现象）发生两次（一个复合事件！）的概率与一个事件（或现象）再次发生的（条件）概率。需要警惕的是，对于后者，在自然语言中人们经常并不会特意在“概率”一词前面加上“条件”的前缀。但是很显然，当我们在 A 事件（比如坠机）发生后谈论“A 事件再次发生的概率”时，实际讨论的正是条件概率。一旦明白这一点，我们就能很自然地理解关于投掷均匀硬币的下述说法：“即使你已经连续扔九次硬币都是正面朝上，你下一次扔硬币得到正面朝上的概率跟它朝下的概率还是一样的”²。

注 3.1. 在理解概率的问题上产生的谬误有时会造成严重后果。此处案例来自文献^[114]，见其中第 20–21 页。1999 年，英国陪审团判决 Sally Clark（萨利·克拉克）谋杀了她自己的两个孩子，她因此被监禁三年，直至该判决被推翻；这两个孩子分别在出生后 8 周和 11 周时猝死。一位儿科医生以专家证人的身份出席庭审时说，一个家庭中有两名婴儿死于猝死综合征的概率只有 $1/73000000$ ；该案中除此之外再无任何谋杀的人证物证，也不存在杀人动机。唯一的可能是陪审团被这个极低的概率说服了。但这个概率是怎样得到的呢？数据显示，在 8500 个像萨利一样的家庭中就会有一例婴儿猝死，因此通过简单计算得出同一个家庭中两名婴儿猝死的概率就是 $(\frac{1}{8500})^2 \approx \frac{1}{73000000}$ 。显然上述计算的前提假设是同一个家庭中前后两次婴儿猝死事件是独立的；但这一假设是存疑的，一个即使没有医学背景的现代人也会自然地想到其中存在基因方面的问题。事实

¹本节的论述较大比例地借鉴了文献^[114]第 15–16 页中论述。

²此处假设你认可硬币是均匀的假定。更多、更深入的讨论读者可以参见第十二章内容。

上,有统计显示:如果有一名婴儿猝死,那么这个家庭中的其他婴儿猝死的风险更大,高达 $1/100$ 。当然,即使更准确的计算,萨利的家庭中有两名婴儿猝死的概率也仅有 $1/850000$, 仍然是很小的概率。但要注意,萨利的第一名猝死的婴儿已经被证明是自然原因死亡,没有谋杀的嫌疑。那么在没有谋杀嫌疑的前提下,再次有婴儿猝死的(条件)概率就是 $1/100$ (而不是 $1/8500$)。如果这一(条件)概率值提交给陪审团,或许萨利就不需要遭受牢狱之灾了。随着萨利案被推翻,这个庭审中出席作证的儿科医学专家也被判严重渎职罪。

3.4.2 小概率原理及现实世界与概率(统计)建模之间的接口

英国统计学家 Karl Pearson (皮尔逊, 1857—1936) 说,“概率是数学中最具争议的一部分,但是它是最有用的。”为了让概率论(及统计学)有用,我们需要解决现实世界与概率(统计)建模之间的接口问题,即入口与出口问题。

在 Littlewood “无穷”悖论问题(例3.7)的解答中,我们认为零概率事件(几乎不可能事件)在实际生活中是不会发生的,更不会重复发生;如果某事件在现实中真真切切地发生了,而按照我们的概率建模该事件是零概率事件,毫无疑问我们应该首先质疑概率建模的正确性,进而设法修正有关模型。

进一步,人们在长期的实践中总结出如下的小概率(事件)原理¹: 概率很小的事件在单次随机试验中实际上几乎不会发生,而在(有限)重复试验中发生的频率极低。但现实生活中,针对不同类型的随机事件,多小的概率可以认为是可忽略的,目前并没有发展出一个统一而客观的准则来确定²。通常,概率值在千分之一或万分之一的级别也可以作为可忽略的参考值;而在很多统计问题(比如假设检验问题)中,5%就可以作为一个可忽略的概率值。

反过来,如果在一个随机试验中有多种(互斥)现象 $A_1, \dots, A_n$ 都可能发生,而在单次随机试验中发生了现象 A_i ,则认为该现象 A_i 应该是所有这些现象 $\{A_i\}_{i=1}^n$ 中发生概率最大者,这被称为极大似然原理;某事件 A 在单次随机试验中真实发生了,而我们的概率建模如果带有未知的参数,则该参数在实际应用中应当认为是使得事件 A 发生的概率达到最大的那个参数值,这种估计方法被称为极大似然估计(方法);相应估计值/量也称为极大似然估计(量)。在本讲义中,极大似然估计的具体案例参见第五章的例5.12、例5.13及第八章的例8.17。

现在我们基于小概率原理来给出现实世界与概率(统计)建模之间的接口问题的相关讨论。

¹小概率(事件)原理在有些文献^[62]中也被称为 Cournot's principle; 参见文献^[90]中论述。

²Borel 认为,小概率是可以忽略的: 10^{-6} 级别的概率值是“human scale”, 10^{-15} 级别的概率值是“terrestrial scale”, 10^{-50} 级别的概率值是“cosmic scale”; 参见文献^[90]中论述。

事实上，现实世界与概率（统计）建模之间的入口问题，包含了翻译与数据输入两方面的问题：其一是如何把（模糊的）自然语言描述的现实生活问题翻译为严谨的概率（统计）语言描述的数学问题，其二是如何把现实生活中收集的数据转化为概率（统计）建模中需要的数据格式问题。这里我们只讨论第一个问题，而这在我们介绍使用集合论的语言进行概率建模的第二章中已有较系统的介绍与论述，在后续章节中将介绍的“数学期望”与“条件数学期望”这两个概率术语也分别对应于生活中自然语言描述的某个量的“平均”与“条件平均”。这里唯一需要补充的是，在统计学中经常会考虑假设检验的问题，特别是所谓的独立性检验的问题。该问题在概率统计的解答层面基于的原理实际上是第十二章中的 Pearson 定理，但在现实生活中“两个事件（或两个随机变量）相互独立”通常表述为“两个因素（之间）无关（或没有关系）”。

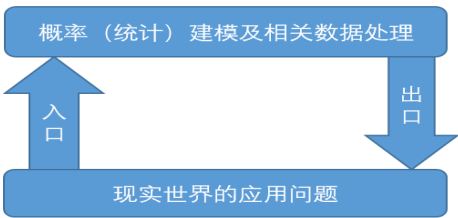


图 3.9: 现实世界与概率（统计）建模之间的接口

而现实世界与概率（统计）建模之间的出口问题，同样包含了数据输出和解释两方面的问题。其中，数据输出是指基于概率（统计）建模给出数学问题的解答；而解释则是基于严谨的概率（统计）解答返回到现实生活问题中作出相应的自然语言的解释。此处我们只讨论后一问题。其中部分自然语言解释可以在现实世界与概率（统计）建模之间的入口问题中找到答案，但有部分自然语言解释需要了解更深层的逻辑。我们以统计学中的假设检验为例来进行说明。为此我们需要介绍自然语言表述的形式逻辑与概率语言表述的命题之间一种自然的对应关系。

自然语言中某类事物的性质，在数学中也经常用集合来表达，集合 A 就代表了某性质 A ；而在概率统计中，集合 A 又可代表随机事件 A 或随机现象 A 。自然语言的关于某默认事物的论断“性质 A 蕴含了性质 B ”经常表述为如下数学形式语言表述的命题：

$$A \implies B.$$

上述命题作为逻辑演绎（logical deduction）来理解时，它包含两个在逻辑上被认为是等价的¹强三段论（strong syllogism）：

- （1） A 是真的，而 $A \implies B$ 成立，所以 B 也是真的，
- （2） B 是假的，而 $A \implies B$ 成立，所以 A 也是假的。

其中（2）的推理在实际应用中被称为反证法。

¹这需要承认排中律成立，而排中律在数学中一般而言总是默认成立的。

当上述 A, B 理解为集合（以及随机事件）时，推理 $A \implies B$ 也可表述为 $A \subset B$ （或稍弱的表达： $\mathbb{P}(B|A) = 1$ ）。因此，在概率论中，如果 A, B 理解为随机现象或随机事件，上述两个强三段论也可相应表述为如下两个“逻辑链”：

(1') A 发生了，并且 $\mathbb{P}(B|A) = 1$ ，从而认为 B 在现实中必定（会）发生，

(2') B 不发生，并且 $\mathbb{P}(B|A) = 1$ ，从而认为 A 在现实中必定不（会）发生。

但在真正的现实生活中，能完全应用上述严格推理的场景还是很稀少的。在具体的随机现象的问题中，我们可以设定一个被认可的小概率值 $\alpha \in (0, 1)$ ，并依据小概率原理，仿照上述推理，得到如下形式的“推理”：

(1'') A 发生了，并且 $\mathbb{P}(B|A) \geq 1 - \alpha$ ，从而认为 B 在现实中有较大“把握”（会）发生，

(2'') B 不发生，并且 $\mathbb{P}(B|A) \geq 1 - \alpha$ ，从而认为 A 在现实中有较大“把握”不（会）发生。

此时，推理 (1'') 是完全依据小概率原理的普通推理；推理 (2'') 则是一个类似反证法的**合情推理** (plausible deduction)¹，从而推理下的结论通常具有不错的可信度。此二者犯错误的概率通常也不相同：推理 (1'') 中判断“ B 在现实中（会）发生”犯错误的概率恰为 $\mathbb{P}(B^c|A) \leq \alpha$ ；而推理 (2'') 中判断“ A 在现实中不（会）发生”犯错误的概率实际为 $\mathbb{P}(A|B^c)$ ，一般而言 $\mathbb{P}(A|B^c) \neq \mathbb{P}(B^c|A)$ 。因此 (1'')、(2'') 通常是不等价的。此外，文献^[57]中还介绍了另一种合情推理，结合小概率原理我们表述如下：

(3'') B 发生了，并且 $\mathbb{P}(B|A) \geq 1 - \alpha$ ，从而认为 A 在现实中有较大“把握”（会）发生。

显然，如果上面表述 (3'') 中 $B = \Omega$ ，则 A 可以为概率空间中任意正概率的随机事件！也就是说，上述合情推理的可信度其实不太高，因而在现实中要注意适当限制其使用范围（比如仅限于科学探索中用于发现线索而不是逻辑或因果论证的用途）。

有时我们也突破 A 是一个随机事件的要求，特别是在假设检验的场景， A 可以是某零假设 H_0 ，从而通过考察对应的所谓**拒绝域** W （对应 $B = W^c$ ）是否发生及其发生概率 $\mathbb{P}(W|H_0)$ 大小来判定是否我们应该在实际问题中采信零假设 H_0 。我们通常假设 $\mathbb{P}(W|H_0) = \alpha$ 是一个临界的概率值 α （比如 $\alpha \approx 0.05$ ， α 也称为**显著性水平**），有以下两种情形发生：

(i) **随机现象 W 发生了**。这时我们采用类似反证法的合情推理 (2'')：

W 发生了，并且 $\mathbb{P}(W|H_0) = \alpha$ ，从而认为 H_0 不成立。

¹ 合情推理最早起源于 George Pólya（波利亚，1887—1985；美籍匈牙利裔）关于推理模式的研究。文献^[57]中讨论了更多形式的合情推理；但需要注意，其中记录的有些合情推理具有较糟糕的可信度，在现实生活中我们不建议使用，仅推荐作为科学研究的启发式思维链条（而不是真正严谨的逻辑推理链条）使用。

这意味着在零假设 H_0 成立时我们将以不可忽略的概率 α 找到了“反例” $\omega \in W$ ，因此我们将冒着犯较小概率的第一类错误¹来拒绝零假设 H_0 ；同样要注意，“依据 W 发生而拒绝零假设 H_0 ”的实际把握（或概率）可以形式地记为 $\mathbb{P}(H_0^c|W) = 1 - \mathbb{P}(H_0|W)$ ，这一概率值通常即使是在 Bayes 假设检验的模型中也不容易算出，特别是一般而言 $\mathbb{P}(H_0|W) \neq \mathbb{P}(W|H_0)$ 。因此，我们通常说此时“在 α 的显著性水平下，假设检验的结果拒绝零假设 H_0 ”。在 α 比较小时，通常认为此处合情推理的结论具有较高的可信度；

(ii) 随机现象 W 没有发生。这时我们采用如下可信度稍差的合情推理（3''）：

$$W \text{ 不发生, 并且 } \mathbb{P}(W|H_0) = \alpha, \text{ 从而认为 } H_0 \text{ 成立.}$$

这个合情推理的可信度稍差的原因在于，“ W 不发生，且 $\mathbb{P}(W|H_0) = \alpha$ ”的事实只说明了：我们通过（大样本的）随机试验没能找到随机现象 W 这种类型的“反例”，不代表它一定没有其他类型的反例。因此我们通常说此时“在 α 的显著性水平下，假设检验的结果不拒绝零假设 H_0 ，从而接受零假设 H_0 ”。需要注意的是，此时接受零假设是有可能犯不小概率的第二类错误的²；而“依据 W 不发生而接受零假设 H_0 ”的实际把握（或概率）可以形式地记为 $\mathbb{P}(H_0|W^c)$ ，这一概率值通常也不容易算出，特别是一般而言 $\mathbb{P}(H_0|W^c) \neq \mathbb{P}(W^c|H_0)$ 。

在早期的概率统计教科书中，情形 (i) 发生，相应统计推断就表述为“以 $1 - \alpha$ 的把握拒绝零假设 H_0 ”；情形 (ii) 发生，相应统计推断就表述为“以 $1 - \alpha$ 的把握不拒绝/接受零假设 H_0 ”。但由于自然语言中，“把握”一词视作“概率”的同义词，上述表述容易分别误解为“ $\mathbb{P}(H_0^c|W) \geq 1 - \alpha$ ”和“ $\mathbb{P}(H_0|W^c) \geq 1 - \alpha$ ”；一般而言，这是显然错误的。因此，在现代统计学中，通常把以上论述中的“以 $1 - \alpha$ 的把握”修改为“在 α 的显著性水平下”，按照这一“技术规范”来表述统计推断。

例 3.25.³ 某接待站在某一周曾接待过 12 次来访；已知所有这 12 次接待都是在周二和周四进行的。问：是否能推断接待时间是有规定的？

¹第一类错误是零假设 H_0 成立的条件下，“由于试验数据落入拒绝域 W 而作出拒绝 H_0 的统计推断”导致的第一种推断错误——**弃真**；它的发生概率是 $\mathbb{P}(W|H_0)$ ，相当于医学诊断问题中的假阳性率。

²第二类错误是零假设 H_0 不成立的条件下，“由于试验数据没有落入拒绝域 W 而作出接受 H_0 的统计推断”导致的第二种推断错误——**采伪**；它的发生概率是 $\mathbb{P}(W^c|H_0^c)$ ，相当于医学诊断问题中的假阴性率。

³本例来源于文献^[115]，见其中的例 1.3.8.

参考解答： 假设接待站的接待时间没有规定，且来访之间是相互独立的，从而诸次来访是等可能性地发生在一周的任何一天。于是，12 次接待来访都发生在周二或周四的概率为

$$\left(\frac{2}{7}\right)^{12} \approx 2.959 \times 10^{-7}.$$

这是一个非常小的概率，但这一小概率的事件在单次的（复杂）随机试验中竟然发生了，根据小概率事件原理有理由怀疑假设的正确性，从而推断接待站不是每天都接待来访者，即认为其接待时间是有规定的。

另一种理解上述结论的做法是，考虑 12 次访问集中发生在一周的某两天（但不明确是哪两天）的概率，这个概率是

$$C_7^2 \cdot \left(\frac{2}{7}\right)^{12} \approx 6.2145 \times 10^{-6},$$

仍然是一个很小的概率。这同样导出上面的推断。 $\square$

例 3.26.¹ 某饮料公司推出一项“再来一瓶”的推销活动，宣称顾客每买一瓶该公司的饮料就有 5% 的机会可以免费再获得一瓶。现有某人买了该公司的 20 瓶饮料，但未中奖，于是他跟朋友们说该公司有欺诈消费者的行为。你认为他的话有道理吗？如果饮料公司宣称中奖率为 25%，情况又将如何？

参考解答： 用 A_k 表示顾客买的第 k 瓶饮料中奖这一事件。我们认为 $\{A_k\}_{k=1}^{20}$ 相互独立，在中奖率为 5% 时，计算得到顾客连续买 20 瓶而未中奖的概率为

$$\mathbb{P}\left(\left(\bigcup_{k=1}^{20} A_k\right)^c\right) = \prod_{k=1}^{20} [1 - \mathbb{P}(A_k)] = 0.95^{20} \approx 0.3585,$$

这是一个不小的概率，由此我们没有充足的理由认为饮料公司有欺诈消费者的行为。

当中奖率为 25% 时，上述概率重新计算为

$$\mathbb{P}\left(\left(\bigcup_{k=1}^{20} A_k\right)^c\right) = \prod_{k=1}^{20} [1 - \mathbb{P}(A_k)] = 0.75^{20} \approx 0.00317,$$

这时我们有较充足理由认为饮料公司有欺诈消费者的行为，至少可以怀疑该公司并没有把有奖饮料充分均匀地分布到所销售的饮料产品中。 $\square$

下面的例子表明，发生概率极小的事件/现象在大量的重复试验中会变成近乎必然事件。这对人口密集城市提出了安全出行、安全生产等方面高水平管理的需求。

¹ 本例来源于文献^[118]，见其中的例 2.5.13，略有改动。

例 3.27.¹ 春节燃放烟花爆竹是我国延续了一千多年的传统风俗，早已成为我国历史文化的一部分。但燃放烟花爆竹也常常引发意外，造成惨剧。假设每次燃放烟花爆竹引发火灾的概率是十万分之一。如果春节期间上海有 100 万人次燃放烟火爆竹，请问全市没有因此引发火警的概率是多少？

参考解答： 取 $n = 10^6$, $A_j =$ 第 j 次燃放烟花爆竹没有引发火警，其中 $1 \leq j \leq n$. 于是春节期间全市没有因 n 人次燃放烟花爆竹而引起火灾这一事件为

$$B := \bigcap_{j=1}^n A_j.$$

此处应认为 $\{A_j\}_{j=1}^n$ 相互独立。按题目中约定， $\mathbb{P}(A_j) = 1 - 10^{-5}$. 于是

$$\mathbb{P}(B) = (1 - 10^{-5})^n = (1 - 10^{-5})^{10^6} \approx 4.54 \times 10^{-5}.$$

也就是说，几乎不太可能不引发火警。 $\square$

最后，我们再次提醒读者：当你计算出某随机事件发生的概率极低时，并不代表它在现实世界中一定不会发生；当你计算出某随机事件发生的概率极高时，也不代表它在现实世界中一定会发生。这方面，B 站视频《概率知多少》中提供了很多案例。

📌 笔记 3.4. 有些文献区分主观概率和客观概率。通常认为，客观概率反映了事物的客观属性，它不因决策者的因素不同而不同，即与决策者的个别解释无关；客观概率的一个重要特点是通过大量重复试验，或在有限集合中事件中的个体数量与总体比例来定义概率。但是，并不是所有事件都能做重复试验（或者做重复试验的代价巨大）；在实际管理活动中，又往往要求人们对这些事件的可能性进行估计，并根据估计的可能性进行决策。这种要求就导致了主观概率概念的形成与应用。*L. J. Savage*（萨维局）认为，主观概率（*subjective probability*）或个人概率（*personal probability*）是一种见解，是合理信念的测度；这是某人对特定事件发生的可能性的信念（或意见、看法）的度量，即他认为的事件发生的可能性。主观概率反映事物的主观属性，它的确定允许与决策者的主观个别解释有关，它是由决策者的经验知识以及对客观情况的了解，利用相关信息进行分析、推理、综合判断而设定的，不是主观臆测。主观概率和客观概率的定义反映了哲学上的两种不同的观点：即主观概率论主义（贝叶斯主义）和客观概率论主义（非贝叶斯主义）。客观概率论主义者认为，概率是系统的固有的客观性质，是在相同条件下重复试验时频率的极限；通常也称客观概率论主义者频率学派。

在编者看来，这种区分的意义不大，无非是有些情况下大家有共同的认知（比如投掷均匀硬币，正面向上的概率与反面向上的概率是均等的），而另一些情况下大家的认知差别巨大，从而本质上我们每一个认知主体所说的概率都是条件概率。在随机的世界里，我们对事物的看法、观点通常都是基于已经发生的事件、已经获得的信息。编者认为，这一定程度上可解释为已介绍的经典的条件概率 $\mathbb{P}(\cdot|A)$ 以及后续将介绍的更一般的条件概率 $\mathbb{P}(\cdot|G)$. 也就是说，每个逻辑自洽的理性人的概率空间实际上都是非常个性化的，是某个共有的概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 关于其个性化的子 σ -代数 G （代表他物理上已经获得，且心理上接受的信息）的条件概率空间；而很多时候理性人所做的判断或决策通常是基于其个性化的条件概率测度结合极大似然原理或 *Bayes* 思想等公认的原则。由于信息上的不对称，现实生活中在很多问题上人们意见经常相左，甚至发生冲突。这也是为什么加强信息交流、传播以消除认知偏差和刻板印象而获得更多共识在现代社会中越来越重要。

¹ 本例来源于何书元老师的《概率论》PPT 资料（或他编撰的教材^[109]），略有改动。

3.5 本章小结与学习建议

本章是全书“概率建模”理念第一次真正落实的章节。编者首先基于古典概率模型中条件概率的直观，在一般的公理化概率模型中引入了条件概率的概念；之后我们通过考虑同时使用两种不同的赌博道具的复杂赌博的概率建模问题，引入了乘积概率空间的技术，继而介绍了事件独立性的概念及其与条件概率的关系；作为经典条件概率和事件独立性的应用，我们介绍了乘法公式、全概率公式和 Bayes 公式，并基于乘积概率空间的技术介绍了重复试验和条件试验。这样一种介绍条件概率和事件独立性的方式应当说是新颖的，但又是自然而合乎公理化概率论的内在逻辑的；同时，这样的处理也有利于初学者借助生活中形成的“事件无关性”的直观来理解概率论中的重要概念“事件独立性”。

编者对初学者在学习本章时的建议是：关于古典概率模型的乘积概率空间部分应当熟练掌握；但在一般的概率空间的乘积空间（与无穷乘积空间）的定义过程中，对乘积 σ -代数的定义略作了解即可，而乘积概率测度的存在唯一性问题则可直接默认相关理论结果。这些更深入的理论可以留待后续课程中进行学习；这也是过往的概率论教学体系的常规做法一本讲义只不过明确点出了这些技术性“深坑”的位置，并提供相关论述与参考文献，便于初学者后续在有必要且有时间的前提下进行更有针对性的学习。在第3.4节中，我们介绍了小概率原理和极大似然原理，并借用概率论的框架介绍了在日常生活中我们经常使用的合情推理，为帮助初学者理解和应用后续概率统计课程中的假设检验和统计推断理论提供了一个总纲性的框架，对此不感兴趣的初学者亦可跳过此部分的论述，这并不影响后续章节的学习。

习 题 3

习题 3.1. 设 $|\Omega_k| < \infty, \mathcal{F}_k = 2^{\Omega_k}, k = 1, 2$, 求证: $\mathcal{F}_1 \otimes \mathcal{F}_2 = 2^{\Omega_1 \times \Omega_2}$.

习题 3.2. 借用习题2.27中定义的几乎互斥概念，进一步定义几乎完备事件组概念如下：如果 $\{A_n\}_{n=1}^N \subset \mathcal{F}$ 是几乎互斥的事件列，并且 $\bigcup_{n=1}^N A_n$ 是几乎必然事件，则称 $\{A_n\}_{n=1}^N$ 是几乎完备事件组；如果 $\mathbb{P}(B \setminus \bigcup_{n=1}^N A_n) = 0$ ，则称几乎互斥事件列 $\{A_n\}_{n=1}^N$ 是 B -几乎完备事件组。请证明：对于 B -几乎完备事件组 $\{A_n\}_{n=1}^N$ ，全概率公式和 Bayes 公式都成立。

习题 3.3. 三门问题中，在你随机选定一门后，如果主持人等概率地打开其他两门之一，请问主持人打开的门对应于山羊的概率？

习题 3.4. 试用其他方法（如全概率公式）给出例3.5的解答。

习题 3.5. 设 $x_n \in [0, 1], \forall n \geq 1$. 证明¹:

$$(1.a) \quad \sum_{n=1}^{\infty} x_n = \infty \Rightarrow \prod_{n=1}^{\infty} (1 - x_n) = 0;$$

(1.b) 如果 $\exists \delta \in (0, 1), x_n \in [0, 1 - \delta], \forall n \geq 1$, 那么

$$\sum_{n=1}^{\infty} x_n = \infty \Leftrightarrow \prod_{n=1}^{\infty} (1 - x_n) = 0;$$

$$(2.a) \quad \sum_{n=2}^{\infty} \mathbb{P}(E_n^c | \bigcap_{k=1}^{n-1} E_k) = \infty \Rightarrow \mathbb{P}(\bigcup_{k=1}^{\infty} E_k^c) = 1;$$

(2.b) 如果 $\exists \delta \in (0, 1), \mathbb{P}(E_n | \bigcap_{k=1}^{n-1} E_k) \geq \delta, \forall n \geq 1$, 那么

$$\sum_{n=2}^{\infty} \mathbb{P}(E_n^c | \bigcap_{k=1}^{n-1} E_k) = \infty \Leftrightarrow \mathbb{P}(\bigcup_{k=1}^{\infty} E_k^c) = 1.$$

习题 3.6. 设 $\mathbb{P}(A) > 0$, 证明: $\mathbb{P}(A \cap B | A \cup B) \leq \mathbb{P}(B | A) \leq \mathbb{P}(B | A \cup B)$.

习题 3.7. 证明: 当 $\mathbb{P}(B | E) > \mathbb{P}(C | E), \forall E \in \{A, A^c\}$ 时, $\mathbb{P}(B) > \mathbb{P}(C)$.

习题 3.8. 设 E, H, G 均为正概率事件. 证明: $\frac{\mathbb{P}(H | E)}{\mathbb{P}(G | E)} = \frac{\mathbb{P}(H)}{\mathbb{P}(G)} \cdot \frac{\mathbb{P}(E | H)}{\mathbb{P}(E | G)}$. 假如在得到“新的证据” E 前, 假设 H 成立的可能性是假设 G 成立的可能性的 3 倍; 而当假设 G 成立时“新的证据” E 出现的可能性是假设 H 成立时的 2 倍. 请问: 当“新证据” E 出现时, 哪种假设更可能成立?

习题 3.9. 某城市 A, B 型出租车各占 85%、15%; 它们颜色相同, 大小略有细微差别; 假定每辆车肇事概率相同. 在一次出租车交通肇事逃逸案中, 某证人指证 B 型车肇事. 警方在肇事地点和相似能见度条件下对证人的甄别能力进行检测, 发现证人识别 A, B 型车的准确率分别为 90%、80%. 如果证人没有撒谎, 请问案件中 B 型车的肇事概率?

习题 3.10. 设概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 中有三个事件 A, B, C 两两独立, 但不相互独立. 并且 A, B, C 三个事件发生的概率都是 p . 如果这三个事件不可能同时发生, 求 p 的取值范围.

¹ 据说本习题的结论 (2.a) 是 Borel 在研究正规数的过程中提出的, 某种程度上它是后来才发展的 Borel-Cantelli 第二引理 (见第十章) 的雏形.

习题 3.11. 试构造一个概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$, 其中有三个事件 A, B, C 两两独立, 但不相互独立。

习题 3.12. 设事件 A, B 相互独立, 且事件 A 发生、 B 不发生的概率与事件 B 发生、 A 不发生的概率都是 $1/4$. 求 $\mathbb{P}(A)$ 和 $\mathbb{P}(B)$.

习题 3.13. 如果 A 是几乎必然事件或几乎不可能事件, 就称事件 A 是平凡的。设事件 A 与其他任何事件都相互独立, 则 A 是平凡的。

习题 3.14. 设 $\mathbb{P}(A) \in (0, 1)$, 则 $\mathbb{P}(B|A) = \mathbb{P}(B|A^c)$ 等价于 A, B 相互独立。

习题 3.15. A, B 相互独立, 且 $\mathbb{P}(A) + \mathbb{P}(B) = 1$. 求 $\mathbb{P}(A \Delta B | A \cup B)$ 的范围。

习题 3.16. 设 $\{A_n\}_{n=1}^N$ 是互斥事件列, 且 A_n 与 B 相互独立, $n = 1, \dots, N$, 那么 $\sigma(\{A_n : 1 \leq n \leq N\})$ 与 B 相互独立。

习题 3.17. 四个人分配两张演唱会的票, 每人至多一张。有人提出如下分配规则: 第一个人投掷一枚(均匀)硬币一次, 掷得正面则拿走一张票; 接下来的每个人也类似操作, 直至所有票分配完; 如果最后还有票没有分配完, 则未掷得正面的倒数几个人获得剩余的票。请问这个分配规则公平吗?

习题 3.18. 假设甲乙丙三人需要等概率地分配一张电影票的所有权, 手边有一枚均匀的硬币。如何设计分配方案以做到公平合理。

习题 3.19. (赌徒破产模型) 设甲乙赌徒进行公平的赌博(即二人单局获胜概率相同; 假定没有平局). 开局初甲乙两人筹码数量分别为 a, b , 每局的输家向赢家支付一个筹码, 某方输光筹码则赌局结束。试求甲在这场赌博中的获胜概率, 并说明当 $a/b \rightarrow 0$ 时甲赌徒输光的概率趋于 1 。

习题 3.20. 在圆周上随机选三个点, 求它们组成的三角形包含圆心的概率。

习题 3.21. 在正方形的四条边上随机选三个点, 求它们能形成三角形概率。

习题 3.22. 设 A_1, A_2 互斥, $A_1 \cup A_2 \subset A$. 仿照例 3.22 说明, 在 A -重复试验中现象 A_1 先于现象 A_2 发生的概率是 $\frac{\mathbb{P}(A_1)}{\mathbb{P}(A_1) + \mathbb{P}(A_2)} = \mathbb{P}(A_1 | A_1 \cup A_2)$.

习题 3.23. Huygens 在他的《论赌博中的计算》的小书中叙述并解答了 14 个概率问题, 其中最后一个问题如下。设甲、乙轮流投掷两枚骰子进行赌博, 约定: 如果甲在乙掷出 7 点之前掷出了 6 点, 则甲胜; 若乙在甲掷出 6 点之前掷出 7 点, 则乙胜; 二人约定甲先掷。请问甲、乙的胜率各几何?

习题 3.24. 某电路是由 A 、 B 元件并联之后再与 C 元件串联而成。其中元件 A 、 B 、 C 损坏（所谓损坏就是元件被烧坏而导致电路断开）的概率分别是 $0.2, 0.2, 0.3$ 。请问这个电路失效（即整体电路无法通电）的概率。

习题 3.25. 用一种新检测方法检测某疾病，有 5% 的概率把健康人判定患病， 100% 的概率检测出患病人群。设该疾病的人群发病率为 10^{-4} 。(1) 普查时某人检测患病，问他确实患病的概率？(2) 若他复查后还是判定患病，请问他确实患病的概率？

习题 3.26. 设甲投掷 $n+1$ 枚均匀硬币，乙投掷 n 枚均匀硬币。证明：甲得到的正面朝上数大于乙得到的正面朝上数的概率为 $1/2$ 。

习题 3.27. 设矩阵 $A = \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix}$ 中诸元素 a_{ij} 等可能性地只取 $0, 1$ 值。在 $\text{tr}(A) > 0$ 的条件下求矩阵 A 可逆的概率。

习题 3.28. 某人编写了一个带有部分记忆功能的模拟投掷硬币的计算机应用程序，它的运行规律如下：首次模拟投掷，得到“硬币正面”的概率为 $c \in (0, 1)$ ；之后，每次模拟投掷，有 $p \in (0, 1)$ 的概率得到与上次模拟投掷相同的结果。求第 n 次模拟投掷时，获得“硬币正面”的概率。当 $n \rightarrow \infty$ 时，这个概率的极限是什么？

习题 3.29. 某家庭恰有三个小孩；并且已知其中有男孩。在男女孩出生概率相等的假定下，该家庭至少有一个女孩的概率是多少？

习题 3.30. 某大型社区养宠物的调查统计结果如下： 36% 的家庭养了狗， 22% 的家庭既养狗又养猫， 30% 的家庭养了猫。随机选择一个家庭，在已知该家庭养了猫的条件下，还养了狗的条件概率是多少？

习题 3.31. 有三个外观无法区分的坛子 A, B, C （标签在坛底）， A 坛子装有两个红球， B 坛子装有两个蓝球， C 坛子装有一个红球一个蓝球，这些球除了颜色之外也是同样材质、无法区分的。已知某人从某个坛子中摸出了一个红球，请问该坛子中另一球也是红球的概率是多少？

习题 3.32. 投掷三枚分别是蓝、红色、黄的骰子（六面同色），记 B, R, Y 为它们对应的点数。我们感兴趣的是 $\mathbb{P}(B < R < Y)$ 。

(a) 这三枚骰子点数都不同的概率是多大？

(b) 在这三枚骰子点数都不同的条件下， $B < R < Y$ 的概率是多大？

(c) 求 $\mathbb{P}(B < R < Y)$ 。

习题 3.33. 沃比冈湖是 *Garrison Keillor* 写的一篇小说的名称，也是一个地名；这个地区的家长都认为自己的小孩是天才，要超过平均水平。*Donald Knuth* 教授提供了本习题，并称之为沃比冈湖的骰子 (*Lake Wobegon Dice*) 来数学上解释一些类似的反直觉现象在理论上的可能性¹。假设有三枚特殊的骰子，分别记作 A_1 、 A_2 、 A_3 ，其中 A_2 、 A_3 是两枚相同的骰子，它们六面的点数情况如下：

骰子 A_1 : 3, 3, 3, 3, 3, 5; 骰子 A_2 、 A_3 : 1, 1, 4, 4, 4, 4.

投掷诸骰子 A_i 所得的点数仍对应记作 A_i ，并记 $\bar{A} := \frac{A_1 + A_2 + A_3}{3}$. 请证明：

$$\mathbb{P}(A_i > \bar{A}) > 1/2, i = 1, 2, 3.$$

习题 3.34. 甲乙进行某项比赛。单局比赛结果没有平局，而甲获胜的概率是 $p \in (0, 1)$ ；胜者得 1 分，负者不得分也不扣分。二人约定：当某人累计多出另一人 2 分时停止比赛，分数多的人赢得比赛。请问甲赢得比赛的概率是多少？

习题 3.35. 包括甲、乙二人在内的 2^n 名乒乓球运动员（假定他们实力相当）参加某个赛事。赛事的规则如下：第一轮时运动员们随机两两配对比赛，该轮比赛的失败者全部淘汰；之后上一轮的胜利者再两两随机配对进行下一轮比赛，总是淘汰比赛的失败者，直至通过这种模式的淘汰赛决出赛事的冠、亚军。请问：在这个赛事中，甲、乙能在比赛中相遇的概率？

习题 3.36. 某车间有两台机床加工同样的零件。第一台生产的次品率为 0.03，第二台生产的次品率为 0.02；加工的零件混合在一起。现在已知第一台加工的零件数是第二台的 2 倍。

(1) 求随意抽检一个零件，发现它是合格品的概率；

(2) 如果抽检的这个零件是次品，请问它是第二台机床生产的概率。

习题 3.37. 人类 ABO 血型的基因型有六种，分别为 AA 、 BB 、 AO 、 BO 、 AB 、 OO 。ABO 血型系统的遗传是由 9 号染色体上的 A 、 B 、 O 三个等位基因来控制的，其中 A 基因、 B 基因是显性的， O 基因是隐性的。也就是说如果 A 和 O 基因同时存在那么表现出来就是 A 型； B 和 O 基因同时存在，那表现出来就是 B 型； A 和 B 基因同时存在表现出来就是 AB 型，两条染色体上都是 O 基因表现出来就是 O 型。据统计，中国人中四大常见血型 O 、 A 、 B 、 AB 中占比大致为 41%、28%、24%、7%。请问，能否推断中国人中的六种基因型大致比例？假定每年总人口的死亡率和出生率分别为 0.70% 和 1.1%，并且假定出生人口的父母总

¹ 参见 <https://www.johndcook.com/blog/2021/08/16/lake-wobegon-dice/>.

是中国人(不考虑人口的输入、输出), 则 100 年后中国人中这四大常见血型比例会演变为多少?

习题 3.38. 某人有 5 把钥匙, 但忘记哪把是房门钥匙, 因此逐一试开。当其中只有一把房门钥匙时, 问:

(1) 恰好第三次打开房门锁的概率是多少?

(2) 三次内打开房门的概率是多少?

当其中恰有两把钥匙是房门钥匙时, 问:

(3) 三次内打开房门的概率是多少?

习题 3.39. 有 $n+1$ 个袋子, 其中第 i 个袋子中有 i 个红球、 $n-i$ 个黑球, $i=0, 1, \dots, n$. 每次取球时, 总是从这 $n+1$ 个袋子中随机挑选一个袋子, 然后从所选袋子中随机抓取一球, 记录好颜色之后又放回原袋中。请问第一次取球获得红球的概率是多少? 如果在第一次取球获得红球的条件下, 第二次直接从刚刚获得红球的袋中摸一个球, 此时摸得红球的概率是多少?

习题 3.40. 有两个口袋, 甲口袋中有 3 个红球、2 个黑球, 乙口袋中有 2 个红球、3 个黑球。现在通过抛掷一枚均匀硬币来决定取球的口袋。如果硬币正面朝上就选甲口袋, 否则选乙口袋。假定只取一球, 记录好颜色后再放回原口袋。已知第一次取球取到的是黑球。请问:

(1) 第一次所取球是来自甲口袋的概率?

(2) 如果我们接着从第一次取球的口袋中直接取球, 那么这次获得黑球的概率是多少?

习题 3.41. 生活中我们经常使用“石头-剪刀-布”的手势游戏, 俗称“划拳”, 用于决出两人中的输家、赢家; 其中拳头代表“石头”, 两个手指岔开成剪刀状代表“剪刀”, 巴掌代表“布”, “石头”克制“剪刀”, “剪刀”克制“布”, “布”克制“石头”。在划拳过程中, 如果两人手势相同则继续进行该游戏, 直至决出最终的输家、赢家。请证明: 二人通过“石头-剪刀-布”的手势游戏方式决出输家、赢家是公平的, 即二人等概率可以成为输家或赢家。

习题 3.42. 孩子们在玩捉迷藏游戏时, 为了选出唯一的“蒙眼人”, 仍然可以使用“石头-剪刀-布”的手势游戏以决出唯一的输家。现在假设有多人为进行捉迷藏游戏而来玩“石头-剪刀-布”, 每轮大家都独立地选择三种手势之一。如果只出现了两种手势, 且被克制手势的玩家是唯一的, 则该玩家就是最终的唯一

输家；否则所有被克制手势的玩家进行下一轮“石头-剪刀-布”游戏直至决出唯一输家；如果大家手势相同，或三种手势都出现了，则认为是平局，需要重新进行“石头-剪刀-布”游戏。请问：3人的“石头-剪刀-布”游戏三轮之内能决出唯一输家的概率有多大？

习题 3.43. 在三个人游戏时，孩子们还时常使用“黑白配”的手势游戏方式决出唯一的输家。“黑白配”的手势游戏是通过区分出手的手掌的正面、反面的多寡来进行游戏。在三人的“黑白配”游戏中，当大家手势相同时，认为是平局，需要进行下一轮“黑白配”；当大家手势不完全相同时，在三个人的场景下唯一不同手势就认为是唯一的输家。请问：3人的“黑白配”游戏一轮就决出唯一输家的概率有多大？需要两轮才决出唯一输家的概率有多大？

习题 3.44. 五个孩子进行游戏，要通过手势决出唯一输家。游戏有可能需要进行两轮。第一轮，他们使用“黑白配”的方式来进行：大家手势都相同时就继续进行新的一局“黑白配”；大家手势不同时、但只有1人与其他人4手势不同，则直接决出唯一输家，不再进行第二轮游戏；如果有两人手势与其余三人不同，则此二人进行第二轮游戏对决。第二轮是通过石头剪刀布来进行的（也有可能需要进行多局）。请问：需要通过第二轮中的石头剪刀布游戏才能决出唯一输家的概率有多大？

习题 3.45. 一群小孩玩乒乓球，为了保证大部分人都能参与、减少相互的等待时间，约定两人单打时每局赢家得一分、输家不得分，积分先到6分者获胜。假定这些小孩水平相当，每局约耗时1分钟。请问：两人单打时，约8分钟内就能决出胜负的概率？在已知两人单打耗时约8分钟条件下，他们曾经出现比分4:0的概率有多大？

习题 3.46. 上一题中，如果规则改成：当一方先到6分，另一方落后超过2分（含2分）时，积分领先者获胜；而当一方先到6分，另一方为5分时，则需要有一方首先领先2分（含2分）才能获胜。请问在此规则下，两人单打时，约8分钟内就能决出胜负的概率？

习题 3.47. 某大学生在毕业时向两个相互无关的用人单位递交了求职信。根据经验，他被第一家单位录用的概率为0.3，被第二家单位录用的概率为0.5。现在已经知道两家单位之一录用了他，请问他也被另一家单位录用的概率？

习题 3.48. 某大学生在毕业时向两个有一定关联的用人单位递交了求职信。根据经验，他被第一家单位录用的概率为0.5，在他被第二家单位录用的前提下，则他被第一家单位录用的概率就提升到0.75；而他在被第一家单位录用的前提下，被第二家单位录用的概率为0.9。

(1) 请问他能被这两家单位中的至少一家录用的概率;

(2) 现在已知两家单位之一录用了他, 请问他也被另一家单位录用的概率?

习题 3.49. 某小学的某英语教师为了提高学生对英语学习的兴趣与热情, 在班上举办了“Bingo! Game”游戏, 每轮的规则如下:

- (a) 首先老师提供九个英语单词(或短语), 每个学生将这九个单词(或短语)不重不漏地随机填入一个九宫格中;
- (b) 之后老师从这九个单词(或短语)中先随机宣读三个单词(或短语), 并询问学生的九宫格中是否有已宣读的单词(或短语)“连成一线”的情况; 这里, “连成一线”是指有三个已宣读单词被写入九宫格的三条水平线、三条竖直线或和两条对角线的对应三个方格中。如果有这样的同学, 则他们中奖, 该轮游戏结束;
- (c) 如果没有前述情形的中奖同学, 则老师随机加报剩下单词(或短语)中的一个。同样, 老师询问学生的九宫格中是否有已宣读的单词(或短语)连成一线的情况。如果有这样的同学, 则他们中奖, 该轮游戏结束; 否则重复进行本步骤直至所有单词(或短语)宣读完毕, 游戏自然结束。

已知该班有 $n = 41$ 个学生。在一轮“Bingo! Game”游戏中, 请计算:

(1) 仅宣读三个单词(或短语)就有学生中奖的概率;

(2) 在宣读四个单词(或短语)才有学生中奖的概率;

(3) 最多需要宣读几个单词(或短语)就必定全员中奖?

习题 3.50. (不等式的概率证明) 设 a, b, c 是三角形的三条边, 且 $a + b + c = 1$. 求证: $\frac{13}{27} \leq a^2 + b^2 + c^2 + 4abc \leq \frac{1}{2}$.

习题 3.51. (不等式的概率证明) 设对任意 $1 \leq i, j \leq n$, 有 $p_{i,j} \in [0, 1]$. 求证:

$$\prod_{j=1}^n [1 - \prod_{i=1}^n p_{i,j}] + \prod_{i=1}^n [1 - \prod_{j=1}^n (1 - p_{i,j})] \geq 1.$$

习题 3.52. 有 n 个非空的有限集 $A_1, \dots, A_n$ 满足: $\sum_{1 \leq i < j \leq n} \frac{|A_i \cap A_j|}{|A_i| \cdot |A_j|} < 1$. 求证: 存在 $a_i \in A_i, i = 1, \dots, n$ 使得 $a_1, \dots, a_n$ 互不相同。

习题 3.53. 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是一个概率空间, 当 Ω 是一个可数集时, 我们就称 $(\Omega, \mathcal{F}, \mathbb{P})$ 是一个离散概率模型或离散概率空间。求证: 两个离散概率空间的乘积概率空间仍然是离散概率空间。

习题 3.54. 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是一个概率空间. 称 $\mathbb{P}$ 是无原子的, 如果对任意 $A \in \mathcal{F}$, 当 $\mathbb{P}(A) > 0$ 时, 总存在 $B \in \mathcal{F}$ 使得 $0 < \mathbb{P}(B|A) < 1$. 假设 $\mathbb{P}$ 是无原子的.

(1) 设 $A \in \mathcal{F}$ 满足 $\mathbb{P}(A) > 0$, 定义 $\mathcal{E}_A := \{B \in \mathcal{F} : \mathbb{P}(B|A) < \frac{1}{3}\}$ 及

$$b := \sup\{\mathbb{P}(B|A) : B \in \mathcal{E}_A\}.$$

通过反证法证明: 存在 $B \in \mathcal{F}$ 使得 $\frac{1}{3} \leq \mathbb{P}(B|A) \leq \frac{2}{3}$;

(2) 证明: 任给 $A \in \mathcal{F}$ 满足 $\mathbb{P}(A) > 0$, 存在 $B \in \mathcal{F}$ 使得 $\mathbb{P}(B|A) = \frac{1}{2}$;

(3) 证明: 存在一族可测集 $\{A_x\}_{x \in [0,1]}$ 满足: (i) $\forall 0 \leq x < y \leq 1, A_x \subset A_y$;
(ii) $\forall x \in [0, 1], \mathbb{P}(A_x) = x$.

习题 3.55. 本题来源于文献^[60], 试图用概率方法证明 *Riemann* 的 *Zeta* 函数 $\zeta(\cdot)$ 基于欧拉 (*Euler*) 的素数分解定理的公式, 其中 $\zeta(s) := \sum_{n=1}^{\infty} \frac{1}{n^s}$. 记 $\mathcal{P} := \{p : p \text{ 为素数}\}$ 及 $\mathcal{P}_n := \{p \leq n : p \text{ 为素数}\}$. 给定 $s > 1$, 定义 $\Omega := \mathbb{N}$ 上的概率

$$\mathbb{P}(\{n\}) := \frac{1}{\zeta(s) \cdot n^s}.$$

在文献^[86]中, 这个概率分布被称为 ζ -分布, 它曾被意大利经济学家 *V. Pareto* 用于描述某个给定国家的家庭收入的分布; 有时也称为 *Zipf* 分布, 因为 *G. K. Zipf* 把这一分布运用到不同领域的更广泛问题中, 从而推广了它的运用. 请证明:

(1) $\mathbb{P}(m\mathbb{N}) = \frac{1}{m^s}, \forall m \in \mathbb{N}$;

(2) $\{p\mathbb{N}\}_{p \in \mathcal{P}}$ 是相互独立的, 从而 $\{(p\mathbb{N})^c\}_{p \in \mathcal{P}}$ 也是相互独立的;

(3) 利用上述结论 (1)、(2) 计算

$$\frac{1}{\zeta(s)} = \mathbb{P}(\{1\}) = \mathbb{P}\left(\bigcap_{p \in \mathcal{P}} (p\mathbb{N})^c\right) = \lim_{n \rightarrow \infty} \mathbb{P}\left(\bigcap_{p \in \mathcal{P}_n} (p\mathbb{N})^c\right),$$

由此完成证明 $\zeta(s) = \prod_{p \in \mathcal{P}} [1 - p^{-s}]^{-1}, \forall s > 1$. 读者也可以思考如何利用容斥原理 (或 *Poincaré* 恒等式) 来进行相应的计算.

第四章 Lebesgue 积分理论简介

为了讲义后续内容的严谨性与逻辑自洽性，我们在本章简略介绍 Lebesgue 积分理论；这一理论本身在历史上也确实对概率论的发展有着极其重要的影响。欧氏空间的 Lebesgue 积分理论是数学分析中的 Riemann 积分理论的推广，在现代数学理论中占有重要地位，它的应用也极其广泛；本章在介绍这一积分理论的同时，也顺带介绍一般测度空间的 Lebesgue 积分理论，因为它们本质上具有完全类似的形式逻辑。

本章的内容一部分来自《实变函数论》，一部分来自《测度论》，较大部分的理论结果我们在本讲义中不提供证明，读者可以参见相关文献。对概率论初学者，本章的有关理论论述只作了解即可，初次学习时不必深究其具体论证。但 Carathéodory 扩张定理、 σ -有限预测度的扩张唯一性定理和 Lebesgue 积分的定义流程建议了解，Levi 单调收敛定理、Fatou 引理、Lebesgue 控制收敛定理和 Fubini 定理建议熟练掌握，Radon-Nikodym 定理建议了解并学会使用。在有关定理的证明过程中使用了单调类定理 (见附录A定理A.2.2)，为了避免正文论述叠加进一步的复杂性，我们把它的论述与证明置于附录A中；但单调类定理在公理化概率论中比较重要，对于深入学习概率论，这个定理是有必要学习掌握的，对于初学者则略作了解即可。

4.1 可测集与可测函数

4.1.1 Borel 可测集与一般可测集

一般地，设 E 是一个非空点集，称 $(E, \mathcal{T}_E)$ 是一个拓扑空间，如果 $\mathcal{T}_E$ 是 E 上的集族，满足：

(i) $\emptyset, E \in \mathcal{T}_E$ ；

(ii) 任意并运算封闭： $A_\alpha \in \mathcal{T}_E, \alpha \in I \Rightarrow \bigcup_{\alpha \in I} A_\alpha \in \mathcal{T}_E$ ；

(iii) 有限交运算封闭: $A, B \in \mathcal{T}_E \Rightarrow A \cap B \in \mathcal{T}_E$.

此时称 $\mathcal{T}_E$ 是 E 上的一个拓扑; 当 $A \in \mathcal{T}_E$ 时, 称 A 为开集, 称 A^c 为闭集.

在一维欧氏空间 $\mathbb{R}$ 中, 我们总是使用所有开区间生成的拓扑, 其中拓扑中的集合都称为开集, 而所有开集生成的 σ -代数就称为 (一维) Borel σ -代数, 记作 $\mathcal{B}$; $\mathcal{B}$ 中的任一元素 $A \in \mathcal{B}$ 都称为是 (一维) Borel 可测集. 以下集族

$$\begin{aligned}\mathcal{E}_1 &:= \{(a, b) : a, b \in \mathbb{R}, a < b\}, \mathcal{E}_2 := \{(a, b] : a, b \in \mathbb{R}, a < b\}, \\ \mathcal{E}_3 &:= \{[a, b] : a, b \in \mathbb{R}, a < b\}, \mathcal{E}_4 := \{(a, b) : a, b \in \mathbb{Q}, a < b\}, \\ \mathcal{E}_5 &:= \{(a, b] : a, b \in \mathbb{Q}, a < b\}, \mathcal{E}_6 := \{[a, b] : a, b \in \mathbb{Q}, a < b\}\end{aligned}$$

生成的 σ -代数都是 $\mathcal{B}$. 这一结论在把上述集族 $\mathcal{E}_4, \mathcal{E}_5, \mathcal{E}_6$ 的表示中的 $\mathbb{Q}$ 替换为其他在 $\mathbb{R}$ 中稠密的子集 $D \subset \mathbb{R}$ 时仍然成立.

在 $n \geq 2$ 维欧氏空间 $\mathbb{R}^n$ 中, 我们可以使用 $\mathbb{R}$ 上拓扑的 n 重乘积拓扑以及乘积 σ -代数, 即可以定义乘积可测结构 $(\mathbb{R}^n, \mathcal{B}^n) := (\mathbb{R}, \mathcal{B})^n$ (参见第三章中乘积 σ -代数的定义)¹, 此处的 n 重乘积 σ -代数 $\mathcal{B}^n$ 就称为 n 维 Borel σ -代数, $\mathcal{B}^n$ 中的任一元素 $A \in \mathcal{B}^n$ 都称为是 n 维 Borel 可测集.

对一般拓扑空间 $(E, \mathcal{T}_E)$, $\mathcal{T}_E$ 是 E 中所有开集的全体 (即所谓的拓扑结构), 那么 $\mathcal{T}_E$ 生成的 σ -代数 $\mathcal{B}_E := \sigma(\mathcal{T}_E)$ 也可以视作一种 Borel σ -代数, 其中的任意子集 $A \in \mathcal{B}_E$ 也称为 E 的 Borel 可测集. 例如, $D \subset \mathbb{R}^n$ 是一个 Borel 可测集, 那么 D 上诱导的自然拓扑为

$$\mathcal{T}_D := \{D \cap V : V \subset \mathbb{R}^n \text{ 是开集}\}.$$

此时容易知道, D 上的 Borel σ -代数为

$$\mathcal{B}_D = \sigma(\mathcal{T}_D) = D \cap \mathcal{B}^n = \{D \cap A : A \in \mathcal{B}^n\}.$$

在欧氏空间或拓扑空间中, 如未指明可测结构, 则我们通常采纳 Borel 可测结构作为默认的可测结构.

更一般地, 设 $(\Omega, \mathcal{F})$ 是一个给定的可测结构 (亦即 $\mathcal{F}$ 是 Ω 上的 σ -代数), 则任意子集 $A \subset \Omega$ 称为可测集 (或 $\mathcal{F}$ -可测集), 如果 $A \in \mathcal{F}$.

4.1.2 Borel 可测函数与一般的可测映射

我们首先给出欧氏空间上的 Borel 可测函数的概念.

¹这里略有符号的滥用, 即此处 $\mathcal{B}^n := \sigma(\mathcal{B} \times \cdots \times \mathcal{B})$ 作 $\mathcal{B} \otimes \cdots \otimes \mathcal{B}$ 理解, 而不作 $\mathcal{B} \times \cdots \times \mathcal{B}$ 理解.

定义 4.1.1. 任意给定一个非空的 *Borel* 可测集 $D \subset \mathbb{R}$. 通常, 我们把 $f: D \rightarrow \mathbb{R}$ 称为 (一元) *Borel* 可测函数 (简称可测函数), 如果对任意 $x \in \mathbb{R}$

$$\{t \in D : f(t) \leq x\} \in \mathcal{B}.$$

这等价于 $f^{-1}(A) \in \mathcal{B}_D = D \cap \mathcal{B}, \forall A \in \mathcal{B}$; 此性质可简写为 $f^{-1}(\mathcal{B}) \subset \mathcal{B}_D$.

任意给定非空 *Borel* 可测集 $D \subset \mathbb{R}^n$ (其中 $n \geq 2$), 我们把 $f: D \rightarrow \mathbb{R}$ 称为 (n 元) *Borel* 可测函数 (简称可测函数), 如果对任意 $x \in \mathbb{R}$

$$\{t \in D : f(t) \leq x\} \in \mathcal{B}_D.$$

这等价于 $f^{-1}(A) \in \mathcal{B}_D = D \cap \mathcal{B}^n, \forall A \in \mathcal{B}$; 此性质也可简写为 $f^{-1}(\mathcal{B}) \subset \mathcal{B}_D$. 但要注意, 此处 f 已经是 n 元函数了, $f^{-1}(A) \subset \mathbb{R}^n$.

一般地, 我们还可以给出欧氏空间之间的 *Borel* 可测映射的概念, 但此时我们一般称为 *Borel* 可测 (向量值) 函数, 即仍然简称可测函数。

定义 4.1.2. 对于自然数 $m, n \geq 1$ 及任意给定一个非空的 *Borel* 可测集 $D \subset \mathbb{R}^n$, 我们把 $f: D \rightarrow \mathbb{R}^m$ 称为 (n 元 m 维向量值) *Borel* 可测函数 (简称可测函数), 如果

$$f^{-1}(A) \in \mathcal{B}_D, \forall A \in \mathcal{B}^m$$

上述性质也可简写为 $f^{-1}(\mathcal{B}^m) \subset \mathcal{B}_D$.

我们定义更一般的可测映射和可测函数如下。

定义 4.1.3. 给定可测结构 $(\Omega_k, \mathcal{F}_k), k = 1, 2$ 以及它们之间的一个映射

$$T: \Omega_1 \rightarrow \Omega_2,$$

称 T 是可测映射 (更确切地, $\mathcal{F}_1/\mathcal{F}_2$ -可测映射), 如果

$$T^{-1}(A) \in \mathcal{F}_1, \forall A \in \mathcal{F}_2.$$

记 $T^{-1}(\mathcal{F}_2) := \{T^{-1}(A) : A \in \mathcal{F}_2\}$, 上述性质也可以简单记为 $T^{-1}(\mathcal{F}_2) \subset \mathcal{F}_1$, 不难知道 $T^{-1}(\mathcal{F}_2)$ 是一个 σ -代数。

上述定义中, 如果 $(\Omega_2, \mathcal{F}_2) = (\mathbb{R}, \mathcal{B})$, 则称可测映射 $T: \Omega_1 \rightarrow \Omega_2$ 为 (实) 可测函数; 如果 $(\Omega_2, \mathcal{F}_2) = (\mathbb{R}^m, \mathcal{B}^m)$, 则称可测映射 $T: \Omega_1 \rightarrow \Omega_2$ 为 (实) 向量值可测函数。在不引起歧义的情况下, 此二者都简称可测函数; 为了指明定义域 Ω_1 中采纳的可测结构, 有时更确切地称它们为 $\mathcal{F}_1$ -可测函数。

容易知道, $\mathbb{R}$ 上的连续函数、单调函数都是 Borel 可测函数。一般地, 设 $(\Omega, \mathcal{F})$ 是一个可测空间, 对任意 $A \subset \Omega$, 示性函数 $1_A : \Omega \rightarrow \mathbb{R}$ 是一个可测函数, 当且仅当 $A \in \mathcal{F}$; 参见示性函数的定义(2.3).

定义 4.1.4. 设 $(\Omega, \mathcal{F})$ 是一个给定的可测结构. Ω 上的可测函数 f 称为简单函数, 如果存在 $N \in \mathbb{N}, \{a_i\}_{i=1}^N \subset \mathbb{R}$ 及 $\{A_i\}_{i=1}^N \subset \mathcal{F}$, 使得

$$f = \sum_{i=1}^N a_i 1_{A_i}.$$

在本书中, 简单函数的全体记作 $\mathcal{S}$, 非负简单函数的全体记作 $\mathcal{S}_+$.

4.2 Lebesgue 测度与一般可测空间中的非负测度

4.2.1 测度、符号测度、预测度与外测度的定义

欧氏空间中的 Lebesgue 测度是我们直观上很容易理解的测度; 在第二章的几何概率模型定义中, 可测集 $A \subset \mathbb{R}^n$ 的“体积”($n=1$ 时叫“长度”, $n=2$ 时叫“面积”)被记作 $|A|$, 它就是我们通常说的可测集 A 的 Lebesgue 测度值。后来在公理化框架下我们定义了概率测度, 在那里我们顺带提及了测度的概念。这里我们重新给出测度的更详细、准确的定义如下。

定义 4.2.1. 给定一个可测空间 $(\Omega, \mathcal{F})$, $\mu : \mathcal{F} \rightarrow \bar{\mathbb{R}} := \mathbb{R} \cup \{\pm\infty\}$ 称为这个可测结构上的 (非负) 测度, 如果它满足

- (1) (非负性 + 平凡性) $\mu(A) \geq 0, \forall A \in \mathcal{F}$, 且 $\mu(\emptyset) = 0$;
- (2) (σ 可加性/可列可加性) 设 $\{A_n\}_{n=1}^{\infty} \subset \mathcal{F}$ 互不相交, 则

$$\mu\left(\biguplus_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mu(A_n).$$

设 μ 为 $(\Omega, \mathcal{F})$ 上测度, 此时称 $(\Omega, \mathcal{F}, \mu)$ 是一个测度空间或一个测度结构。如果 $\mu(\Omega) < \infty$, 则称 μ 为有限测度。如果存在 $\Omega_n \nearrow \Omega$ 使得 $\mu(\Omega_n) < \infty, \forall n$, 则称 μ 为 σ -有限测度。如果 Ω 是一个拓扑空间, $\mathcal{B}_\Omega$ 是它的 Borel σ -代数, μ 为 $(\Omega, \mathcal{B}_\Omega)$ 上测度, 则称 μ 为 Borel 测度; 进一步, 如果对 Ω 中任意紧集 $K \subset \Omega$, 总有 $\mu(K) < \infty$, 则称 μ 为 Ω 上 Radon 测度。

例 4.1. (计数测度) 给定一个非空集合 Ω , 对它的任意子集 $A \subset \Omega$, 可以考虑 A 的元素个数 $\#(A)$, 则 $\#(\cdot) : 2^\Omega \rightarrow \bar{\mathbb{R}}$ 是一个测度, 称为计数测度。在古典概率模型中我们把 $\#(A)$ 记作了 $|A|$ 。

例 4.2. (体积测度) 在欧氏空间 $\mathbb{R}^d$ 中, 我们有“体积测度”的直观概念 ($d=1$ 时叫“长度”, $d=2$ 时叫“面积”, $d=3$ 时叫“体积”), 对任意 Borel 子集 $A \subset \mathbb{R}^d$, 我们后续将严格定义它在 $\mathbb{R}^d$ 中的“体积”, 记作 $\text{Vol}(A)$ 或 $\text{Vol}^{(d)}(A)$, 有时也记作 $\text{Leb}(A)$ 、 $\text{Leb}^{(d)}(A)$; 它满足:

$$\text{Vol}^{(d)}((a_1, b_1] \times \cdots \times (a_d, b_d]) = \prod_{i=1}^d (b_i - a_i), \text{ 其中 } a_i < b_i, i = 1, 2, \dots, d.$$

在几何概率模型中我们把 $\text{Vol}(A)$ 仍然记作了 $|A|$.

下面例子中奇怪的测度不是我们感兴趣的测度:

例 4.3. (奇异测度) 设 Ω 是非空集合, $\mathcal{F}$ 是其上 σ -代数, 定义 $\mu(\emptyset) := 0$ 及

$$\mu(A) := \infty, \forall A \in \mathcal{F}, A \neq \emptyset,$$

则 $\mu: \mathcal{F} \rightarrow \bar{\mathbb{R}}$ 是一个测度, 称为奇异测度。

类似于概率测度的性质, 不难知道 $(\Omega, \mathcal{F})$ 上测度 μ 具有以下性质:

(M1) (非负性) $\mu(A) \geq 0, \forall A \in \mathcal{F}$;

(M2) (平凡性) $\mu(\emptyset) = 0$;

(M3) (σ -可加性) 设 $\{A_n\}_{n=1}^{\infty} \subset \mathcal{F}$ 互不相交, 则 $\mu(\biguplus_{n=1}^{\infty} A_n) = \sum_{n=1}^{\infty} \mu(A_n)$;

(M4) (有限可加性) 对任意给定的 $n \geq 1$, 若 $\{A_k\}_{k=1}^n \subset \mathcal{F}$ 且互不相交, 则

$$\mu(\biguplus_{k=1}^n A_k) = \sum_{k=1}^n \mu(A_k).$$

(M5) (单调性) 若 $A, B \in \mathcal{F}$ 且 $A \subset B$, 则 $\mu(A) \leq \mu(B)$;

(M6) (次可数可加性) 若诸 $A_n \in \mathcal{F}$, 则 $\mu(\bigcup_{n=1}^{\infty} A_n) \leq \sum_{n=1}^{\infty} \mu(A_n)$;

(M7) (下连续性) 若诸 $A_n \in \mathcal{F}$ 且 $A_n \uparrow A$, 则 $A \in \mathcal{F}$, 并且

$$\mu(A) = \mu(\lim_{n \rightarrow \infty} A_n) = \lim_{n \rightarrow \infty} \mu(A_n); \quad (4.1)$$

(M8) (上连续性) 若诸 $A_n \in \mathcal{F}$ 且 $A_n \downarrow A$, 并且存在 $n_0 < \infty$ 使得 $\mu(A_{n_0}) < \infty$, 则 $A \in \mathcal{F}$, 并且

$$\mu(A) = \mu(\lim_{n \rightarrow \infty} A_n) = \lim_{n \rightarrow \infty} \mu(A_n); \quad (4.2)$$

特别地, μ 在 $\emptyset$ 处上连续, 即

(M8') ($\emptyset$ -连续性) 若诸 $A_n \in \mathcal{F}$ 且 $A_n \downarrow \emptyset$, 并且存在 $n_0 < \infty$ 使得 $\mu(A_{n_0}) < \infty$, 则 $\lim_{n \rightarrow \infty} \mu(A_n) = 0$.

这里, 我们指出: 测度这个概念是物理学中一类特殊的物理量—**广延量** (比如质量、体积、内能等物理量) 的数学抽象, 其中测度的 σ -可加性就是这类特殊物理量的广延性的数学抽象描述.

如果函数 $\mu: \mathcal{F} \rightarrow \bar{\mathbb{R}}$ 仅具有性质 (M2) 与 (M3), 则称 μ 是 $(\Omega, \mathcal{F})$ 上的**符号测度**. 称此符号测度 μ 是**有限的**, 如果对于任意 $A \in \mathcal{F}$, $|\mu(A)| < \infty$; 类似可以定义 σ -有限的符号测度: 对 $\mathcal{F}$ 上符号测度 μ , 如果存在 $A_n \in \mathcal{F}$, $A_n \nearrow \Omega$, 且 $|\mu(A_n)| < \infty, \forall n$, 则称 μ 是 **σ -有限的**. 可测集 $A \in \mathcal{F}$ 称为 **μ -正集 (负集)**, 如果其任意可测子集的 μ 测度均为非负 (非正).

我们还需要给出预测度的概念.

定义 4.2.2. 给定非空集 Ω 及其上一个非空的子集族 $\mathcal{E}$ (未必是 σ -代数), 其中 $\emptyset \in \mathcal{E}$. $\mu: \mathcal{E} \rightarrow \bar{\mathbb{R}}$ 称为 $\mathcal{E}$ 上的 (非负) **预测度**, 如果它满足

(1) (非负性 + 平凡性) $\mu(A) \geq 0, \forall A \in \mathcal{E}$, 且 $\mu(\emptyset) = 0$;

(2) (σ 可加性/可列可加性) 设 $\{A_n\}_{n=1}^{\infty} \subset \mathcal{E}$ 互斥, 且 $\biguplus_{n=1}^{\infty} A_n \in \mathcal{E}$, 则

$$\mu\left(\biguplus_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mu(A_n).$$

📌 注记 4.1. 在一些测度论的文献中, 把预测度定义中的 (2) 换为以下两条:

(2.1) (有限可加性) 设 $A, B \in \mathcal{E}$ 互斥, 且 $A \cup B \in \mathcal{E}$, 则

$$\mu(A \uplus B) = \mu(A) + \mu(B);$$

(2.2) ($\emptyset$ -连续性) 设 $A_n \in \mathcal{E}$ 满足 $A_n \downarrow \emptyset$ 且 $\mu(A_1) < \infty$, 则

$$\lim_{n \rightarrow \infty} \mu(A_n) = 0.$$

当 $\mathcal{E}$ 是环或代数, 且 $\mu: \mathcal{E} \rightarrow \bar{\mathbb{R}}$ 满足 (1) 时, (2.1)+(2.2) 与 (2) 是等价的.

我们进一步给出外测度的概念如下.

定义 4.2.3. 设 Ω 是非空集. $\mu: 2^{\Omega} \rightarrow \bar{\mathbb{R}}$ 称为 Ω 上的**外测度**, 如果它满足

(1) (非负性 + 平凡性) $\mu(A) \geq 0, \forall A \subset \Omega$, 并且 $\mu(\emptyset) = 0$;

(2) (次可列可加性) 设 $\{A_n\}_{n=1}^{\infty}$ 为 Ω 中集列, 那么 $\mu\left(\bigcup_{n=1}^{\infty} A_n\right) \leq \sum_{n=1}^{\infty} \mu(A_n)$;

(3) (单调性) 若 $A \subset B \subset \Omega$, 则 $\mu(A) \leq \mu(B)$.

4.2.2 符号测度的 Hahn 分解与 Jordan 分解

设 μ 为 $\mathcal{F}$ 上符号测度。易知，可加性蕴含：或者 $\mu(A) < \infty, \forall A \in \mathcal{F}$ ；或者 $\mu(A) > -\infty, \forall A \in \mathcal{F}$. 对任意 $A \in \mathcal{F}$ ，定义

$$\mu^+(A) := \sup\{\mu(B) : B \subset A, B \in \mathcal{F}\}, \quad \mu^- := (-\mu)^+.$$

从而 μ^+, μ^- 均为非负的集函数（因为 $\mu(\emptyset) = 0$ ）. 下面的定理说明， μ^+, μ^- 实际上是非负测度，即符号测度总是两个非负测度的差。

♠ **定理 4.2.1.** (*Hahn 分解与 Jordan 分解*) 设 $(\Omega, \mathcal{F})$ 为可测空间， μ 为 $\mathcal{F}$ 上一个符号测度。那么

- (1) 正集的可列并是正集；
- (2) $A \in \mathcal{F}$ 是正集 $\Leftrightarrow \mu^-(A) = 0$ ； $A \in \mathcal{F}$ 是负集 $\Leftrightarrow \mu^+(A) = 0$ ；
- (3) μ^+, μ^- 具有单调性；
- (4) 存在 $H \in \mathcal{F}$ 使得： H 为正集，而 H^c 为负集；集合 H 称为 *Hahn 集*。空间分解 $\Omega = H \cup H^c$ 就称为 *Hahn 分解*；
- (5) $\mu^+(A) = \mu(A \cap H), \mu^-(A) = -\mu(A \cap H^c), \forall A \in \mathcal{F}$. 因而 μ^+, μ^- 都是测度（分别称为符合测度 μ 的正部和负部），且其中至少有一个是有限测度；
- (6) $\mu = \mu^+ - \mu^-$ ，这称为 *Jordan 分解*。如果存在测度 μ_1, μ_2 使得 $\mu = \mu_1 - \mu_2$ ，那么 $\mu^+ \leq \mu_1, \mu^- \leq \mu_2$ ；记 $|\mu| := \mu^+ + \mu^-$ ，它称为是 μ 的全变差测度， $\|\mu\|_{\text{TV}} := |\mu|(\Omega)$ 称为 μ （在 Ω 上）的全变差；
- (7) *Hahn 集* 通常不唯一，但在只相差一个 $|\mu|$ -零测集的意义下唯一。

概率论的初学者对上述定理的陈述略作了解即可；下面提供的证明只是出于全书封闭性的考量。

定理 4.2.1 的证明： (1) — (3) 的证明留作习题。下面我们证明 (4) — (6).

不妨设 $\mu(A) < \infty, \forall A \in \mathcal{F}$ ，且 μ 不是零测度。令 $b := \sup\{\mu(A) : A \in \mathcal{F}\}$ ；则 $0 \leq b \leq \infty$. 我们先证明下面的断言 1.

断言 1： 对任意 $\beta \in [0, b)$ ，存在正集 $A \in \mathcal{F}$ 使得 $\mu(A) \geq \beta$.

$b = 0$ 是平凡情况；以下设 $b > 0$. 由 b 的定义，存在 $B \in \mathcal{F}$ ， $\mu(B) > \beta$. 若 B 是正集，则取 $A = B$. 否则 $0 < \mu^-(B) \leq \infty$ ；进而，对任意 $a_1 > 0$ 满足 $\frac{\mu^-(B)}{2} \wedge 1 < a_1 < \mu^-(B)$ ，存在 $E_1 \subset B$ ， $\mu(E_1) < -a_1$ ，从而对 $B_1 := B \setminus E_1$ ， $\mu(B_1) > \beta_1 := \beta + a_1$. 若 B_1 为正集，则记 $A = B_1$. 否则，对任意 $a_2 > 0$

满足 $\frac{\mu^-(B_1)}{2} \wedge 1 < a_2 < \mu^-(B_1)$, 存在 $E_2 \subset B_1$, $\mu(E_2) < -a_2$, 从而对 $B_2 := B_1 \setminus E_2 = B \setminus (E_1 \dot{\cup} E_2)$, $\mu(B_2) > \beta_2 := \beta + a_1 + a_2$. 如此进行下去, 若有限步内总是不能得到所需的正集, 则可得到 B 中一系列互不相交的可测集 $\{E_n\}_{n=1}^\infty$ 和一系列正实数 $\{a_n\}_{n=1}^\infty$ 以及 $B_n := B \setminus (\bigcup_{k=1}^n E_k)$, 满足: $\mu^-(B_n) > 0, \mu(E_n) < -a_n, \forall n \geq 1$, 其中

$$0 < \min\left(\frac{\mu^-(B_n)}{2}, 1\right) < a_n < \mu^-(B_n).$$

令 $E := \bigcup_{n=1}^\infty E_n \subset B, A := B \setminus E$. 若 $\mu^-(A) > 0$, 注意到 $A \subset B_n, \forall n \geq 1$, 有 $\mu^-(B_n) \geq \mu^-(A)$, 从而 $a_n \geq a := \min\left(\frac{\mu^-(A)}{2}, 1\right) > 0$, 进而

$$\mu(E) = \sum_{n=1}^\infty \mu(E_n) \leq \sum_{n=1}^\infty (-a_n) = -\infty,$$

即 $0 \leq \beta < \mu(B) = \mu(A) + \mu(E) = -\infty$, 矛盾. 因此断言 1 成立.

我们进一步证明下面的断言 2.

断言 2: $b < \infty$ 且 $\exists H \in \mathcal{F}, \mu(H) = b$, 且 H 可取为 Hahn 集.

由断言 1, 我们可取可测正集列 $\{A_n\}_{n=1}^\infty$, 使得 $\lim_{n \rightarrow \infty} \mu(A_n) = b$. 现在令 $H := \bigcup_{n=1}^\infty A_n$. H 显然为正集, 且 $\mu(H) \geq b$, 故 $b = \mu(H) < \infty$. 另外, 对 H^c 的任何可测子集 A , 有 $b \geq \mu(H \cup A) = b + \mu(A)$, 即 $\mu(A) \leq 0$, 从而 H^c 是负集. 于是 H 是 Hahn 集, 且满足断言 2.

由 Hahn 集 H 的存在性, 我们知道

$$\begin{aligned} \mu^+(A) &:= \sup\{\mu(B) : B \in \mathcal{F}, B \subset A\} \\ &= \sup\{\mu(B \cap H) + \mu(B \cap H^c) : B \in \mathcal{F}, B \subset A\} \\ &\leq \sup\{\mu(B \cap H) : B \in \mathcal{F}, B \subset A\} = \mu(A \cap H). \end{aligned}$$

但显然应有 $\mu^+(A) \geq \mu(A \cap H)$. 因此, $\mu^+(A) = \mu(A \cap H)$. 同理 $\mu^-(A) = -\mu(A \cap H^c)$.

现在定理中的结论 (5) — (6) 很容易验证了, 留作习题.

我们现在回过头来看 Hahn 集的唯一性问题. 设 H_1, H_2 均为 Hahn 集, 由我们的假定, 有 $0 \leq \mu(H_1) = \mu(H_2) < \infty$. 另外,

$$\mu(H_1 \setminus H_2) = \mu(H_1 \cap H_2^c) = \mu^+(H_2^c) = -\mu^-(H_1),$$

从而 $\mu(H_1 \setminus H_2) = 0$, 同理 $\mu(H_2 \setminus H_1) = 0$. 注意到

$$\begin{aligned} |\mu|(H_1 \Delta H_2) &= \mu^+(H_1 \Delta H_2) + \mu^-(H_1 \Delta H_2) \\ &= \mu(H_1 \cap (H_1 \Delta H_2)) - \mu(H_1^c \cap (H_1 \Delta H_2)) \\ &= \mu(H_1 \setminus H_2) - \mu(H_2 \setminus H_1) = 0, \end{aligned}$$

可见 Hahn 集虽然一般不唯一, 但在相差一个 $|\mu|$ -零测集的意义下唯一. $\square$



图 4.1: H. Hahn(1879-1934)



图 4.2: C. Jordan(1838-1922)

注 4.1. Hans Hahn (哈恩, 1879—1934; 奥地利/匈牙利) 生于维也纳, 卒于维也纳。他的父亲是当时的电话局高级官员。他 1898 年成为维也纳大学的学生, 起初学习法律, 1899 年转学数学, 之后游学于斯特拉斯堡大学、慕尼黑大学和哥廷根大学; 1902 年在维也纳获得博士学位。上面提及的 Hahn 集就是以他的名字命名的。他的著名工作有泛函分析中的 Hahn-Banach 定理、一致有界原理 (共鸣定理; 也被称为 Banach-Steinhaus 定理), 抽象代数中的 Hahn 嵌入定理, 测度论中的 Hahn-Kolmogorov 定理 (有时也称为 Carathéodory-Fréchet 扩张定理、Carathéodory-Hopf 扩张定理、Hopf 扩张定理、Hahn-Kolmogorov 扩张定理)、Vitali-Hahn-Saks 定理, 拓扑方面的 Hahn-Mazurkiewicz 定理等。

Hahn 培养的知名学生有: K. Menger (1902—1985; 奥地利-美国数学家, 以 Menger 定理知名, Sierpinski 方块/海绵实际是他发现的, 应称为 Menger 方块/海绵), W. Hurewicz (1904—1956; 波兰数学家, 以高阶同伦群、纤维的长正则同伦序列和 Hurewicz 定理知名), K. Gödel (哥德尔, 1906—1978; 奥地利/匈牙利-美国数学家、逻辑学家、分析哲学家, 以 Gödel 不完备定理、Gödel 完备定理等成果闻名于世) 等。

Camille Jordan (约当, 1838—1922; 法国) 生于里昂, 卒于巴黎; 大学毕业于巴黎综合理工学院。他以 Jordan 曲线定理、Jordan 标准型、Jordan 矩阵等知名, 他在把 Galois 理论推进到数学的主流上做了不少贡献; 他写的教材《Cours d'analyse》影响很大。上面提及的 Jordan 分解也以他的姓氏冠名; 1920 年的斯特拉斯堡国际数学家大会上他是特邀报告人。他的姓名容易与其他两位也姓 Jordan 的德国学者混淆: Wilhelm Jordan (1842—1899; 德国几何学家, 以 Gauss-Jordan 消去算法知名)、Pascual Jordan (1902—1980; 德国物理学家, 在量子力学、量子场论、矩阵力学等方面有贡献, Jordan 代数、Jordan-Brans-Dicke 理论、Jordan and Einstein 标架、Jordan 映射、Jordan-Wigner 变换等是以他的姓氏命名的)。

4.2.3 Carathéodory 扩张与 Lebesgue 测度

现在我们可以来定义 $\mathbb{R}$ 中的 Lebesgue 测度了。取

$$\mathcal{E} := \{(a, b] : -\infty \leq a \leq b \leq +\infty\}.$$

定义 $\mu : \mathcal{E} \rightarrow \bar{\mathbb{R}}$ 如下:

$$\mu((a, b]) = b - a, \text{ 其中 } -\infty \leq a \leq b \leq +\infty. \quad (4.3)$$

显然 μ 是 $\mathcal{E}$ 上的预测度。我们可以如下诱导外测度 $\mu^* : 2^{\mathbb{R}} \rightarrow \bar{\mathbb{R}}$:

$$\mu^*(A) := \inf \left\{ \sum_{n=1}^{\infty} \mu(A_n) : A \subset \bigcup_{n=1}^{\infty} A_n, A_n \in \mathcal{E}, n = 1, 2, \dots \right\}.$$

接着, 定义集族

$$\mathcal{L} := \{A \subset \mathbb{R} : \mu^*(E) = \mu^*(E \cap A) + \mu^*(E \cap A^c), \forall E \subset \mathbb{R}\}. \quad (4.4)$$

在实变函数论中, 已经证明了上述集族 $\mathcal{L}$ 是一个 σ -代数, 并且 $\mathcal{E} \subset \mathcal{L}$. $\mathcal{L}$ 中元素称为 Lebesgue 可测集。由 $\mathcal{E} \subset \mathcal{L}$ 立即知道 $\mathcal{B} = \sigma(\mathcal{E}) \subset \mathcal{L}$. 在此基础上, 实变函数论中也证明了

$$\mu^* : \mathcal{L} \rightarrow \bar{\mathbb{R}}$$

是一个测度, 称为 $\mathbb{R}$ 上 Lebesgue 测度。进而 $\text{Leb} := \mu^*|_{\mathcal{B}}$ 也是一个测度, 仍然称为 $\mathbb{R}$ 上 Lebesgue 测度, 它可以认为是预测度 $\mu : \mathcal{E} \rightarrow \bar{\mathbb{R}}$ 的自然延拓。这种自然延拓的方法被称为 Carathéodory 扩张。

$\mathbb{R}^n$ 上的 Lebesgue 测度被定义为 $\mathbb{R}$ 上 Lebesgue 测度 Leb 的 n 重乘积测度 $\text{Leb}^{(n)} := \text{Leb} \otimes \cdots \otimes \text{Leb}$; 为方便, 在不产生歧义时, $\mathbb{R}^n$ 上的 Lebesgue 测度仍然记作 Leb . 在第二章的几何概率模型中, 所谓可测集 A 的体积测度, 就是它的 Lebesgue 测度, 即 $|A| := \text{Leb}(A)$, $A \in \mathcal{B}^n$.

给定一个单调递增、右连续函数 $F : \mathbb{R} \rightarrow \mathbb{R}$, 把(4.3)替换为

$$\mu_F((a, b]) = F(b) - F(a), \text{ 其中 } -\infty \leq a \leq b \leq +\infty, \quad (4.5)$$

并同样使用 Carathéodory 扩张的程序, 可以得到一个新的测度 $\mu_F : \mathcal{B} \rightarrow \bar{\mathbb{R}}$, 它称为 F 诱导的分布测度。

上述 Carathéodory 扩张的流程在抽象空间中仍然可以使用。为此我们先介绍以下几个集合系/集合类的概念。

定义 4.2.4. $\mathcal{E}$ 称为 π -系 (π -system), 如果 $A, B \in \mathcal{E}$ 蕴含了 $A \cap B \in \mathcal{E}$. 在此基础上, π -系 $\mathcal{E}$ 进一步称为半环 (Semi-ring)¹, 如果 $A, B \in \mathcal{E}$ 蕴含了: 存在 $\mathcal{E}$ 中两两不交的有限集合列 $\{A_k\}_{k=1}^n \subset \mathcal{E}$, 使得 $A \setminus B = \biguplus_{k=1}^n A_k$.

注意: 对半环 $\mathcal{E}$, $A, B \in \mathcal{E}$ 时, 未必有 $A \setminus B \in \mathcal{E}$! 即, 对于半环, 集合的差运算未必封闭.

如果半环定义中的后一条修改成“集合的差运算封闭”, 再补充上“集合的并运算封闭”就得到了环的概念, 陈述如下:

定义 4.2.5. $\mathcal{E}$ 称为环 (Ring), 如果它满足:

- (i) $A, B \in \mathcal{E}$, 则 $A \cap B \in \mathcal{E}$;
- (ii) $A, B \in \mathcal{E}$, 则 $A \cup B \in \mathcal{E}$;
- (iii) $A, B \in \mathcal{E}$, 则 $A \setminus B \in \mathcal{E}$.

定义 4.2.6. $\mathcal{E}$ 称为代数 (Algebra) 或域 (Field), 如果它满足:

- (i) $\Omega \in \mathcal{E}$;
- (ii) 如果 $A \in \mathcal{E}$, 则 $A^c \in \mathcal{E}$;
- (iii) 如果 $A, B \in \mathcal{E}$, 则 $A \cup B \in \mathcal{E}$.

显然代数对集合并、交、补、差运算有限封闭. 上述 (i) — (iii) 也等价于

- (i') $\Omega \in \mathcal{E}$;
- (ii') 如果 $A, B \in \mathcal{E}$, 则 $A \setminus B \in \mathcal{E}$.

事实上, $A^c = \Omega \setminus A$, $A \cup B = (A^c \cap B^c)^c = \Omega \setminus [(\Omega \setminus A) \setminus B]$.

容易知道, 代数就是包含了全空间 Ω 的环; 因此有些文献也称环为预代数 (pre-algebra).

例 4.4. $\Omega = \mathbb{R}$, $\mathcal{E}_1 := \{(a, b] : -\infty < a \leq b < \infty\}$,

$$\mathcal{E}_2 := \{E = \bigcup_{k=1}^n A_k : n \in \mathbb{N}, \{A_k\}_{k=1}^n \subset \mathcal{E}_1 \text{ 是两两不交的集合列}\}.$$

则 $\mathcal{E}_1$ 是 π -系、半环, 但不是环; $\mathcal{E}_2$ 是环, 但不是代数. $\mathcal{E}_2$ 恰好是 $\mathcal{E}_1$ 生成的环: $\mathcal{E}_2 = R(\mathcal{E}_1)$.

¹在文献^[29]中有比半环定义略苛刻的 Semialgebra 的定义, 其中后一条件替换成了: 集合系中元素的补集可以表达成集合系内部有限个元素的不交并; 这隐含了集合系中存在全空间的有限覆盖的要求. 因此, 本书例4.4中集合类不满足文献^[29]中的 Semialgebra 的要求.

在很多场合, 我们所关心的测度只是在某个特定的半环上有良好的定义, 比如我们之前讲的 $\mathbb{R}$ 上的 Lebesgue 测度就是如此. 但由半环生成的环结构更好 (对集合的有限次的并、交、补运算都封闭), 并且其上的测度取值理论上也可借助半环上的测度取值简单计算出来. 因此为了表述的简洁, 在研究测度时, 以下我们总是考虑环, 而不再提半环.

定义 4.2.7. 设 $\mathcal{E}$ 为 Ω 上的环. 设 $\mu: \mathcal{E} \rightarrow \bar{\mathbb{R}}_+ := \mathbb{R}_+ \cup \{\infty\} = [0, \infty]$ 是 $\mathcal{E}$ 上的预测度. 如果 $\bar{\mu}$ 是 $\mathcal{F} := \sigma(\mathcal{E})$ 上测度, 且 $\bar{\mu}|_{\mathcal{E}} = \mu$, 则称 $\bar{\mu}$ 为 μ 的一个扩张或延拓.

类似于 σ -有限测度的定义, 环 $\mathcal{E}$ 上预测度 μ 称为 σ -有限的, 如果存在 $A_n \in \mathcal{E}, n \geq 1$ 使得 $\Omega = \bigcup_{n \geq 1} A_n$ 且 $\mu(A_n) < \infty$; 有限预测度类似定义.

很自然要问: 在环上定义的预测度, 能否延拓成环生成的 σ -代数上的一个测度? 进一步, 如果能延拓, 得到的测度是否是唯一的? 以下的 Carathéodory 测度扩张定理肯定地回答了延拓存在性的问题; 而后续的定理则告诉我们, 当预测度具有 σ -有限性时, 延拓也是唯一的. 为了读者的方便, 此处我们提供了这两个定理的证明.

给定空间 Ω 上一个环 $\mathcal{E}$ 及其上一个预测度 μ , 定义 μ^* 如下: $\forall E \in 2^\Omega$

$$\mu^*(E) := \inf \left\{ \sum_{n=1}^{\infty} \mu(A_n) : A_n \in \mathcal{E}, n \geq 1, E \subset \bigcup_{n=1}^{\infty} A_n \right\}. \quad (4.6)$$

(约定 $\inf \emptyset = \infty$.) 显然 μ^* 具有性质 (5) 中陈述的单调性, 并且容易验证它具有性质 (4) 中陈述的次可列可加性, 因此 μ^* 是 Ω 上一个外测度. 此时显然有 $\mu^*|_{\mathcal{E}} = \mu$. 对任意 $A \subset \Omega$, 称 A 为 μ^* -可测, 如果

$$\mu^*(E) = \mu^*(A \cap E) + \mu^*(A^c \cap E), \quad \forall E \subset \Omega.$$

记 $\mathcal{F}_*$ 为 Ω 上 μ^* -可测集的全体.

♠ **定理 4.2.2.** (Carathéodory 测度扩张定理) 给定空间 Ω 上一个环 $\mathcal{E}$ 及其上一个预测度 μ , 外测度 μ^* 及集族 $\mathcal{F}_*$ 如上定义. 则

- (1) $(\Omega, \mathcal{F}_*, \mu^*)$ 是一个测度空间;
- (2) $\mathcal{F}_* \supset \mathcal{F} = \sigma(\mathcal{E}) \supset \mathcal{E}$, $\mu^*|_{\mathcal{E}} = \mu$, 从而 $\mu^*|_{\mathcal{F}}$ 是 μ 的一个扩张, 称之为 Carathéodory 扩张;
- (3) $\mathcal{F}_*$ 包含了所有 μ^* -零测集, 因而 $(\Omega, \mathcal{F}_*, \mu^*)$ 是一个完备的测度空间.

定理4.2.2的证明： 上面的定理本质上源于 Lebesgue 测度的构造，其证明除了需要把 Lebesgue 测度替换为一般测度以外，所有细节也毫无二致。但为了读者的便利，我们还是给出它的证明。

为证明 (1)，我们需要证明： $\mathcal{F}_*$ 是 σ -代数，且 μ^* 是其上测度。

显然， $\emptyset, \Omega \in \mathcal{F}_*$ ，且 $\mathcal{F}_*$ 对补集运算封闭。故只需进一步验证 $\mathcal{F}_*$ 对可列并运算封闭。

事实上， $\mathcal{F}_*$ 对有限并运算封闭，因为若 $A, B \in \mathcal{F}_*$ ，则对任意 $E \subset \Omega$

$$\begin{aligned}\mu^*(E) &= \mu^*(A \cap E) + \mu^*(A^c \cap E) \\ &= \mu^*(A \cap E) + [\mu^*(B \cap (A^c \cap E)) + \mu^*(B^c \cap (A^c \cap E))] \\ &= [\mu^*(A \cap (A \cup B) \cap E) + \mu^*(A^c \cap (A \cup B) \cap E)] + \mu^*((A \cup B)^c \cap E) \\ &= \mu^*((A \cup B) \cap E) + \mu^*((A \cup B)^c \cap E),\end{aligned}$$

由此 $A \cup B \in \mathcal{F}_*$ 。

下面只需再验证 $\mathcal{F}_*$ 对不相交集列的可列并运算封闭。设 $\{A_n\}_{n=1}^\infty$ 是 $\mathcal{F}_*$ 中互不相交的集列。令 $B_n := \biguplus_{k=1}^n A_k$, $A := \biguplus_{k=1}^\infty A_k$ ，由外测度的单调性，

$$\begin{aligned}\mu^*(E) &= \mu^*(E \cap B_n) + \mu^*(E \cap B_n^c) \\ &\geq \mu^*(E \cap B_n) + \mu^*(E \cap A^c) \\ &= \mu^*(E \cap B_n \cap B_{n-1}) + \mu^*(E \cap B_n \cap B_{n-1}^c) + \mu^*(E \cap A^c) \\ &= \mu^*(E \cap B_{n-1}) + \mu^*(E \cap A_n) + \mu^*(E \cap A^c) \\ &= \cdots = \sum_{k=1}^n \mu^*(E \cap A_k) + \mu^*(E \cap A^c).\end{aligned}$$

由 n 的任意性以及 μ^* 的次可列可加性

$$\mu^*(E) \geq \sum_{k=1}^\infty \mu^*(E \cap A_k) + \mu^*(E \cap A^c) \geq \mu^*(E \cap A) + \mu^*(E \cap A^c).$$

因此 $A \in \mathcal{F}_*$ 。同时，从上述证明过程也看到， μ^* 在 $\mathcal{F}_*$ 上具有有限可加性。结合 μ^* 的次可列可加性，立即导出 μ^* 在 $\mathcal{F}_*$ 上具有可列可加性。由此， μ^* 是 $(\Omega, \mathcal{F}_*)$ 上测度。



图 4.3: Carathéodory (1873-1950)

下面证明 (2), 为此设 $A \in \mathcal{E}$. $\forall E \subset \Omega$, 往证 $\mu^*(E) = \mu^*(E \cap A) + \mu^*(E \cap A^c)$, 即 $A \in \mathcal{F}_*$.

如果 $\mu^*(E) = \infty$, 由次可加性, $\infty = \mu^*(E) \leq \mu^*(E \cap A) + \mu^*(E \cap A^c)$, 立即得到 $\mu^*(E) = \mu^*(E \cap A) + \mu^*(E \cap A^c)$.

因此, 以下我们设 $\mu^*(E) < \infty$. 于是对 $\forall \varepsilon > 0$, 存在 $\{A_n\}_{n=1}^\infty \subset \mathcal{E}$ 满足

$$E \subset \bigcup_{n=1}^{\infty} A_n, \quad \sum_{n=1}^{\infty} \mu^*(A_n) \leq \mu^*(E) + \varepsilon.$$

因而

$$\begin{aligned} \mu^*(E) &\leq \mu^*(E \cap A) + \mu^*(E \cap A^c) \\ &\leq \mu^*\left(\left(\bigcup_{n \geq 1} A_n\right) \cap A\right) + \mu^*\left(\left(\bigcup_{n \geq 1} A_n\right) \cap A^c\right) \\ &= \mu^*\left(\bigcup_{n \geq 1} (A_n \cap A)\right) + \mu^*\left(\bigcup_{n \geq 1} (A_n \cap A^c)\right) \\ &\leq \sum_{n \geq 1} [\mu^*(A_n \cap A) + \mu^*(A_n \cap A^c)] \\ &\leq \sum_{n \geq 1} [\mu(A_n \cap A) + \mu(A_n \cap A^c)] \\ &= \sum_{n \geq 1} \mu(A_n) \leq \mu^*(E) + \varepsilon. \end{aligned}$$

由 $\varepsilon > 0$ 的任意性, $\mu^*(E) = \mu^*(E \cap A) + \mu^*(E \cap A^c)$, 即 $A \in \mathcal{F}_*$. 因此 $\mathcal{E} \subset \mathcal{F}_*$, 进而由于 $\mathcal{F}_*$ 是 σ -代数, 由单调类定理 (见附录 A 定理 A.2.2), $\mathcal{E} \subset \sigma(\mathcal{E}) = \mathcal{F} \subset \mathcal{F}_*$.

最后我们来证明 (3). 设 $B \in \mathcal{F}_*$ 为零测集, 即 $\mu^*(B) = 0$. 设 $A \subset B$, 则

$$0 \leq \mu^*(A) \leq \mu^*(B) = 0,$$

即 $\mu^*(A) = 0$. $\forall E \subset \Omega$, 有 $E \cap A \subset A \subset B$, 从而 $\mu^*(E \cap A) = 0$. 进而

$$\mu^*(E \cap A^c) \leq \mu^*(E) \leq \mu^*(E \cap A) + \mu^*(E \cap A^c) = \mu^*(E \cap A^c),$$

因此 $\mu^*(E) = \mu^*(E \cap A^c) = \mu^*(E \cap A) + \mu^*(E \cap A^c)$. 进而 $A \in \mathcal{F}_*$. 由此可见 $(\Omega, \mathcal{F}_*, \mu^*)$ 是一个完备的测度空间. $\square$

注 4.2. 希腊数学家 *Constantin Carathéodory* (卡拉西奥多里, 1873—1950) 生于柏林, 卒于慕尼黑; 他原籍希腊, 祖先数代前移居土耳其埃迪尔内 (*Edirne*), 他的父亲是土耳其驻圣彼得堡、柏林等地的外交官. 1891—1895 年 *Carathéodory* 在比利时的军事学院学习, 毕业后受雇于英国政府到埃及参加阿斯尤特 (*Asyut*) 水坝的建设. 1900 年返回柏林研究数学. 1902 年到哥廷根, 在 *H. Minkowski* (闵可夫斯基, 1864—1909) 指

导下于 1904 年取得博士学位。后在哥廷根、波恩、汉诺威、布雷斯劳、柏林等地任教。1920 年被希腊政府召回到士麦那筹建大学。1922 年士麦那被土耳其人焚毁，他领导学校将图书馆移至雅典，并在雅典大学任教。1924 年应邀到慕尼黑大学接替 C. L. F. von Lindemann (冯·林德曼; 1852—1939) 任教授。他曾是《数学年刊》杂志的编辑。

Carathéodory 在数学上有多方面的贡献。他发展了变分法，把光滑曲线的理论推广到有角曲线上，特别提出解曲线场的概念。他重新研究变分法与一阶偏微分方程的关系，并应用于解拉格朗日问题。在函数论方面，研究函数值分布论，简化了在单位圆上单连通域的保形变换的主要定理，给出了边界对应的理论。在测度论方面，进行了公理化研究，所提出的测度扩张方法被大学教科书普遍采用。此外，对热力学公理化和狭义相对论也有贡献。

Carathéodory 培养的知名学生有：H. Rademacher (雷德马彻; 1892—1969, 德国出生的美国数学家，研究方向为数学分析和数论), P. Finsler (芬斯勒; 1894—1970; 德国-瑞士数学家，以 Finsler 空间、Hadwiger-Finsler 不等式等知名), H. Boerner (博尔内; 1906—1982; 德国数学家，研究方向为变分、复分析、群表示理论), E. Peschl (佩施尔; 1906—1986; 德国数学家，研究方向为几何复分析、偏微分方程、多变量复分析等), G. Aumann (奥曼; 1906—1980; 德国数学家，以 General topology、Contact relations 方向的研究而知名), W. Seidel (赛德尔; 1907—1981; 俄罗斯出生的德国-美国数学家，以 Seidel 类闻名), N. Terzioglu (1912—1976; 土耳其数学家) 等。

需要指出的是，Carathéodory 扩张在一般情形下并不总是唯一的扩张。

例 4.5. 取 $\mathbb{R}$ 上环 $\mathcal{E} := \{\bigcup_{i=1}^n (a_i, b_i] : n \geq 1, a_i \leq b_i, 1 \leq i \leq n\}$, 则 $\mathcal{B} = \sigma(\mathcal{E})$. 对任意 $A \in \mathcal{E}$, 定义

$$\mu(A) := \begin{cases} 0, & A = \emptyset, \\ \infty, & A \neq \emptyset. \end{cases}$$

则 μ 的 Carathéodory 扩张是 $(\mathbb{R}, \mathcal{B})$ 上奇异测度，对任意 $A \in \mathcal{F}$, $\mu(A)$ 取值情况同上。但是计数测度 $\#(\cdot)$ 无疑也是 μ 的一个扩张，它不同于 Carathéodory 扩张。本例中， μ 在环 $\mathcal{E}$ 上不是 σ -有限的。

♠ **定理 4.2.3. (测度扩张的唯一性)** 给定 Ω 上一个环 $\mathcal{E}$ 及其上一个预测度 μ . 如果这个预测度是 σ -有限的，那么它在 $\mathcal{F} = \sigma(\mathcal{E})$ 上的扩张是唯一的。

证明: 设 μ 有两个扩张 μ_1, μ_2 . 任取 $\Omega_0 \in \mathcal{E}$ 使得 $\mu(\Omega_0) < \infty$, 注意到习题 2.17, 我们断言:

$$\mu_1(A) = \mu_2(A), \quad \forall A \in \Omega_0 \cap \mathcal{F}.$$

事实上，记 $\Omega_0 \cap \mathcal{F} = \{\Omega_0 \cap A : A \in \mathcal{F}\}$, 它可以视为 Ω_0 上的 σ -代数; 令

$$\mathcal{A}_0 := \{A \in \Omega_0 \cap \mathcal{F} : \mu_1(A) = \mu_2(A)\}.$$

容易验证: (i) $\Omega_0 \cap \mathcal{E} \subset \mathcal{A}_0 \subset \Omega_0 \cap \mathcal{F}$; (ii) $\mathcal{A}_0$ 是 Ω_0 上 Dynkin 系。由于 $\Omega_0 \cap \mathcal{E}$ 是 Ω_0 上环，由单调类定理 (见附录 A 定理 A.2.2),

$$\mathcal{A}_0 \supset \lambda_{\Omega_0}(\Omega_0 \cap \mathcal{E}) = \sigma_{\Omega_0}(\Omega_0 \cap \mathcal{E}) = \Omega_0 \cap \sigma_{\Omega}(\mathcal{E}) = \Omega_0 \cap \mathcal{F}.$$

因此 $\mathcal{A}_0 = \Omega_0 \cap \mathcal{F}$, 即断言成立。

由预测度 μ 的 σ -有限性, 存在单调上升集合列 $\{\Omega_n : n \geq 1\} \subset \mathcal{E}$ 满足 $\Omega_n \nearrow \Omega$ 且 $\mu(\Omega_n) < \infty$. 于是对任意 $A \in \mathcal{F}$, $\Omega_n \cap A \in \Omega_n \cap \mathcal{F}$,

$$\mu_1(A) = \lim_{n \rightarrow \infty} \mu_1(\Omega_n \cap A) = \lim_{n \rightarrow \infty} \mu_2(\Omega_n \cap A) = \mu_2(A).$$

从而 $\mu_1 = \mu_2$ 在 $\mathcal{F}$ 上成立。 □

4.2.4 乘积测度空间

设 $(\Omega_k, \mathcal{F}_k, \mu_k), k = 1, 2$ 是两个测度空间, 其中 μ_1, μ_2 都是 σ -有限测度。那么, 如同第三章, 我们可以定义乘积测度空间

$$(\Omega, \mathcal{F}, \mu) := (\Omega_1, \mathcal{F}_1, \mu_1) \otimes (\Omega_2, \mathcal{F}_2, \mu_2)$$

如下。依旧取 $\mathcal{F} := \mathcal{F}_1 \otimes \mathcal{F}_2 = \sigma(\mathcal{F}_1 \times \mathcal{F}_2)$, 取 $\mu := \mu_1 \otimes \mu_2$, 其中 $\mu_1 \otimes \mu_2$ 如下定义:

$$\mu_1 \otimes \mu_2(A_1 \times A_2) := \mu_1(A_1) \cdot \mu_2(A_2), \quad \forall A_1 \in \mathcal{F}_1, A_2 \in \mathcal{F}_2. \quad (4.7)$$

由定理4.2.2及定理4.2.3, 上述方程在 $\mathcal{F}_1 \otimes \mathcal{F}_2$ 上定义了一个唯一的测度。有关论证细节, 请读者参看附录A的 §A.3.1, 在那里我们证明了乘积概率测度的存在唯一性, 那个证明稍加修改后也同样适用于此处。

有了此处的乘积测度空间的手段后, 我们基于一维 Lebesgue 测度, 就可以构建任意有限维欧氏空间中的 Lebesgue 测度了。在不需要强调维度的场合, 这些 Lebesgue 测度我们统一用 Leb 来表达; 而在需要强调维度时, 我们总用 $\text{Leb}^{(n)}$ 来表示 $\mathbb{R}^n$ 上的 Lebesgue 测度。

4.3 欧氏空间中的 Lebesgue 积分

4.3.1 Lebesgue 积分的定义

现在假定 $E \subset \mathbb{R}^d$ 是 Borel 可测集。 $f : E \rightarrow \mathbb{R}$ 是 Borel 可测函数。当 f 满足“适当条件”(后续将明确何为“适当条件”)时, 我们将给出积分 $\int_E f d\text{Leb}$ 的定义; 传统上, 这个积分将被更简单地记作

$$\int_E f dx := \int_E f d\text{Leb},$$

并把它理解为 $\int_E f dx = \int 1_E \cdot f dx$. Lebesgue 本人对他的这一积分思想做过一个生动有趣的描述^[125]: “我必须偿还一笔钱。如果我从口袋中随意地摸出来各种不同面值的钞票, 逐一地还给债主直到全部还清, 这就是 **Riemann** 积分; 不过我还有另外一种做法, 就是把钱全部拿出来并把相同面值的钞票放一起, 然后再一起付出应还的数目, 这就是我的积分”。

$\mathbb{R}^d$ 上 Borel 可测函数关于其上的 Lebesgue 测度 Leb 的 Lebesgue 积分定义的出发点是, 把 Borel 可测集 A 的测度值 (体积) $\text{Leb}(A) = |A|$ 视作可测函数 1_A 关于测度 Leb 的积分:

$$\int 1_A d\text{Leb} = \int 1_A dx := \text{Leb}(A) = |A|. \quad (4.8)$$

在此基础上, 我们意图保持积分的线性性质; 聪明的读者应该看到了此处与泛函中的 Hahn-Banach 延拓方法上的相似之处。

对任意非负简单函数 $f \in \mathcal{S}_+$, 存在有限集 $\{a_k\}_{k=1}^n \subset \bar{\mathbb{R}}_+$ 及互不相交的可测集列 $\{A_k\}_{k=1}^n \subset \mathcal{F}$, 使得 $\mathbb{R}^d = \biguplus_{k=1}^n A_k$ 且 $f = \sum_{k=1}^n a_k 1_{A_k}$. 此时定义

$$\int f dx := \sum_{k=1}^n a_k \cdot |A_k|,$$

称之为 f 的 Lebesgue 积分。此处约定 $0 \cdot \infty = 0$. 不难验证, 映射

$$\mathcal{S}_+ \ni f \mapsto \int f dx$$

是单调且线性的。

对于一般的非负可测函数 $f: \mathbb{R}^d \rightarrow \bar{\mathbb{R}}_+$, 定义

$$\int f dx := \sup \left\{ \int g dx : 0 \leq g \leq f, g \in \mathcal{S}_+ \right\},$$

称之为 f 的 Lebesgue 积分。另一种等价、但相对容易理解的处理是使用函数逼近的思想: 对任意非负可测函数 $f: \mathbb{R}^d \rightarrow \bar{\mathbb{R}}_+$, 可以找到非负简单函数 $f_n \uparrow f$ (比如可以取 $f_n := \frac{\lfloor 2^n \cdot f \rfloor}{2^n} \wedge n$), 定义

$$\int f dx := \lim_{n \rightarrow \infty} \int f_n dx;$$

但在此过程中需要论证极限与序列 f_n 的选取无关, 以保证定义是良性的。容易知道, 在非负可测函数类上, $f \mapsto \int f dx$ 仍然具有单调性和线性性质。

对于一般的可测函数 $f: \mathbb{R}^d \rightarrow \bar{\mathbb{R}}$, 注意到 $f = f^+ - f^-$, 其中 f^+, f^- 分别为 f 的正部和负部, 当 $\int f^+ dx, \int f^- dx$ 两者中至少有一个取有限值时, 称 f 的 Lebesgue 积分有意义 (或有定义), 记作

$$\int f dx := \int f^+ dx - \int f^- dx.$$

当 $\int f^+ dx, \int f^- dx$ 两者均取有限值时, 称 f 是 Lebesgue 可积的, 记作 $f \in L^1(\mathbb{R}^d)$ 或更简单的 $f \in L^1$; 这也等价于 $\int |f| dx < \infty$.

另外, f 在 $E \in \mathcal{F}$ 上的 Lebesgue 积分记为 $\int_E f dx := \int 1_E \cdot f dx$.

4.3.2 Lebesgue 积分与极限的交换

本小节我们探讨欧氏空间上的 Lebesgue 积分与极限的交换问题, 即探讨

$$\lim_{n \rightarrow \infty} \int f_n dx = \int \lim_{n \rightarrow \infty} f_n dx$$

成立的 (充分) 条件, 最终得到 Levi 单调收敛定理、Fatou 引理、Lebesgue 控制收敛定理三个重要结论。它们配合本节中最后一小节的 Fubini 定理基本上就能解决大多数实际问题中提出的积分与极限的交换问题 (含两重积分的交换问题)。

从积分的定义出发不难验证积分的单调性: 如果 $f \leq g$ 且两个函数的积分都存在, 则 $\int f dx \leq \int g dx$. 进一步有下面的 Levi 单调收敛定理:

♠ **定理 4.3.1.** (Levi 单调收敛定理) 设 $\{f_n\}_{n=1}^\infty$ 为一列非负可测函数, 且存在可测函数 f 使得 $f_n \nearrow f$. 那么 $\lim_{n \rightarrow \infty} \int f_n dx = \int f dx$.

证明: 由单调性, 显然数列 $\{\int f_n dx\}_{n=1}^\infty$ 有 (广义) 非负极限, 且

$$\int f dx \geq \lim_{n \rightarrow \infty} \int f_n dx.$$

不妨设 $\int f dx < \infty$. 现在任取非负简单函数 $g \leq f$ 以及正实数 $\lambda \in (0, 1)$, 令 $A_n := \{x \in \mathbb{R}^d : f_n(x) \geq \lambda \cdot g(x)\}$. 注意到 $g \leq f, f_n \leq f, f_n \nearrow f$, 显然有 $A_n \nearrow \mathbb{R}^d$. 于是

$$\int f_n dx \geq \int f_n \cdot 1_{A_n} dx \geq \lambda \int g \cdot 1_{A_n} dx.$$



图 4.4: Levi(1875—1961)

由于 g 是非负简单函数,

$$\lim_{n \rightarrow \infty} \int f_n dx \geq \lim_{n \rightarrow \infty} \lambda \int g \cdot 1_{A_n} dx = \lambda \int g dx;$$

最后的等号利用了积分在 S_+ 上的线性性质及测度 Leb 的下连续性. 由 λ 的任意性,

$$\lim_{n \rightarrow \infty} \int f_n dx \geq \int g dx.$$

再由 $\int f dx$ 的定义立得

$$\lim_{n \rightarrow \infty} \int f_n dx \geq \int f dx.$$

$\int f dx = \infty$ 情形的证明可以类似实现, 细节留给读者. $\square$

利用上面的单调收敛定理, 容易证明积分具有线性性: 如果 f, g 均可积, 则对任意实数 α, β ,

$$\int [\alpha f + \beta g] dx = \alpha \int f dx + \beta \int g dx.$$

注 4.3. 上面定理中的 *Levi* 是意大利数学家 *Beppo Levi* (列维, 1875—1961), 而不是法国数学家 *Paul Lévy* (莱维, 1886—1971), 也不是意大利数学家 *E. E. Levi* (莱维, 1883—1917) 或另一个意大利数学家、物理学家 *Tullio Levi-Civita* (列维-奇维塔, 1873—1941). *Beppo Levi* 以其单调收敛定理闻名, 他出生在 *Turin*, 21 岁获得博士学位, 几年后在 *Plaisance* 大学任教授, 后加入 *Cagliari* 大学. 由于他的犹太人身份, 1938 年被墨索里尼政府废除公职. 之后他移民到阿根廷, 在当地建立数学系, 创办数学杂志.

上面的单调收敛定理说明了: 在被积函数列非负且单调上升这一特殊情况下, 积分与极限可以交换. 如果被积函数列仅仅有非负性, 而没有单调性质时, 下面的 *Fatou* 引理就非常有用.

定理 4.3.2. (*Fatou* 引理) 设 $\{f_n\}_{n=1}^\infty$ 为一列非负可测函数, 那么

$$\liminf_{n \rightarrow \infty} \int f_n dx \geq \int \liminf_{n \rightarrow \infty} f_n dx.$$

证明: 令 $g_n := \inf\{f_k : k \geq n\}$. 于是 $\{g_n\}_{n=1}^\infty$ 是一个单调递增的非负可测函数列, 且 $g_n \leq f_n$. 于是由单调收敛定理

$$\int (\liminf_{n \rightarrow \infty} f_n) dx = \int (\lim_{n \rightarrow \infty} g_n) dx = \lim_{n \rightarrow \infty} \int g_n dx \leq \liminf_{n \rightarrow \infty} \int f_n dx.$$

$\square$

下面的 *Lebesgue* 控制收敛定理是用来处理函数极限与积分交换关系的重要工具, 需要重点掌握, 学会应用.

♠ 定理 4.3.3. (Lebesgue 控制收敛定理) 设 $\{f_n\}_{n=1}^{\infty}$ 为一列几乎处处 (或依测度) 收敛于 f 的可测函数, 且存在可测函数 $g \in L^1$ 使得 $|f_n| \leq g$. 那么

$$\lim_{n \rightarrow \infty} \int f_n dx = \int \lim_{n \rightarrow \infty} f_n dx.$$

证明: 记 $f = \lim_{n \rightarrow \infty} f_n$. 因 $\{g + f_n\}_{n=1}^{\infty}$ 与 $\{g - f_n\}_{n=1}^{\infty}$ 都是非负可测函数列, 对前者利用 Fatou 引理及 g 的可积性

$$\int (g + f) dx = \int \left[\lim_{n \rightarrow \infty} (g + f_n) \right] dx \leq \lim_{n \rightarrow \infty} \int (g + f_n) dx = \int g dx + \lim_{n \rightarrow \infty} \int f_n dx.$$

$$\text{由此 } \int f dx \leq \lim_{n \rightarrow \infty} \int f_n dx.$$

同理对 $\{g - f_n\}_{n=1}^{\infty}$ 利用 Fatou 引理可得 $\overline{\lim}_{n \rightarrow \infty} \int f_n dx \leq \int f dx$. 由此

$$\lim_{n \rightarrow \infty} \int f_n dx = \int f dx. \quad \square$$

📌 注 4.4. 上面定理中出现的 Fatou 和 Lebesgue 都是法国数学家。

微积分从它诞生时起, 主要是处理光滑曲线和可导函数的。但 1872 年 7 月 18 日德国大数学家 Weierstrass 在柏林科学院的一次讲演中给出了一族处处连续、处处不可导的函数

$$f(x) = \sum_{n=0}^{\infty} b^n \cos(a^n \pi x).$$

Direchlet 同样举出了在无理点取值 0、有理点取值 1 的极端病态函数; 众多的病态函数破坏了 Riemann 意义下的可积性, 因而有必要给出 Riemann 可积性的完整刻画讨论。

Henri Léon Lebesgue (勒贝格, 1875—1941) 生于博韦 (Beauvais), 卒于巴黎。他在 1894 年考入巴黎高等师范学校, 1897 年大学毕业后在该校图书馆工作了两年。他是法国数学家 E. Borel (博雷尔, 1871—1956) 的学生。Lebesgue 从 1899 年到 1902 年在 Nancy 的一所中学任教, 虽然工作繁忙, 但仍孜孜不倦地研究有关积分的理论, 并于 1902 年发表了博士论文“积分、长度、面积” (Intégrale, longueur, aire), 同年在 Sorbonne 巴黎大学理学院通过博士学位。在这篇文章中, Lebesgue 创立了后来以他的名字命名的积分理论, 它能很好的讨论病态函数的积分问题。Lebesgue 积分一出现就用来研究三角级数, 由此人们可以得到函数可展为三角级数的更弱的充分条件, 接着导数的概念也得到推广, 一门微积分的延续学科——实变函数论在 Lebesgue 手中诞生了。

Lebesgue 的工作一开始并未得到人们的一致赞成, 反对病态函数的人到处都是; 当时很多人认为病态函数是“一种变态的不健康的函数”、“一种学究式的数学游戏”。法国著名数学家 Poincaré (庞加莱, 1854—1912) 认为, “逻辑有时产生怪物, 过去人们为了一个实际的目的而创造一个新的函数; 今天人们为了说明先辈在推理方面的不足而故意造出这些函数来, 而从这些函数所能推出来的也就是仅此而已。”当时, 批评病态函数最严厉的是法国数学家 C. Hermite (埃尔米特, 1822—1901), 他在一封信中说“我怀着惊恐的心情对不可导函数的令人痛惜的祸害感到厌恶”^[13]直到 1910 年, Lebesgue 才被同意进入巴黎大学理学院工作, 1921 年起才进入法兰西学院任教授, 次年进入巴黎科学院。这时 Lebesgue 已经 47 岁, 距离他 27 岁发表博士论文已经足足 20 年。

到 20 世纪 30 年代, Lebesgue 积分已经成熟, 并在概率论、谱理论、泛函空间等方面获得广泛应用。时至今日, 连工程师也不得不接触病态函数、谈论抽象积分。历史是一面镜子, 科学体系中内部矛盾所提出的理论问题, 有时会成为这门学科的生长点。但理论问题也不是越抽象越好, Lebesgue 就曾经这样告诫自己: “搞出过于一般的理论, 数学将会变成没有内容的漂亮的形式, 而这将会很快死亡。”

Lebesgue 培养的知名学生有: P. Montel (蒙特尔; 1876—1975; 法国数学家, 专长为复分析中的全纯函数, 以 Montel 定理、Montel 空间等闻名), Z. Janiszewski (亚尼塞夫斯基; 1888—1920; 波兰数学家, 以 Janiszewski



图 4.5: Lebesgue(1875 — 1941)



图 4.6: Fatou(1878-1929)

定理和 *Brouwer-Janiszewski-Knaster* 连续统闻名), *G. de Rham* (德拉姆; 1903—1990; 瑞士数学家, 因对微分拓扑方向的贡献而闻名于世) 等。

Pierre Joseph Louis Fatou (法图, 1878—1929) 生于洛里昂 (*Lorient*), 卒于波尔尼谢 (*Pornichet*)。他在 1898 年就学于巴黎高等师范学校, 1907 年获博士学位, 指导老师是 *P. Painlevé* (1863—1933; 法国数学家、政治家, 以微分方程理论中的 *Painlevé* 性质等闻名); 之后长期在巴黎天文台供职。对 *Taylor* 级数、亚纯函数、*Lebesgue* 积分等方面的问题有论述, 得到 *Lebesgue* 积分的一些基本结果; 在复动力系统中, *Fatou* 集 (*Julia* 集的余集) 就是以他的名字命名。他还在天文学上用概率方法对恒星与行星的位置测定、双星测量、天文仪器常数等进行过研究。

4.3.3 Lebesgue 积分与 Riemann 积分

在分析学中我们曾经学习过欧氏空间上的 *Riemann* 积分的定义。现在, 欧氏空间上可测函数关于 *Lebesgue* 测度 (记为 *Leb*) 的积分也已给出定义, 称之为 *Lebesgue* 积分。很自然要研究它们之间的关系。

本小节我们将证明: 有界区间上 *Riemann* 可积蕴涵 *Lebesgue* 可积, 且此时两种积分值相同。

♠ **定理 4.3.4.** 设 $I = [a, b]$ 为 $\mathbb{R}$ 中有界区间, $f : I \rightarrow \mathbb{R}$ 为 *Riemann* 可积函数。那么 f 也是 *Lebesgue* 可积的, 并且

$$\int_I f d\text{Leb} = \int_a^b f(x) dx.$$

证明: 回忆 *Riemann* 积分的定义, 在 *Darboux* 大和、*Darboux* 小和的极限值存在、有限且相等的前提下, *Riemann* 积分就定义为这一共同极限值, 并称对应函数 *Riemann* 可积。由于 f 是 *Riemann* 可积的, 因此它在区间 $I = [a, b]$ 上有界。于是不妨假设 $f \geq 0$ (否则考虑 $f + \|f\|_\infty \geq 0$)。设有一列逐渐加细的分

割 $\{\Delta_n : n \geq 1\}$, 其中 Δ_n 设为以下诸分点所成的有序集

$$a = t_0^{(n)} < t_1^{(n)} < \cdots < t_{\ell_n}^{(n)} = b.$$

定义 $\|\Delta_n\| := \max\{t_k^{(n)} - t_{k-1}^{(n)} : k = 1, \dots, \ell_n\}$. 下面定义

$$\bar{f}_n(t) := \sum_{k=1}^{\ell_n} \sup f([t_{k-1}^{(n)}, t_k^{(n)})) \cdot 1_{\{t_{k-1}^{(n)} \leq t < t_k^{(n)}\}} + f(b) \cdot 1_{\{t=b\}},$$

$$\underline{f}_n(t) := \sum_{k=1}^{\ell_n} \inf f([t_{k-1}^{(n)}, t_k^{(n)})) \cdot 1_{\{t_{k-1}^{(n)} \leq t < t_k^{(n)}\}} + f(b) \cdot 1_{\{t=b\}}.$$

显然, f 关于分割 Δ_n 的 Darboux 大和、小和分别为

$$\bar{S}(f; \Delta_n) := \sum_{k=1}^{\ell_n} \sup f([t_{k-1}^{(n)}, t_k^{(n)})) \cdot [t_k^{(n)} - t_{k-1}^{(n)}] = \int_I \bar{f}_n d\text{Leb}, \quad (4.9)$$

$$\underline{S}(f; \Delta_n) := \sum_{k=1}^{\ell_n} \inf f([t_{k-1}^{(n)}, t_k^{(n)})) \cdot [t_k^{(n)} - t_{k-1}^{(n)}] = \int_I \underline{f}_n d\text{Leb}. \quad (4.10)$$

由于 Δ_{n+1} 是 Δ_n 的加细, 显然有 $\underline{f}_n \leq \underline{f}_{n+1} \leq f \leq \bar{f}_{n+1} \leq \bar{f}_n$. 从而存在可测函数 $\underline{f}, \bar{f}$ 使得 $\underline{f}_n \uparrow \underline{f}$ 以及 $\bar{f}_n \downarrow \bar{f}$. 由此 $\underline{f}_n \leq f \leq \bar{f}_n$. 继而由 f 的 Riemann 可积性, $\lim_{n \rightarrow \infty} \bar{S}(f; \Delta_n) = \lim_{n \rightarrow \infty} \underline{S}(f; \Delta_n) =: \int_a^b f(x) dx$, 我们有

$$\int_I (\bar{f} - \underline{f}) d\text{Leb} \leq \int_I (\bar{f}_n - \underline{f}_n) d\text{Leb} = \bar{S}(f; \Delta_n) - \underline{S}(f; \Delta_n) \rightarrow 0.$$

这表明 $\bar{f} = \underline{f}$ 在 I 上 Leb-a.e. 成立, 进而 $\bar{f} = \underline{f} = f$ 在 I 上 Leb-a.e. 成立. $\bar{f}, \underline{f}$ 的 Lebesgue 可积性说明了 f 的 Lebesgue 可积性, 由此立即知道定理中方程成立. $\square$

上面的定理说明, 在有界闭区间上, 一个 Riemann 可积函数 (比如连续函数) 一定是 Lebesgue 可积的, 并且这两种积分值相等; 在此意义下, 人们通常认为 Lebesgue 积分是 Riemann 积分的推广¹.

例 4.6. Dirichlet 函数为 $D(x) := 1_{\mathbb{Q} \cap [0,1]}(x)$. 则它在区间 $I := [0, 1]$ 上是 Lebesgue 可积: $\int_0^1 D(x) d\text{Leb} = 0$, 但不 Riemann 可积:

$$\int_I \bar{D}(x) d\text{Leb} = 1, \int_I \underline{D}(x) d\text{Leb} = 0.$$

¹ 借用文献^[60]的第 97 页中观点: Riemann 积分需要考虑逐渐加细的垂直条带, 反映定义域中的几何特性; 而 Lebesgue 积分需要考虑逐渐加细的水平条带, 反映值域中的几何特性. 而对于被积函数而言, 值域的几何性质通常好于定义域的. 这是“推广”能成功的底层逻辑。

Lebesgue 实际上证明了下面的定理, 从而彻底解决了 Riemann 可积函数的刻画问题。

♠ **定理 4.3.5.** 在有界闭区间上, 一个有界可测函数是 *Riemann* 可积的, 当且仅当它的不连续点全体是 *Lebesgue* 零测集。

因而, 人们在书写积分表达式时也经常把微元 dx 视作 $d\text{Leb}$ 而不加区分是 Lebesgue 积分还是 Riemann 积分。但实际上严格意义下来说, 这个书写习惯略有瑕疵。

为了证明这个定理, 我们需要下面的引理。

◆ **引理 4.3.1.** 设 $f: [a, b] \rightarrow \mathbb{R}$ 是有界可测函数。定义 f 在 $I := [a, b]$ 上的振幅函数 ω_f 如下

$$\omega_f(x) := \lim_{\delta \downarrow 0} \sup_{x_1, x_2 \in B(x, \delta) \cap I} |f(x_1) - f(x_2)|. \quad (4.11)$$

则 $\omega_f(x)$ 是一个有界可测函数, 并且

$$\int_a^b \omega_f(x) dx = \bar{S}(f) - \underline{S}(f),$$

其中, 记 $\bar{S}(f; \Delta)$ 、 $\underline{S}(f; \Delta)$ 分别为 f 关于 I 的有限分割 Δ 的 *Darboux* 大和、小和 (见(4.9)、(4.10)),

$$\bar{S}(f) := \sup\{\bar{S}(f; \Delta) : \Delta \text{ 为 } I \text{ 的有限分割}\},$$

$$\underline{S}(f) := \inf\{\underline{S}(f; \Delta) : \Delta \text{ 为 } I \text{ 的有限分割}\}$$

证明: 如定理4.3.4的证明中的符号设置, 取一系列逐渐加细的分割 $\{\Delta_n : n \geq 1\}$ (其中 Δ_n 也同时视作对应分割点的集合), 定义 $E = \bigcup_{n=1}^{\infty} \Delta_n$,

$$\omega_n(x) := \begin{cases} \bar{f}_n(x) - \underline{f}_n(x), & \text{如果 } x \in I \setminus \Delta_n, \\ 0, & \text{如果 } x \in \Delta_n. \end{cases}$$

那么容易知道

$$\omega_f(x) \cdot 1_{I \setminus E}(x) = \lim_{n \rightarrow \infty} \omega_n(x) = [\bar{f}(x) - \underline{f}(x)] \cdot 1_{I \setminus E}(x).$$

注意到 $0 \leq \omega_n(x) \leq 2 \sup\{|f(x)| : x \in I\} < \infty$ 以及

$$\int_I \bar{f}_n(x) d\text{Leb} = \bar{S}(f; \Delta_n) \rightarrow \bar{S}(f),$$

$$\int_I f_{-n}(x) d\text{Leb} = \underline{S}(f; \Delta_n) \rightarrow \underline{S}(f),$$

由控制收敛定理就立即得到引理的结论。 $\square$

由上述引理就可以立即证明 Lebesgue 对有界区间上 Riemann 可积函数的刻画定理 4.3.5, 有关证明细节就留给读者。

例 4.7. $I := [0, 1]$, 其上 Riemann 函数定义为

$$R(x) := \begin{cases} \frac{1}{q}, & \text{如果 } x = \frac{p}{q} \in I \cap \mathbb{Q}, \text{ 其中 } p, q \text{ 是互素的自然数,} \\ 0, & \text{如果 } x \in I \setminus \mathbb{Q}. \end{cases}$$

则它在 I 上既是 Lebesgue 可积的, 也是 Riemann 可积的, 且积分值为 0。

在无穷区间上, 情况有所不同。下面就是一个 Riemann 可积但 Lebesgue 积分不存在的例子, 原因就在于它不是有界闭区间上的积分。

例 4.8. 考虑函数 $f(x) := \frac{\sin x}{x}, x \in \mathbb{R}$ (在 $x = 0$ 处, $f(0) := 1$)。设 Leb 是 $\mathbb{R}$ 上 Lebesgue 测度, 则易验证 $\int f^+ d\text{Leb} = \int f^- d\text{Leb} = \infty$, 从而 f 的 Lebesgue 积分不存在。而由数学分析中的结论, f 是 Riemann 可积的, 且

$$\int_{-\infty}^{\infty} \frac{\sin x}{x} dx = \pi. \quad (4.12)$$

上面的积分结果就是著名的 Riemann-Lebesgue 引理。我们在本书第十一章特征函数的唯一性定理的证明部分需要用到这一结果。

读者不难证明下面讨论广义 Riemann 可积与 Lebesgue 可积的结果。

♠ 定理 4.3.6. 设 $f: [a, \infty) \rightarrow \mathbb{R}$ 是可测函数, 且它的不连续点全体是 Lebesgue 零测集, 并且在任何有界闭区间 $[a, b]$ 上它都是有界函数。那么 f 在在区间 $[a, \infty)$ 上 Lebesgue 可积的充要条件是它的广义 Riemann 积分绝对收敛; 此时它的 Lebesgue 积分值与广义 Riemann 积分值相等:

$$\int_a^\infty f d\text{Leb} = \int_a^\infty f dx.$$

📌 注 4.5. Isaac Newton (牛顿, 1643—1727; 英国)、Gottfried Wilhelm Leibniz (莱布尼茨, 1646—1716; 德国) 在 17 世纪末就各自独立地给出了定积分的定义。¹但是定积分的现代数学定义却是用 Riemann 和的极限给出。

¹根据 Newton 周围的人所述, Newton 要比 Leibniz 早几年得出他的方法; 但在 1693 年以前 Newton 几乎没有发表任何相关内容, 并直至 1704 年他才给出了其完整的叙述。其间, Leibniz 已在 1684 年发表了他的方法的完整叙述。此外, Leibniz 的符号和“微分法”被欧洲大陆全面地采用; 在大约 1820 年以后, 英国也采用了该方法。



图 4.7: Newton(1643-1727)



图 4.8: Leibniz(1646-1716)



图 4.9: Riemann(1826-1866)



图 4.10: Darboux(1842-1917)

G. F. B. Riemann (黎曼, 1826—1866) 是德国著名的数学家, 他在数学分析和微分几何方面作出过重要贡献, 开创了黎曼几何, 并且给后来爱因斯坦的广义相对论提供了数学基础; 数论中著名的黎曼猜想也是他提出的。*Riemann* 出生于汉诺威王国 (今德国) 的小镇布列斯伦茨 (*Breselenz*), 父亲是当地的路德会牧师。1846 年, 他进入哥廷根大学学习哲学和神学。在此期间他去听了一些数学讲座, 包括 *C. F. Gauss* (高斯, 1777—1855; 德国) 关于最小二乘法的讲座。在得到父亲的允许后他改学数学, 成为 *Gauss* 晚年的学生。1847 年春, *Riemann* 转到柏林大学, 投入 *C. G. J. Jacobi* (雅可比, 1804—1851; 德国)、*P. G. L. Dirichlet* (狄利克雷, 1805—1859; 德国) 和 *J. Steiner* (施泰纳, 1796—1863; 瑞士) 门下, 两年后回到哥廷根。1851 年 *Riemann* 在柏林大学获博士学位; 1854 年成为哥廷根大学的讲师, 1857 年升为哥廷根大学的编外教授, 1859 年接替 *Dirichlet* 成为教授。1866 年 7 月 20 日, 他在第三次去意大利休养的途中因肺结核在塞拉斯卡 (*Selasca*) 去世。

Riemann 培养的知名学生有: *E. Selling* (塞林; 1834—1920; 德国数学家, 计算器发明者之一)、*G. A. Roch* (罗奇; 1839—1866; 德国数学家, 以 *Riemann-Roch* 定理闻名)。

J. G. Darboux (达布, 1842—1917) 是法国数学家, 在数学分析 (积分、偏微分方程) 和微分几何 (曲线和曲面的研究) 等方向做出了重要贡献。他生于尼姆 (*Nimes*), 卒于巴黎。*Darboux* 幼年丧父, 家境清贫, 但他勤奋好学, 上完中学后, 1861 年以名列榜首的骄人成绩考入巴黎高等师范学校学习, 大学四年级时就脱颖而出, 发表了一篇关于正交曲面的论文, 1864 年大学毕业后留校任教并攻读博士学位, 1866 年 7 月获博士学位, 导师是 *Michel Floréal Chasles* (查斯勒, 1793—1880; 法国数学家, *Poisson* 的学生, 以射影几何中的多个 *Chasles* 定理知名)。之后他相继在两所中学及法兰西学院、巴黎大学、索邦大学、巴黎高等师范学校任教, 1880 年起成为巴黎高等师范学校的教授。1889—1903 年任巴黎大学理学院院长, 后任名誉院长。1884 年当选为法国科学院院士。1895 年被选为彼得堡科学院通讯院士。他同时还被聘为英国皇家学会会员和其他国家科学会的会员, 并荣获国内外许多大学的名誉学位。

Darboux 培养的知名学生有: E. Picard (皮卡, 1856—1941; 法国数学家, 以他的姓氏命名的数学结果有: Picard 函子、Picard 群、Picard 定理、Picard-Lefschetz 公式、Picard-Lindelöf 定理等), T. Stieltjes (斯蒂尔切斯, 1856—1894; 荷兰数学家, 矩问题的先驱, 对连分数研究也有贡献, 以 Riemann-Stieltjes 积分闻名), E. Goursat (古尔萨, 1858—1936; 法国数学家, 二十世纪初出版了数学分析、复分析方面的经典教材 *Cours d'analyse mathématique*), S. Zaremba (1863—1942; 波兰数学家, 工程师), E. Cartan (嘉当, 1869—1951; 法国数学家, 在 Lie 群、微分系统和微分几何方面有奠基性的工作), E. Borel (博雷尔, 1871—1956; 法国数学家、政治家), G. Tîrteica (1873—1939; 罗马尼亚数学家, 在几何学方面有重要贡献, 被认为是微分几何罗马尼亚学派的创始人) 等。

4.3.4 微积分基本定理的探讨

在定义了 Lebesgue 积分后, 对于 $\mathbb{R}$ 上任意可积的可测函数 ρ 以及 $a, b \in \mathbb{R}, a < b$, 我们可以定义

$$F(x) := \int_a^x \rho(u) du, \quad x \in [a, b].$$

实变函数告诉我们, 此时 F 的导函数 F' 在 Lebesgue 几乎处处意义下存在, 并且 $F' = \rho$ 几乎处处成立。于是此时有

$$\int_a^b F'(x) dx = F(b) - F(a),$$

即微积分基本定理成立——只不过我们把左边的积分按照 Lebesgue 积分而不是 Riemann 积分的意义来理解; 也就是说, 微积分基本定理在更广的意义下成立。

现在我们的问题是: 对什么样的 F , 下述形态的微积分基本定理成立

$$\int_a^x F'(u) du = F(x) - F(a), \quad \forall x \in [a, b]. \quad (4.13)$$

实变函数论最终给出的回答是: 当 F 是 $[a, b]$ 上的有界变差函数时, 导函数 F' 在 Lebesgue 几乎处处意义下存在; 进一步, 微积分基本定理(4.13)成立, 当且仅当 F 是 $[a, b]$ 上的绝对连续函数; 此处有关概念将在下文中给出。

定义 4.3.1. 给定实值函数 $f: [a, b] \rightarrow \mathbb{R}$, 做划分 $\Delta: a = x_0 < x_1 < \cdots < x_n = b$, 并定义

$$V_\Delta(f) := \sum_{i=1}^n |f(x_i) - f(x_{i-1})|.$$

令 $\bigvee_a^b f := \sup\{V_\Delta(f) : \Delta \text{ 为 } [a, b] \text{ 的划分}\}$. 我们称 $\bigvee_a^b f$ 为 f 在 $[a, b]$ 上的全变差, 当这个全变差有限时, 我们称 f 为 $[a, b]$ 上的有界变差函数。 $[a, b]$ 上的有界变差函数全体记作 $BV([a, b])$.

关于有界变差函数, 实变函数的理论告诉我们下面的结果。

♠ **定理 4.3.7.** 给定 $\mathbb{R}$ 中实数 $a < b$. 对函数 $f: [a, b] \rightarrow \mathbb{R}$, 以下结论成立:

(1) 如果 f 是单调函数, 那么 $f \in \text{BV}([a, b])$;

(2) $\text{BV}([a, b])$ 是一个线性空间;

(3) 当 f 是 Lipschitz 函数时, $f \in \text{BV}([a, b])$, 且 $\bigvee_a^b f \leq \text{Lip}(f) \cdot (b - a)$;

(4) 如果 $a < c < b$, $f \in \text{BV}([a, b])$, 则 $\bigvee_a^b f = \bigvee_a^c f + \bigvee_c^b f$;

(5) (Jordan 分解定理) $f \in \text{BV}([a, b])$, 当且仅当存在单调递增函数 g, h 使得 $f = g - h$. 事实上, 当 $f \in \text{BV}([a, b])$ 时, 可以取

$$g(x) := \frac{1}{2} \left[\bigvee_a^x f + f(x) \right], \quad h(x) := \frac{1}{2} \left[\bigvee_a^x f - f(x) \right].$$

(6) 如果 $f \in \text{BV}([a, b])$, 那么 f' 几乎处处存在, 并且 f' 可积。当 f 为单调上升函数时, $\int_a^x f'(u) du \leq f(x) - f(a)$, $\forall x \in [a, b]$.

设 μ 是 $[a, b]$ 上的一个只取有限值的符号测度, 定义

$$f(x) := \mu([a, x]), x \in [a, b],$$

则: (1) 当 μ 是非负测度时, f 是单调递增、右连续函数; (2) 对于有限的符号测度 μ , 总有 $f \in \text{BV}([a, b])$; (3) 通过 μ 的 Hahn 分解可以建立 f 的 Jordan 分解: 我们可以取上述定理 (5) 中的函数 g, h 如下:

$$g(x) = \mu^+([a, x]), \quad h(x) = \mu^-([a, x]), \quad \forall x \in [a, b].$$

定义 4.3.2. 给定实值函数 $f: [a, b] \rightarrow \mathbb{R}$. 如果对任给 $\varepsilon > 0$, 存在 $\delta > 0$, 使得: 对任意有限个不交开区间的并 $I = \bigcup_{i=1}^n (a_i, b_i) \subset [a, b]$, 当 $|I| < \delta$ 时就有

$\sum_{i=1}^n |f(b_i) - f(a_i)| < \varepsilon$, 那么我们称 f 是 $[a, b]$ 上的绝对连续函数。

不难知道, 绝对连续函数是有界变差的连续函数; 但有界变差的连续函数未必是绝对连续函数。

对于单调递增、右连续函数 F , 我们可以定义测度 μ_F :

$$\mu_F((\alpha, \beta]) = F(\beta) - F(\alpha), \quad a \leq \alpha < \beta \leq b.$$

Carathéodory 扩张的理论告诉我们上述定义给出了 $[a, b]$ 上的一个有限测度。此时, F 的绝对连续性, 也等价于测度 μ_F 具有如下的一种“连续性”: 对任意开集列 $I_n \subset [a, b]$, $|I_n| \rightarrow 0$ 时也必定有 $\mu_F(I_n) \rightarrow 0$. 回忆物理学中物质的密度概念: 单位体积内的质量称为密度; 这一点态密度的概念将意味着, 具有密度函数的物质应当具有如下的“连续性”: 当以任一固定点为中心的区域的体积足够小时, 该区域内的物质的质量也必定充分小。这一物质的“连续性”是该物质的密度函数存在的必要条件。实变函数论及测度论告诉我们, 该条件也是充分的, 并且这一条件有更简单的等价形式 (的静态) 刻画: 测度 μ_F 关于 Lebesgue 测度绝对连续, 记作 $\mu_F \ll \text{Leb}$.

定义 4.3.3. 称 $\mathbb{R}^d$ 上 (σ -有限的) 测度 μ 关于 Lebesgue 测度绝对连续, 记作 $\mu \ll \text{Leb}$, 如果 Leb-零测集都是 μ -零测集, 亦即: $\forall A \in \mathcal{B}^n, \text{Leb}(A) = 0$ 蕴含了 $\mu(A) = 0$.

$\mathbb{R}^d$ 上 (σ -有限的) 符号测度 μ 关于 Lebesgue 测度绝对连续, 记作 $\mu \ll \text{Leb}$, 如果全变差测度满足 $|\mu| \ll \text{Leb}$.

在下面定理中我们仅表述了一维的结果; 据说这个定理是 G. Vitali (维塔利, 1875 — 1932; 意大利) 的贡献。

♠ **定理 4.3.8.** 给定 $\mathbb{R}$ 中实数 $a < b$. 设 $F : [a, b] \rightarrow \mathbb{R}$ 是实函数。那么存在 $\rho \in L^1([a, b])$ 使得

$$\int_a^x \rho(u) du = F(x) - F(a), \quad \forall x \in [a, b]$$

的充分必要条件是: F 是绝对连续函数。此时, Lebesgue 几乎处处成立 $\rho = F'$, 进而微积分基本定理成立:

$$\int_a^x F'(u) du = F(x) - F(a), \quad \forall x \in [a, b].$$



图 4.11: Vitali(1875-1932)

4.3.5 重积分与累次积分 — Fubini 定理

在 Riemann 积分框架下, 数学分析中研究了何时重积分可以化为累次积分, 由此也探讨了两重积分能够交换积分次序的条件; 在那里的讨论是比较繁杂的。在 Lebesgue 积分框架下, 也有类似的重积分化为累次积分以及两重积分何时能交换积分次序的问题, 但此时的讨论就非常清爽, 最终的结果统一成如下的 Fubini 定理。



图 4.12: Fubini(1879-1943)

♠ **定理 4.3.9.** (Fubini 定理) 设 $f: \mathbb{R}^m \times \mathbb{R}^n \rightarrow \mathbb{R}$ 是非负可测函数 (或 $f \in L^1(\mathbb{R}^{m+n})$), 那么

$$\begin{aligned} \int_{\mathbb{R}^m \times \mathbb{R}^n} f(x, y) dx dy &= \int_{\mathbb{R}^n} \left[\int_{\mathbb{R}^m} f(x, y) dx \right] dy \\ &= \int_{\mathbb{R}^m} \left[\int_{\mathbb{R}^n} f(x, y) dy \right] dx. \end{aligned}$$

证明思想: 为了方便, 记 $\mathbb{R}^n$ 中的 Lebesgue 测度为 $\text{Leb}^{(n)}$. 这样, 定理的结论就可以表述为

$$\int f(x, y) d\text{Leb}^{(m)} \otimes \text{Leb}^{(n)} = \int \left[\int f(x, y) d\text{Leb}^{(m)} \right] d\text{Leb}^{(n)} \quad (4.14)$$

$$= \int \left[\int f(x, y) d\text{Leb}^{(n)} \right] d\text{Leb}^{(m)}. \quad (4.15)$$

Step 1. 对于 $A \in \mathcal{B}^m, B \in \mathcal{B}^n$, 改写下方方程

$$\text{Leb}^{(m)} \otimes \text{Leb}^{(n)}(A \times B) = \text{Leb}^{(m)}(A) \cdot \text{Leb}^{(n)}(B)$$

为积分

$$\begin{aligned} \int 1_{A \times B}(x, y) d\text{Leb}^{(m)} \otimes \text{Leb}^{(n)} &= \int \left[\int 1_{A \times B}(x, y) d\text{Leb}^{(m)} \right] d\text{Leb}^{(n)} \\ &= \int \left[\int 1_{A \times B}(x, y) d\text{Leb}^{(n)} \right] d\text{Leb}^{(m)}. \end{aligned}$$

即方程(4.14)、(4.15)对于 $f = 1_{A \times B}$ 成立。单调类方法将能证明方程(4.14)、(4.15)对于 $f = 1_E$ 成立, 只要 $E \in \mathcal{B}^{m+n}$.

Step 2. 利用 Lebesgue 积分的定义与性质, 立即知道方程(4.14)、(4.15)对于非负可测函数 f 成立;

Step 3. 进一步, 利用 $f = f^+ - f^-$, 立即知道方程(4.14)、(4.15)对于可测函数 $f \in L^1(\mathbb{R}^{m+n})$ 成立。□

注 4.6. Guido Fubini (富比尼, 1879/01/19—1943/06/06; 意大利) 生于威尼斯, 卒于美国纽约。他中学毕业后到比萨继续深造。1901 年起先后在热那亚 (Genoa) 大学和都灵 (Turin) 大学讲授数学分析; 1938 年因法西斯政府的民族歧视法令而被迫离职, 次年移居美国, 任职于普林斯顿高等研究院。

4.4 抽象测度的 Lebesgue 积分

4.4.1 抽象测度的 Lebesgue 积分的定义

上一节欧氏空间的 Lebesgue 积分的理论可以几乎完全平行地发展为一般的测度空间上的 Lebesgue 积分理论。当然, 在微积分基本定理的处理上就略微不太一样了; 测度论中在此处的对应是发展出了所谓的 (一个测度关于另一个测度的) Radon-Nikodym 导数来代替通常的 (函数的) 导数, 从而也有类似于微积分基本定理的探讨; 有关讨论见本章内的后续几个小节。

给定测度空间 $(\Omega, \mathcal{F}, \mu)$. 我们按照以下流程定义可测函数 $f: \Omega \rightarrow \mathbb{R}$ 关于测度 μ 的积分 $\int f d\mu = \mu(f)$ (有时也记作 $\mu(f)$) 如下:

首先定义

$$\int 1_A d\mu := \mu(A), \quad \forall A \in \mathcal{F}. \quad (4.16)$$

其次, 对任意非负简单函数 $f \in \mathcal{S}_+$, 存在 $N \in \mathbb{N}, \{a_n\}_{n=1}^N \subset \mathbb{R}_+$ 及不交集列 $\{A_n\}_{n=1}^N \subset \mathcal{F}$, 使得 $f = \sum_{n=1}^N a_n 1_{A_n}$, 此时定义

$$\int f d\mu = \sum_{n=1}^N a_n \mu(A_n).$$

之后, 对任意非负可测函数 f , 定义

$$\int f d\mu := \sup \left\{ \int g d\mu : 0 \leq g \leq f, g \in \mathcal{S}_+ \right\}. \quad (4.17)$$

最后, 对任意可测函数 f , 注意到 $f = f^+ - f^-$, 当

$$\min \left\{ \int f^+ d\mu, \int f^- d\mu \right\} < \infty$$

时, 就定义

$$\int f d\mu := \int f^+ d\mu - \int f^- d\mu; \quad (4.18)$$

否则称 f 关于 μ 的积分不存在。当

$$\max \left\{ \int f^+ d\mu, \int f^- d\mu \right\} < \infty$$

时, 就称 f 关于 μ 可积, 简记为 $f \in L^1(\mu)$.

4.4.2 抽象测度的 Lebesgue 积分的极限交换问题

本小节我们探讨抽象测度的 Lebesgue 积分的两类极限交换问题：其一是

$$\lim_{n \rightarrow \infty} \int f_n d\mu = \int \lim_{n \rightarrow \infty} f_n d\mu$$

成立的（充分）条件的探讨；其二是抽象测度的重积分何时可以化成累次积分的问题，也就是两重积分的交换问题。

测度论的理论告诉我们，积分 $\int f d\mu$ 关于 f 具有线性性质，并且上一节中的 Levi 单调收敛定理、Fatou 引理、Lebesgue 控制收敛定理和 Fubini 定理仍然成立；我们把它们罗列如下：

♠ **定理 4.4.1.** (*Levi 单调收敛定理*) 给定测度空间 $(\Omega, \mathcal{F}, \mu)$. 设 $\{f_n\}_{n=1}^{\infty}$ 为一列非负可测函数，且存在可测函数 f 使得 $f_n \nearrow f$. 那么

$$\lim_{n \rightarrow \infty} \int f_n d\mu = \int f d\mu.$$

♠ **定理 4.4.2.** (*Fatou 引理*) 给定测度空间 $(\Omega, \mathcal{F}, \mu)$. 设 $\{f_n\}_{n=1}^{\infty}$ 为一列非负可测函数，那么

$$\liminf_{n \rightarrow \infty} \int f_n d\mu \geq \int \liminf_{n \rightarrow \infty} f_n d\mu.$$

定义 4.4.1. 给定测度空间 $(\Omega, \mathcal{F}, \mu)$, $\{f_n\}_{n=1}^{\infty}$ 为其上一列可测函数。称它们几乎处处收敛于 f (记作 $f_n \xrightarrow{a.e.} f$ 或 $f_n \xrightarrow{\mu-a.e.} f$ 或 $f_n \rightarrow f, \mu - a.e.$)，如果

$$\mu(\{\omega : \lim_{n \rightarrow \infty} f_n(\omega) \neq f(\omega)\}) = 0.$$

当 μ 是一个概率测度时，相应的可测函数也称为随机变量，而此时的几乎处处收敛也称为以概率 1 收敛或几乎必然收敛 (*almost sure convergence*)，记作 $f_n \xrightarrow{a.s.} f$.

如果

$$\lim_{n \rightarrow \infty} \mu(\{\omega : |f_n(\omega) - f(\omega)| \geq \varepsilon\}) = 0, \quad \forall \varepsilon > 0,$$

则称 $\{f_n\}_{n=1}^{\infty}$ 依测度收敛到 f ，记作 $f_n \xrightarrow{\mu} f$ ；当 μ 是一个概率测度时，上述收敛也称依概率收敛。

给定 $p > 0$ ，对测度空间 $(\Omega, \mathcal{F}, \mu)$ 上可测函数 f ，定义

$$\|f\|_p := \left[\int |f|^p d\mu \right]^{1/p}.$$

记 $L^p(\Omega, \mathcal{F}, \mu) := \{f \text{ 为 } (\Omega, \mathcal{F}, \mu) \text{ 上可测函数} : \|f\|_p < \infty\}$ ，有时也简记为 $L^p(\mu)$ 或 L^p . 设 $\{f_n\}_{n=0}^{\infty} \subset L^p$ ，如果

$$\|f_n - f_0\|_p \rightarrow 0,$$

则称 $\{f_n\}_{n=1}^\infty$ L^p -收敛到 f_0 , 记作 $f_n \xrightarrow{L^p} f_0$.

♠ **定理 4.4.3.** (*Lebesgue 控制收敛定理*) 给定测度空间 $(\Omega, \mathcal{F}, \mu)$. 设 $\{f_n\}_{n=1}^\infty$ 为一列几乎处处收敛(或依测度收敛)于 f 的可测函数, 且存在可测函数 $g \in L^1(\mu)$ 使得 $|f_n| \leq g$. 那么

$$\lim_{n \rightarrow \infty} \int f_n d\mu = \int \lim_{n \rightarrow \infty} f_n d\mu.$$

♠ **定理 4.4.4.** (*Fubini 定理*¹) 给定两个 σ -有限的测度空间 $(\Omega_k, \mathcal{F}_k, \mu_k), k = 1, 2$. 设 $f: \Omega_1 \times \Omega_2 \rightarrow \mathbb{R}$ 是非负可测函数 (或 $f \in L^1(\mu_1 \otimes \mu_2)$), 那么

$$\begin{aligned} \int_{\Omega_1 \times \Omega_2} f d\mu_1 \otimes \mu_2 &= \int_{\Omega_2} \left[\int_{\Omega_1} f(\omega_1, \omega_2) d\mu_1(\omega_1) \right] d\mu_2(\omega_2) \\ &= \int_{\Omega_1} \left[\int_{\Omega_2} f(\omega_1, \omega_2) d\mu_2(\omega_2) \right] d\mu_1(\omega_1). \end{aligned}$$

4.4.3 微积分基本定理的推广: Radon-Nikodym 定理

为了后续讨论的需要, 我们给出一个测度关于另一个测度绝对连续和两个测度相互奇异的观念。

定义 4.4.2. 给定 $(\Omega, \mathcal{F})$ 上两个 (σ -有限的) 测度 μ, ν . 称 μ 关于 ν 绝对连续, 记作 $\mu \ll \nu$, 如果任意 ν -零测集都是 μ -零测集, 即

$$\forall A \in \mathcal{F}, (\nu(A) = 0 \Rightarrow \mu(A) = 0).$$

如果 $\mu \ll \nu$ 且 $\nu \ll \mu$, 则称 μ, ν 相互等价, 记作 $\mu \sim \nu$.

称 μ, ν 为相互奇异的, 记作 $\mu \perp \nu$, 如果存在 $H \in \mathcal{F}$, 使得 $\mu(H^c) = 0$ 且 $\nu(H) = 0$.

上述概念对于符号测度也可以定义, 只不过其实质是对应的全变差测度之间的关系, 我们对此不再赘述。

下面的结果是测度论中非常深刻的一个结果, 本质上它是抽象测度版本的微积分基本定理。

♠ **定理 4.4.5.** (*Radon-Nikodym 定理*) 设 μ, ν 分别是可测空间 $(\Omega, \mathcal{F})$ 上的测度与符号测度, 二者均 σ -有限。设 $\mu \ll \nu$. 则存在 ν -几乎处处有限的可测函数 f 使得 $\mu = f \cdot \nu$, 即

$$\mu(A) = \int_A f d\nu, \forall A \in \mathcal{F}.$$

¹有些文献^[4]也称之为 Fubini-Tonelli 定理。

函数 f 称为 μ 关于 ν 的 Radon-Nikodym 导数, 记作 $\frac{d\mu}{d\nu} := f$. 在 ν -几乎处处相等的意义下, Radon-Nikodym 导数是唯一的。

证明: 为简单起见, 不妨设 ν 是测度而不是符号测度 (否则 $\nu = \nu^+ - \nu^-$, 且此时 $\nu^+ \ll \mu, \nu^- \ll \mu$, 分别考虑 ν^+, ν^- 关于 μ 的 R-N 导数即可); 进一步不妨设 μ, ν 都是有限测度。(读者请思考: 为什么可以这样假设?)

为简化记号, 对任意可测函数 h , 令 $h \cdot \mu$ 代表一个测度, 它定义为

$$(h \cdot \mu)(A) := \int_A h d\mu.$$

现在定义 $\mathcal{H} := \{h \geq 0 : h \text{ 关于 } \mathcal{F} \text{ 可测, 且 } h \cdot \mu \leq \nu\}$, 并令 $b := \sup\{\mu(h) : h \in \mathcal{H}\}$.

我们首先证明 $\mathcal{H}$ 关于函数运算 $\vee$ 封闭. 事实上, 对任意 $h_1, h_2 \in \mathcal{H}$, 记 $h := h_1 \vee h_2$, 有 $h = h_2 \cdot 1_{\{h_1 \leq h_2\}} + h_1 \cdot 1_{\{h_1 > h_2\}}$, 进而

$$\begin{aligned} h \cdot \mu &= (h_2 \cdot 1_{\{h_1 \leq h_2\}}) \cdot \mu + (h_1 \cdot 1_{\{h_1 > h_2\}}) \cdot \mu \\ &\leq 1_{\{h_1 \leq h_2\}} \cdot \nu + 1_{\{h_1 > h_2\}} \cdot \nu = \nu, \end{aligned}$$

因此 $h \in \mathcal{H}$.

于是存在递增列 $\{h_n\}_{n=1}^\infty \subset \mathcal{H}$, 使得 $b = \lim_{n \rightarrow \infty} \mu(h_n)$. 令 $g = \lim_{n \rightarrow \infty} h_n$, 由单调收敛定理, $g \in \mathcal{H}$ 且 $b = \mu(g) = (g \cdot \mu)(\Omega) \leq \nu(\Omega) < \infty$.

下面证明 $\nu = g \cdot \mu$. 令 $\gamma = \nu - g \cdot \mu$, 由于 $g \in \mathcal{H}$, γ 是一个有限测度. 任给 $n \geq 1$, 设 D_n 是符号测度 $\gamma - \frac{1}{n}\mu$ 的 Hahn 集. 于是对任意 $A \in \mathcal{F}$

$$\nu(A \cap D_n) \geq g \cdot \mu(A \cap D_n) + \frac{1}{n}\mu(A \cap D_n), \quad (4.19)$$

$$\gamma(A \cap D_n^c) \leq \frac{1}{n}\mu(A \cap D_n^c). \quad (4.20)$$

(4.19)亦即 $1_{D_n} \cdot (g + \frac{1}{n}) \cdot \mu \leq 1_{D_n} \cdot \nu$. 从而对 $g_n := g + \frac{1}{n} \cdot 1_{D_n}$, 有

$$\begin{aligned} g_n \cdot \mu &= g \cdot \mu + \frac{1}{n} \cdot 1_{D_n} \cdot \mu \\ &= 1_{D_n^c} \cdot g \cdot \mu + 1_{D_n} \cdot g \cdot \mu + \frac{1}{n} \cdot 1_{D_n} \cdot \mu \\ &= 1_{D_n^c} \cdot g \cdot \mu + 1_{D_n} \cdot (g + \frac{1}{n}) \cdot \mu \\ &\leq 1_{D_n^c} \cdot \nu + 1_{D_n} \cdot \nu = \nu. \end{aligned}$$

由此 $g_n \in \mathcal{H}$. 而由 g 的极大性, 应有 $\mu(D_n) = 0$. 令 $D = \bigcup_{n=1}^\infty D_n$, 有 $\mu(D) = 0$, 进而 $\gamma(D) = 0$. 另一方面, 由(4.20),

$$\gamma(D^c) \leq \gamma(D_n^c) \leq \frac{1}{n}\mu(D_n^c) \leq \frac{1}{n}\mu(\Omega) \rightarrow 0,$$

于是 $\gamma(D^c) = 0$. 因此 $\gamma = 0$, 即 $\nu = g \cdot \mu$.

显然 Radon-Nikodym 导数 $f := g$ 是几乎处处有限的, 并且容易看出在 μ -几乎处处相等的意义下, Radon-Nikodym 导数是唯一的. $\square$

基于上述结果, 我们指出下面的定理成立; 这是我们前述的质量与密度两个物理概念的内涵在数学上的抽象表达。

♠ **定理 4.4.6.** 给定 $(\mathbb{R}^d, \mathcal{B}^d)$ 上两个 σ -有限的测度 μ, ν .

- (1) μ 关于 ν 绝对连续的充分必要条件是如下版本的“ μ 关于 ν 的连续性”成立: $\forall V_n \in \mathcal{B}^d, V_n \downarrow$, 且 $\nu(V_n) \downarrow 0$ 时, 就有 $\mu(V_n) \rightarrow 0$;
- (2) 当上述“ μ 关于 ν 的连续性”成立时, 对 ν -a.e. $x \in \mathbb{R}^d$

$$\rho(x) := \frac{d\mu}{d\nu}(x) = \lim_{r \downarrow 0} \frac{\mu(B(x, r))}{\nu(B(x, r))}.$$

$$\text{此时 } \mu(A) = \int_A \rho(x) d\nu(x), \quad \forall A \in \mathcal{B}^d.$$

上述定理中 $d = 1$ 时的结果 (同时取 $\nu = \text{Leb}$), 就对应了上一节中对微积分基本定理的探讨。



图 4.13: Radon(1887-1956)



图 4.14: Nikodym(1887-1974) 与 Banach(1892-1945) 的纪念雕像 (波兰, Kraków)

📌 **注 4.7.** Giuseppe Vitali (维塔利, 1875—1932) 是意大利数学家、力学家, 生于拉韦纳 (Ravenna), 卒于博洛尼亚 (Bologna); 他最早研究可测函数的性质, 建立了 Vitali 覆盖定理、解析函数列的极限函数列的解析性定理、积分与极限符号可交换的定理。他在 1905 年引入了绝对连续函数的概念, 并且证明了

$$\int_a^x f(t) dt = F(x) - F(a), \quad \forall x \in [a, b]$$

成立的充分必要条件是 $F'(x) = f(x)$ a.e. 于 $[a, b]$, 且 $F(x)$ 在 $[a, b]$ 上绝对连续的。这样, Lebesgue 积分扩大了使微积分基本定理成立的函数类。

Johann Radon (拉东, 1887—1956) 是奥地利数学家, 生于捷克斯洛伐克的波希米亚 (Bohemia, 现名为 Decin), 1947 年他受聘为维也纳大学教授, 并选为奥地利科学院院士, 后卒于奥地利的维也纳。在分析学上

他提出了 Radon 测度和 Radon 积分。他 1913 年把 Vitali 的上述工作推广到定义在 n 维欧氏空间中的 Borel 测度的情形。

Otto Marcin Nikodym (尼科迪姆, 1887—1974) 是美籍波兰数学家, 生于波兰 Zabłotów 郊区, 1948 年移民到美国任教于 Kenyon 学院, 1966 年退休后移居纽约直至逝世。他于 1929 年把上述 Radon 的工作进一步推广到一般测度空间中的积分情形。

由 Radon-Nikodym 定理, 我们有下面的简单推论。

推论 4.4.1. 设 μ, ν 分别是可测空间 $(\Omega, \mathcal{F})$ 上的 σ -有限测度与符号测度, 其中 $\nu = f \cdot \mu$, f 是一个广义实值可测函数。那么

- (i) $|\nu(\Omega)| < \infty$ 等价于 $f \in L^1(\mu)$;
- (ii) ν 是 σ -有限的等价于 $\mu(\{|f| = \infty\}) = 0$;
- (iii) ν 是零测度的充要条件是 $\mu(\{f \neq 0\}) = 0$.

上述推论中的 (iii) 是我们经常需要使用的一个结果, 实际应用中经常表现为下面的形式:

$$\left(\int_A f d\mu = 0, \forall A \text{ 可测} \right) \Rightarrow f = 0 \mu - \text{a.e.} \quad (4.21)$$

下面的 Lebesgue 分解定理则给出了一般的 (符号) 测度在给定参考测度下的结构。

定理 4.4.7. (Lebesgue 分解) 设 μ, ν 分别是可测空间 $(\Omega, \mathcal{F})$ 上的测度与符号测度, 二者均 σ -有限。则可将 ν 唯一地表示为 $\nu = \nu_1 + \nu_2$, 使得 ν_1, ν_2 均为 σ -有限的符号测度, 且 $\nu_1 \ll \mu, \nu_2 \perp \mu$.

证明: 类似于 Radon-Nikodym 定理的证明, 不妨设 μ, ν 均为有限测度。令

$$\mathcal{L} := \{f \in L^1(\Omega, \mathcal{F}, \mu) : f \cdot \mu \leq \nu\}.$$

则 $\mathcal{L}$ 有下面一些性质:

- (i) $0 \in \mathcal{L}$, 从而 $\mathcal{L}$ 非空;
- (ii) 如果 $f_1, f_2 \in \mathcal{L}$, 则 $f_1 \vee f_2 \in \mathcal{L}$. 这是因为

$$\begin{aligned} (f_1 \vee f_2) \cdot \mu &= 1_{\{f_1 \leq f_2\}} \cdot f_2 \cdot \mu + 1_{\{f_1 > f_2\}} \cdot f_1 \cdot \mu \\ &\leq 1_{\{f_1 \leq f_2\}} \cdot \nu + 1_{\{f_1 > f_2\}} \cdot \nu = \nu; \end{aligned}$$

(iii) 如果 $f_n \in \mathcal{L}, f_n \nearrow f$, 则 $f \in \mathcal{L}$. 事实上, 容易知道

$$g_n := f_n + f_1^- \geq f_1 + f_1^- = f_1^+ \geq 0$$

是一个非负单调函数列, 由此 $g_n \nearrow f + f_1^- \geq 0$, 根据单调收敛定理, 易知 $f \in L^1(\Omega, \mathcal{F}, \mu)$ 且 $f \cdot \mu \leq \nu$, 进而 $f \in \mathcal{L}$.

根据以上性质, $\mathcal{L}$ 中有极大元 $f \geq 0$, 且 $\nu_1 := f \cdot \mu \leq \nu$. 记 $\nu_2 := \nu - f \cdot \mu$, 于是 $\nu = \nu_1 + \nu_2$, 且 $\nu_1 \ll \mu$. 以下证明 $\nu_2 \perp \mu$. 事实上, 令 D_n 为 $\nu_2 - \frac{1}{n}\mu$ 的 Hahn 集. 于是对任意 $A \in \mathcal{F}$

$$\nu_2(A \cap D_n) \geq \frac{1}{n}\mu(A \cap D_n), \quad \nu_2(A \cap D_n^c) \leq \frac{1}{n}\mu(A \cap D_n^c).$$

由此 $(f + \frac{1}{n} \cdot 1_{D_n}) \cdot \mu \leq f \cdot \mu + 1_{D_n} \cdot \nu_2 \leq \nu_1 + \nu_2 = \nu$, 即 $f + \frac{1}{n} \cdot 1_{D_n} \in \mathcal{L}$. 由 f 的极大性, $\mu(D_n) = 0$. 记 $D := \bigcup_{n=1}^{\infty} D_n$, 则 $\mu(D) = 0$. 另一方面,

$$\nu_2(D^c) \leq \nu_2(D_n^c) \leq \frac{1}{n}\mu(D_n^c) \leq \frac{1}{n}\mu(\Omega).$$

令 $n \rightarrow \infty$ 即知 $\nu_2(D^c) = 0$. 由此 $\nu_2 \perp \mu$. □

4.5 本章小结与学习建议

如本章开头所述, 本章简略介绍了欧氏空间和一般测度空间上的 Lebesgue 积分理论. 对于不具有实变函数论基础 (特别是非数学专业) 的概率论初学者, 建议在第一遍学习时跳过本章, 而在后续用到有关理论时再来翻看并承认它们即可; 对于具有实变函数论基础的概率论初学者, 则建议扼要浏览本章罗列的有关理论, 但也不必过于深究其中复杂度较高的部分证明, 而以了解有关理论想要解决的问题与最终的解决方案为首要学习目的, 之后通过在后续的应用场景中逐渐熟悉、理解有关理论。

习 题 4

习题 4.1. 设 μ 是 $(\Omega, \mathcal{F})$ 上的符号测度. 求证: 它是有限符号测度的充要条件是 $|\mu(\Omega)| < \infty$.

习题 4.2. 设 μ 是 $(\Omega, \mathcal{F})$ 上的符号测度, 其中 $\Omega = \{1, \dots, N\}$, $\mathcal{F} = 2^\Omega$. 定义 $\mu_i := \mu(\{i\})$. 求证: $\|\mu\|_{\text{TV}} := |\mu|(\Omega) = \sum_{i=1}^N |\mu_i|$.

习题 4.3. 设是 $(E, \mathcal{T})$ 是拓扑空间, $\mathcal{B}_E := \sigma(\mathcal{T})$ 是 E 上 Borel σ -代数. 求证: E 上连续函数是可测函数.

习题 4.4. 设是 $(E_k, \mathcal{T}_k), k = 1, 2$ 都是拓扑空间, $\mathcal{B}_k := \sigma(\mathcal{T}_k)$ 是 E_k 上 Borel σ -代数; 乘积拓扑 $\mathcal{T}_1 \otimes \mathcal{T}_2$ 定义为由 $\mathcal{T}_1 \times \mathcal{T}_2 := \{A_1 \times A_2 : A_1 \in \mathcal{T}_1, A_2 \in \mathcal{T}_2\}$ 生成的拓扑. 请基于附录 A 中的单调类定理证明: $\sigma(\mathcal{T}_1 \times \mathcal{T}_2) = \mathcal{B}_1 \otimes \mathcal{B}_2$.

习题 4.5. 设 $m \in \mathbb{N}$, 证明 $\mathbb{R}^m$ 上单调函数是可测函数.

习题 4.6. 设 μ 是 $(\Omega, \mathcal{F})$ 上测度, 对 $1 \leq p < \infty$, 证明以下结论成立:

(1) 对任意 $a \in \mathbb{R}, f \in L^p := L^p(\Omega, \mathcal{F}, \mu)$, 有 $\|af\|_p = |a| \cdot \|f\|_p$;

(2) Hölder (霍德) 不等式: 对任意 $f \in L^p, g \in L^q$, 其中 $\frac{1}{p} + \frac{1}{q} = 1$ (此时称 p, q 共轭), 有

$$\|f \cdot g\|_1 \leq \|f\|_p \cdot \|g\|_q;$$

(3) Minkowski (闵可夫斯基) 不等式/三角不等式: 对任意 $f, g \in L^p$, 有

$$\|f + g\|_p \leq \|f\|_p + \|g\|_p;$$

(4) 对任意 $f, g \in L^p$, 我们认为 $f = g$ 如果 $\mu(\{f \neq g\}) = 0$. 在这种认同下 $(L^p, \|\cdot\|_p)$ 是一个赋范空间: 它满足上面的 (1)、(3) 及

$$\|f\|_p = 0 \Leftrightarrow f = 0 \quad \mu\text{-a.e.};$$

(5) $((L^p, \|\cdot\|_p)$ 的完备性) 称 $\{f_n\}_{n=1}^\infty \subset L^p$ 为 L^p 中的 Cauchy (柯西) 列, 如果 $\lim_{n, m \rightarrow \infty} \|f_n - f_m\|_p = 0$. 对于上述 Cauchy 列, 存在 $f \in L^p$, 使得

$$\lim_{n \rightarrow \infty} \|f_n - f\|_p = 0.$$

于是 $(L^p, \|\cdot\|_p)$ 是一个 Banach (巴拿赫) 空间 (即完备的赋范线性空间)

习题 4.7. 设 μ 是 $(\Omega, \mathcal{F})$ 上测度, $0 < p < \infty$. 对任意可测函数 $f: \Omega \rightarrow \mathbb{R}$, 有

$$\|f\|_1 = \int_0^\infty \mu(|f| > t) dt, \quad \|f\|_p^p = \int_0^\infty p t^{p-1} \mu(|f| > t) dt.$$

习题 4.8. 设 μ 是 $(\Omega, \mathcal{F})$ 上测度, $p = \infty$. 对可测函数 $f: \Omega \rightarrow \mathbb{R}$, 定义

$$\|f\|_\infty := \inf\{M \geq 0 : \mu(|f| > M) = 0\},$$

称 $\|f\|_\infty$ 为 f 的本质范数或无穷范数, 并定义

$$L^\infty(\Omega, \mathcal{F}, \mu) := \{f : f \text{ 是可测函数, 且 } \|f\|_\infty < \infty\},$$

有时也简记为 $L^\infty(\mu)$ 或 L^∞ . 求证: 上面习题 4.6 中结论对 $p = \infty$ 仍然成立。

习题 4.9. 设 μ 是 $(\Omega, \mathcal{F})$ 上有限测度。设 $f \in L^\infty(\Omega, \mathcal{F}, \mu)$, 其中 $\|f\|_\infty > 0$, 求证: (1) $\lim_{p \rightarrow \infty} \|f\|_p = \|f\|_\infty$; (2) $\lim_{p \rightarrow \infty} \frac{\|f\|_{p+1}^{p+1}}{\|f\|_p^p} = \|f\|_\infty$.

习题 4.10. 设 μ 是 $(\Omega, \mathcal{F})$ 上有限测度。对 $1 \leq p < \infty$ 定义

$$L_*^p(\Omega, \mathcal{F}, \mu) := \{f : f \text{ 是 } \Omega \text{ 上可测函数, 且 } \sup_{t>0} [t^{p-1} \mu(|f| > t)] < \infty\}.$$

有时也把 $L_*^p(\Omega, \mathcal{F}, \mu)$ 简记为 $L_*^p(\mu)$ 或 L_*^p . 求证: $L^p \subset L_*^p \subset L^{p-\varepsilon}, \forall \varepsilon > 0$.

习题 4.11. 设 μ 是 $(\Omega, \mathcal{F})$ 上测度。又设 $p_1 < p < p_2$, 且存在 $\alpha \in (0, 1)$ 使得 $\frac{1}{p} = \frac{\alpha}{p_1} + \frac{1-\alpha}{p_2}$. 那么对任意 $f \in L^{p_1}(\mu) \cap L^{p_2}(\mu)$, $\|f\|_p \leq \|f\|_{p_1}^\alpha \cdot \|f\|_{p_2}^{1-\alpha}$.

习题 4.12. 设 μ 是 $(\Omega, \mathcal{F})$ 上符号测度。试证明:

$$\|\mu\|_{\text{TV}} = \sup \left\{ \int f d\mu : f \text{ 是可测函数, 且 } |f| \leq 1 \right\}.$$

习题 4.13. 设 μ 是 $(\Omega, \mathcal{F})$ 上有限测度, $p, q \geq 1$ 满足 $\frac{1}{p} + \frac{1}{q} = 1$. 试证明:

$$\|f\|_p = \sup \left\{ \int f \cdot g d\mu : g \in L^q(\mu), \|g\|_q \leq 1 \right\}, \forall f \in L^p(\mu).$$

习题 4.14. 设 $(\Omega, \mathcal{F}, \mu)$ 上非负 L^1 -函数列 $\{f_n\}_{n=0}^\infty$ 在 $n \rightarrow \infty$ 时满足: (1) $\int (f_n - f_0) d\mu \rightarrow 0$; (2) $f_n \xrightarrow{\mu\text{-a.e.}} f_0$. 那么 $f_n \xrightarrow{L^1} f_0$. 这个结果被称为 *Scheffé's* (谢菲) 定理。

习题 4.15. 利用 *Fubini* 定理、控制收敛定理讨论下面函数

$$F(x) := \sum_{n=0}^{\infty} x^n \ln \frac{1+x^n}{1+x^{n+1}}$$

在 $x \nearrow 1$ 时的极限, 进而计算 $\lim_{x \rightarrow 1-} \prod_{n=0}^{\infty} \left(\frac{1+x^{n+1}}{1+x^n} \right)^{x^n}$.

第五章 随机变量及其分布律 (I)

接下来我们将介绍概率论中最重要且基础的概念：随机变量（Random Variables, 缩写为 r.v.）及其分布律（Distribution Laws）。

在后文中，我们总假设 $(\Omega, \mathcal{F}, \mathbb{P})$ 为概率空间。如第三章开篇所述，由于有了乘积概率空间（参见 §3.2.1 及附录A）的技术手段，我们总可以假设为复杂的随机试验建模而得到的概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 足够丰富，以至于能容纳我们所需讨论的有关随机变量。这里，随机变量是我们用来精确描绘有关随机事件的一个重要概念；借助这个概念，有关随机事件的概率计算最终可以落实到随机变量的分布律的计算上。事实上，在公理化概率论建立以后，概率论中几乎所有的演绎与推理本质上都是立足于分布律的。因此，随机变量及其分布律的理论与应用是初等概率论的核心主题。而相对来说，在大多数场景下，概率空间本身的具体构造对于有关立足分布律的演绎推理来说是无关紧要的。因此，除非在一些确有必要关心的场景（例如后续的例题6.6与习题6.52等），我们在后续论述中不再详细描述概率空间的具体构造，也不再反复陈述 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间这一假定。

此处，我们提前请读者思考如下问题：既然概率空间是对随机试验的概率建模，那么概率空间中的随机变量又对应于随机试验中的什么量呢？我们先卖一个关子；认真的读者当能在学完本章后找到答案。

为了教学安排的方便，在本书中我们把随机变量及其分布律的初步介绍拆分为三个不连贯的章节进行，它们分别是本章（第五章）、第八章和第九章，中间插入了第六、七章用以介绍数学期望和条件数学期望及条件分布律；后续章节则进一步介绍随机变量及其分布律的更高级的理论与应用。

本章的内容安排如下。

首先我们给出随机变量的定义，在此基础上再进一步定义随机向量。借助这两个概念，我们就可以很方便地探讨随机事件，进而发展出更多的概念与理论。不同于现行的大部分初等概率论教材，在本章我们通过令人信服的例子指出，为了维持概率理论应用原有的宽泛性，我们应当在“随机变量是可测函数”

这一传统定义的基础上施行一个合理的“补丁程序”，以确保逻辑的严谨性以及概率论整体理论体系的自洽性：这个“补丁程序”本质上也是对两个随机变量在几乎处处相等意义下的认同，这一点在概率论的高级课程中是常规设定。

在随机变量/向量概念的基础上，我们将介绍它们的分布律的概念，目前来说就是（联合）分布函数或相应的分布测度。之后，我们进一步介绍多个随机变量/向量之间的相互独立性概念，并给出独立性概念的性质与等价刻画。

最后，我们将介绍离散型随机变量和常见离散型分布，并给出如下几个应用：（1）抛掷硬币模型的“游程检验”，一定程度上可以用来甄别数据的“真伪”；（2）利用离散型分布的样本数据进行极大似然估计的两个经典应用案例。

5.1 随机变量、随机向量及其分布律

5.1.1 随机变量与随机向量的定义

在概率论中，随机变量引入的一个重要目的就是为了更方便且精确地描述各种各样的、与随机现象关联的、实际问题中“能谈论概率”的那些（随机）事件。历史上，在讨论投掷均匀骰子点数的有关问题中，如果只考虑投掷一枚骰子一次的随机试验，人们经常引入某个字母符号，比如 ξ ，代表这枚骰子投掷出的点数，于是可以用 $\{\xi = i\}$ 代表事件“骰子投掷出点数 i ”（其中 $i = 1, \dots, 6$ ）；如果考虑一次性投掷三枚均匀的骰子（或重复投掷一枚骰子三次）的随机试验，则可以引入 ξ_k 代表第 k 枚（或第 k 次， $k = 1, 2, 3$ ）骰子投掷出的点数，通过它们可以很方便且精确地描写一些更复杂的事件，比如“三枚骰子投掷出的点数和为 n ”这一事件可以表述为 $\{\xi_1 + \xi_2 + \xi_3 = n\}$ 。这些记号 ξ, ξ_k 在概率论中称为“随机变量”。这种借助引进“随机变量”来描述事件的方法，在概率论发展的初期人们早已无意识地普遍使用了；特别地，很多现实问题中这种“随机变量”也是很自然出现，且被人们关心，第一章的例1.2中有关问题就是一个明证。现代概率论中，我们需要对“随机变量”的数学内涵进行明确，并对其使用加以规范¹。

传统的概率论教科书中，随机变量是按照如下方式定义的。

定义 5.1.1. 函数 $\xi : \Omega \rightarrow \mathbb{R}$ 称为可测函数，如果

$$\{\xi \leq x\} \in \mathcal{F}, \forall x \in \mathbb{R}. \quad (5.1)$$

¹因此，概率论对随机变量概念的使用经历了一个从无意识走向有意识、从自发走向自觉、从不规范走向规范的过程；这种对成功经验的分析、理解、吸收与内化的过程在科学的发展、竞技体育的训练等过程中是非常普遍的。我们在数学的学习过程也应尽力自觉地遵循这种规律，方能事半功倍。

此时可测函数 ξ 也称为 (概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上的) 随机变量。

用自然语言来说, 当函数 $\xi: \Omega \rightarrow \mathbb{R}$ 满足: 对所有 $x \in \mathbb{R}$, 事件 $\{\xi \leq x\}$ 都能谈论概率, 就称 ξ 是随机变量。这也等价于要求 $\xi^{-1}(\mathcal{B}) \subset \mathcal{F}$, 此处 $\mathcal{B}$ 是 $\mathbb{R}$ 上的 Borel σ -代数 (见第四章 §4.1),

$$\xi^{-1}(\mathcal{B}) := \{\xi^{-1}(B) : B \in \mathcal{B}\}$$

有时也称为 ξ 生成的 σ -代数, 记作 $\sigma(\xi) := \xi^{-1}(\mathcal{B})$; 它本质上就是 “能用 ξ 描写的 (能谈论概率的) 事件” 的全体。

而随机向量只不过是若干个随机变量组成的有序组。

定义 5.1.2. 给定 $n \in \mathbb{N}$, 当 $\xi_1, \dots, \xi_n$ 都是随机变量时, 我们称

$$\xi = (\xi_1, \dots, \xi_n)^T : \Omega \rightarrow \mathbb{R}^n$$

为 n 维随机 (列) 向量, 此处 $(\dots)^T$ 代表向量的转置。

此时, 随机向量 ξ 满足

$$\xi^{-1}(B) \in \mathcal{F}, \forall B \in \mathcal{B}^n, \quad (5.2)$$

这一性质及其证明参见稍后陈述的定理 5.1.1.

为了方便, 本书约定 (随机) 向量都指 (随机) 列向量, 除非特殊申明。欧氏空间中两向量 x, y 的标准内积我们也简单的以 $x \cdot y$ 表达; 有时也用 $\langle x, y \rangle$ 或 $x^T y = y^T x$ (其中 x^T 表示 x 的转置) 表达。这里同样有 n 维随机向量 ξ 生成的 σ -代数的概念, 它实际上是

$$\sigma(\xi) = \xi^{-1}(\mathcal{B}^n) := \{\xi^{-1}(B) : B \in \mathcal{B}^n\}.$$

此时有 $\sigma(\xi) = \sigma(\bigcup_{i=1}^n \sigma(\xi_i))$.

在上述定义中, 有几处偷懒的记号需要指出: 事件 $\{\xi \leq x\}$ 的准确描述是 $\{\omega \in \Omega : \xi(\omega) \leq x\}$, 事件 $\{\xi \leq x\}$ 的概率被简单地记作 $\mathbb{P}(\xi \leq x)$. 这些记号上的偷懒都是概率论长期发展过程中形成的约定俗成的书写习惯, 需要读者铭记于心并灵活使用。另外, 传统上我们一般使用 26 个英文字母中排列较前的大写字母 (如 A, B, C, D 等) 代表事件, 用 26 个英文字母中排列较后的大写字母 (如 U, V, W, X, Y, Z 等) 及一些小写希腊字母 (例如 ξ, η, ζ 等) 表示随机变量, 用小写英文字母表示具体值。

上面通过可测函数的概念给出了随机变量和随机向量的一种定义。为了叙述的方便, 我们把定义 5.1.1、5.1.2 中给出的随机变量/向量称为普通随机变

量/向量。显然, 普通随机变量/向量不能取无穷值; 但这个要求其实过于苛刻, 从而在实际应用中普通随机变量/向量概念不方便使用。下面的例子就充分说明了这一点。

例 5.1. 投掷一枚均匀硬币的无穷重复随机试验的一种概率建模方法是取

$$(\Omega, \mathcal{F}, \mathbb{P}) := (\Sigma, 2^\Sigma, \mu)^\infty, \text{ 其中 } \Sigma = \{0, 1\}, \mu(\{0\}) = \mu(\{1\}) := \frac{1}{2}.$$

于是 $\omega = (\omega_1, \omega_2, \dots)$ 就代表了这个复杂随机试验的一个实验记录, 其中第 n 次投掷该硬币, 获得正面时, 实验结果记录为 $\omega_n = 1$, 否则记为 $\omega_n = 0$. 记 $X_n := \omega_n$; 一般地, 我们会关心为了获得首个硬币正面所需要的的最少的投掷次数 τ (参见例 1.2 的第三个问题或例 3.22 中的 τ_A); 它在数学上可以表述为

$$\tau := \inf\{n \geq 1 : X_n = 1\}.$$

不难知道, 对任意自然数 $n \geq 1$

$$\mathbb{P}(\tau = n) = \mathbb{P}(X_1 = \dots = X_{n-1} = 0, X_n = 1) = \frac{1}{2^n},$$

从而 $\mathbb{P}(\tau = \infty) = 0$. 在初等概率论中一般认为 τ 是随机变量, 服从的分布是参数为 $1/2$ 的几何分布。但是在逻辑上我们无法排除 $\{\tau = \infty\}$ 非空, 即

$$\{X_n = 0, \forall n \geq 1\} \neq \emptyset$$

的可能。也就是说, 在严格意义上, 此处 τ 的取值空间不是 $\mathbb{N}$ (或 $\mathbb{R}$), 而应把 τ 视作 $\tau : \Omega \rightarrow \bar{\mathbb{N}} := \mathbb{N} \cup \{\infty\}$ (或更一般的 $\tau : \Omega \rightarrow \bar{\mathbb{R}} := \mathbb{R} \cup \{\pm\infty\}$)。

由此我们给出一般的随机变量的如下定义, 其定义流) 亦称为第一种“补丁程序”¹:

定义 5.1.3. 以 $\bar{\mathbb{R}} := \mathbb{R} \cup \{\pm\infty\}$ 表示广义实数空间。广义实值函数 $\xi : \Omega \rightarrow \bar{\mathbb{R}}$ 称为是可测的, 如果对任意 $x \in \mathbb{R}$, $\{\xi \leq x\} \in \mathcal{F}$. 此时广义实值可测函数 ξ 也称为广义实值随机变量; 当它额外满足 $\mathbb{P}(|\xi| = \infty) = 0$, 亦即

$$\mathbb{P}(|\xi| < \infty) = 1 \tag{5.3}$$

时, 才称 ξ 是概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上的随机变量。随机向量仍按照 5.1.2 定义。

在上述补丁程序的精神下, 两个随机变量 ξ, η 认为是同一个随机变量, 或者说, $\xi = \eta$ 几乎处处成立, 如果 $\mathbb{P}(\xi \neq \eta) = 0$, 亦即 $\mathbb{P}(\xi = \eta) = 1$. 在这种认同下, 我们还有关于随机变量定义的如下更一般的第二种“补丁程序”:

¹有时也称其中要求(5.3)为第一种补丁程序。

定义 5.1.4. 设 $\Omega_* \subset \Omega$ 是一个几乎必然事件 (即 $\Omega_* \in \mathcal{F}$ 且 $\mathbb{P}(\Omega_*) = 1$), 称

$$\xi : \Omega_* \rightarrow \mathbb{R}$$

为可测函数, 如果 $\Omega_* \cap \{\xi \leq x\} \in \mathcal{F}, \forall x \in \mathbb{R}$. 此时, 我们也把 ξ 视作 $(\Omega, \mathcal{F}, \mathbb{P})$ 上的随机变量 (哪怕它在 $\Omega \setminus \Omega_*$ 上并没有定义). 随机向量仍按照 5.1.2 定义。

显然, 普通随机变量/向量也是我们此处补丁程序中定义的随机变量/向量。在概率论中我们认可上述补丁程序, 这是因为, 通过定义 $\mathcal{F}_* := \Omega_* \cap \mathcal{F}$, $\mathbb{P}_* := \mathbb{P}|_{\mathcal{F}_*}$, 我们得到一个子概率空间 $(\Omega_*, \mathcal{F}_*, \mathbb{P}_*)$, 且它实际与 $(\Omega, \mathcal{F}, \mathbb{P})$ 并无本质区别:

$$\mathbb{P}(A) = \mathbb{P}_*(\Omega_* \cap A), \forall A \in \mathcal{F}.$$

而此时可测函数 $\xi : \Omega_* \rightarrow \mathbb{R}$ 即可视作概率空间 $(\Omega_*, \mathcal{F}_*, \mathbb{P}_*)$ 上的普通随机变量。假设广义实值随机变量 ξ 满足 $\mathbb{P}(|\xi| = \infty) = 0$, 我们也可以缩小 ξ 的定义域, 使得 ξ 成为真正的可测函数: 定义 $\Omega_* := \Omega \setminus \{|\xi| = \infty\}$, $\mathcal{F}_*, \mathbb{P}_*$ 如上定义, 则此时 $\xi : \Omega_* \rightarrow \mathbb{R}$ 也是 $(\Omega_*, \mathcal{F}_*, \mathbb{P}_*)$ 上的一个普通随机变量。因此, 虽然为了语言的严谨性, 我们在上面讲述了随机变量/向量的两种补丁程序, 但在惯例上我们仍然把随机变量等同于可测函数; 课程中我们总按此惯例处置, 仅在有必要场景启动 (第一种或第二种) 补丁程序。

♠ 定理 5.1.1. (随机变量的复合) 设 X, Y 都是随机变量, g 是二元可测函数, 那么 $g(X, Y)$ 是随机变量; 更一般地, 当 ξ 是 n 维随机向量时, (5.2) 成立。特别地, $X + Y, X \cdot Y$ 是随机变量; 而当 $\mathbb{P}(Y = 0) = 0$ 时, X/Y 也可视作随机变量。

证明: 我们基于前述惯例来处置有关证明。

我们先证明二维随机 (行) 向量 $\xi := (X, Y)$ 具有 (5.2) 中性质, 亦即: 对任意 $A \in \mathcal{B}^2$, $\{(X, Y) \in A\} \in \mathcal{F}$; 更一般的 n 维随机向量情形结论的证明留给读者。

记 $\mathcal{G} := \{A \in \mathcal{B}^2 : \{(X, Y) \in A\} \in \mathcal{F}\}$. 不难证明 $\mathcal{G}$ 是一个 σ -代数。

另一方面, 当 $A = A_1 \times A_2, A_1, A_2 \in \mathcal{B}$ 时, 我们有

$$\{(X, Y) \in A\} = \{X \in A_1\} \cap \{Y \in A_2\} \in \mathcal{F},$$

因此 $\mathcal{B} \times \mathcal{B} \subset \mathcal{G}$.

注意到 $\sigma(\mathcal{B} \times \mathcal{B}) = \mathcal{B} \otimes \mathcal{B} = \mathcal{B}^2$, 我们立即得到¹如下结论: $\mathcal{G} = \mathcal{B}^2$.

¹ 由于 $\mathcal{G}$ 是 σ -代数, 此处结论无需使用单调类定理, 即定理 A.2.2.

现在, 对二元可测函数 g 及任意 $B \in \mathcal{B}, A := g^{-1}(B) \in \mathcal{B}^2$, 进而

$$\{g(X, Y) \in B\} = \{(X, Y) \in g^{-1}(B)\} \in \mathcal{F}.$$

也就是说, $g(X, Y)$ 是可测函数, 亦即随机变量。

取 $g(x, y) := x + y$, 则 g 是二元可测函数, 因此 $g(X, Y) = X + Y$ 是随机变量; 同理, $X \cdot Y$ 也是随机变量。而当 $\mathbb{P}(Y = 0) = 0$ 时, 取 $g(x, y) := 1_{\{y \neq 0\}} \cdot \frac{x}{y}$, 则 g 是二元可测函数, 并且 $\xi := g(X, Y)$ 仍然是随机变量, 这个随机变量在零测集 $\{Y = 0\}$ 之外的取值恰为 X/Y , 因此在第二种补丁程序下 X/Y 可以视作随机变量。□

由上述定理容易看到, 概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上的随机变量的全体构成一个代数空间 (线性空间且乘法运算封闭); 并且当随机变量 ξ, η 满足 $\mathbb{P}(\eta = 0) = 0$ 时, ξ/η 也是随机变量。在第三章例3.7对问题3的回答“到12点钟整的时刻, 坛子里一个球也没有”的理解也遵循了前述补丁程序的精神。

📌 注记 5.1. 在本书的“前言与导读”章节及第一章中我们就已明确, 概率空间是对随机试验的概率建模, 其中的样本空间是所有在逻辑上可能的“基本结果”的全体。回到随机试验的自然语言描述场景, 我们可以说, 一个随机变量实际上就是我们在随机试验中的一个物理测量值; 由于“基本结果”发生的不确定性, 这个测量值通常也具有不确定性——这是随机变量的“随机性”的根源所在。因此, 随机变量作为可测函数, 实际也代表了我們做随机试验时的一个“仪器仪表设备”, 一种确定性的测量方法; 而随机变量的具体值就是在随机试验中这个“仪器仪表”的刻度读数。

在随机变量的定义基础上, 我们还有更一般的随机元的说法。当 $(E, \mathcal{B}_E)$ 为一般的可测空间时, 可测映射 $\xi: (\Omega, \mathcal{F}) \rightarrow (E, \mathcal{B}_E)$ 有时也称为**随机元**, 它等价于要求:

$$\xi^{-1}(A) := \{\xi \in A\} \in \mathcal{F}, \forall A \in \mathcal{B}_E,$$

这也可以概括为 $\xi^{-1}(\mathcal{B}_E) \subset \mathcal{F}$; 同样, $\sigma(\xi) := \xi^{-1}(\mathcal{B}_E)$ 称为 ξ 生成的 σ -代数。

5.1.2 随机变量与随机向量的分布律

对于随机变量与随机向量, 我们先定义分布函数与联合分布函数如下。

定义 5.1.5. 给定随机变量 ξ , 定义函数 $F: \mathbb{R} \rightarrow \mathbb{R}$ 为

$$F(x) := \mathbb{P}(\xi \leq x), \quad \forall x \in \mathbb{R},$$

称之为 ξ 的**分布函数**, 记作 $\xi \sim F$, 读作: ξ 服从分布 F , 或 ξ 的分布函数是 F 。

当 ξ 是 n 维随机 (列) 向量时, 函数 $F: \mathbb{R}^n \rightarrow \mathbb{R}$

$$F(x) := \mathbb{P}(\xi \leq x) = \mathbb{P}(\xi_1 \leq x_1, \dots, \xi_n \leq x_n), \quad \forall x = (x_1, \dots, x_n)^T \in \mathbb{R}^n$$

就称为 ξ 的**联合分布函数**, 也简称 (联合) 分布; 对应地记 $\xi \sim F$, 读作: ξ 服从分布 F , 或 ξ 的联合分布函数是 F 。

设 $\xi_i \sim F_i, i = 1, \dots, n$, 如果 $\xi \sim F$, 通过令 $x_j \rightarrow +\infty, 1 \leq j \neq i \leq n$, 可以从联合分布函数 F 取极限得到 ξ_i 的分布函数 F_i , 这可以简单地记为

$$F_i(x_i) = F(\underbrace{\infty, \dots, \infty}_{i-1 \text{ 个}}, x_i, \underbrace{\infty, \dots, \infty}_{n-i \text{ 个}}).$$

这里, 每个 F_i 都称为联合分布函数 F 的一个 (一维) 边缘分布函数; 准确地说, F_i 是 ξ 的第 i 维边缘分布函数。更一般地, 对于 $1 \leq d < n$ 以及 $1 \leq j_1 < j_2 < \dots < j_d \leq n$, $(\xi_{j_1}, \dots, \xi_{j_d})$ 的联合分布函数 $F_{j_1, \dots, j_d}$ 称为 F 的一个 d 维边缘分布函数 (简称边缘分布函数)。

对于随机变量/向量 ξ , 设它的值域为 $\mathbb{R}^n$, 我们可以定义它的 (联合) 分布测度 μ_ξ 如下:

$$\mu_\xi(A) := \mathbb{P}(\xi \in A), \text{ 其中 } A \text{ 为 } \mathbb{R}^n \text{ 中可测集.}$$

此时 μ_ξ 是可测空间 $(\mathbb{R}^n, \mathcal{B}^n) := (\mathbb{R}, \mathcal{B})^n$ 上的 (Borel) 概率测度; 我们也记 $\xi \sim \mu_\xi$, 读作: ξ 服从分布 μ_ξ , 或 ξ 的分布测度是 μ_ξ . 对于随机向量, 此处也有边缘 (分布) 测度的说法: 例如 ξ_i 的分布测度 μ_{ξ_i} 就称为 μ_ξ (或 ξ) 的第 i 维边缘分布测度。

不难知道, 一维随机变量的分布函数具有如下性质。

♣ **命题 5.1.1.** 设 F 是随机变量 ξ 的分布函数, 即 $F(x) := \mathbb{P}(\xi \leq x)$. 那么

(i) $F: \mathbb{R} \rightarrow \mathbb{R}$ 是单调递增函数;

(ii) F 是右连续函数;

(iii) $F(-\infty) := \lim_{x \rightarrow -\infty} F(x) = 0, F(+\infty) := \lim_{x \rightarrow +\infty} F(x) = 1$.

📌 **注记 5.2.** 随机变量 ξ 的分布函数 F 与它的分布测度 μ_ξ 之间是一一对应的。事实上, 给定分布函数 F , 可以定义

$$\mu_F((a, b]) := F(b) - F(a), \text{ 其中 } a < b, a, b \in \mathbb{R}. \quad (5.4)$$

上式进一步通过 Carathéodory 扩张 (参见第四章) 的方式唯一确定了 $(\mathbb{R}, \mathcal{B})$ 上的一个概率测度 μ_F , 称为随机变量 ξ 的分布测度。反过来, 也容易看到

$$F(x) = \mu_F((-\infty, x]), \text{ 其中 } x \in \mathbb{R}.$$

当 $\xi \sim F$ 时, $\mu_\xi = \mu_F$. 高维随机向量的联合分布函数与分布测度之间的对应关系也是完全类似的。

随机变量 (或随机向量) 的分布函数 (或联合分布函数) 是随机变量 (或随机向量) 的统计特征, 被认为是对应随机变量 (或随机向量) 的分布律的一种表现形式; 分布测度也是分布律的一种表现形式; 本章将介绍的离散型随机

变量的概率分布列、第八章介绍的连续型随机变量/向量的密度函数/联合密度函数, 以及第十一章介绍的特征函数都是分布律的表现形式。这些分布律的表现形式(本质上就是随机变量的分布测度)都能决定对应随机变量的其他各种统计特征(比如第六章将介绍的随机变量的数学期望、方差等)。在附录B中, 我们进一步介绍了矩问题和 Laplace 变换, 其目的也在于介绍特殊情况下用来刻画分布律的其他一些非常规的手段。

注记 5.3. 概率论中使用随机变量这一术语代替可测函数这一术语的原因, 编者揣测有两个: 其一, 可测函数的概念容易让人联想到定义域和映射法则, 而概率论中的随机变量通常不知道明确的定义域(因为概率论中经常不明确说出样本空间的构造), 通常也更不清楚映射法则; 其二, 可测函数容易让人联想到确定性, 而概率论中的随机变量通常仅仅可以知道统计规律, 通常无法确定, 也无需关心其映射法则, 具有不确定性。

5.1.3 随机变量/向量之间的相互独立性

在第三章中我们发展了事件的相互独立性概念; 现在我们引进随机变量概念后, 就可以完全类似地发展随机变量/向量之间的相互独立性概念。

定义 5.1.6. 设 X, Y 是两个随机变量/向量。称 X, Y 相互独立, 如果

$$\mathbb{P}(X \leq x, Y \leq y) = \mathbb{P}(X \leq x) \cdot \mathbb{P}(Y \leq y), \forall x, y \quad (5.5)$$

成立。上式中, 在 X 是随机向量的场合, x 也理解为对应维度的向量, 同时事件 $\{X \leq x\}$ 被理解为“ X 的各维分量对应小于等于 x 的各维分量同时发生”这样一个复合事件。

类似于事件列的相互独立性, 随机变量列/向量列 $\{X_n\}_{n=1}^N$ 称为相互独立的, 如果对任意 $r \in \mathbb{N}, 2 \leq r \leq N$, 以及任意的 $1 \leq i_1 < \cdots < i_r \leq N$

$$\mathbb{P}(X_{i_1} \leq x_1, \cdots, X_{i_r} \leq x_r) = \mathbb{P}(X_{i_1} \leq x_1) \cdots \mathbb{P}(X_{i_r} \leq x_r), \forall x_1, \cdots, x_r$$

成立。但此处容易知道, 当 $N < \infty$ 时, 随机变量列/向量列 $\{X_n\}_{n=1}^N$ 相互独立, 当且仅当

$$\mathbb{P}(X_1 \leq x_1, \cdots, X_N \leq x_N) = \prod_{k=1}^N \mathbb{P}(X_k \leq x_k), \forall x_1, \cdots, x_N. \quad (5.6)$$

如果两个随机变量或随机向量 X, Y 具有相同的分布函数/分布测度, 我们就称它们同分布, 记作 $X \stackrel{d}{=} Y$ 。

设随机变量列/向量列 $\{X_n\}_{n=1}^N$ 相互独立, 如果它们具有相同的分布函数(或联合分布函数) F , 即 $X_n \sim F, \forall n$, 则称随机变量列/向量列 $\{X_n\}_{n=1}^N$ 独立

同分布于 F , 记作 $\{X_n\}_{n=1}^N \stackrel{\text{i.i.d.}}{\sim} F$, 亦可记作 $\{X_n\}_{n=1}^N \stackrel{\text{i.i.d.}}{\sim} \mu_F$, 其中 μ_F 是分布函数 F 诱导的分布测度。在统计学中此时把 $\{X_n\}_{n=1}^N$ 称为来自分布 F 的 (N 个) 简单样本, 同时把 N 称为样本量。

我们有下面近乎显然、但非常实用的推论。

推论 5.1.1. 设 $X \stackrel{d}{=} Y$, 那么 $\varphi(X) \stackrel{d}{=} \varphi(Y)$, 其中 φ 为使 $\varphi(X), \varphi(Y)$ 有意义的可测函数。

我们指出, 随机变量列/向量列 $\{X_n\}_{n=1}^N$ 相互独立, 等价于子 σ -代数列 $\{\sigma(X_n)\}_{n=1}^N$ 相互独立 (参见定义3.2.3), 其中 $\sigma(X)$ 表示 X 生成的 σ -代数。

下面的定理给出了随机变量/向量独立性的刻画与重要性质。

◆ 定理 5.1.2. (随机变量相互独立性的刻画定理) 设 X, Y 是两个随机变量/向量, 其中 $X \sim \mu_X, Y \sim \mu_Y$. 则

(1) X, Y 相互独立, 当且仅当

$$\mathbb{P}(X \in A, Y \in B) = \mathbb{P}(X \in A) \cdot \mathbb{P}(Y \in B), \forall A, B \text{ 可测}. \quad (5.7)$$

这也等价于

$$(X, Y) \sim \mu_X \otimes \mu_Y; \quad (5.8)$$

(2) X, Y 相互独立, 且 φ, ψ 是可测函数, 则 $\varphi(X), \psi(Y)$ 也相互独立。

证明: 为书写方便, 以下我们假定 X, Y 是一维随机变量; 随机向量情形的证明完全类似。

先证明 (1) 的必要性部分。当 X, Y 相互独立时, (5.5) 成立, 由此基于附录中的单调类方法 (见定理A.2.2) 可以得到

$$\mathbb{P}(X \in A, Y \in B) = \mathbb{P}(X \in A) \cdot \mathbb{P}(Y \in B), \forall A, B \in \mathcal{B}.$$

此即(5.7). 这也意味着 (X, Y) 的联合分布测度 $\mu_{X,Y}$ 满足:

$$\mu_{X,Y}(A \times B) = \mu_X(A) \cdot \mu_Y(B) = \mu_X \otimes \mu_Y(A \times B), \forall A, B \in \mathcal{B}.$$

因此 $\mu_{X,Y} = \mu_X \otimes \mu_Y$ (请同学思考此处结论为何成立?). 此即(5.8).

再证明 (1) 的充分性部分。假设(5.7)成立。在(5.7)中特殊取

$$A = (-\infty, x], B = (-\infty, y],$$

由 x, y 任意性, 立即得到 X, Y 相互独立。

现在假设 $(X, Y) \sim \mu_X \otimes \mu_Y$, 那么对任意 $x, y \in \mathbb{R}$

$$\begin{aligned}
 & \mathbb{P}(X \leq x, Y \leq y) \\
 &= \mathbb{P}((X, Y) \in (-\infty, x] \times (-\infty, y]) \\
 &= \mu_X \otimes \mu_Y((-\infty, x] \times (-\infty, y]) \\
 &= \mu_X((-\infty, x]) \cdot \mu_Y((-\infty, y]) \\
 &= \mathbb{P}(X \leq x) \cdot \mathbb{P}(Y \leq y).
 \end{aligned}$$

因此 X, Y 相互独立。

现在来证明 (2). 当 X, Y 相互独立时我们知道, 对任意 $A, B \in \mathcal{B}$, 利用 (1) 中的刻画, 对任意 $x, y \in \mathbb{R}$

$$\begin{aligned}
 & \mathbb{P}(\varphi(X) \leq x, \psi(Y) \leq y) \\
 &= \mathbb{P}(X \in \varphi^{-1}((-\infty, x]), Y \in \psi^{-1}((-\infty, y])) \\
 &= \mathbb{P}(X \in \varphi^{-1}((-\infty, x])) \cdot \mathbb{P}(Y \in \psi^{-1}((-\infty, y])) \\
 &= \mathbb{P}(\varphi(X) \leq x) \cdot \mathbb{P}(\psi(Y) \leq y).
 \end{aligned}$$

因此 $\varphi(X), \psi(Y)$ 相互独立。 □

需要指出的是, 上述定理的结论对于比随机变量更复杂的“随机元”也成立。另外, 类似于我们第三章中对事件独立性的定义源头的描述, 我们说, 两个概率空间中的“风马牛不相及”的随机变量 (从而它们具有“无关”的随机性来源) 总可以看作是相应的乘积概率空间中的相互独立的随机变量。

例 5.2. 任给两概率空间 $(\Omega_k, \mathcal{F}_k, \mathbb{P}_k), k = 1, 2$, 设 $\xi_k : (\Omega_k, \mathcal{F}_k) \rightarrow \mathbb{R}^{d_k}$ 是随机向量, $k = 1, 2$; 它们都可以自然地视作乘积概率空间

$$(\Omega, \mathcal{F}, \mathbb{P}) := (\Omega_1, \mathcal{F}_1, \mathbb{P}_1) \otimes (\Omega_2, \mathcal{F}_2, \mathbb{P}_2)$$

上的随机向量:

$$\xi_1(\omega_1, \omega_2) := \xi_1(\omega_1), \quad \xi_2(\omega_1, \omega_2) := \xi_2(\omega_2).$$

在此乘积概率空间中, 它们是相互独立的。

证明: 我们只证明随机变量的情形, 即假定 $d_1 = d_2 = 1$. 此时, 不难知道

$$\begin{aligned}
 \mathbb{P}(\xi_1 \in A_1, \xi_2 \in A_2) &= \mathbb{P}_1 \otimes \mathbb{P}_2(\{\xi_1 \in A_1\} \times \{\xi_2 \in A_2\}) \\
 &= \mathbb{P}_1(\xi_1 \in A_1) \mathbb{P}_2(\xi_2 \in A_2) \\
 &= \mathbb{P}(\xi_1 \in A_1) \mathbb{P}(\xi_2 \in A_2)
 \end{aligned}$$

对任意可测集 A_1, A_2 成立。这表明 ξ_1, ξ_2 相互独立。 □

5.2 离散型分布

5.2.1 离散型随机变量的定义

投掷一枚骰子一次所得点数是一个非常典型的随机变量。这种类型的随机变量被抽象概括为离散型随机变量。

定义 5.2.1. 设 ξ 是一个随机变量/向量。当 a 使得 $\mathbb{P}(\xi = a) > 0$ 时, 就称 a 是 ξ 的 (分布的) 一个原子。记 $D := \{a : \mathbb{P}(\xi = a) > 0\}$, 它称为 ξ 的原子集, 不难证明它是一个可数集, 因此可以写作 $D = \{a_i : 1 \leq i \leq m\}$ (其中 $m \leq \infty$)。如果此时 $\mathbb{P}(\xi \in D) = 1$, 就称 ξ 是离散型随机变量/向量。

对上述定义中的离散型随机变量 ξ , 记 $p_i := \mathbb{P}(\xi = a_i) > 0$, 称点列 $\{(a_i, p_i)\}_{i=1}^m$ (或数列 $\{p_i\}_{i=1}^m$) 为 ξ 的概率分布列, 并记

$$\xi \sim \begin{pmatrix} a_1 & \cdots & a_m \\ p_1 & \cdots & p_m \end{pmatrix} \quad \text{或} \quad \xi \sim \begin{pmatrix} a_1, & \cdots, & a_m \\ p_1, & \cdots, & p_m \end{pmatrix}.$$

显然此处的概率分布列 $\{p_i\}_{i=1}^m$ 应满足

$$\sum_{i=1}^m p_i = 1. \quad (5.9)$$

上面狭义的概率分布列要求诸 p_i 是严格正的: $p_i > 0, \forall i$. 在更一般的意义下, 一个满足(5.9)的非负数列 $\{p_i\}_{i=1}^m$ 也称为 (广义的) 概率分布列, 即其中容许某些 $p_i = 0$. 本书中的概率分布列通常作狭义的概率分布列理解; 考虑到相应的边缘概率分布列描述的需要, 联合概率分布列则按放宽的要求来理解, 此处联合概率分布列、边缘概率分布列的定义将随后给出。

有时我们也用图表5.1来表达离散随机变量 ξ 的分布律。

表 5.1: 分布律—列表形式

ξ	a_1	$\cdots$	a_m
$\mathbb{P}$	p_1	$\cdots$	p_m

对于两个离散型随机变量/向量 ξ, η , 设

$$p_{i,j} := \mathbb{P}(\xi = a_i, \eta = b_j), i = 1, \cdots, m, j = 1, \cdots, n,$$

其中 $\{a_i\}_{i=1}^m$ 互不相同, $\{b_j\}_{j=1}^n$ 也互不相同, 并且

$$\sum_{1 \leq i \leq m} \sum_{1 \leq j \leq n} p_{i,j} = 1, \quad (5.10)$$

表 5.2: 联合分布律的列表形式

(a) 列表形式				(b) 列联表形式				
$\xi \backslash \eta$	b_1	$\cdots$	b_n	$\xi \backslash \eta$	b_1	$\cdots$	b_n	
a_1	$p_{1,1}$	$\cdots$	$p_{1,n}$	a_1	$p_{1,1}$	$\cdots$	$p_{1,n}$	$p_{1,\bullet}$
a_2	$p_{2,1}$	$\cdots$	$p_{2,n}$	a_2	$p_{2,1}$	$\cdots$	$p_{2,n}$	$p_{2,\bullet}$
$\vdots$	$\vdots$	$\cdots$	$\vdots$	$\vdots$	$\vdots$	$\cdots$	$\vdots$	$\vdots$
a_m	$p_{m,1}$	$\cdots$	$p_{m,n}$	a_m	$p_{m,1}$	$\cdots$	$p_{m,n}$	$p_{m,\bullet}$
					$p_{\bullet,1}$	$\cdots$	$p_{\bullet,n}$	

则称 $\{(a_i, b_j; p_{i,j})\}_{\substack{1 \leq i \leq m \\ 1 \leq j \leq n}}$ (或 $\{p_{i,j}\}_{\substack{1 \leq i \leq m \\ 1 \leq j \leq n}}$) 为随机向量 (ξ, η) 的联合概率分布列, 此处一般要求

$$p_{i,\bullet} := \mathbb{P}(\xi = a_i) = \sum_{j=1}^n p_{i,j} > 0, \quad p_{\bullet,j} := \mathbb{P}(\eta = b_j) = \sum_{i=1}^m p_{i,j} > 0.$$

有时也用图表 5.2(a) 来表达上述 (ξ, η) 的分布律。有时进一步在表格 5.2(a) 的每行、每列的末端分别配置上对应的 $p_{i,\bullet}, p_{\bullet,j}$ 值, 这种图表就称为列联表, 如表 5.2(b) 所示。此处我们称 $\{(a_i, p_{i,\bullet})\}_{i=1}^m$ (或 $\{p_{i,\bullet}\}_{i=1}^m$) 为随机向量 (ξ, η) 的 (第一个) 边缘概率分布列; 类似地, 称 $\{(b_j, p_{\bullet,j})\}_{j=1}^n$ (或 $\{p_{\bullet,j}\}_{j=1}^n$) 为随机向量 (ξ, η) 的 (第二个) 边缘概率分布列。当 ξ 是离散型随机变量或离散型随机向量时, 我们也称它的 (联合) 分布函数和 (联合) 分布测度是离散型的。

在上述定义中, 如果 D 是单点集 $\{a\}$, 即 $\mathbb{P}(\xi = a) = 1$, 则称 ξ 服从单点分布或退化分布、Dirac 分布 (Dirac Distribution), 对应分布测度记作 δ_a , 称为 a 点处的 Dirac 测度 (或单点测度); 此时可记 $\xi \sim \delta_a$, 这样的随机变量/向量也被称为退化随机变量/向量。当 D 是两点集 $\{a, b\}$, 即 $\mathbb{P}(\xi \in \{a, b\}) = 1$ 且 $\mathbb{P}(\xi = a) > 0, \mathbb{P}(\xi = b) > 0$ 时, 我们称 ξ 服从两点分布 (Two-Point Distribution)。

对于离散型随机变量/向量之间的独立性, 我们有下面更简单的基于概率分布列的判据, 这使得在离散型随机变量的相互独立性的判断中列联表非常有用; 有关证明留给读者。

推论 5.2.1. 设 X, Y 都是离散型随机变量/向量。它们相互独立当且仅当

$$\mathbb{P}(X = x, Y = y) = \mathbb{P}(X = x)\mathbb{P}(Y = y), \quad \forall x, y.$$

5.2.2 常见离散型分布

以下我们介绍一些常见的离散型分布。

例 5.3. (离散型均匀分布) 设 $N \geq 2$, $X \sim \left(\frac{a_1}{N}, \dots, \frac{a_N}{N}\right)$, 则此分布也称为 $\{a_1, \dots, a_N\}$ 上的离散均匀分布 (*Discrete Uniform Distribution*), 简记为 $X \sim U(\{a_1, \dots, a_N\})$. $N = 6, a_k = k, k = 1, \dots, 6$ 时 X 可解释为投掷一枚均匀骰子一次所得点数。

例 5.4. (0-1 两点分布) 设 $A \in \mathcal{F}$, 且 $p := \mathbb{P}(A) \in [0, 1]$; 记 $q := 1 - p$. 则 $\xi := 1_A$ 是一个随机变量, 并且 $\mathbb{P}(\xi = 1) = p, \mathbb{P}(\xi = 0) = q$.

(1) 当 $p = 0$ 或 $p = 1$ 时, $\xi \sim \delta_p$, 它是一个退化分布 (单点分布/*Dirac* 分布);

(2) 当 $p \in (0, 1)$ 时, ξ 的分布也称为 0-1 两点分布, 记作 $\xi \sim \binom{0}{q} \binom{1}{p}$, 有时也记作 $\xi \sim B(1, p)$, 称为 *Bernoulli* 两点分布。

以下我们总假设某项试验成功的概率为 p (称为成功概率参数), 其中 $p \in (0, 1)$, 此时总记 $q := 1 - p$. 当第 k 次试验成功时, 我们记 $X_k = 1$, 否则记 $X_k = 0$. 于是 $\{X_k\}_{k=1}^n \stackrel{\text{i.i.d.}}{\sim} B(1, p)$.

例 5.5. (Bernoulli 二项分布) 设 $\{X_k\}_{k=1}^n \stackrel{\text{i.i.d.}}{\sim} B(1, p)$, 记 $S_n := X_1 + \dots + X_n$. 它可解释为 “重复做 n 次试验后试验成功的总次数”, 满足

$$\mathbb{P}(S_n = k) = \binom{n}{k} p^k q^{n-k}, \quad k = 0, 1, \dots, n. \quad (5.11)$$

因为 $1 = (p + q)^n = \sum_{k=0}^n \binom{n}{k} p^k q^{n-k}$, 所以 S_n 的分布律称为 (*Bernoulli*) 二项分布 (*Binomial Distribution*), 记作 $S_n \sim B(n, p)$.

二项分布还有如下推广—多项分布。

例 5.6. (多项分布) 给定 $n \in \mathbb{N}$, 设 $\{X_k\}_{k=1}^n \stackrel{\text{i.i.d.}}{\sim} \begin{pmatrix} e_1, & \dots, & e_r \\ p_1, & \dots, & p_r \end{pmatrix}$, 其中 $2 \leq r < \infty$, 行向量组 $\{e_k\}_{k=1}^r$ 是 $\mathbb{R}^r$ 中标准正交基, 即

$$e_k = (\underbrace{0, \dots, 0}_{k-1 \text{ 个 } 0}, \underbrace{1, 0, \dots, 0}_{r-k \text{ 个 } 0}), \quad k = 1, \dots, r.$$

那么 $S_n := X_1 + \dots + X_n$ 服从的分布称为 “自由度参数为 n 、概率分布列参数为 $\{p_k\}_{k=1}^r$ 的多项分布 (*Multinomial Distribution*)”, 它的概率分布列如下:

$$\mathbb{P}(S_n = (m_1, \dots, m_r)) = \binom{n}{m_1, \dots, m_r} p_1^{m_1} \dots p_r^{m_r}, \quad (5.12)$$

其中非负整数组 $\{m_k\}_{k=1}^r$ 满足 $m_1 + \dots + m_r = n$, 而多项组合数

$$\binom{n}{m_1, \dots, m_r} := \frac{n!}{m_1! \dots m_r!}.$$

当存在正整数 $N, \ell_1, \dots, \ell_r$ 使得 $p_k = \frac{\ell_k}{N}, k = 1, \dots, N$ 时, 上述模型可以直观解释为: 一个坛子中有 r 种不同颜色球共 N 个, 其中第 k 种颜色的球恰好有 ℓ_k 个, $k = 1, \dots, r$. 从这个坛子中有放回地重复取球 n 次, 最后总共取得“第 k 种颜色的球恰好 m_k 次, $k = 1, \dots, r$ ”的概率就是(5.12)右端表达式。

例 5.7. (几何分布) 现在设 $\{X_k\}_{k=1}^{\infty} \stackrel{\text{i.i.d.}}{\sim} B(1, p)$, 定义 $\tau := \inf\{n \geq 1 : X_n = 1\}$, 它可解释为“为获得一次成功的试验所需进行的重复试验次数”, 满足

$$\mathbb{P}(\tau = k) = pq^{k-1}, k = 1, 2, \dots. \quad (5.13)$$

τ 的分布律称为几何分布 (Geometric Distribution), 记作 $\tau \sim \text{Geo}(p)$.

例 5.8. (Pascal 分布与负二项分布) 给定 $r \in \mathbb{N}$. 现在设 $\{\tau_k\}_{k=1}^{\infty} \stackrel{\text{i.i.d.}}{\sim} \text{Geo}(p)$, 定义 $N_r := \tau_1 + \dots + \tau_r$, 它可解释为“为获得累计 r 次成功的试验所需进行的重复试验次数”, 满足

$$\mathbb{P}(N_r = \ell) = \binom{\ell-1}{r-1} p^r q^{\ell-r}, \ell = r, r+1, \dots. \quad (5.14)$$

N_r 的分布律称为 Pascal 分布 (Pascal Distribution), 记作 $N_r \sim \text{Pascal}(r, p)$.

现在令 $\tilde{N}_r = N_r - r$, 那么 $\tilde{N}_r$ 满足

$$\mathbb{P}(\tilde{N}_r = \ell) = \binom{r+\ell-1}{\ell} p^r q^{\ell}, \ell = 0, 1, \dots, \quad (5.15)$$

记作 $\tilde{N}_r \sim \text{NB}(r, p)$, 称之为负二项分布 (Negative Binomial Distribution). “负二项分布”的得名缘由如下: 对 $\alpha \in \mathbb{R}$ 与 $\ell \in \mathbb{Z}_+$, 引进记号 $\binom{\alpha}{\ell} := \frac{\prod_{k=1}^{\ell} (\alpha - k + 1)}{\ell!}$ (约定 $\binom{\alpha}{0} := 1$), 于是(5.15)的右端可表达为

$$\binom{r+\ell-1}{\ell} p^r q^{\ell} = \binom{-r}{\ell} p^r (-q)^{\ell},$$

上述表达式中自动出现了负指标的“组合数” $\binom{-r}{\ell}$, 它与牛顿二项式定理

$$(1+x)^{-r} = \sum_{\ell=0}^{\infty} \binom{-r}{\ell} x^{\ell}, \forall x \in (-1, 1) \quad (5.16)$$

相关联。类似地, $\tilde{N}_r$ 可解释为“为获得累计 r 次成功的试验所需忍受的重复试验失败次数”。

例 5.9. (超几何分布) 我们用 Pólya 的坛子模型来解释本例将介绍的超几何分布: 从有 b 个黑球、 r 个红球的坛子里无放回地取 $n \leq b+r$ 个球所获得的黑球数量记作 X_n , 则 X_n 的概率分布列为

$$\mathbb{P}(X_n = k) = \frac{\binom{b}{k} \binom{r}{n-k}}{\binom{b+r}{n}}, \ell_1 := (n-r)^+ \leq k \leq \ell_2 := b \wedge n. \quad (5.17)$$

此时, 我们记 $X_n \sim H(b, r; n)$, 称之为超几何分布 (Hypergeometric Distribution)

在例2.5中, 当 $p = \frac{b}{b+r}$ 时, 从有 b 个黑球、 r 个红球的坛子里有放回地取 $n \leq b+r$ 个球所获得的黑球数量记作 X , 则 $X \sim B(n, p)$.

对上例中的 X_n , 如果 $p \in (0, 1)$, $b \rightarrow \infty, r \rightarrow \infty$ 且 $\frac{b}{b+r} \rightarrow p$, 则对固定的 $0 \leq k \leq n$

$$\mathbb{P}(X_n = k) = \frac{\binom{b}{k} \binom{r}{n-k}}{\binom{b+r}{n}} \rightarrow \binom{n}{k} p^k (1-p)^{n-k}.$$

因此例5.9中的分布被称为超几何分布纯粹是历史原因 (源于 Euler 对超几何级数的研究), 它本质上是与 Bernoulli 二项分布对应的 Pólya 坛子模型无放回摸球版本。

下例中的分布是与 Pascal 分布对应的 Pólya 坛子模型无放回摸球版本。

例 5.10. (*Pascal 分布的 Pólya 坛子模型无放回摸球版本*) 在有 b 个黑球、 r 个红球的坛子里进行反复的无放回取球操作。为了取到 $s \leq b$ 个黑球所需的最少取球次数记作 Y_s , 则 Y_s 的概率分布列为

$$\mathbb{P}(Y_s = \ell) = \frac{s}{\ell} \cdot \frac{\binom{b}{s} \binom{r}{\ell-s}}{\binom{b+r}{\ell}}, s \leq \ell \leq r+s. \quad (5.18)$$

当 $\frac{b}{b+r} \rightarrow p \in (0, 1), b+r \rightarrow \infty, q := 1-p$ 时, $\mathbb{P}(Y_s = \ell) \rightarrow \binom{\ell-1}{s-1} p^s q^{\ell-s}$, 即此时 Y_s 的极限分布律为 Pascal(s, p).

例 5.11. (*Poisson 小数定理与 Poisson 分布*) 设 $\{X_n\}_{n=1}^{\infty}$ 满足 $X_n \sim B(n, p_n)$, 其中 p_n 满足 $\lim_{n \rightarrow +\infty} np_n = \lambda \in (0, \infty)$, 那么

$$\lim_{n \rightarrow +\infty} \mathbb{P}(X_n = k) = \frac{\lambda^k}{k!} e^{-\lambda}, k = 0, 1, \dots \quad (5.19)$$

上述结论称为 Poisson 小数定理。 $\{\frac{\lambda^k}{k!} e^{-\lambda}\}_{k=0}^{\infty}$ 是一个概率分布列, 对应分布称为参数为 λ 的 Poisson 分布 (Poisson Distribution), 记作 Poisson(λ). 于是 $Y \sim \text{Poisson}(\lambda)$ 时

$$\mathbb{P}(Y = k) = \frac{\lambda^k}{k!} e^{-\lambda}, k = 0, 1, \dots \quad (5.20)$$

现实世界中许多量的分布规律近似服从 Poisson 分布。例如, 1910 年著名科学家 Rutherford (卢瑟福, 1871/08/30 — 1937/10/19) 和 Geiger (盖




图 5.1: Rutherford 与 Geiger 放射性粒子数观察频率与拟合概率

革, 1882/09/30 —1945/09/24) 观察了放射性物质钋 (Polonium) 放射 α 粒子的情况; 他们进行了 $N = 2608$ 次观测, 每次观察 7.5 秒, 一共观测到 10094 个 α 粒子, 表格5.3就是他们的实验数据的拟合情况 (参见文献^[103]第 77 页), 而图5.1是根据该表格而绘制。

表 5.3: Rutherford 与 Geiger 放射性粒子数观察频率与拟合概率

放射粒子数 X	观察到次数 n_k	频率 $\nu_k = \frac{n_k}{N}$	拟合概率 (参数 $\lambda = 3.87$) $\mathbb{P}(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}$
0	57	0.022	0.021
1	203	0.078	0.081
2	383	0.147	0.156
3	525	0.201	0.201
4	532	0.204	0.195
5	408	0.156	0.151
6	273	0.105	0.097
7	139	0.053	0.054
8	45	0.017	0.026
9	27	0.010	0.011
10	10	0.004	0.004
≥ 11	6	0.002	0.003
总计	N=2608	0.999	1.000

统计数据表明, 某段高速公路上一一年内的交通事故数、某市场一天中到达的顾客次数、某办公室一天中收到的电话数等都近似服从 Poisson 分布。又如, 有人统计了 1500-1931 年共 $N = 432$ 年间的战争, 一年中爆发战争的频率与 Poisson 分布的概率接近, 表5.4就是这些数据的拟合情况 (参见文献^[108]第 63 页); 图5.2是根据该表格而绘制。

有兴趣的同学在学完全书后, 可依托第十二章中的有关理论, 做基于上述数据构建 Poisson 分布模型、并进行假设检验的工作, 此处我们略去了这些细节。




图 5.2: 1500 —1931 年间发生的重要战争年度观察频率与拟合概率

表 5.4: 1500—1931 年间发生的重要战争年度频次与概率拟合

年度战争次数 X	观察到的年数 n_k	频率 $\nu_k = \frac{n_k}{N}$	拟合概率 (参数 $\lambda=0.69$) $\mathbb{P}(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}$
0	223	0.516	0.502
1	142	0.329	0.346
2	48	0.111	0.119
3	15	0.035	0.028
≥ 4	4	0.009	0.005
总计	N=432	1.000	1.000

5.3 离散型分布的应用

在建立了公理化的概率理论体系后，之前古典概率模型和几何概率模型的有关应用问题都可以转化为公理化的概率模型中离散型随机变量和连续型随机变量（见第八章）的讨论。这里我们提供离散型分布的几个典型应用。

5.3.1 应用（I）：真假随机性的判断

假设有甲、乙二人声称他们做独立重复投掷一枚硬币 100 次的随机试验记录¹，如表格5.5所示，其中 1 表示获得硬币正面，0 表示获得硬币反面。

表 5.5: 甲、乙声称的投掷硬币 100 次的实验记录

记录序号 \ 实验者	甲	乙
第 1—20 次	1001110100 1001101101	1001010100 1010011010
第 21—40 次	1000110100 1011101101	0110010101 0110010010
第 41—60 次	1110001100 1011011000	0111001010 0101010110
第 61—80 次	1011000101 1001000110	0011000100 1001001010
第 81—100 次	1110100010 1110101010	1010110101 1001110110

我们的问题是：他们的实验记录可信吗？是否这些记录有可能是人为伪造的数据呢？

从甲、乙的实验记录中知道：甲掷出了 52 个正面、48 个反面，正面的频率是 52%；乙掷出了 47 个正面、53 个反面，正面的频率是 47%。单纯是从这个

¹ 本节内容来源于何书元教授编写的教材^[108]，略有改动。

频率数据不能判断数据的真伪。为此我们需要更细致地检查实验数据序列,以便更好地利用其中隐藏的信息。

在上述记录中,我们称连续的“0”字符串为“0”游程,而对应的“0”游程中包含 0 的个数就称为这个游程的游程长度;对应也有“1”游程及其长度的说法。例如甲的记录中第一个“0”游程是“00”(由第二、三次的实验记录形成),其游程长度为 2;甲记录中的第二个“1”游程为“111”(由第三、四、五次实验记录形成),其游程长度为 3。由于 0、1 地位是对称的,除非特殊申明,我们以下说的游程都指“1”游程。给定一个长度为 n 的“0”、“1”序列,我们关心两个量:游程的总数量 R_n (简称游程数)、最长的游程长度 L_n (简称最大游程)。关于此两个量的分布律,我们有下面的结果。

♠ 定理 5.3.1. 假设 $\{X_k\}_{k=1}^n \stackrel{\text{i.i.d.}}{\sim} B(1, p)$, 其中 $p \in (0, 1)$. 在已知

$$S_n := \sum_{k=1}^n X_k = m$$

(其中 $1 \leq m \leq n-1$) 的条件下,“0”、“1”序列 $X_1, \dots, X_n$ 的游程数 R_n 满足

$$\mathbb{P}(R_n = r | S_n = m) = \frac{\binom{n-m+1}{r} \binom{m-1}{m-r}}{\binom{n}{m}}, \quad r = 1, \dots, m,$$

我们可以把上面条件分布简单记作 $R_n | S_n = m \sim H(n-m+1, m-1; m)$.

♠ 定理 5.3.2. 假设 $\{X_k\}_{k=1}^n \stackrel{\text{i.i.d.}}{\sim} B(1, \frac{1}{2})$. “0”、“1”序列 $X_1, \dots, X_n$ 的最大游程长度 L_n 满足

$$\mathbb{P}(L_n \geq k) = \sum_{1 \leq r \leq \frac{n+1}{k+1}} (-1)^{r+1} \cdot \frac{\binom{n-rk}{r} + 2\binom{n-rk}{r-1}}{2^{r(k+1)}}, \quad k = 1, \dots, n.$$

定理 5.3.1 的参考证明. 考虑样本空间为 $\Omega := \{0, 1\}^n$, 其中 $\omega_i = X_i, i = 1, \dots, n$. 不难知道, 在 $S_n = m$ 的条件下, 恰有 r 个“1”游程的事件 $\{\omega \in \Omega : S_n = m, R_n = r\}$ 中元素个数与下面方程组

$$\begin{cases} y_0 + y_1 + \dots + y_r &= n - m, \\ z_1 + \dots + z_r &= m, \\ y_0, y_r \geq 0, y_1, \dots, y_{r-1} &\geq 1, \\ z_1, \dots, z_r &\geq 1 \end{cases} \quad (5.21)$$

的非负整数解的个数相同; 而这个方程组在对应约束下解的个数为

$$\binom{n-m+1}{r} \cdot \binom{m-1}{r-1} = \binom{n-m+1}{r} \binom{m-1}{m-r}.$$

又 $\{\omega \in \Omega : S_n = m\}$ 中的元素个数为 $\binom{n}{m}$, 从而

$$\mathbb{P}(R_n = r | S_n = m) = \frac{\binom{n-m+1}{r} \binom{m-1}{m-r}}{\binom{n}{m}}. \quad \square.$$

定理5.3.2的参考证明. 此处的证明参考了文献^[86]中的证明; 那里还提供了一种直接用 Jordan 恒等式进行计算的证明方法。我们把 $\{X_k\}_{k=1}^n$ 视作投掷 (均匀) 硬币所得的记录序列, 其中 “1” 表示正面, “0” 表示反面。

对固定的 k , 令 $P_k(n) := \mathbb{P}(L_n \geq k)$; 此地 $\{L_n \geq k\}$ 可解释为投掷 n 次硬币的过程中曾经出现过连续 k 次的正面。令 F_j 表示投掷 n 次硬币的过程中, 第一次反面是第 j 次投掷的结果; 令 H_k 表示前 k 次投掷结果都是正面。于是, 对 $j = 1, \dots, k$, 我们有 $\mathbb{P}(L_n \geq k | F_j) = P_k(n-j)$, $\mathbb{P}(F_j) = 2^{-j}$, 且 $\mathbb{P}(L_n \geq k | H_k) = 1$, $\mathbb{P}(H_k) = 2^{-k}$, 因此

$$P_k(n) = \sum_{j=1}^k P_k(n-j) \cdot 2^{-j} + 2^{-k}.$$

结合 $P_k(k) = 2^{-k}$, 使用归纳法结合一些复杂的整理工作就能完成定理的证明, 此处从略。 $\square$

在上面的问题中, 仔细检查乙的实验记录, 100 次投掷硬币的结果中, 有 47 次正面朝上, 但是 “1” 游程数达到了 35 个。根据定理 5.3.1, 我们可以算出

$$\begin{aligned} \mathbb{P}(R_{100} \leq 16 | S_{100} = 47) &\approx 1.570 \times 10^{-4}, \\ \mathbb{P}(R_{100} \geq 35 | S_{100} = 47) &\approx 1.026 \times 10^{-4}. \end{aligned}$$

这表明 “1” 游程数达到了 35 个是一个非常小的概率, 而这么小的概率居然在一次随机试验中发生了, 因此我们有很强理由据此怀疑乙的实验记录的真实性。如果来检查甲的实验记录, 100 次投掷硬币的结果中, 有 52 个正面, “1” 游程数达到了 31 个, 同样可以计算出

$$\mathbb{P}(R_{100} = 31 | S_{100} = 52) \approx 0.0142, \mathbb{P}(R_{100} \geq 31 | S_{100} = 52) \approx 0.0219.$$

这两个概率都不算大, 从而也有一定理由怀疑甲的实验记录的真实性。

如果认为甲、乙实验中的硬币是均匀的, 即认为他们实验中硬币投掷后正面、反面出现的可能性是相同的, 那么我们还可以用定理 5.3.2 的理论来检验其实验数据。此时, 我们有下面的结果

$$\begin{aligned} \mathbb{P}(L_{100} \geq 3) &\approx 0.9997, \\ \mathbb{P}(L_{100} \geq 4) &\approx 0.9727, \quad \mathbb{P}(L_{100} = 3) \approx 0.0270, \end{aligned}$$

$$\mathbb{P}(L_{100} \geq 5) \approx 0.8101, \quad \mathbb{P}(L_{100} = 4) \approx 0.1626,$$

$$\mathbb{P}(L_{100} \geq 6) \approx 0.5461, \quad \mathbb{P}(L_{100} = 5) \approx 0.2640,$$

$$\mathbb{P}(L_{100} \geq 7) \approx 0.3175, \quad \mathbb{P}(L_{100} = 6) \approx 0.2286,$$

$$\mathbb{P}(L_{100} \geq 8) \approx 0.1702, \quad \mathbb{P}(L_{100} = 7) \approx 0.1473,$$

$$\mathbb{P}(L_{100} \geq 9) \approx 0.0876, \quad \mathbb{P}(L_{100} = 8) \approx 0.0826.$$

在甲的实验记录中, 最大“0”游程是3, 最大“1”游程是4; 在乙的实验记录中, 最大“0”游程是3, 最大“1”游程是3。因此, 根据上面的结果, 我们同样有理由怀疑甲乙二人实验记录的真实性。

综上, 乙的实验记录最可疑, 甲的实验记录也值得怀疑。

5.3.2 应用 (II): 两个极大似然估计的例子

下面我们举两个对离散型分布的分布参数做极大似然估计的例子。对于其他一些离散型分布族, 读者掌握了极大似然估计的思想后, 也可以思考应当如何进行它们的分布参数的极大似然估计。

例 5.12. (频率代替概率的合理性) 设某项实验成功的概率为 p , S_n 为该实验重复做 n 次后, 实验成功的总次数, 于是 n 次实验成功的频率为

$$f_n := \frac{S_n}{n}.$$

我们知道, $S_n \sim B(n, p)$, 亦即 $\mathbb{P}(S_n = k) = \binom{n}{k} p^k (1-p)^{n-k}$. 不难知道 $\mathbb{P}(S_n = k)$ 作为参数 p 的函数 (k 视作常数) 的最大值点为 $\hat{p} = \frac{k}{n}$. 这个过程可以总结如下¹:

$$\hat{p} = \arg \max_{p \in [0, 1]} \mathbb{P}(S_n = k) = \frac{k}{n}, \quad \text{当 } S_n = k \text{ 时}.$$

也就是说, 当知道该实验重复做 n 次总共成功 S_n 次时, 我们对实验成功概率参数 p 的一种合理估计为 $\hat{p} := \frac{S_n}{n} =: f_n$. 上述估计方法就是所谓的极大似然估计方法。这个例子说明, 在实际生活中, 基于极大似然估计的思想, 使用实验成功的频率作为实验成功概率的估计是有道理的; 后文中给出的 *Bernoulli* 弱大数律 (以及 *Kolmogorov* 强大数律) 进一步说明, 在大样本条件下这样的估计值能逼近真实的参数值。至于这样做估计的误差对应的近似分布/极限分布, 可由后文的中心极限定理给出。

¹ 此处记号 $\arg \max_{p \in D} f(p)$ 表示在约束条件 $p \in D$ 下找到的函数 $f(p)$ 的极大值点 (假定有唯一极大值点)。

例 5.13. (估算池塘里的鱼) 现有一个池塘, 内有若干成鱼; 假设共 N 条, 其中 N 未知待估计。常用的估计方法如下: 首先从池塘中捕捞出 M 条成鱼, 都做好标记, 并重新放回池塘。过几天后 (假定期间成鱼数量不改变, 且之前制作的标记不会脱落), 再次进行捕捞, 捞出了 n 条成鱼, 其中有 $X = m$ 条是之前做过标记的成鱼。那么统计学家认为, 如下定义的 $\hat{N}$ 就是一个合理的估计量:

$$\hat{N} := \left\langle \frac{nM}{X} \right\rangle,$$

其中 $\langle x \rangle$ 代表离 x 最近的整数 (当 $x - \frac{1}{2}$ 为整数时, 取 $\langle x \rangle = x - \frac{1}{2}$)。上述估计的逻辑是: 此时 $X \sim H(M, N - M; n)$, $X = m$ 的概率值

$$\mathbb{P}(X = m) = \frac{\binom{M}{m} \binom{N-M}{n-m}}{\binom{N}{n}}$$

作为参数 N 的函数, 最大值点 $\hat{N}$ 就是离 $\frac{nM}{m}$ 最近的整数, 请读者自行论证这一点。整体计算过程可以总结如下

$$\hat{N} = \arg \max_N \mathbb{P}(X = m) = \left\langle \frac{nM}{m} \right\rangle, \quad \text{当 } X = m \text{ 时}.$$

由此 $\hat{N} := \left\langle \frac{nM}{X} \right\rangle$ 就是此模型下的极大似然估计。

📌 注记 5.4. 历史上, 上述巧妙的估计方法最早是 Laplace 在 1786 年为了估计法国人口时提出的。上述统计方法经后人发展成为所谓的“捕获再捕获抽样”理论, 广泛应用于生态学等领域。上述方法, 本质上是二重抽样: 只不过第一重抽样的目的是给予样本“贴标签”再放回总样本中。由于有可能二次抽样时没有获得贴有标签的子样本, 即 $X = 0$, 从而统计方法失效, 为此人们提出所谓的“逆抽样”的方法: 在第二次抽样时, 并不对 n 的数量作出规定, 而是一直抽到曾做过记号的单元数达到 s (它是预先给定的值) 个为止。假设第二次抽样的样本量为 n (它是随机的, 分布律参见例 5.10), 此时可以同样用估计量 $\hat{N} := \left\langle \frac{nM}{s} \right\rangle$ 作为总体样本量的估计, 该估计仍然是极大似然估计, 请有兴趣的同学证明这一点。

5.4 本章小结与学习建议

在本章我们首先引入了随机变量/随机向量的概念, 讨论了随机变量/随机向量的分布律 (即随机变量/随机向量的分布测度或分布函数)、随机变量/随机向量的独立性及其分布律刻画; 之后介绍了离散型随机变量/随机向量的概念, 并重点介绍了一些典型的离散型分布。

我们可以很明显地看到, 第三章介绍的乘积概率测度在讨论随机变量/随机向量的独立性的分布律刻画中起到了非常关键的作用; 这在第十一章讨论随机变量/随机向量的独立性的特征函数刻画中亦有突出体现—这说明了我们在

讲义中介绍概率空间的乘积技术在逻辑上的必要性与实际应用中的重要性。另外,本章中关于随机变量的补丁程序的讨论在逻辑和实际应用角度也都是必要的;特别地,如果读者秉承“概率建模”的理念,把概率空间解释成随机试验的概率建模,把随机变量解释成随机试验中的物理测量,则有关概念也自然具有了来自生活经验的直观,而关于随机变量的几乎处处相等意义下的认同及有关补丁程序就成为非常自然的事情了。

习 题 5

习题 5.1. 证明: 在概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 中, 1_A 是随机变量当且仅当 $A \in \mathcal{F}$.

习题 5.2. 设 $\{X_n\}_{n=1}^\infty$ 是一列随机变量, 证明: $\sup_{n \geq 1} X_n, \inf_{n \geq 1} X_n, \overline{\lim}_{n \rightarrow \infty} X_n, \underline{\lim}_{n \rightarrow \infty} X_n$ 都是广义随机变量¹。

习题 5.3. 设 $\{X_n\}_{n=1}^\infty$ 是一列随机变量, τ 是一个非负整数值随机变量。定义 $S_n := X_1 + \cdots + X_n, \forall n \geq 1; S_0 := 0$. 证明: S_τ 是随机变量。

习题 5.4. 试证明: 一个连续的分佈函数 $F: \mathbb{R} \rightarrow \mathbb{R}$ 是一致连续的。

习题 5.5. 设 $\xi \sim F$, 其中 $F: \mathbb{R} \rightarrow \mathbb{R}$ 是分佈函数。那么 F 在 $x = a$ 处连续的充分必要条件是 $\mathbb{P}(\xi = a) = 0$.

习题 5.6. 设 $(X_1, X_2) \sim F$, F_1, F_2 是对应的边缘分佈函数。那么联合分佈函数 F 是二元连续函数的充分必要条件是边缘分佈函数 F_1, F_2 都是连续函数。

习题 5.7. 设 D 是 $\mathbb{R}$ 中稠密子集, F 是分佈函数, 则 F 由 $F|_D$ 唯一决定。

习题 5.8. 设 $\mathbb{P}(X \leq x, Y \leq y) = F(x \wedge y), \forall x, y$, 求证: $X \stackrel{\text{a.s.}}{=} Y$.

习题 5.9. 设 $X \sim F$, 其中 X 是 d 维随机向量, 定义分佈 F 的支撑集

$$S_F := \{x: \mathbb{P}(\|X - x\| \leq \frac{1}{n}) > 0, \forall n \geq 1\},$$

其中 $\|\cdot\|$ 是 $\mathbb{R}^d$ 中欧氏范数。那么 S_F 是闭集, 且 $\mathbb{P}(X \in S_F) = 1$.

习题 5.10. 试证明命题 5.1.1.

习题 5.11. 试证明推论 5.2.1.

习题 5.12. 设 X 是离散型随机变量/向量, Y 是一般的随机变量/向量。求证: X, Y 相互独立的充分必要条件是

$$\mathbb{P}(X = x, Y \leq y) = \mathbb{P}(X = x) \cdot \mathbb{P}(Y \leq y), \quad \forall x, y.$$

¹不少教材在此处给出的结论是“随机变量”而不是“广义随机变量”;这是有失严谨性的。

习题 5.13. 设 $X \sim B(1, p)$. 求 X 的分布函数 F , 并计算 $Y := F(X)$ 的分布。

习题 5.14. 设甲乙二人相互独立地各投掷一枚均匀的硬币 n 次, 并各自计算得到的硬币正面次数。问: 他们总计得到相同的正面次数的概率有多大?

习题 5.15. 已知三个随机变量 $X_0 \sim F_0, X_1 \sim F_1, I \sim B(1, p)$ 相互独立, 其中 F_0, F_1 是分布函数。求证: $X_I \sim (1-p)F_0 + pF_1$ 。

习题 5.16. 证明几何分布有下面的无记忆性: 设 $X \sim \text{Geo}(p)$, 则

$$\mathbb{P}(X > n+m | X > n) = \mathbb{P}(X > m), \forall n, m \in \mathbb{Z}_+.$$

习题 5.17. 请利用 *Pascal* 分布来解决 *Banach* 火柴问题 (见习题 2.54)。

习题 5.18. 一枚深水炸弹击沉、击伤和不能击中一艘潜水艇的概率分别为 $1/3, 1/2$ 和 $1/6$. 假定两次击伤该潜水艇也能导致该潜水艇沉没。求用 3 枚深水炸弹击沉该潜水艇的概率。为了 99% 的把握击沉该潜水艇, 我们最少应该发射几枚深水炸弹?

习题 5.19. 某人自称有超强感官力。作为对他的检验, 将一枚均匀的硬币抛 10 次, 让他事先预测抛得的结果, 10 次中他说对了 7 次。如果他没有超强感官力, 他能做出至少如此好的预测的概率有多大呢?

习题 5.20. 假定某 12 人组成的陪审团至少有 9 票投有罪票时才能判决一被告有罪, 并设陪审员对有罪人投无罪票的概率为 0.2, 对无罪人投有罪票的概率为 0.1; 没有弃权票。如果各陪审员独立行事, 且 65% 的被告是事实上有罪的。请问此陪审团做出正确判决的概率。被告中被判为有罪的占多大比例?

习题 5.21. 二人通过“石头-剪刀-布”的手势游戏方式决出输家、赢家所需的局数记作 X , 求 X 的分布律。

习题 5.22. 3 个小孩玩捉迷藏的游戏。他们决定用“黑白配”的方式 (参见习题 3.43) 决定谁当“蒙眼人”。请问:

- (1) 正好三轮“黑白配”就决出输家的概率;
- (2) 进行了 4 轮以上“黑白配”才决出输家的概率;
- (3) 三个小孩通过“黑白配”的方式决出唯一输家所需的局数记作 X , 求 X 的分布律。

习题 5.23. 五个孩子进行游戏, 游戏设置同习题 3.44. 求三局之内能决出唯一输家的概率。

习题 5.24. 令 $\{X_k\}_{k=1}^3 \stackrel{\text{i.i.d.}}{\sim} \begin{pmatrix} -1 & 1 \\ \frac{1}{2} & \frac{1}{2} \end{pmatrix}$; 取 $Y_1 := X_2 \cdot X_3, Y_2 := X_3 \cdot X_1, Y_3 := X_1 \cdot X_2$. 求证: $\{Y_k\}_{k=1}^3$ 两两独立, 但不相互独立; 它们都同分布于 X_1 .

习题 5.25. $\{X_k \sim B(n_k, p)\}_{k=1}^2$ 相互独立, 那么 $X_1 + X_2 \sim B(n_1 + n_2, p)$.

习题 5.26. $\{X_k \sim \text{Poisson}(\lambda_k)\}_{k=1}^2$ 相互独立, 那么 $X_1 + X_2 \sim \text{Poisson}(\lambda_1 + \lambda_2)$.

习题 5.27. 设 $\{\tau_k \sim \text{Geo}(p_k)\}_{k=1}^n$ 相互独立, $\tau := \min_{1 \leq k \leq n} \tau_k$, $q_k := 1 - p_k, k = 1, \dots, n$. 证明 $\tau \sim \text{Geo}(1 - q_1 \cdots q_n)$.

习题 5.28. 设有两个现象 A, B , 记 $p_A, p_B \in (0, 1)$ 为单次实验中 A 现象、 B 现象各自成功出现的概率。我们总记 τ_A 为检测到 A 现象所需进行的最少重复试验次数; 记号 τ_B 作同样理解。求证:

- (1) $\tau_A \sim \text{Geo}(p_A), \tau_B \sim \text{Geo}(p_B)$;
- (2) $\tau_{A \cup B} = \min(\tau_A, \tau_B)$, 从而当 A, B 互斥时 $\min(\tau_A, \tau_B) \sim \text{Geo}(p_A + p_B)$;
- (3) A, B 相互独立, 当且仅当 τ_A 与 τ_B 相互独立¹;
- (4) A, B 几乎互斥 (定义参见习题 2.27), 当且仅当 τ_A 与 τ_B 不可能取值相同;
- (5) 记 $\tau_{[1]} := \tau_A \wedge \tau_B, \tau_{[2]} := |\tau_A - \tau_B|$. 当 A, B 互斥时, $\tau_{[1]}, \tau_{[2]}$ 相互独立, 并且 $\tau_{[2]}$ 的分布律是两个几何分布 $\text{Geo}(p_A), \text{Geo}(p_B)$ 的凸组合。特别地, 当 $p_A = p_B := p$ 时, $\tau_{[2]} \sim \text{Geo}(p)$;
- (6) 一般地, 设有 $n \geq 2$ 个互斥事件 $A_1, \dots, A_n$, 满足

$$\mathbb{P}(A_1) = \cdots = \mathbb{P}(A_n) =: p \in (0, \frac{1}{n}].$$

记 T_r 为重复试验时现象 $A_1, \dots, A_n$ 中恰出现了 r 种不同现象时所需的最小试验次数, 约定 $T_0 := 0$. 对 $r = 1, \dots, n$, 记 $\tau_{[r]} := T_r - T_{r-1}$, 它代表重复试验过程中为了观察到诸现象 $A_1, \dots, A_n$ 中的第 r 种“新现象”额外所需的试验次数。那么 $\{\tau_{[k]}\}_{k=1}^n$ 是相互独立的, 并且

$$\tau_{[k]} \sim \text{Geo}((n - k + 1)p), \quad k = 1, \dots, n.$$

习题 5.29. 记 N_r^A 是为了观察到 r 次 A 现象所需进行的最少重复试验次数。在习题 5.28 基础上进一步探讨以下结论是否成立: A, B 相互独立, 当且仅当 N_r^A 与 N_s^B 相互独立。其中 $r, s \geq 1$ 是给定的自然数。

¹注意, 此问题中两处独立性是在不同概率空间中谈论的; 参见第三章重复试验的定义。

习题 5.30. 设 X, Y 相互独立, $X \sim B(b, p), Y \sim B(r, p)$, 则当 $n \leq b + r$ 时

$$\mathbb{P}(X = k | X + Y = n) = \frac{\binom{b}{k} \binom{r}{n-k}}{\binom{b+r}{n}}, \quad \ell_1 := (n-r)^+ \leq k \leq \ell_2 := b \wedge n.$$

即 $X | X + Y = n \sim H(b, r; n)$.

习题 5.31. 设 $X, Y \stackrel{\text{i.i.d.}}{\sim} \text{Geo}(p)$, 则 $\mathbb{P}(X = k | X + Y = n) = \frac{1}{n-1}$, $1 \leq k \leq n-1$.
即 $X | X + Y = n \sim U(\{1, \dots, n-1\})$.

习题 5.32. 给定离散型随机变量 $X \sim \begin{pmatrix} a_1 & \cdots & a_N \\ p_1 & \cdots & p_N \end{pmatrix}$; 这里 $a_1, \dots, a_N$ 两两不等, 可以是向量. 定义它的 *Shannon*¹ 熵为

$$H(X) := - \sum_{i=1}^N p_i \ln p_i.$$

离散型随机向量的 *Shannon* 熵类似定义. 当 X, Y 都是离散型随机变量时, 定义条件熵 $H(Y|X)$ 如下:

$$H(Y|X) := - \sum_{x,y} \mathbb{P}(X = x, Y = y) \ln \mathbb{P}(Y = y | X = x).$$

对离散型随机变量 X, Y , 求证:

- (1) $H(X) \leq \ln N_X$, 其中 $N_X := N$ 是 X 的不同取值的个数;
- (2) X, Y 相互独立, 当且仅当 $H(X, Y) = H(X) + H(Y)$, 此处 $H(X, Y)$ 表示随机向量 (X, Y) 的 *Shannon* 熵;
- (3) 一般而言, $H(X, Y) = H(X) + H(Y|X)$, 且 $H(Y|X) \leq H(Y)$, 后一式等号成立当且仅当 X, Y 相互独立.

习题 5.33. 设 $\{X_k\}_{k=1}^n \stackrel{\text{i.i.d.}}{\sim} \text{Poisson}(\lambda)$, $\lambda > 0$ 未知, 求极大似然估计 $\hat{\lambda}$.

习题 5.34. 设 $\{X_k\}_{k=1}^n \stackrel{\text{i.i.d.}}{\sim} \text{Geo}(p)$, $p \in (0, 1)$ 未知, 求极大似然估计 $\hat{p}$.

¹Claude Elwood Shannon (香农, 1916—2001) 是美国数学家、发明家、密码学家, 信息论创始人, 美国国家工程院院士、美国国家科学院院士、美国艺术与科学院院士, 生前是麻省理工学院名誉教授。

第六章 数学期望与分布律

数学期望是概率论中针对随机变量概念发展的一套重要工具，是日常自然语言中“平均值”的数学抽象。它本质上与概率空间中的概率测度是等价的，但性质更为优良：数学期望作为算子（随机变量的泛函）是线性的；而概率测度（作为可谈论概率的事件的函数）最重要的性质是 σ -可加性，这是非线性的。因此数学期望这一工具引入到概率论中后，数学中更多的分析技巧得以借此途径施展，从而大大促进了概率论的发展。

在本章，我们通过回顾历史上 Huygens 的贡献，借助期望收益的直观，首先对离散型随机变量定义了数学期望，之后通过借助实变函数论中 Lebesgue 积分的定义流程框架，实现对一般的随机变量的数学期望的抽象数学定义。最后我们进一步借助保测映射的观点，证明了通常大部分初等概率论教材中给出的基于随机变量的分布律的数学期望计算公式。

这样一套定义与说理是略显冗长的，但在目前的学科发展形势下来看，对于数学专业（特别是概率论方向）的学生是有了解的必要的；对于非数学专业的学生，也可以在学习时跳过此定义流程，（或对前述定义流程略作了解后）直接采纳最终导出的计算公式，并承认数学期望的有关基本性质——这本质上也是过往大多数（特别是非数学专业的）概率论教材中采用的教学安排体系。本讲义编撰的目的是作为数学专业学生的初等概率论课程的专业教科书，自然有责任为学有余力的学生们保留学习更严谨而现代的概率理论知识的便捷通道。

6.1 数学期望的定义

在第四章，我们已经定义了一般测度空间上的可测函数的抽象 Lebesgue 积分；由于随机变量 ξ 是概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 中的可测函数，很自然也就定义了积分 $\int \xi d\mathbb{P}$ ，在概率论中更习惯把它称作 ξ 的**数学期望**，同时把它书写为 $\mathbb{E}\xi$ ，

亦即

$$\mathbb{E}\xi = \int \xi d\mathbb{P}. \quad (6.1)$$

但为了读者的方便, 在本章我们还是通过回顾概率论发展的历史重新给出随机变量的数学期望的定义, 并通过逻辑演绎给出基于随机变量的分布律的数学期望计算公式。

历史上, Pascal 和 Fermat 在 1654 年左右进行了若干次¹通信, 讨论了著名的赌金分配问题; 在那个问题的讨论中, Pascal 和 Fermat 确立了分配赌金的原则: 赌徒应当按照最终获胜的概率的比值来分配赌金。尽管 Pascal 和 Fermat 并没有给出概率的定义, 但在他们的讨论过程实质上暗含了等可能性假设下的古典概率模型的概率定义。1655 年, 正在巴黎游学的青年时期的 Huygens 听说了他们关于赌金分配问题的讨论, 也开始研究这个问题, 最终于 1657 年发表了《论赌博中的计算》一书; 在此书中, Huygens 进一步把 Pascal 和 Fermat 的分配赌金的原则推广为: 赌徒应当按照各自期望收益的比例来进行赌金的分配。这个原则相比 Pascal 和 Fermat 给出的原则, 适用范围大大拓广, 可以不再局限于原始的赌金分配问题所限定的赌博类型。我们今天要讲的数学期望, 本质上就来源于 Huygens 给出的期望收益的定义。

仍然局限于原始的赌金分配问题, 其中涉及的两个赌徒为方便分别称为甲、乙赌徒。用今天的术语来讲, 设随机变量 ξ 代表甲赌徒在继续赌下去直至决出最后的赢家时的真实收益, 设 A 代表甲赌徒是最终赢家这一事件, 用 K 代表最终约定分配的总赌金, 由原始的赌金分配问题中的“赢者通吃”规则, 显然应有

$$\xi = K \cdot 1_A \sim \begin{pmatrix} 0 & K \\ 1 - \mathbb{P}(A) & \mathbb{P}(A) \end{pmatrix}.$$

朴素的直觉告诉我们 (这也同时是 Huygens 选择的定义²), 此时甲赌徒的期望收益 (有时也称为平均收益) 为

$$\mathbb{E}\xi := K \cdot \mathbb{P}(A).$$

也就是说, Huygens 的期望收益分配原则与 Pascal、Fermat 的最终获胜概率分配原则在原始的赌金分配问题中本质上是等价的。这里蕴含了我们定义数学期望的根基与出发点: 对任意可测集 $A \in \mathcal{F}$, 1_A 是一个随机变量, 它的数学期望定义为

$$\mathbb{E}1_A := \mathbb{P}(A). \quad (6.2)$$

¹据说是七次。

²通过考察基于古典概率模型的彩票抽奖问题, Huygens 是从经济学或博弈论角度推理而得出 “Value of the Game” 或 “the expectation of a player” 的计算公式的, 参见文献^[50]第 6 章。

我们将在承认算子 $\mathbb{E}$ 的线性性质的基础上，结合上面的方程给出随机变量的数学期望的抽象定义。

尽管赌博是不好的行为，我们还是选择借用这个概念的外衣来进行解释。在选择把随机变量 ξ 解释为随机世界里你参与某项赌博结束时的真实收益，把 $\mathbb{E}\xi$ 解释为你参与这项赌博的期望收益后，数学期望算子 $\mathbb{E}$ 的线性性质就可以变成我们的直观能简单地理解的东西了：第一，原则上你可以参加多项赌博，整体期望收益应该是各项赌博期望收益的加和：

$$\mathbb{E}[\xi_1 + \xi_2] = \mathbb{E}\xi_1 + \mathbb{E}\xi_2;$$

第二，原则上你可以使用杠杆放大原始真实收益若干倍，相应的期望收益也应当会放大相应的倍数：

$$\mathbb{E}[k\xi] = k\mathbb{E}\xi, \text{ 其中 } k \text{ 为常数.}$$

在上述理解的基础上，我们按以下流程来实现随机变量的数学期望 $\mathbb{E}\xi$ 的定义：

- **Step 1.** 定义 $\mathcal{S} := \text{span}\{1_A : A \in \mathcal{F}\}$ 为简单函数（亦即只取有限个实数值的离散型随机变量，我们称之为简单随机变量）所成的线性空间；其中非负简单随机变量的全体所成集合记为 $\mathcal{S}_+$ 。对任意 $\xi \in \mathcal{S}$ ，存在有限个两两不同的实数 $\{a_i\}_{i=1}^N$ ，使得

$$\xi = \sum_{i=1}^N a_i \cdot 1_{\{\xi=a_i\}}, \quad (6.3)$$

此时，基于(6.2)，定义

$$\mathbb{E}\xi := \sum_{i=1}^N a_i \cdot \mathbb{P}(\xi = a_i). \quad (6.4)$$

在本步骤下，我们来证明 $\mathbb{E} : \mathcal{S} \rightarrow \mathbb{R}$ 的线性性质和单调性质成立，即以下结论成立： $\forall \xi, \eta \in \mathcal{S}, c \in \mathbb{R}$

$$\mathbb{E}[c\xi] = c\mathbb{E}\xi, \quad (6.5)$$

$$\mathbb{E}[\xi + \eta] = \mathbb{E}\xi + \mathbb{E}\eta, \quad (6.6)$$

$$\xi \leq \eta \Rightarrow \mathbb{E}\xi \leq \mathbb{E}\eta. \quad (6.7)$$

我们分别证明上面三式如下。

(1.1) 只需讨论 $c \neq 0$ 情形. 设 $\xi \sim \begin{pmatrix} a_1 & \cdots & a_m \\ p_1 & \cdots & p_m \end{pmatrix}$, 则 $c\xi \sim \begin{pmatrix} ca_1 & \cdots & ca_m \\ p_1 & \cdots & p_m \end{pmatrix}$.

由此

$$\mathbb{E}[c\xi] = \sum_{k=1}^m ca_k \cdot p_k = c \sum_{k=1}^m a_k \cdot p_k = c\mathbb{E}\xi.$$

此即(6.5).

(1.2) 由于 ξ, η 都是简单随机变量, 可假设 (ξ, η) 满足

$$\mathbb{P}(\xi = a_i, \eta = b_j) = p_{i,j}, \quad \sum_{1 \leq i \leq m} \sum_{1 \leq j \leq n} p_{i,j} = 1,$$

其中 $\{a_i\}_{i=1}^m, \{b_j\}_{j=1}^n$ 两数列内部的元素都是两两不同的. 沿用第五章中关于联合概率分布列对应的边缘概率分布列的记号, 我们知道

$$\xi \sim \begin{pmatrix} a_1 & \cdots & a_m \\ p_{1,\bullet} & \cdots & p_{m,\bullet} \end{pmatrix}, \eta \sim \begin{pmatrix} b_1 & \cdots & b_n \\ p_{\bullet,1} & \cdots & p_{\bullet,n} \end{pmatrix}.$$

于是记 $\mathcal{R}(\xi + \eta)$ 为 $\xi + \eta$ 的值域 (至多有 $m \cdot n$ 个元素), 我们有

$$\begin{aligned} \mathbb{E}[\xi + \eta] &= \sum_{x \in \mathcal{R}(\xi + \eta)} x \mathbb{P}(\xi + \eta = x) \\ &= \sum_{x \in \mathcal{R}(\xi + \eta)} x \sum_{(i,j): a_i + b_j = x} \mathbb{P}(\xi = a_i, \eta = b_j) \\ &= \sum_{x \in \mathcal{R}(\xi + \eta)} \sum_{(i,j): a_i + b_j = x} (a_i + b_j) p_{i,j} \\ &= \sum_{i=1}^m \sum_{j=1}^n (a_i + b_j) \cdot p_{i,j} \\ &= \sum_{i=1}^m a_i \cdot \sum_{j=1}^n p_{i,j} + \sum_{j=1}^n b_j \cdot \sum_{i=1}^m p_{i,j} \\ &= \sum_{i=1}^m a_i \cdot p_{i,\bullet} + \sum_{j=1}^n b_j \cdot p_{\bullet,j} = \mathbb{E}\xi + \mathbb{E}\eta. \end{aligned}$$

此即(6.6).

(1.3) 当 $\xi, \eta \in \mathcal{S}$ 且 $\xi \leq \eta$ 时, $0 \leq \eta - \xi \in \mathcal{S}_+$, 于是 $\mathbb{E}[\eta - \xi] \geq 0$. 在此基础上, $\mathbb{E}\eta = \mathbb{E}\xi + \mathbb{E}[\eta - \xi] \geq \mathbb{E}\xi$. 此即(6.7).

• **Step 2.** 对于一般的非负随机变量 ξ , 定义

$$\mathbb{E}\xi := \sup\{\mathbb{E}\eta : 0 \leq \eta \leq \xi, \eta \in \mathcal{S}_+\}. \quad (6.8)$$

这里需要注意, 由于是使用上确界给出的定义, 有可能出现 $\mathbb{E}\xi = \infty$.

这里还需要指出, 在有些文献中, 上述步骤也被替换为极限模式: 对于一般的非负随机变量 ξ , 可取非负简单随机变量 ξ_n (比如 $\xi_n := \min\left(\frac{\lfloor 2^n \xi \rfloor}{2^n}, n\right)$) 使得 $\xi_n \nearrow \xi$, 此时就定义

$$\mathbb{E}\xi := \lim_{n \rightarrow \infty} \mathbb{E}\xi_n.$$

这样定义是完全等价的, 在直观上也显得更容易理解, 但随之而来的额外工作就是需要验证这样操作的良定义性 (即极限值不依赖于序列 ξ_n 的选取). 在本讲义中, 我们采纳上述上确界的定义方式, 以绕开良定义性的检查工作。

同样, 在本步骤下, 我们来论证数学期望的单调性质和线性性质成立。

(2.1) 数学期望的单调性显然由上确界的定义方式得到了保证。

(2.2) 现在我们来证明此时数学期望在非负随机变量空间中具有线性性质。这部分的证明被拆分成下面的 (i) —(iii)。

(i) 先证明对非负随机变量 ξ 及 $c \in \mathbb{R}_+$, $\mathbb{E}[c\xi] = c\mathbb{E}\xi$.

事实上, 对任意非负随机变量 ξ 及 $c \in \mathbb{R}_+$ (此处不妨设 $c > 0$)

$$\begin{aligned} \mathbb{E}[c\xi] &:= \sup\{\mathbb{E}\eta : 0 \leq \eta \leq c\xi, \eta \in \mathcal{S}_+\} \\ &= \sup\{\mathbb{E}[c\eta] : 0 \leq \eta \leq \xi, \eta \in \mathcal{S}_+\} \\ &= \sup\{c \cdot \mathbb{E}[\eta] : 0 \leq \eta \leq \xi, \eta \in \mathcal{S}_+\} \\ &= c \cdot \sup\{\mathbb{E}[\eta] : 0 \leq \eta \leq \xi, \eta \in \mathcal{S}_+\} = c \cdot \mathbb{E}\xi. \end{aligned}$$

(ii) 由 (2.1), 不难知道, Levi 单调收敛定理成立: 设 $\{\xi_n\}_{n=1}^\infty$ 为一列非负随机变量, 且存在随机变量 ξ 使得 $\xi_n \nearrow \xi$. 那么 $\lim_{n \rightarrow \infty} \mathbb{E}[\xi_n] = \mathbb{E}[\xi]$.

上述结论的证明请读者参见第四章对应定理的证明。

(iii) 现在证明: 对任意非负随机变量 ξ, η , $\mathbb{E}[\xi + \eta] = \mathbb{E}\xi + \mathbb{E}\eta$.

事实上, 由 Levi 单调收敛定理, 存在 $\xi_n, \eta_n \in \mathcal{S}_+$ 使得 $\xi_n \nearrow \xi, \eta_n \nearrow \eta$, 进而 $\xi_n + \eta_n \nearrow \xi + \eta$, 由 Levi 单调收敛定理,

$$\begin{aligned} \mathbb{E}[\xi + \eta] &= \lim_{n \rightarrow \infty} \mathbb{E}[\xi_n + \eta_n] \quad (\text{Levi 单调收敛定理}) \\ &= \lim_{n \rightarrow \infty} [\mathbb{E}\xi_n + \mathbb{E}\eta_n] \quad (\mathbb{E} : \mathcal{S}_+ \rightarrow \mathbb{R} \text{ 的线性性质}) \\ &= \mathbb{E}\xi + \mathbb{E}\eta. \quad (\text{Levi 单调收敛定理}) \end{aligned}$$

- **Step 3.** 对于一般的随机变量 ξ , 注意到 $\xi = \xi^+ - \xi^-$, 当 $\mathbb{E}[\xi^+], \mathbb{E}[\xi^-]$ 至少有一者是有限值时, 定义

$$\mathbb{E}\xi := \mathbb{E}[\xi^+] - \mathbb{E}[\xi^-], \tag{6.9}$$

称之为随机变量 ξ 的**数学期望**。此时称 ξ 的**数学期望有意义**。当 $\mathbb{E}[\xi^+], \mathbb{E}[\xi^-]$ 都是有限值时, 此时 $\mathbb{E}\xi$ 也是一个有限值, 称 ξ 的**数学期望存在**, 有时也称 ξ **可积**, 记作 $\xi \in L^1(\Omega, \mathcal{F}, \mathbb{P})$ 或简单的 $\xi \in L^1(\mathbb{P})$, 或更简单的 $\xi \in L^1$. 当 $\mathbb{E}[\xi^+], \mathbb{E}[\xi^-]$ 都是无穷值时, 称 ξ 的**数学期望无意义**。

现在我们证明, 在数学期望的定义 **Step 3**. 完成后, 在随机变量空间中具有线性性质和单调性质。

(3.1) 线性性质的证明如下。

对于 $c \in \mathbb{R}$ 及使 $\mathbb{E}\xi$ 有意义的 ξ , $\mathbb{E}[c\xi] = c\mathbb{E}\xi$ 的证明是简单的, 留给读者。以下我们证明, 当 ξ, η 均可积时, 仍然有(6.6)成立, 即

$$\mathbb{E}[\xi + \eta] = \mathbb{E}\xi + \mathbb{E}\eta.$$

此时, 由于 $|\xi + \eta| \leq |\xi| + |\eta|$, $\xi + \eta$ 也可积。注意到

$$(\xi + \eta)^+ - (\xi + \eta)^- = \xi + \eta = \xi^+ - \xi^- + \eta^+ - \eta^-,$$

我们有

$$(\xi + \eta)^+ + \xi^- + \eta^- = (\xi + \eta)^- + \xi^+ + \eta^+.$$

由上一步骤的结论, 我们得到

$$\mathbb{E}[(\xi + \eta)^+] + \mathbb{E}[\xi^-] + \mathbb{E}[\eta^-] = \mathbb{E}[(\xi + \eta)^-] + \mathbb{E}[\xi^+] + \mathbb{E}[\eta^+].$$

移项整理即得 $\mathbb{E}[\xi + \eta] = \mathbb{E}\xi + \mathbb{E}\eta$.

(3.2) 数学期望的单调性在获证线性性质后, 可由 **Step 2**. 中证明的单调性直接导出。

需要特别指出的是, 在约定 $0 \cdot \infty = 0$ 后, 上述数学期望的定义流程对于广义实值随机变量也可以操作; 并且在第十章中我们基于 Chebyshev 不等式也给出了第五章中提出的随机变量的“补丁程序”的一种便捷的检查手段。

显然, 离散型随机变量的数学期望有下面的计算公式:

♠ **定理 6.1.1.** 设 $\xi \sim \begin{pmatrix} a_1 & \cdots & a_N \\ p_1 & \cdots & p_N \end{pmatrix}$, 那么当 $\mathbb{E}\xi$ 有意义时,

$$\mathbb{E}\xi = \sum_{i=1}^N a_i p_i. \quad (6.10)$$

特别地, 对任意可测函数 φ , 如果 $\mathbb{E}[\varphi(\xi)]$ 有意义, 那么

$$\mathbb{E}[\varphi(\xi)] = \sum_{i=1}^N \varphi(a_i) p_i. \quad (6.11)$$

6.2 数学期望的性质与简单应用

6.2.1 数学期望的基本性质及有关极限交换定理

数学期望具有很多性质, 以下我们先罗列它的一些基本性质; 这些性质已经在上一节中给出了证明. 以下总假设 ξ, η 是随机变量.

(E0) $\mathbb{P}(A) = \mathbb{E}[1_A], \forall A \in \mathcal{F}$;

(E1) (线性性质) 设 $a, b \in \mathbb{R}$ 且 $\mathbb{E}\xi, \mathbb{E}\eta, a\mathbb{E}\xi + b\mathbb{E}\eta$ 均有意义, 则

$$\mathbb{E}[a\xi + b\eta] = a\mathbb{E}\xi + b\mathbb{E}\eta;$$

(E2) (正算子/单调性) 如果 $\xi \geq 0$ a.s., 那么 $\mathbb{E}\xi \geq 0$. 一般地, 设 $\mathbb{E}\xi, \mathbb{E}\eta$ 有意义, 且 $\xi \leq \eta$ a.s., 那么 $\mathbb{E}\xi \leq \mathbb{E}\eta$. 特别地, $|\mathbb{E}\xi| \leq \mathbb{E}|\xi|$;

(E3) 如果 $\xi = a \in \mathbb{R}$ a.s., 那么 $\mathbb{E}\xi = a$;

下面我们罗列涉及数学期望的极限交换定理, 它们分别是 Levi 单调收敛定理、Fatou 引理、Lebesgue 控制收敛定理和 Fubini 定理; 在第四章中我们实际上已有所论述, 把它们集中收集于此只是再次强调其重要性.

♠ 定理 6.2.1. (Levi 单调收敛定理) 设 $\{X_n\}_{n=1}^\infty$ 是单调上升的非负随机变量列, 即 $0 \leq X_1 \leq X_2 \leq \cdots \leq X_n \leq X_{n+1} \leq \cdots$, 则 $X_\infty := \lim_{n \rightarrow \infty} X_n$ 是非负的广义实值随机变量, 且 $\lim_{n \rightarrow \infty} \mathbb{E}X_n = \mathbb{E}X_\infty$.

♠ 定理 6.2.2. (Fatou 引理) 设 $\{X_n\}_{n=1}^\infty$ 是非负随机变量列. 那么

$$\mathbb{E} \lim_{n \rightarrow \infty} X_n \leq \lim_{n \rightarrow \infty} \mathbb{E}X_n.$$

♠ 定理 6.2.3. (Lebesgue 控制收敛定理) 设随机变量列 $\{X_n\}_{n=1}^\infty$ 满足: (1) (控制条件) $|X_n| \leq X$, 其中 $\mathbb{E}X < \infty$; (2) (收敛条件) $\lim_{n \rightarrow \infty} X_n = X_\infty$. 那么

$$\lim_{n \rightarrow \infty} \mathbb{E}X_n = \mathbb{E}X_\infty.$$

♠ 定理 6.2.4. (Fubini 定理) 设 $(D, \mathcal{E}, \mu)$ 是一个 σ -有限的测度空间, $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间. 设 $\{X_t = X_t(\omega)\}_{t \in D}$ 是一族随机变量, 它们满足:

$$X : (D \times \Omega, \mathcal{E} \otimes \mathcal{F}) \rightarrow \mathbb{R}, \quad (t, \omega) \mapsto X_t(\omega)$$

是二元可测的 (即关于 $\mathcal{E} \otimes \mathcal{F}$ 可测), 并且是非负的 (即 $X_t \geq 0, \forall t \in D$) 或二元可积的 (即 $\int |X_t(\omega)| d\mu \otimes \mathbb{P}(t, \omega) < \infty$), 那么

$$\mathbb{E} \left[\int_D X_t d\mu(t) \right] = \int X_t(\omega) d\mu \otimes \mathbb{P}(t, \omega) = \int_D [\mathbb{E}X_t] d\mu(t).$$

6.2.2 常见数学期望不等式

在本小节, 我们进一步介绍一些常用的数学期望不等式。尽管在实变函数等教材中已经出现过这些不等式的类似版本及其证明(亦可参见本讲义第四章习题4.6), 为了全书的完备性, 我们还是在罗列这些不等式后再附上它们的证明。

以下总设 ξ, η 为实值随机变量。承接之前数学期望性质的编号, 我们罗列有关常用的数学期望不等式如下:

(E4) Jensen (琴生) 不等式: 设 g 为 $\mathbb{R}$ 上的凸函数, $\mathbb{E}\xi, \mathbb{E}g(\xi)$ 有定义。那么

$$g(\mathbb{E}\xi) \leq \mathbb{E}g(\xi);$$

(E5) 矩不等式: 设 ξ 为随机变量, 对任意 $p > 0$, 定义

$$\|\xi\|_p := (\mathbb{E}[|\xi|^p])^{1/p}. \quad (6.12)$$

那么 $\|\xi\|_s \leq \|\xi\|_t, \forall 0 < s < t$;

(E6) Hölder (霍德) 不等式: 设 $\frac{1}{p} + \frac{1}{q} = 1, p, q > 1$. 那么 $\|\xi \cdot \eta\|_1 \leq \|\xi\|_p \cdot \|\eta\|_q$;

(E7) Minkowski (闵可夫斯基) 不等式: 设 $p > 0$.

(i) $p \geq 1$ 时, $\|\xi + \eta\|_p \leq \|\xi\|_p + \|\eta\|_p$;

(ii) $0 < p < 1$ 时, $\|\xi + \eta\|_p^p \leq \|\xi\|_p^p + \|\eta\|_p^p$.

此处我们指出, 如果定义

$$\|\xi\|_\infty := \inf\{M > 0 : \mathbb{P}(|\xi| > M) = 0\}, \quad (6.13)$$

则上述 Hölder 不等式中 $p = 1, q = \infty$ 时结论亦成立, 感兴趣的读者可以自行完成这个并不难的证明。

上述数学期望不等式的证明: (1) 为了证明 Jensen 不等式, 这里我们需要使用凸函数的一个等价性质, 具体陈述如下(证明就留给读者)。

◆ **引理 6.2.1.** g 是区间 I 上的凸函数, 当且仅当: $\forall x_0 \in I^\circ$ (此处 I° 表示 I 的内点的全体), $\exists \alpha \in \mathbb{R}$ (可取为右导数 $\alpha = g'(x_0+)$), 使得

$$g(x) \geq g(x_0) + \alpha(x - x_0), \forall x \in I. \quad (6.14)$$

因此, 当 g 为 $\mathbb{R}$ 上的凸函数时, 对于可积随机变量 ξ , 取 $x_0 := \mathbb{E}\xi$, 则存在常数 $\alpha \in \mathbb{R}$

$$g(\xi) \geq g(\mathbb{E}\xi) + \alpha(\xi - \mathbb{E}\xi).$$

于是对上式两边取数学期望, 立即得到 Jensen 不等式 $\mathbb{E}[g(\xi)] \geq g(\mathbb{E}\xi)$.

对于 ξ 未必可积, 但 $g(\mathbb{E}\xi)$ 和 $\mathbb{E}[g(\xi)]$ 有意义的情形的 Jensen 不等式的证明, 留给读者思考.

(2) 现在我们可以基于 Jensen 不等式证明矩不等式了。事实上, 对任意 $p > 1$, $g(x) := x^p$ 为 $\mathbb{R}_+$ 上的凸函数。于是对任意随机变量 ξ , $|\xi|$ 是非负随机变量, 并且由 Jensen 不等式

$$\mathbb{E}[g(|\xi|)] \geq g(\mathbb{E}|\xi|),$$

此即 $\|\xi\|_1 \leq \|\xi\|_p$. 特别地, 对 $0 < s < t$, 取 $p = t/s > 1$, $\||\xi|^s\|_1 \leq \||\xi|^s\|_p$, 化简即得 $\|\xi\|_s \leq \|\xi\|_t$.

(3) 现在我们来证明数学期望版本的 Hölder 不等式。这部分的论证基础是数学分析中如下版本的 Hölder 不等式:

$$\frac{a^p}{p} + \frac{b^q}{q} \geq ab, \forall a, b \geq 0, \quad (6.15)$$

其中 $p > 1, q > 1$ 满足 $\frac{1}{p} + \frac{1}{q} = 1$.

在承认上述 Hölder 不等式的基础上, 假设 $\xi \in L^p, \eta \in L^q$, 且 $\|\xi\|_p \cdot \|\eta\|_q > 0$, 那么取 $a = |\xi|, b = t \cdot |\eta|$, 其中 $t > 0$, 立即得到

$$\frac{|\xi|^p}{p} + \frac{|t\eta|^q}{q} \geq t|\xi\eta|, \forall t > 0.$$

对上式取数学期望, 整理得到

$$\|\xi\eta\|_1 \leq \frac{\|\xi\|_p^p}{pt} + \frac{\|\eta\|_q^q}{q} \cdot t^{q-1}, \forall t > 0.$$

特取 $t = \|\xi\|_p^{p/q} \cdot \|\eta\|_q^{-1}$, 代入上式整理即得 $\|\xi\eta\|_1 \leq \|\xi\|_p \cdot \|\eta\|_q$.

(4) 现在我们来证明数学期望版本的 Minkowski 不等式。

在 $p = 1$ 情形, 对三角不等式 $|\xi + \eta| \leq |\xi| + |\eta|$ 两边取数学期望, 立即得到 $\|\xi + \eta\|_1 \leq \|\xi\|_1 + \|\eta\|_1$.

下面设 $p > 1$. 此时不妨设 $\|\xi\|_p < \infty, \|\eta\|_p < \infty$, 不难知道

$$\|\xi + \eta\|_p^p = \mathbb{E}[|\xi + \eta|^p] \leq 2^{p-1} \mathbb{E}[|\xi|^p + |\eta|^p] < \infty.$$

于是, 不妨设 $\|\xi + \eta\|_p > 0$, 利用 $\||\xi + \eta|^{p-1}\|_q = \|\xi + \eta\|_p^{p-1}$, 我们有

$$\begin{aligned} \|\xi + \eta\|_p^p &= \mathbb{E}[|\xi + \eta|^p] \leq \mathbb{E}[|\xi + \eta|^{p-1} \cdot (|\xi| + |\eta|)] \quad (\text{三角不等式}) \\ &\leq [\|\xi\|_p + \|\eta\|_p] \cdot \||\xi + \eta|^{p-1}\|_q \quad (\text{Hölder 不等式}) \end{aligned}$$

$$\leq [\|\xi\|_p + \|\eta\|_p] \cdot \|\xi + \eta\|_p^{p-1}.$$

进而 $\|\xi + \eta\|_p \leq \|\xi\|_p + \|\eta\|_p$.

现在设 $0 < p < 1$, 我们证明 $\|\xi + \eta\|_p^p \leq \|\xi\|_p^p + \|\eta\|_p^p$, 即

$$\mathbb{E}[|\xi + \eta|^p] \leq \mathbb{E}[|\xi|^p] + \mathbb{E}[|\eta|^p].$$

当 $a, b \geq 0$ 且 $a + b = 1$ 时, $a \leq a^p, b \leq b^p, 1 = a + b \leq a^p + b^p$. 这进一步意味着

$$(a + b)^p \leq a^p + b^p, \quad \forall 0 < p < 1, a, b > 0. \quad (6.16)$$

现在 $|\xi + \eta|^p \leq [|\xi| + |\eta|]^p \leq |\xi|^p + |\eta|^p$; 对此式两边取数学期望即完成此情形下 Minkowski 不等式的证明. $\square$

6.2.3 数学期望的简单应用

下面我们以 Buffon 投针为例来说明: 数学期望引入后, 对于一些问题的讨论产生了巨大的便利. 具体来说, 上面数学期望的性质 (E0)、(E1) 已经足够我们来解决 Buffon 投针问题了:

例 6.1. (Buffon 投针问题: 续) 在地面上有无数条等间隔的平行线 (设间隔为 L), 某人拿着一个材质均匀、形状怪异但总体外边界形成平面上的凸区域的“小针”¹ 随机地投向地面, 则这个“小针”与这组平行线相交的概率的计算公式如下:

$$\text{相交概率} = \frac{\text{“小针”的“周长”}}{\pi L}. \quad (6.17)$$

特别地, 当“小针”是长为 $\ell < L$ 的直线段形态时, 这个“小针”与这组平行线相交的概率 $= \frac{2\ell}{\pi L}$.

参考证明²: 对于一般 (规则) 形态的“针” Γ , 记 N_Γ 为投掷“针” Γ 时它与平行线形成的交点数目. 记 $p_k = \mathbb{P}(N_\Gamma = k)$ 是投掷“针” Γ 与平行线相交恰好形成 k 个交点的概率, $k \geq 0$; 默认 $\mathbb{P}(N_\Gamma = \infty) = 0$. 此时“针” Γ 与平行线相交的概率为 $p_\Gamma := \mathbb{P}(N_\Gamma \geq 1) = \sum_{k=1}^{\infty} p_k$, 而它与平行线的平均交点数为

$$E(\Gamma) := \mathbb{E}N_\Gamma = \sum_{k=1}^{\infty} kp_k.$$

¹ 此处, 说一根“针”是“小针”, 是指它形成的凸区域中最远两点的距离 $< L$, 从而 (几乎) 不会出现同时与两条平行线相交的状况。

² 此处提供的对公式 (6.17) 的证明来自《数学天书中的证明》^[2] 第 155—158 页, 略有改动。

当“针” Γ 是直线段形态的短针, 针的长度为 $\ell < L$, 此时 $p_k = 0, \forall k \geq 2$, 因此 $\mathbb{E}N_\Gamma = p_1 = p_\Gamma$, 即直线段的短针与平行线相交的概率就是它与平行线相交的平均频数/平均交点数。

对于直线段形态的针 Γ , 如果它的长度为 ℓ (未必满足 $\ell < L$), 我们将记 $E(\ell) := \mathbb{E}N_\Gamma$ 为它与平行线相交的平均交点数 (与多条平行线相交需要计算多次). 如果 $\ell = x + y, x, y \geq 0$, 我们可以把针分成长度分别为 x 和 y 的两部分, 而针与平行线相交的平均交点数就分别来源于这两部分对应的平均交点数的贡献, 因此很显然应有

$$E(x + y) = E(x) + E(y), \forall x, y \geq 0.$$

显然 E 是单调的, 从而由实变函数理论, 存在常数 $C \geq 0$ 使得 $E(x) = Cx$.

现在假设“小针” Γ 是凸多边形 (设边数为 n) 形状. 这时, 我们设“小针”的各边为 $\Gamma := \{\vec{\ell}_i\}_{i=1}^n$. 注意到凸多边形“小针” Γ 与平行线相交时, 排除有无数多个交点的极端情况, 总是恰好有两条边与某平行线相交, 即¹

$$N_\Gamma \stackrel{\text{a.s.}}{=} \sum_{i=1}^n 1_{\{\vec{\ell}_i \text{ 与某平行线相交}\}}. \quad (6.18)$$

于是由数学期望的性质 (E0)、(E1), 我们有下面的表达式:

$$\begin{aligned} E(\Gamma) &= \mathbb{E}N_\Gamma = \mathbb{E}\left[\sum_{i=1}^n 1_{\{\vec{\ell}_i \text{ 与平行线相交}\}}\right] \\ &= \sum_{i=1}^n \mathbb{P}(\vec{\ell}_i \text{ 与平行线相交}) \\ &= \sum_{i=1}^n E(|\vec{\ell}_i|) = C \cdot |\Gamma|, \end{aligned}$$

其中 $|\Gamma| := \sum_{i=1}^n |\vec{\ell}_i|$ 表示 Γ 的周长. 于是

$$E(\Gamma) = C \cdot |\Gamma|. \quad (6.19)$$

记 $A_i = \{\vec{\ell}_i \text{ 与某平行线相交}\}$, 对于凸多边形“小针” Γ , 事件列 $\{A_i\}_{i=1}^n$ 满足: (a) 三个及以上事件不可能同时发生; (b) 单个事件不可能发生. 注意到习题2.28, 我们得到凸多边形的“小针”与平行线的相交概率为

$$\mathbb{P}(\Gamma \text{ 与平行线相交}) = \mathbb{P}(\exists i, \vec{\ell}_i \text{ 与平行线相交}) = \frac{C}{2} \cdot |\Gamma|,$$

¹事实上, 方程(6.18)左右两端不相等的情形就是“小针” Γ 的某条边完全落在了某条平行线上, 从而形成无数个交点; 这是零概率事件, 要严格证明这一点并不难, 但需要多说一些话, 有关讨论就留给读者思考。

即这个概率值是凸多边形“小针”的周长的 $\frac{C}{2}$ 倍。

现在的问题是如何计算出常数 C . 由于上面的讨论对任意的凸多边形“小针”都成立, 物理上我们相信¹, 结论对于圆形的“小针”仍然成立. 特别地, 当这个圆形“小针”的直径恰好是 L 时, 它与平行线相交的平均交点数显然为 2. 因此 $C \cdot \pi L = 2$, 即 $C = \frac{2}{\pi L}$. 于是在原始 Buffon 投针问题中, 当短针长为 $\ell < L$ 时, 它与平行线相交的概率就是 $\frac{2\ell}{\pi L}$, 并且公式(6.17)成立. $\square$

如同例 2.10, 下面两例再次说明, 图论问题、组合问题有时可以用概率方法来解决. 这里的核心思想是: 如果某个量 N 在某个概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 中可以视作(广义)随机变量, 并且 $\mathbb{E}[N] \geq 0$, 则 $\{N \geq 0\} \neq \emptyset$.

例 6.2. 任给一个有限图 $G = (V, E)$, 其中 V 是顶点集, E 是边集. 对任意子集 $W \subset V$ 及边 $e \in E$, 定义

$$I_e(W) := \begin{cases} 1, & \text{如果 } e \text{ 连接 } W \text{ 和 } W^c, \\ 0, & \text{其他.} \end{cases}$$

记 $N(W) := \sum_{e \in E} I_e(W)$, 即 $N(W)$ 为图中连接 W, W^c 的边的数量. 求证: 存在 W 使得 $N(W) \geq |E|/2$.

参考证明: 以下证明来源于 Erdős. 取样本空间 $\Omega := 2^V$ 是 V 的幂集, 考虑古典概率模型 $(\Omega, \mathcal{F}, \mathbb{P})$. 此时 $W \subset V$ 视作样本点, 从而对任意 $e \in E$, $I_e = I_e(W)$ 是随机变量, 进而 $N := N(W)$ 也是随机变量. 现在来计算 $\mathbb{P}(I_e = 1)$. 事实上,

$$A_e := \{I_e = 1\} = \{W \in \Omega : e \text{ 连接 } W \text{ 和 } W^c\}.$$

A_e^c 就是 e 的两个端点同时在 W 或 W^c 之一中的 W 的全体. 同时包含 e 的两个端点的 $W \subset V$ 的数目为 $2^{|V|-2}$ 个; 同时不包含 e 的两个端点的 $W \subset V$ 的数目也是 $2^{|V|-2}$ 个, 这是因为在这个计数过程中可以把 e 的两个端点认同为一个点. 于是 $|A_e^c| = 2^{|V|-1}$, 进而注意到 $|\Omega| = |2^V| = 2^{|V|}$,

$$\mathbb{P}(I_e = 1) = \mathbb{P}(A_e) = 1 - \mathbb{P}(A_e^c) = 1 - \frac{|A_e^c|}{|\Omega|} = \frac{1}{2}.$$

此时 $\mathbb{E}N = \sum_{e \in E} \mathbb{P}(I_e = 1) = \frac{1}{2}|E|$, 很自然蕴含了本例中的结论. $\square$

例 6.3. (相交系集合个数问题) 设 $\mathcal{E}$ 是 $[n] := \{1, 2, \dots, n\}$ 的一个子集族. 称 $\mathcal{E}$ 为相交系, 如果对任意两个不同的元素 $A, B \in \mathcal{E}$, 总有 $A \cap B \neq \emptyset$. Erdős-Ko-Rado 定理²说, 对任意 $k \geq 1$, 如果 $n \geq 2k$, 那么对任意一个由 $[n]$ 的 k 元子集构成的相交系 $\mathcal{E}$, 总有 $|\mathcal{E}| \leq \binom{n-1}{k-1}$.

¹此处承认相交概率对凸形状“小针”的“形状”的连续依赖; 它的数学证明其实是非常困难的.

²此处的 Ko 就是我国的柯召院士 (1910—2002).

参考证明： 此处提供一个简单的概率证明。考虑圆上 n 个点的随机赋值模型（即把 $1, \dots, n$ 这些数字不重不漏地赋给圆周上依顺时针次序排列的圆内接正 n 边形的 n 个顶点；两种赋值方案认为是相同的，如果经过适当旋转，两种赋值方案下圆周诸数字完全重合），对于 $[n]$ 中的一个 k 元集 A ，称它在赋值下是**相邻集**，如果存在圆内接正 n 边形的两个顶点所形成的一个圆弧 $\widehat{P_i P_j}$ ，使得其上恰有圆内接正 n 边形的 k 个顶点 P_β ，并且它们的赋值都在 A 中。对 k 元集 $A \subset [n]$ ，计算概率 $\mathbb{P}(A \text{ 是相邻集})$ 为

$$\mathbb{P}(A \text{ 是相邻集}) = \frac{k!(n-k)!}{(n-1)!} = k / \binom{n-1}{k-1}.$$

据此计算一个 k 元子集构成的相交系 $\mathcal{E}$ 中相邻集的平均数量为 $k \cdot |\mathcal{E}| / \binom{n-1}{k-1}$ 。

但另一方面，对任意一个 k 元相邻集 $A \in \mathcal{E}$ ，在 $[n]$ 的所有 k 元子集中至多有 $2(k-1)$ 个其他的相邻集与 A 相交，而这些相邻集是可以两两配对成互不相交的，例如 $A = \{a_1, \dots, a_k\}$ （其中在所给随机赋值方案下数字列 $a_1, \dots, a_k$ 在圆周上顺时针排列），适当取

$$\begin{aligned} A_1 &= \{a_\beta : 1 \leq \beta \leq i\} \cup \{b_j : 1 \leq j \leq k-i\}, \\ A_2 &= \{a_\beta : i+1 \leq \beta \leq k\} \cup \{c_j : 1 \leq j \leq i\} \end{aligned}$$

可以使得 A_1, A_2 都是 $[n]$ 的 k 元子集¹，且 $A_1 \cap A_2 = \emptyset$ ，从而 A_1, A_2 中至多只能有一个在相交系 $\mathcal{E}$ 中。由此

$$k \cdot |\mathcal{E}| / \binom{n-1}{k-1} \leq \frac{2(k-1)}{2} + 1 = k,$$

进而 $|\mathcal{E}| \leq \binom{n-1}{k-1}$ 。 □

6.3 基于分布律的数学期望计算公式

本节我们来探讨如何利用分布律信息给出数学期望的计算公式。在此过程中，我们也探讨一下如何来定义概率空间之间的同构这一概念，并介绍利用此概念来简化有关的概率计算的部分案例。

6.3.1 数学期望的计算公式 (I)

在第四章中我们已经给出了一个可测函数关于一个给定的参考测度的抽象 Lebesgue 积分的概念；在本章我们也给出了在给定的概率空间中一个随机

¹在给定的随机赋值下，如果还要求 A_1, A_2 也是相邻集，则它们完全由这个随机赋值确定下来了。

变量的数学期望的抽象定义。但在实际应用中,我们希望抽象定义的积分、特别是上面抽象定义的数学期望能有更为简单、实用的计算办法。本节就是为此目的而展开讨论的。

定义 6.3.1. 设 $(\Omega_i, \mathcal{F}_i, \mu_i), i = 1, 2$ 是两个测度空间, 设映射 $T: \Omega_1 \rightarrow \Omega_2$ 是 $\mathcal{F}_1/\mathcal{F}_2$ 可测的 (简称可测的, 即 $T^{-1}\mathcal{F}_2 \subset \mathcal{F}_1$). 在此基础上, 称 T 是保测映射 (简称保测的), 如果 $\mu_2 = \mu_1 \circ T^{-1}$. 此时, 我们可以认为

$$T: (\Omega_1, \mathcal{F}_1, \mu_1) \rightarrow (\Omega_2, \mathcal{F}_2, \mu_2)$$

是两个测度空间之间的同态。

设 $(\Omega, \mathcal{F}, \mu)$ 是个测度空间, 当 $T: (\Omega, \mathcal{F}, \mu) \rightarrow (\Omega, \mathcal{F}, \mu)$ 保测时, 称 μ 是 T -不变测度, 简称不变测度, 或称 T 保测度 μ , 或称 T 为保测变换。此时 $(\Omega, \mathcal{F}, \mu; T)$ 或 (μ, T) 称为保测系统。此时, 我们可以认为

$$T: (\Omega, \mathcal{F}, \mu) \leftarrow$$

是测度空间 $(\Omega, \mathcal{F}, \mu)$ 上的自同态。

📌 注记 6.1. 在第五章介绍随机变量/向量概念时, 我们提到过边缘分布测度的说法。事实上, 设 μ 为 $(\mathbb{R}^n, \mathcal{B}^n)$ 上的 (概率分布) 测度, 设 $n = p + q$, $\mathbb{R}^n = \mathbb{R}^p \times \mathbb{R}^q$. 我们可以定义自然投影 π_1, π_2 如下

$$\begin{aligned}\pi_1: \mathbb{R}^p \times \mathbb{R}^q &\rightarrow \mathbb{R}^p, & (x, y) &\mapsto x, \\ \pi_2: \mathbb{R}^p \times \mathbb{R}^q &\rightarrow \mathbb{R}^q, & (x, y) &\mapsto y.\end{aligned}$$

那么 $\mu_i := \mu \circ \pi_i^{-1}, i = 1, 2$ 都可以称为 μ 的边缘 (分布) 测度。

对于第四章介绍的抽象 Lebesgue 积分, 我们有下面的积分变换公式, 有些文献也称为积分换元公式。

♠ 定理 6.3.1. (积分变换公式) 设 $(\Omega_i, \mathcal{F}_i, \mu_i), i = 1, 2$ 是两个测度空间, 并且 $T: (\Omega_1, \mathcal{F}_1, \mu_1) \rightarrow (\Omega_2, \mathcal{F}_2, \mu_2)$ 是保测的。那么 $\mu_2 = \mu_1 \circ T^{-1}$, 且

$$\int_{\Omega_1} f \circ T d\mu_1 = \int_{\Omega_2} f d\mu_2 \quad (6.20)$$

对任意的 $f \in L^1(\Omega_2, \mathcal{F}_2, \mu_2)$ 成立。特别地, 上式对非负可测函数 f 总成立。

证明: 注意到 T 是保测映射, 因此对任意 $A \in \mathcal{F}_2$,

$$\int 1_A \circ T d\mu_1 = \mu_1(T^{-1}A) = \mu_2(A) = \int 1_A d\mu_2.$$

于是 (6.20) 对任意可测的示性函数、进而对任意 (非负) 简单函数 $f \in \mathcal{F}_2$ 成立。类似于我们定义积分的流程, 立即知道 (6.20) 对任意非负可测函数 $f \in \mathcal{F}_2$ 成立。进而该式对任意的 $f \in L^1(\Omega_2, \mathcal{F}_2, \mu_2)$ 成立。□

注记 6.2. 上面证明中的方法被称为**典型方法**，它在后续很多场合有用。

当 $(\Omega_i, \mathcal{F}_i, \mathbb{P}_i), i = 1, 2$ 都是概率空间（相应数学期望算符分别记作 $\mathbb{E}_1, \mathbb{E}_2$ ），且 $T : (\Omega_1, \mathcal{F}_1, \mathbb{P}_1) \rightarrow (\Omega_2, \mathcal{F}_2, \mathbb{P}_2)$ 是保测映射时，我们可以通过下面的交换图

$$\begin{array}{ccc} (\Omega_1, \mathcal{F}_1, \mathbb{P}_1) & \xrightarrow{T} & (\Omega_2, \mathcal{F}_2, \mathbb{P}_2) \\ & \searrow f \circ T & \downarrow f \\ & & (\mathbb{R}, \mathcal{B}) \end{array}$$

来解释上面定理（积分变换公式）的结论：设 f 和 $f \circ T$ 分别是概率空间 $(\Omega_2, \mathcal{F}_2, \mathbb{P}_2)$ 和 $(\Omega_1, \mathcal{F}_1, \mathbb{P}_1)$ 上的能谈数学期望的随机变量；映射 T 的保测性意味着 f 与 $f \circ T$ 在各自概率空间中数学期望是一致的：

$$\mathbb{E}_2[f] = \mathbb{E}_1[f \circ T].$$

用期望收益来理解上式就是很自然的：同一份真实的随机收益，不同人的概率建模可能不同，但期望收益应该保持一致（否则就说明其中有人概率建模不正确）。

给定概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ ；设 ξ 为其上的随机变量，则

$$\xi : (\Omega, \mathcal{F}, \mathbb{P}) \rightarrow (\mathbb{R}, \mathcal{B}, \mathbb{P} \circ \xi^{-1})$$

就是一个保测映射，它自动就形成两个概率空间之间的**同态**， $\mathbb{P} \circ \xi^{-1}$ 恰为随机变量 ξ 对应的**分布**（或称**分布测度**），对应的**分布函数**为

$$F(x) := \mathbb{P}(\xi \leq x) = \mathbb{P}(\xi^{-1}((-\infty, x])) = \mathbb{P} \circ \xi^{-1}((-\infty, x]).$$

此时，随机变量 ξ 的分布测度 $\mathbb{P} \circ \xi^{-1}$ 本质上就是如下方式（借助 Carathéodory 定理）唯一确定的、定义于 $\mathbb{R}$ 上的 **Borel 概率测度** μ_F ：

$$\mu_F((a, b]) := F(b) - F(a), \text{ 其中 } -\infty < a < b < \infty.$$

给定一个“好”的可测函数 $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ ，我们可以借助随机变量 $\xi \sim F$ 构建如下交换图：

$$\begin{array}{ccc} (\Omega, \mathcal{F}, \mathbb{P}) & \xrightarrow{\xi} & (\mathbb{R}, \mathcal{B}, \mu_F) \\ & \searrow \varphi \circ \xi = \varphi(\xi) & \downarrow \varphi \\ & & (\mathbb{R}, \mathcal{B}) \end{array}$$

因此积分变换公式告诉我们， $\varphi(\xi) = \varphi \circ \xi$ 的数学期望与 φ 在概率空间 $(\mathbb{R}, \mathcal{B}, \mu_F)$ 中的数学期望一致。在概率论中，概率空间 $(\mathbb{R}, \mathcal{B}, \mu_F)$ 中的一个可测函数 φ

(视作随机变量)的数学期望,也就是 φ 关于测度 μ_F 的积分,它可以写作 $\int \varphi d\mu_F =: \int \varphi dF$. 于是如果可测函数 φ 使得 $\mathbb{E}\varphi(\xi)$ 存在,则

$$\mathbb{E}[\varphi(\xi)] := \int \varphi(\xi(\omega)) d\mathbb{P}(\omega) = \int \varphi(x) d\mathbb{P} \circ \xi^{-1}(x) = \int \varphi(x) dF(x).$$

以上讨论对于 m 维随机向量 ξ 仍然成立,只不过需要相应把概率空间 $(\mathbb{R}, \mathcal{B}, \mu_F)$ 对应修改为 $(\mathbb{R}^m, \mathcal{B}^m, \mu_F)$, 其中 F 是联合分布函数, μ_F 是联合分布测度. 因此我们有下面的定理,它给出了基于分布律的数学期望计算公式。

♠ **定理 6.3.2.** 当随机变量/向量 $\xi \sim F$ 且 φ 为相应的可测函数时¹,

$$\mathbb{E}[\varphi(\xi)] = \int \varphi(x) dF(x), \quad (6.21)$$

如果上式两端有一者有意义;特别地,当 $\mathbb{E}\xi$ 有意义时,它有如下计算公式

$$\mathbb{E}\xi = \int x dF(x), \quad (6.22)$$

上述定理是初等概率论中可以利用分布函数来计算对应随机变量的数学期望的原因;但在严格的公理化体系下,通常不直接把(6.22)作为数学期望的定义,以免造成不便。

6.3.2 概率空间的同态、同构及其应用

在上一小节讨论中已经提及概率空间(或测度空间)之间同态的概念。但注意到在概率论中,我们通常可以扔掉零概率事件来考虑问题,因而概率结构(或测度结构)的同态概念还可以更一般一点。简单来说,在讨论两个概率空间 $(\Omega_i, \mathcal{F}_i, \mathbb{P}_i), i = 1, 2$ (或测度空间)之间的可测映射

$$T : (\Omega_1, \mathcal{F}_1, \mathbb{P}_1) \rightarrow (\Omega_2, \mathcal{F}_2, \mathbb{P}_2)$$

是否是同态(即保测映射)时,我们可以不妨假设这两个概率空间已经是完备概率空间了,即 σ -代数 $\mathcal{F}_i$ 包含了 $\mathbb{P}_i$ 的所有零测集及其子集;在此基础上,甚至 T 不必在整个 Ω_1 上都有定义,它可以只在 Ω_1 的一个满测集上有定义即可。只不过在很多应用层面,我们上一小节介绍的通常的同态概念就足够了。

在上述讨论基础上进一步推进,就可以引出概率空间(或测度空间)之间同构的概念;例如,当保测映射实际上是双向可逆保测时,我们就可以认为通过这个可逆保测映射联系的两个概率结构(或测度结构)同构(我们称之为通

¹在 φ 为连续函数时, (6.21)右端积分也可以理解为 Riemann-Stieltjes 积分。

常意义下的同构)；但由于我们在概率论中通常可以扔掉零概率事件来考虑问题，因而概率结构（或测度结构）的同构概念还可以更一般一点。

首先，给定一个概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ ，如果 $\Omega' \in \mathcal{F}$ 满足 $\mathbb{P}(\Omega \setminus \Omega') = 0$ ，且 $\mathcal{F}' := \Omega' \cap \mathcal{F}, \mathbb{P}' := \mathbb{P}|_{\mathcal{F}'}$ ，则认为 $(\Omega, \mathcal{F}, \mathbb{P})$ 与 $(\Omega', \mathcal{F}', \mathbb{P}')$ 同构，记作 $(\Omega, \mathcal{F}, \mathbb{P}) \cong (\Omega', \mathcal{F}', \mathbb{P}')$ 。

其次，对于同一个概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上的两个子 σ -代数 $\mathcal{G}_1, \mathcal{G}_2 \subset \mathcal{F}$ ，称在模 $\mathbb{P}$ 意义下 $\mathcal{G}_1$ 包含于 $\mathcal{G}_2$ ，记作 $\mathcal{G}_1 \subset \mathcal{G}_2(\text{mod } \mathbb{P})$ ，如果对任意 $A_1 \in \mathcal{G}_1$ ，存在 $A_2 \in \mathcal{G}_2$ 使得 $\mathbb{P}(A_1 \Delta A_2) = 0$ 。进一步，如果同时有 $\mathcal{G}_1 \subset \mathcal{G}_2(\text{mod } \mathbb{P})$ 和 $\mathcal{G}_2 \subset \mathcal{G}_1(\text{mod } \mathbb{P})$ ，则称在模 $\mathbb{P}$ 意义下 $\mathcal{G}_1, \mathcal{G}_2$ 等价，记作 $\mathcal{G}_1 \equiv \mathcal{G}_2(\text{mod } \mathbb{P})$ ，此时我们认为 $(\Omega, \mathcal{G}_1, \mathbb{P})$ 与 $(\Omega, \mathcal{G}_2, \mathbb{P})$ 同构，记作 $(\Omega, \mathcal{G}_1, \mathbb{P}) \cong (\Omega, \mathcal{G}_2, \mathbb{P})$ 。

最后，给定两个概率空间 $(\Omega_k, \mathcal{F}_k, \mathbb{P}_k), k = 1, 2$ ，称它们同构，记作

$$(\Omega_1, \mathcal{F}_1, \mathbb{P}_1) \cong (\Omega_2, \mathcal{F}_2, \mathbb{P}_2),$$

如果存在概率空间 $(\Omega'_k, \mathcal{F}'_k, \mathbb{P}'_k), k = 1, 2$ 及映射 $T: \Omega'_1 \rightarrow \Omega'_2$ 使得

(i) 对 $k = 1, 2$ ， $\Omega'_k \in \mathcal{F}_k$ 且 $\mathbb{P}_k(\Omega_k \setminus \Omega'_k) = 0$ ；

(ii) 对 $k = 1, 2$ ，存在 $\bar{\mathcal{F}}_k \equiv \mathcal{F}_k(\text{mod } \mathbb{P}_k)$ 且 $\mathcal{F}'_k = \Omega'_k \cap \bar{\mathcal{F}}_k$ 使得

$$\text{id}_k: (\Omega'_k, \mathcal{F}'_k, \mathbb{P}'_k) \rightarrow (\Omega_k, \bar{\mathcal{F}}_k, \mathbb{P}_k), \omega \mapsto \omega$$

是可测且保测映射（这等价于要求 $\mathbb{P}'_k(A) := \mathbb{P}_k(A), \forall A \in \mathcal{F}'_k$ ）；

(iii) $T: (\Omega'_1, \mathcal{F}'_1, \mathbb{P}'_1) \rightarrow (\Omega'_2, \mathcal{F}'_2, \mathbb{P}'_2)$ 是可逆保测映射。

上面的 (i)、(ii) 本质上是在说，对样本空间和事件域作适当的微小修正后，子概率空间与原概率空间认为同构：

$$(\Omega'_k, \mathcal{F}'_k, \mathbb{P}'_k) \cong (\Omega_k, \mathcal{F}_k, \mathbb{P}_k), \quad k = 1, 2;$$

(iii) 则是在各自修正后的概率空间之间具有我们通常意义下的同构：

$$(\Omega'_1, \mathcal{F}'_1, \mathbb{P}'_1) \cong (\Omega'_2, \mathcal{F}'_2, \mathbb{P}'_2).$$

两者结合就给出了最终的概率空间的同构概念。

在（初等）概率论中，很多场景下我们使用通常意义下的概率空间的同构概念就足以解决有关问题。例如，我们在第五章给出的两个随机变量的相互独立性的刻画也可以借用同态、同构的语言描述如下：

♠ **定理 6.3.3.** 设 X_1, X_2 是概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上的两个随机列向量, 其中 X_k 是 n_k 维列向量, $X_k \sim \mu_k, k = 1, 2$. 则随机向量 $X := (X_1^T, X_2^T)^T$ 诱导了同态

$$X : (\Omega, \mathcal{F}, \mathbb{P}) \rightarrow (\mathbb{R}^{n_1+n_2}, \mathcal{B}^{n_1+n_2}, \mathbb{P} \circ X^{-1}).$$

X_1, X_2 相互独立的充要条件是 $\mathbb{P} \circ X^{-1} = \mu_1 \otimes \mu_2$, 这也等价于:

$$(\mathbb{R}^{n_1+n_2}, \mathcal{B}^{n_1+n_2}, \mathbb{P} \circ X^{-1}) = (\mathbb{R}^{n_1}, \mathcal{B}^{n_1}, \mu_1) \otimes (\mathbb{R}^{n_2}, \mathcal{B}^{n_2}, \mu_2).$$

结合例5.2, 上述定理实际说明了: 随机变量/向量“相互独立”, 当且仅当它们各自具有本质上“无关”的随机性源头。而借助上述定理中的思想与观点, 我们也可以说, 概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 中一列事件 $\{A_n\}_{n=1}^N$ 相互独立, 当且仅当: 存在一列概率空间 $\{(\Omega_n, \mathcal{F}_n, \mathbb{P}_n)\}_{n=1}^N$ 及与之对应的事件列 $\{\hat{A}_n \in \mathcal{F}_n\}_{n=1}^N$ 以及概率空间之间的同态

$$\varphi : (\Omega, \mathcal{F}, \mathbb{P}) \rightarrow \otimes_{k=1}^N (\Omega_k, \mathcal{F}_k, \mathbb{P}_k),$$

使得

$$A_n = \varphi^{-1}(\pi_n^{-1}(\hat{A}_n)), n = 1, \dots, N,$$

其中 $\pi_n : \otimes_{k=1}^N (\Omega_k, \mathcal{F}_k, \mathbb{P}_k) \rightarrow (\Omega_n, \mathcal{F}_n, \mathbb{P}_n)$ 是自然投影。于是, 随机事件“相互独立”当且仅当它们具有本质上“无关”的随机性源头。因此, 在概率空间同态意义下, 概率论语言的“相互独立”本质性地与自然语言的“无关”对应, 这也是本讲义中借助概率空间的独立乘积手段来介绍事件独立性的本质原因所在。

以下再举几个例子来说明有关概念的引入确实带来了说理论证上的便利。

例 6.4. *Galileo Galilei* (伽利略) 曾经研究过投掷 3 枚骰子的相关问题。他发现总点数和为 10 与 11 两个事件 (分别记作 A_{10} 与 A_{11}) 的频率或概率相同: $\mathbb{P}(A_{10}) = \mathbb{P}(A_{11})$ (均等于 $\frac{1}{8}$)。我们来说明这并不是一个纯粹计算上的巧合。

对于投掷单个骰子, 我们可以使用 $\Sigma := \{1, \dots, 6\}$ 上的古典概率模型作为它的概率模型, 其中可以定义变换 $T(x) := 7 - x$, 显然变换 $T : \Sigma \rightarrow \Sigma$ 是这个古典概率模型上的同构。对于投掷三枚骰子, 我们可以使用 $\Omega_3 := \Sigma^3$ 上的古典概率模型作为它的概率模型, 上面可以定义乘积变换 $T : \Omega_3 \rightarrow \Omega_3$ 为 $T(x_1, x_2, x_3) := (T(x_1), T(x_2), T(x_3)) = (7 - x_1, 7 - x_2, 7 - x_3)$, 仍然是一个同构, 从而 $\mathbb{P} \circ T^{-1} = \mathbb{P}$. 事件 A_n 表示三枚骰子总点数和为 n 这一事件, 即

$$A_n := \{(x_1, x_2, x_3) : x_1 + x_2 + x_3 = n\}.$$

于是显然有 $T^{-1}A_{10} = A_{11}$, 因此 $\mathbb{P}(A_{10}) = \mathbb{P}(A_{11})$. □

例 6.5. 甲乙二人投掷同一枚均匀的硬币。甲投掷了 $n+1$ 次, 得到 X 个正面; 乙投掷了 n 次, 得到 Y 个正面。请计算甲获得的正面次数多于乙获得的正面次数的概率 $\mathbb{P}(X > Y)$ 。

参考解答: 如果使用组合计数技巧直接进行计算, 当然也能得出问题的解答。这里我们借用上一例题中的观点来给出一个快速而严谨的解答。

首先, 为了说话方便, 我们选择的概率空间为 $\Omega := \{0, 1\}^{2n+1}$ 上的古典概率模型; 其中 1 代表硬币正面, 0 代表硬币反面。对于投掷单个硬币, 我们可以定义 $T(x) = 1 - x$; 它诱导 Ω 上的一个乘积映射: $T(\omega_1, \dots, \omega_{2n+1}) = (1 - \omega_1, \dots, 1 - \omega_{2n+1})$, 它是保测的。这时不妨认为

$$X = \omega_1 + \dots + \omega_{n+1}, Y = \omega_{n+2} + \dots + \omega_{2n+1}.$$

显然 $X \circ T = (n+1) - X, Y \circ T = n - Y$, 从而

$$T^{-1}(\{X > Y\}) = \{X \circ T > Y \circ T\} = \{X \leq Y\} = (\{X > Y\})^c,$$

于是 $\mathbb{P}(X > Y) = \mathbb{P}(T^{-1}(\{X > Y\})) = \mathbb{P}((\{X > Y\})^c)$. 由此 $\mathbb{P}(X > Y) = \mathbb{P}(X \leq Y) = 1/2$. $\square$

在下例中, 我们将借助同构的思想来讨论习题5.28的结论(3), 以避开复杂的计算; 为方便读者, 我们把习题5.28的结论(3)再次陈述在例子中。

例 6.6. 记 p_A, p_B 为单次随机试验中 A 现象、 B 现象各自成功出现的概率, 假设 $p_A \cdot p_B > 0$. 总记 τ_A 为试验过程中检测到 A 现象发生所需进行的最少重复试验次数; 记号 τ_B 作同样理解。那么 A, B 相互独立, 当且仅当 τ_A 与 τ_B 相互独立。

参考证明: 这里我们向读者明确 (参见 §3.3.4): 事件 A, B 所在的概率空间为 $(\Omega, \mathcal{F}, \mathbb{P})$; 而随机变量 τ_A 与 τ_B 所在的概率空间为 $(\tilde{\Omega}, \tilde{\mathcal{F}}, \tilde{\mathbb{P}}) := (\Omega, \mathcal{F}, \mathbb{P})^{\mathbb{N}}$.

在本例中, 不难知道, 当 τ_A 与 τ_B 相互独立时, 我们有

$$\begin{aligned} \mathbb{P}(A \cap B) &= \tilde{\mathbb{P}}(\tau_A = 1, \tau_B = 1) = \tilde{\mathbb{P}}(\tau_A = 1) \tilde{\mathbb{P}}(\tau_B = 1) \\ &= p_A p_B = \mathbb{P}(A) \mathbb{P}(B). \end{aligned}$$

此即 A, B 相互独立。

以下我们论证, 当 A, B 相互独立时, τ_A 与 τ_B 也必定相互独立。这里, 我们不妨¹设概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 是乘积空间 $(\Sigma_2, \mathcal{F}_2, \mu_1) \otimes (\Sigma_2, \mathcal{F}_2, \mu_2)$, 其中 $\Sigma_2 = \{0, 1\}, \mathcal{F}_2 = 2^{\Sigma_2}$, 并且 $A = \{1\} \times \Sigma_2, B = \Sigma_2 \times \{1\}$,

$$\mu_1(\{1\}) = p_A, \mu_1(\{0\}) = 1 - p_A, \quad \mu_2(\{1\}) = p_B, \mu_2(\{0\}) = 1 - p_B.$$

¹请读者思考补全可以这样做的原因。

于是, 取 $(\tilde{\Omega}_k, \tilde{\mathcal{F}}_k, \tilde{\mathbb{P}}_k) := (\Sigma_2, \mathcal{F}_2, \mu_k)^{\mathbb{N}}, k = 1, 2$, 容易知道

$$(\tilde{\Omega}, \tilde{\mathcal{F}}, \tilde{\mathbb{P}}) \cong (\tilde{\Omega}_1, \tilde{\mathcal{F}}_1, \tilde{\mathbb{P}}_1) \otimes (\tilde{\Omega}_2, \tilde{\mathcal{F}}_2, \tilde{\mathbb{P}}_2).$$

于是对 $\tilde{\omega} \in \tilde{\Omega}$, $\tilde{\omega} = \{(\omega_n^{(1)}, \omega_n^{(2)})\}_{n=1}^{\infty}$, 借助上述同构我们有如下坐标表示:

$$\tilde{\omega} = (\omega^{(1)}, \omega^{(2)}) \in \tilde{\Omega}_1 \times \tilde{\Omega}_2,$$

其中 $\omega^{(1)} = (\omega_1^{(1)}, \omega_2^{(1)}, \dots) \in \Sigma_2^{\mathbb{N}} = \tilde{\Omega}_1$, $\omega^{(2)} = (\omega_1^{(2)}, \omega_2^{(2)}, \dots) \in \Sigma_2^{\mathbb{N}} = \tilde{\Omega}_2$. 并且, 我们知道

$$\begin{aligned} \tau_A(\tilde{\omega}) &= \inf\{n \geq 1 : (\omega_n^{(1)}, \omega_n^{(2)}) \in A\} \\ &= \inf\{n \geq 1 : \omega_n^{(1)} = 1\} =: \tau_1(\omega^{(1)}), \\ \tau_B(\tilde{\omega}) &= \inf\{n \geq 1 : (\omega_n^{(1)}, \omega_n^{(2)}) \in B\} \\ &= \inf\{n \geq 1 : \omega_n^{(2)} = 1\} = \tau_1(\omega^{(2)}). \end{aligned}$$

根据定理5.1.2 (亦可参见习题6.52的结论(3)), 显然有 τ_A 与 τ_B 相互独立. $\square$

6.3.3 数学期望的计算公式 (II)

注意到 Fubini 定理6.2.4 (亦可参见定理4.4.4), 对于非负随机变量, 我们还有如下方式来计算数学期望:

♠ **定理 6.3.4.** 设 ξ 是非负随机变量, 那么

$$\mathbb{E}\xi = \int_0^{\infty} \mathbb{P}(\xi > x) dx. \quad (6.23)$$

参考证明: 注意到 $\mathbb{P}(\xi > x) = \mathbb{E}[1_{\{\xi > x\}}]$ 以及数学期望本质上是一种积分, 利用 Fubini 定理就能得到

$$\begin{aligned} \int_0^{\infty} \mathbb{P}(\xi > x) dx &= \int \mathbb{E}[1_{\{\xi > x\}}] dx = \mathbb{E}\left[\int_0^{\infty} 1_{\{\xi > x\}} dx\right] \\ &= \mathbb{E}\left[\int_0^{\xi} dx\right] = \mathbb{E}\xi. \end{aligned}$$

这里, 我们要指出, $1_{\{\xi > x\}} = 1_{(0, \infty)}(\xi - x)$ 实际上是一个非负的二元函数, 自变量为 (ω, x) , 因为 $\xi = \xi(\omega)$; 这个函数的二元可测性是显然的. $\square$

上述非负随机变量情形的数学期望计算公式及其中蕴含的思想方法有时非常有用. 请参见本章及第七章有关课后习题.

6.4 矩与无偏估计

6.4.1 方差、协方差与独立性

以上我们定义了一个随机变量 ξ 的数学期望 $\mathbb{E}\xi$ ；如果 $\mathbb{E}\xi$ 是一个有限值，我们把它称为随机变量 ξ 的一阶矩。一般地，我们把 ξ 的 n 阶矩定义为 $\mathbb{E}[\xi^n]$ ，如果它存在；否则将称 ξ 的 n 阶矩不存在。更一般地，对任意 $0 < p \leq \infty$ ，我们定义 p -范数

$$\|\xi\|_p := \begin{cases} (\mathbb{E}[|\xi|^p])^{1/p}, & p \in (0, \infty) \\ \inf\{M > 0 : \mathbb{P}(|\xi| > M) = 0\}, & p = \infty. \end{cases} \quad (6.24)$$

进一步，我们可以定义 ξ 的方差：当 ξ 的二阶矩存在时，称

$$\mathbb{V}\text{ar}(\xi) := \mathbb{E}[(\xi - \mathbb{E}\xi)^2] \quad (6.25)$$

为 ξ 的方差；当 ξ 的二阶矩不存在时，我们也称 ξ 的方差不存在。易知

$$\mathbb{V}\text{ar}(\xi) = \mathbb{E}[\xi^2] - (\mathbb{E}\xi)^2. \quad (6.26)$$

这蕴含了如下矩不等式

$$(\mathbb{E}\xi)^2 \leq \mathbb{E}[\xi^2]. \quad (6.27)$$

现在我们考虑两个随机变量 ξ 与 η 的乘积的数学期望 $\mathbb{E}[\xi \cdot \eta]$ 。通过考察二次多项式函数

$$f(t) := \mathbb{E}[|t\xi - \eta|^2] = t^2\mathbb{E}[|\xi|^2] - 2t\mathbb{E}[\xi \cdot \eta] + \mathbb{E}[|\eta|^2],$$

不难得到如下形式的 **Cauchy 不等式**：当 ξ, η 的二阶矩都存在时，

$$|\mathbb{E}[\xi \cdot \eta]|^2 \leq \mathbb{E}[|\xi|^2] \cdot \mathbb{E}[|\eta|^2]. \quad (6.28)$$

我们定义 ξ 与 η 的**协方差**为

$$\mathbb{C}\text{ov}(\xi, \eta) := \mathbb{E}[(\xi - \mathbb{E}\xi)(\eta - \mathbb{E}\eta)], \quad (6.29)$$

如果上式右端是有限值（否则将称 ξ 与 η 的协方差不存在）。利用前述的 Cauchy 不等式，也立即得到有关协方差的 **Cauchy 不等式**：当 ξ, η 的二阶矩都存在时，

$$|\mathbb{C}\text{ov}(\xi, \eta)|^2 \leq \mathbb{V}\text{ar}(\xi) \cdot \mathbb{V}\text{ar}(\eta). \quad (6.30)$$

当 $\mathbb{Cov}(\xi, \eta) = 0$ 时, 我们也称 ξ 与 η 线性不相关。当 ξ, η 的方差存在且均不为 0 时, 人们进一步定义所谓的 ξ 与 η 的相关系数:

$$\mathbb{Corr}(\xi, \eta) := \frac{\mathbb{Cov}(\xi, \eta)}{\sqrt{\mathbb{Var}(\xi) \cdot \mathbb{Var}(\eta)}}. \quad (6.31)$$

此时应有 $\mathbb{Corr}(\xi, \eta) \in [-1, 1]$. 特别地, 当 $\mathbb{Var}(\xi), \mathbb{Var}(\eta) \in (0, \infty)$ 时

$$\mathbb{Corr}(\xi, \eta) = 1 \Leftrightarrow \exists a > 0, b \in \mathbb{R}, \mathbb{P}(\eta = a\xi + b) = 1, \quad (6.32)$$

$$\mathbb{Corr}(\xi, \eta) = -1 \Leftrightarrow \exists a < 0, b \in \mathbb{R}, \mathbb{P}(\eta = a\xi + b) = 1. \quad (6.33)$$

关于利用数学期望来探讨随机变量的独立性, 我们有如下重要结果。

♠ **定理 6.4.1.** 设 ξ 与 η 相互独立, 并且它们的一阶矩都存在, 那么

$$\mathbb{E}[\xi \cdot \eta] = \mathbb{E}\xi \cdot \mathbb{E}\eta. \quad (6.34)$$

亦即此时有 $\mathbb{Cov}(\xi, \eta) = 0$. 反之¹, 如果 $\mathbb{Cov}(\varphi(\xi), \psi(\eta)) = 0$ 对任意有界连续函数 φ, ψ 都成立, 则 ξ 与 η 相互独立。

参考证明: 为方便, 设 ξ 与 η 的分布测度分别是 μ, ν , 即 $\xi \sim \mu, \eta \sim \nu$.

当 ξ 与 η 相互独立时, 根据定理 5.1.2, $(\xi, \eta) \sim \mu \otimes \nu$; 根据 (6.21) 以及 Fubini 定理 (见定理 4.4.4)

$$\begin{aligned} \mathbb{E}[\xi \cdot \eta] &= \int x \cdot y d\mu \otimes \nu(x, y) = \int \left[\int x \cdot y d\mu(x) \right] d\nu(y) \\ &= \int \left[\int x d\mu(x) \right] \cdot y d\nu(y) = \int [\mathbb{E}\xi] \cdot y d\nu(y) \\ &= [\mathbb{E}\xi] \cdot \int y d\nu(y) = [\mathbb{E}\xi] \cdot [\mathbb{E}\eta]. \end{aligned}$$

反过来, $\mathbb{Cov}(\varphi(\xi), \psi(\eta)) = 0$ 等价于:

$$\mathbb{E}[\varphi(\xi) \cdot \psi(\eta)] = \left[\int \varphi(x) d\mu(x) \right] \left[\int \psi(x) d\nu(x) \right].$$

上式对所有有界连续函数 φ, ψ 成立, 进而对所有有界可测函数 φ, ψ 成立。特别地, 取 $\varphi = 1_A, \psi = 1_B$, 其中 A, B 为可测集, 立即得到

$$\mathbb{P}(\xi \in A, \eta \in B) = \mu(A) \cdot \nu(B).$$

特取 $A = (-\infty, x], B = (-\infty, y]$, 立即得到 ξ 与 η 独立。□

¹习题 B.9 告诉我们, 此处定理中 φ, ψ 仅仅跑遍所有多项式而不是所有有界连续函数时对应结论有反例。亦即: $\mathbb{Cov}(\xi^m, \eta^n) = 0, \forall m, n \in \mathbb{Z}$ 并不总能导出 ξ 与 η 相互独立。

 **推论 6.4.1.** 设 ξ, η 的二阶矩都存在。如果它们相互独立（或线性不相关，即 $\mathbb{Cov}(\xi, \eta) = 0$ ），那么

$$\mathbb{V}\text{ar}(\xi \pm \eta) = \mathbb{V}\text{ar}(\xi) + \mathbb{V}\text{ar}(\eta). \quad (6.35)$$

我们有如下简单事实：

 **引理 6.4.1.** 设 X, Y 独立同分布且 $\mathbb{E}[X^2] < \infty$ ，那么 $\mathbb{E}[|X - Y|^2] = 2\mathbb{V}\text{ar}(X)$ 。

基于此，我们进一步介绍一种估算方差的技巧如下。

 **定理 6.4.2.** 设 $g: \mathbb{R} \rightarrow \mathbb{R}$ 满足

$$|g(x) - g(y)| \leq L \cdot |x - y|, \forall x, y,$$

其中 $L \in \mathbb{R}_+$ 。又设 $\mathbb{E}[X^2] < \infty$ ，那么

$$\mathbb{V}\text{ar}(g(X)) \leq L^2 \cdot \mathbb{V}\text{ar}(X).$$

证明： 基于引理6.4.1导出的对称化方法进行论证。取 X, Y 独立同分布。由于 g 是 Lipschitz 函数，对任意取定 $x_0 \in \mathbb{R}$

$$|g(X)| \leq |g(x_0)| + |g(X) - g(x_0)| \leq |g(x_0)| + L \cdot |X - x_0|,$$

从而由 $X \in L^2(\mathbb{P})$ 导出 $g(X) \in L^2(\mathbb{P})$ 。进而再由 $|g(X) - g(Y)| \leq L \cdot |X - Y|$ 及 $g(X), g(Y)$ 独立同分布，得到

$$\begin{aligned} \mathbb{V}\text{ar}(g(X)) &= \frac{1}{2} \mathbb{E}[|g(X) - g(Y)|^2] \\ &\leq \frac{L^2}{2} \mathbb{E}[|X - Y|^2] = L^2 \cdot \mathbb{V}\text{ar}(X). \quad \square \end{aligned}$$

6.4.2 统计量与无偏估计简介

给定随机变量列 $\{X_k\}_{k=1}^n$ （在统计学中也称“样本”），设它们的联合分布为 $(X_1, \dots, X_n) \sim F_\theta$ ，其中（确定性的）参数 $\theta \in \Theta$ 未知，但对任意固定 $\theta \in \Theta$ ，分布函数 F_θ 都是已知的。我们将用 $\mathbb{E}_\theta$ 和 $\mathbb{V}\text{ar}_\theta$ 表示分布律 F_θ 确定的数学期望算子与方差算子。

如果我们想利用这些样本构造出一个统计量 $T = T(X_1, \dots, X_n)$ 来估计 $g(\theta)$ （其中 g 为一已知的可测函数），则当

$$\mathbb{E}_\theta[T] = g(\theta), \forall \theta \in \Theta$$

时, 我们就称 T 是参数 $g(\theta)$ 的**无偏估计**; 对于给定 $\theta_0 \in \Theta$, 如果在所有的无偏估计中, $\mathbb{V}\text{ar}_{\theta_0}(T)$ 达到最小, 则称 T 是参数 $g(\theta)$ (在 $\theta = \theta_0$ 处) 的**最小方差无偏估计**; 如果对所有的 $\theta_0 \in \Theta$, T 是参数 $g(\theta)$ 在 $\theta = \theta_0$ 处的最小方差无偏估计, 则进一步称 T 是**一致最小方差无偏估计**。

在第五章中, 通过例5.12和例5.13, 我们介绍了基于极大似然的思想构建极大似然估计的方法。另外, 统计学中还有一种矩方法用于构造相应的估计量。记 $\widehat{M}_k := \frac{1}{n}(X_1^k + \cdots + X_n^k)$, 称之为 **k -阶样本矩**。如果通过解方程

$$\mu_k = f_k(\theta) := \mathbb{E}_\theta[\widehat{M}_k], k = 1, \cdots, p$$

可以反解出 $g(\theta) = h(\mu_1, \cdots, \mu_p)$, 其中 h 是一个不依赖于参数 θ 的(连续)函数, $\mu_1, \cdots, \mu_k$ 是任何有意义的常数, 则可以构造统计量

$$T := h(\widehat{M}_1, \cdots, \widehat{M}_p).$$

这种构造统计量的办法称为**矩方法**, 此时 T 称为参数 $g(\theta)$ 的一个**矩估计**。

例 6.7. 设 $\{X_k\}_{k=1}^n$ 独立同分布, 假定 $\mathbb{E}[X_1^2] < \infty$. 则均值 $\mu := \mu_1 = \mathbb{E}X_1$ 的矩估计为

$$\widehat{\mu} := \widehat{\mu}_1 = \bar{X}_n = \frac{X_1 + \cdots + X_n}{n},$$

二阶矩 $\mu_2 := \mathbb{E}[X_1^2]$ 的矩估计为

$$\widehat{\mu}_2 := \overline{X^2}_n = \frac{X_1^2 + \cdots + X_n^2}{n},$$

由此构建出方差 $\sigma^2 := \mathbb{V}\text{ar}(X_1) = \mu_2 - \mu_1^2$ 的如下矩估计

$$\widehat{\sigma^2} := \widehat{\mu}_2 - (\widehat{\mu}_1)^2 = \frac{1}{n} \sum_{k=1}^n (X_k - \bar{X}_n)^2. \quad (6.36)$$

但这个估计 $\widehat{\sigma^2}$ 不是无偏的:

$$\mathbb{E}[\widehat{\sigma^2}] = \frac{n-1}{n} \sigma^2.$$

因此, 在统计学中更多使用下面的 σ^2 的无偏估计

$$s_n^2 := \frac{1}{n-1} \sum_{k=1}^n (X_k - \bar{X}_n)^2 \quad (6.37)$$

作为样本的估计值, 它被称为**样本标准方差**, 而其根号值 s_n 就称为**样本标准根差**。

统计学中关于如何寻找性质优良的估计量有系统的理论与方法, 本书不展开论述; 感兴趣的读者请参看习题9.20—9.22, 或其他专业的统计书籍。

6.5 本章小结与学习建议

本章我们基于

$$\mathbb{E}1_A := \mathbb{P}(A), \forall A \in \mathcal{F},$$

定义了一般随机变量的数学期望，有三种可能：（1）数学期望无意义；（2）数学期望有意义，但取无穷值；（3）数学期望有意义，且取有限值；最后一种情况又称为数学期望存在，或称对应的随机变量可积。本章定义数学期望的形式化流程本质上是泛函分析中的 **Hahn-Banach** 延拓定理在概率论中的应用，它在概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 的随机变量空间上定义出了数学期望算子 $\mathbb{E}$ 。之后，我们引入保测映射的概念，并基于此概念导出的积分变换公式，推导出了可积随机变量的基于分布律的数学期望计算公式，介绍了概率论与数理统计学中非常重要的矩、方差、无偏估计等概念；期间也顺带介绍了概率空间的同态与同构概念。对于没有学过实变函数论或泛函分析的概率论初学者，上述定义数学期望的流程略作了解即可，其中的严谨证明暂时不必深究，但有关数学期望的性质、特别是数学期望的计算公式需要掌握；关于涉及极限交换的几个大结果（Levi 单调收敛定理、Fatou 引理、Lebesgue 控制收敛定理、Fubini 定理），初学时亦可采取承认其结论而不深究其逻辑证明的态度，通过在一些案例中应用来熟悉有关结果。

习 题 6

习题 6.1. 基于以下函数恒等式

$$1_{A \cup B} = 1_A \vee 1_B = 1_A + 1_B - 1_{A \cap B},$$

$$1_{A \cap B} = 1_A \wedge 1_B = 1_A \cdot 1_B, \quad 1_{A \Delta B} = |1_A - 1_B| = 1_A + 1_B \pmod{2},$$

$$1_{A \Delta B \Delta C} = 1_{A \setminus (B \cup C)} + 1_{B \setminus (A \cup C)} + 1_{C \setminus (A \cup B)} + 1_{A \cap B \cap C},$$

证明以下诸概率恒等式

$$\begin{aligned} \mathbb{P}(A \cup B) &= \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B), \\ \mathbb{P}(A \cup B) &= \frac{1}{2}[\mathbb{P}(A) + \mathbb{P}(B) + \mathbb{P}(A \Delta B)], \end{aligned} \quad (6.38)$$

$$\mathbb{P}(A \cap B) = \frac{1}{2}[\mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \Delta B)] \quad (6.39)$$

以及不等式

$$\begin{aligned} \mathbb{P}(A \Delta B) &\leq \mathbb{P}(A \Delta C) + \mathbb{P}(C \Delta B), \\ \mathbb{P}(A \Delta B \Delta C) - \mathbb{P}(A \cap B \cap C) &\leq \frac{1}{2}[\mathbb{P}(A \Delta B) + \mathbb{P}(B \Delta C) + \mathbb{P}(C \Delta A)]. \end{aligned}$$

习题 6.2. 利用 $\mathbb{P}(A) = \mathbb{E}1_A$ 的观点结合数学期望的有关性质, 给出习题 2.26 的新证明。

习题 6.3. 设 X 服从整数子集 $D := (a, b] \cap \mathbb{Z}$ 上的均匀分布, 其中 $a < b$ 是整数。计算 X 的数学期望与方差。

习题 6.4. 设 $\{X_k\}_{k=1}^n \stackrel{\text{i.i.d.}}{\sim} B(1, p)$. 计算 $X_1 \sim B(1, p)$ 的数学期望与方差, 进而计算 $S_n := X_1 + \cdots + X_n \sim B(n, p)$ 的数学期望与方差。此题也表明例 5.12 中估计也可以视作矩估计, 并且是无偏估计。

习题 6.5. 设 $\tau \sim \text{Geo}(p)$. 证明: $\mathbb{E}[\tau] = \frac{1}{p}$, $\mathbb{E}[\tau(\tau+1)] = \frac{2}{p^2}$, 从而 $\text{Var}(\tau) = \frac{q}{p^2}$.

习题 6.6. 求 $\tilde{N}_r \sim NB(r, p)$ 的数学期望与方差, 其中 $r \geq 1$ 是整数。

习题 6.7. 证明例 5.13 中估计量是矩估计, 并且是无偏估计。

习题 6.8. 设 F 是分布函数, $a > 0$, 证明: $\int [F(x+a) - F(x)]dx = a$.

习题 6.9. 设 $X \sim F$ 满足: 对某常数 $a > 0$, $\int [F(x+a) - F(x)]^{2024} dx = a$. 试论证: X 是退化的随机变量, 即存在 $b \in \mathbb{R}$ 使得 $\mathbb{P}(X = b) = 1$. 反过来的结论也成立。

习题 6.10. 设 $X \sim F$, $\mu := \mathbb{E}X \in \mathbb{R}$. 证明: 当 F 是连续函数时, 方程 $\int_{-\infty}^a F(x)dx = \int_a^{\infty} [1 - F(x)]dx$ 具有唯一解 $a = \mu$.

习题 6.11. 设 $p > 0$, 求证: $\mathbb{E}[|X|^p] = \int_0^{\infty} px^{p-1}\mathbb{P}(|X| > x)dx$.

习题 6.12. 求证: 随机变量 X 可积的充分必要条件是 $\sum_{n=1}^{\infty} \mathbb{P}(|X| \geq n) < \infty$.

习题 6.13. 设随机变量 X 只取非负整数值, 求证:

$$\begin{aligned}\mathbb{E}[X] &= \sum_{n=1}^{\infty} \mathbb{P}(X \geq n), & \mathbb{E}[X^2] &= \sum_{n=1}^{\infty} (2n-1)\mathbb{P}(X \geq n), \\ \mathbb{E}\left[\frac{X(X+1)}{2}\right] &= \sum_{n=1}^{\infty} n \cdot \mathbb{P}(X \geq n), & \mathbb{E}\left[\frac{X(X-1)}{2}\right] &= \sum_{n=1}^{\infty} n \cdot \mathbb{P}(X > n).\end{aligned}$$

习题 6.14. 本题是对上一习题的进一步思考。请寻找可测函数 g , 使得对任意随机变量 X 都有 $\sum_{n=0}^{\infty} \mathbb{P}(X \geq n) = \mathbb{E}[g(X)]$.

习题 6.15. 设 $\{X_k\}_{k=1}^n \stackrel{\text{i.i.d.}}{\sim} \begin{pmatrix} 0 & 1 & 2 & \cdots \\ p_0 & p_1 & p_2 & \cdots \end{pmatrix}$. 求证: $\mathbb{E}[\min_{1 \leq i \leq n} X_i] = \sum_{m=1}^{\infty} \left(\sum_{i=m}^{\infty} p_i \right)^n$.

习题 6.16. 设 $\{X_k\}_{k=1}^n$ 独立同分布, 且 $\mathbb{P}(X_1 \geq 0) = 1$. 求证:

$$\mathbb{E}[\min_{1 \leq i \leq n} X_i] = \int_0^{\infty} \mathbb{P}(X_1 > t)^n dt.$$

习题 6.17. 对可积随机变量 X , 考察函数 $f(a) := \mathbb{E}|X - a|$ 的最小值点全体所成集合 Med_x , 说明它是单点集或一个非空闭区间. 对任意 $a \in Med_x$, 证明: $\mathbb{P}(X \leq a) \geq \frac{1}{2}$, $\mathbb{P}(X \geq a) \geq \frac{1}{2}$. 这样的点 a 都称为是 X 的分布对应的中位数 (有时仅把最小的 $a = \inf Med_x$ 称为 $\frac{1}{2}$ -分位数).

习题 6.18. 对 L^2 -可积的 X , 证明: $f(a) := \mathbb{E}[(X - a)^2]$ 的最小值点是 $a = \mathbb{E}X$.

习题 6.19. 对 L^2 -可积随机变量列 $\{X_k\}_{k=1}^n, \{Y_k\}_{k=1}^n$, 证明:

$$\left[\sum_{k=1}^n \text{Cov}(X_k, Y_k) \right]^2 \leq \left[\sum_{k=1}^n \text{Var}(X_k) \right] \cdot \left[\sum_{k=1}^n \text{Var}(Y_k) \right].$$

习题 6.20. 设 X, Y 为两随机变量, 均值为 0, 方差为 1, 协方差 r . 试证明: $\mathbb{E}[\max(X^2, Y^2)] \leq 1 + \sqrt{1 - r^2}$.

习题 6.21. 设 $\{X_k\}_{k=1}^n$ 相互独立, $0 < \sigma_k^2 := \text{Var}(X_k) < \infty, k = 1, \dots, n$. 试求权重向量 $p = (p_1, \dots, p_n)$ (即 $p \in \mathbb{R}_+^n$ 且 $p_1 + \dots + p_n = 1$), 使得 $\text{Var}(\sum_{k=1}^n p_k X_k)$ 达到最小.

习题 6.22. 设 $\{X_k\}_{k=1}^n$ 相互独立, $\mu_k := \mathbb{E}X_k > 0, 0 < \sigma_k^2 := \text{Var}(X_k) < \infty, k = 1, \dots, n$. 试求权重向量 $p = (p_1, \dots, p_n)$ (即 $p \in \mathbb{R}_+^n$ 且 $p_1 + \dots + p_n = 1$), 使得 $\frac{\mathbb{E}[\sum_{k=1}^n p_k X_k]}{\sqrt{\text{Var}(\sum_{k=1}^n p_k X_k)}}$ 达到最大.

习题 6.23. 考虑习题 3.39. 如果记 r 次取球中取到的红球数为 X , 请计算 $\mathbb{E}X, \text{Var}(X)$.

习题 6.24. 仍然考虑习题 3.39. 如果只在每次取到红球时记录下袋子的编号加 1 得到的值 (否则记录 0), 取了 r 次球后, 把这些记录值求和得到一个值 Y , 请计算 $\mathbb{E}Y, \text{Var}(Y)$.

习题 6.25. 二人通过“石头-剪刀-布”的手势游戏方式决出输家、赢家所需的平均局数是多少? 其中平均发生了多少平局?

习题 6.26. 习题 3.42 中 3 个小孩为决出唯一输家而进行“石头-剪刀-布”游戏平均需要进行多少局? 其中平均发生了多少平局?

习题 6.27. 求习题 3.43 中的 3 个小孩平均需要进行多少局“黑白配”才能决出唯一输家? 其中平均发生了多少平局?

习题 6.28. 习题 3.44 中的五个孩子为决出唯一输家平均需要进行多少局手势游戏? 其中平均发生了多少平局?

习题 6.29. 习题 3.45 中, 两人单打的平均耗时约是多少?

习题 6.30. 习题 3.46 中, 两人单打的平均耗时约是多少?

习题 6.31. 设 X, Y 都是离散型随机变量, 它们相互独立. 又设 $g(x, y)$ 是有界可测函数, 求证: $\mathbb{E}[g(X, Y)] = \mathbb{E}[\mathbb{E}g(X, y)|_{y=Y}]$.

习题 6.32. 设两事件 A, B 都是正概率事件: $\mathbb{P}(A) > 0, \mathbb{P}(B) > 0$. 称 A 与 B 是正相关的, 如果 $\mathbb{P}(B|A) > \mathbb{P}(B)$. 求证: A 与 B 是正相关的充要条件是 $\text{Cov}(1_A, 1_B) > 0$. 于是 A 与 B 是正相关的, 当且仅当 B 与 A 是正相关的.

习题 6.33. 对于 50 个人的班级, 请计算成对的同生日同学的平均对数.

习题 6.34. 设 $\{X_k\}_{k=1}^n$ 是独立同分布的正值随机变量序列. 求证:

$$\mathbb{E}\left[\frac{X_1 + X_2 + \cdots + X_m}{X_1 + X_2 + \cdots + X_n}\right] = \frac{m}{n}, \quad m = 1, \cdots, n.$$

习题 6.35. 设 $X \sim \text{Poisson}(\lambda)$. 求证: 对任意非负可测函数 g , 总有

$$\mathbb{E}[Xg(X)] = \lambda \cdot \mathbb{E}[g(X+1)].$$

习题 6.36. 设有 $n+1$ 人参加一项人机对抗的电子竞技赛事, 假定比赛中每人与机器对抗成功的概率均为 $p \in (0, 1)$. 主办方有 1 单位金额的奖金提供给该赛事的获胜者们平均分配; 如果没有获胜者, 则该奖金将被主办方收回. 借此模型, 用自然语言说明: 如果 $\{X_k\}_{k=1}^{n+1} \stackrel{\text{i.i.d.}}{\sim} B(1, p)$, $S_n := X_1 + \cdots + X_n$, 则 $\mathbb{E}\left[\frac{1}{1+S_n}\right] = \frac{1-(1-p)^{n+1}}{(n+1)p}$.

习题 6.37. 总共 4 辆校车载着 148 名中学生从学校到虹口足球场去踢球; 车上分别有 40 名、33 名、25 名、50 名同学以及每车一名带队老师. 从 148 名学生中随机选一名同学, 用 X 表示他所在的车上的学生数量; 从 4 名带队老师中随机选一名老师, 用 Y 表示他所带领的学生数量. 请计算 $\mathbb{E}X, \mathbb{E}Y$, 比较它们的大小.

习题 6.38. 设 f, g 为单调递增函数, X 是一个随机变量, 使得本题涉及的数学期望均存在. 求证: $\mathbb{E}[f(X)g(X)] \geq \mathbb{E}[f(X)] \cdot \mathbb{E}[g(X)]$.

习题 6.39. 设 X 的二阶矩有限, 求证: $\text{Var}(X \wedge a) \leq \text{Var}(X), \forall a \in \mathbb{R}$.

习题 6.40. 设 $0 < a < b < \infty$, $\mathbb{P}(X \in [a, b]) = 1$, 则有算术平均-几何平均不等式的如下加强版本:

$$\frac{a}{2b^2} \cdot \text{Var}(X) \leq \mathbb{E}X - e^{\mathbb{E} \ln X} \leq \frac{b}{2a^2} \cdot \text{Var}(X).$$

更强的版本为:

$$\frac{\text{Var}(X)}{2b} \leq \mathbb{E}X - e^{\mathbb{E} \ln X} \leq \frac{\text{Var}(X)}{2a}. \quad (6.40)$$

习题 6.41. 设 $0 < a < b < \infty$, $\mathbb{P}(X \in [a, b]) = 1$, 则

$$\frac{\text{Var}(X) \cdot \mathbb{E}X}{\text{Var}(X) + b \cdot \mathbb{E}X} \leq \mathbb{E}X - \left(\mathbb{E}[X^{-1}] \right)^{-1} \leq \frac{\text{Var}(X) \cdot \mathbb{E}X}{\text{Var}(X) + a \cdot \mathbb{E}X}. \quad (6.41)$$

习题 6.42. 设 $0 < a < b < \infty$, 随机变量 X 满足 $\mathbb{P}(X \in [a, b]) = 1$. 求证: 对任意 $m \geq 1$ 如下不等式成立:

$$m \left(\frac{a}{b} \right)^{m-1} \cdot \frac{\text{Var}(X)}{\mathbb{E}X} \leq \frac{\mathbb{E}[X^{m+1}]}{\mathbb{E}[X^m]} - \mathbb{E}X \leq m \left(\frac{b}{a} \right)^{m-1} \cdot \frac{\text{Var}(X)}{\mathbb{E}X}.$$

习题 6.43. 设 $X \sim \left(\begin{smallmatrix} a_1 & \cdots & a_N \\ p_1 & \cdots & p_N \end{smallmatrix} \right)$, $a_i > 0, p_i > 0, i = 1, \dots, N$, 其中 N 有限. 求

$$\text{证: } \lim_{n \rightarrow \infty} \frac{\mathbb{E}[X^{n+1}]}{\mathbb{E}[X^n]} = \max_{1 \leq i \leq N} a_i = \|X\|_\infty.$$

习题 6.44. 证明: $\|X\|_\infty = \liminf_{\varepsilon \downarrow 0} \{M > 0 : \mathbb{P}(|X| > M) \leq \varepsilon\}$.

习题 6.45. 证明: $\|\xi \cdot \eta\|_1 \leq \|\xi\|_1 \cdot \|\eta\|_\infty$.

习题 6.46. 设 a, b, c 是正数, 满足 $a^2 + b^2 + c^2 = 1$. 用概率方法证明:

$$\frac{a^2}{b} + \frac{b^2}{c} + \frac{c^2}{a} > \frac{a^3}{b} + \frac{b^3}{c} + \frac{c^3}{a} \geq 1.$$

习题 6.47. 本习题改编自文献^[7], 拟讨论离散概率模型 (定义参见习题 3.53).

(1) 记 $\Sigma_2 := \{0, 1\}$, 设 $(\Sigma_2, \mathcal{B}_{\Sigma_2}, \mu)$ 是古典概率模型, $(\Omega, \mathcal{F}, \mathbb{P}) := (\Sigma_2, \mathcal{B}_{\Sigma_2}, \mu)^{\mathbb{N}}$ 为乘积空间. 定义 $T: \Omega \rightarrow [0, 1]$ 为

$$T(\omega) := \sum_{n=1}^{\infty} \frac{\omega_n}{2^n}, \quad \text{其中 } \omega = (\omega_1, \omega_2, \dots) \in \Omega.$$

则 T 是 $(\Omega, \mathcal{F}, \mathbb{P})$ 到 $([0, 1], \mathcal{B}_{[0,1]}, \text{Leb})$ 的保测映射. 特别地, 存在 $\mathbb{P}$ -零测集 $A_0 \in \mathcal{F}$ 及 Leb -零测集 $B_0 \subset [0, 1]$ 使得

$$T: \Omega \setminus A_0 \rightarrow [0, 1] \setminus B_0$$

是双射. 从而 $(\Omega, \mathcal{F}, \mathbb{P}) \cong ([0, 1], \mathcal{B}_{[0,1]}, \text{Leb})$;

(2) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是一个概率空间, $\{A_n\}_{n=1}^\infty$ 是一列相互独立的事件。如果

$$\sum_{n=1}^{\infty} \min(\mathbb{P}(A_n), 1 - \mathbb{P}(A_n)) = \infty,$$

则 $(\Omega, \mathcal{F}, \mathbb{P})$ 不可能同构于一个离散概率空间。

习题 6.48. 设 $P_1, \dots, P_{2022}$ 是平面单位圆周上 2022 个不同的点。证明一定可以找到一个圆周上的点 Q , 使得 Q 到 $P_1, \dots, P_{2022}$ 的距离之和大于 2574。

习题 6.49. 请证明下面的朋友悖论 (*Friendship Paradox*): 在一个有限人的封闭社区中, 平均而言, 一个人的朋友数量少于他的朋友的朋友数量。

习题 6.50. 试给出第一章习题 1.11 的解答。

习题 6.51. 陶哲轩 (Terrence Tao) 在其博客中指出, 可以定义概率空间的扩张如下: 设 $\pi: (\tilde{\Omega}, \tilde{\mathcal{F}}, \tilde{\mathbb{P}}) \rightarrow (\Omega, \mathcal{F}, \mathbb{P})$ 是两个概率空间之间的一个满同态 (即 π 是同态且是满射), 则可视 $(\tilde{\Omega}, \tilde{\mathcal{F}}, \tilde{\mathbb{P}})$ 为 $(\Omega, \mathcal{F}, \mathbb{P})$ 的扩张 (更严谨地, 应该称概率空间之间的满同态 π 是概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 的扩张); 借此手段可以逐步通过扩张概率空间纳入更多随机性。设 $(\Omega_k, \mathcal{F}_k, \mathbb{P}_k), k = 1, 2$ 是两个概率空间, 求证: 在陶的观点下, 乘积空间 $(\Omega_1, \mathcal{F}_1, \mathbb{P}_1) \otimes (\Omega_2, \mathcal{F}_2, \mathbb{P}_2)$ 是 $(\Omega_1, \mathcal{F}_1, \mathbb{P}_1)$ 扩张。

习题 6.52. 一个随机变量称为是非平凡的, 如果它是非退化的随机变量, 亦即在几乎处处意义下它不是常数值的随机变量。记 $\Sigma_n := \{0, 1, \dots, n-1\}$, μ_n 是样本空间 Σ_n 上概率测度, 它使得 $(\Sigma_n, 2^{\Sigma_n}, \mu_n)$ 成为一个具有 n 个样本点的古典概率模型, 我们把这个概率空间简记为 (Σ_n, μ_n) 。习题 6.47 的 (1) 及习题 9.7 告诉我们, $(0, 1)$ 配上 Lebesgue 测度就形成了一个足够丰富的概率空间, 它能容纳无穷多相互独立的非平凡随机变量。本题拟探讨 n 个样本点的古典概率模型中能容纳的相互独立的非平凡随机变量的最大个数; 这个量可类比代数学中线性空间的极大线性无关组的元素个数, 因此这是非常有意义的问题。请分别证明下面几个结论:

(1) Σ_n 上任一置换诱导了概率空间 (Σ_n, μ_n) 的自同构;

(2) 对于给定的正整数 $n \geq 2, m \geq 2$, 定义

$$g(x, y) := n \cdot x + y, x \in \Sigma_m, y \in \Sigma_n,$$

则 $g: \Sigma_m \times \Sigma_n \rightarrow \Sigma_{mn}$ 是一个同构 (一一映射), 它给出了下面的概率空间之间的一个同构:

$$(\Sigma_m, \mu_m) \otimes (\Sigma_n, \mu_n) \cong (\Sigma_{mn}, \mu_{mn});$$

- (3) 设 X_k 是概率空间 $(\Omega_k, \mathcal{F}_k, \mathbb{P}_k)$ 上定义的随机变量 (或随机向量), $k = 1, 2$. 则 X_1, X_2 视作乘积概率空间 $(\Omega_1 \times \Omega_2, \mathcal{F}_1 \otimes \mathcal{F}_2, \mathbb{P}_1 \otimes \mathbb{P}_2)$ 上定义的随机变量 (或随机向量) 时, 它们是互相独立的;
- (4) 设 p 是一个素数, 则概率空间 (Σ_p, μ_p) 上找不到两个相互独立的非平凡随机变量;
- (5) 设 X 是概率空间 (Σ_n, μ_n) 上的随机变量 (或随机向量), 它的值域记作 $\mathcal{R}_X$. 记

$$d := \text{g.c.d.} \{|X^{-1}(u)| : u \in \mathcal{R}_X\},$$

其中 $\text{g.c.d.}(A)$ 表示整数子集 A 的最大公约数, 则 $1 \leq d \leq n$ 且 $d|n$, 并且 X 非平凡的充要条件是 $1 \leq d < n$. 进一步, 在概率空间 (Σ_n, μ_n) 上存在与 X 相互独立的非平凡随机变量 Y 的充要条件是: $2 \leq d < n$. 特别地, 当 $2 \leq d < n$ 时, 存在 $\hat{X}$ 定义在概率空间 $(\Sigma_{n/d}, \mu_{n/d})$ 中, 使得 $\hat{X} \stackrel{d}{=} X$ (此时存在一一映射 $\varphi: \Sigma_{n/d} \times \Sigma_d \rightarrow \Sigma_n$ 使得 $\hat{X} = X \circ \varphi$).

基于以上诸条结论, 我们就能证明: 恰有 n 个样本点的古典概率模型中能容纳的相互独立的非平凡随机变量的最大个数就是正整数 n 的乘法因式分解中包含的素因子的总数量 (重数计算在内).

习题 6.53. (两信封悖论, Two-Envelopes Paradox) 本题来源于文献^[31], 我们对其表述略作了改编. 假设你的老板已包了两个信封 (外观完全相同) 的红包作为年终奖选项发给你, 当然你只能选其中一个红包. 已知这两个红包中, 其中一个红包的金额是另一个红包的两倍. 你已随机领取了其中某一个红包, 但还未打开; 这时老板问你: 你是否需要更换红包? 你的选择是换还是不换呢? 一个主张换的逻辑如下: 如果你手里的红包金额为 $F > 0$, 那么另一红包的金额有一半的可能性是 $2F$, 一半的可能性是 $F/2$, 平均而言

$$\frac{1}{2} \cdot (2F) + \frac{1}{2} \cdot (F/2) = \frac{5F}{4} > F.$$

也就是说, 换红包是能增加平均收益的. 但是, 站在另一个红包立场来看, 有完全相同的逻辑与结论, 从而形成悖论, 问题到底出在哪里呢?

第七章 条件数学期望与条件分布律

上一章我们给出了数学期望的定义，并推导出了数学期望的基于分布律的计算公式。在本章我们将进一步介绍条件数学期望这一重要概率论工具，并在此基础上介绍与之紧密联系的条件分布律概念。

条件数学期望是概率论中与数学期望和随机向量的条件分布律等强烈关联的另一套重要工具；它的发展历史与定义流程显得更复杂，但与数学期望的定义的精神相通。数学期望与条件数学期望这两套工具再结合概率论中的独立性概念，衍生出诸多在现代概率论中频繁使用的高级技巧。在本课程中，囿于篇幅及教学体系，我们只能对它们进行初步的介绍。

7.1 条件数学期望的定义

在实际生活中，我们经常遇到如下类似的场景：两家同行业的上市公司，在过往多年他们都公布了相关财务信息。但在当前年度的某个财务季，其中一家公司向公众公布了它的财务状况，另一家公司暂时没有公布；那么如何合理借助已公布的财务状况等信息，来对另一家公司的财务状况做估计？在当前学生成绩作为隐私经常保密的情况下，学生们如何借助一些公开信息结合自己的个人信息合理预测或估算自己及朋友在班级中的排名状况？在商业竞争中，如何利用行业内公开信息以及己方信息，估算竞争对手的（工厂）产能或利润情况等？现代人的生活中，根据已有的一些信息对不确定的量进行估计或预测的需求数不胜数。在一些理想化假设下，现代概率论对此类预测问题给出了一种比较统一的理论解决方案作为参考，这就是“条件数学期望”这一工具；我们将看到它具有二阶误差最小的优良性质。

条件数学期望是概率论中继数学期望工具之后的又一重要工具。正如早期的数学期望概念被 Huygens 创造出来的目的是解决赌博中的“平均收益”或“期望收益”这一自然语言中的概念的数学精确化表达，条件数学期望也有它准备解决的数学问题：假设某种随机试验中有两个测量 X, Y ，根据历史经验

我们知道它们的联合分布律¹: $(X, Y) \sim F$. 现在新做了一次这种实验, 并且获得了测量值 X , 但由于某种原因没有获得测量值 Y , 因此我们关心如何利用联合分布律 F 在已知 X 的取值的条件下给出 Y 的一个“合理”的估计或预测。把 Y 视作随机试验中某人的真实收益, §7.1.1中结论告诉我们, 在仅知道 Y 的分布律信息而没收集任何其他数据的前提下, 对 Y 的合理预测就是它的数学期望, 这也就是自然语言中的“平均收益”或“平均值”。现在, 在知道 (X, Y) 的联合分布律以及 X 的具体取值的条件下, 对 Y 的一个合理预测可以称为 Y 的“平均条件收益”或 Y 的“条件平均值”(在 X, Y 均为离散型随机变量情形时参见 §7.1.2). 因此, 上述问题某种程度上相当于问: 自然语言中的“平均条件收益”或“条件平均值”应当如何给出合理的数学定义? 数学上, 我们使用“条件数学期望”这一概念来代替自然语言中的“条件平均值”². 我们将说明, 条件数学期望是二阶损失最小意义下的一种最佳预测。基于此, 我们最终给出条件数学期望的数学定义³, 并给出一些典型情况的条件数学期望的计算公式。

7.1.1 数学期望的一个性质

给定一个随机变量 ξ , 简单起见, 不妨假设它是非负随机变量。我们可以把 ξ 解释为某赌场(庄家)的一个赌博项目, 参加这个赌博后的赌徒将获得 ξ 金额的“风险收益”, 而 $\mathbb{E}\xi$ 就是赌徒参与这个赌博项目的所谓的期望收益(平均收益); 显然赌徒应当向庄家支付一定的“门票价格”以参加该项赌博。 $\mathbb{E}\xi$ 就是庄家应向参与这个赌博的赌徒收取的(最低的)合理“门票价格”: 以此价格作为门票价格, 长期运营这个赌博项目的话, 庄家是“平均角度”保本的(不考虑其他运营成本), 略高于此的门票价格将会导致长期稳定盈利, 而略低于此的门票价格将会导致亏损, 这些结论读者可以结合后续章节中的 Kolmogorov 强大数律来理解。如果 ξ 具有二阶矩, 那么其他门票价格 $c \neq \mathbb{E}\xi$ 都将导致庄家和赌徒二者都计算在内(视作一个系统)的平均“二阶损失” $\mathbb{E}[(\xi - c)^2]$ 更大(注意, 我们假定赌博是零和博弈, $\xi - c$ 是赌徒的正收益的话, 它就恰好也是庄家的损失; 反之亦然), 即下面的不等式成立

$$\mathbb{E}[(\xi - c)^2] > \mathbb{E}[(\xi - \mathbb{E}\xi)^2] = \text{Var}(\xi), \forall c \neq \mathbb{E}\xi. \quad (7.1)$$

这只要注意到(记 $\mu = \mathbb{E}\xi$)

$$\mathbb{E}[(\xi - c)^2] = \mathbb{E}[(\xi - \mu)^2 + 2(\mu - c)(\xi - \mu) + (\mu - c)^2]$$

¹显然, 这是一个理想化的假设。

²通常用“条件期望收益”来代替自然语言中的“平均条件收益”, 它本质上还是条件数学期望。

³大多数教科书是直接把定义7.1.1作为条件数学期望的定义, 参见文献^[29]等。

$$\begin{aligned}
&= \mathbb{E}[(\xi - \mu)^2] + 2(\mu - c)\mathbb{E}[(\xi - \mu)] + (\mu - c)^2 \\
&= \mathbb{E}[(\xi - \mu)^2] + (\mu - c)^2.
\end{aligned}$$

一般而言, 平均二阶损失过大的赌博通常难以真正长期进行下去: 或者赌徒不乐意参加, 或者庄家不乐意主持这样的赌局; 除非这两方的参与者至少有一方失去了理智。

7.1.2 从经典条件概率到经典条件数学期望

在前述章节中, 我们已经定义了经典的条件概率 (见第三章) 和经典的 (无条件) 数学期望 (见第六章). 以下我们将定义经典情形的条件数学期望, 简称经典条件数学期望。

对于概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 中正概率事件 $A \in \mathcal{F}$, 我们定义过“条件概率空间” $(\Omega_A, \mathcal{F}_A, \mathbb{P}_A)$, 其中 $\Omega_A := A, \mathcal{F}_A := A \cap \mathcal{F}$, 而 $\mathbb{P}_A(\cdot) = \mathbb{P}(\cdot|A)$ 如下给出:

$$\mathbb{P}_A(B) := \frac{\mathbb{P}(B)}{\mathbb{P}(A)}, \quad B \in \mathcal{F}_A.$$

依据我们定义数学期望的原则, 自然可以在“条件概率空间” $(\Omega_A, \mathcal{F}_A, \mathbb{P}_A)$ 中定义相应的数学期望 $\mathbb{E}_A$, 我们改记号为 $\mathbb{E}[\cdot|A]$, 即

$$\mathbb{E}_A[\xi] = \mathbb{E}[\xi|A].$$

注意到 $\xi = 1_B, B \in \mathcal{F}$ 时, ξ 仍然可视为“条件概率空间” $(\Omega_A, \mathcal{F}_A, \mathbb{P}_A)$ 上随机变量 (等同于 $\xi|_A = \xi \cdot 1_A$), 应有

$$\mathbb{E}_A[1_B] = \mathbb{E}_A[1_B \cdot 1_A] = \mathbb{P}_A(A \cap B) = \mathbb{E}[1_A \cdot 1_B]/\mathbb{P}(A).$$

也就是说我们有下面的经典条件数学期望的出发点:

$$\mathbb{E}[1_B|A] := \mathbb{E}[1_A \cdot 1_B]/\mathbb{P}(A), \quad \forall B \in \mathcal{F}. \quad (7.2)$$

按照数学期望的定义流程 (或依据附录A中介绍的单调类定理), 很容易知道下面计算公式成立:

$$\mathbb{E}[\xi|A] = \frac{\mathbb{E}[1_A \cdot \xi]}{\mathbb{P}(A)}. \quad (7.3)$$

我们称上式中的 $\mathbb{E}[\xi|A]$ 为经典条件数学期望。注意, 这里要求 $\mathbb{P}(A) > 0$!

至此, 我们自然可以考虑一个 (可积) 随机变量 X 关于另一个离散型随机变量 Y 的经典条件数学期望 $\mathbb{E}[X|Y]$, 它被定义为: 当 $Y = y$ 发生时, 就取值为 $\mathbb{E}[X|Y = y]$, 即

$$\mathbb{E}[X|Y] = \mathbb{E}[X|Y = y], \quad \text{如果 } Y = y.$$

上面表达中同样有记号上的偷懒, 即把事件 $A = \{Y = y\}$ 表达式外面的花括号省略不写了。总之, 在 Y 都是离散随机变量 (且 X 具有可积性) 的情形下, 条件数学期望 $\mathbb{E}[X|Y]$ 被合理地定义为一个新的随机变量 $\varphi_*(Y)$ 了, 其中函数

$$\varphi_*(y) := \mathbb{E}[X|Y = y]$$

是自然语言中在 $Y = y$ 的条件下 X 的“条件平均值”; 此处, y 是 Y 的原子。

在 X, Y 均为离散型随机变量这一更特殊的情形下, 我们设 X, Y 的值域分别为 $\mathcal{R}_X, \mathcal{R}_Y$, 它们都是可数集。对任意给定的 $x \in \mathcal{R}_X, y \in \mathcal{R}_Y$, 记

$$\begin{aligned} p_{x,y} &:= \mathbb{P}(X = x, Y = y), \\ p_{x,\bullet} &:= \mathbb{P}(X = x) = \sum_{y \in \mathcal{R}_Y} p_{x,y}, \\ p_{\bullet,y} &:= \mathbb{P}(Y = y) = \sum_{x \in \mathcal{R}_X} p_{x,y}. \end{aligned}$$

于是 $\mathbb{P}(X = x|Y = y) = \frac{p_{x,y}}{p_{\bullet,y}}, \forall x \in \mathcal{R}_X, y \in \mathcal{R}_Y$. 当 $\mathbb{E}X$ 存在时, 不难知道

$$\varphi_*(y) := \mathbb{E}[X|Y = y] = \sum_{x \in \mathcal{R}_X} x \cdot \frac{p_{x,y}}{p_{\bullet,y}}, \quad \forall y \in \mathcal{R}_Y.$$

基于上述表示, 当讨论的数学期望有意义时, 我们推导条件数学期望的两个重要性质如下。

计算

$$\begin{aligned} \mathbb{E}[\mathbb{E}[X|Y]] &= \mathbb{E}[\varphi_*(Y)] = \sum_{y \in \mathcal{R}_Y} \varphi_*(y) \cdot p_{\bullet,y} \\ &= \sum_{y \in \mathcal{R}_Y} \sum_{x \in \mathcal{R}_X} x \cdot \frac{p_{x,y}}{p_{\bullet,y}} \cdot p_{\bullet,y} \\ &= \sum_{y \in \mathcal{R}_Y} \sum_{x \in \mathcal{R}_X} x \cdot p_{x,y} = \sum_{x \in \mathcal{R}_X} x \cdot \sum_{y \in \mathcal{R}_Y} p_{x,y} \\ &= \sum_{x \in \mathcal{R}_X} x \cdot p_{x,\bullet} = \mathbb{E}X. \end{aligned}$$

因此我们得到条件数学期望的第一个重要性质——**全期望公式**:

$$\mathbb{E}[X] = \mathbb{E}[\mathbb{E}[X|Y]]. \quad (7.4)$$

它是全概率公式的期望版本, 有些文献仍然称之为全概率公式。

根据不等式(7.1), 对任意可测函数 ψ 及任意固定的 $y \in \mathcal{R}_Y$, 我们有

$$\mathbb{E}[(X - \psi(y))^2|Y = y] \geq \mathbb{E}[(X - \varphi_*(y))^2|Y = y] = \mathbb{E}[(X - \varphi_*(Y))^2|Y = y],$$

进而

$$\begin{aligned}
 \mathbb{E}[(X - \psi(Y))^2] &= \mathbb{E}[\mathbb{E}[(X - \psi(Y))^2|Y]] \\
 &= \sum_{y \in \mathcal{R}_Y} \mathbb{E}[(X - \psi(Y))^2|Y = y] \cdot p_{\bullet, y} \\
 &= \sum_{y \in \mathcal{R}_Y} \mathbb{E}[(X - \psi(y))^2|Y = y] \cdot p_{\bullet, y} \\
 &\geq \sum_{y \in \mathcal{R}_Y} \mathbb{E}[(X - \varphi_*(Y))^2|Y = y] \cdot p_{\bullet, y} \\
 &= \mathbb{E}[\mathbb{E}[(X - \varphi_*(Y))^2|Y]] = \mathbb{E}[(X - \varphi_*(Y))^2].
 \end{aligned}$$

于是我们得到数学期望的性质(7.1)的推广:

$$\mathbb{E}[(X - \psi(Y))^2] \geq \mathbb{E}[(X - \mathbb{E}[X|Y])^2], \forall \psi \text{ 为可测函数}. \quad (7.5)$$

上面方程表明, 在所有形如 $\psi(Y)$ 的预测中, $\varphi_*(Y) = \mathbb{E}[X|Y]$ 是平均二阶损失最小的对 X 的预测。

对于同一个概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上任何两个有二阶矩的 (实值) 随机变量 ξ, η , 我们可以定义 “内积”

$$\langle \xi, \eta \rangle := \mathbb{E}[\xi\eta], \quad (7.6)$$

由此诱导了范数 $\|\eta\|_2 := \sqrt{\langle \eta, \eta \rangle}$. 给定随机变量 Y , 我们可以定义它诱导的一个 (实) Hilbert 空间 $\mathcal{H}_Y$

$$\mathcal{H}_Y := \{\psi(Y) : \psi \text{ 是可测函数, 且 } \mathbb{E}[\psi(Y)^2] < \infty\}.$$

当 $\mathbb{E}[X^2] < \infty$ 且 X, Y 都是离散型随机变量时, (7.5) 表明了两点:

- 1) $\mathbb{E}[X|Y] \in \mathcal{H}_Y$;
- 2) $\|X - Z\|_2 \geq \|X - \mathbb{E}[X|Y]\|_2, \forall Z \in \mathcal{H}_Y$.

这说明, 条件数学期望 $\mathbb{E}[X|Y]$ 可以视作 X 向 $\mathcal{H}_Y$ 的正交投影:

$$\mathbb{E}[X|Y] = \text{Proj}_{\mathcal{H}_Y}(X). \quad (7.7)$$

7.1.3 抽象的条件数学期望的定义

以上我们已经在具有二阶矩的离散随机变量情形导出了条件数学期望 $\mathbb{E}[X|Y]$ 的一种合理定义: 正交投影, 见(7.7). 我们可以把这个定义作为一般的具有二阶矩的随机变量 X 关于另一个随机变量 Y 的条件数学期望的定义。

以下我们准备进一步拓广这个定义：一方面对“条件数学期望” $\mathbb{E}[X|Y]$ 中所加的“条件” Y 拓广，另一方面降低对 X 的可积性的要求。

现在我们给定 $X \in L^2(\Omega, \mathcal{F}, \mathbb{P})$ ，其含义就是： X 是概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上有二阶矩的随机变量。再给定一个子 σ -代数 $\mathcal{G} \subset \mathcal{F}$ ，于是我们同样有概率空间 $(\Omega, \mathcal{G}, \mathbb{P}|_{\mathcal{G}})$ ，进而也有一个 Hilbert 空间

$$\mathcal{H}_{\mathcal{G}} := L^2(\Omega, \mathcal{G}, \mathbb{P}|_{\mathcal{G}}).$$

此处，请读者自证：当 Y 是随机变量时， $\mathcal{H}_{\sigma(Y)} = \mathcal{H}_Y$ 。于是我们仿照上一节，对 $X \in L^2(\Omega, \mathcal{F}, \mathbb{P})$ ，定义

$$\mathbb{E}[X|\mathcal{G}] := \text{Proj}_{\mathcal{H}_{\mathcal{G}}}(X). \quad (7.8)$$

它具有如下优良性质：

$$\mathbb{E}[(X - \xi)^2] \geq \mathbb{E}[(X - \mathbb{E}[X|\mathcal{G}])^2], \forall \xi \in \mathcal{H}_{\mathcal{G}}, \quad (7.9)$$

即 $\mathbb{E}[X|\mathcal{G}]$ 是 $\mathcal{H}_{\mathcal{G}}$ 中对 X 的最优预测。

上述定义已经比较宽泛了，但它对 X 还要求有二阶矩；我们准备进一步把这个条件降低至一阶矩。为此，进一步来分析上述方程(7.8). 它实际上要求：

- (1) $\xi := \mathbb{E}[X|\mathcal{G}]$ 被定义为一个特殊的随机变量 $\xi \in \mathcal{H}_{\mathcal{G}}$ ，即它是 $\mathcal{G}$ -可测的随机变量，并且二阶矩存在；
- (2) ξ 进一步满足：对任意 $\eta \in \mathcal{H}_{\mathcal{G}}$ ， $\mathbb{E}[(X - \xi)\eta] = 0$ ，亦即

$$\mathbb{E}[X \cdot \eta] = \mathbb{E}[\xi \cdot \eta], \forall \eta \in \mathcal{H}_{\mathcal{G}}.$$

注意到 $\mathcal{H}_{\mathcal{G}}$ 可以视作 $\text{span}\{1_B : B \in \mathcal{G}\}$ 的闭包，我们最终可以给出下面版本的条件数学期望的定义。

定义 7.1.1. 给定子 σ -代数 $\mathcal{G} \subset \mathcal{F}$ ，当 X 的数学期望存在时， X 关于 $\mathcal{G}$ 的条件数学期望被定义为具有如下性质的一个随机变量 ξ ：

- (1) ξ 是 $\mathcal{G}$ -可测的随机变量；
- (2) ξ 进一步满足：

$$\mathbb{E}[X \cdot 1_B] = \mathbb{E}[\xi \cdot 1_B], \forall B \in \mathcal{G}. \quad (7.10)$$

具有上述性质的随机变量 ξ 是存在的，并且它在 $\mathbb{P}$ -几乎处处相等的意义下唯一，我们把它记作 $\mathbb{E}[X|\mathcal{G}]$ 。

在上面定义中, 我们断言具有性质 (1)、(2) 的随机变量 ξ 是存在唯一的, 这可以用第四章中 R-N 导数的理论来解释. 我们定义符号测度 $\mu: \mathcal{G} \rightarrow \bar{\mathbb{R}}$ 如下

$$\mu(B) := \mathbb{E}[X \cdot 1_B], \quad B \in \mathcal{G}.$$

显然此时有 $\mathbb{P}(B) = 0$ 蕴含了 $\mu(B) = 0$. 因而 $\mu \ll \mathbb{P}|_{\mathcal{G}}$. 于是存在 ρ 为 $\mathcal{G}$ -可测函数, 使得 $\rho = \frac{d\mu}{d\mathbb{P}|_{\mathcal{G}}}$, 即

$$\mu(B) = \int_B \rho d\mathbb{P}|_{\mathcal{G}}, \quad \forall B \in \mathcal{G}.$$

上式 (其中 $\rho =: \xi$) 改用数学期望表达就是 (7.10).

如果 Y 是随机变量或随机向量, 我们介绍过 Y 生成的 σ -代数 $\sigma(Y)$ 的概念. 我们可以定义随机变量 X 关于 $\mathcal{G} = \sigma(Y)$ 的**条件数学期望**, 把它简单记作 $\mathbb{E}[X|Y]$, 即有如下符号上的认同:

$$\mathbb{E}[X|Y] := \mathbb{E}[X|\sigma(Y)]. \quad (7.11)$$

下面的定理 7.1.1 说明了: 条件数学期望 $\mathbb{E}[X|\sigma(Y)]$ 如果存在, 它就可以表达为 Y 的某个可测函数 $\mathbb{E}[X|\sigma(Y)] = \varphi_*(Y)$, 此时概率论中对于函数 $\varphi_*(\cdot)$ 的一个偷懒的写法是: $\mathbb{E}[X|Y = y]$, 亦即此处有如下认同:

$$\varphi_*(y) := \mathbb{E}[X|Y = y], \text{ 则 } \mathbb{E}[X|Y] = \varphi_*(Y). \quad (7.12)$$

上述函数 φ_* 可以按如下方式求解:

$$\mathbb{E}[\varphi_*(Y) \cdot 1_A(Y)] = \mathbb{E}[X \cdot 1_A(Y)], \quad \forall A \text{ 为可测集},$$

从而它也等价于

$$\int_A \varphi_*(y) d\mu_Y(y) = \int x \cdot 1_A(y) d\mu_{X,Y}(x, y), \quad \forall A \text{ 为可测集},$$

其中 μ_Y 是 Y 的分布测度, $\mu_{X,Y}$ 是 (X, Y) 的分布测度. 由此, 可测函数 φ_* 是在 μ_Y -几乎处处相等意义下唯一确定的. 上述这种认同与记号上的偷懒, 在理解和计算条件数学期望等量的过程中经常需要用到, 读者需要在学习的过程中逐渐做到熟练掌握.

♠ 定理 7.1.1.¹ 设 $(\Omega_k, \mathcal{F}_k), k = 1, 2$ 是可测空间, $f: \Omega_1 \rightarrow \Omega_2$ 是可测映射. f 生成的 σ -代数 $\sigma(f)$ 理解为 $\sigma(f) = f^{-1}(\mathcal{F}_2) \subset \mathcal{F}_1$. 给定广义实值函数 $g: \Omega_1 \rightarrow \bar{\mathbb{R}}$. 那么 g 是 $\sigma(f)/\mathcal{B}(\bar{\mathbb{R}})$ 可测的, 当且仅当存在可测函数 $\varphi: (\Omega_2, \mathcal{F}_2) \rightarrow (\bar{\mathbb{R}}, \mathcal{B}(\bar{\mathbb{R}}))$ 使得 $g = \varphi \circ f$.

¹ 参见文献^[60]第 41 页的 Corollary 1.97.

下面的交换图解释了上述定理的结论。

$$\begin{array}{ccc} (\Omega_1, \mathcal{F}_1) & \xrightarrow{f} & (\Omega_2, \mathcal{F}_2) \\ & \searrow g & \downarrow \varphi \\ & & (\bar{\mathbb{R}}, \bar{\mathcal{B}}) \end{array}$$

为了证明上述结论, 需要下面的引理。

◆ **引理 7.1.1.**¹ 设 $(\Omega, \mathcal{F})$ 是可测空间, $f: \Omega \rightarrow [0, \infty]$ 是广义非负可测函数。那么以下结论成立:

- (i) 存在非负简单函数列 $\{f_n\}_1^\infty$, 使得 $f_n \nearrow f$;
- (ii) 存在可测集列 $\{A_n\}_1^\infty \subset \mathcal{F}$ 以及非负实数列 $\{\alpha_n \geq 0\}_1^\infty$ 使得

$$f = \sum_{n=1}^{\infty} \alpha_n \cdot 1_{A_n}.$$

证明: 定义 $f_n := \frac{\lfloor 2^n \cdot f \rfloor}{2^n} \wedge n$, 其中 $\lfloor \cdot \rfloor$ 表示取整函数。显然 f_n 可测, 并且最多取 $n \cdot 2^n + 1$ 个不同的非负值, 因此是非负简单函数。显然 $f_n \nearrow f$. 此即 (i).

对于上述 f_n , 有 $f = f_1 + \sum_{n=1}^{\infty} (f_{n+1} - f_n)$. 显然 $\{f_{n+1} - f_n\}_{n=0}^\infty$ 也是非负简单函数列 (约定 $f_0 := 0$). 由此知道引理结论 (ii) 成立。□

定理 7.1.1 的证明: 定理的充分性是显然的, 下面证明必要性。

我们先对非负函数 $g \geq 0$ 给出证明。此时, 由上述引理, 存在可测集列 $\{A_n\}_{n=1}^\infty \subset \sigma(f)$ 及非负实数列 $\{\alpha_n\}_{n=1}^\infty$ 使得

$$g = \sum_{n=1}^{\infty} \alpha_n 1_{A_n}.$$

注意到 $A_n \in \sigma(f)$, 存在 $B_n \in \mathcal{F}_2$ 使得 $A_n = f^{-1}(B_n)$, 亦即 $1_{A_n} = 1_{B_n} \circ f$. 于是可以定义广义非负可测函数

$$\varphi := \sum_{n=1}^{\infty} \alpha_n 1_{B_n},$$

它满足 $g = \varphi \circ f$.

对于一般情形, g 是 $\sigma(f)/\mathcal{B}(\bar{\mathbb{R}})$ 可测的, 因此 $g^+ := g \vee 0, g^- := (-g) \vee 0$ 也是 $\sigma(f)/\mathcal{B}(\bar{\mathbb{R}})$ 可测的。于是存在

$$\varphi^{(\pm)} = \sum_{n=1}^{\infty} \alpha_n^{(\pm)} \cdot 1_{B_n^{\pm}}$$

¹ 参见文献^[60]第 41 页 Theorem 1.96.

使得 $g^\pm = \varphi^{(\pm)} \circ f$. 令 $B := \{\omega_2 : \varphi^{(+)}(\omega_2) = \varphi^{(-)}(\omega_2) = \infty\} \in \mathcal{F}_2$, 显然应有 $f^{-1}(B) = \emptyset, f(\Omega_1) \subset B^c$ (否则与 $g = g^+ - g^-$ 有定义相矛盾). 从而总可以定义 $\varphi(\omega_2) := 1_{B^c}(\omega_2) \cdot [\varphi^{(+)}(\omega_2) - \varphi^{(-)}(\omega_2)]$. 此时显然有 $g = \varphi \circ f$. $\square$

7.1.4 从条件数学期望 $\mathbb{E}[\cdot|\mathcal{G}]$ 到条件概率 $\mathbb{P}(\cdot|\mathcal{G})$

以上我们定义了抽象的条件数学期望 $\mathbb{E}[\cdot|\mathcal{G}]$; 在当初数学期望的定义过程中, 我们有下面的对应关系

$$\mathbb{E}1_B = \mathbb{P}(B), \forall B \in \mathcal{F}.$$

现在我们可以模仿这个关系来定义抽象的条件概率 $\mathbb{P}(\cdot|\mathcal{G})$, 即

$$\mathbb{P}(B|\mathcal{G}) := \mathbb{E}[1_B|\mathcal{G}], \forall B \in \mathcal{F}. \quad (7.13)$$

这里需要注意, 与经典的条件概率 $\mathbb{P}(B|A)$ 是 $[0, 1]$ 中的一个数值不同, $\mathbb{P}(B|\mathcal{G})$ 本质上是一个随机变量! 虽然有这个差别, 但是下面例子揭示了二者间的联系, 说明抽象定义的条件概率是经典条件概率这一概念的自然推广。

例 7.1. 设 $A \neq \emptyset, \mathcal{G} = \{\emptyset, A, A^c, \Omega\}$, 它是包含事件 A 的最小 σ -代数。我们假定 $0 < \mathbb{P}(A) < 1$. 则容易计算出

$$\begin{aligned} \mathbb{P}(B|\mathcal{G})(\omega) &= \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)} \cdot 1_A(\omega) + \frac{\mathbb{P}(A^c \cap B)}{\mathbb{P}(A^c)} \cdot 1_{A^c}(\omega) \\ &= \mathbb{P}(B|A) \cdot 1_A(\omega) + \mathbb{P}(B|A^c) \cdot 1_{A^c}(\omega). \end{aligned}$$

最后一个等式中出现的条件概率 $\mathbb{P}(B|A), \mathbb{P}(B|A^c)$ 是经典的条件概率; 并且当 A 发生时, 亦即 $\omega \in A$ 时, $\mathbb{P}(B|\mathcal{G})(\omega) = \mathbb{P}(B|A)$. 这表明, 本节中抽象的条件概率的定义与第三章中的经典条件概率定义是相容的。

在有了条件数学期望、条件概率的定义后, 之前的独立性也可以有如下的等价刻画: 任给两事件域 (σ -代数) $\mathcal{G}_1, \mathcal{G}_2 \subset \mathcal{F}$,

$$\mathcal{G}_1, \mathcal{G}_2 \text{ 相互独立} \Leftrightarrow \left(\mathbb{P}(A_2|\mathcal{G}_1) = \mathbb{P}(A_2) \quad \mathbb{P} - a.e., \quad \forall A_2 \in \mathcal{G}_2 \right). \quad (7.14)$$

请读者自己验证该命题, 它是之前经典情形结果(3.10)的推广。在编者看来, 这相当于说: 在现实生活中, 我们基于完全无关的信息所做理性判断, 与没有得到这些信息时所作理性判断应该毫无区别¹。

¹但现实生活中的难点在于界定所获得信息与所要考察事件的关联性。在统计学中有一个与此相关的新兴研究领域: 因果推断。

7.2 条件数学期望的基本性质与常见不等式

为了减少在数学期望和条件数学期望的计算或估算过程中的计算量, 本节我们基于条件数学期望的定义来讨论条件数学期望的性质与常见不等式。

以下总假设 ξ, η 是随机变量, $\mathcal{G}, \mathcal{G}_1$ 是概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 中的子 σ -代数。

7.2.1 条件数学期望的基本性质

在本小节, 我们先罗列条件数学期望如下一些性质, 证明之后给出:

(CE0) 设 $\mathbb{E}|\eta| < \infty$, 则 $\mathbb{E}[\eta|\mathcal{G}]$ 是 $\mathcal{G}$ -可测随机变量, 且全期望公式成立:

$$\mathbb{E}\eta = \mathbb{E}[\mathbb{E}[\eta|\mathcal{G}]];$$

(CE1) (线性性质) 设 $a, b \in \mathbb{R}$ 且 $\mathbb{E}\xi, \mathbb{E}\eta, a\mathbb{E}\xi + b\mathbb{E}\eta$ 均有意义, 则

$$\mathbb{E}[a\xi + b\eta|\mathcal{G}] = a\mathbb{E}[\xi|\mathcal{G}] + b\mathbb{E}[\eta|\mathcal{G}];$$

(CE2) (正算子/单调性) 如果 $\xi \geq 0$ a.s., 那么 $\mathbb{E}[\xi|\mathcal{G}] \geq 0$ a.s.. 更一般地, 设 $\mathbb{E}|\xi| < \infty, \mathbb{E}|\eta| < \infty$, 且 $\xi \leq \eta$ a.s., 则 $\mathbb{E}[\xi|\mathcal{G}] \leq \mathbb{E}[\eta|\mathcal{G}]$ a.s.. 特别地, $|\mathbb{E}[\xi|\mathcal{G}]| \leq \mathbb{E}[|\xi||\mathcal{G}]$ a.s.;

(CE3) ($\mathcal{G}$ -可测线性) 设 $\mathbb{E}|\eta| < \infty$, 则对任意 $A \in \mathcal{G}$, 有

$$\mathbb{E}[1_A \cdot \eta|\mathcal{G}](\omega) = 1_A(\omega) \cdot \mathbb{E}[\eta|\mathcal{G}](\omega) \text{ a.s..}$$

更一般地, 设 ξ 为 $\mathcal{G}$ -可测随机变量, 那么

$$\mathbb{E}[\xi \cdot \eta|\mathcal{G}](\omega) = \xi(\omega) \cdot \mathbb{E}[\eta|\mathcal{G}](\omega) \text{ a.s. ;}$$

(CE4) 对任意常数 $a \in \mathbb{R}$, $\mathbb{E}[a|\mathcal{G}] = a$ a.s.; 进而如果 ξ 是 $\mathcal{G}$ -可测的, 那么 $\mathbb{E}[\xi|\mathcal{G}] = \xi$;

(CE5) 设 $\mathbb{E}|\xi| < \infty$. 又设 $\mathcal{G} \subset \mathcal{G}_1 \subset \mathcal{F}$ 均为 σ -代数, 则

$$\mathbb{E}[\mathbb{E}[\xi|\mathcal{G}_1]|\mathcal{G}] = \mathbb{E}[\xi|\mathcal{G}] \text{ a.s.,}$$

$$\mathbb{E}[\mathbb{E}[\xi|\mathcal{G}]|\mathcal{G}_1] = \mathbb{E}[\xi|\mathcal{G}] \text{ a.s. ;}$$

(CE6) 设 $\mathbb{E}|\eta| < \infty$. 如果 η 与 $\mathcal{G}$ 独立 (其定义为: η 生成的 σ -代数与 $\mathcal{G}$ 独立; 或者等价的, 任给 $A \in \mathcal{G}$, η 与 A 独立, 即 $\mathbb{P}(\{\eta \leq x\} \cap A) = \mathbb{P}(\eta \leq x) \cdot \mathbb{P}(A), \forall x \in \mathbb{R}, A \in \mathcal{G}$), 那么

$$\mathbb{E}[\eta|\mathcal{G}] = \mathbb{E}\eta \text{ a.s. ;}$$

上面性质中, 性质 (CE4)、(CE5) 的证明留给读者。以下给出其他几个性质的证明。

性质 (CE0) 的证明: 对于给定概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$, 给定的子 σ -代数 $\mathcal{G} \subset \mathcal{F}$ 以及随机变量 $\eta \in L^1(\Omega, \mathcal{F}, \mathbb{P})$, 由于 $\tilde{\eta} := \mathbb{E}[\eta|\mathcal{G}]$ 被定义为满足下面方程组的 $\mathcal{G}$ -可测随机变量

$$\mathbb{E}[\eta \cdot 1_B] = \mathbb{E}[\tilde{\eta} \cdot 1_B], \forall B \in \mathcal{G}, \quad (7.15)$$

因此取 $B = \Omega$ 就得到了全期望公式: $\mathbb{E}[\eta] = \mathbb{E}[\mathbb{E}[\eta|\mathcal{G}]]$. $\square$

性质 (CE1) 的证明: 由定义 7.1.1, 特别是方程 (7.10), 很容易看到: 条件数学期望算子的线性性质来自于无条件数学期望算子的线性性质。 $\square$

性质 (CE2) 的证明: 注意到 $\mathbb{E}$ 是正算子, 易知 $\xi \geq 0$ 几乎处处成立时必定有 $\tilde{\xi} := \mathbb{E}[\xi|\mathcal{G}]$ 满足:

$$\mathbb{E}[\tilde{\xi} \cdot 1_B] = \mathbb{E}[\xi \cdot 1_B] \geq 0, \forall B \in \mathcal{G}.$$

取 $B := \{\tilde{\xi} < 0\}$, 显然有 $B \in \mathcal{G}$; 如果 $\mathbb{P}(B) > 0$, 那么 $\mathbb{E}[\tilde{\xi} \cdot 1_B] = -\mathbb{E}[|\tilde{\xi}| \cdot 1_B] < 0$, 矛盾。因此 $\mathbb{P}(B) = 0$, 即 $\tilde{\xi} \geq 0$ 几乎处处成立, 进而 $\mathbb{E}[\cdot|\mathcal{G}]$ 是正算子, 即它具有单调性。

由 $\mathbb{E}[\cdot|\mathcal{G}]$ 的线性性质, 注意到 $\pm\xi \leq |\xi|$, 我们有 $\pm\tilde{\xi} := \mathbb{E}[\pm\xi|\mathcal{G}] \leq \mathbb{E}[|\xi|\mathcal{G}]$ 几乎处处成立。此即

$$|\mathbb{E}[\xi|\mathcal{G}]| \leq \mathbb{E}[|\xi|\mathcal{G}].$$

当 $\xi \in L^1(\Omega, \mathcal{F}, \mathbb{P})$ 时, 上式结合全概率公式立即得到

$$\|\mathbb{E}[\xi|\mathcal{G}]\|_1 \leq \|\xi\|_1.$$

由此, 可以把 $\mathbb{E}[\cdot|\mathcal{G}]$ 视作算子:

$$\mathbb{E}[\cdot|\mathcal{G}] : L^1(\Omega, \mathcal{F}, \mathbb{P}) \rightarrow L^1(\Omega, \mathcal{G}, \mathbb{P}),$$

它是正算子、线性算子。 $\square$

性质 (CE3) 的证明: 事实上, 由定义容易证明: 对任意 $A \in \mathcal{G}, \eta \in L^1(\Omega, \mathcal{F}, \mathbb{P})$, $\mathbb{E}[1_A \cdot \eta|\mathcal{G}] = 1_A \cdot \mathbb{E}[\eta|\mathcal{G}]$, 亦即对任意 $B \in \mathcal{G}$

$$\mathbb{E}[(1_A \cdot \eta) \cdot 1_B] = \mathbb{E}[(1_A \cdot \mathbb{E}[\eta|\mathcal{G}]) \cdot 1_B].$$

由于 A 的任意性, 立即根据数学期望的定义流程 (或单调类定理) 得到

$$\mathbb{E}[(\xi \cdot \eta) \cdot 1_B] = \mathbb{E}[(\xi \cdot \mathbb{E}[\eta|\mathcal{G}]) \cdot 1_B]$$

对任意 $\mathcal{G}$ -可测随机变量 ξ 成立, 只要它使得 $\xi \cdot \eta \in L^1(\Omega, \mathcal{F}, \mathbb{P})$ 仍然成立。对上式, 进一步由 $B \in \mathcal{G}$ 的任意性及条件数学期望的定义 (注意到此时 $\xi \cdot \mathbb{E}[\eta|\mathcal{G}]$ 是 $\mathcal{G}$ -可测随机变量), 有

$$\mathbb{E}[(\xi \cdot \eta)|\mathcal{G}] = \xi \cdot \mathbb{E}[\eta|\mathcal{G}].$$

因此 $\mathbb{E}[\cdot|\mathcal{G}]$ 是 $\mathcal{G}$ -线性算子。 $\square$

性质 (CE6) 的证明: 此处我们要证明: 当 η 与 $\mathcal{G}$ 相互独立且 η 可积时,

$$\mathbb{E}[\eta|\mathcal{G}] \stackrel{\text{a.s.}}{=} \mathbb{E}\eta.$$

这只要注意到 η 与 $\mathcal{G}$ 的充要条件是: 对任意 Borel 可测集 A 及可测集 $B \in \mathcal{G}$

$$\mathbb{P}(\{\eta \in A\} \cap B) = \mathbb{P}(\eta \in A) \cdot \mathbb{P}(B).$$

把上式写成数学期望形式, 即 $\mathbb{E}[1_A(\eta) \cdot 1_B] = \mathbb{E}[1_A(\eta)] \cdot \mathbb{E}[1_B]$. 注意到 A 的任意性, 我们有

$$\mathbb{E}[\varphi(\eta) \cdot 1_B] = \mathbb{E}[\varphi(\eta)] \cdot \mathbb{E}[1_B], \quad \forall B \in \mathcal{G},$$

其中 φ 是使 $\varphi(\eta)$ 可积的可测函数。由条件数学期望定义, 立即得到

$$\mathbb{E}[\varphi(\eta)|\mathcal{G}] \stackrel{\text{a.s.}}{=} \mathbb{E}[\varphi(\eta)].$$

特取 $\varphi(x) = x$ 即得 $\mathbb{E}[\eta|\mathcal{G}] \stackrel{\text{a.s.}}{=} \mathbb{E}\eta$. $\square$

7.2.2 条件数学期望的常见不等式

类似上一章节的处理, 我们此处罗列条件数学期望的常见不等式如下:

(CE7) 条件 Jensen 不等式: 设 g 为 $\mathbb{R}$ 上连续凸函数, $\mathbb{E}[\xi|\mathcal{G}], \mathbb{E}[g(\xi)|\mathcal{G}]$ 有定义。那么

$$g(\mathbb{E}[\xi|\mathcal{G}]) \leq \mathbb{E}[g(\xi)|\mathcal{G}] \text{ a.s.};$$

(CE8) 条件 Hölder 不等式: 设 $\frac{1}{p} + \frac{1}{q} = 1, p, q > 1$. 那么

$$\mathbb{E}[|\xi\eta||\mathcal{G}] \leq (\mathbb{E}[|\xi|^p|\mathcal{G}])^{1/p} \cdot (\mathbb{E}[|\eta|^q|\mathcal{G}])^{1/q} \text{ a.s.};$$

(CE9) 条件矩不等式: 设 $0 < s < t$. 那么

$$(\mathbb{E}[|\xi|^s|\mathcal{G}])^{1/s} \leq (\mathbb{E}[|\xi|^t|\mathcal{G}])^{1/t} \text{ a.s.};$$

(CE10) 条件 Minkowski 不等式: 设 $p > 0$.

- (i) $p \geq 1$ 时, $(\mathbb{E}[|\xi + \eta|^p | \mathcal{G}])^{1/p} \leq (\mathbb{E}[|\xi|^p | \mathcal{G}])^{1/p} + (\mathbb{E}[|\eta|^p | \mathcal{G}])^{1/p}$ a.s.;
- (ii) $0 < p < 1$ 时, $\mathbb{E}[|\xi + \eta|^p | \mathcal{G}] \leq \mathbb{E}[|\xi|^p | \mathcal{G}] + \mathbb{E}[|\eta|^p | \mathcal{G}]$ a.s..

条件 Jensen 不等式的证明: 简单起见, 设 g 是 $\mathbb{R}$ 上连续的凸函数, 设 ξ 可积且 $g(\xi)$ 可积. 我们证明

$$g(\mathbb{E}[\xi | \mathcal{G}]) \leq \mathbb{E}[g(\xi) | \mathcal{G}] \text{ a.s..}$$

利用凸函数的等价刻画, 对 $\tilde{\xi} := \mathbb{E}[\xi | \mathcal{G}]$ 存在 $\alpha(\tilde{\xi})$ (其中 $\alpha(\cdot)$ 可测), 使得

$$g(x) \geq g(\tilde{\xi}) + \alpha(\tilde{\xi}) \cdot (x - \tilde{\xi}), \forall x.$$

取 $x = \xi$ 代入上式, 并取条件数学期望, 根据条件数学期望的单调性、 $\mathcal{G}$ -线性性质以及 $\mathbb{E}[\xi - \tilde{\xi} | \mathcal{G}] = 0$, 立即得到 $\mathbb{E}[g(\xi) | \mathcal{G}] \geq g(\tilde{\xi})$, 从而完成条件 Jensen 不等式的证明. $\square$

其他一些不等式的证明, 如条件 Hölder 不等式、条件矩不等式、条件 Minkowski 不等式就留作习题。

7.3 条件数学期望的计算

对于抽象条件数学期望 $\mathbb{E}[X | \mathcal{G}]$ 的计算, 当不知道更多关于 $X, \mathcal{G}$ 的信息时, 我们也没有太多办法, 只能是按照定义去计算。也就是说, 此时我们只能去求解满足下面方程 (组) 的 $\mathcal{G}$ -可测随机变量 ξ :

$$\mathbb{E}[X \cdot 1_B] = \mathbb{E}[\xi \cdot 1_B], \quad \forall B \in \mathcal{G}. \quad (7.16)$$

当有更多 $X, \mathcal{G}$ 的信息时, 我们就有其他计算方法。这里, 我们将介绍随机变量的条件分布律的概念, 并将基于条件分布律给出条件数学期望的计算公式。

7.3.1 条件数学期望的积分变换公式

在讨论数学期望的计算时, 那里有所谓的积分变换公式, 当初我们利用这个公式发展出了利用分布函数来计算数学期望的办法。到了条件数学期望的场合, 同样有类似的积分变换公式。我们在下文中进行讨论。

给定两个概率空间 $(\Omega_1, \mathcal{F}_1, \mathbb{P}_1)$ 和 $(\Omega_2, \mathcal{F}_2, \mathbb{P}_2)$, 其上数学期望算子分别记作 $\mathbb{E}_1, \mathbb{E}_2$. 假定有可测映射

$$T: (\Omega_1, \mathcal{F}_1) \rightarrow (\Omega_2, \mathcal{F}_2)$$

使得 $\mathbb{P}_2 = \mathbb{P}_1 \circ T^{-1}$, 即 $T : (\Omega_1, \mathcal{F}_1, \mathbb{P}_1) \rightarrow (\Omega_2, \mathcal{F}_2, \mathbb{P}_2)$ 是保测映射. 假定 $\varphi : (\Omega_2, \mathcal{F}_2) \rightarrow \mathbb{R}$ 是概率空间 $(\Omega_2, \mathcal{F}_2, \mathbb{P}_2)$ 上的可积 (或非负) 随机变量, 那么 $\varphi \circ T$ 是概率空间 $(\Omega_1, \mathcal{F}_1, \mathbb{P}_1)$ 上的可积 (或非负) 随机变量, 并且

$$\mathbb{E}_1[\varphi \circ T] = \mathbb{E}_2[\varphi].$$

这是我们之前就讲过的积分变换公式。

现在, 我们进一步假定 $\mathcal{G}_2 \subset \mathcal{F}_2$ 是一个子 σ -代数, 那么 $T^{-1}\mathcal{G}_2 \subset \mathcal{F}_1$. 在上述假定下, 本节我们将证明下面的条件数学期望版本的积分变换公式:

♠ **定理 7.3.1.** 设 $T : (\Omega_1, \mathcal{F}_1, \mathbb{P}_1) \rightarrow (\Omega_2, \mathcal{F}_2, \mathbb{P}_2)$ 是保测映射, $\mathcal{G}_2 \subset \mathcal{F}_2$ 是一个子 σ -代数. 那么对任意非负可测函数 $\varphi : (\Omega_2, \mathcal{F}_2) \rightarrow \mathbb{R}$ (或 $\varphi \in L^1(\mathbb{P}_2)$)

$$\mathbb{E}_1[\varphi \circ T | T^{-1}\mathcal{G}_2] = \mathbb{E}_2[\varphi | \mathcal{G}_2] \circ T. \quad (7.17)$$

上面公式(7.17)也可以表述为:

$$\mathbb{E}_{\mathbb{P}_1}[\varphi \circ T | T^{-1}\mathcal{G}_2] = \mathbb{E}_{\mathbb{P}_1 \circ T^{-1}}[\varphi | \mathcal{G}_2] \circ T.$$

请参考下面的交换图:

$$\begin{array}{ccc} (\Omega_1, \mathcal{F}_1, \mathbb{P}_1; T^{-1}\mathcal{G}_2) & \xrightarrow{T} & (\Omega_2, \mathcal{F}_2, \mathbb{P}_1 \circ T^{-1}; \mathcal{G}_2) \\ & \searrow \varphi \circ T & \downarrow \varphi \\ & & \mathbb{R} \end{array}$$

现在我们在可积性条件下来证明(7.17). 事实上, 设 $\xi_2 := \mathbb{E}_2[\varphi | \mathcal{G}_2]$, 显然有 $\xi_1 := \xi_2 \circ T$ 是概率空间 $(\Omega_1, \mathcal{F}_1, \mathbb{P}_1)$ 上的随机变量, 并且它是 $T^{-1}\mathcal{G}_2$ 可测的. 于是对任意 $A_1 \in T^{-1}\mathcal{G}_2$, 存在 $A_2 \in \mathcal{G}_2$ 使得 $A_1 = T^{-1}A_2$, 并且

$$\begin{aligned} \mathbb{E}_1[\xi_1 \cdot 1_{A_1}] &= \mathbb{E}_1[\xi_2 \circ T \cdot 1_{A_2} \circ T] \\ &= \mathbb{E}_2[\xi_2 \cdot 1_{A_2}] = \mathbb{E}_2[\varphi \cdot 1_{A_2}] \\ &= \mathbb{E}_1[\varphi \circ T \cdot 1_{A_2} \circ T] = \mathbb{E}_1[\varphi \circ T \cdot 1_{A_1}]. \end{aligned}$$

由 $A_1 \in T^{-1}\mathcal{G}_2$ 的任意性, $\mathbb{E}_1[\varphi \circ T | T^{-1}\mathcal{G}_2] = \xi_2 \circ T$ 几乎处处成立, 即(7.17)几乎处处成立。

7.3.2 条件分布律与条件数学期望的计算公式

有了一个事件 A 关于一个子 σ -代数 $\mathcal{G}$ 的条件概率 $\mathbb{P}(A | \mathcal{G})$ 的定义, 很自然也可以引出一个随机变量 ξ 关于一个子 σ -代数 $\mathcal{G}$ 的条件分布的定义: 我们

称 $\mathbb{P}(\xi \leq x | \mathcal{G})$ 为随机变量 ξ 关于子 σ -代数 $\mathcal{G}$ 的条件分布。一般而言，我们有下面的定理。

♠ **定理 7.3.2.** 给定概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上 $d \geq 1$ 维随机向量 ξ 和子 σ -代数 $\mathcal{G}$ ，总存在二元可测函数

$$F(\cdot) : \Omega \times \mathbb{R}^d \rightarrow \mathbb{R}, (\omega, x) \mapsto F_\omega(x)$$

满足：

- (1) 任意固定 $\omega \in \Omega$ ， $F_\omega(\cdot)$ 是一个概率分布函数；
- (2) 任意固定 $x \in \mathbb{R}^d$ ， $F_\omega(x)$ 是一个随机变量，且对 $\mathbb{P}$ -a.e. ω 成立

$$F_\omega(x) = \mathbb{P}(\xi \leq x | \mathcal{G})(\omega). \quad (7.18)$$

我们把具有上述性质的（二元）函数 $F(\cdot)$ 称为随机向量 ξ 关于子 σ -代数 $\mathcal{G}$ 的条件分布。把 F_ω 诱导的分布测度记作 μ_ω 。此时我们把分布函数族 $\{F_\omega\}_\omega$ 或分布测度族 $\{\mu_\omega\}_\omega$ 都称为 ξ 关于 $\mathcal{G}$ 的条件分布律¹，并记作

$$\xi | \mathcal{G} \sim F_\omega \quad \text{或} \quad \xi | \mathcal{G} \sim \mu_\omega.$$

特别地，对任意可测函数 φ ，当 $\varphi(\xi)$ 非负或可积时，下面的条件数学期望计算公式（几乎处处）成立：

$$\mathbb{E}[\varphi(\xi) | \mathcal{G}](\omega) = \int \varphi(x) dF_\omega(x). \quad (7.19)$$

上述定理通常在概率论的高级教程中才会给出²。但实际上这个定理的证明并不算太难。此处给出证明也是为了整体讲义逻辑体系的完备性。

定理 7.3.2 的证明： 为方便，我们仅讨论 $d = 1$ 的情形；高维情形可以类似处理。对任意 $r \in \mathbb{Q}$ ，我们可以通过条件概率定义一个随机变量 $\omega \mapsto G_\omega(r)$

$$G_\omega(r) := \mathbb{P}(\xi \leq r | \mathcal{G})(\omega),$$

即 $G_\omega(r)$ 是 $\mathbb{P}(\xi \leq r | \mathcal{G})$ 的一个“代表元”。由此我们得到了一个映射

$$G : \Omega \times \mathbb{Q} \rightarrow [0, 1], (\omega, r) \mapsto G_\omega(r).$$

¹注意，条件分布律在几乎处处相等的意义下是唯一的。具体来说，对两个分布函数族 $\{F_\omega\}_\omega$ 与 $\{G_\omega\}_\omega$ ，如果映射 $\omega \mapsto F_\omega$ 与 $\omega \mapsto G_\omega$ 在挖去一个零测集后是相同的，那么就认为它们对应的条件分布律相同。

²为了讨论随机元的条件分布律，在“高等概率论”中还通常给出了所谓的“正则条件分布”的概念。

但要注意, 对于固定的 $\omega \in \Omega$, 函数 $G_\omega : \mathbb{Q} \rightarrow \mathbb{R}$ 的分析性质可能不太好; 现在我们准备缩小变元 ω 的定义域以便改善这个函数的分析性质。

首先, 对任意 $r_1 < r_2, r_1, r_2 \in \mathbb{Q}$, 显然有 $1_{\{\xi \leq r_1\}} \leq 1_{\{\xi \leq r_2\}}$. 于是由条件数学期望的单调性, 我们知道此时有

$$\mathbb{P}(\xi \leq r_1 | \mathcal{G}) \leq \mathbb{P}(\xi \leq r_2 | \mathcal{G})$$

几乎处处成立。也就是说, 存在 $A_{r_1, r_2} \in \mathcal{F}, \mathbb{P}(A_{r_1, r_2}) = 0$, 使得

$$G_\omega(r_1) \leq G_\omega(r_2), \forall \omega \notin A_{r_1, r_2}.$$

令 $\mathcal{N}_1 := \bigcup_{\substack{(r_1, r_2) \in \mathbb{Q}^2 \\ r_1 < r_2}} A_{r_1, r_2}$, 则对任意固定的 $\omega \in \Omega \setminus \mathcal{N}_1$, 函数

$$G_\omega : \mathbb{Q} \rightarrow [0, 1], r \mapsto G_\omega(r)$$

关于 r 是单调递增的。

其次, 由条件数学期望的控制收敛定理, 对任意 $r \in \mathbb{Q}$, 我们有

$$\lim_{\mathbb{Q} \ni r' \downarrow r} \mathbb{P}(\xi \leq r' | \mathcal{G}) = \mathbb{P}(\xi \leq r | \mathcal{G})$$

几乎处处成立, 也有

$$\lim_{\mathbb{Q} \ni r' \downarrow -\infty} \mathbb{P}(\xi \leq r' | \mathcal{G}) = 0, \quad \lim_{\mathbb{Q} \ni r' \uparrow +\infty} \mathbb{P}(\xi \leq r' | \mathcal{G}) = 1$$

几乎处处成立。也就是说, 对任意 $r \in \mathbb{Q}$, 存在 $B_r, B_\infty \in \mathcal{F}, \mathbb{P}(B_r) = \mathbb{P}(B_\infty) = 0$, 使得

$$\lim_{\mathbb{Q} \ni r' \downarrow r} G_\omega(r') = G_\omega(r), \forall r \in \mathbb{Q}, \omega \notin B_r$$

及对 $\forall \omega \notin B_\infty$

$$\lim_{\mathbb{Q} \ni r' \downarrow -\infty} G_\omega(r') = 0, \quad \lim_{\mathbb{Q} \ni r' \uparrow +\infty} G_\omega(r') = 1.$$

令 $\mathcal{N}_2 := B_\infty \cup (\bigcup_{r \in \mathbb{Q}} B_r)$. 对任意固定的 $\omega \in \Omega \setminus \mathcal{N}_2$, 函数

$$G_\omega : \mathbb{Q} \rightarrow [0, 1], r \mapsto G_\omega(r)$$

具有“右连续性”, 且 $G_\omega(-\infty) = 0, G_\omega(\infty) = 1$.

现在取 $\mathcal{N} := \mathcal{N}_1 \cup \mathcal{N}_2$, 则 $\mathbb{P}(\mathcal{N}) = 0$. 我们定义

$$F_\omega(x) := \lim_{\mathbb{Q} \ni r \downarrow x} G_\omega(r), \forall \omega \in \Omega \setminus \mathcal{N}, x \in \mathbb{R} \setminus \mathbb{Q}.$$

对任意 $\omega \in \mathcal{N}$, 补充定义 $F_\omega(x) = x^+ \wedge 1, \forall x \in \mathbb{R}$. 于是我们定义好了

$$F : \Omega \times \mathbb{R} \rightarrow [0, 1], (\omega, x) \mapsto F_\omega(x),$$

现在不难证明: 对任意 $x \in \mathbb{R}$, (7.18) 几乎处处成立. 基于此也不难利用单调类定理证明(7.19). $\square$

类似于定理7.3.2, 我们给出一个随机变量关于另一个随机变量的条件分布律的概念如下:

定义 7.3.1. 假设 $X_i \sim \mu_i, i = 1, 2$, 其中 μ_1, μ_2 是分布测度.

如果存在一族对 μ_2 -几乎处处 x_2 定义的概率测度族 $\{\mu_{x_2}^{(1)}\}_{x_2}$, 使得对任意可测集 A_1, A_2

$$\mathbb{P}(X_1 \in A_1, X_2 \in A_2) = \int_{A_2} \mu_{x_2}^{(1)}(A_1) d\mu_2(x_2), \quad (7.20)$$

则称这族概率测度族 $\{\mu_{x_2}^{(1)}\}_{x_2}$ 为 X_1 关于 X_2 的条件分布, 记作

$$X_1 | X_2 = x_2 \sim \mu_{x_2}^{(1)}. \quad (7.21)$$

如果存在二元可测函数

$$(x_1, x_2) \mapsto F_{x_1|x_2}(x_1|x_2),$$

使得对任意固定 x_2 , $F_{x_1|x_2}(\cdot|x_2)$ 是一个概率分布函数, 并且

$$\mathbb{P}(X_1 \leq x_1, X_2 \leq x_2) = \int_{(-\infty, x_2]} F_{x_1|x_2}(x_1|x_2) d\mu_2(x_2), \quad (7.22)$$

那么我们称概率分布函数族 $\{F_{x_1|x_2}(\cdot|x_2)\}_{x_2}$ 为 X_1 关于 X_2 的条件分布函数(族); 它在 μ_2 -几乎处处相等意义下是唯一的. 此时, 我们记

$$X_1 | X_2 = x_2 \sim F_{x_1|x_2}(\cdot|x_2). \quad (7.23)$$

上述概率分布测度族 $\{\mu_{x_2}^{(1)}\}_{x_2}$ 或概率分布函数族 $\{F_{x_1|x_2}(\cdot|x_2)\}_{x_2}$ 都称为 X_1 关于 X_2 的条件分布律.

采用类似的证明手法, 可以证明上述定义中的一个随机变量关于另一个随机变量的“条件分布律”总是存在的, 并且在上面记号的基础上, 对任意非负可测或有界可测函数 φ (或使得 $\varphi(\xi, \eta)$ 可积的可测函数 φ), 我们不难证明

$$\mathbb{E}[\varphi(X_1, X_2) | X_2 = y] = \int \varphi(x, y) dF_{x_1|x_2}(x|y). \quad (7.24)$$

这个公式与我们之前得到的（无条件）数学期望的计算公式十分相像，仅仅是把之前公式中的（无条件）分布函数修改为相应的条件分布函数。

上述讨论显得比较抽象。为获得一些直观，我们来看看容易理解的情形： ξ, η 均为离散型随机变量。

例 7.2. 设 ξ, η 均为离散型随机变量，它们的联合分布如下：

$$\mathbb{P}(\xi = a_i, \eta = b_j) = p_{i,j}, \quad i = 1, \dots, M, \quad j = 1, \dots, N,$$

其中 $\sum_{1 \leq i \leq M} \sum_{1 \leq j \leq N} p_{i,j} = 1$. 令

$$p_{i,\cdot} = \sum_{j=1}^N p_{i,j}, \quad p_{\cdot,j} = \sum_{i=1}^M p_{i,j}.$$

此时, $\mathbb{P}(\xi = a_i) = p_{i,\cdot}, \mathbb{P}(\eta = b_j) = p_{\cdot,j}$. 对应定义中符号体系, $(X_1, X_2) = (\xi, \eta)$, 我们有

$$\mu_x^{(2)}(A) = \mathbb{P}(\xi \leq x, \eta \in A) = \sum_{i=1}^M \sum_{j=1}^N p_{i,j} \cdot 1_{[a_i, \infty)}(x) \cdot 1_A(b_j),$$

并且 $\mu_2(A) = \mathbb{P}(\eta \in A), \mu_2(\{b_j\}) = p_{\cdot,j}$. 因此 $\mu_x^{(2)}, \mu_2$ 都是离散型分布。进而易知, $F(x|y) := \mathbb{P}(\xi \leq x | \eta = y)$ 只对 $y \in \{b_j : 1 \leq j \leq N\}$ 有意义, 并且

$$F(x|b_j) = \frac{d\mu_x^{(2)}}{d\mu_2}(b_j) = \frac{\mu_x^{(2)}(\{b_j\})}{\mu_2(\{b_j\})} = \sum_{i=1}^M \frac{p_{i,j}}{p_{\cdot,j}} \cdot 1_{[a_i, \infty)}(x).$$

$F(\cdot|b_j)$ 是一个离散型的概率分布函数, 它诱导如下经典的条件概率分布列:

$$\mathbb{P}(\xi = a_i | \eta = b_j) = \frac{p_{i,j}}{p_{\cdot,j}}, \quad i = 1, 2, \dots, M,$$

并且此时

$$\mathbb{E}[\varphi(\xi, \eta) | \eta = b_j] = \sum_i \varphi(a_i, b_j) \cdot \frac{p_{i,j}}{p_{\cdot,j}}. \quad (7.25)$$

在下一章, 我们将会讨论 (ξ, η) 服从连续型分布时 ξ 关于 η 的条件分布律的问题, 那时我们将会得到条件分布律的另一种刻画: **条件密度**。

以上提及的条件分布函数、条件概率分布列、条件密度都是条件分布律在特定条件下的表现形式。

7.3.3 条件数学期望与独立性

当随机变量/向量 X, Y 相互独立时, 关于条件数学期望我们有下面非常实用的定理。

♠ **定理 7.3.3.** 设 X, Y 相互独立, φ 是使下述讨论有意义的可测函数, 那么

$$\begin{aligned}\mathbb{E}[\varphi(X, Y)|Y] &= \mathbb{E}[\varphi(X, y)]|_{y=Y}, \\ \mathbb{E}[\varphi(X, Y)] &= \mathbb{E}\left[\mathbb{E}[\varphi(X, y)]|_{y=Y}\right].\end{aligned}$$

特别地, 对任意可测集 A, B

$$\mathbb{P}(X \in A, Y \in B|Y) = \mathbb{P}(X \in A) \cdot 1_B(Y).$$

参考证明: 设 X, Y 的分布测度分别为 μ_x, μ_y , 记 $\psi(y) = \mathbb{E}[\varphi(X, y)]$. 那么

$$\psi(y) = \int \varphi(x, y) d\mu_x(x),$$

进而对任意可测集 B ,

$$\begin{aligned}\mathbb{E}[\psi(Y) \cdot 1_B(Y)] &= \int \psi(y) \cdot 1_B(y) d\mu_y(y) \\ &= \int \left[\int \varphi(x, y) d\mu_x(x) \right] \cdot 1_B(y) d\mu_y(y) \\ &= \int \left[\int \varphi(x, y) \cdot 1_B(y) d\mu_x(x) \right] d\mu_y(y) \\ &= \int \left[\varphi(x, y) \cdot 1_B(y) \right] d\mu_x \otimes \mu_y(x, y) \quad (\text{Fubini 定理}) \\ &= \mathbb{E}[\varphi(X, Y) \cdot 1_B(Y)].\end{aligned}$$

由定义立即知道定理的第一个结论成立, 对此再两边取数学期望就证明了第二个结论。再取 $\varphi(x, y) = 1_A(x) \cdot 1_B(y)$ 就证明了第三个结论。□

我们也可以把上述定理按照下面更直观、但不太严谨的逻辑来理解:

$$\begin{aligned}\mathbb{E}[\varphi(X, Y)|Y = y] &= \mathbb{E}[\varphi(X, y)|Y = y] \quad (Y = y \text{ 的代换}) \\ &= \mathbb{E}[\varphi(X, y)] \quad (X, Y \text{ 相互独立}).\end{aligned}$$

实际上我们有下面更抽象、但也更强大的推论¹, 它的证明就留给读者。

¹注意, 这个结论本身是 Fubini 定理这个分析结论在条件分布律这个概率视角下的一种抽象的、高观点的等价表述。

☞ 推论 7.3.1. 设 φ 是可测函数, μ_Y 是 Y 的分布测度. 当 X, Y 相互独立时,

$$(\varphi(X, Y) | Y = y) \stackrel{d}{=} \varphi(X, y) \quad (7.26)$$

对 μ_Y -a.e. y 成立. 上式的含义是: 记 $\varphi(X, y) \sim F_y$, 则 $\varphi(X, Y)$ 关于 Y 的条件分布律恰为分布族 $\{F_y\}_y$. 这也可以用自然语言解读为: 当 X, Y 相互独立时, 对 μ_Y -a.e. y , $\varphi(X, Y)$ 在 $Y = y$ 的条件下的 (条件) 分布律就是 $\varphi(X, y)$ 的无条件分布律.

此外, 我们还有下面使用条件分布律来刻画独立性的判据:

♠ 定理 7.3.4. 设 Y 的分布测度为 μ_Y . 那么 X, Y 相互独立的充分必要条件是: 存在分布函数 F , 使得对 μ_Y -a.e. y ,

$$X | Y = y \sim F \quad (7.27)$$

成立. 当上式成立时, $X \sim F$.

参考证明: 设 X 的分布函数为 F_X . 当 X, Y 相互独立时, 对任意可测集 B 及任意点 x , 我们有

$$\mathbb{P}(X \leq x, Y \in B) = \mathbb{P}(X \leq x) \mathbb{P}(Y \in B) = \int_B F_X(x) d\mu_Y(y).$$

即 X 关于 $Y = y$ 的条件分布函数为

$$F_{X|Y}(x|y) = F_X(x), \quad \mu_Y\text{-a.e. } y.$$

取 $F = F_X$ 即得(7.27).

反过来, 如果(7.27)成立, 那么对 μ_Y -a.e. y 及任意 x

$$\mathbb{P}(X \leq x | Y = y) = F(x).$$

于是对任意点 x, y

$$\begin{aligned} \mathbb{P}(X \leq x, Y \leq y) &= \mathbb{E}[\mathbb{P}(X \leq x | Y) \cdot 1_{\{Y \leq y\}}] \\ &= \mathbb{E}[\mathbb{P}(X \leq x | Y = t) \Big|_{t=Y} \cdot 1_{\{Y \leq y\}}] \\ &= \mathbb{E}[F(x) \cdot 1_{\{Y \leq y\}}] = F(x) \cdot \mathbb{P}(Y \leq y). \end{aligned}$$

令 $y \rightarrow \infty$, 立即得到 $\mathbb{P}(X \leq x) = F(x)$, 即 $X \sim F$. 进而

$$\mathbb{P}(X \leq x, Y \leq y) = \mathbb{P}(X \leq x) \cdot \mathbb{P}(Y \leq y), \quad \forall x, y.$$

因此 X, Y 相互独立. □

7.4 条件数学期望的应用

以下我们介绍条件数学期望的一些简单应用。

例 7.3. 有一枚不均匀的硬币，已知单次投掷它获得正面的概率为 $p \in (0, 1)$. 现在考虑反复投掷这枚不均匀硬币，请问为了获得首个硬币正面记录平均所需的最少投掷硬币次数。

参考解答： 在之前章节我们已经论证过，如果记 N 是为了获得首个硬币正面记录所需的最少投掷硬币次数，则 $N \sim \text{Geo}(p)$ ，基于此可以直接计算出本问题所求的量 $\mathbb{E}N = \frac{1}{p}$. 此处我们给出一种不需要知道 N 的分布律信息也能求解 $\mathbb{E}N$ 的方法。事实上，记 X_1 为第一次投掷硬币所获得的记录（当获得硬币正面时，记录为“H”，否则记录为“T”）。于是容易知道

$$\mathbb{E}[N|X_1 = H] = 1, \quad \mathbb{E}[N|X_1 = T] = 1 + \mathbb{E}N.$$

由全概率公式

$$\begin{aligned} \mathbb{E}N &= \mathbb{E}[\mathbb{E}(N|X_1)] \\ &= \mathbb{P}(X_1 = H) \cdot \mathbb{E}[N|X_1 = H] + \mathbb{P}(X_1 = T) \cdot \mathbb{E}[N|X_1 = T] \\ &= p + (1-p) \cdot (1 + \mathbb{E}N) = 1 + (1-p)\mathbb{E}N. \end{aligned}$$

于是 $\mathbb{E}N = \frac{1}{p}$ 即为所求。 $\square$

例 7.4. 考虑反复投掷一枚均匀硬币，如果获得正面则记录“H”，获得反面则记录“T”。请问，

- (1) 为了获得记录“HT”平均所需的最少投掷硬币次数；
- (2) 为了获得记录“HHTH”平均所需的最少投掷硬币次数。

参考解答： 对任意一个记录 A ，记 N_A 是为了获得记录 A 实际所需的最少投掷硬币次数。记 $\mathcal{S} := \{H, T\}$. 对于一个记录 A ，如果其中字符串长度为 $\ell(A) = n$ ，我们就记 $x \in \mathcal{S}_n := \mathcal{S}^n$ ，同时我们将用 $\mathbb{P}(A)$ 表示初始 n 次投掷硬币形成记录 A 的概率，用 $\mathbb{E}[\cdot|A]$ 表示在初始 n 次投掷硬币形成记录 A 的条件下的条件数学期望。在这种略有点符号滥用、但符合直观的记号下，我们来进行有关讨论与计算。

(1) 此处要讨论的是 $\mathbb{E}[N_{HT}]$. 显然由全期望公式，有

$$\mathbb{E}[N_{HT}] = \sum_{A \in \mathcal{S}_n} \mathbb{P}(A) \cdot \mathbb{E}[N_{HT}|A]. \quad (7.28)$$

在上式中取 $n = 1$, 得到 $\mathbb{E}[N_{HT}] = \frac{1}{2}(\mathbb{E}[N_{HT}|H] + \mathbb{E}[N_{HT}|T])$. 从直观容易知道 $\mathbb{E}[N_{HT}|T] = 1 + \mathbb{E}[N_{HT}]$, 由此解得

$$\mathbb{E}[N_{HT}] = 1 + \mathbb{E}[N_{HT}|H].$$

在(7.28)中取 $n = 2$, 并注意到

$$\begin{aligned}\mathbb{E}[N_{HT}|HH] &= 1 + \mathbb{E}[N_{HT}|H], & \mathbb{E}[N_{HT}|HT] &= 2, \\ \mathbb{E}[N_{HT}|TH] &= 1 + \mathbb{E}[N_{HT}|H], & \mathbb{E}[N_{HT}|TT] &= 2 + \mathbb{E}[N_{HT}],\end{aligned}$$

我们得到

$$3\mathbb{E}[N_{HT}] = 6 + 2\mathbb{E}[N_{HT}|H] = 4 + 2\mathbb{E}[N_{HT}].$$

于是解得 $\mathbb{E}[N_{HT}] = 4$.

(2) 此处当然还可以按照(1)中方式进行求解. 但为了有关表述更简洁, 这里对任意记录 x, A , 我们引进一个新的记号 $N_{x|A}$, 用来代表已获得记录序列 A 的条件下, 为了获得记录序列 x 所需要的最少的额外投币次数. 这里强调一下, 我们实际上有

$$\mathbb{E}[N_x|A] = \mathbb{E}[N_{x|A}] + \ell(A).$$

以下固定取 $x = HHTH$, 显然本问所求为 $\mathbb{E}[N_x]$. 注意到

$$N_x = N_H + N_{x|H},$$

我们有 $\mathbb{E}[N_x] = \mathbb{E}[N_H] + \mathbb{E}[N_{x|H}]$, 于是 $\mathbb{E}[N_x] = 2 + \mathbb{E}[N_{x|H}]$.

类似地, 由

$$\mathbb{E}[N_{x|H}|H] = 1 + \mathbb{E}[N_{x|HH}], \quad \mathbb{E}[N_{x|H}|T] = 1 + \mathbb{E}[N_x],$$

我们得到 $\mathbb{E}[N_{x|H}] = 4 + \mathbb{E}[N_{x|HH}]$; 由

$$\mathbb{E}[N_{x|HH}|H] = 1 + \mathbb{E}[N_{x|HHH}], \quad \mathbb{E}[N_{x|HH}|T] = 1 + \mathbb{E}[N_{x|HHT}],$$

我们得到 $\mathbb{E}[N_{x|HH}] = 2 + \mathbb{E}[N_{x|HHT}]$; 由

$$\mathbb{E}[N_{x|HHT}|H] = 1, \quad \mathbb{E}[N_{x|HHT}|T] = 1 + \mathbb{E}[N_x],$$

我们得到 $\mathbb{E}[N_{x|HHT}] = 1 + \frac{1}{2}\mathbb{E}[N_x]$.

综合上面诸式立即得到 $\mathbb{E}[N_x] = 18$. □

文献^{[85][126]}利用更新过程(或马氏链)的有关理论, 给出了一种对上述问题的更一般性的快速解答方法, 感兴趣的读者可以前往了解学习。

7.5 本章小结与学习建议

在本章，我们通过比较复杂的流程定义了抽象的条件数学期望概念，进而定义了抽象的条件概率概念，它们本质上都被定义为具有特定性质的随机变量；但回归到经典情形，它们又分别与经典情形的条件数学期望、条件概率概念相一致。特别地，我们基于抽象的条件数学期望概念，导出了一个随机变量关于另一个随机变量的条件分布律的概念，并基于条件分布律，给出了一个随机变量关于另一个随机变量的条件数学期望的计算公式；作为应用，我们还特意讨论了独立性与条件数学期望的关系，见 §7.3.3.

非数学专业的概率论初学者在学习本章时，在了解抽象的条件数学期望、条件概率的大致定义流程基础上，可以跳过有关证明（数学专业的概率论初学者则建议对这些证明与说理流程有所了解，但也不必掌握所有细节），直接承认条件数学期望的定义7.1.1、条件分布律的定义7.3.1以及一个随机变量关于另一个随机变量的条件数学期望的计算公式(7.24)，通过一些应用来熟悉条件数学期望这套复杂的概率论工具。这里需要特别指出，随机变量 X 的分布律就是一个概率分布函数 F_X ：

$$F_X(x) := \mathbb{P}(X \leq x), \forall x,$$

或一个分布测度 μ_X ：

$$\mu_X(A) := \mathbb{P}(X \in A), \forall A \text{ 为可测集},$$

这被简记为 $X \sim F_X$ 或 $X \sim \mu_X$. 而随机变量 X 关于另一个随机变量 Y 的条件分布律就是一族分布函数 $\{F(\cdot|y)\}_y$ 或一族分布测度 $\{\nu_y\}_y$ （而这个族群也只需要对 μ_Y -几乎处处的 y 有定义），它们满足

$$\mathbb{P}(X \leq x | Y = y) = F(x|y), \forall x$$

和

$$\mathbb{P}(X \in A | Y = y) = \nu_y(A), \forall A \text{ 为可测集},$$

更确切地，

$$\mathbb{P}(X \leq x, Y \in B) = \int_B F(x|y) d\mu_Y(y), \forall x, \forall B \text{ 为可测集}$$

及

$$\mathbb{P}(X \in A, Y \in B) = \int_B \nu_y(A) d\mu_Y(y), \forall A, B \text{ 为可测集}.$$

以上两方程也分别被简记为

$$X|Y = y \sim F(\cdot|y) \quad \text{和} \quad X|Y = y \sim \nu_y.$$

本章中条件数学期望、条件概率、条件分布律等复杂的定义流程及有关推理,目的就在于从概率论的公理出发,严格论证条件分布律这套工具及相应符号体系的存在性与合理性;这是概率论初学者需要了解,但又可跳开其中严谨逻辑推理的部分内容。而基于条件分布律这套工具,条件数学期望的计算公式(7.24)以及其他一些相关命题也就不难理解了。特别地,有了条件分布律这套工具及相应符号体系,在 X, Y 相互独立的条件下,我们有结论(7.26)这样自然、优美、强大而又富含概率论韵味的结论,这在国内外很多概率论教程中都没有给予论述;定理7.3.4也是值得注意的。

习 题 7

习题 7.1. 设 X, Y 独立同分布, 证明: $\mathbb{E}[(X - Y)^2] < \infty$ 当且仅当 $\mathbb{E}[X^2] < \infty$.

习题 7.2. 设 X, Y 相互独立, 证明: $\mathbb{E}|X - Y| < \infty$ 当且仅当 $\mathbb{E}|X| < \infty$ 且 $\mathbb{E}|Y| < \infty$.

习题 7.3. 设随机变量 X, Y 相互独立, 具有共同的分布函数 F . 证明:

$$\mathbb{E}[|X - Y|] = 2 \int F(x)[1 - F(x)]dx.$$

特别地, 如果 m 是分布 F 的中位数 (即 $F(m) \geq \frac{1}{2}$ 且 $F(m-) \leq \frac{1}{2}$), 那么

$$\mathbb{E}|X - m| \leq \mathbb{E}|X - Y|.$$

习题 7.4. 设随机变量 X, Y 相互独立, 具有共同的分布函数 F . 证明:

$$\mathbb{E}[|X - Y|^2] = 4 \int_{\mathbb{R}^2} F(u)[1 - F(v)] \cdot 1_{\{u < v\}} du dv.$$

习题 7.5. 设随机变量 $X \sim F$, m_x 是分布 F 的中位数, 证明:

$$\mathbb{E}|X - m_x| \leq \mathbb{E}|X - y|, \forall y \in \mathbb{R}.$$

利用此性质, 也可以证明: 如果 Y 与 X 相互独立 (不必同分布), 那么

$$\mathbb{E}|X - m_x| \leq \mathbb{E}|X - Y|.$$

习题 7.6. 如果 X, Y 独立, 各自分布函数分别为 F, G , 请读者给出 $\mathbb{E}[|X - Y|]$ 的类似习题7.3的积分表达式, 并基于此来论证习题7.5中最后的不等式。回到 Y 退化成常数的情况, 这本质上给出了习题7.5中的第一个不等式。

习题 7.7. 设 X, Y 相互独立、同分布且可积。证明: $\mathbb{E}|X - \mathbb{E}X| \leq \mathbb{E}|X - Y|$.

习题 7.8. 设 X, Y 相互独立、同分布且可积。证明: $\mathbb{E}|X - Y| \leq \mathbb{E}|X + Y|$.

习题 7.9. 设 X, Y 相互独立、同分布且可积。证明: $\mathbb{E}|X| \leq \mathbb{E}|X + Y|$.

习题 7.10. 设 X, Y 相互独立, 其中 $\mathbb{E}Y = 0$. 证明: $\mathbb{E}|X| \leq \mathbb{E}|X + Y|$.

习题 7.11. 考虑反复投掷一枚均匀硬币, 如果获得正面则记录“H”, 获得反面则记录“T”。请问

- (1) 为了获得记录“HHH”平均所需的最少投掷硬币次数;
- (2) 为了获得记录“HTH”平均所需的最少投掷硬币次数;
- (3) 为了获得记录“HTHTH”平均所需的最少投掷硬币次数。

习题 7.12. 设 $\{X_n\}_{n=1}^{\infty}$ 独立同分布, 它们与非负整数值随机变量 τ 相互独立, 其中 $\mathbb{E}[|X_1|] < \infty$, $\mathbb{E}\tau < \infty$. 记 $S_n := X_1 + \cdots + X_n$, 求证:

- (1) $\mathbb{E}S_{\tau} = (\mathbb{E}\tau) \cdot \mathbb{E}X_1$;
- (2) 当 $\mathbb{E}[X_1^2] < \infty$, $\mathbb{E}[\tau^2] < \infty$ 时, $\text{Var}(S_{\tau}) = (\mathbb{E}\tau) \cdot \text{Var}(X_1) + (\mathbb{E}X_1)^2 \text{Var}(\tau)$.

习题 7.13. 设 $\{X_n\}_{n=1}^{\infty}$ 独立同分布, 且 $\mathbb{E}[|X_1|] < \infty$. 记 $\bar{X}_n := \frac{X_1 + \cdots + X_n}{n}$. 求证: $\mathbb{E}[X_1 | \bar{X}_n] = \bar{X}_n$. 更一般地, $\mathbb{E}[X_j | \bar{X}_{\ell}, \ell \geq n] = \bar{X}_n$ 对所有 $1 \leq j \leq n$ 成立, 进而

$$\mathbb{E}[\bar{X}_m | \bar{X}_{\ell}, \ell \geq n] = \bar{X}_n, \quad \forall 1 \leq m \leq n.$$

习题 7.14. 设随机向量 X 的分布测度为 μ_{θ} , 其中 $\theta \in \Theta$ 是一个参数, Θ 是欧氏空间中的一个有内点的可测集。设 $T(\cdot)$ 是欧氏空间中的可测函数, 使得 $T(X)$ 有定义; 则 $T(X)$ 是一个统计量。称 $T(X)$ 是参数 θ 的充分统计量, 如果已知 $T(X)$ 的取值后, X 关于 $T(X)$ 的条件分布律总是不依赖于参数 $\theta \in \Theta$ (这说明, 从样本 X 能获得的关于 θ 的有关信息已经完全包含在统计量 $T(X)$ 中了, 因此使用充分统计量 $T(X)$ 来代替样本 X 就达到了“加工样本数据而不损失信息”的效果, 统计学中把这样的性质就称为“充分的”)。求证: 如果 $T(X)$ 是参数 θ 的充分统计量, 那么对于参数 $g(\theta)$ 的任一无偏统计量 V , 都能找到形如 $\varphi(T(X))$ 的无偏统计量, 其中 φ 是不依赖于参数 θ 的可测函数。

习题 7.15. 给定某个带参数 θ 的分布族的简单样本。如果参数 $g(\theta)$ 存在无偏估计, 则称该参数是可估的, 否则称为不可估的。并不是所有参数都是可估的: 设 $\{X_k\}_{k=1}^n \stackrel{\text{i.i.d.}}{\sim} B(1, p)$ (其中 $p \in (0, 1)$), 则参数 $1/p$ 不存在无偏估计, 从而它是不可估的。

习题 7.16. 有人在旅游区摆摊设置赌博小游戏。游戏规则如下：摊主和参加游戏的游客（下称玩家）各自使用一枚同样的硬币（能区分正、反面），相约同时展示硬币。如果展示的两枚硬币都是正面，则摊主支付游客 3 元；如果展示的两枚硬币都是反面，则摊主支付玩家 1 元；其他情况则玩家支付摊主 2 元。请问这个游戏公平吗？

习题 7.17. 证明条件数学期望的性质 (CE4)、(CE5)。

习题 7.18. 证明条件 Hölder 不等式。

习题 7.19. 证明条件矩不等式。

习题 7.20. 证明条件 Minkowski 不等式。

习题 7.21. 设 $\mathcal{G}_1, \mathcal{G}_2, \mathcal{G}_3$ 为概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 中三个子 σ -代数。 $\mathcal{G}_1 \vee \mathcal{G}_2$ 总表示由 $\mathcal{G}_1 \cup \mathcal{G}_2$ 生成的 σ -代数。假设 $\mathcal{G}_1 \vee \mathcal{G}_2$ 与 $\mathcal{G}_3$ 独立，基于附录 A 中的单调类定理，请证明：对任意 $\mathcal{G}_1$ 可测的随机变量 f ，（当下面等式的左右两边条件数学期望有意义时）总有

$$\mathbb{E}[f|\mathcal{G}_2 \vee \mathcal{G}_3] = \mathbb{E}[f|\mathcal{G}_2].$$

习题 7.22. 上一题也可以继续推广（本质上都是在推广： $\mathbb{E}[X|\mathcal{G}] = \mathbb{E}X$ ，如果 X 与 $\mathcal{G}$ 独立）：设 $\mathcal{G}_1, \mathcal{G}_2$ 为概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 中两个子 σ -代数。任给可积的（或非负的）随机变量 X ，假设 X 与 $\mathcal{G}_2$ 关于 $\mathcal{G}_1$ 条件独立：

$$\mathbb{P}(\{X \leq x\} \cap A|\mathcal{G}_1) = \mathbb{P}(X \leq x|\mathcal{G}_1) \cdot \mathbb{P}(A|\mathcal{G}_1), \quad \forall x \in \mathbb{R}, A \in \mathcal{G}_2,$$

那么 $\mathbb{E}[X|\mathcal{G}_1 \vee \mathcal{G}_2] = \mathbb{E}[X|\mathcal{G}_1]$ 。

习题 7.23. 区间 D 上的凸函数 $\varphi: D \rightarrow \mathbb{R}$ 具有如下性质（假定 $D^\circ \neq \emptyset$ ）：令 $S = \{(a, b) \in \mathbb{Q}^2 : ax + b \leq \varphi(x), \forall x \in D\}$ ，则

$$\varphi(x) = \sup_{(a,b) \in S} [ax + b].$$

概率学家 Durrett 建议基于此给出条件数学期望的 Jensen 不等式的证明，你知道如何落实这个证明吗？

习题 7.24. 设 Y 是一个有二阶矩的随机变量， $\mathcal{G}$ 是一个子 σ -代数，我们记 $\text{Var}(Y|\mathcal{G}) := \mathbb{E}[(Y - \mathbb{E}[Y|\mathcal{G}])^2|\mathcal{G}]$ 。求证：

$$\text{Var}(Y) = \mathbb{E}[\text{Var}(Y|\mathcal{G})] + \text{Var}(\mathbb{E}[Y|\mathcal{G}]).$$

第八章 随机变量及其分布律 (II)

在第五章我们介绍了随机变量/向量的概念和离散型随机变量/向量。在本章我们继续介绍一类重要的随机变量/向量：**连续型随机变量/向量**，它们对应的分布称为**连续型分布**，其严谨定义将涉及 Lebesgue 测度及 Lebesgue 积分。本章中 $\mathbb{R}^n$ 的可测子集 D 的 Lebesgue 测度 $\text{Leb}(D)$ 有时也简单地记作 $|D|$ 。

离散型随机变量与连续型随机变量是初等概率论中最重要的一类随机变量；它们对应的复合随机变量的分布律或其他一些统计特征量（如均值、方差、协方差）的计算（包括基于分布律等的计算来论证或否定独立性等）是初等概率论中的典型问题，需要读者认真学习掌握相关的理论与方法。

8.1 连续型随机变量的有关基本概念

8.1.1 连续型分布与密度函数的定义

最容易理解的连续型分布发生在几何概率模型中，那里本质上定义了某区域上的均匀分布。

例 8.1. 设 $D \subset \mathbb{R}^n$ 是 $\mathbb{R}^n$ 中 Borel 可测集，且 $0 < |D| < \infty$ 。取 $\mathcal{B}_D = \mathcal{B}(D)$ 为 D 的所有 Borel 可测子集全体。于是可以取概率空间 $(\Omega, \mathcal{F}, \mathbb{P}) := (D, \mathcal{B}_D, m_D)$ 是样本空间为 $\Omega := D$ 的几何概率模型，此处

$$\mathbb{P}(A) = m_D(A) := \frac{|A \cap D|}{|D|}, \forall A \in \mathcal{F}.$$

定义 $X(\omega) := \omega, \forall \omega \in D$ ，取 $\rho_D(x) := 1_D(x)/|D|$ ，则

$$\mathbb{P}(X \in A) = m_D(A) = \int_A \rho_D(x) dx.$$

更一般地，对于任何概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 中的 n 维随机向量 X ，如果它满足

$$\mathbb{P}(X \in A) = \int_A \rho_D(x) dx, \forall A \in \mathcal{B}^n,$$

我们就称 X 服从 D 上的均匀分布, 记作 $X \sim U(D)$, 同时也称 ρ_D 为 X 的(概率)密度函数。

例 8.2. 对于 $D = (0, 1)$, 上例中构建了一个概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 及其中一个服从 $(0, 1)$ 上均匀分布的特殊随机变量 X , 我们记 $X \sim U(0, 1)$; 有时我们把它称为标准均匀分布。此时它的密度函数为 $\rho_D(x) = 1_{(0,1)}(x)$. 这个随机变量的分布函数为

$$F(x) := \mathbb{P}(X \leq x) = \int_{(-\infty, x]} 1_{(0,1)}(x) dx = x, \quad \forall x \in [0, 1].$$

亦即

$$F(x) = \begin{cases} 0, & \text{如果 } x \leq 0, \\ x, & \text{如果 } 0 < x \leq 1, \\ 1, & \text{如果 } x > 1. \end{cases}$$

容易知道, 随机变量 $Y := 2X \pmod{1}$ 也是一个服从 $(0, 1)$ 上均匀分布的随机变量。这表明: 随机变量的分布律信息通常不足以决定随机变量的映射法则。

对于 $a < b$, 我们把 (a, b) 上均匀分布记作 $U(a, b)$. 容易知道, 它的密度函数为 $\frac{1}{b-a} \cdot 1_{(a,b)}(x)$. 另外, 如果 $X \sim U(0, 1)$, 那么 $a + (b-a) \cdot X \sim U(a, b)$.

类似于上述均匀分布随机变量, 我们可以定义更一般的具有密度函数的随机变量, 即所谓的连续型随机变量。

定义 8.1.1. 给定可测函数 $\rho: \mathbb{R}^n \rightarrow \mathbb{R}$, 如果随机向量 X 满足

$$\mathbb{P}(X \in A) = \int_A \rho(x) dx, \quad \forall A \in \mathcal{B}^n, \quad (8.1)$$

则称 ρ 是 X 的(联合)密度函数; 此时我们认为 X 是连续型随机向量(当 $n = 1$ 时就称为连续型随机变量)。

根据实变函数中 Lebesgue 积分的理论(参见本讲义第四章), 不难知道上述概率密度函数 ρ 一定是非负可测函数, 并且

$$\int_{\mathbb{R}^n} \rho(x) dx = 1. \quad (8.2)$$

很多时候, 我们也把具有性质(8.2)的非负可测函数 ρ 直接称为 $\mathbb{R}^n$ 上的(概率)密度函数, 简称密度。显然, 满足(8.1)的非负可测函数 ρ (即随机变量 X 的密度函数)实际上不是唯一的, 它只是在 Lebesgue 几乎处处相等的意义下唯一。

以下我们简略地探讨一维随机变量 X 的分布函数 F 具有何种性质时就能确保 X 是一个连续型随机变量。这个问题的准确陈述如下: 给定一维随机变

量 ξ 的分布函数 $F(x) := \mathbb{P}(X \leq x)$, 何时存在 $\rho \in L^1(\mathbb{R})$, 使得

$$F(x) = \int_{-\infty}^x \rho(t) dt, \quad \forall x \in \mathbb{R}. \quad (8.3)$$

定理4.3.8告诉我们, 这等价于要求 F 是绝对连续函数; 此时 $\rho = F'$ 几乎处处成立。

📌 注记 8.1. 在概率论发展的早期, 人们也用连续随机变量 (或连续型随机变量) 的术语用以指代那些可以连续取值的随机变量 (实际亦即不是离散型随机变量的那些随机变量). 从一些非常早期的概率论或数理统计方向的文献中可以知道, 最初人们误以为分布函数连续的随机变量总是有密度函数的; 后来实变函数的发展澄清了这个错误认知, 现代概率论中把具有密度函数的那些随机变量 (亦即对应分布测度关于 *Lebesgue* 测度绝对连续的那些随机变量) 统称为绝对连续型随机变量, 在本讲义中则把这类随机变量简称为连续型随机变量, 而废弃“连续随机变量”的讲法。在第九章中我们将更细致地讨论随机变量的分类问题。

在本书中, 为了节约语言, 当连续型随机变量/向量 X 的 (联合) 密度函数为 ρ 时, 我们将简单记作

$$X \sim \rho(x) dx.$$

同样根据测度论的理论 (参见本讲义第四章), 不难知道下面定理成立:

♠ 定理 8.1.1. d 维随机向量 X 具有密度函数, 当且仅当它的分布测度 μ_X 满足 $\mu_X \ll \text{Leb}$, 亦即如下条件成立: 对任意 $A \in \mathcal{B}^d$, 如果 $\text{Leb}(A) = 0$, 则 $\mathbb{P}(X \in A) = 0$.

8.1.2 连续型随机变量的数学期望计算公式

假设有连续型随机变量/向量 X , 其中 $X \sim \rho(x) dx$.

给定可测函数 φ , 假设我们可以定义复合随机变量 $Y := \varphi(X)$. 根据数学期望的计算公式(6.21), 我们立即得到 Y 的数学期望的计算公式:

$$\mathbb{E}[\varphi(X)] = \int \varphi(x) \rho(x) dx, \quad (8.4)$$

只要可测函数 φ 使得上述公式右端的积分有意义。读者也可以直接从等式

$$\mathbb{E}[1_A(X)] = \mathbb{P}(X \in A) = \int 1_A(x) \rho(x) dx, \quad \forall A \in \mathcal{B}$$

出发, 结合单调类定理和数学期望的定义流程来证明公式(8.4).

8.1.3 边缘密度、条件密度与条件分布函数

设 $d \geq 2$, 且 d 维随机行向量 $X = (X_1, \dots, X_d)$ 是以 ρ 为联合密度函数的连续型随机向量。容易知道每个分量 X_i 仍然是连续型随机变量, 具有密度 ρ_i , 即 $X_i \sim \rho_i(x_i)dx_i$, 其中

$$\rho_i(x_i) = \int_{\mathbb{R}^{d-1}} \rho(x) dx_1 \cdots \widehat{dx_i} \cdots dx_d.$$

上式中, $\widehat{dx_i}$ 表示积分表达式中把 dx_i 项去掉。此处, 我们称 ρ_i 为随机行向量 $X = (X_1, \dots, X_d)$ (或联合密度 ρ) 的第 i 个边缘分布密度, 简称边缘分布密度。一般地, 对任意 $2 \leq n < d$, 以及 $1 \leq j_1 < \dots < j_n \leq d$, $(X_{j_1}, \dots, X_{j_n})$ 仍然是连续型随机向量, 它对应的联合分布密度也称为边缘分布密度。

设 $(X, Y) \sim \rho(x, y)dx dy$, 即随机 (行) 向量 (X, Y) 是连续型的, 并且具有联合密度函数 ρ . 这时不难证明, $X \sim \rho_X(x)dx, Y \sim \rho_Y(y)dy$, 其中

$$\rho_X(x) = \int \rho(x, y)dy, \quad \rho_Y(y) = \int \rho(x, y)dx. \quad (8.5)$$

我们定义 (下式中约定 $\frac{0}{0} = 0, \frac{1}{0} = \infty, 0 \cdot \infty = 0$)

$$\rho_{X|Y}(x|y) := 1_{\{\rho_Y(y) > 0\}} \cdot \frac{\rho(x, y)}{\rho_Y(y)}. \quad (8.6)$$

不难知道, 对 Lebesgue a.e. (x, y) , $\rho_{X|Y}(x|y)$ 只取有限值。根据条件分布函数 $F_{X|Y}(\cdot|\cdot)$ 的定义 (参见定义 7.3.1), 注意到 $Y \sim \rho_Y(y)dy$

$$\mathbb{P}(X \leq x, Y \in A) = \int_A F_{X|Y}(x|y) \rho_Y(y) dy.$$

但此处 $(X, Y) \sim \rho(x, y)dx dy$, 于是我们知道

$$\begin{aligned} \mathbb{P}(X \leq x, Y \in A) &= \int_A \left[\int_{-\infty}^x \rho(u, v) du \right] dv \\ &= \int_A \left[\int_{-\infty}^x \rho_{X|Y}(u|v) du \right] \rho_Y(v) dv. \end{aligned}$$

前后两个方程结合起来, 并注意到 A 的任意性, 我们得到

$$F_{X|Y}(x|y) = \int_{-\infty}^x \rho_{X|Y}(u|y) du \quad (8.7)$$

对 Lebesgue 几乎处处的 $y \in \{y : \rho_Y(y) > 0\}$ 成立。 $F_{X|Y}(x|y)$ 是 X 关于 $Y = y$ 的条件分布函数; 固定 y , 关于自变量 x , 函数 $F_{X|Y}(x|y)$ 仍然是一个连续型

分布函数, 对应的密度恰好为 $\rho_{X|Y}(x|y)$, 因此我们把 $\rho_{X|Y}(x|y)$ 称为 X 关于 $Y = y$ 的条件分布密度, 记作

$$X|Y = y \sim \rho_{X|Y}(x|y)dx. \quad (8.8)$$

现在, 在 (X, Y) 联合分布是连续型的情形下, 我们来讨论条件数学期望的计算问题。

例 8.3. 设 (X, Y) 具有联合密度 ρ , 从而 X 与 Y 分别具有边缘密度 ρ_X, ρ_Y :

$$\rho_X(x) := \int \rho(x, y)dy, \quad \rho_Y(y) := \int \rho(x, y)dx.$$

由此不难知道, 对任意非负可测或有界可测函数 φ , 我们有

$$\mathbb{E}[\varphi(X, Y)|Y = y] = \int \varphi(x, y)\rho_{X|Y}(x|y)dx, \quad (8.9)$$

其中

$$\rho_{X|Y}(x|y) := 1_{\{\rho_Y(y) > 0\}} \cdot \frac{\rho(x, y)}{\rho_Y(y)}$$

恰为我们刚刚介绍的 X 关于 Y 的条件分布密度函数。上述条件数学期望 $\mathbb{E}[\varphi(X, Y)|Y = y]$ 的计算公式与无条件数学期望的计算公式在形式上是一致的, 只是密度上做了调整。

另外, 也有人按如下方式来解释条件数学期望 $\mathbb{E}[\varphi(X, Y)|Y = y]$:

$$\mathbb{E}[\varphi(X, Y)|Y = y] = \lim_{\delta \downarrow 0} \mathbb{E}[\varphi(X, Y)|Y \in (y - \delta, y + \delta)]. \quad (8.10)$$

读者可以证明, 在本例中, 上式对 Lebesgue 几乎处处的 y 成立; 对于一般情况上式 (有些文献把这个式子称为 **Borel Density Lemma**) 本质上关于 μ_Y 几乎处处的 y 成立 (其中 μ_Y 是 Y 的分布测度), 这个结果的严格证明具有一定难度。对于条件分布函数和条件密度函数, 也有类似的解释。

对于两个随机变量 X, Y , 如果 $(X, Y) \sim \rho(x, y)dx dy$, 实变函数的理论告诉我们: 对 Lebesgue 几乎处处的 $y \in \{y : \rho_Y(y) > 0\}$, 极限

$$F_{X|Y}(x|y) := \lim_{\varepsilon \downarrow 0} \mathbb{P}(X \leq x | Y \in (y - \varepsilon, y + \varepsilon)) \quad (8.11)$$

存在, 并且 $F_{X|Y}(x|y) = \int_{-\infty}^x \rho_{X|Y}(t|y)dt$. 这个结果的证明留给读者思考。

关于两个连续型随机变量/向量之间的独立性, 我们有下列的结果; 这是定理 5.1.2 结合密度函数定义的简单推论, 因此此处的证明留给读者。

♠ **定理 8.1.2.** 假设 $X_i \sim \rho_i(x_i)dx_i, i = 1, 2$. 则 X_1 与 X_2 相互独立的充分必要条件是: (X_1, X_2) 仍然是连续型分布, 并且对应的联合密度函数为

$$\rho(x_1, x_2) = \rho_1(x_1) \cdot \rho_2(x_2). \quad (8.12)$$

上述等号是在 *Lebesgue* 几乎处处相等意义下理解的。上述联合密度函数满足的条件也等价于

$$\rho_{x_1|x_2}(x_1|x_2) = \rho_1(x_1), \quad (8.13)$$

即“条件密度”等于“无条件密度”; 同样, (8.13)是在 *Leb-a.e.* 的 x_1 及 *Leb-a.e.* 的 $x_2 \in \{x_2 : \rho_2(x_2) > 0\}$ 处相等的意义下理解的。

8.2 概率微元法

在初等概率论中, 经常要考虑连续型随机变量/向量经过光滑 (或分片光滑) 映射变成新的随机变量/向量后的分布律的计算问题。本节的目的就是为此提供有关的理论推导与计算方法。

首先做一些记号上的约定。当 $X \sim \rho(x)dx$ 时, 我们知道

$$\mathbb{P}(X \in A) = \int_A \rho(x)dx, \quad \forall \text{ 可测集 } A. \quad (8.14)$$

我们认为, 上式对应的“概率微元”形式的表达式为

$$\mathbb{P}(X = x + dx) = \rho(x)dx, \quad (8.15)$$

其中 $x + dx$ 理解为 x 处的一个“微分形式”的“平行四边形” (含“矩形”), 我们称之为“微元区域”; x 点在这个“微元区域”的边界或内部均可。而关系 $X = x + dx$ 应理解为 $X \in x + dx$, 即随机变量/向量 X 落入这个“微元区域”中。上述方程的右端项 dx 理解为“微元区域” $x + dx$ 的体积。

基于上述约定, 我们来进行前述问题的探讨, 即考虑 $Y := \varphi(X)$ 的分布律的计算。我们总假设对某区域 $\mathcal{D} \subset \mathbb{R}^d$

$$\mathbb{P}(X \in \mathcal{D}) = 1. \quad (8.16)$$

8.2.1 光滑可逆变换情形

现在假定 $\varphi : \mathcal{D} \rightarrow \mathbb{R}^d$ 可逆, 并且 $\varphi^{-1} : \varphi(\mathcal{D}) \rightarrow \mathcal{D}$ 光滑。此时, 记 D 为导算子, 我们有下面的形式演算:

$$\mathbb{P}(Y = y + dy) = \mathbb{P}(\varphi(X) = y + dy) = \mathbb{P}(X = \varphi^{-1}(y + dy))$$

$$\begin{aligned}
&= \mathbb{P}(X = \varphi^{-1}(y) + D\varphi^{-1}(y)\mathrm{d}y) \quad (\text{Taylor 公式}) \\
&= \rho(\varphi^{-1}(y)) \cdot |\det(D\varphi^{-1}(y))|\mathrm{d}y.
\end{aligned}$$

上述形式演算告诉我们, $Y := \varphi(X)$ 的分布密度为

$$\rho_Y(y) = \rho(\varphi^{-1}(y)) \cdot |\det(D\varphi^{-1}(y))|.$$

以上形式演算实际上是可以严谨化的 (特别注意, 以下积分都是 Lebesgue 积分):

$$\begin{aligned}
&\mathbb{P}(\varphi(X) \in A) = \mathbb{P}(X \in \varphi^{-1}(A)) \\
&= \int_{\varphi^{-1}(A)} \rho(x)\mathrm{d}x \quad (X \sim \rho(x)\mathrm{d}x \text{ 的定义(8.14)}) \\
&= \int_A \rho(\varphi^{-1}(y)) \cdot |\det(D\varphi^{-1}(y))|\mathrm{d}y \quad (\text{换元 } x = \varphi^{-1}(y)).
\end{aligned}$$

于是我们有下面的定理。

♠ **定理 8.2.1.** X 是 d 维随机向量, 可测集 $\mathcal{D} \subset \mathbb{R}^d$ 满足 $\mathbb{P}(X \in \mathcal{D}) = 1$. 又设 $\varphi: \mathcal{D} \rightarrow \mathbb{R}^d$ 是可测单射, 并且 $\varphi^{-1}: \varphi(\mathcal{D}) \rightarrow \mathcal{D}$ 光滑, 那么当 $X \sim \rho(x)\mathrm{d}x$ 时, $Y := \varphi(X)$ 的密度函数为

$$\rho_Y(y) = \rho(\varphi^{-1}(y)) \cdot |\det(D\varphi^{-1}(y))|. \quad (8.17)$$

🔔 **注 8.1.** 定理 8.2.1 中, $\det(D\varphi^{-1}(y))$ 称为变换 φ^{-1} 在 y 处的 *Jacobi* 行列式. *Jacobi* 矩阵与 *Jacobi* 行列式是由德国数学家 *Carl Gustav Jacob Jacobi* (1804—1851) 提出的, 他在椭圆函数、动力学、微分方程、行列式和数论等方面做出了重要贡献。

8.2.2 分片光滑可逆变换情形

很多时候, 我们遇到的变换并不是可逆变换, 而是分片可逆的。一个典型的一维例子是

$$\varphi: \mathbb{R} \rightarrow \mathbb{R}_+ := [0, \infty), x \mapsto x^2.$$

我们可以取 $\mathcal{D}_1 := (0, \infty)$, $\mathcal{D}_2 := (-\infty, 0)$, 及 $\varphi_i := \varphi|_{\mathcal{D}_i}$, $i = 1, 2$, $\mathcal{D} := \mathcal{D}_1 \cup \mathcal{D}_2$, 则此时对连续型随机变量 X 有 $\mathbb{P}(X \in \mathcal{D}) = 1$, 并且 φ_i 都是可逆映射,

$$\varphi_1^{-1}(y) := \sqrt{y}, y \in (0, \infty), \quad \varphi_2^{-1}(y) := -\sqrt{y}, y \in (0, \infty).$$

$\varphi_1^{-1}, \varphi_2^{-1}$ 都有很好的光滑性。另一个典型例子是例 8.2 中提及的变换

$$\varphi: [0, 1) \rightarrow [0, 1), x \mapsto 2x \pmod{1}.$$

显然我们可以取 $\mathcal{D}_1 = [0, 1/2)$, $\mathcal{D}_2 = [1/2, 1)$ 及 $\varphi_i := \varphi|_{\mathcal{D}_i}$, $i = 1, 2$; 此时 φ_i 都是可逆的仿射变换, 请读者自行计算 φ_i^{-1} 的表达式。

现在假定可测映射 φ 分片可逆, 并且它的分片逆映射是光滑的。不妨设

$$\varphi: \mathcal{D} = \mathcal{D}_1 \uplus \mathcal{D}_2 \rightarrow \mathbb{R}^d,$$

其中对于 $i = 1, 2$, $\varphi_i := \varphi|_{\mathcal{D}_i}$ 是单射, 并且 $\varphi_i^{-1}: \varphi(\mathcal{D}_i) \rightarrow \mathcal{D}_i$ 是光滑的。

类似于 (1) 中演算, 我们有

$$\begin{aligned} \mathbb{P}(Y = y + \mathrm{d}y) &= \mathbb{P}(\varphi(X) = y + \mathrm{d}y) \\ &= \sum_{i=1}^2 \mathbb{P}(\varphi(X) = y + \mathrm{d}y, X \in \mathcal{D}_i) \\ &= \sum_{i=1}^2 \mathbb{P}(X = \varphi_i^{-1}(y + \mathrm{d}y), X \in \mathcal{D}_i) \\ &= \sum_{i=1}^2 \mathbb{P}(X = \varphi_i^{-1}(y) + D\varphi_i^{-1}(y)\mathrm{d}y) \cdot 1_{\varphi(\mathcal{D}_i)}(y) \\ &= \left[\sum_{i=1}^2 \rho(\varphi_i^{-1}(y)) \cdot |\det(D\varphi_i^{-1}(y))| \cdot 1_{\varphi(\mathcal{D}_i)}(y) \right] \mathrm{d}y. \end{aligned}$$

上述形式演算告诉我们, $Y := \varphi(X)$ 的分布密度为

$$\rho_Y(y) = \sum_{i=1}^2 \rho(\varphi_i^{-1}(y)) \cdot |\det(D\varphi_i^{-1}(y))| \cdot 1_{\varphi(\mathcal{D}_i)}(y).$$

请读者验证: 上述形式演算也是可以严谨化的。于是我们得到下面的定理。

♠ **定理 8.2.2.** X 是 d 维随机向量, 可测集 $\mathcal{D} \subset \mathbb{R}^d$ 满足 $\mathbb{P}(X \in \mathcal{D}) = 1$. 又设存在可测集列 $\{\mathcal{D}_i\}_{i=1}^N$ 使得 $\mathcal{D} = \biguplus_{i=1}^N \mathcal{D}_i$, 且可测映射 $\varphi: \mathcal{D} \rightarrow \mathbb{R}^d$ 满足: 对任意 $1 \leq i \leq N$, $\varphi_i := \varphi|_{\mathcal{D}_i}$ 是单射并且 $\varphi_i^{-1}: \varphi(\mathcal{D}_i) \rightarrow \mathcal{D}_i$ 光滑, 那么当 $X \sim \rho(x)\mathrm{d}x$ 时, $Y := \varphi(X)$ 的密度函数为

$$\rho_Y(y) = \sum_{i=1}^N \rho(\varphi_i^{-1}(y)) \cdot |\det(D\varphi_i^{-1}(y))| \cdot 1_{\varphi(\mathcal{D}_i)}(y). \quad (8.18)$$

下面推论的证明留给读者。

☞ **推论 8.2.1.** 假设 $X_i \sim \rho_i(x_i)\mathrm{d}x_i$, $i = 1, 2$, 并且 X_1 与 X_2 相互独立。令 $Y_1 = X_1 + g(X_2)$, 其中 g 为光滑函数。则 Y_1 关于 $Y_2 := X_2$ 的条件密度为

$$\rho_{Y_1|Y_2}(y_1|y_2) = \rho_1(y_1 - g(y_2)).$$

定义 8.2.1. 假设 $X_i \sim \mu_i, i = 1, 2$. 如果存在非负(二元)可测函数 $\rho_{X_1|X_2}(x_1|x_2)$ 使得: 对任意可测集 A_1, A_2

$$\mathbb{P}(X_1 \in A_1, X_2 \in A_2) = \int_{A_2} \left[\int_{A_1} \rho_{X_1|X_2}(x_1|x_2) dx_1 \right] d\mu_2(x_2), \quad (8.19)$$

则称 $\rho_{X_1|X_2}(\cdot|\cdot)$ 为 X_1 关于 X_2 的条件密度, 记作

$$X_1|X_2 = x_2 \sim \rho_{X_1|X_2}(x_1|x_2)dx_1. \quad (8.20)$$

由第七章的定义7.3.1, 我们容易知道, 上述条件分布密度的概念是有意义的, 它完全由随机向量的联合分布律决定。

在上述推广了的条件密度的概念下, 我们其实有比上述推论8.2.1的更好结果, 它放弃了推论中的函数 g 的光滑性和 X_2 具有分布密度的要求, 见下面的定理。

♠ **定理 8.2.3.** 设 $X_1 \sim \rho_1(x)dx$, g 是可测函数。如果 X_1 与 X_2 相互独立, 那么 $Y_1 := X_1 + g(X_2)$ 关于 $Y_2 := X_2$ 的条件密度函数存在, 它正好是

$$\rho_{Y_1|Y_2}(y_1|y_2) = \rho_1(y_1 - g(y_2)).$$

参考证明: 由推论7.3.1立即知道: 对 μ_{Y_2} -a.e. 的 y

$$(Y_1|Y_2 = y) \stackrel{d}{=} (X_1 + g(y)),$$

而 $X_1 \sim \rho_1(x)dx$, 因此 $X_1 + g(y) \sim \rho_1(x - g(y))dx$. 于是定理的结论成立。□

不难证明, 下面的结论也成立:

♠ **定理 8.2.4.** 设 $X|Y = y \sim \rho(x|y)dx$, 那么 X 是连续型随机变量/向量, 其密度函数可以按如下公式计算:

$$\rho_X(x) = \mathbb{E}[\rho(x|Y)]. \quad (8.21)$$

8.3 常见连续型分布

在本章的第一节开头, 我们就给出了均匀分布的概念。在本小节, 我们将介绍更多的常见的连续型分布。

我们先探讨两个连续型随机变量独立和 $X_1 + X_2$ 的分布与和项 X_1, X_2 的分布之间的关系。

例 8.4. (连续型随机变量的独立和的分布律) 给定两个相互独立的连续型随机变量 X_1, X_2 , 假设

$$X_1 \sim \rho_1(x)dx, \quad X_2 \sim \rho_2(x)dx.$$

那么 $Y := X_1 + X_2 \sim \rho(x)dx$, 其中

$$\rho(x) = \rho_1 * \rho_2(x) := \int \rho_1(t)\rho_2(x-t)dt = \int \rho_1(x-t)\rho_2(t)dt.$$

参考证明: 这里, 注意到定理8.1.2, 我们可以直接进行计算:

$$\begin{aligned} \mathbb{P}(Y \leq x) &= \mathbb{P}(X_1 + X_2 \leq x) \\ &= \int_{\mathbb{R}^2} 1_{\{x_1+x_2 \leq x\}} \cdot \rho_1(x_1) \cdot \rho_2(x_2) dx_1 dx_2 \\ &= \int \left[\int 1_{\{x_1+x_2 \leq x\}} \cdot \rho_1(x_1) \cdot \rho_2(x_2) dx_2 \right] dx_1 \\ &\stackrel{x_2=s-x_1}{=} \int \left[\int 1_{\{s \leq x\}} \cdot \rho_1(x_1) \cdot \rho_2(s-x_1) ds \right] dx_1 \\ &= \int_{-\infty}^x \left[\int \rho_1(x_1) \cdot \rho_2(s-x_1) dx_1 \right] ds \\ &= \int_{-\infty}^x \rho_1 * \rho_2(s) ds. \end{aligned}$$

上述方程中, 第三个等号使用了 Fubini 定理化重积分为累次积分, 第四个等号是对内层的积分施行了换元, 第五个等号使用了 Fubini 定理实现两重积分的交换次序, 最后一个等号是利用了分析学中函数卷积的定义。因此本例中的结论成立。□

上面的例子表明, 两个连续型随机变量的独立和仍然是连续型的。但实际上, 对于随机变量的独立和, 只要其中某一个随机变量是连续型的, 那么独立和就仍然是连续型的; 参见下例中的结论与证明。

例 8.5. 设随机变量 X_1, X_2 相互独立, 其中 $X_1 \sim \rho_1(x)dx$, $X_2 \sim \mu_2$. 那么 $Y := X_1 + X_2$ 是连续型随机变量, 具有密度 ρ_Y :

$$\rho_Y(x) = \rho_1 * \mu_2(x) := \int \rho_1(x-t)d\mu_2(t).$$

这个结论的一种证明方法与上一例类似, 有关细节留给读者思考。此处我们提供另一种借助推论7.3.1的结论结合定理8.2.4来完成计算与论证的方法: 由于 X_1, X_2 相互独立, $X_1 \sim \rho_1(x)dx$, 我们有

$$(Y|X_2 = t) \stackrel{d}{=} X_1 + t \sim \rho_1(x-t)dx.$$

而 $X_2 \sim \mu_2$, 因此

$$\rho_Y(x) = \mathbb{E}[\rho_1(x - X_2)] = \int \rho_1(x - t) d\mu_2(t).$$

例 8.6. (指数分布 $\mathcal{E}(\lambda)$) 给定 $\lambda > 0$; $1/\lambda$ 视作尺度参数。设 $U \sim U(0, 1)$, 取

$$X := -(\ln U)/\lambda,$$

则容易知道 X 的分布函数为

$$F_\lambda(x) := \mathbb{P}(X \leq x) = (1 - e^{-\lambda x})^+, \text{ 其中 } x \in \mathbb{R}.$$

它是一个连续型分布, 具有密度函数

$$\rho(x; \lambda) = \lambda e^{-\lambda x} \cdot 1_{(0, \infty)}(x).$$

分布 F_λ 称为参数为 λ 的**指数分布**; 在本书中我们简单记作: $X \sim \mathcal{E}(\lambda)$. 易知

$$\mathbb{P}(X > t) = e^{-\lambda t}, \quad \forall t \geq 0.$$

特别地, 我们称 $\mathcal{E}(1)$ 为**标准指数分布**。

例 8.7. (指数分布的无记忆性) 设 ξ 代表了教室里的日光灯的寿命 (假定从不熄灯, 除非日光灯坏了, 那时认为日光灯寿终正寝了). 到 $t > 0$ 时刻日光灯仍然正常工作, 这个事件表示为 $\{\xi > t\}$; 此时我们称 $\xi_t := \xi - t$ 是 t 时刻日光灯的**剩余寿命**. 姑且假设 $\xi \sim \mathcal{E}(\lambda)$ (尽管对现实生活中的日光灯来说我们后面将看到该假设的不合理性), 我们计算在 t 时刻日光灯仍然正常工作的条件下它的剩余寿命的分布如下: 对任意 $s > 0$

$$\begin{aligned} \mathbb{P}(\xi_t > s | \xi > t) &= \mathbb{P}(\xi > s + t | \xi > t) = \frac{\mathbb{P}(\xi > s + t)}{\mathbb{P}(\xi > t)} \\ &= \frac{e^{-\lambda(s+t)}}{e^{-\lambda t}} = e^{-\lambda s} = \mathbb{P}(\xi_0 > s). \end{aligned}$$

这表明, 在 t 时刻日光灯仍然正常工作的条件下它的剩余寿命就如同它没有使用过一样¹, 仍然服从指数分布 $\mathcal{E}(\lambda)$. 也就是说, 指数分布总满足下面的方程

$$\mathbb{P}(\xi > s + t | \xi > t) = \mathbb{P}(\xi > s), \quad \forall s, t \geq 0. \quad (8.22)$$

这个性质就称为**指数分布的无记忆性**。

¹这当然违背了我们关于日光灯的常识和直观; 此处我们以日常生活中随处可见的日光灯为背景, 只是为了借用其寿命、剩余寿命的直观。

例 8.8. (Erlang 分布, $\Gamma(n, \lambda)$ 分布) 现在假设 $\{X_i\}_{i=1}^n \stackrel{\text{i.i.d.}}{\sim} \mathcal{E}(\lambda)$. 定义 $S_n := X_1 + \cdots + X_n$, 则 S_n 的分布密度为

$$\rho_n(x; \lambda) = \frac{\lambda^n x^{n-1}}{(n-1)!} \cdot e^{-\lambda x} \cdot 1_{(0, \infty)}(x).$$

这是下面将要介绍的 *Gamma* 分布族中的 $\Gamma(n, \lambda)$ 分布, 在有的文献中也称为 *Erlang* (爱尔朗) 分布; 其中 n 视作自由度参数, $1/\lambda$ 视作尺度参数。

参考证明: 本例中的密度 ρ_n 的计算可以利用例 8.4 中结论通过归纳法来完成证明; 也可以在后面的 *Gamma* 分布的半生成性的基础上来实现计算。有关细节留给读者。 $\square$

例 8.9. (*Gamma* 分布及其半生成性) 对任意给定的 $\alpha > 0, \lambda > 0$

$$\rho(x; \alpha, \lambda) := \frac{\lambda^\alpha \cdot x^{\alpha-1}}{\Gamma(\alpha)} \cdot e^{-\lambda x} \cdot 1_{(0, \infty)}(x)$$

是一个密度函数。我们称这个密度函数对应的分布为 $\Gamma(\alpha, \lambda)$ 分布, 简称 *Gamma* (伽马) 分布; 其中 α 视作“自由度”参数, $1/\lambda$ 视作尺度参数。

设 $X_i \sim \Gamma(\alpha_i, \lambda), i = 1, 2$, 且 X_1 与 X_2 独立, 则

$$X_1 + X_2 \sim \Gamma(\alpha_1 + \alpha_2, \lambda).$$


这个性质称为 *Gamma* 分布的半生成性。

参考证明: 本例中 $\rho(x; \alpha, \lambda)$ 是密度函数的证明不难, 细节留给读者。

以下我们论证例中提及的 *Gamma* 分布的半生成性。根据例 8.4 的结论, 记 $\rho_i(x) := \rho(x; \alpha_i, \lambda), i = 1, 2$, 我们计算卷积如下: 不妨设 $x > 0$

$$\begin{aligned} \rho_1 * \rho_2(x) &= \int \rho_1(t) \rho_2(x-t) dt \\ &= \int \frac{\lambda^{\alpha_1+\alpha_2} t^{\alpha_1-1} (x-t)^{\alpha_2-1}}{\Gamma(\alpha_1) \Gamma(\alpha_2)} \cdot e^{-\lambda x} \cdot 1_{(0, \infty)}(t) \cdot 1_{(0, \infty)}(x-t) dt \\ &\stackrel{t=xu}{=} \frac{\lambda^{\alpha_1+\alpha_2} \cdot x^{\alpha_1+\alpha_2-1}}{\Gamma(\alpha_1) \Gamma(\alpha_2)} \cdot e^{-\lambda x} \cdot \int_0^1 u^{\alpha_1-1} (1-u)^{\alpha_2-1} du \\ &= \frac{\lambda^{\alpha_1+\alpha_2} \cdot x^{\alpha_1+\alpha_2-1}}{\Gamma(\alpha_1) \Gamma(\alpha_2)} \cdot e^{-\lambda x} \cdot B(\alpha_1, \alpha_2) \\ &= \frac{\lambda^{\alpha_1+\alpha_2} \cdot x^{\alpha_1+\alpha_2-1}}{\Gamma(\alpha_1 + \alpha_2)} \cdot e^{-\lambda x} = \rho(x; \alpha_1 + \alpha_2, \lambda). \end{aligned}$$

当 $x \leq 0$ 时 $\rho_1 * \rho_2(x) = 0$. 因此本例中结论成立。 $\square$

图 8.1: $Beta(\frac{1}{2}, \frac{1}{2})$ 分布密度函数图

例 8.10. (Beta 分布) 对任意给定的 $\alpha > 0, \beta > 0$

$$\rho(x; \alpha, \beta) := \frac{x^{\alpha-1}(1-x)^{\beta-1}}{B(\alpha, \beta)} \cdot 1_{(0,1)}(x)$$

是一个密度函数。我们称这个密度函数对应的分布为 $Beta(\alpha, \beta)$ 分布, 简称 $Beta$ (贝塔) 分布; 其中, 由于 $Beta(\frac{1}{2}, \frac{1}{2})$ 分布的分布函数在 $[0, 1]$ 上为

$$F(x) = \frac{2}{\pi} \arcsin \sqrt{x},$$

这个分布又称为反正弦律。参数 α, β 取自然数的 $Beta$ 分布将在第九章讨论均匀分布 $U(0, 1)$ 的次序统计量的分布律问题中出现。

以下我们先从一维标准正态分布开始来系统介绍正态分布及其相关分布。

例 8.11. (一维标准正态分布) 容易知道

$$\varphi(x) := \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$

是一个密度函数; 我们把这个密度对应的分布称为 (一维) 标准正态分布, 记作 $N(0, 1)$. 它对应的分布函数通常记作 Φ , 即

$$\Phi(x) := \int_{-\infty}^x \varphi(x) dx = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx.$$

设 $Z \sim N(0, 1)$, 通过简单计算我们知道: 对任意整数 $n \geq 1$

$$\mathbb{E}[Z^{2n-1}] = 0, \quad \mathbb{E}[Z^{2n}] = (2n-1)!! \quad (8.23)$$

此处对整数 $n \geq 1$, $(2n-1)!! := 1 \cdot 3 \cdots (2n-1)$, $(2n)!! := 2 \cdot 4 \cdots (2n)$. 因此, $\mathbb{E}Z = 0$, $\text{Var}(Z) = \mathbb{E}[Z^2] = 1$.





图 8.2: 一维标准正态分布密度函数图

图 8.3: 一维正态分布 $N(0, \sigma^2)$ 密度函数图

例 8.12. (一维正态分布) 设 $Z \sim N(0, 1)$. 给定 $\mu \in \mathbb{R}, \sigma > 0$, 定义

$$X := \mu + \sigma Z.$$

容易知道 X 的密度函数为

$$\rho(x; \mu, \sigma^2) := \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}.$$

我们把这个密度对应的分布称为以 μ 为均值参数, 以 σ^2 为方差参数的正态分布 (简称正态分布), 记作 $N(\mu, \sigma^2)$. 不难知道, 当 $X \sim N(\mu, \sigma^2)$ 时

$$\mathbb{E}X = \mu, \quad \text{Var}(X) = \sigma^2.$$

在讲高维正态分布之前, 我们先介绍随机向量的协方差矩阵的概念。设

$X = (X_1, \dots, X_n)^T$ 为 n 维随机列向量。如果对任意 $1 \leq i, j \leq n$,

$$\sigma_{i,j} := \text{Cov}(X_i, X_j)$$

都存在, 则我们定义 X 的协方差矩阵为矩阵 $\Sigma := (\sigma_{i,j})_{1 \leq i, j \leq n}$. 有时仍然把 X 的协方差矩阵记作 $\text{Var}(X) := \Sigma$.

对随机列向量 $X = (X_1, \dots, X_n)^T$, 记 $\mathbb{E}X := (\mathbb{E}X_1, \dots, \mathbb{E}X_n)^T$, 易知

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}X)(X - \mathbb{E}X)^T]. \quad (8.24)$$

上式右端的含义是: 对任意 i, j 指标, 计算出“随机矩阵” $(X - \mathbb{E}X)(X - \mathbb{E}X)^T$ 的 (i, j) 元的数学期望, 作为一个新矩阵的 (i, j) 元, 由此得到的新矩阵就视作矩阵形态随机元的数学期望 $\mathbb{E}[(X - \mathbb{E}X)(X - \mathbb{E}X)^T]$.

类似的, 我们还可以定义两个随机列向量 X, Y 之间的协方差矩阵 $\text{Cov}(X, Y)$ (如果下面方程中的数学期望存在)

$$\text{Cov}(X, Y) := \mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)^T]. \quad (8.25)$$

上述方程中数学期望的理解与(8.24)类似。

不难知道, $X \mapsto \mathbb{E}X$ 是线性的, $(X, Y) \mapsto \text{Cov}(X, Y)$ 是 (共轭) 双线性的; 具体陈述如下:

♠ **定理 8.3.1.** 设 X, Y 分别是实数域上的 n 维和 m 维随机列向量; A, B 分别是 $k \times n$ 和 $\ell \times m$ 的常数矩阵; α, β 分别是 k 维和 ℓ 维常数向量。那么

(1) 当 $\mathbb{E}X, \mathbb{E}Y$ 存在时

$$\mathbb{E}[AX + \alpha] = A(\mathbb{E}X) + \alpha, \quad \mathbb{E}[BY + \beta] = B(\mathbb{E}Y) + \beta;$$

(2) 在 (1) 的基础上, 当 $\text{Cov}(X, Y)$ 存在时

$$\text{Cov}(AX + \alpha, BY + \beta) = A\text{Cov}(X, Y)B^T.$$

稍后将看到, 上述性质在高维正态分布的有关讨论中使用起来非常便捷。

♠ **定理 8.3.2.** 设矩阵 $\Sigma = (\sigma_{i,j})_{1 \leq i, j \leq n}$ 是 n 维实随机向量 X 的协方差矩阵, 那么 Σ 是对称、非负定/半正定矩阵。

参考证明: Σ 的对称性是显然的, 以下验证它的非负定/半正定性。取 $a = (a_1, \dots, a_n)^T \in \mathbb{R}^n$, 则

$$a^T \Sigma a = \sum_{1 \leq i, j \leq n} \sigma_{i,j} a_i a_j = \sum_{1 \leq i, j \leq n} \text{Cov}(X_i, X_j) a_i a_j$$

$$\begin{aligned}
&= \mathbb{Cov}\left(\sum_{i=1}^n a_i X_i, \sum_{j=1}^n a_j X_j\right) \\
&= \mathbb{Var}\left(\sum_{i=1}^n a_i X_i\right) \geq 0.
\end{aligned}$$

因此定理结论成立。 $\square$

例 8.13. (高维标准正态分布) 给定正整数 $n \geq 2$. 现在设

$$\{Z_i\}_{i=1}^n \stackrel{\text{i.i.d.}}{\sim} N(0, 1).$$

我们称随机 (列) 向量 $Z := (Z_1, \dots, Z_n)^T$ 服从 n 维标准正态分布, 记作 $N(0, I_n)$. 容易知道 Z 的联合分布密度为

$$\varphi_n(x) := \frac{1}{\sqrt{(2\pi)^n}} \exp \left\{ -\frac{1}{2} \sum_{i=1}^n x_i^2 \right\}.$$




图 8.4: 二维标准正态分布密度函数图

例 8.14. (高维正态分布) 给定正整数 $n \geq 2$. 现在设 $Z \sim N(0, I_n)$. 给定 $\mu \in \mathbb{R}^n$ 以及 n 阶可逆方阵 A , 定义

$$X := \mu + AZ.$$

记 $\Sigma := AA^T$; 它是一个实的对称正定矩阵. 容易知道 X 的密度函数为

$$\rho(x; \mu, \Sigma) := \frac{1}{\sqrt{(2\pi)^n \det(\Sigma)}} \exp \left\{ -\frac{(x - \mu)^T \Sigma^{-1} (x - \mu)}{2} \right\}. \quad (8.26)$$

我们把这个密度对应的分布称为以 μ 为均值参数, 以 Σ 为协方差矩阵参数的高维正态分布 (简称正态分布), 记作 $N(\mu, \Sigma)$; 此时我们也称 X 的诸分量之间服从联合正态分布, 记作 $X \sim N(\mu, \Sigma)$. 容易知道

$$\mathbb{E}X = \mu, \quad \mathbb{Var}(X) = \Sigma. \quad (8.27)$$

根据上述正态分布的定义方式, 我们很容易得到以下的一系列结果。

♠ **定理 8.3.3.** 设 X 是 n 维随机列向量, $X \sim N(\mu, \Sigma)$, 其中 $\mu \in \mathbb{R}^n$, Σ 是 n 阶实对称正定阵。设 A 为 n 阶可逆矩阵, $\beta \in \mathbb{R}^n$, 则

$$Y := \beta + AX \sim N(\tilde{\mu}, \tilde{\Sigma}),$$

其中 $\tilde{\mu} = \beta + A\mu$, $\tilde{\Sigma} = A\Sigma A^T$.

☞ **推论 8.3.1.** 设 Z 是 n 维标准正态随机列向量, 即 $Z \sim N(0, I_n)$. 则对任意单位正交矩阵 $A \in O(n)$,

$$AZ \sim N(0, I_n).$$

根据本书对正态分布的定义, 上述定理和推论的证明都比较简单, 因此留给读者作为练习。

♠ **定理 8.3.4.** 设 $X = \begin{pmatrix} X_1 \\ X_2 \end{pmatrix}$ 是 $n \geq 2$ 维随机列向量, 其中 X_1 为 n_1 维随机列向量, X_2 为 n_2 维随机列向量, $n_1 + n_2 = n$. 又设 $X \sim N(\mu, \Sigma)$, 其中 $\mu \in \mathbb{R}^n$, Σ 是 n 阶实对称正定阵, 并且它们根据 $X = \begin{pmatrix} X_1 \\ X_2 \end{pmatrix}$ 的分块形式有下面对应的分块表示

$$\mu = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \quad \Sigma = \begin{pmatrix} \Sigma_{1,1} & \Sigma_{1,2} \\ \Sigma_{2,1} & \Sigma_{2,2} \end{pmatrix}.$$

那么

- (1) $X_1 \sim N(\mu_1, \Sigma_{1,1})$, $X_2 \sim N(\mu_2, \Sigma_{2,2})$, 并且 $\Sigma_{1,2} = \text{Cov}(X_1, X_2)$;
- (2) X_1 与 X_2 相互独立的充分必要条件是:

$$\text{Cov}(X_1, X_2) = 0; \quad (8.28)$$

- (3) X_1 关于 $X_2 = x_2$ 的条件分布律仍然是正态分布, 具体来说

$$X_1 | X_2 = x_2 \sim N(\tilde{\mu}_1(x_2), \tilde{\Sigma}_{1,1}), \quad (8.29)$$

其中

$$\begin{cases} \tilde{\mu}_1(x_2) &= \mu_1 + \Sigma_{1,2}\Sigma_{2,2}^{-1}(x_2 - \mu_2), \\ \tilde{\Sigma}_{1,1} &= \Sigma_{1,1} - \Sigma_{1,2}\Sigma_{2,2}^{-1}\Sigma_{2,1}. \end{cases}$$

参考证明: 首先, 我们证明 $\Sigma_{1,2} = \text{Cov}(X_1, X_2)$. 事实上, 这只要注意到

$$X_1 = (I_{n_1}, 0)X, X_2 = (0, I_{n_2})X$$

以及 $\text{Cov}(X, X) = \text{Var}(X) = \Sigma$, 立即利用 $\text{Cov}(X, Y)$ 关于 X, Y 的 (共轭) 双线性性质得到

$$\text{Cov}(X_1, X_2) = (I_{n_1}, 0)\text{Cov}(X, X)(0, I_{n_2})^T = \Sigma_{1,2}.$$

其次, 我们证明: 在 X_1, X_2 服从联合正态分布的条件下, $\Sigma_{1,2} = 0$ 是 X_1 与 X_2 独立的充分必要条件, 并且此时 $X_1 \sim N(\mu_1, \Sigma_{1,1})$, $X_2 \sim N(\mu_2, \Sigma_{2,2})$. 当 X_1 与 X_2 独立时, 显然有 $\Sigma_{1,2} = \text{Cov}(X_1, X_2) = 0$, 因此我们重点需要证明充分性部分. 现在设 $\Sigma_{1,2} = 0$, 从而由于 Σ 是对称矩阵, $\Sigma_{2,1} = \Sigma_{1,2}^T = 0$, 进而 Σ 实际上是分块对角矩阵 $\Sigma = \text{diag}\{\Sigma_{1,1}, \Sigma_{2,2}\}$. 根据例8.14中密度 $\rho(x; \mu, \Sigma)$ 的表达式(8.26), 此时不难验证它满足:

$$\rho(x; \mu, \Sigma) = \rho(x_1; \mu_1, \Sigma_{1,1}) \cdot \rho(x_2; \mu_2, \Sigma_{2,2}).$$

从而 X_1 与 X_2 独立, 并且 $X_1 \sim N(\mu_1, \Sigma_{1,1})$, $X_2 \sim N(\mu_2, \Sigma_{2,2})$.

最后, 我们论证定理中的其他结论. 选取合适的矩阵 B , 使得线性变换 $Y = AX$ 具有如下形态

$$Y = \begin{pmatrix} Y_1 \\ Y_2 \end{pmatrix} = \begin{pmatrix} I_{n_1} & -B \\ 0 & I_{n_2} \end{pmatrix} \begin{pmatrix} X_1 \\ X_2 \end{pmatrix},$$

并且 $\text{Cov}(Y_1, Y_2) = 0$. 这只要取 $B = \Sigma_{1,2}\Sigma_{2,2}^{-1}$ 即可. 此时, 显然 Y 仍然服从高维正态分布, 并且 Y_1, Y_2 相互独立 (进而它们也分别服从高维正态分布). 注意到 $Y_2 = X_2$, 并且 $\mathbb{E}X_2 = \mu_2$, $\text{Var}(X_2) = \Sigma_{2,2}$, 我们立即得到在一般情形下也有 $X_2 \sim N(\mu_2, \Sigma_{2,2})$ 的结论; 对称的, 也应有 $X_1 \sim N(\mu_1, \Sigma_{1,1})$. 这完成了定理 (1) 部分的证明. 设 $Y_1 \sim N(\hat{\mu}_1, \hat{\Sigma}_{1,1})$, 注意到 $Y_1 = X_1 - BX_2$, 应有:

$$\begin{cases} \hat{\mu}_1 &= \mathbb{E}Y_1 = \mathbb{E}X_1 - B\mathbb{E}X_2 = \mu_1 - B\mu_2, \\ \hat{\Sigma}_{1,1} &= \text{Var}(Y_1) = \Sigma_{1,1} - \Sigma_{1,2}\Sigma_{2,2}^{-1}\Sigma_{2,1} =: \tilde{\Sigma}_{1,1}. \end{cases}$$

利用推论7.3.1, 我们立即得到 $X_1 = Y_1 + BY_2$ 关于 $X_2 = Y_2$ 的条件分布律为

$$(X_1 | X_2 = x_2) = (Y_1 + BY_2 | Y_2 = x_2) \stackrel{d}{=} Y_1 + Bx_2 \sim N(\hat{\mu}_1 + Bx_2, \hat{\Sigma}_{1,1}).$$

而 $\hat{\mu}_1 + Bx_2 = \mu_1 + \Sigma_{1,2}\Sigma_{2,2}^{-1}(x_2 - \mu_2) = \tilde{\mu}_1(x_2)$, $\hat{\Sigma}_{1,1} = \tilde{\Sigma}_{1,1}$, 因此定理结论(8.29)成立. 读者也可基于推论8.2.1来进行计算与推理. $\square$

基于上述结果, 我们进一步有下面的推论; 它的证明就留给读者.

推论 8.3.2. 设 X 是 n 维随机列向量, $X \sim N(\mu, \Sigma)$, 其中 $\mu \in \mathbb{R}^n$, Σ 是 n 阶实对称正定阵. 设 A 为 $m \times n$ 矩阵且行满秩 (从而 $m = \text{rank}(A) \leq n$), $\beta \in \mathbb{R}^m$, 则

$$Y := \beta + AX \sim N(\tilde{\mu}, \tilde{\Sigma}),$$

其中 $\tilde{\mu} = \beta + A\mu, \tilde{\Sigma} = A\Sigma A^T$.

📌 笔记 8.2. 在第十一章的习题中, 我们利用特征函数的工具, 可以把正态分布 $N(\mu, \Sigma)$ 中参数 Σ 的正定性要求减弱为非负定, 对应推广的分布称为 *Gauss 分布* 或 *广义正态分布*, 仍然记作 $N(\mu, \Sigma)$ (但需要注意, 当 $\det(\Sigma) = 0$ 时, $N(\mu, \Sigma)$ 不再是连续型分布, 而是一种集中在稍低维度的线性子流形上的分布). 在这种认同下, 上述推论中矩阵 A 的行满秩要求可以去掉。

这里, 我们特别指出: 在 X, Y 服从联合正态分布的条件下, 才有

$$\mathbb{Cov}(X, Y) = 0 \Leftrightarrow X, Y \text{ 相互独立}.$$

在 X, Y 各自服从正态分布, 但不服从联合正态分布时, 上述结论不再成立。请看下面最简单的反例。更多反例请参见课后习题。

例 8.15. 设 $X \sim N(0, 1)$. 取 ξ 与 X 相互独立, 且 $\mathbb{P}(\xi = 1) = \mathbb{P}(\xi = -1) = \frac{1}{2}$. 那么不难证明

$$Y := \xi \cdot X \sim N(0, 1),$$

且 $\mathbb{Cov}(X, Y) = 0$, 并且 $\mathbb{P}(X = Y) = 1/2 > 0$, 从而 X, Y 不独立。请读者思考并补全此处有关推理的逻辑¹。




图 8.5: 卡方分布 $\chi^2(n)$ 密度函数图

例 8.16. (卡方分布 $\chi^2(n)$) 现在假设 $\{Z_i\}_{i=1}^n \stackrel{\text{i.i.d.}}{\sim} N(0, 1)$. 定义

$$Y_n := Z_1^2 + \cdots + Z_n^2,$$

¹提示: 此处有关推理的一般性结论可以参见习题9.4; 但我们建议读者先自行思考。

称 Y_n 服从 n 个自由度的卡方分布, 记作 $\chi^2(n)$. 不难知道,

$$Z_1^2 \sim \Gamma\left(\frac{1}{2}, \frac{1}{2}\right),$$

从而由 *Gamma* 分布的半再生性 (见例 8.9), $\chi^2(n) = \Gamma\left(\frac{n}{2}, \frac{1}{2}\right)$. 进而 $\chi^2(2) = \mathcal{E}\left(\frac{1}{2}\right)$.

例 8.17. (正态分布 $N(\mu, \sigma^2)$ 的极大似然估计) 设有正态分布 $N(\mu, \sigma^2)$ (其中两个参数均未知) 的 n 个简单样本 $\{X_i\}_{i=1}^n$, 亦即

$$\{X_i\}_{i=1}^n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2).$$

由 $(X_1, \dots, X_n)$ 的联合密度函数 $L = L(x_1, \dots, x_n; \mu, \sigma^2)$ 得到

$$\ln L = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2.$$

固定具体样本值 $(x_1, \dots, x_n)$, 把 L 视作参数 (μ, σ^2) 的函数 (统计学中, 把联合密度函数 L 在视作参数的函数时, 又称之为似然函数), L 的极大值点 $(\hat{\mu}, \hat{\sigma}^2)$ 就是极大似然估计

$$(\hat{\mu}, \hat{\sigma}^2) = \arg \max_{(\mu, \sigma^2)} L(x; \mu, \sigma^2).$$

因此, 我们最终基于这 n 个简单样本 $\{X_i\}_{i=1}^n$ 得到参数的似然估计

$$\begin{cases} \hat{\mu} &:= \bar{X} = \frac{1}{n}[X_1 + \dots + X_n], \\ \hat{\sigma}^2 &:= \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2. \end{cases}$$

其中, $\bar{X}$ 称为样本均值, $\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 称为样本方差. 不难计算出

$$\mathbb{E}[\bar{X}] = \mu, \quad \mathbb{E}\left[\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2\right] = \frac{n-1}{n} \sigma^2 < \sigma^2.$$

也就是说, 上述极大似然估计中, $\hat{\mu}$ 是无偏估计, $\hat{\sigma}^2$ 不是无偏估计; 为此我们可以调整系数, 称 $\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 称为样本标准方差, 以此作为真实分布的方差的估计就是无偏估计了。

下面进一步研究两个参数的极大似然估计的分布律问题. 为方便, 对问题进行转化, 令

$$Z_i := \frac{X_i - \mu}{\sigma}.$$

则 $\{Z_i\}_{i=1}^n \stackrel{\text{i.i.d.}}{\sim} N(0, 1)$. 于是

$$\hat{\mu} = \mu + \sigma \bar{Z}, \quad \hat{\sigma}^2 = \frac{\sigma^2}{n} \sum_{i=1}^n (Z_i - \bar{Z})^2.$$

易知 $\bar{Z} \sim N(0, \frac{1}{n})$. 以下我们将证明: $\sum_{i=1}^n (Z_i - \bar{Z})^2 \sim \chi^2(n-1)$, 并且它与 $\bar{Z}$ 相互独立. 从而

$$\frac{\sqrt{n}(\hat{\mu} - \mu)}{\sigma} \sim N(0, 1), \quad \frac{n\hat{\sigma}^2}{\sigma^2} \sim \chi^2(n-1),$$

并且上述两个随机变量相互独立. 上述第二个分布律信息可以用来构建 σ^2 的区间估计 (置信区间).

注意到标准正态分布在正交变换下保持不变 (推论8.3.1), 存在正交矩阵 A , 使得它的第一行元素如下指定:

$$A = \begin{pmatrix} \frac{1}{\sqrt{n}} & \cdots & \frac{1}{\sqrt{n}} \\ * & \cdots & * \\ \vdots & \ddots & \vdots \\ * & \cdots & * \end{pmatrix}.$$

令 $Y = AZ \sim N(0, I_n)$, 其中 $Z = (Z_1, \dots, Z_n)^T$. 那么 $\{Y_i\}_{i=1}^n \stackrel{\text{i.i.d.}}{\sim} N(0, 1)$, 且

$$\sqrt{n}\bar{Z} = Y_1, \quad \|Z\|^2 = \|Y\|^2.$$

进而 $\sum_{i=1}^n (Z_i - \bar{Z})^2 = \sum_{i=1}^n Z_i^2 - n\bar{Z}^2 = \sum_{i=2}^n Y_i^2 \sim \chi^2(n-1)$, 且它与 $\bar{Z} = Y_1/\sqrt{n}$ 相互独立.

在上一例中, 为了构建参数 μ 的区间估计, 可以考虑两个相互独立的随机变量

$\frac{\sqrt{n}(\hat{\mu} - \mu)}{\sigma}$ 与 $\sqrt{\frac{n\hat{\sigma}^2}{\sigma^2}}/(n-1)$ 的商

$$W := \frac{\sqrt{n-1}(\hat{\mu} - \mu)}{\sqrt{\hat{\sigma}^2}}$$

的分布律, 从而把未知参数 σ 消去. W 的分布律就是下例中将介绍的 $n-1$ 个自由度的 t -分布.



图 8.6: Gosset (1876—1937)

例 8.18. (t -分布) 一般而言, 设 $X \sim N(0, 1)$, $Y \sim \chi^2(n)$, 且 X, Y 相互独立, 则记

$$\frac{X}{\sqrt{Y/n}} \sim t(n),$$

称商 $\frac{X}{\sqrt{Y/n}}$ 服从 n 个自由度的 t -分布. 不难算出, $t(n)$ -分布的密度函数为:

$$t_n(x) = \frac{\Gamma(\frac{n+1}{2})}{\sqrt{n\pi}\Gamma(\frac{n}{2})} \cdot (1 + \frac{x^2}{n})^{-\frac{n+1}{2}}.$$




图 8.7: t -分布 $t(n)$ 密度函数图; 图像与纵轴交点由高到低依次对应参数 $n = 1, 2, 3, 4$

注 8.2. t -分布又称为 *Student t*-分布。它的推导是由 William Sealy Gosset (戈塞特, 1876—1937; 英国化学家、数学家与统计学家) 于 1908 年首先发表。当时他还在都柏林的健力士酿酒厂工作, 因为不能以他本人的名义发表, 所以论文使用了学生 (Student) 这一笔名; Gosset 被认为是英国现代统计方法发展的先驱、小样本理论研究的先驱。他为研究样本分布理论奠定了重要基础, 被统计学家誉为统计推断理论发展史上的里程碑。之后 t 检验以及相关理论经由 R. Fisher (费雪, 1890—1962; 英国) 的工作发扬光大, 而正是他将此分布称为学生分布。

例 8.19. (F -分布) 假定有两族来源于不同分布且互相独立的样本:

$$\{X_i\}_{i=1}^m \sim N(\mu_1, \sigma_1^2), \quad \{Y_j\}_{j=1}^n \sim N(\mu_2, \sigma_2^2).$$

关心的问题是: 是否可以认为 $\sigma_1^2 = \sigma_2^2$? 即两个分布的方差是否相同? 如果 μ_1, μ_2 已知, 则可以知道

$$T_1 := \frac{\sum_{i=1}^m (X_i - \mu_1)^2}{\sigma_1^2} \sim \chi^2(m), \quad T_2 := \frac{\sum_{j=1}^n (Y_j - \mu_2)^2}{\sigma_2^2} \sim \chi^2(n),$$

且它们相互独立。商 $\frac{T_1/m}{T_2/n}$ 的分布律称为自由度参数为 (m, n) 的 F -分布, 记作

$$\frac{T_1/m}{T_2/n} \sim F(m, n).$$

基于此就可以构建相应的拒绝域来完成对应的假设检验。不难算出 $F(m, n)$ -分布的密度函数为

$$f_{m,n}(x) = \frac{\Gamma(\frac{m+n}{2})}{\Gamma(\frac{m}{2})\Gamma(\frac{n}{2})} \cdot \left(\frac{m}{n}\right)^{\frac{m}{2}} \cdot x^{\frac{m}{2}-1} \left(1 + \frac{m}{n}x\right)^{-\frac{m+n}{2}} \cdot 1_{(0,\infty)}(x).$$

当 μ_1, μ_2 未知时, 则取

$$T_1 := \frac{\sum_{i=1}^m (X_i - \bar{X})^2}{\sigma_1^2} \sim \chi^2(m-1), \quad T_2 := \frac{\sum_{j=1}^n (Y_j - \bar{Y})^2}{\sigma_2^2} \sim \chi^2(n-1),$$

此时商 $\frac{T_1/(m-1)}{T_2/(n-1)} \sim F(m-1, n-1)$.

为了更好地介绍后文中的 Cauchy (柯西) 分布与 Rayleigh (瑞利) 分布, 我们先来看下面有关二维标准正态分布的一个性质, 证明就留给读者。

例 8.20. 设 $\{Z_i\}_{i=1}^2 \stackrel{\text{i.i.d.}}{\sim} N(0, 1)$, $\xi \sim \begin{pmatrix} -1 & 1 \\ \frac{1}{2} & \frac{1}{2} \end{pmatrix}$ 与 $Z_1, |Z_2|$ 相互独立, 那么

$$(Z_1, Z_2) \stackrel{d}{=} (Z_1 \cdot \xi, |Z_2| \cdot \xi).$$

定义 $\text{sgn}(x) := 1_{(0, \infty)}(x) - 1_{(-\infty, 0)}(x)$, 则 Z_1 、 $\text{sgn}(Z_2)$ 、 $|Z_2|$ 相互独立, 进而

$$(Z_1, Z_2) \stackrel{d}{=} (Z_1 \cdot \text{sgn}(Z_2), |Z_2|),$$

由此 $\frac{Z_1}{Z_2} \stackrel{d}{=} \frac{Z_1}{|Z_2|}$.

例 8.21. (Cauchy 分布) 设 $\{Z_i\}_{i=1}^2 \stackrel{\text{i.i.d.}}{\sim} N(0, 1)$. 定义 $X := \frac{Z_1}{Z_2}$, 则 X 的密度函数为

$$\rho(x) = \frac{1}{\pi(1+x^2)},$$

它对应的分布律称为**标准 Cauchy 分布** (亦即 $t(1)$ 分布). 给定 $\mu \in \mathbb{R}, a > 0$, $Y := \mu + aX$ 的分布称为参数为 (μ, a) 的 Cauchy 分布, 它的密度函数为

$$\rho_Y(y) = \frac{a}{\pi[a^2 + (y - \mu)^2]}.$$

参考证明: 注意到例8.20, 为了求 X 的分布律, 我们不妨来求 $W := \frac{Z_1}{|Z_2|}$ 的分布律。为方便, 我们引入 $R := \sqrt{Z_1^2 + Z_2^2}$, 于是 $|Z_2| = \frac{R}{\sqrt{1+W^2}}, Z_1 = \frac{W \cdot R}{\sqrt{1+W^2}}$. 基于此立即由 $(Z_1, |Z_2|)$ 的联合密度得到 (W, R) 的联合密度函数

$$\rho(w, r) = \frac{1}{\pi(1+w^2)} \cdot r \cdot e^{-\frac{r^2}{2}} \cdot 1_{(0, \infty)}(r).$$

进而 W 的密度函数 (亦即 X 的密度函数) 为 $\rho_W(w) = \frac{1}{\pi(1+w^2)}$. $Y := \mu + aX$ 的密度函数的计算留给读者。□

📌 注记 8.3. 上例中计算方法很典型, 问题本来是求 2 维随机向量的一维复合随机变量的分布律, 作为变换是从 2 维变成 1 维, 肯定是不可逆的。我们提供的方法是补充定义“缺失”的一维复合随机变量, 从而把原始的复合映射补全后变成可逆或分片可逆的光滑变换, 使用光滑变换的思想求出联合分布密度, 再由此去求关心的边缘分布函数。在例8.17的计算过程中本质上也使用了这一方法。

在例8.21的证明中, 还能算出 R 的密度函数为

$$\rho(r) = r \cdot e^{-\frac{r^2}{2}} \cdot 1_{(0, \infty)}(r),$$




图 8.8: Rayleigh 分布密度函数图

这个密度函数对应的分布律称为 **Rayleigh 分布**，它的图像见图8.8.

下面我们基于两个简单例子简略介绍基于 **Bayes** 思想的极大似然估计；其他类型的 **Bayes** 估计留待读者到相关专业课程或专业教科书中去学习。

例 8.22. 设 $p \sim U(0, 1)$ 是 (随机) 参数 p 的先验分布；而给定 $p = t \in (0, 1)$ 后，有样本 $\{X_k\}_{k=1}^n \stackrel{\text{i.i.d.}}{\sim} B(1, t)$. 求 p 在给定了样本值 $X_1, \dots, X_n$ 时的 **Bayes** 极大似然估计。

参考解答： 我们需要计算条件分布律 $p|(X_1, X_2, \dots, X_n)$. 事实上，对任意 $0 \leq a < b \leq 1$ 及 $x_1, \dots, x_n \in \{0, 1\}$ ，记 $x_1 + \dots + x_n = k$ ，则

$$\begin{aligned} & \mathbb{P}(p \in (a, b], X_1 = x_1, \dots, X_n = x_n) \\ &= \int_{(a,b]} \mathbb{P}(X_1 = x_1, \dots, X_n = x_n | p = t) dt \\ &= \int_{(a,b]} C_n^k t^k (1-t)^{n-k} dt. \end{aligned}$$

取 $a = 0, b = 1$ 得到 $\mathbb{P}(X_1 = x_1, \dots, X_n = x_n) = \frac{1}{n+1}$. 于是条件分布律 $p|(X_1, X_2, \dots, X_n)$ 具有密度

$$\rho(t|X_1, \dots, X_n) = (n+1) \cdot C_n^{S_n} t^{S_n} (1-t)^{n-S_n} \cdot 1_{(0,1)}(t),$$

其中 $S_n = X_1 + \dots + X_n$. 这个密度函数的极大值点在 $t = \frac{S_n}{n}$ 处. 于是我们再次得到此时 p 的 **Bayes** 极大似然估计 $\hat{p} = \frac{S_n}{n}$. $\square$

例 8.23. 设 $\mu \sim N(\mu_0, \sigma_0^2)$ 是 (随机) 参数 μ 的先验分布，其中 μ_0, σ_0^2 是常数；而给定 $\mu = \beta \in \mathbb{R}$ 后，有样本 $\{X_k\}_{k=1}^n \stackrel{\text{i.i.d.}}{\sim} N(\beta, \sigma^2)$ ，其中 σ^2 也是常数. 求 μ 在给定了样本值 $X_1, \dots, X_n$ 时的极大似然估计。

参考解答：同样我们需要计算条件分布律 $\mu|(X_1, X_2, \dots, X_n)$ ；我们总记 $S_n = X_1 + \dots + X_n$, $\bar{X} = \frac{S_n}{n}$. 记 $X_0 := \mu$, 则容易知道 $Y := (X_0, X_1, \dots, X_n)^T$ 服从联合正态分布, 有 $\mathbb{E}X_i = \mu_0, i = 0, 1, \dots, n$. 不难算出 Y 的协方差矩阵为

$$\Sigma = \sigma_0^2 \cdot \mathbf{1} \cdot \mathbf{1}^T + \sigma^2 \cdot \text{diag}\{0, I_n\},$$

其中 $\mathbf{1} \in \mathbb{R}^{n+1}$ 代表分量全为 1 的列向量, I_n 代表 n 维单位矩阵. 于是由本章关于高维正态分布的理论可知, 条件分布律 $X_0|(X_1, X_2, \dots, X_n)$ 仍然为正态分布, 其方差恒定, 而均值即为

$$\mathbb{E}[X_0|(X_1, X_2, \dots, X_n)] = \mu_0 + \frac{n\sigma_0^2}{n\sigma_0^2 + \sigma^2} \cdot (\bar{X}_n - \mu_0).$$

于是条件分布律 $X_0|(X_1, X_2, \dots, X_n)$ 的密度的最大值点就是 Bayes 极大似然估计

$$\hat{\mu} := \mu_0 + \frac{n\sigma_0^2}{n\sigma_0^2 + \sigma^2} \cdot (\bar{X}_n - \mu_0).$$

它与通常的极大似然估计有了区别. □

8.4 本章小结与学习建议

在本章, 我们首先给出了连续型随机变量/随机向量及其概率密度函数的严谨定义, 回答了具有给定分布函数的随机变量何时是连续型随机变量的问题. 之后, 为了解决连续型随机变量/随机向量在光滑或分片光滑变换下的分布律变化问题, 我们介绍了一个兼具直观性与严谨性的推理计算方法——概率微元法; 其中记号体系是编者在前人工作基础上首创的. 最后我们介绍了初等概率论中常见的连续型分布; 其中有关一维和高维正态分布的理论是读者需要熟练掌握的内容, 特别是服从高维正态分布的随机向量的分量间的条件分布律的讨论实质上是上一章条件分布律定义的应用, 概率论初学者正好可以借此应用场景来了解和熟悉条件分布律的抽象定义及有关重要性质.

习 题 8

习题 8.1. 给定 $\alpha, \beta > 0$. 如果随机变量 X 具有密度函数

$$\rho(x; \alpha, \beta) = \frac{x^{\alpha-1}}{B(\alpha, \beta)(1+x)^{\alpha+\beta}} \cdot 1_{(0, \infty)}(x),$$

则记 $X \sim Z(\alpha, \beta)$, 称 X 服从参数为 (α, β) 的 Z 分布 (或第 II 类 Beta 分布).

求证: 如果 $X_k \sim \Gamma(\alpha_k, \lambda), k = 1, 2$ 相互独立 (其中 $\alpha_1, \alpha_2, \lambda > 0$), 那么

(1) $Y_1 := X_1 + X_2 \sim \Gamma(\alpha_1 + \alpha_2, \lambda)$, $Y_2 := \frac{X_1}{X_1 + X_2} \sim \text{Beta}(\alpha_1, \alpha_2)$, 且 Y_1, Y_2 相互独立;

(2) $Z_2 := \frac{Y_2}{1 - Y_2} = \frac{X_1}{X_2} \sim Z(\alpha_1, \alpha_2)$, 且 Y_1, Z_2 相互独立。

习题 8.2. 设 n 是正整数。关于 χ^2 分布, 我们有下面的结论。

(1) $\chi^2(1) = \Gamma(\frac{1}{2}, \frac{1}{2})$, 即当 $X \sim N(0, 1)$ 时, $X^2 \sim \Gamma(\frac{1}{2}, \frac{1}{2})$. 进而由此推断 $\chi^2(n) = \Gamma(\frac{n}{2}, \frac{1}{2})$;

(2) 如果 $X_k \sim N(\mu_k, 1), k = 1, \dots, n$ 相互独立, 那么 $Y := X_1^2 + \dots + X_n^2$ 的分布律由参数 n 及 $\delta := \sqrt{\mu_1^2 + \dots + \mu_n^2}$ 决定, 记作 $Y \sim \chi^2(n; \delta)$, 称之为自由度 n 的非中心 χ^2 -分布;

(3) 设 $\delta > 0, I \sim \text{Poisson}(\frac{\delta^2}{2}), Y_k \sim \chi^2(k), k = 1, 2, \dots$ 相互独立且与 I 也相互独立。那么 $Y_{2I+1} \sim \chi^2(1; \delta)$; 特别的, $Y_{2I+n} \sim \chi^2(n; \delta)$ 。

习题 8.3. 对于给定的正整数 n_1, n_2 , 如果 $X_k \sim \chi^2(n_k), k = 1, 2$ 相互独立, 那么就称 $X := \frac{X_1/n_1}{X_2/n_2}$ 服从自由度参数对 (n_1, n_2) 的 F 分布, 记作 $X \sim F(n_1, n_2)$. 求证: 此时有 $\frac{n_1}{n_2} \cdot X \sim Z(\frac{n_1}{2}, \frac{n_2}{2})$. 当 $X_1 \sim \chi^2(n_1, \delta), X_2 \sim \chi^2(n_2)$ 且相互独立时, 就称 $X := \frac{X_1/n_1}{X_2/n_2}$ 服从自由度参数对 (n_1, n_2) 、位置参数 $\delta > 0$ 的 F 分布, 记作 $X \sim F(n_1, n_2; \delta)$; 试利用上一习题给出 $F(n_1, n_2; \delta)$ 的类似表示。

习题 8.4. 对给定正整数 n , 如果 $X_1 \sim N(0, 1), X_2 \sim \chi^2(n)$ 且相互独立, 那么就记 $T_n := \frac{X_1}{\sqrt{X_2/n}} \sim t(n)$, 称它服从自由度为 n 的 t 分布。如果 $X_1 \sim N(\mu, 1), X_2 \sim \chi^2(n)$ 且相互独立, 那么就记 $T_n(\mu) := \frac{X_1}{\sqrt{X_2/n}} \sim t(n; \mu)$, 称它服从位置参数为 μ 、自由度为 n 的非中心 t 分布。求证: $T_n(-\mu) \stackrel{d}{=} -T_n(\mu)$ 。

习题 8.5.¹ 设 ξ 取值于 $(0, 1)$. 如果对一切 $0 \leq x \leq y \leq 1, \mathbb{P}(x < \xi \leq y)$ 只与区间 $(x, y]$ 的长度 $y - x$ 有关, 试证明: $\xi \sim U(0, 1)$ 。

习题 8.6. 设 ξ 取值于 $[0, 1]$. 如果对一切 $0 \leq x \leq y \leq 1, \mathbb{P}(x \leq \xi \leq y)$ 只与区间 $[x, y]$ 的长度 $y - x$ 有关, 试证明: $\xi \sim U(0, 1)$ 。

习题 8.7. 本习题的目的是帮助读者理解例 8.5. 设 $X \sim B(1, p), Y \sim U(0, 1)$, 且它们相互独立。求 $Z := X + Y$ 的密度函数。

习题 8.8. 请证明定理 8.2.4.

¹ 当本题中取值条件修改为“ ξ 取值于 $[0, 1]$ ”时, $\xi \equiv 1$ 也满足: $\mathbb{P}(x < \xi \leq y) = \delta_{1, y-x}, \forall 0 \leq x \leq y \leq 1$.

习题 8.9. 请证明定理 8.3.3.

习题 8.10. 请证明推论 8.3.1.

习题 8.11. 请证明例 8.20 中结论.

习题 8.12. 设 $\{Z_i\}_{i=1}^2 \stackrel{\text{i.i.d.}}{\sim} N(0, 1)$. 考虑 (Z_1, Z_2) 的极坐标 (R, Θ) , 即 $R \geq 0, \Theta \in [0, 2\pi)$ 满足:

$$\begin{cases} Z_1 = R \cos \Theta, \\ Z_2 = R \sin \Theta. \end{cases}$$

则 R 与 Θ 相互独立. R 服从 Rayleigh 分布, 特别地, $R^2 = Z_1^2 + Z_2^2 \sim \mathcal{E}(\frac{1}{2})$, 而 $\Theta \sim U(0, 2\pi)$.

习题 8.13. 设 $X \sim F$ 是连续型随机变量, 其中 F 是它的分布函数, 密度函数为 ρ . 我们称 $\bar{F}(x) := 1 - F(x)$ 为风险函数 (Hazard Function), $f = \rho/\bar{F}$ 称为风险率函数 (Hazard Rate Function). 现在设 X 是非负随机变量, 且它的风险率函数 f 是非零常数, 求证: X 服从指数分布.

习题 8.14. 一只松鼠爬到了一根长为 l 米的笔直的枯树枝上. 已知松鼠沿着枯枝往顶端爬行过程中, 枯枝断裂的风险率 (见上一习题风险率函数的定义) 按照与枯枝根部端点距离成正比的方式逐渐增大, 到枯枝顶端时枯枝就有一半的可能性断裂. 请问, 当松鼠爬到枯枝一半的位置时, 枯枝断裂的可能性有多大?

习题 8.15. 在圆周上随机地取三点, 分别求这三点构成锐角/直角/钝角三角形的概率.

习题 8.16. 设 $X \sim N(0, 1)$, 求证: 存在 $a > 0$, 使得当

$$Y := \begin{cases} -X, & \text{当 } |X| \leq a \\ X, & \text{其他} \end{cases}$$

时, 有 $Y \sim N(0, 1)$, $\text{Cov}(X, Y) = 0$, 但 X, Y 显然不相互独立.

习题 8.17. 取 $D := \{(x, y) : x^2 + y^2 \leq 1\}$ 及

$$D_+ := \{(x, y) \in D : xy > 0\}, D_- := \{(x, y) \in D : xy < 0\}.$$

任给 $c \in \mathbb{R}, 0 < |c| \leq 1$

$$\rho(x, y) := \frac{1}{2\pi} \cdot e^{-\frac{x^2+y^2}{2}} + \frac{c}{2\pi\sqrt{e}}[1_{D_+}(x, y) - 1_{D_-}(x, y)].$$

(1) 求证: $\rho \geq 0$ 且 $\int \rho(x, y) dx dy = 1$, 即 ρ 可以作为一个密度函数;

- (2) 设 $(X, Y) \sim \rho(x, y)dx dy$, 求证: $X, Y \sim N(0, 1)$, 但 $\text{Cov}(X, Y) > 0$, 从而 X, Y 不相互独立。

习题 8.18. 取 $D := \{(x, y) : x^2 + y^2 \leq 1\}$. 任给 $c \in \mathbb{R}, 0 < |c| \leq 1$

$$\rho(x, y) := \frac{1}{2\pi} \cdot e^{-\frac{x^2+y^2}{2}} + \frac{cxy(x^2 - y^2)}{2\pi\sqrt{e}} \cdot 1_D(x, y).$$

- (1) 求证: $\rho \geq 0$ 且 $\int \rho(x, y)dx dy = 1$, 即 ρ 可以作为一个密度函数;
 (2) 设 $(X, Y) \sim \rho(x, y)dx dy$, 求证: $X, Y \sim N(0, 1)$, 且 $\text{Cov}(X, Y) = 0$, 但 X, Y 不相互独立。

习题 8.19. 设 X, Y 服从联合正态分布, 且 $X, Y \sim N(0, 1)$, $\text{Cov}(X, Y) = r$.

- (1) 求证: 存在 $Z \sim N(0, 1)$ 与 X 相互独立, 使得 $Y = rX + \sqrt{1-r^2}Z$;
 (2) 令 $W := \max(X, Y)$, 求证: $\mathbb{E}[W] = \sqrt{\frac{1-r}{\pi}}, \mathbb{E}[W^2] = 1$;
 (3) 取 $\sigma_1, \sigma_2 > 0$. 令 $T := \max(\sigma_1 X, \sigma_2 Y)$, 证明:

$$\mathbb{E}[T] = \sqrt{\frac{\sigma_1^2 + \sigma_2^2 - 2r\sigma_1\sigma_2}{2\pi}}, \mathbb{E}[|T|] = \frac{\sigma_1 + \sigma_2}{\sqrt{2\pi}}, \mathbb{E}[T^2] = \frac{\sigma_1^2 + \sigma_2^2}{2}.$$

习题 8.20. 设 $\{X_k\}_{k=1}^n \stackrel{\text{i.i.d.}}{\sim} \text{Cauchy}(0, 1)$, 求 $\bar{X} := \frac{X_1 + \dots + X_n}{n}$ 的分布律。

习题 8.21. 设 $X \sim \text{Cauchy}(0, 1)$, 求 $\mathbb{E}[|X|]$ 与 $\mathbb{E}[\min(|X|, 1)]$.

习题 8.22. 设 $X_k \sim \mathcal{E}(\lambda_k), k = 1, 2$, 且它们相互独立. 求 $\mathbb{P}(X_1 > X_2)$.

习题 8.23. 设 $\{U_k\}_{k=1}^n \stackrel{\text{i.i.d.}}{\sim} U(0, 1)$, $Y_x := \inf\{n \geq 1 : U_1 + \dots + U_n > x\}$, 其中 $x \in [0, 1]$. 计算 $g(x) := \mathbb{E}[Y_x]$.

习题 8.24. 设 $\xi \sim \mathcal{E}(1)$, $\beta = 1/\alpha > 0, \tau > 0$ 是常数. 令 $\eta = \tau \cdot \xi^\alpha$, 则 η 的分布律称为 *Weibull* 分布 (其中, τ 称为尺度参数, β 称为形状参数), 这个分布在可靠性理论中占有重要地位. 请证明: 上述 *Weibull* 分布的分布函数为 $F(t) = (1 - \exp\{-(\frac{t}{\tau})^\beta\})^+$, 它的风险率函数 (定义参见习题 8.13) 为 $\frac{\beta}{\tau} \cdot (\frac{t}{\tau})^{\beta-1} \cdot 1_{(0, \infty)}(t)$.

习题 8.25. 两个随机变量 X, Y 称为 *Positively Associated* (简称 *P.A.*), 如果对任意 (有界) 单调递增函数 f, g , 总有 $\text{Cov}(f(X), g(Y)) \geq 0$ (取 $f(x) = 1_{(a, \infty)}(x), g(x) = 1_{(b, \infty)}(x)$, 这将导致第十章的正象限相关概念). 习题 6.38 表明, 对任意随机变量 X 而言, 总有 X, X 是 *P.A.* 的. 现在设 X, Y 服从联合正态分布, 且 $r := \text{Corr}(X, Y)$. 证明: X, Y 是 *P.A.* 的充要条件是 $r \geq 0$.

习题 8.26. 设 $X \sim N(0, \sigma^2)$, 求证: 对于任何绝对连续、导数有界的函数 f , $\mathbb{E}[Xf(X)] = \sigma^2 \mathbb{E}[f'(X)]$.

习题 8.27. 设有两个连续型随机变量 X, Y , 其中 $X \sim \rho(x)dx$, $Y \sim \rho(y)g(y)dy$. 求证: 对任意有界可测函数 φ , $\mathbb{E}[\varphi(Y)] = \mathbb{E}[\varphi(X)g(X)]$.

习题 8.28. 设有相互独立的连续型随机变量 X_1, X_2 , 记 ρ_1, ρ_2 分别为 X_1, X_2 的分布密度. 又设有相互独立的连续型随机变量 Y_1, Y_2 , 它们的分布密度分别为 $\tilde{\rho}_1, \tilde{\rho}_2$. 假定

$$\frac{\tilde{\rho}_1(x)}{\rho_1(x)} = Z_1^{-1} \exp(-\beta x), \quad \frac{\tilde{\rho}_2(x)}{\rho_2(x)} = Z_2^{-1} \exp(-\beta x),$$

其中 Z_1, Z_2, β 为常数. 记 $X_1 + X_2$ 的分布密度为 ρ , 记 $Y_1 + Y_2$ 的分布密度为 $\tilde{\rho}$. 那么, $\frac{\tilde{\rho}(x)}{\rho(x)} = \frac{\exp(-\beta x)}{Z_1 Z_2}$, 进而对任意有界可测函数 φ

$$\mathbb{E}[\varphi(Y_1 + Y_2)] = \mathbb{E}[\varphi(X_1 + X_2) \exp\{-\beta(X_1 + X_2)\} / (Z_1 Z_2)].$$

习题 8.29. 我们观察到: 当 $X \sim \mathcal{E}(\lambda)$ 时, $\mathbb{E}[X|X > t] = t + \mathbb{E}X \geq \mathbb{E}X, \forall t \geq 0$; 当 $X \sim U(0, 1)$ 时也有 $\mathbb{E}[X|X > t] = \frac{t}{2} + \mathbb{E}X \geq \mathbb{E}X, \forall t \in (0, 1)$. 那么, 当 $X \in L^1$ 时, 一般结论

$$\mathbb{E}[X|X > t] \geq \mathbb{E}X$$

(其中 t 满足 $\mathbb{P}(X > t) > 0$) 是否成立? 当 $X \sim \rho(x)dx$ 且 $X \in L^1$ 时, 试计算

$$g(t) := \frac{\partial}{\partial t} \mathbb{E}[X|X > t].$$

如果 $g(t) = 1_{[0, \infty)}(t)$, X 的分布具有什么性质?

习题 8.30. 设随机变量列 $\{X_k\}_{k=1}^{2n} \stackrel{\text{i.i.d.}}{\sim} N(0, 1)$. 定义

$$U_n := \frac{\sum_{k=1}^n X_{2k-1} X_{2k}}{\sqrt{\sum_{k=1}^n X_{2k}^2}}.$$

求 U 的分布律。

习题 8.31. 设随机向量 (X, Y) 的条件密度都存在:

$$X|Y=y \sim \rho_{X|Y}(x|y)dx, \quad Y|X=x \sim \rho_{Y|X}(y|x)dy.$$

请问, 随机向量 (X, Y) 的联合分布具有密度吗? 如果存在, 请给出它的表达式; 如果可能不存在, 请给出对应的一个具体例子。

第九章 随机变量及其分布律 (III)

本章是我们介绍“随机变量及其分布律”的系列章节中的最后一章。此处，我们将先介绍分布函数的刻画与随机变量的实现，再在此基础上特别讨论总体服从连续型分布的条件下次序统计量的分布律计算问题。最后，我们讨论随机变量的分类问题；这部分内容的介绍只是为了避免读者在初等概率论的学习过程中僵化了思维，误以为：随机变量只有离散型和连续型两种类型，不是离散型就一定是连续型。

9.1 分布函数的刻画与随机数发生器的构造

在本节，我们先介绍分布函数的刻画，之后介绍一些典型的随机数发生器的构造办法。

在本节的第一、二小节中，我们讨论了

- (1) 分布函数的刻画问题，特别是如何基于均匀分布 $U(0,1)$ 随机数发生器实现给定分布 F 的随机数发生器以及反过来的问题；
- (2) 如何构造标准正态分布的随机数发生器。

这些理论对于实现 Monte-Carlo（蒙特卡罗）随机模拟计算大有用处。

9.1.1 分布函数的刻画

下面的分布函数的刻画定理说明了：一个函数可以实现为某个随机变量的分布函数的充分必要条件是它满足定理中的分析条件 (1) — (3).

♠ **定理 9.1.1.** 随机变量 ξ 的分布函数 F 具有下面性质：

- (1) F 是单调递增函数；
- (2) F 是右连续的；

$$(3) \lim_{x \rightarrow -\infty} F(x) = 0, \lim_{x \rightarrow +\infty} F(x) = 1.$$

反之, 对于具有上述三条性质的函数 F , 设随机变量 $U \sim U(0, 1)$, 则 $F^{-1}(U)$ 的分布函数恰好为 F , 即: $F^{-1}(U) \sim F$. 此处, 函数 F^{-1} 称为 F 的广义逆, 定义为:

$$F^{-1}(p) := \inf\{t : F(t) \geq p\}, \quad p \in (0, 1). \quad (9.1)$$

因此, 我们直接把具有上述三条性质的函数 F 称为分布函数。

证明: 利用概率测度本身的单调性、上连续性、下连续性等, 很容易论证出一个随机变量的分布函数具有性质 (1) — (3), 这部分内容在第五章部分 (见命题 5.1.1) 已有论述, 因此此处有关具体论证细节从略。

以下论证定理第二部分结论。设已有某概率空间中随机变量 $U \sim U(0, 1)$ (例 8.2 中已说明这样的概率空间与随机变量存在) 以及给定的满足 (1) — (3) 的函数 F . 我们论证 $\xi := F^{-1}(U) \sim F$. 为此只需证明广义逆有如下重要性质:

$$F^{-1}(p) \leq x \Leftrightarrow p \leq F(x), \quad \forall p \in (0, 1), x \in \mathbb{R}. \quad (9.2)$$

因为如上述性质成立, 那么

$$\mathbb{P}(\xi \leq x) = \mathbb{P}(F^{-1}(U) \leq x) = \mathbb{P}(U \leq F(x)) = F(x).$$

现在我们来证明 (9.2). 注意到 $x_p := F^{-1}(p)$ 是通过下确界定义的, 应当有

$$(x_p, x_p + \varepsilon] \cap \{t : F(t) \geq p\} \neq \emptyset, \forall \varepsilon > 0,$$

因此结合函数 F 的单调性, 必定有 $F(x_p + \varepsilon) \geq p, \forall \varepsilon > 0$, 而由 F 的右连续性知道 $F(x_p) \geq p$. 因而当 $x \geq x_p$ 时, 由 F 的单调性得到 $F(x) \geq F(x_p) \geq p$; 而当 $F(x) \geq p$ 时, 由 x_p 的下确界定义方式立即得到 $x \geq x_p$. $\square$

对于分布函数 F 的广义逆, 设 $p \in (0, 1)$, 不难知道 $x_p := F^{-1}(p)$ 实际上是由以下两条性质唯一确定的:

$$(a) F(x_p) \geq p;$$

$$(b) F(x_p - \varepsilon) < p, \forall \varepsilon > 0.$$

利用上述两条性质, 再结合 F 的单调性与右连续性, 读者不难证明习题 9.1 中罗列的分布函数的广义逆的更多性质。

📌 注记 9.1. 上述定理理论上给出了从一个均匀随机数发生器出发如何构造服从任意给定分布律的随机数发生器的一种办法, 这被称为反函数方法 (*Inverse Transformation Method*). 在本章 §9.1.2 中, 我们将会介

绍其他构造随机数发生器的办法；更多的构造随机数发生器的办法请参阅其他专业书籍，如文献^[85] 这些构造随机数发生器的办法对于 *Monte-Carlo* 模拟计算来说非常重要。在计算机编程方式实现的 *Monte-Carlo* 模拟计算中，对今天的我们来说，大多数常见分布律的随机数发生器的算法通常已内嵌于各种软件中并可直接调用，但了解其中原理还是非常有必要的——毕竟在一些实际问题中你完全可能遇到需要自行构建某个不常见分布律的随机数发生器的（更高效）算法的场景。

我们还有以下事实。

♠ **定理 9.1.2.** 如果 $X \sim F$ ，且 F 是连续函数，那么 $F(X) \sim U(0, 1)$ 。

此处，我们提请读者前往习题5.13，看看上述定理中分布函数 F 不连续时会发生什么现象。

定理9.1.2的证明： 我们证明在定理所给条件下，

$$F(F^{-1}(p)) = p, \forall p \in (0, 1).$$

事实上， $x_p := F^{-1}(p)$ 满足： $F(x_p) \geq p$ 以及 $F(x_p - \varepsilon) < p, \forall \varepsilon > 0$ 。由 F 的连续性立即知道 $F(x_p) = F(x_p -) \leq p \leq F(x_p)$ ，因此 $F(x_p) = p$ 。

由此，对任意 $p \in (0, 1)$

$$\mathbb{P}(F(X) \geq p) = \mathbb{P}(X \geq x_p) = 1 - F(x_p -) = 1 - p.$$

由此立即知道

$$\mathbb{P}(F(X) \leq p) = \lim_{\varepsilon \downarrow 0} [1 - \mathbb{P}(F(X) \geq p + \varepsilon)] = p, \forall p \in (0, 1),$$

亦即 $F(X) \sim U(0, 1)$. □

📌 **注记 9.2.** 上述定理也可以不严谨地表述为：当 F 连续时，以下两个概率空间同构

$$(\mathbb{R}, \mathcal{B}, \mu_F) \cong ((0, 1), \mathcal{B}(0, 1), \text{Leb}).$$

付出一些努力，可以证明， $\mathbb{R}$ 配上任意 *Borel* 概率测度 μ ，概率空间 $(\mathbb{R}, \mathcal{B}, \mu)$ 同构于 $(0, 1)$ 上配上 *Lebesgue* 测度与某离散概率测度的凸组合得到的概率空间。（具有这种性质的概率空间，动力系统中通常称为 **Lebesgue 空间**；本注记说明，一维欧氏空间配上任何 *Borel* 概率测度，得到的都是 *Lebesgue* 空间。这一结论在高维欧氏空间以及更一般的 *Polish* 空间中仍然成立。）

9.1.2 随机数发生器的构造

定理9.1.1在理论上给出了基于均匀随机数发生器，构造具有给定分布函数 F 的随机数发生器的一般性的办法（Inverse Transformation Method；反函数方法）：

$$U \sim U(0, 1) \Rightarrow X := F^{-1}(U) \sim F.$$

但在实际应用中, 很多连续型分布具有很好计算的密度函数 ρ , 对应的分布函数 F (特别是广义逆 F^{-1}) 并不好计算. 因此人们发展出一些新的办法来构造对应的随机数发生器. 本小节内容节选自文献^[85] (部分地方有改动).

下面的舍选法 (Rejection Method) 就是一种常见办法.

♠ **定理 9.1.3. (Rejection Method)** 假设 f, g 都是密度函数, 并且存在 $C \geq 1$, 使得 $h := f/g \leq C$ 总成立 (这里约定 $0/0 = 0, 1/0 = \infty$). 那么按照以下流程将产生随机变量 $X \sim f(x)dx$:

步骤 1. 产生 $Y \sim g(x)dx$, 以及 $U \sim U(0, 1)$;

步骤 2. 如果 $U \leq h(Y)/C$, 那么就输出 $X := Y$, 否则转上一步.

证明: 设 N 为定理中为了得到随机变量 X 所须进行的循环次数, Y_k 为第 k 次循环中产生的随机变量 Y ; 取 $p := \mathbb{P}(U \leq h(Y)/C)$. 由例 3.22, 我们显然有

$$\begin{aligned} \mathbb{P}(X \leq x) &= \mathbb{P}(Y_N \leq x) = \mathbb{P}(Y \leq x | U \leq h(Y)/C) \\ &= \frac{\mathbb{P}(Y \leq x, U \leq h(Y)/C)}{\mathbb{P}(U \leq h(Y)/C)} \\ &= \frac{1}{p} \mathbb{E}[\mathbb{P}(Y \leq x, U \leq h(Y)/C | Y)] \\ &= \frac{1}{p} \int_{-\infty}^x \frac{h(y)}{C} \cdot g(y) dy = \frac{1}{pC} \int_{-\infty}^x f(y) dy. \end{aligned}$$

令 $x \rightarrow \infty$, 得到 $pC = 1, p = 1/C$. 因此 $X \sim f(x)dx$. □

容易知道, 上面证明中的 $N \sim \text{Geo}(p)$, 其中 $p = 1/C$; 从而 $\mathbb{E}N = C$. 即上述定理中为了得到满足条件的随机数, 平均需要进行 C 次循环调用.

例 9.1. (基于 $\mathcal{E}(1)$ 的随机数发生器构建 $N(0, 1)$ 的随机数发生器) 注意到 $Z \sim N(0, 1)$ 时, $|Z|$ 具有密度

$$f(x) := \frac{2}{\sqrt{2\pi}} e^{-x^2/2} \cdot 1_{(0, \infty)}(x),$$

考虑 $\mathcal{E}(1)$ 的密度函数 $g(x) = e^{-x} \cdot 1_{(0, \infty)}(x)$, 容易知道

$$\frac{f(x)}{g(x)} = \sqrt{\frac{2e}{\pi}} \cdot \exp\left\{-\frac{(x-1)^2}{2}\right\} \leq \sqrt{\frac{2e}{\pi}} \approx 1.32.$$

于是可以按照以下流程得到 $X \stackrel{d}{=} |Z|$ 的随机数发生器:

(a) 产生 $Y \sim \mathcal{E}(1)$ 以及 $U \sim U(0, 1)$;

(b) 如果 $U \leq \exp\{-(Y-1)^2/2\}$ (或等价地: $-\ln U \geq (Y-1)^2/2$), 那么就令 $X = Y$, 否则转上一步.

注意到在上述流程中, $-\ln U \sim \mathcal{E}(1)$, 可以进一步改进上面的流程如下:

(a') 产生 $Y_1, Y_2 \sim \mathcal{E}(1)$;

(b') 如果 $Y_2 \geq (Y_1 - 1)^2/2$, 那么就令 $X = Y_1$, 否则转上一步。

进一步, 我们可以按照以下流程得到 $Z \sim N(0, 1)$ 的随机数发生器:

步骤 1. 产生 $Y_1, Y_2 \sim \mathcal{E}(1)$;

步骤 2. 如果 $Y_2 \geq (Y_1 - 1)^2/2$, 那么转下一步, 否则转上一步;

步骤 3. 产生 $Y_3 \sim \mathcal{E}(1)$, 并输出

$$Z := \begin{cases} Y_1, & \text{如果 } Y_3 \leq \ln 2 \\ -Y_1, & \text{如果 } Y_3 > \ln 2 \end{cases}$$

此时 $Z \sim N(0, 1)$. □

有一种用于构造非负连续型随机变量的随机数发生器的办法称为 **Hazard Rate Method**, 由于其论证需要用到 Poisson 过程, 超出本书的范围, 因此请感兴趣的读者参阅文献^[85]中的 Poisson 过程相关的章节。习题9.10原则上提供了一种类似的构造非负整数值随机变量的随机数发生器的办法, 可以视作离散版本的 **Hazard Rate Method**.

下面我们讨论基于均匀分布随机数发生器构造标准正态随机数发生器的其他办法。

例 9.2. 设 $X, Y \sim N(0, 1)$ 且相互独立。记 (X, Y) 的极坐标表示为 (R, Θ) (其中 $\Theta \in [0, 2\pi)$), 那么 $R^2 \sim \mathcal{E}(\frac{1}{2})$, $\Theta \sim U(0, 2\pi)$ 且相互独立 (参见习题8.12)。由此可以有下面基于均匀分布随机数发生器得到标准正态分布随机数发生器的办法 (称为 **Box-Muller Approach**): 设 $U_1, U_2 \sim U(0, 1)$ 且相互独立, 那么下面方程

$$X := \sqrt{-2 \ln U_1} \cos(2\pi U_2), \quad Y := \sqrt{-2 \ln U_1} \sin(2\pi U_2)$$

给出了两个独立同分布的标准正态随机变量 X, Y . □

上述办法中, 计算常数 π 、调用函数 $\cos, \sin$ 都是比较耗时的。注意到, 如果我们能得到 (V_1, V_2) 在单位圆内均匀分布, 则 (V_1, V_2) 的极坐标表示 (R, Θ) 就满足 $R := \sqrt{V_1^2 + V_2^2} \sim U(0, 1)$, $\Theta \sim U(0, 2\pi)$, 且二者相互独立。此时, $\cos \Theta = \frac{V_1}{\sqrt{V_1^2 + V_2^2}}$, $\sin \Theta = \frac{V_2}{\sqrt{V_1^2 + V_2^2}}$. 这样就可以使用下例中的流程来构造标准正态随机数发生器 (规避出现计算 π 、调用函数 $\cos, \sin$):

例 9.3. 以下得到一对独立的标准正态随机变量的方法称为 **Polar Method**:

步骤 1. 产生 $U_1, U_2 \sim U(0, 1)$;

步骤 2. 令 $V_1 := 2U_1 - 1, V_2 := 2U_2 - 1, S := V_1^2 + V_2^2$, 如果 $S \leq 1$, 那么转下一步, 否则转上一步;

步骤 3. 输出 $X := \sqrt{\frac{-\ln S}{S}} \cdot V_1, Y := \sqrt{\frac{-\ln S}{S}} \cdot V_2$. □

更多构造特定随机数发生器的办法, 请参见文献^[85]第 11 章。

9.2 次序统计量

本节我们介绍统计学中的一个重要概念**一次序统计量**。假定我们已经有了来自分布 F 的 n 个简单样本 $\{X_i\}_{i=1}^n$, 亦即 $\{X_i\}_{i=1}^n \stackrel{\text{i.i.d.}}{\sim} F$. 我们可以按照它们的取值从小到大排列, 记作

$$X_{(1:n)} \leq X_{(2:n)} \leq \cdots \leq X_{(n:n)}.$$

当样本量 n 明确时, 也经常简单记 $X_{(i)} := X_{(i:n)}, i = 1, 2, \cdots, n$. 我们称 $\{X_{(i)}\}_{i=1}^n$ 为 $\{X_i\}_{i=1}^n$ 的**次序统计量**, 称 $X_{(i)}$ 是第 i 个**次序统计量**。特别地, 我们也称 $X_{(1)}$ 是**最小次序统计量**, 称 $X_{(n)}$ 是**最大次序统计量**; 此二者是统计学中非常关注的极端值, 有时也简称**极值** (extreme value)。

在习题 9.14 中, 借助若干个数的取大或取小运算, 我们给出了对次序统计量的一种有趣的理解方式。在考虑一些类似于次序统计量的数学量的数学期望计算时, 这种理解方式有时能简化有关计算, 请读者参考习题 9.16—9.18。

下面我们考虑次序统计量的分布律的计算。

例 9.4. 最小次序统计量 $X_{(1)}$ 的分布律计算如下:

$$\begin{aligned} \mathbb{P}(X_{(1)} > x) &= \mathbb{P}(X_1 > x, \cdots, X_n > x) \\ &= \mathbb{P}(X_1 > x) \cdots \mathbb{P}(X_n > x) = [1 - F(x)]^n, \end{aligned}$$

即 $X_{(1)}$ 的分布函数为

$$F_{(1)}(x) = 1 - [1 - F(x)]^n.$$

同理, 最大次序统计量 $X_{(n)}$ 的分布函数为

$$F_{(n)}(x) = F(x)^n.$$

特别地, 如果这些简单样本的公共分布 F 具有密度 ρ , 则最小、最大的次序统计量对应的密度函数分别为

$$\rho_{(1)}(x) = n\rho(x)[1 - F(x)]^{n-1}, \quad \rho_{(n)}(x) = n\rho(x)[F(x)]^{n-1}.$$

一般地, 对于连续的分布函数 F , 基于本章的定理9.1.1、定理9.1.2和第五章的定理5.1.2, 我们有下面的结论:

♠ **定理 9.2.1.** 设 F 是连续的分布函数。

- (i) 如果 $\{X_i\}_{i=1}^n \stackrel{\text{i.i.d.}}{\sim} F$, 那么 $\{U_i := F(X_i)\}_{i=1}^n \stackrel{\text{i.i.d.}}{\sim} U(0, 1)$, 并且两者之间的次序统计量有下面的对应关系:

$$U_{(i)} = F(X_{(i)}), i = 1, \dots, n;$$

- (ii) 如果 $\{U_i\}_{i=1}^n \stackrel{\text{i.i.d.}}{\sim} U(0, 1)$, 那么 $\{X_i := F^{-1}(U_i)\}_{i=1}^n \stackrel{\text{i.i.d.}}{\sim} F$, 并且两者之间的次序统计量有下面的对应关系:

$$X_{(i)} = F^{-1}(U_{(i)}), i = 1, \dots, n.$$

因此, 借助上述定理, 人们经常把统计学中关心的次序统计量的有关问题转化为标准均匀分布的次序统计量问题来考虑。

以下在 F 具有密度函数 ρ 的条件下讨论次序统计量的分布律。此时

$$F(x) = \int_{-\infty}^x \rho(t) dt$$

是连续的分布函数, 因此可以应用上述定理得到下例中结论。

例 9.5. 设 $\{X_i\}_{i=1}^n \stackrel{\text{i.i.d.}}{\sim} F$, 其中 F 是连续的分布函数。则

$$\mathbb{P}(\exists i, j, 1 \leq i < j \leq n, X_i = X_j) = 0. \quad (9.3)$$

因此我们可以认为次序统计量实际上是按照如下严格大小顺序排列的:

$$X_{(1)} < X_{(2)} < \dots < X_{(n)}.$$

参考证明: 只需证明: $\mathbb{P}(X_i = X_j) = 0, \forall i \neq j$. 但实际上, 注意到此时 $\{U_i := F(X_i)\}_{i=1}^n \stackrel{\text{i.i.d.}}{\sim} U(0, 1)$, 我们有 $\{X_i = X_j\} \subset \{U_i = U_j\}$, 进而

$$\mathbb{P}(X_i = X_j) \leq \mathbb{P}(U_i = U_j) = \int_{(0,1)^2} 1_{\{x=y\}} dx dy = 0.$$

因此上例中的结论成立。□

现在, 基于分布 F 具有密度 ρ 的条件, 我们用概率微元法来探讨次序统计量的密度函数的计算问题。在此处的讨论中我们总认为次序统计量是按照如下严格大小顺序排列的:

$$X_{(1)} < X_{(2)} < \dots < X_{(n)}.$$

首先讨论 $X_{(k)}$ 的密度, 其中 $2 \leq k \leq n-1$. 此时

$$\begin{aligned} & \mathbb{P}(X_{(k)} = x + \mathrm{d}x) := \mathbb{P}(X_{(k)} \in (x, x + \mathrm{d}x]) \\ &= \mathbb{P}(X_1, \dots, X_n \text{ 中有 } k-1 \text{ 个取值 } \leq x, \\ & \quad \text{有 1 个取值 } \in (x, x + \mathrm{d}x], \text{ 有 } n-k \text{ 个取值 } > x + \mathrm{d}x) \\ &= \frac{n!}{(k-1)!1!(n-k)!} \cdot [F(x)]^{k-1}[1-F(x)]^{n-k}\rho(x)\mathrm{d}x. \end{aligned}$$

因此, $X_{(k)}$ 的密度为

$$\rho_{(k)}(x) = \frac{n!}{(k-1)!(n-k)!} \cdot [F(x)]^{k-1}[1-F(x)]^{n-k}\rho(x). \quad (9.4)$$

接着, 我们讨论 $(X_{(k)}, X_{(\ell)})$ 的联合密度, 其中 $1 \leq k < \ell \leq n$. 此时, 设 $x < y$,

$$\begin{aligned} & \mathbb{P}(X_{(k)} = x + \mathrm{d}x, X_{(\ell)} = y + \mathrm{d}y) \\ &:= \mathbb{P}(X_{(k)} \in (x, x + \mathrm{d}x], X_{(\ell)} \in (y, y + \mathrm{d}y]) \\ &= \mathbb{P}(\{X_j\}_{j=1}^n \text{ 中有 } k-1 \text{ 个取值 } \leq x, \text{ 有 1 个取值 } \in (x, x + \mathrm{d}x], \text{ 有 } \ell-k-1 \\ & \quad \text{个取值 } \in (x + \mathrm{d}x, y], \text{ 有 1 个取值 } \in (y, y + \mathrm{d}y], \text{ 有 } n-\ell \text{ 个取值 } > y + \mathrm{d}y) \\ &= \frac{n!}{(k-1)!1!(\ell-k-1)!1!(n-\ell)!} \cdot [F(x)]^{k-1}[F(y)-F(x)]^{\ell-k-1} \\ & \quad \cdot [1-F(y)]^{n-\ell}\rho(x)\rho(y)\mathrm{d}x\mathrm{d}y. \end{aligned}$$

因此, $(X_{(k)}, X_{(\ell)})$ 的联合密度为

$$\begin{aligned} \rho_{(k,\ell)}(x,y) &= \frac{n!}{(k-1)!(\ell-k-1)!(n-\ell)!} \cdot [F(x)]^{k-1} \\ & \quad \cdot [F(y)-F(x)]^{\ell-k-1}[1-F(y)]^{n-\ell}\rho(x)\rho(y) \cdot 1_{\{x < y\}}. \end{aligned} \quad (9.5)$$

更一般地, 当 $r \geq 3, 1 \leq k_1 < k_2 < \dots < k_r \leq n$ 时, $(X_{(k_1)}, \dots, X_{(k_r)})$ 的联合密度可以类似计算. 特别地, $(X_{(1)}, \dots, X_{(n)})$ 的联合密度为

$$\rho_{(1,\dots,n)}(x_1, \dots, x_n) = n!\rho(x_1) \cdots \rho(x_n) \cdot 1_{\{x_1 < \dots < x_n\}}. \quad (9.6)$$

我们特意把均匀分布 $U(0,1)$ 的次序统计量的分布律总结为如下定理.

♠ **定理 9.2.2.** 设 $\{U_i\}_{i=1}^n \stackrel{\text{i.i.d.}}{\sim} U(0,1)$, 那么

(i) $U_{(k)}$ 的密度为

$$\rho_{(k)}(x) = \frac{n!}{(k-1)!(n-k)!} \cdot x^{k-1}(1-x)^{n-k} \cdot 1_{(0,1)}(x). \quad (9.7)$$

于是¹ $U_{(k)} = U_{(k:n)} \sim \text{Beta}(k, n - k + 1)$;

- (ii) 对 $2 \leq r \leq n$, $1 \leq k_1 < k_2 < \cdots < k_r \leq n$, $(U_{(k_1)}, \cdots, U_{(k_r)})$ 的联合密度为 (此处约定 $k_0 := 0, k_{r+1} := n + 1$ 以及 $x_0 := 0, x_{r+1} = 1$)

$$\rho_{(k_1, \dots, k_r)}(x_1, \dots, x_r) = \frac{n!}{\prod_{j=1}^{r+1} (k_j - k_{j-1} - 1)!} \cdot \prod_{j=1}^{r+1} (x_j - x_{j-1})^{k_j - k_{j-1} - 1} \cdot 1_{\{0 < x_1 < \cdots < x_r < 1\}}. \quad (9.8)$$

- (iii) $(U_{(1)}, \dots, U_{(n)})$ 的联合密度为

$$\rho_{(1, \dots, n)}(x_1, \dots, x_n) = n! \cdot 1_{\{0 < x_1 < \cdots < x_n < 1\}}. \quad (9.9)$$

基于上面的定理, 约定 $U_{(0)} := 0, U_{(n+1)} := 1$, 不难知道下面结论成立。

♠ **定理 9.2.3.** 设 $\{U_i\}_{i=1}^n \stackrel{\text{i.i.d.}}{\sim} U(0, 1)$, 那么对 $0 \leq k < \ell \leq n + 1, \ell - k \geq 2$,

$$\left\{ \frac{U_{(i)} - U_{(k)}}{U_{(\ell)} - U_{(k)}} \right\}_{i=k+1}^{\ell-1} \stackrel{d}{=} \{U_{(j:\ell-k-1)}\}_{j=1}^{\ell-k-1},$$

并且它们与 $\{U_{(j)}\}_{j \notin (k, \ell)}$ 相互独立。

9.3 阅读材料：随机变量的分类

在之前章节及习题中, 我们频繁地讨论了各种离散型随机变量和连续型随机变量, 很容易给读者造成一种错误印象: 随机变量只有这两种类型。因此, 本节我们特意来详细讨论随机变量的分类, 以便澄清这种错误认知。

例 9.6. 著名的 *Cantor* 函数 F 是一种特殊的分布函数, 它在 $[0, 1]$ 上的定义可以如下构造。令 $F_0(x) = x, x \in C_0 := [0, 1]$. 下一步三等分 C_0 并去掉中间的区间, 得到集合 $C_1 = [0, 1/3] \cup [2/3, 1] =: C_{0,0} \cup C_{0,1}$, 产生两个新的分点 $1/3$ 与 $2/3$, 令 $F_1(0) := 0, F_1(1/3) = F_1(2/3) := \frac{F_0(0) + F_0(1)}{2} = \frac{1}{2}, F_1(1) = 1$, 其余取值采用线性插值。假设已经定义 C_n, F_n , 对集合 C_n 的每个连通区间进行三等分并去掉中间区间的操作, 得到新的集合 C_{n+1} , 产生一系列的新、老的分点 $\{x_{n+1,k} : k = 1, \dots, 2^{n+1}\}$, 定义函数 F_{n+1} 如下: 在之前得到的分点上的函数值与 F_n 相同; 在新的分点 $x_{n+1,k}$ 上的取值定为在 C_n 中包含 $x_{n+1,k}$ 的连

¹这里提醒读者, 次序统计量 $U_{(k)} = U_{(k:n)}$ 在所有次序统计量中是“第 k 小”、“第 $n - k + 1$ 大”的, 这对应了此处 *Beta* 分布的参数。

通区间两端点的 F_n -函数值的平均; 其余函数值采用线性插值. 很容易知道 F_n 一致收敛到某函数 F , 从而 F 仍然为连续函数, 并且是一个分布函数; 它在 Cantor 三分点集 $C := \bigcup_{n=1}^{\infty} C_n$ 上也有如下简单的表达式:

$$F\left(\sum_{k=1}^{\infty} \frac{2x_k}{3^k}\right) = \sum_{k=1}^{\infty} \frac{x_k}{2^k}, \forall \{x_k\}_{k=1}^{\infty} \subset \{0, 1\}.$$

容易验证这样构造的 Cantor 函数 F 满足: (1) F 是连续的分布函数; (2) 对于分布测度 μ_F , 存在 Lebesgue 零测集 $E_0 \in \mathcal{B}$ 使得 $\mu_F(E_0)$, 这也可以等价地表示为 F 的导函数 Lebesgue 几乎处处为 0.

定义 9.3.1. 设 μ 是一个 Borel 测度. 称 a 是 μ 的一个原子, 如果 $\mu(\{a\}) > 0$. 现在设 μ 是 $\mathbb{R}$ 上的 Borel 概率测度, 称 μ 为奇异型 (或奇异连续型), 如果测度 μ 无原子, 且 μ 与 Leb 相互奇异 (记作 $\mu \perp \text{Leb}$, 定义参见第四章). 任给一个分布函数 F , 如果它诱导的分布测度 μ_F 是奇异 (连续) 型, 我们就称 F 是奇异 (连续) 型的, 或是奇异 (连续) 的; 相应地, 具有这种分布函数的随机变量/向量就称为奇异 (连续) 型随机变量/向量.

因此, 在上述定义下, 例9.6中的分布函数 F 是奇异 (连续) 型的.

在本节, 针对随机变量分布的分类, 我们将说明有三种所谓的纯型: 离散型、连续型 (又称绝对连续型) 和奇异型 (又称奇异连续型), 一般随机变量的分布是这三种纯型的凸组合: 任何 $\mathbb{R}$ 上的分布函数 F , 存在离散型分布函数 F_d 、连续型分布函数 F_c 、奇异型分布函数 F_s 以及 $\alpha_d, \alpha_c, \alpha_s \geq 0$, 使得

$$\alpha_d + \alpha_c + \alpha_s = 1, \quad (9.10)$$

$$\alpha_d F_d + \alpha_c F_c + \alpha_s F_s = F. \quad (9.11)$$

特别地, 如果取 $\xi_1 \sim F_d, \xi_2 \sim F_c, \xi_3 \sim F_s$ 及 $I \sim \begin{pmatrix} 1 & 2 & 3 \\ \alpha_d & \alpha_c & \alpha_s \end{pmatrix}$, 并要求它们相互独立, 那么 $\xi := \xi_I \sim F$.

以下我们简略讨论一维随机变量的分布的分类; 高维情形的做法类似. 设 $\xi \sim F$, 其中 F 是分布函数, 它诱导了分布测度 μ_F .

首先我们可以定义 F 的原子点集 $\mathcal{D}$ 如下

$$\mathcal{D} := \{x \in \mathbb{R} : \mu_F(\{x\}) = F(x) - F(x-) > 0\}.$$

进一步定义 $\alpha_d := \mu_F(\mathcal{D}) = \sum_x [F(x) - F(x-)]$.

如果点集 $\mathcal{D}$ 非空, 则 $\alpha_d > 0$, 就可以定义 μ_d 和 F_d 如下:

$$\begin{aligned}\mu_d(A) &:= \mu_F(A \cap \mathcal{D})/\alpha_d, \forall A \in \mathcal{B}, \\ F_d(x) &:= \mu_d((-\infty, x]), \forall x \in \mathbb{R}.\end{aligned}$$

于是 F_d 是离散型概率分布函数。如果 $\mathcal{D} = \emptyset$, 则 $\alpha_d = 0$, 此时可取 F_d 为任一离散型概率分布函数, 比如 $F_d(x) = 1_{[0, \infty)}(x)$.

此时, 不难验证 $G(x) := F(x) - \alpha_d F_d(x) = \mu_F((-\infty, x] \cap \mathcal{D}^c)$ 是一个连续的单调递增函数。因而 G 几乎处处有导函数 G' . 定义 α_c 如下:

$$\alpha_c := \int G'(x) dx.$$

易知, $0 \leq \alpha_c \leq 1 - \alpha_d$, 后一等号成立当且仅当 G 是绝对连续函数。

- (i) $\alpha_c = 0$. 此时可任取一连续型分布函数 F_c (比如取 $F_c(x) = x^+ \wedge 1$), 取 $\alpha_s = 1 - \alpha_d$, 并取 $F_s(x) = G(x)/\alpha_s$, 则 F_s 是一个奇异型分布函数。
- (ii) $\alpha_c = 1 - \alpha_d > 0$. 此时定义 $F_c := G/\alpha_c$, 则 F_c 是连续型概率分布函数。取 $\alpha_s = 0$, 可任取一奇异型分布函数 F_s (如本节提供的 Cantor 分布函数)。
- (iii) $0 < \alpha_c < 1 - \alpha_d$. 此时定义 $F_c(x) := \int_{-\infty}^x G'(x) dx / \alpha_c$, 它是一个连续型概率分布函数。定义 $\alpha_s := 1 - \alpha_d - \alpha_c$, 并取 $F_s = (G - \alpha_c F_c)/\alpha_s$, 它是一个奇异型概率分布函数。

于是我们总有(9.10)、(9.11)成立。

9.4 本章小结与学习建议

在本章, 我们首先介绍了分布函数的刻画定理, 从而得到了基于均匀分布随机数发生器生成服从给定分布律的随机变量的“反函数方法”(Inverse Transform Method); 考虑到很多场景中分布函数的反函数并不容易算出, 我们介绍了基于均匀分布随机数发生器和另一种连续型分布的随机数发生器生成服从第三种连续型分布的随机变量的“舍选法”(Rejection Method), 并基于此方法提供了生成标准正态分布随机数的几个算法。之后, 我们介绍了简单样本的次序统计量, 并基于概率微元法讨论了来自于连续型分布的简单样本的次序统计量的分布律计算问题。最后, 我们讨论了随机变量分布的分类问题, 证明了: 一般而言, 随机变量的分布函数是三类分布函数的凸组合; 这三类分布

函数分别是离散型、连续型（或绝对连续型）和奇异连续型分布函数，它们被称为随机变量分布的三种纯型，对应的随机变量恰好分别传统的离散型随机变量、连续型随机变量和初等概率论中较少提及的奇异连续型随机变量（也简称奇异型随机变量）。对于概率论的初学者，基于均匀分布生成标准正态分布随机数的算法以及最后的随机变量分布的分类理论部分可以跳过；其他部分的内容都建议学习了解。

习 题 9

习题 9.1. 设 F 是分布函数， F^{-1} 是它的广义逆；约定 $F^{-1}(0) := F^{-1}(0+)$, $F^{-1}(1) := F^{-1}(1-)$. 试证明：

- (1) F^{-1} 是单调递增、左连续的；
- (2) $F(F^{-1}(p)) \geq p, \forall p \in (0, 1)$, 而 $F^{-1}(F(x)) \leq x, \forall x$;
- (3) 对 $p \in (0, 1)$, $F^{-1}(p) \leq x$ 当且仅当 $p \leq F(x)$;
- (4) 如果 $F(a) > F(a-)$, 那么 $F^{-1}(p) \equiv a, \forall p \in (F(a-), F(a)]$;
- (5) 如果 $a < b$ 且 $F(x) \equiv p, \forall x \in (a, b)$, 那么 $F^{-1}(p+) > F^{-1}(p)$;
- (6) 如果 $p \in (0, 1)$ 是 F^{-1} 的连续点, 那么 $F^{-1}(p) < x$ 蕴含了 $p < F(x)$.

习题 9.2. 设有两个分布函数 F_0, F_1 以及一个常数 $\alpha \in (0, 1)$. 再设有随机变量 $X_0 \sim F_0, X_1 \sim F_1, I \sim B(1, \alpha)$, 并且此三个随机变量相互独立。试求证： $X_I \sim (1 - \alpha)F_0 + \alpha F_1$.

习题 9.3. 设有随机变量 X_1, X_2 , 分别是离散型、连续型随机变量。求证：对任意 $C \in \mathbb{R}$, $\mathbb{P}(X_1 = X_2 + C) = 0$.

习题 9.4. 设有相互独立随机变量 $X_1 \sim F_1, X_2 \sim F_2$, 其中 F_1, F_2 为分布函数。求证： F_1 是连续函数蕴含了 $\mathbb{P}(X_1 = X_2) = 0$.

习题 9.5. 请基于 $U(0, 1)$ 的随机数发生器来构建标准指数随机数发生器。

习题 9.6. 设 $U \sim U(0, 1)$, 定义 X_1 为 $2U$ 的整数部分；一般地, 设 $2^n U$ 的整数部分为 N_n , 如果它是奇数则令 $X_n = 1$, 否则 $X_n = 0$. 求证: $\{X_n\}_1^\infty$ 是 i.i.d. 的, 服从等概率的 0-1 两点分布, 并且 $U = \sum_{n=1}^{\infty} \frac{X_n}{2^n}$.

习题 9.7. 本习题想要说明: $((0, 1), \mathcal{B}_{(0,1)}, \text{Leb})$ 已经是一个非常丰富的概率空间了。事实上, 对任意 $x \in (0, 1)$, 设它的二进制表示为 $x = \sum_{n=1}^{\infty} \frac{x_n}{2^n}$, 其中 $x_n \in \{0, 1\}$ (此处不允许序列 $\{x_n\}_1^{\infty}$ 从某个位置开始后续全部为 1, 以保证表示的唯一性)。我们可以把序列 $\{x_n\}_1^{\infty}$ 排列成如下无穷矩阵形式:

$$\begin{array}{ccccccc} x_1 & x_2 & x_9 & x_{10} & \cdots \\ x_4 & x_3 & x_8 & x_{11} & \cdots \\ x_5 & x_6 & x_7 & x_{12} & \cdots \\ x_{16} & x_{15} & x_{14} & x_{13} & \cdots \\ \vdots & \vdots & \vdots & \vdots & \cdots \end{array}$$

其中第 i 行、第 j 列的元素记作 $x_{i,j}$. 我们可以如下定义随机变量

$$U_i := \sum_{j=1}^{\infty} \frac{x_{i,j}}{2^j}.$$

请证明: $\{U_i\}_{i=1}^{\infty}$ 是 *i.i.d.* 的随机变量序列, 共同分布为 $(0, 1)$ 上均匀分布。

习题 9.8. 设 $\{X_n\}_{n=1}^{\infty} \stackrel{\text{i.i.d.}}{\sim} B(1, \frac{1}{2})$, 令 $Y := \sum_{n=1}^{\infty} \frac{2X_n}{3^n}$. 求证: Y 是良定义的随机变量, 它的分布函数恰为例 9.6 中介绍的 *Cantor* 分布函数。

习题 9.9. 计算例 9.6 中介绍的 *Cantor* 分布对应的数学期望与方差。

习题 9.10. 设 X 是非负整数值随机变量, 定义 $h(k) := \mathbb{P}(X = k | X \geq k)$, $k \geq 0$. 若 $\{U_n\}_{n=0}^{\infty} \stackrel{\text{i.i.d.}}{\sim} U(0, 1)$, 证明: $Z := \min\{n : U_n \leq h(n)\}$ 与 X 同分布。(注: 此处构建随机数发生器的办法可以称为离散版本的 *Hazard Rate Method*; 用 *Inverse Transformation Method* 及此处方法都可以构建几何分布 $\text{Geo}(\frac{1}{2})$ 的随机数发生器; 请读者思考两种方法在计算机上实现的优劣。)

习题 9.11. 设 $\{X_k\}_{k=1,2} \stackrel{\text{i.i.d.}}{\sim} N(0, 1)$, 求证¹: $\frac{X_1 X_2}{\sqrt{X_1^2 + X_2^2}} \sim N(0, 1)$.

习题 9.12. 设有相互独立随机变量 $X_1 \sim F_1, X_2 \sim F_2$, 其中 F_1, F_2 为分布函数。求证: F_1 是连续函数蕴含了 $X_1 + X_2$ 的分布函数也是连续函数; X_1 是连续型的蕴含了 $X_1 + X_2$ 也是连续型的。

习题 9.13. 设 $\{U_k\}_{k=1}^n \stackrel{\text{i.i.d.}}{\sim} U(0, 1)$. 求证: $1 \leq i < j \leq n$ 时, $U_{(j)} - U_{(i)} \stackrel{d}{=} U_{(j-i)}$.

¹ 本题来自 Larry Shepp (谢普), 参见文献^[20]的 Exercise 4.40.

习题 9.14. 在实数域中, 记 $a \vee b := \max(a, b)$, $a \wedge b := \min(a, b)$. 关于次序统计量, 请证明如下结论:

$$\bigvee_{i=1}^n x_i = \sum_{r=1}^n (-1)^{r-1} \sum_{1 \leq j_1 < \dots < j_r \leq n} \bigwedge_{k=1}^r x_{j_k}, \quad (9.12)$$

$$\bigwedge_{i=1}^n x_i = \sum_{r=1}^n (-1)^{r-1} \sum_{1 \leq j_1 < \dots < j_r \leq n} \bigvee_{k=1}^r x_{j_k}. \quad (9.13)$$

上面第一个式子中, 取 $x_i = 1_{A_i}$, 注意到 $\max(1_{A_1}, \dots, 1_{A_n}) = 1_{A_1 \cup \dots \cup A_n}$, $\min(1_{A_1}, \dots, 1_{A_n}) = 1_{A_1 \cap \dots \cap A_n}$, 立即得到容斥原理.

更一般地, 如果把 $x_1, \dots, x_n$ 从小到大排序, 记作

$$x_{(1:n)} \leq x_{(2:n)} \leq \dots \leq x_{(n:n)},$$

也称 $\{x_{(k:n)}\}_{k=1}^n$ 是数据 $\{x_k\}_{k=1}^n$ 的次序统计量. 那么对任意 $1 \leq m \leq n$

$$x_{(m:n)} = \sum_{r=m}^n (-1)^{r-m} \binom{r-1}{m-1} \sum_{1 \leq j_1 < \dots < j_r \leq n} \bigvee_{k=1}^r x_{j_k} \quad (9.14)$$

$$= \sum_{r=n-m+1}^n (-1)^{r-(n-m+1)} \binom{r-1}{n-m} \sum_{1 \leq j_1 < \dots < j_r \leq n} \bigwedge_{k=1}^r x_{j_k}. \quad (9.15)$$

值得指出的是, 如果函数 φ 是单调递增函数, 那么数据 $\{y_k := \varphi(x_k)\}_{k=1}^n$ 的次序统计量满足 $y_{(m:n)} = \varphi(x_{(m:n)})$, $m = 1, \dots, n$, 从而它们也满足上面的方程.

习题 9.15. 设 $\{A_k\}_{k=1}^n$ 是一列互斥的正概率事件, 我们把它们视作重复试验中的现象. 记 τ_i 为 A_i -条件实验的实验序号, 记 $\{\tau_{(i)}\}_{i=1}^n$ 为 $\{\tau_i\}_{i=1}^n$ 的次序统计量. 求证: $\tau_{(r)}$ 代表重复实验中累计恰观察到 $\{A_k\}_{k=1}^n$ 中 r 种不同现象所需的最少实验次数, 其中 $1 \leq r \leq n$.

习题 9.16. 本题是来自知乎社区的数学问题. 上一习题中结论就是编者受此问题激发而总结. 某网络游戏中击杀一次怪物 M 有可能掉落 4 种装备 $A_1, \dots, A_4$ 中的一种 (或不掉落任何装备), 其中掉落 A_1 的概率为 10%, 掉落 A_2 的概率为 20%, 掉落 A_3 或 A_4 的概率均为 30%. 若想集齐一整套装备, 求需要击杀怪物 M 的次数的期望值?

习题 9.17. 某网络游戏中击杀一次怪物 M 有可能掉落 2 种装备 A_1, A_2 中的一种 (或不掉落任何装备), 其中掉落 A_1 的概率为 10%, 掉落 A_2 的概率为 20%. 记 τ 为想集齐一整套装备所需的击杀怪物 M 的次数. 求 τ 的期望值与方差.

习题 9.18. 记 τ 为连续投掷一枚均匀的骰子直至六个面都出现为止所进行的实际投掷次数. 求 $\mathbb{E}\tau$ 和 $\text{Var}(\tau)$.

习题 9.19. 请基于定理 9.2.2 证明定理 9.2.3.

习题 9.20. (充分统计量的因子化定理) 设 $\{\mu_\theta\}_{\theta \in \Theta}$ 为 $\mathbb{R}^n$ 上一族概率测度 (也称为分布族; 对应数学期望将记作 $\mathbb{E}_\theta$), 它们关于 $\mathbb{R}^n$ 上 σ -有限测度 ν 绝对连续: $\mu_\theta \ll \nu, \forall \theta \in \Theta$, 记 $\rho_\theta := \frac{d\mu_\theta}{d\nu}$. 总假定 $X \sim \mu_\theta$. 设 $T: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 为可测函数, 记 $T := T(X)$, 称之为统计量. 称 T 是 (关于 θ 的) 充分统计量, 如果条件分布 $X|T(X)$ 与 θ 无关. 请证明 T 是关于 θ 的充分统计量的一个充分条件是: 存在非负可测函数 $g_\theta: \mathbb{R}^m \rightarrow \mathbb{R}$ 及 $h: \mathbb{R}^n \rightarrow \mathbb{R}$ 使得 $\rho_\theta(x) = g_\theta(T(x))h(x)$. Neyman 证明了这个条件也是必要的.

习题 9.21. (接习题 9.20) 统计量 $T = T(X)$ 称为关于分布族 $\{\mu_\theta\}_{\theta \in \Theta}$ 是完全统计量 (或完备统计量), 如果对于任意 (可积的) 可测函数 ψ ,

$$\mathbb{E}_\theta[\psi(T)] = 0, \forall \theta \in \Theta$$

蕴含了 $\mu_\theta(\{\psi(T) = 0\}) = 1, \forall \theta \in \Theta$. 任意给定可测函数 $g: \Theta \rightarrow \mathbb{R}$. 统计量 $\hat{g} = \hat{g}(X)$ 称为是参数 $g(\theta)$ 的无偏估计, 如果 $\mathbb{E}_\theta[\hat{g}] = g(\theta), \forall \theta$. 求证:

(1) 如果 T 是分布族 $\{\mu_\theta\}_{\theta \in \Theta}$ 的完全统计量, 则

$$\{h(T): h \text{ 为可测函数, 且 } \mathbb{E}_\theta[h(T)] = g(\theta), \forall \theta \in \Theta\}$$

是空集或单点集;

(2) (Rao-Blackwell) 如果 $\hat{g}$ 是 $g(\theta)$ 的无偏估计, 且 T 是分布族 $\{\mu_\theta\}_{\theta \in \Theta}$ 的充分统计量, 那么: $h(T) := \mathbb{E}[\hat{g}|T]$ 也是 $g(\theta)$ 的无偏估计 (参见习题 7.14), 并且 (当可以谈方差时)

$$\text{Var}_\theta(h(T)) \leq \text{Var}_\theta(\hat{g}), \forall \theta \in \Theta.$$

上面不等式中等号恒成立的充要条件是 $\mu_\theta(\{h(T) = \hat{g}(X)\}) = 1, \forall \theta \in \Theta$;

(3) (Lehmann-Scheffé) 如果 T 是充分且完全的统计量, $\hat{g}$ 是 $g(\theta)$ 的方差有限的无偏估计, 那么 $h(T) = \mathbb{E}[\hat{g}|T]$ 是 $g(\theta)$ 的唯一的一致最小方差无偏估计 (UMVUE).

习题 9.22. 对习题 9.20 中的分布族 $\{\mu_\theta\}_{\theta \in \Theta}$, 如果 $\rho_\theta := \frac{d\mu_\theta}{d\nu}$ 具有表达式

$$\rho_\theta(x) = C(\theta) \exp\left\{\sum_{j=1}^k Q_j(\theta) T_j(x)\right\} h(x),$$

其中 $C(\cdot), Q_j(\cdot), T_j(\cdot), h(\cdot)$ 都是可测函数, 则称分布族 $\{\mu_\theta: \theta \in \Theta\}$ 是指数分布族. 求证:

(1) 统计量 $T(X) := (T_1(X), \dots, T_k(X))$ 是充分的; 进一步, 如果

$$\{(Q_1(\theta), \dots, Q_k(\theta)) : \theta \in \Theta\}$$

在 $\mathbb{R}^k$ 中有内点, 那么 $T(X)$ 也是完全的。

(2) 对指数分布族 $\{\mu_\theta\}_{\theta \in \Theta}$, 存在某 σ -有限测度 μ 满足 $\mu_\theta \ll \mu$, 以及可逆参数变换 $\tilde{\theta} = g(\theta)$, $\tilde{\Theta} := \{g(\theta) : \theta \in \Theta\}$ (从而作认同: $\mu_{\tilde{\theta}} := \mu_\theta$), 使得

$$\frac{d\mu_{\tilde{\theta}}}{d\mu} = \frac{1}{Z(\tilde{\theta})} \exp\left\{\sum_{j=1}^k \tilde{\theta}_j T_j(x)\right\}, \forall \tilde{\theta} \in \tilde{\Theta}.$$

(上式蕴含了 $\tilde{\theta}_j = Q_j(\theta)$, $j = 1, \dots, k$.) 此时, 如果 $\tilde{\theta}$ 的各分量都是独立的自由变量, 并且 $Z(\tilde{\theta})$ 关于 $\tilde{\theta}$ 连续可微, 那么

$$\frac{\partial \log Z}{\partial \tilde{\theta}_i} = \mathbb{E}[T_i(X)], \quad i = 1, \dots, k.$$

习题 9.23. 设 $\{X_k\}_{k=1}^n \stackrel{\text{i.i.d.}}{\sim} U(0, \theta)$, 其中 $\theta > 0$ 未知. 请证明: $X_{(n)} := \max_{1 \leq k \leq n} X_k$ 是完全、充分统计量。

习题 9.24. 任给 $p \in (0, 1)$, $q := 1 - p$, 是否可以通过有限次投掷一枚均匀骰子生成一个服从 $B(1, p) = \binom{0}{q} \binom{1}{p}$ 分布的随机数 Y ? 如果可以, 你的算法平均需要投掷这个骰子多少次?

习题 9.25. 在知乎上有这样一个有意思的问题: $n \geq 3$ 只小鸭子在一个圆形大水池中相互独立地随机游泳, 它们的实际位置 (视作质点) 记作 $\{P_i\}_{i=0}^{n-1}$; 我们关心它们同时落入某个半圆 (圆心仍然是大水池的圆心 O) 的概率. 为了简化问题实现概率建模, 设想水池周边已标记好了相对于大圆周上某初始点 (记为 O^*) 的圆心角 (按逆时针方向计量角度). 设想圆心 O 点与第 i 只鸭子所在位置 P_i 的连线与大圆周交于点 P_i^* , 而沿着大圆周从 O^* 逆时针走到 P_i^* 所经历的圆心角刻度记作 Θ_i , $\{\Theta_i\}_{i=0}^{n-1}$ 可以视作此 n 只鸭子的绝对圆心角坐标. 定义 $X_i = \frac{\Theta_i}{2\pi}$. 我们可以假定 $\{\Theta_i\}_{i=0}^{n-1} \stackrel{\text{i.i.d.}}{\sim} U(0, 2\pi)$; 我们也可以如下设想: 我们总是把第 0 只鸭子 (这是群鸭中做了特殊固定标记的一只鸭子, 比如把它叫做“头领鸭”) 的相对圆心角坐标记作 $\hat{\Theta}_0 := 0$, 而第 $i \geq 1$ 只鸭子的相对圆心角坐标记作 $\hat{\Theta}_i$ (它实际对应于沿着大圆周从 P_0^* 逆时针走到 P_i^* 所经历的圆心角刻度), 定义 $\hat{X}_i = \frac{\hat{\Theta}_i}{2\pi}$. 我们把 $\{X_i\}_{i=0}^{n-1}$ 叫做群鸭的“绝对坐标”, 而把 $\{\hat{X}_i\}_{i=1}^{n-1}$ 叫做诸普通鸭相对“头领鸭”的“相对坐标”。

(1) 给出“绝对坐标”到“相对坐标”的计算公式;

- (2) 证明 $\{\hat{X}_i\}_{i=1}^{n-1} \stackrel{\text{i.i.d.}}{\sim} U(0, 1)$, 且它们与 X_0 相互独立;
- (3) 基于上述概率建模算出 $n \geq 3$ 只小鸭子落入某半圆的概率。

第十章 随机变量列的收敛与大数律

在本章我们将先介绍 Chebyshev (切比雪夫) 不等式, 之后介绍有关随机变量列的各种收敛的定义: 几乎处处收敛/几乎必然收敛¹、依概率收敛、 L^p -收敛与依分布收敛; 在讨论了几种收敛之间的关系后, 我们将进一步介绍历史上几个著名的大数律, 其中也将系统性地介绍证明几乎处处收敛的重要概率工具: Borel-Cantelli 引理以及 Borel-Cantelli 引理第二引理。最后, 我们给出本章理论的一些应用实例。

10.1 Chebyshev 不等式

在概率论中, 有一个简单、但又非常重要的不等式, 这就是下面的 Chebyshev 不等式; 有些文献称之为 Markov 不等式, 此处我们不作区分。

♠ **定理 10.1.1.** (Chebyshev 不等式) 设 ξ 是一个随机变量, 则对任意 $\varepsilon > 0$

$$\mathbb{P}(|\xi| \geq \varepsilon) \leq \frac{1}{\varepsilon} \cdot \mathbb{E}|\xi|.$$

上面定理的证明很简单, 只需在天然的不等式 $1_{\{|\xi| \geq \varepsilon\}} \leq \frac{|\xi|}{\varepsilon}$ 两边取数学期望即可; 但这个定理及其思想在概率论中非常重要, 它实现了通过数学期望的计算来估算概率, 为估算概率带来了极大的便利。历史上 Bernoulli 得到他的大数律是通过复杂的概率估算实现的; 而基于 Chebyshev 不等式, 今天的我们对 Bernoulli 大数律的证明不过短短一行; 请参见后文相关论述。

📌 **注 10.1.** 原始的 Chebyshev 不等式是用二阶矩来估计概率的, 是俄国数学家、力学家 P. L. Chebyshev (切比雪夫, 1821—1894) 首创的方法, 用来简洁地论证 Bernoulli 弱大数律, 进而得到更一般的 Chebyshev 弱大数律。Chebyshev 生于奥卡多沃, 卒于彼得堡。他早年接受家庭教育, 1841 年毕业于莫斯科大学并获银质奖章, 1847 年开始任彼得堡大学副教授, 1850 年升为教授, 1859 年被选为彼得堡科学院院士。他终身未娶, 日常生活十分简朴, 他的一点积蓄全部用来买书和造机器, 最大乐趣是与年轻人讨论数学问题。以 Chebyshev 为首, 19 世纪下半叶俄国开始形成自己的第一个有国际影响的数学学派, 称为圣彼得堡学派或 Chebyshev 学派。

¹ “几乎处处收敛”或“几乎必然收敛”在有些文献中也称为“以概率 1 收敛”。




图 10.1: P. L. Chebyshev(1821-1894)



图 10.2: A. A. Markov(1856-1922)

Chebyshev 培养的知名学生有: *A. Korkin* (科尔金; 1837—1908; 俄罗斯数学家, 在偏微分方程方向有贡献, 是当时的圣彼得堡学派的第二把交椅), *K. A. Posse* (泼什; 1847—1928; 俄罗斯数学家, 在数学分析、特别是逼近论方面有贡献), *A. A. Markov* (安德雷·马尔可夫; 1856—1922; 俄国), *A. Lyapunov* (李雅普诺夫; 1857—1918; 俄罗斯数学家、力学家、物理学家, 以发展了动力系统的稳定性理论闻名, 对数学物理和概率论也有很多贡献), *D. Grave* (格列夫; 1863—1939; 俄罗斯-苏联数学家, 被认为是代数学 *Kyiv* 大学学派创始人, 这个大学后来成为苏联代数学的中心; 他的另一位博士论文导师是 *A. Korkin*), *V. A. Markov* (*V*·马尔可夫 1871—1897; 俄罗斯数学家, *A. A. Markov* 的弟弟, 与他哥哥一块证明了 *Markov* 不等式)。

A. A. Markov (马尔可夫, 1856—1922; 俄国) 是 *Chebyshev* 最亲密的学生。他 1874 年进入彼得堡大学物理数学系学习, 1878 年毕业于圣彼得堡大学并获得金质奖章; 1880 年获得硕士学位, 并在彼得堡大学任教, 1884 年获得物理数学博士学位, 1886 年成为教授。他在 1896 年当选为圣彼得堡科学院院士; 上面的不等式是他整理提出的。*Markov* 被 *Kolmogorov* 评价为“*Chebyshev* 思想的优秀表达者”[116, 序言]; 他同时也是马氏链 (*Markov Chain*) 理论的开创者。他的儿子也叫 *A. A. Markov* (小马尔可夫, 1903—1979), 也是数学家, 但专长是数理逻辑。

Markov 培养的知名学生有: *G. Voronoy* (沃罗诺伊; 1868—1908; 俄罗斯数学家, 以 *Voronoi* 图、*Voronoi* 迭代/算法、*Voronoi* 公式知名), *V. Kagan* (卡根; 1869—1953; 俄罗斯-苏联数学家, 专长是几何学, 他是 *Y. Sinai* 和 *G. Barenblatt* 的外祖父, 他的另一位博士论文导师是 *Konstantin Posse*), *N. Günther* (冈瑟; 1871—1941; 俄罗斯数学家, 以位势理论、积分和偏微分方程方面的工作而知名, 他是连续三届国际数学家大会的邀请报告人; 1924 年多伦多、1928 年波洛尼亚、1932 年苏黎世), *V. I. Romanovsky* (罗曼诺夫斯基; 1879—1954; 俄罗斯-苏联-乌兹别克斯坦数学家, 塔什干数学学派创始人), *J. V. Uspensky* (乌斯本斯基; 1883—1947; 俄罗斯-美国数学家, 以 *Theory of Equations* 而知名), *J. Tamarkin* (塔玛金; 1888—1945; 俄罗斯-美国数学家, 以数学分析方向的工作知名, 美国女数学家 *D. L. Bernstein* (伯恩斯坦)、美国数学家 *N. Dunford* (邓福德)、斯坦福计算机系创始系主任 *G. Forsythe* (福赛思) 等都是他的学生), *A. Besicovitch* (贝斯科维奇; 1891—1970; 俄罗斯数学家, 以 *Hausdorff-Besicovitch* 维数、*Besicovitch* 函数、*Besicovitch* 覆盖定理等闻名于世) 等。

Chebyshev 不等式有下面一个简单但又非常实用的推论, 它给出了第五章随机变量定义的补丁程序中条件 $\mathbb{P}(|\xi| = \infty) = 0$ 的一种简洁的验证手段:

☞ 推论 10.1.1. 对于广义实值随机变量 ξ , $\mathbb{E}|\xi| < \infty$ 蕴含了 $|\xi| < \infty$ a.s..

另外 *Chebyshev* 不等式还有如下一些重要分布上的应用。下面的几个例子

中都是通过计算矩母函数来实现对相应事件概率的估计的, 这种方法给出的界称为切诺夫界 (Chernoff Bounds)。

例 10.1. 设 $Z \sim N(0, 1)$, 则对 $a > 0$

$$\mathbb{P}(Z \geq a) \leq e^{-a^2/2}.$$

参考证明: 考虑引进带参数 $t > 0$ 的函数 $g(x, t) = e^{tx}$. 于是 $Z \geq a$ 当且仅当 $g(Z, t) \geq g(a, t) > 0$, 由 Chebyshev 不等式

$$\mathbb{P}(Z \geq a) \leq \frac{\mathbb{E}g(Z, t)}{g(a, t)} = \exp\left\{\frac{t^2}{2} - at\right\}.$$

上式中取 $t = a$, 立即得到欲证明的不等式。使用纯分析方法, 习题10.54给出了更精细的估计; 感兴趣的读者可以自行尝试给出证明。 $\square$

例 10.2. 设 $X \sim \text{Poisson}(\lambda)$, 则对任意 $\delta > 0$, $\mathbb{P}(|X - \lambda| \geq \delta) \leq \frac{\lambda}{\delta^2}$. 此外, 我们有 Poisson 分布对应的 Chernoff 界如下:

$$\mathbb{P}(X \geq x) \leq \left(\frac{e\lambda}{x}\right)^x \cdot e^{-\lambda}, \forall x \geq [\lambda, \infty), \quad (10.1)$$

$$\mathbb{P}(X \leq x) \leq \left(\frac{e\lambda}{x}\right)^x \cdot e^{-\lambda}, \forall x \in (0, \lambda]. \quad (10.2)$$

特别地,

$$\mathbb{P}(X \geq \lambda + \delta) \leq \exp\left\{-\frac{\delta^2}{2(\lambda + \delta)}\right\}, \forall \delta > 0 \quad (10.3)$$

$$\mathbb{P}(X \leq \lambda - \delta) \leq \exp\left\{-\frac{\lambda - \frac{5}{3}\delta}{2(\lambda - \delta)^2} \cdot \delta^2\right\}, \forall \delta \in (0, \frac{\lambda}{2}]. \quad (10.4)$$

参考证明: 由于 $\mathbb{E}X = \lambda, \text{Var}(X) = \lambda$, 第一个不等式是 Chebyshev 不等式的简单应用。

注意到 $\mathbb{E}[e^{tX}] = \exp\{\lambda(e^t - 1)\}$, 对任意给定 $x > 0$, 取 $t := \ln(x/\lambda)$, 有

$$e^{-tx} \mathbb{E}[e^{tX}] = \left(\frac{e\lambda}{x}\right)^x \cdot e^{-\lambda}.$$

这里请注意: 当 $x \geq \lambda$ 时, $t := \ln(x/\lambda) \geq 0$; 当 $0 < x \leq \lambda$ 时 $t := \ln(x/\lambda) \leq 0$. 对随机变量 $e^{t(X-x)}$ 应用 Chebyshev 不等式, 就得到(10.1)、(10.2).

在(10.1)中取 $x = \lambda + \delta$, 再结合不等式

$$\ln\left(1 - \frac{\delta}{\lambda + \delta}\right) \leq -\frac{\delta}{\lambda + \delta} - \frac{\delta^2}{2(\lambda + \delta)^2}, \forall \delta > 0$$

立即得到(10.3).

当 $\delta \in (0, \frac{\lambda}{2}]$ 时, 在(10.2)中取 $x = \lambda - \delta$, $\frac{\delta}{\lambda - \delta} \in (0, 1]$, 此时注意到

$$\ln(1 + \frac{\delta}{\lambda - \delta}) \leq \frac{\delta}{\lambda - \delta} - \frac{\delta^2}{2(\lambda - \delta)^2} + \frac{\delta^3}{3(\lambda - \delta)^3}, \forall \delta \in (0, \frac{\lambda}{2}]$$

立即可以整理得到(10.4). □

10.2 随机变量列的收敛性

本节我们讨论随机变量列的各种收敛性及其之间的关系。

10.2.1 各种收敛性的定义

概率论中, 关于随机变量列的收敛, 主要有下面几种不同的收敛性。

定义 10.2.1. 设 $\{\xi_n\}_{n=1}^{\infty}$ 为一个随机变量序列, ξ 为一个随机变量。

- (1) 称 $\{\xi_n\}_{n=1}^{\infty}$ **几乎处处收敛/几乎必然收敛** 到 ξ , 记作 $\xi_n \xrightarrow{a.e.} \xi$ 或 $\xi_n \xrightarrow{a.s.} \xi$, 或 $\lim_{n \rightarrow \infty} \xi_n \stackrel{a.e.}{=} \xi$, 或 $\lim_{n \rightarrow \infty} \xi_n \stackrel{a.s.}{=} \xi$, 如果

$$\mathbb{P}(\lim_{n \rightarrow \infty} \xi_n \neq \xi) = 0.$$

- (2) 称 $\{\xi_n\}_{n=1}^{\infty}$ **依概率收敛** 到 ξ , 记作 $\xi_n \xrightarrow{\mathbb{P}} \xi$, 如果

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\xi_n - \xi| \geq \varepsilon) = 0, \quad \forall \varepsilon > 0;$$

- (3) 给定 $p > 0$, $\{\xi_n\}_{n=1}^{\infty}$ 称为 **L^p 收敛** 到 ξ , 记作 $\xi_n \xrightarrow{L^p} \xi$, 如果

$$\lim_{n \rightarrow \infty} \mathbb{E}[|\xi_n - \xi|^p] = 0;$$

- (4) $\{\xi_n\}_{n=1}^{\infty}$ 称为 **依分布收敛**¹ 到 ξ , 记作 $\xi_n \xrightarrow{d} \xi$, 如果

$$\lim_{n \rightarrow \infty} F_n(x) = F(x)$$

在 F 的所有连续点 x 上成立; 此处 F_n, F 分别是 ξ_n, ξ 的分布函数; 有时也记 $F_n \xrightarrow{w} F$ 或 $\xi_n \xrightarrow{d} F$.

¹ 当 μ_n, μ 分别是 ξ_n, ξ 的分布测度时, 也记 $\mu_n \xrightarrow{w} \mu$, 称为弱收敛, 参见第十一章。

在本章第10.3节我们通过定理10.3.8指出, 当 $\{X_n\}_{n=1}^{\infty} \stackrel{\text{i.i.d.}}{\sim} B(1, p)$ 时,

$$\xi_n := \frac{X_1 + \cdots + X_n}{n} \xrightarrow{\text{a.s.}} p;$$

可以知道在以上四种收敛意义下均有 $\xi_n \rightarrow p$ 成立。

需要指出的是, 在上述定义中, 与其他收敛性不同, 依分布收敛的随机变量列本身可以定义在不同的概率空间中, 而不必定义在同一个概率空间; 本质上它是分布函数列的一种收敛性质。关于依分布收敛 (及更一般的测度的弱收敛), 第十一章将进一步详细论述。本章重点讨论前三种收敛性质之间的关系。

10.2.2 几种收敛之间的关系

§10.2.2 (A) L^p -收敛、依概率收敛与几乎处处收敛之间的关系

一般而言, L^p -收敛、依概率收敛与几乎处处收敛之间的关系如下。

♠ **定理 10.2.1.** 设 $\{\xi_n : n \geq 1\}$ 为一个随机变量序列, ξ 为一个随机变量。

- (1) 给定 $p > 0$, $\xi_n \xrightarrow{L^p} \xi$ 蕴含了 $\xi_n \xrightarrow{\mathbb{P}} \xi$;
- (2) $\xi_n \xrightarrow{\text{a.s.}} \xi$ 蕴含了 $\xi_n \xrightarrow{\mathbb{P}} \xi$;
- (3) 若 $\xi_n \xrightarrow{\mathbb{P}} \xi$, 则存在子序列 $\{\xi_{n_k} : k \geq 1\}$ 使得 $\xi_{n_k} \xrightarrow{\text{a.s.}} \xi$.

证明: 结论 (1) 由 Chebyshev 不等式保证。

结论 (2) 的证明如下。容易验证

$$\{\omega : \lim \xi_n(\omega) \neq \xi(\omega)\} = \bigcup_{k=1}^{\infty} \bigcap_{N=1}^{\infty} \bigcup_{n=N}^{\infty} \{\omega : |\xi_n(\omega) - \xi(\omega)| \geq \frac{1}{k}\},$$

从而 $\xi_n \xrightarrow{\text{a.s.}} \xi$ 时,

$$0 = \mathbb{P}\left(\lim_{n \rightarrow \infty} \xi_n \neq \xi\right) = \mathbb{P}\left(\bigcup_{k=1}^{\infty} \bigcap_{N=1}^{\infty} \bigcup_{n=N}^{\infty} \{\omega : |\xi_n(\omega) - \xi(\omega)| \geq \frac{1}{k}\}\right).$$

进而对任意 $k \geq 1$

$$\begin{aligned} 0 &= \mathbb{P}\left(\bigcap_{N=1}^{\infty} \bigcup_{n=N}^{\infty} \{\omega : |\xi_n(\omega) - \xi(\omega)| \geq \frac{1}{k}\}\right) \\ &= \lim_{N \rightarrow \infty} \mathbb{P}\left(\bigcup_{n=N}^{\infty} \{\omega : |\xi_n(\omega) - \xi(\omega)| \geq \frac{1}{k}\}\right) \\ &\geq \overline{\lim}_{n \rightarrow \infty} \mathbb{P}\left(\{\omega : |\xi_n(\omega) - \xi(\omega)| \geq \frac{1}{k}\}\right), \end{aligned}$$

即知 $\lim_{n \rightarrow \infty} \mathbb{P}(|\xi_n - \xi| \geq \varepsilon) = 0, \forall \varepsilon > 0$.

下面证明结论 (3). 由于 $\xi_n \xrightarrow{\mathbb{P}} \xi$, 对任意整数 $k \geq 1$, 必存在 n_k 使得

$$\mathbb{P}(|\xi_{n_k} - \xi| \geq \frac{1}{k}) \leq \frac{1}{2^k}.$$

由 B-C 引理, 集合 $\mathcal{N} := \bigcap_{K=1}^{\infty} \bigcup_{k=K}^{\infty} \{\omega : |\xi_{n_k}(\omega) - \xi(\omega)| \geq \frac{1}{k}\}$ 对应的概率为 0;

显然 $\forall \omega \notin \mathcal{N}, \lim_{k \rightarrow \infty} \xi_{n_k}(\omega) = \xi(\omega)$. 因此 $\xi_{n_k} \xrightarrow{\text{a.s.}} \xi$. $\square$

为了进一步阐述各种收敛之间的关系, 我们引入一致可积的概念; 这个概念本身也是概率论中的重要概念之一。

定义 10.2.2. 设 $\{\xi_\alpha\}_{\alpha \in I}$ 为 (可积的) 随机变量族, 称它是一致可积的, 如果

$$\lim_{N \rightarrow \infty} \sup_{\alpha \in I} \mathbb{E}[|\xi_\alpha| \cdot 1_{\{|\xi_\alpha| \geq N\}}] = 0.$$

显然, 如果随机变量族被同一个可积的随机变量所控制, 则这族随机变量是一致可积的; 反之未必成立。

下面定理给出了一致可积的一种等价刻画, 它形式上与泛函分析中的 Ascoli-Arzelà 定理非常相似。

♠ 定理 10.2.2. 设 $\{\xi_\alpha\}_{\alpha \in I}$ 为一个 (可积的) 随机变量族, 则它一致可积的充分必要条件是:

- (1) 等度绝对连续¹: 对任意 $\varepsilon > 0$, 存在 $\delta > 0$ 使得当 $A \in \mathcal{F}$ 满足 $\mathbb{P}(A) < \delta$ 时就有 $\mathbb{E}[|\xi_\alpha| \cdot 1_A] < \varepsilon, \forall \alpha \in I$;
- (2) 一致 L^1 有界: $\sup_{\alpha \in I} \mathbb{E}|\xi_\alpha| < \infty$.

证明: 必要性. 对任意 $A \in \mathcal{F}, N > 0$, 有

$$\begin{aligned} \mathbb{E}[|\xi_\alpha| \cdot 1_A] &= \mathbb{E}[|\xi_\alpha| \cdot 1_{A \cap \{|\xi_\alpha| \geq N\}}] + \mathbb{E}[|\xi_\alpha| \cdot 1_{A \cap \{|\xi_\alpha| < N\}}] \\ &\leq \mathbb{E}[|\xi_\alpha| \cdot 1_{\{|\xi_\alpha| \geq N\}}] + N\mathbb{P}(A). \end{aligned}$$

由一致可积性, 推出 (1) 中的等度绝对连续性. 在上式中取 $A = \Omega$, 得

$$\mathbb{E}[|\xi_\alpha|] \leq \mathbb{E}[|\xi_\alpha| \cdot 1_{\{|\xi_\alpha| \geq N\}}] + N,$$

¹此条也可等价地表述为: 对任意 $\varepsilon > 0$, 存在 $\delta > 0$ 使得当 $A_\alpha \in \mathcal{F}$ 满足 $\mathbb{P}(A_\alpha) < \delta$ 时就有 $\mathbb{E}[|\xi_\alpha| \cdot 1_{A_\alpha}] < \varepsilon, \forall \alpha \in I$; 这样的表述从应用上更方便, 但书中的表述形式上显得更弱. 请读者思考: 为何这两种表述其实是等价的?

立得 (2) 中的一致 L^1 有界性。

充分性。利用一致 L^1 有界性, 由 Chebyshev 不等式, 当 $N \rightarrow \infty$ 时

$$\sup_{\alpha \in I} \mathbb{P}(|\xi_\alpha| \geq N) \leq \frac{1}{N} \sup_{\alpha \in I} \mathbb{E}|\xi_\alpha| \rightarrow 0.$$

进而由等度绝对连续性, $\sup_{\alpha \in I} \mathbb{E}[|\xi_\alpha| \cdot 1_{\{|\xi_\alpha| \geq N\}}] \rightarrow 0$. □

下面给出一种比较实用的检验一致可积性的方法; 证明留给读者。

♠ **定理 10.2.3.** 给定随机变量族 $\{\xi_\alpha\}_{\alpha \in I}$, 它一致可积的一个充分条件是: 存在非负函数 $G: [0, \infty) \rightarrow \mathbb{R}_+$, 满足 $\lim_{t \rightarrow \infty} \frac{G(t)}{t} = \infty$ 及 $\sup_{\alpha \in I} \mathbb{E}[G(|\xi_\alpha|)] < \infty$.

之前我们已经说明, L^1 收敛蕴含了依概率收敛。反过来, 在适当条件下, 依概率收敛也能导出 L^1 收敛。

♠ **定理 10.2.4.** 可积随机变量列 $\{\xi_n\}_{n=1}^\infty$ L^1 收敛于 ξ 的充要条件是:

(1) $\{\xi_n\}_{n=1}^\infty$ 一致可积;

(2) $\xi_n \xrightarrow{\mathbb{P}} \xi$.

证明: (A) **必要性:** 首先, 当随机变量列 $\{\xi_n\}_{n=1}^\infty$ 在 L^1 意义下收敛于 ξ 时, $\xi_n \xrightarrow{\mathbb{P}} \xi$ 是显然的。此即定理结论 (2)。

其次, 我们有 $\mathbb{E}|\xi| \leq \mathbb{E}|\xi_n - \xi| + \mathbb{E}|\xi_n| < \infty$ 以及

$$\sup_n \mathbb{E}|\xi_n| \leq \sup_n \mathbb{E}|\xi_n - \xi| + \mathbb{E}|\xi| < \infty.$$

这表明 $\{\xi_n\}_{n=1}^\infty$ 一致 L^1 -有界。

对任意 $A \in \mathcal{F}$, 由 $\mathbb{E}[|\xi_n| \cdot 1_A] \leq \mathbb{E}[|\xi| \cdot 1_A] + \mathbb{E}[|\xi_n - \xi|]$ 立得 (此处约定 $\xi_0 := \xi$)

$$\sup_n \mathbb{E}[|\xi_n| \cdot 1_A] \leq \max_{0 \leq k \leq N} \mathbb{E}[|\xi_k| \cdot 1_A] + \sup_{n \geq N} \mathbb{E}[|\xi_n - \xi|].$$

由 $\mathbb{E}[|\xi_n - \xi|] \rightarrow 0$ 及 $\xi_k \in L^1$, 立得 $\{\xi_n\}_{n=1}^\infty$ 的等度 (绝对) 连续性。

由定理 10.2.2, $\{\xi_n\}_{n=1}^\infty$ 一致可积。此即定理结论 (1)。

(B) **充分性:** 对任意 $\varepsilon > 0$,

$$\begin{aligned} \mathbb{E}[|\xi_n - \xi|] &\leq \varepsilon + \mathbb{E}[|\xi_n - \xi| \cdot 1_{\{|\xi_n - \xi| \geq \varepsilon\}}] \\ &\leq \varepsilon + \mathbb{E}[|\xi_n| \cdot 1_{\{|\xi_n - \xi| \geq \varepsilon\}}] + \mathbb{E}[|\xi| \cdot 1_{\{|\xi_n - \xi| \geq \varepsilon\}}]. \end{aligned}$$

因为 $\lim_{n \rightarrow \infty} \mathbb{P}(|\xi_n - \xi| \geq \varepsilon) = 0$, 由 $\{\xi_n\}_{n=1}^\infty$ 的一致可积与 ξ 的可积性, 上面不等式右端可以任意小, 即 $\xi_n \xrightarrow{L^1} \xi$. $\square$

讨论 L^1 收敛与其他收敛的关系的一个目的是研究极限与数学期望交换

$$\mathbb{E}[\lim_{n \rightarrow \infty} \xi_n] = \lim_{n \rightarrow \infty} \mathbb{E}[\xi_n] \quad (10.5)$$

的条件. 定理10.2.4告诉我们, 若 $\{\xi_n\}_{n=1}^\infty$ 一致可积, 且 $\xi_n \xrightarrow{\mathbb{P}} \xi$, 那么上面极限与数学期望就可以交换. 而习题10.6告诉我们, L^1 -控制条件能导出一致可积性, 因此一致可积性比 Lebesgue 控制收敛定理中的 L^1 -控制条件稍弱, 但仍能确保极限交换(10.5)成立的一个充分条件, 它也近乎是必要的.

§10.2.2 (B) 依概率收敛与依分布收敛之间的关系

显然, 依概率收敛可以导出依分布收敛.

♠ **定理 10.2.5.** 设 $\{\xi_n\}_{n=1}^\infty$ 依概率收敛到 ξ , 那么 $\{\xi_n\}_{n=1}^\infty$ 依分布收敛到 ξ .

证明: 留作习题. $\square$

在特定条件下, 依概率收敛与依分布收敛之间可以做到互相等价.

♠ **定理 10.2.6.** 设 $\{\xi_n\}_{n=1}^\infty$ 依分布收敛到某常数 c 的充分必要条件是 $\{\xi_n\}_{n=1}^\infty$ 依概率收敛到这个常数 c .

证明: 留作习题. $\square$

上面的定理10.2.6再结合第十一章中的特征函数理论, 就给出了论证弱大数律的另一种特殊技巧: **特征函数方法**. Khintchine 弱大数律就是使用这种方法建立起来的 (参见第十一章定理11.3.1).

利用分布函数广义逆的性质, 很容易论证如下版本的 Skorokhod 嵌入定理.

♠ **定理 10.2.7. (Skorokhod 嵌入定理)** 设 $\{F_n\}_{n=0}^\infty$ 是一列分布函数. 如果 $F_n \xrightarrow{w} F_0$, 那么存在某个概率空间上的随机变量列 $\{X_n\}_{n=0}^\infty$, 使得:

(i) $X_n \sim F_n, \forall n \geq 0$;

(ii) $X_n \rightarrow X_0$ 几乎处处成立.

证明: 取 $U \sim U(0, 1)$ 为均匀分布随机变量. 记 F_0^{-1} 为 F_0 的广义逆, 即

$$F_0^{-1}(y) := \inf\{x : F_0(x) \geq y\}.$$

令 $X_n = F_n^{-1}(U) \sim F_n, X = F_0^{-1}(U) \sim F_0$. 可以论证 (反证法; 留作习题10.14): 在定理的条件下,

$$\lim_{n \rightarrow \infty} F_n^{-1}(p) = F_0^{-1}(p)$$

对于 F_0^{-1} 的连续点 $p \in (0, 1)$ 成立. 于是定理的两个结论都成立. $\square$

10.2.3 阅读材料：随机序与随机控制收敛定理

两个实数总是可以比较大小、排一个顺序。但很多场合也希望对两个或多个随机的数（随机变量）排“大小”顺序，也就是所谓的随机序。我们这里只介绍如下在经济、金融及统计中广为应用的一种随机序。更多的随机序及相关应用，请读者参考相关文献。

定义 10.2.3. 给定两个随机变量 X, Y （未必定义在同一个概率空间中），称 X 比 Y 随机地小（或称 X 被 Y 随机控制），如果 $\mathbb{P}(X > x) \leq \mathbb{P}(Y > x), \forall x \in \mathbb{R}$. 此时我们记作 $X \preceq Y$.

在一些文献中，这种随机序也被称为一阶随机占优。显然它只是一种偏序关系。

给定两个分布函数 F_1, F_2 ，如果 $F_1 \geq F_2$ ，那么它们的广义逆就显然满足 $F_1^{-1} \leq F_2^{-1}$. 注意到定理9.1.1，我们容易论证下面的结果。

♠ **定理 10.2.8.** 以下命题相互等价：

- (1) $X \preceq Y$;
- (2) 存在定义在同一个概率空间中的随机变量 $\tilde{X} \stackrel{d}{=} X, \tilde{Y} \stackrel{d}{=} Y$ 使得 $\tilde{X} \leq \tilde{Y}$ 几乎处处成立;
- (3) 对于任意单调非降函数 g , $g(X) \preceq g(Y)$;
- (4) 对 $\mathcal{D}_{X,Y} := \{g : g \text{ 为单调非降函数, 且 } \mathbb{E}[g(X)], \mathbb{E}[g(Y)] \text{ 都有意义}\}$, 总有

$$\mathbb{E}[g(X)] \leq \mathbb{E}[g(Y)], \quad \forall g \in \mathcal{D}_{X,Y}.$$

给定非负随机变量 $X \sim F$ ，设 $0 < \mathbb{E}X < \infty$ ，定义

$$F^*(x) := \frac{\mathbb{E}[X \cdot 1_{\{X \leq x\}}]}{\mathbb{E}X}.$$

那么 F^* 也是一个分布函数，它称为 F 的 **size-biased 变换**。取

$$f(y) := y, g(y) := 1_{(x, \infty)}(y),$$

它们都是单调递增函数。设 $\tilde{X}$ 与 X 同分布且独立，那么

$$[f(\tilde{X}) - f(X)] \cdot [g(\tilde{X}) - g(X)] \geq 0$$

几乎处处成立。两边取数学期望，并整理就得到了 $F^*(x) \leq F(x), \forall x$. 于是我们有下面的结果。

♣ **命题 10.2.1.** 设 $X \sim F$ 为非负随机变量, 满足 $0 < \mathbb{E}X < \infty$. 设 F^* 是 F 的 *size-biased* 变换, $X^* \sim F^*$. 那么 $X \preceq X^*$.

上面定义的随机序的另一个重要应用是关于一致可积性以及控制收敛定理的如下讨论; 这给出了一类比控制收敛定理中可积的几乎处处控制条件稍弱的极限与数学期望交换的充分条件, 相应结果可以称为**随机控制收敛定理**.

♠ **定理 10.2.9.** (随机控制收敛定理) 设随机变量族 $\{X_\alpha : \alpha \in I\}$ 、 X 满足:

$$(1) |X_\alpha| \preceq X, \forall \alpha \in I;$$

$$(2) \mathbb{E}[X] < \infty.$$

那么 $\{X_\alpha : \alpha \in I\}$ 是一致可积的. 特别地, 如果此时还有: $\mathbb{N} \subset I$, 且 $X_n \rightarrow X_\infty$ 几乎处处 (或依概率/依分布) 成立, 那么

$$\lim_{n \rightarrow \infty} \mathbb{E}X_n = \mathbb{E}X_\infty.$$

证明: 不妨设所讨论的随机变量都是非负随机变量, 否则分别考虑它们的正部、负部即可; 请读者思考能这样做的理由.

设 $X_\alpha \sim F_\alpha, X \sim F, U \sim U(0, 1)$. 取 $\{\tilde{X}_\alpha := F_\alpha^{-1}(U) : \alpha \in I\}$ 、 $\tilde{X} := F^{-1}(U)$. 在所给条件下, 易知: (1) $X_\alpha \stackrel{d}{=} \tilde{X}_\alpha, \forall \alpha \in I, X \stackrel{d}{=} \tilde{X}$; (2) $0 \leq \tilde{X}_\alpha \leq \tilde{X}$ 几乎处处. 此时, 对任意 $M > 0$

$$|\tilde{X}_\alpha| \cdot 1_{\{|\tilde{X}_\alpha| \geq M\}} \leq \tilde{X} \cdot 1_{\{\tilde{X} \geq M\}},$$

进而

$$\sup_{\alpha \in I} \mathbb{E}[|X_\alpha| \cdot 1_{\{|X_\alpha| \geq M\}}] = \sup_{\alpha \in I} \mathbb{E}[|\tilde{X}_\alpha| \cdot 1_{\{|\tilde{X}_\alpha| \geq M\}}] \leq \mathbb{E}[\tilde{X} \cdot 1_{\{\tilde{X} \geq M\}}].$$

结合 $\mathbb{E}X = \mathbb{E}[\tilde{X}] < \infty$, 即知 $\{X_\alpha : \alpha \in I\}$ 是一致可积的.

定理的后一结论是一致可积性结合 Skorokhod 嵌入定理、Lebesgue 控制收敛定理的简单推论. $\square$

♣ **注记 10.1.** 定理 10.2.4 结合 Skorokhod 嵌入定理告诉我们, 在已经有随机变量序列的 (几乎处处/依概率/依分布) 收敛性的前提下, 一致可积性差不多是极限与数学期望交换的充分必要条件. 现在, 我们又得到了随机控制方法下的一致可积性的判别方法, 进而得到了随机控制收敛定理. 很自然要问一个反过来的问题: 是否一致可积的 (非负) 随机变量族总能找到可积的随机控制? 这个问题的答案是否定的, 如下反例是赵敏智老师提供的: 设 $\{X_n\}_{n=1}^\infty$ 满足 $\frac{X_n}{n+1} \sim B(1, p_n), p_n = \frac{1}{(n+1)\ln(n+1)}$. 显然有 $X_n \xrightarrow{L^1} 0$. 但不存在 $Y \in L^1$, 使得 $X_n \preceq Y$, 否则

$$\mathbb{P}(Y > n) \geq \mathbb{P}(X_n > n) = \frac{1}{(n+1)\ln(n+1)}, \quad \forall n \geq 1,$$

$$\sum_{n=0}^{\infty} \mathbb{P}(Y > n) = \infty,$$

与 $Y \in L^1$ 相矛盾.

注记 10.2. 一般地, 我们可以按照如下办法定义更多的随机序: 给定一个特定的“效用函数集” $\mathcal{U}$, 对任意两个给定的随机变量 X, Y (本质上是谈它们对应的分布律), 我们称 Y 是 $\mathcal{U}$ -随机占优于 X , 记作 $X \preceq_{\mathcal{U}} Y$, 如果

$$\mathbb{E}[u(X)] \leq \mathbb{E}[u(Y)], \forall u \in \mathcal{U}$$

(假定涉及的数学期望有意义). 上面定义的一阶随机占优, 使用的效用函数集合为

$$\mathcal{U}_1 := \{g : g \text{ 是单调不减函数}\} \supset \{1_{(a, \infty)}(x) : a \in \mathbb{R}\}.$$

我们把 $X \preceq_{\mathcal{U}_1} Y$ 简记为 $X \preceq_1 Y$.

在文献中, 有所谓的**二阶随机占优**, $X \preceq_2 Y$, 它的原始定义为:

$$\int_{-\infty}^x [\mathbb{P}(X \leq t) - \mathbb{P}(Y \leq t)] dt \geq 0, \forall x \in \mathbb{R}.$$

当 $X, Y \in L^1$ 时, 这也等价于 $\mathbb{E}[X \wedge x] \leq \mathbb{E}[Y \wedge x], \forall x \in \mathbb{R}$, 也等价于

$$\mathbb{E}[(x - X)^+] \geq \mathbb{E}[(x - Y)^+], \forall x \in \mathbb{R}.$$

可以证明, 在可积随机变量类中, 二阶随机占优也等价于 $\mathcal{U}_2$ -随机占优, 其中

$$\mathcal{U}_2 := \{g : g \text{ 是单调不减的凹函数}\} \supset \{x \wedge a : a \in \mathbb{R}\}.$$

另外, 还有所谓的**三阶随机占优**, $X \preceq_3 Y$, 它的原始定义为:

$$\int_{-\infty}^x \int_{-\infty}^y [\mathbb{P}(X \leq t) - \mathbb{P}(Y \leq t)] dt dy \geq 0, \forall x \in \mathbb{R}.$$

易知, 在 L^2 随机变量类中, 三阶随机占优也等价于 $\mathcal{U}_3$ -随机占优, 其中

$$\mathcal{U}_3 := \{-(x - a)^2 \cdot 1_{[a, \infty)}(x) : a \in \mathbb{R}\}.$$

为了刻画一致可积性, 我们也可以定义如下的随机占优序 $\preceq'$: 取

$$\mathcal{U}' := \{xg(x) : g \text{ 单调不减, 且 } g(-\infty) = 0\} \supset \{x \cdot 1_{(a, \infty)}(x) : a \in \mathbb{R}\},$$

我们定义 $X \preceq' Y$, 如果 $X \preceq_{\mathcal{U}'} Y$. 可以证明, 随机变量族 $\{X_\alpha\}_{\alpha \in I}$ 是一致可积的, 当且仅当存在 $Y \in L^1$, 使得 $|X_\alpha| \preceq' Y, \forall \alpha \in I$.

10.3 大数律简介

本节我们准备介绍概率论中的第一个经典极限理论范式: 大数律, 这包括弱大数律和强大数律。我们先系统介绍用于讨论几乎处处收敛的重要工具: Borel-Cantelli 第一、第二引理; 之后按照从 Bernoulli 弱大数律到 Borel 强大数律、从 Khintchine 弱大数律到 Kolmogorov 强大数律的顺序介绍经典的强、弱大数定律; 最后介绍在二阶矩条件下 Kolmogorov 强大数律的两种加强: 经典的重对数律和较少出现于教科书中的 Hsu-Robbins 完全收敛定理。

10.3.1 Borel-Cantelli 第一、第二引理

下面的 Borel-Cantelli 引理本身的证明非常简单, 但它是概率论中用来证明有关几乎处处收敛性命题的重要工具; 读者可以从习题10.1中感受到其中的原因。

♠ 定理 10.3.1. (Borel-Cantelli 引理) 如果事件列 $\{A_n\}_{n=1}^\infty$ 满足

$$\sum_{n=1}^{\infty} \mathbb{P}(A_n) < \infty,$$

那么 $\mathbb{P}(\{A_n\}_n \text{ i.o.}) = 0$, 亦即

$$\sum_{n=1}^{\infty} 1_{A_n} < \infty \text{ 几乎处处成立.} \quad (10.6)$$

证明: 定义广义非负随机变量 $\xi := \sum_{n=1}^{\infty} 1_{A_n}$. 显然 $\mathbb{E}\xi = \sum_{n=1}^{\infty} \mathbb{P}(A_n) < \infty$. 于是 $\xi < \infty$ a.s., 此即 $\mathbb{P}(\{A_n\}_n \text{ i.o.}) = 0$, 亦即(10.6). $\square$

上面的 Borel-Cantelli 引理, 有时也称为 Borel-Cantelli 第一引理。利用上述 Borel-Cantelli 引理, 我们可以证明如下结果。

♠ 定理 10.3.2.¹ 设 $S_n := \sum_{k=1}^n X_k$ 为非负随机变量列 $\{X_n\}_{n=1}^\infty$ 的部分和。假定 $\mathbb{E}S_n \rightarrow \infty$. 如果存在正数 $C, \delta > 0$ 使得: 对一切正整数 n , 我们有下面估计

$$\text{Var}(S_n) \leq C \cdot (\mathbb{E}S_n)^{2-\delta} \quad (10.7)$$

或者更弱的估计

$$\text{Var}(S_n) \leq C \cdot (\mathbb{E}S_n)^2 / (\ln \mathbb{E}S_n)^{1+\delta}, \quad (10.8)$$

那么

$$\lim_{n \rightarrow \infty} \frac{S_n}{\mathbb{E}S_n} \stackrel{\text{a.s.}}{=} 1. \quad (10.9)$$

证明: 我们只在假定(10.7)下进行讨论; 另一更弱假定下的讨论是类似的, 读者可以参考文献.^[102]

首先寻找合适的子列, 确保子列极限的存在性。为此, 记 $E(n) := \mathbb{E}S_n$, 且不妨设 $E(1) > 0$, 并取 $n_0 := 1$ 及 $\beta := 2/\delta$. 现在递归地定义 n_k 如下: 对 $k \geq 1$, 定义

$$n_k := \inf\{n > n_{k-1} : \frac{E(n+1)}{E(n)} \geq (1 + \frac{2}{k})^\beta \text{ 或 } \frac{E(n)}{E(n_{k-1})} \geq (1 + \frac{2}{k})^\beta\}.$$

由于 $E(n) \nearrow \infty$, 上述定义是有意义的: 总有 $n_k < \infty$. 并且容易知道, 对任意 $k \geq 1$, 总有

$$\frac{E(n_k+1)}{E(n_k)} \geq (1 + \frac{2}{k})^\beta \text{ 或 } \frac{E(n_k)}{E(n_{k-1})} \geq (1 + \frac{2}{k})^\beta.$$

¹本定理本质上隐含于 Dvoretzky 与 Erdős 在 1950 年的一项合作工作中; 编者发掘整理、最后在 2019 级周瑞松同学提供的更巧妙地寻找子列的方法下形成此处的结论与证明, 说明了更早版本^[13]中假定 $\sup\{\mathbb{E}X_n : n \geq 1\} < \infty$ 的冗余性。

当上式的后者不成立时, 就有前者成立, 此时

$$\frac{E(n_k + 1)}{E(n_k)} \geq (1 + \frac{2}{k})^\beta > (1 + \frac{2}{k+1})^\beta,$$

也就是说这将导致 $n_{k+1} = n_k + 1$, 并且自然有 $\frac{E(n_{k+1})}{E(n_k)} \geq (1 + \frac{2}{k})^\beta$. 于是我们总有

$$\frac{E(n_{k+1})}{E(n_{k-1})} \geq \max\left(\frac{E(n_k)}{E(n_{k-1})}, \frac{E(n_{k+1})}{E(n_k)}\right) \geq (1 + \frac{2}{k})^\beta, \quad \forall k \geq 1.$$

分奇偶性重写上式, 得到: 对任意 $j \geq 1$

$$\begin{aligned} \frac{E(n_{2j})}{E(n_{2(j-1)})} &\geq (1 + \frac{2}{2j-1})^\beta = (\frac{2j+1}{2j-1})^\beta, \\ \frac{E(n_{2j+1})}{E(n_{2(j-1)+1})} &\geq (1 + \frac{1}{j})^\beta = (\frac{j+1}{j})^\beta. \end{aligned}$$

由此立即得到

$$E(n_{2j}) \geq (2j+1)^\beta \cdot E(n_0), \quad E(n_{2j+1}) \geq (j+1)^\beta \cdot E(n_1), \quad \forall j \geq 1.$$

进而存在 $C_0 > 0$ 使得 $E(n_k) \geq (C_0 \cdot k)^\beta, \forall k \geq 1$.

现在, 由 Chebyshev 不等式及估计 (10.7)

$$\mathbb{P}(|\frac{S_{n_k}}{E(n_k)} - 1| \geq \varepsilon) \leq \frac{\text{Var}(S_{n_k})}{\varepsilon^2 \cdot E(n_k)^2} \leq \frac{C}{\varepsilon^2 C_0^2 \cdot k^2}, \quad \forall k \geq 1, \varepsilon > 0.$$

由 Borel-Cantelli 引理, $\lim_{k \rightarrow \infty} \frac{S_{n_k}}{E(n_k)} \stackrel{\text{a.s.}}{=} 1$. 从而对任意 $\varepsilon \in (0, 1)$ 及 $\mathbb{P}$ -a.e. ω , 存在 $K = K(\varepsilon, \omega)$, 使得对任意 $k \geq K$

$$|\frac{S_{n_k}}{E(n_k)} - 1| \leq \frac{\varepsilon}{3}, \quad (1 + \frac{2}{k+1})^{2\beta} \leq 1 + \frac{\varepsilon}{3}.$$

对满足上述结论的样本点 ω , 我们来证明 $\frac{S_n}{E(n)} \rightarrow 1$ 成立。

事实上, 对任意 $\varepsilon \in (0, 1)$, 当 $n \geq n_K$ 时, 我们分两种情形来讨论。

(i) 如果对某 $k \geq 1$, $n = n_k$, 则 $k \geq K$, 从而 $|\frac{S_n}{E(n)} - 1| \leq \frac{\varepsilon}{3}$.

(ii) 如果 $n \notin \{n_j\}_{j=0}^\infty$, 注意到 $n \geq n_K$, 存在 $k \geq K$ 使得 $n \in (n_k, n_{k+1})$.

此时利用 n_{k+1} 的定义, 对 $s = n_{k+1} - 1 > n_k$ 应有

$$\frac{E(n_{k+1})}{E(s)} = \frac{E(s+1)}{E(s)} < (1 + \frac{2}{k+1})^\beta, \quad \frac{E(s)}{E(n_k)} < (1 + \frac{2}{k+1})^\beta,$$

从而

$$1 \leq \frac{E(n_{k+1})}{E(n_k)} < (1 + \frac{2}{k+1})^{2\beta} \leq 1 + \frac{\varepsilon}{3}.$$

现在利用 $S_n, E(n)$ 的单调性,

$$1 - \varepsilon \leq \frac{E(n_k)}{E(n_{k+1})} \cdot \frac{S_{n_k}}{E(n_k)} \leq \frac{S_n}{E(n)} \leq \frac{E(n_{k+1})}{E(n_k)} \cdot \frac{S_{n_{k+1}}}{E(n_{k+1})} \leq 1 + \varepsilon.$$

由 (i)、(ii) 及 $\varepsilon > 0$ 的任意性, $\frac{S_n}{E(n)} \rightarrow 1$ 几乎处处成立. $\square$

由上述证明可以知道以下更一般的结论。

推论 10.3.1. 设 $\{S_n\}_{n=1}^\infty$ 非负、单调上升, 且 $E(n) := \mathbb{E}S_n \rightarrow \infty$. 记 $V(n) := \text{Var}(S_n)$. 如果存在子列 n_k 满足

$$\sum_{k=1}^{\infty} \frac{V(n_k)}{E(n_k)^2} < \infty \quad \text{且} \quad \lim_{\substack{k \rightarrow \infty \\ n_{k+1} - n_k \geq 2}} \frac{E(n_k)}{E(n_{k+1})} = 1, \quad (10.10)$$

则定理 10.3.2 中的结论 (10.9) 仍然成立。

某种程度上, Borel-Cantelli 引理的逆命题成立, 具体陈述为如下定理; 在一些文献中这被称为 Borel-Cantelli 第二引理¹。

定理 10.3.3. 设事件列 $\{A_n\}_{n=1}^\infty$ 满足下面条件中的任意一条:

- (1) $\{A_n\}_{n=1}^\infty$ 相互独立;
- (2) $\{A_n\}_{n=1}^\infty$ 成对独立;
- (3) 存在 $\rho = \{\rho_n\}_1^\infty \in \ell^1$ 使得对任意 $i \neq j$

$$\mathbb{P}(A_i \cap A_j) - \mathbb{P}(A_i) \cdot \mathbb{P}(A_j) \leq \rho_{|i-j|} \sqrt{\mathbb{P}(A_i) \cdot \mathbb{P}(A_j)}.$$

- (3') 存在 $\rho = \{\rho_n\}_1^\infty \in \ell^1$ 使得对任意 $i \neq j$

$$\mathbb{P}(A_i \cap A_j) - \mathbb{P}(A_i) \cdot \mathbb{P}(A_j) \leq \rho_{|j-i|} (\mathbb{P}(A_i) + \mathbb{P}(A_j)),$$

- (4) 存在 $a = (a_i : i \geq 1) \in \ell^2$ 使得对任意 $i \neq j$

$$\mathbb{P}(A_i \cap A_j) - \mathbb{P}(A_i) \cdot \mathbb{P}(A_j) \leq a_i a_j \sqrt{\mathbb{P}(A_i) \cdot \mathbb{P}(A_j)};$$

- (4') 存在无穷矩阵 $a = (a_{i,j} : i \geq 1, j \geq 1) : \ell^2 \rightarrow \ell^2, x \mapsto a \cdot x$ 为有界线性算子, 使得对任意 $i \neq j$

$$\mathbb{P}(A_i \cap A_j) - \mathbb{P}(A_i) \cdot \mathbb{P}(A_j) \leq a_{i,j} \sqrt{\mathbb{P}(A_i) \cdot \mathbb{P}(A_j)};$$

¹部分文献把条件 (1) 下的结果单独叫做 Borel-Cantelli 第二引理, 或者与之前的 Borel Cantelli 引理的结果放在一块陈述, 合称 Borel-Cantelli 引理; 有些文献也把条件 (3)–(4') 下的结果称为 Borel-Cantelli 第二引理。在本书中我们把几种条件下的结果统一称为 Borel-Cantelli 第二引理。但实际上最早的 Borel-Cantelli 第二引理的雏形是习题 3.5 的结论 (2.a)。

那么 $\sum_{n=1}^{\infty} \mathbb{P}(A_n) = \infty$ 蕴含了 $\mathbb{P}(\{A_n\}_n \text{ i.o.}) = 1$, 亦即

$$\sum_{n=1}^{\infty} 1_{A_n} = \infty \quad \text{几乎处处成立.} \quad (10.11)$$

对于上述定理, 我们有下面相对统一且简单的基于定理10.3.2的证明。

定理10.3.3的证明: 简单起见, 我们只在条件 (3) 下给出证明, 其余情况类似可证 (留作习题)。

令 $S_n := \sum_{k=1}^n 1_{A_k}$. 显然 S_n 满足定理10.3.2前半部分条件. 再考察方差:

$$\begin{aligned} \text{Var}(S_n) &= \sum_{k=1}^n \text{Var}(1_{A_k}) + 2 \sum_{1 \leq i < j \leq n} \text{Cov}(1_{A_i}, 1_{A_j}) \\ &\leq \sum_{k=1}^n \mathbb{P}(A_k) + 2 \sum_{1 \leq i < j \leq n} \rho_{|i-j|} \sqrt{\mathbb{P}(A_i) \cdot \mathbb{P}(A_j)} \\ &\leq \mathbb{E}S_n + \sum_{1 \leq i < j \leq n} \rho_{|i-j|} \cdot [\mathbb{P}(A_i) + \mathbb{P}(A_j)] \\ &\leq (1 + 2\|\rho\|_1) \cdot \mathbb{E}S_n. \end{aligned}$$

于是定理10.3.2的所有条件都满足, 由此 $\lim_{n \rightarrow \infty} \frac{S_n}{\mathbb{E}S_n} = 1$ 几乎处处成立. 由于 $\mathbb{E}S_n \rightarrow \infty$, $S_n \rightarrow \infty$ 几乎处处成立, 亦即 $\mathbb{P}(A_n \text{ i.o.}) = 1$. $\square$

下面介绍另一个证明 (见文献^[92])。

定理10.3.3在条件 (3) 下的另一证明: 令 $S_n := \sum_{k=1}^n 1_{A_k}$. 同上导出: $\exists C > 0$ 使得 $\text{Var}(S_n) \leq C \cdot \mathbb{E}S_n, \forall n \geq 1$. 现在, 对任意 $a > 0$, 取 $N \geq 1$ 充分大, 使得 $\mathbb{E}S_N > a$. 于是对任意 $n \geq N$

$$\begin{aligned} \mathbb{P}(S_{\infty} \leq a) &\leq \mathbb{P}(S_n \leq a) = \mathbb{P}(-(S_n - \mathbb{E}S_n) \geq \mathbb{E}S_n - a) \\ &\leq \frac{\mathbb{E}[|S_n - \mathbb{E}S_n|^2]}{[\mathbb{E}S_n - a]^2} = \frac{\text{Var}(S_n)}{[\mathbb{E}S_n - a]^2} \leq \frac{C \cdot \mathbb{E}S_n}{[\mathbb{E}S_n - a]^2}. \end{aligned}$$

令 $n \rightarrow \infty$, 注意到 $\mathbb{E}S_n \rightarrow \infty$, 立即得到 $\mathbb{P}(S_{\infty} \leq a) = 0, \forall a > 0$. 于是定理结论成立. $\square$

为便于读者参考、比较, 此处我们也写下传统教科书中在条件 (1) 下对定理10.3.3的一个证明。

定理10.3.3在条件 (1) 下的传统证明: 注意到 $\{\{A_n\}_n \text{ i.o.}\} = \bigcap_{N=1}^{\infty} \bigcup_{n=N}^{\infty} A_n$, 结

合集合运算的 De Morgen 律、概率测度的上下连续性、条件 (1) 等, 有

$$\begin{aligned}
 1 - \mathbb{P}(\{A_n\}_n \text{ i.o.}) &= \mathbb{P}([\bigcap_{N=1}^{\infty} \bigcup_{n=N}^{\infty} A_n]^c) = \mathbb{P}(\bigcup_{N=1}^{\infty} \bigcap_{n=N}^{\infty} A_n^c) \\
 &= \lim_{N \rightarrow \infty} \mathbb{P}(\bigcap_{n=N}^{\infty} A_n^c) = \lim_{N \rightarrow \infty} \lim_{M \rightarrow \infty} \mathbb{P}(\bigcap_{n=N}^M A_n^c) \\
 &= \lim_{N \rightarrow \infty} \lim_{M \rightarrow \infty} \prod_{n=N}^M [1 - \mathbb{P}(A_n)] \\
 &\leq \lim_{N \rightarrow \infty} \lim_{M \rightarrow \infty} \prod_{n=N}^M e^{-\mathbb{P}(A_n)} = \lim_{N \rightarrow \infty} \exp\{-\sum_{n=N}^{\infty} \mathbb{P}(A_n)\}.
 \end{aligned}$$

注意到 $\sum_{n=N}^{\infty} \mathbb{P}(A_n) = \infty$, 因此 $1 - \mathbb{P}(\{A_n\}_n \text{ i.o.}) \leq 0$, 即 $\mathbb{P}(\{A_n\}_n \text{ i.o.}) = 1$. $\square$

习题 10.50 则告诉我们下面的关于 Borel-Cantelli 第二引理的更一般结果。

♠ **定理 10.3.4.** (*Kochen-Stone*^[61]) 给定事件列 $\{A_n\}_{n=1}^{\infty}$, 令 $S_n := \sum_{k=1}^n 1_{A_k}$. 如

果 $\overline{\lim}_{n \rightarrow \infty} \frac{(\mathbb{E} S_n)^2}{\mathbb{E}[S_n^2]} = 1$, 或者等价的,

$$\lim_{n \rightarrow \infty} \frac{\text{Var}(S_n)}{(\mathbb{E} S_n)^2} = 0, \quad (10.12)$$

那么 $\sum_{n=1}^{\infty} \mathbb{P}(A_n) = \infty$ 蕴含了 (10.11), 亦即 $\mathbb{P}(\{A_n\}_n \text{ i.o.}) = 1$.

以后 Borel-Cantelli (第一/二) 引理也时常简写为 B-C (第一/二) 引理。

最初版本的 B-C 第一、第二引理是 Borel (1909)、Cantelli (1917) 各自独立的工作¹, 距今已有上百年的历史, 其间众多数学家在此方向有工作积累而形成上述有关论述。值得指出的是, 对一个给定的事件列 $\{A_n\}_{n=1}^{\infty}$, B-C 第一、第二引理分别给出上限集 $\{\{A_n\}_n \text{ i.o.}\}$ 是几乎不可能事件 (即 $\mathbb{P}(\{A_n\}_n \text{ i.o.}) = 0$) 和几乎必然事件 (即 $\mathbb{P}(\{A_n\}_n \text{ i.o.}) = 1$) 的充分条件, 但非常奇怪的是众多研究工作²与概率论经典教材或专著 (例如文献^{[11][23]}等) 中均未曾认真讨论事件 $\{\{A_n\}_n \text{ i.o.}\}$ 是几乎不可能事件 (或几乎必然事件) 的充分必要条件。有关概率理论研究累积至今天, 是时候在本讲义中对此给出一个完备的回答了。

具体来说, 一方面, 我们有如下对事件 $\{\{A_n\}_n \text{ i.o.}\}$ 是几乎不可能事件 (亦即 (10.6)) 的等价刻画, 这个刻画本质上还是 B-C 引理类型的。

¹ 参见文献^[36]中论述。

² 参见文献^{[18][66][28][43][22][53][80][73][44][36]}等; 最近一些年也有发展动力系统中的 B-C 引理以用于数论研究的倾向, 参见文献^{[81][14][59][23][55]}等。

♠ **定理 10.3.5.** 给定事件列 $\{A_n\}_{n=1}^\infty$, 则(10.6)的充要条件是: 存在自然数的子列 $\{n_k\}_{k=1}^\infty$ (约定 $n_0 := 0$), 使得事件列 $\{B_k := \bigcup_{j \in (n_{k-1}, n_k]} A_j\}_{k=1}^\infty$ 满足

$$\sum_{k=1}^{\infty} \mathbb{P}(B_k) < \infty. \quad (10.13)$$

证明: 假设 $n_k \nearrow \infty$, 不难证明: 对于 $B_k := \bigcup_{j \in (n_{k-1}, n_k]} A_j$,

$$\sum_{n=1}^{\infty} 1_{A_n} < \infty \Leftrightarrow \sum_{k=1}^{\infty} 1_{B_k} < \infty. \quad (10.14)$$

基于此及 Borel-Cantelli 引理, (10.13)蕴含(10.6)就是显然的了。

反过来, 假设(10.6), 这也等价于

$$\mathbb{P}\left(\bigcap_{N=1}^{\infty} \bigcup_{n=N}^{\infty} A_n\right) = 0,$$

亦即 $\lim_{N \rightarrow \infty} \mathbb{P}\left(\bigcup_{n=N}^{\infty} A_n\right) = 0$. 于是, 可以递归定义 $n_0 := 0$

$$n_k := \inf\{N > n_{k-1} : \mathbb{P}\left(\bigcup_{n=N}^{\infty} A_n\right) \leq \frac{1}{2^{k+1}}\}.$$

那么对定理中定义的 B_k 总有 $\mathbb{P}(B_k) \leq \frac{1}{2^k}$. 进而(10.13)成立。□

另一方面, 基于 Kochen-Stone 定理, 给定事件列 $\{A_n\}_{n=1}^\infty$, 也有如下对事件 $\{\{A_n\}_n \text{ i.o.}\}$ 是几乎必然事件 (亦即(10.11)) 的等价刻画, 这个刻画本质上还是 Kochen-Stone 定理类型的。

♠ **定理 10.3.6.** (10.11)的充要条件是存在 $n_k \nearrow \infty$, 使得: 对 $B_k := \bigcup_{j \in (n_{k-1}, n_k]} A_j$

$$\sum_{k=1}^{\infty} \mathbb{P}(B_k) = \infty \quad (10.15)$$

成立, 且对 $S_n := \sum_{k=1}^n 1_{B_k}$, (10.12)成立。

证明: 对任意给定自然数的子列 $n_k \nearrow \infty$, 在上述定理的记号下, 不难证明

$$\sum_{n=1}^{\infty} 1_{A_n} = \infty \Leftrightarrow \sum_{k=1}^{\infty} 1_{B_k} = \infty. \quad (10.16)$$

如果 $n_k \nearrow \infty$, 使得(10.15)及(10.12)成立, Kochen-Stone 定理告诉我们

$$\sum_{k=1}^{\infty} 1_{B_k} = \infty \text{ 几乎处处成立.}$$

由此立即导出(10.11).

反过来假设(10.11), 这意味着

$$1 = \mathbb{P}(\overline{\lim}_{n \rightarrow \infty} A_n) = \mathbb{P}(\bigcap_{N=1}^{\infty} \bigcup_{n=N}^{\infty} A_n) = \lim_{N \rightarrow \infty} \lim_{M \rightarrow \infty} \mathbb{P}(\bigcup_{n=N}^M A_n).$$

因此可以递归定义自然数的子列 $\{n_k\}_{k=1}^{\infty}$ 如下: $n_0 := 0$,

$$n_k := \inf\{n > n_{k-1} : \mathbb{P}(\bigcup_{j \in (n_{k-1}, n]} A_j) > 1 - \frac{1}{2^k}\}.$$

如定理中定义 B_k 与 S_m . 此时总有 $\mathbb{P}(B_k) > 1 - \frac{1}{2^k}$. 因此(10.15)成立, 并且

$$\begin{aligned} \text{Var}(S_m) &= \sum_{1 \leq k, \ell \leq m} \mathbb{Cov}(1_{B_k}, 1_{B_\ell}) \\ &\leq \sum_{1 \leq k, \ell \leq m} \sqrt{\text{Var}(1_{B_k}) \cdot \text{Var}(1_{B_\ell})} \\ &\leq \sum_{1 \leq k, \ell \leq m} \sqrt{2^{-(k+\ell)}} \leq 3 + 2\sqrt{2}. \end{aligned}$$

于是(10.12)成立。 □



图 10.3: Borel(1871—1956)



图 10.4: Cantelli(1875—1966)

注 10.2. *Émile Borel* (博雷尔, 1871—1956; 法国) 生于圣阿夫里克 (Saint-Affrique), 卒于巴黎, 父亲是一个新教牧师。他以第一名的身份同时通过巴黎高等师范学校和巴黎综合理工的考试, 在 1889 年入学巴黎高等师范学校, 1892 年毕业, 1893 年发表博士论文 (导师是 *G. Darboux*), 并在里尔大学任教。1897 年他回到巴黎高等师范学校并任函数论方向的主席到 1941 年。E. Borel 与 R.-L. Baire、H. Lebesgue 三人是当时的

测度论方向的先驱；他还在数论（正规数）、双曲几何与狭义相对论等方面有重要贡献。1922 年他筹建了巴黎统计研究所（Paris Institute of Statistics），1928 年他与 Birkhoff 一起筹建了 Poincaré 研究所（Institut Henri Poincaré）。

Borel 培养的知名学生有：P. Dienes（1882—1952；匈牙利数学家、诗人），H. Lebesgue（1875—1941；法国数学家，以 Lebesgue 积分闻名于世），P. Montel（1876—1975；法国数学家，研究复分析中的全纯函数，以 Montel 定理、Montel 空间、Normal 族闻名；据说他同时也是 Lebesgue 的学生），G. Valiron（1884—1955；法国数学家，以 Valiron 定理知名，1932 年苏黎世国际数学家大会的大会报告人）等。

Francesco Paolo Cantelli（坎泰利，1875—1966；意大利）生于帕勒莫（Palermo），卒于罗马。他 1899 年博士毕业于帕勒莫大学，早期从事天文学和天体力学方面的工作。1903—1923 年他转而研究数理金融学和精算科学以及概率论，由此才逐渐成名。他在概率论方面的著名工作有 Borel-Cantelli 引理、Glivenko-Cantelli 定理等。

下面纯分析的引理在证明随机变量列的几乎处处收敛时非常有用；证明留给读者。

◆ 引理 10.3.1. 设 $\{X_n\}_{n=1}^\infty$ 满足：存在 $\{n_k\}_{k=1}^\infty \subset \mathbb{N}$ 使得 $X_{n_k} \xrightarrow{a.s.} X$ ，并且

$$\max_{n_{k-1} \leq n \leq n_k} |X_n - X_{n_{k-1}}| \xrightarrow{a.s.} 0 \quad (\text{或} \quad \max_{n_{k-1} \leq n \leq n_k} |X_n - X_{n_k}| \xrightarrow{a.s.} 0),$$

那么 $X_n \xrightarrow{a.s.} X$ 。

下面的定理给出了通过 p 阶绝对矩的估算来论证几乎处处收敛的一种比较粗糙、但非常实用的办法；证明同样留给读者。

♠ 定理 10.3.7. 设 $\{X_n\}_{n=1}^\infty$ 满足：存在 $p > 0$ 使得

$$\sum_{n=1}^{\infty} \mathbb{E}[|X_n|^p] < \infty.$$

那么 $X_n \xrightarrow{a.s.} 0$ 。

10.3.2 从 Bernoulli 弱大数律到 Borel 强大数律

概率论发展史上最早的大数定律由 Jacob Bernoulli 给出，它也被认为是概率论历史上第一个极限定理，具体陈述如下。

♠ 定理 10.3.8. (Bernoulli 弱大数律) 设 $\{X_n\}_{n=1}^\infty$ 为独立同分布的 Bernoulli 两点分布的随机变量序列， $X_1 \sim \begin{pmatrix} 0 & 1 \\ q & p \end{pmatrix}$ ，其中 $q = 1 - p$ ， $p \in (0, 1)$ 。那么弱大数律成立： $\overline{X}_n \xrightarrow{\mathbb{P}} p$ ，其中 $\overline{X}_n := \frac{1}{n}(X_1 + \cdots + X_n)$ 。

通常把上述定理中的 X_n 解释为第 n 次独立重复某项实验得到的结果, $X_n = 1$ 代表成功, 概率为 p ; $X_n = 0$ 代表失败, 概率为 q ; 从而可以把 $\bar{X}_n$ 解释为前 n 次重复试验中成功的频率。而上述定理的结论是, 当重复试验充分多次后, 成功的频率就稳定在成功的概率附近。这被认为是古典概率论对概率的一种直观解释, 也是我们第一章就介绍了的“频率稳定性”的精确数学陈述。

定理10.3.8的证明: 使用二阶矩对应的 Chebyshev 不等式得到: $\forall \varepsilon > 0$

$$\mathbb{P}(|\bar{X}_n - p| \geq \varepsilon) \leq \frac{\mathbb{E}[|\bar{X}_n - p|^2]}{\varepsilon^2} = \frac{pq}{n\varepsilon^2} \rightarrow 0,$$

其中 $q := 1 - p$. □

基于上面的论证技巧, Chebyshev 建立了如下更一般的弱大数律:

♠ **定理 10.3.9.** (*Chebyshev 弱大数律*) 设 $\{X_n\}_1^\infty$ 两两无关, 且它们的方差存在并具有共同的有限上界

$$\sup_n \text{Var}(X_n) < \infty.$$

则弱大数律成立:

$$\frac{S_n - \mathbb{E}S_n}{n} \xrightarrow{\mathbb{P}} 0, \quad (10.17)$$

其中 $S_n = X_1 + \cdots + X_n$.

Markov 指出, $\frac{\text{Var}(S_n)}{n^2} \rightarrow 0$ 时就有(10.17), 这被称为 **Markov 弱大数律**。

重新回到原始的 Bernoulli 弱大数律, Borel 进一步考虑使用四阶矩对应的 Chebyshev 不等式得到:

$$\begin{aligned} \mathbb{P}(|\bar{X}_n - p| \geq \varepsilon) &\leq \frac{\mathbb{E}[|\bar{X}_n - p|^4]}{\varepsilon^4} = \frac{3n(n-1)(pq)^2 + npq(p^3 + q^3)}{n^4\varepsilon^4} \\ &\leq \frac{pq[3pq + p^3 + q^3]}{n^2\varepsilon^4} = \frac{pq}{n^2\varepsilon^4}. \end{aligned}$$

于是用 B-C 引理得出结论: $\lim_{n \rightarrow \infty} \bar{X}_n \stackrel{\text{a.s.}}{=} p$. 此处也可以通过论证

$$\sum_{n=1}^{\infty} \mathbb{E}[|\bar{X}_n - p|^4] < \infty,$$

一定程度上避开 B-C 引理而得出结论; 这一结论也正是习题1.10中提及的当 $C \neq \mathbb{P}(A)$ 时“A 合约”有“统计套利”的原因。

上述方法应用到一般的 i.i.d. 随机变量序列上就得到下面的 Borel 强大数律。

♠ **定理 10.3.10.** (*Borel 强大数律*) 设 $\{X_n\}_{n=1}^{\infty}$ 为独立同分布的随机变量序列, 满足 $\mathbb{E}[|X_1|^4] < \infty$. 那么 $\lim_{n \rightarrow \infty} \bar{X}_n = \mathbb{E}X_1$ 几乎处处成立.

钟开莱^[132]告诉我们, 1932 年 A. Rajchman (雷奇曼, 1890—1940; 犹太裔波兰数学家) 在 Chebyshev 弱大数律的条件下得到了如下结果:

♠ **定理 10.3.11.** (*Rajchman 强大数律*) 设 $\{X_n\}_1^{\infty}$ 两两无关, 且它们的方差存在并具有共同有限上界

$$\sup_{n \geq 1} \text{Var}(X_n) < \infty.$$

则强大数律成立: $\frac{S_n - \mathbb{E}S_n}{n} \xrightarrow{\text{a.s.}} 0$, 其中 $S_n = X_1 + \cdots + X_n$.

证明: 不妨设 $\mathbb{E}X_n = 0, \forall n \geq 1$ 及 $M := \sup_n \text{Var}(X_n)$, 我们论证 $\frac{S_n}{n} \xrightarrow{\text{a.s.}} 0$.

由 $\{X_n\}_1^{\infty}$ 两两无关,

$$\mathbb{E}[S_n^2] = \text{Var}(S_n) = \sum_{k=1}^n \text{Var}(X_k) \leq nM.$$

由此容易知道 $\sum_{n=1}^{\infty} \mathbb{E}[(\frac{S_n^2}{n^2})^2] \leq \sum_{n=1}^{\infty} \frac{M}{n^2} < \infty$, 进而 $\frac{S_n^2}{n^2} \xrightarrow{\text{a.s.}} 0$.

以下考察 $D_n := \sup\{|S_k - S_{n^2}| : n^2 \leq k < (n+1)^2\}$. 利用 Cauchy 不等式, 得到

$$D_n^2 \leq 2n \sum_{n^2 < k < (n+1)^2} X_k^2.$$

于是同理可得 $\sum_{n=1}^{\infty} \mathbb{E}[(\frac{D_n}{n^2})^2] \leq \sum_{n=1}^{\infty} \frac{4M}{n^2} < \infty$, 进而 $\frac{D_n}{n^2} \xrightarrow{\text{a.s.}} 0$.

现在, 对任意 k 充分大, 存在 n 充分大, 使得 $n^2 \leq k < (n+1)^2$. 此时

$$\frac{|S_k|}{k} \leq \frac{|S_{n^2}| + D_n}{n^2}.$$

根据之前已经论证的结论, 立即知道定理结论成立. □

📌 **注记 10.3.** 历史上, J. Bernoulli 对他的弱大数律的证明是通过二项分布的“尾部”概率的复杂估计而得出的; 后来 De Moivre (棣莫弗, 1667/5/26—1754/11/27; 法国-英国) 和 Laplace (拉普拉斯, 1749/3/23—1827/3/5; 法国) 直接对二项分布的概率 $\binom{n}{k} p^k (1-p)^{n-k}$ (前者对 $p = \frac{1}{2}$, 后者对一般 p) 给出渐近公式, 基于这种方法, 不仅重新论证了 Bernoulli 弱大数定律, 而且得到了 Bernoulli 分布对应的“局部中心极限定理”和“中心极限定理”; 参见第十一章习题 11.40. 现在我们论证弱大数律所用的 Chebyshev 不等式估计概率的思想、论证强大数律所用的基于 B-C 引理结合 Chebyshev 不等式 (及其他推广的概率不等式) 进行概率估计的方法以及以后将介绍的论证中心极限定理的特征函数方法等经典思想与方法都是后人在前辈经典工作的基础上总结提高、反思创新而陆续发展出来的。

10.3.3 从 Khintchine 弱大数律到 Kolmogorov 强大数律

回到 i.i.d. 情形, Chebyshev 弱大数律要求二阶矩条件; 在一阶矩条件下, Khintchine 证明了他的弱大数律, 陈述如下 (证明请参见第十一章):

♠ **定理 10.3.12.** (*Khintchine 弱大数律*) 设 $\{X_n\}_{n=1}^\infty$ 为独立同分布的随机变量序列, 满足 $\mathbb{E}|X_1| < \infty$. 记 $\mu := \mathbb{E}X_1$, 那么 $\bar{X}_n \xrightarrow{\mathbb{P}} \mu$.

后来, Kolmogorov 进一步得到了冠以他名字的一个强大数律; 它是独立同分布随机变量列情形下的最优结果, 命题陈述如下:

♠ **定理 10.3.13.** (*Kolmogorov 强大数律*) 设 $\{X_n\}_{n=1}^\infty$ 为独立同分布的随机变量序列. 则存在随机变量 μ , 使得 $\lim_{n \rightarrow \infty} \bar{X}_n = \mu$ a.s. 成立的充分必要条件是: $\mathbb{E}|X_1| < \infty$. 此时, $\mu = \mathbb{E}X_1$ 是常数。

在 Kolmogorov 强大数律的证明过程中, 数学分析中著名的 Kronecker 引理发挥了重要的作用, 它把证明平均值的极限存在性问题转化为相应级数的收敛性问题。我们不加证明地陈述这一重要分析引理如下。

◆ **引理 10.3.2.** (*Kronecker 引理*) 设 $\{x_n\}_{n=1}^\infty$ 为实数列。如果 $\sum_{n=1}^\infty \frac{x_n}{n} < \infty$, 那么 $\lim_{n \rightarrow \infty} \frac{x_1 + \cdots + x_n}{n} = 0$. 更一般地, 设 $0 < a_n \nearrow \infty$, 且 $\sum_{n=1}^\infty \frac{x_n}{a_n} < \infty$, 那么 $\lim_{n \rightarrow \infty} \frac{x_1 + \cdots + x_n}{a_n} = 0$.

为了证明 Kolmogorov 强大数律, 我们还需要一些预备结果。

在处理独立和的几乎处处收敛问题中, 一个重要工具就是下面的 Kolmogorov 不等式, 它某种程度上可以视作 Chebyshev 不等式的推广。

◆ **引理 10.3.3.** (*Kolmogorov 不等式*) 设随机变量列 $\{X_k\}_{k=1}^n$ 相互独立, 且 $\mathbb{E}X_k = 0, \mathbb{E}[X_k^2] < \infty, k = 1, \dots, n$. 那么对任意 $\varepsilon > 0$

$$\mathbb{P}(\max_{1 \leq k \leq n} |S_k| \geq \varepsilon) \leq \frac{1}{\varepsilon^2} \mathbb{E}[|S_n|^2] = \frac{1}{\varepsilon^2} \sum_{k=1}^n \text{Var}(X_k).$$

证明: 不妨设 $n \geq 2$, 令 $\mathcal{F}_k = \sigma(X_1, \dots, X_k)$,

$$A_k := \{|S_i| < \varepsilon, 1 \leq i < k\} \cap \{|S_k| \geq \varepsilon\},$$

及 $A := \biguplus_{k=1}^n A_k$. 于是 $A_k \in \mathcal{F}_k$, 且

$$\mathbb{E}[|S_n|^2 \cdot 1_{A_k}] = \mathbb{E}[\mathbb{E}[|S_n|^2 \cdot 1_{A_k} | \mathcal{F}_k]] = \mathbb{E}[\mathbb{E}[|S_n|^2 | \mathcal{F}_k] \cdot 1_{A_k}]$$

$$\begin{aligned}
&= \mathbb{E}[\mathbb{E}[|S_n - S_k + S_k|^2 | \mathcal{F}_k] \cdot 1_{A_k}] \\
&\geq \mathbb{E}[|S_k|^2 \cdot 1_{A_k}] \geq \varepsilon^2 \mathbb{P}(A_k),
\end{aligned}$$

进而 $\mathbb{E}[|S_n|^2 \cdot 1_A] \geq \varepsilon^2 \sum_{k=1}^n \mathbb{P}(A_k) = \varepsilon^2 \mathbb{P}(A)$. 注意到

$$\mathbb{E}[|S_n|^2 \cdot 1_A] \leq \mathbb{E}[|S_n|^2] = \sum_{k=1}^n \text{Var}(X_k),$$

引理结论成立。 $\square$

利用 Kolmogorov 不等式, 我们很容易证明下面的结论。

◆ 引理 10.3.4. 设随机变量列 $\{X_n\}_{n=1}^\infty$ 相互独立, 且 $\mathbb{E}X_k = 0, \forall k$. 如果

$$\sum_{n=1}^{\infty} \mathbb{E}[X_n^2] < \infty,$$

那么 $\sum_{n=1}^{\infty} X_n$ 几乎处处收敛。特别地, 如果 $\sum_{n=1}^{\infty} \frac{\text{Var}(X_n)}{n^2} < \infty$, 那么 $\sum_{n=1}^{\infty} \frac{X_n}{n}$ 几乎处处收敛。

证明: 后一推论是显然的。我们来证明引理的前一个结论。

令 $S_n := \sum_{k=1}^n X_k$. 由 $\{X_n\}_{n=1}^\infty$ 的相互独立性及零均值性, 容易知道存在随机变量 S_∞ 使得 $S_n \xrightarrow{L^2} S_\infty$, 进而存在子列 $\{n_k : k \geq 1\} \subset \mathbb{N}$ 使得 $S_{n_k} \xrightarrow{\text{a.s.}} S_\infty$. 又由 Kolmogorov 不等式, 对任意 $k \geq 0$ (此处约定 $n_0 := 0$ 及 $S_0 := 0$)

$$\mathbb{P}\left(\max_{n_k < p \leq n_{k+1}} |S_p - S_{n_k}| \geq \varepsilon\right) \leq \frac{1}{\varepsilon^2} \cdot \mathbb{E}[|S_{n_{k+1}} - S_{n_k}|^2],$$

且 $\sum_{k=0}^{\infty} \mathbb{E}[|S_{n_{k+1}} - S_{n_k}|^2] = \sum_{n=1}^{\infty} \mathbb{E}[X_n^2] < \infty$. 由 B-C 引理, $\max_{n_k < p \leq n_{k+1}} |S_p - S_{n_k}| \rightarrow 0$ 几乎处处成立, 进而由引理 10.3.1, $S_n \rightarrow S_\infty$ 几乎处处成立。 $\square$

定理 10.3.13 的证明: (1) 一阶矩有限条件的必要性: 由于 $\{X_k\}_{k=1}^\infty$ 相互独立, $A_k := \{\omega : |X_k(\omega)| \geq k\}, k = 1, 2, \dots$ 也相互独立。而 $\lim_{n \rightarrow \infty} \bar{X}_n = \mu$ a.s. 无疑蕴含了 $\lim_{n \rightarrow \infty} \frac{X_n}{n} = 0$ a.s. 成立, 进而应有 $\mathbb{P}(A_n \text{ i.o.}) = 0$. 由定理 10.3.3, 这意味着 $\sum_{n=1}^{\infty} \mathbb{P}(A_n) < \infty$. 由同分布性, 此即 $\sum_{n=1}^{\infty} \mathbb{P}(|X_1| \geq n) < \infty$, 上述结论亦等价于 $\mathbb{E}|X_1| < \infty$ (见习题 6.12)。

(2) 以下证明一阶矩有限条件是充分的。此时不妨设 $\mathbb{E}X_1 = 0$. 令 $Y_n := X_n \cdot 1_{\{|X_n| \leq n\}}, n \geq 1$. 我们断言:

断言 1. $\frac{1}{n} \sum_{k=1}^n \mathbb{E}Y_k \rightarrow 0$ 成立;

断言 2. $\frac{1}{n} \sum_{k=1}^n (X_k - Y_k) \rightarrow 0$ 几乎处处成立;

断言 3. $\frac{1}{n} \sum_{k=1}^n (Y_k - \mathbb{E}Y_k) \rightarrow 0$ 几乎处处成立。

显然, 我们只需要证明上述 3 个断言即可。

注意到 $\mathbb{E}Y_n = \mathbb{E}X_1 \cdot 1_{\{|X_1| \leq n\}} \rightarrow \mathbb{E}X_1 = 0$, 断言 1 显然成立。

由于 $\mathbb{P}(X_n - Y_n \neq 0) = \mathbb{P}(|X_n| > n) = \mathbb{P}(|X_1| > n)$, 而 $\mathbb{E}|X_1| < \infty$ 保证了 $\sum_{n=1}^{\infty} \mathbb{P}(|X_1| > n) < \infty$. 由 B-C 引理, $\mathbb{P}(X_n - Y_n \neq 0 \text{ i.o.}) = 0$, 即对于几乎处处的样本点, 序列 $\{X_n - Y_n\}_{n=1}^{\infty}$ 中非零元素只有有限个。从而必定有断言 2 成立。

下面证明断言 3 成立。我们计算

$$\begin{aligned} \sum_{n=1}^{\infty} \frac{\mathbb{V}\text{ar}(Y_n - \mathbb{E}Y_n)}{n^2} &\leq \sum_{n=1}^{\infty} \frac{\mathbb{E}Y_n^2}{n^2} = \sum_{n=1}^{\infty} \frac{\mathbb{E}X_1^2 \cdot 1_{\{|X_1| \leq n\}}}{n^2} \\ &= \mathbb{E}[X_1^2 \cdot \sum_{n \geq |X_1| \vee 1} \frac{1}{n^2}] \\ &\leq \mathbb{E}[X_1^2 \cdot \frac{2}{|X_1| \vee 1}] \leq 2\mathbb{E}|X_1| < \infty. \end{aligned}$$

由引理 10.3.4 及引理 10.3.2, 断言 3 成立。 $\square$

利用 Makov 首创发明的截断手续, Kolmogorov 实际上证明了关于独立和级数的如下版本的三级数定理:

♠ 定理 10.3.14. 设 $\{X_n\}_{n=1}^{\infty}$ 相互独立。称随机级数 $\sum_{n=1}^{\infty} X_n$ 几乎处处收敛, 简记为 $\sum_{n=1}^{\infty} X_n < \infty$ 几乎处处, 如果存在随机变量 ξ 使得

$$\sum_{n=1}^N X_n \xrightarrow{N \rightarrow \infty} \xi$$

几乎处处成立。随机级数 $\sum_{n=1}^{\infty} X_n$ 几乎处处收敛当且仅当存在某常数 $C > 0$, 使得下面三个确定性级数收敛:

- (i) $\sum_{i=1}^{\infty} \mathbb{P}(|X_i| > C) < \infty$;
- (ii) $\sum_{i=1}^{\infty} \mathbb{E}[X_i \cdot 1_{\{|X_i| \leq C\}}] < \infty$;
- (iii) $\sum_{i=1}^{\infty} \mathbb{V}\text{ar}(X_i \cdot 1_{\{|X_i| \leq C\}}) < \infty$;

并且当 (i) — (iii) 对某正数 $C > 0$ 成立时, 它们也对一切正数 $C > 0$ 成立。

在 Kolmogorov 本人证明其强大数律的过程中, 他是利用 Kronecker 引理结合上述三级数定理来完成证明的; 此处我们略去三级数定理的证明。

著名的华人概率学家钟开莱给出了 Kolmogorov 强大数律的一个更为初等的证明, 感兴趣的读者可以参考其著作.^[15] 读者也可以尝试按照如下路径 (不使用引理 10.3.4) 证明断言 3: 记 $\tilde{X}_n := Y_n - \mathbb{E}Y_n$, $\tilde{S}_n := \tilde{X}_1 + \cdots + \tilde{X}_n$, 基于估计 $\sum_{n=1}^{\infty} \frac{\mathbb{E}[\tilde{X}_n^2]}{n^2} < \infty$, 首先论证 $\frac{\tilde{S}_{2^n}}{2^n} \rightarrow 0$ 几乎处处成立; 之后借助 Kolmogorov 不等式论证 $\max_{k \in (2^n, 2^{n+1}]} \frac{|\tilde{S}_k - \tilde{S}_{2^n}|}{k} \rightarrow 0$ 几乎处处成立; 最后在前两步基础上就能论证 $\frac{\tilde{S}_n}{n} \rightarrow 0$ 几乎处处成立。

在 $\{X_n\}_{n=1}^{\infty}$ 同分布, 而独立性减弱的情况下, 也有一些最优的结果。称随机变量 X, Y 是正象限相关的, 如果

$$\mathbb{P}(X \geq x, Y \geq y) \geq \mathbb{P}(X \geq x) \cdot \mathbb{P}(Y \geq y), \forall x, y;$$

称它们是负象限相关的, 如果

$$\mathbb{P}(X \geq x, Y \geq y) \leq \mathbb{P}(X \geq x) \cdot \mathbb{P}(Y \geq y), \forall x, y.$$

♠ **定理 10.3.15.** (*Etemadi-Matula 强大数律*) 设 $\{X_n\}_1^{\infty}$ 同分布, 并且成对独立 (或成对负象限相关). 则存在随机变量 μ , 使得 $\lim_{n \rightarrow \infty} \bar{X}_n = \mu$ a.s. 成立的充分必要条件是: $\mathbb{E}|X_1| < \infty$. 此时, $\mu = \mathbb{E}X_1$ 是常数。

证明: 我们只对“成对独立”的情形移植文献^[37]中给出的证明, 另一情形的证明请参见文献.^[76] 显然, 这个证明也可以作为 Kolmogorov 强大数律的证明。

必要性部分的证明与 Kolmogorov 强大数律完全类似。此处从略。

充分性。由于此时 $\{X_n^+ : n \geq 1\}$ 与 $\{X_n^- : n \geq 1\}$ 都满足定理假设条件, 且 $X_n = X_n^+ - X_n^-$, 故不妨直接假设 $X_n \geq 0$ 。

令 $Y_n := X_n \cdot 1_{\{X_n \leq n\}}$, 并记 $S_n^* = Y_1 + \cdots + Y_n$. 现任取 $\varepsilon > 0$ 及 $\alpha > 1$, 令 $n_k := \lfloor \alpha^k \rfloor$, 利用 Chebyshev 不等式计算:

$$\begin{aligned} \sum_{k=1}^{\infty} \mathbb{P}\left(\left|\frac{S_{n_k}^* - \mathbb{E}S_{n_k}^*}{n_k}\right| \geq \varepsilon\right) &\leq \sum_{k=1}^{\infty} \frac{\text{Var}(S_{n_k}^*)}{\varepsilon^2 \cdot n_k^2} = \sum_{k=1}^{\infty} \frac{1}{\varepsilon^2 \cdot n_k^2} \sum_{i=1}^{n_k} \text{Var}(Y_i) \\ &\leq O(1) \cdot \sum_{i=1}^{\infty} \frac{\mathbb{E}[Y_i^2]}{i^2} = O(1) \cdot \mathbb{E}\left[X_1^2 \cdot \sum_{i \geq X_1} \frac{1}{i^2}\right] \\ &\leq O(1) \cdot \mathbb{E}\left[X_1^2 \cdot \frac{1}{1 \vee X_1}\right] \leq O(1) \cdot \mathbb{E}X_1 < \infty. \end{aligned}$$

由此 $\lim_{k \rightarrow \infty} \frac{S_{n_k}^* - \mathbb{E}S_{n_k}^*}{n_k} \stackrel{\text{a.s.}}{=} 0$. 但 $\mathbb{E}Y_n \rightarrow \mathbb{E}X_1$, 故 $\frac{\mathbb{E}S_n^*}{n} \rightarrow \mathbb{E}X_1$, $\lim_{k \rightarrow \infty} \frac{S_{n_k}^*}{n_k} \stackrel{\text{a.s.}}{=} \mathbb{E}X_1$.

另外, $\sum_{n=1}^{\infty} \mathbb{P}(X_n \neq Y_n) = \sum_{n=1}^{\infty} \mathbb{P}(X_1 > n) \leq \mathbb{E}X_1 < \infty$, 由 B-C 引理, $\mathbb{P}(X_n \neq Y_n \text{ f.o.}) = 1$. 于是 $\lim_{k \rightarrow \infty} \frac{S_{n_k}}{n_k} = \mathbb{E}X_1$.

利用 S_n 的单调性, 我们可以证明: 几乎处处有

$$\frac{1}{\alpha} \cdot \mathbb{E}X_1 \leq \varliminf_{n \rightarrow \infty} \frac{S_n}{n} \leq \varlimsup_{n \rightarrow \infty} \frac{S_n}{n} \leq \alpha \cdot \mathbb{E}X_1.$$

由 $\alpha > 1$ 的任意性, 上、下极限必定几乎处处相等, 且等于 $\mathbb{E}X_1$. $\square$

10.3.4 在二阶矩条件下 Kolmogorov 强大数律的加强

二阶矩条件下 Kolmogorov 强大数律有几种加强方式, 此处我们简要介绍两种加强: 其一是经典的重对数律, 其二是 Hsu-Robbins 完全收敛定理。

我们先介绍重对数律。

最早的重对数律是 Khintchine 在研究 Bernoulli 序列的强大数律的收敛速度问题时建立的。他的结果后来被 Kolmogorov (1929) 和 Hartman-Winter (1941) 所推广。这些早期的结果后来在两个方面得到发展: 1964 年 Strassen 加强了重对数律的结论, 得到 Strassen 不变原理; 20 世纪 60 年代以来, 随着一系列鞅不等式的建立, 不少关于独立和的结果被推广到鞅上。本小节我们只陈述独立同分布情形的经典的重对数律 (Hartman-Winter 重对数律) 以及 Acosta 给出的广义重对数律, 有关证明读者可以参看文献。^[105, 126]

以下总假设 $\{X_n\}_1^\infty$ 独立同分布, 并记

$$S_n := X_1 + \cdots + X_n, \quad \bar{X}_n = \frac{S_n}{n}, \quad \log^{(2)} n := \log \log n.$$

♠ 定理 10.3.16. (**Hartman-Wintner 重对数律**) 设 $\mathbb{E}X_1 = 0, \mathbb{E}X_1^2 = 1$. 那么下面的极限几乎处处成立:

$$\varlimsup_{n \rightarrow \infty} \frac{S_n}{\sqrt{2n \log^{(2)} n}} = 1, \quad \varliminf_{n \rightarrow \infty} \frac{S_n}{\sqrt{2n \log^{(2)} n}} = -1.$$

♠ 定理 10.3.17. (**Acosta 广义重对数律**) 设 $\mathbb{E}X_1 = 0, \mathbb{E}X_1^2 = 1$. 那么对几乎处处的样本点而言, $\{\frac{S_n}{\sqrt{2n \log^{(2)} n}}\}$ 的极限点充满了区间 $[-1, 1]$.

以下介绍 Hsu-Robbins 完全收敛定理。

完全收敛是我国的概率统计先驱许宝騄先生 (1910—1970) 与 H. Robbins 在 1947 年的合作中提出的开创性概念, 后人基于他们的工作发展出了更多研究成果, 感兴趣的读者请自行检索。

定义 10.3.1. 称 Y_n 完全收敛到 Y , 如果

$$\lim_{N \rightarrow \infty} \sum_{n=N}^{\infty} \mathbb{P}(|Y_n - Y| \geq \varepsilon) = 0, \forall \varepsilon > 0,$$

这也等价于 $\sum_{n=1}^{\infty} \mathbb{P}(|Y_n - Y| \geq \varepsilon) < \infty$ 对任意 $\varepsilon > 0$ 成立。

♠ **定理 10.3.18.** 设 $\{X_k\}_{k=1}^n$ 是简单样本 (即他们是 *i.i.d.* 的). 则样本均值 $\bar{X}_n$ 完全收敛到 0 的充要条件是 $\mathbb{E}X_1 = 0, \mathbb{E}[X_1^2] < \infty$, 即

$$\left(\sum_{n=1}^{\infty} \mathbb{P}(|\bar{X}_n| \geq \varepsilon) < \infty, \forall \varepsilon > 0 \right) \Leftrightarrow \left(\mathbb{E}X_1 = 0, \mathbb{E}[X_1^2] < \infty \right). \quad (10.18)$$

上述结果的充分性部分的原始证明是许与 Robbins 通过特征函数的估算获得的, 见文献^[54], 1949 年前后 Erdős 给出了另一种更直接的估算方法; 必要性部分的证明也是 Erdős 在同一篇文章中给出的¹, 见文献.^[33,34]

📌 **注 10.3.** 许宝騄 (1910—1970), 字闲若, 出生于北京, 数学家, 中央研究院第一届院士、中国科学院学部委员, 北京大学数学系教授。他于 1933 年从清华大学毕业后考取留英名额, 因体重不合格未能成行, 因此在北京西山休养一年; 1934 年至 1936 年担任北京大学数学系助教; 1936 年再次考取了赴英留学, 派往伦敦大学学院, 在 *J. Neyman* (内曼, 1894—1981; 波兰裔美国籍著名统计学家) 的指导下攻读博士学位; 1938 年获得哲学博士学位, 两年后又获得科学博士学位, 随即从英国回到中国, 担任北京大学数学系教授, 执教于国立西南联合大学²; 1945 年至 1947 年先后在美国加州大学伯克利分校、哥伦比亚大学、北卡罗莱纳大学任访问教授; 1947 年至 1970 年担任北京大学数学系教授; 1948 年当选为中央研究院院士; 1955 年当选为中国科学院学部委员; 1970 年 12 月 18 日在北京逝世。

许宝騄主要从事数理统计学和概率论研究。他最先发现线性假设的似然比检验 (F 检验) 的优良性, 给出了多元统计中若干重要分布的推导, 推动了矩阵论在多元统计中的应用; 他与 *H. Robbins* 一起提出的完全收敛的概念是对强大数定律的重要加强。

许宝騄先生为概率统计方向培养了许多专业人才, 其中在概率界享有国际盛誉、被称为 20 世纪后半叶“概率学界学术教父”的钟开莱先生 (1917—2009) 是许宝騄先生在西南联大时期培养的研究生。

10.4 应用举例

基于 Borel 强大数律, 我们首先给出极限与数学期望不交换的一个例子。

例 10.3. 设想某赌场有一赌博项目, 押注金额不限, 记第 n 局的回报率为 ξ_n , 其中 $\{\xi_n\}_1^\infty$ 独立同分布, 满足 $\xi_1 \sim \begin{pmatrix} \frac{2}{3} & -\frac{2}{3} \\ \frac{2}{3} & \frac{1}{3} \end{pmatrix}$, 从而单局平均收益率为 $\mathbb{E}\xi_1 = \frac{2}{9} > 0$.

¹其中钟开莱亦有贡献, 在 Erdős 的原始证明基础上提出了简化证明。

²1937 年 11 月 1 日, 由国立北京大学、国立清华大学、私立南开大学在长沙组建成立的国立长沙临时大学在长沙开学 (这一天也成为西南联大校庆日). 由于长沙连遭日机轰炸, 1938 年 2 月中旬, 经中华民国教育部批准, 长沙临时大学分三路西迁昆明。1938 年 4 月, 改称国立西南联合大学; 到 1946 年 7 月 31 日国立西南联合大学停止办学。

某玩家采用 *All-In* 策略每次都押上全部赌金。令 $X_n := 1 + \xi_n$, $\mathbb{E}X_1 = \frac{11}{9} > 1$. 考虑乘积

$$M_n := X_1 \cdots X_n,$$

它是玩家在第 n 局过后所得实际赌本对应于初始赌金的倍数; $\mathbb{E}M_n = (\frac{11}{9})^n$. 但是 $\mathbb{E}[(\ln X_1)^4] < \infty$ 且

$$\mathbb{E}[\ln X_1] = \frac{2}{3} \ln \frac{5}{3} + \frac{1}{3} \ln \frac{1}{3} = \frac{1}{3} \ln \frac{25}{27} < 0.$$

根据 *Borel* 强大数律, 应有 $M_n = \exp\{\sum_{k=1}^n \ln X_k\} \xrightarrow{\text{a.s.}} 0$. 因此此时

$$\mathbb{E}[\lim_{n \rightarrow \infty} M_n] = 0 \neq \infty = \lim_{n \rightarrow \infty} \mathbb{E}[M_n]. \quad \square$$

对于上例, 我们也可以把其中的赌博解释成好听一点的名词“投资”: 假定某人每次投资都有 $\frac{2}{3}$ 的概率获得 $\frac{2}{3}$ 的利润率, $\frac{1}{3}$ 的概率获得 $-\frac{2}{3}$ 的利润率 (即亏损 $\frac{2}{3}$ 的本金); 那么平均而言, 他单次投资的期望利润率为 $\frac{2}{9} > 0$. 如果他每次都使用全部资金进行投资, 看似平均而言单次的投资都应该平均角度赚钱的, 然而长期而言他必然会破产。习题3.19的结论告诉我们, 在公平赌博情形, 由于玩家赌本远小于赌场, 最终玩家逃不了破产的结局; 上例则说明, 即使是对玩家有利的某些赌局, 如果过于贪婪采用 *All-In* 策略, 最终仍会破产。

如果单次投资的收益率同分布于 $\xi > -1$, 且各次投资之间相互独立, 那么真正高明的专业投资者应当做到平均收益率、平均对数收益率都为正值:

$$\mathbb{E}\xi > 0, \mathbb{E}[\ln(1 + \xi)] > 0.$$

只有这样他才能真正做到通过复利的方式长期、稳定地获利。当然要注意, 例10.3中研究的投资方式是“*All-In*”的梭哈式赌博, 在现实生活中应该极力避免; 在风险资产的投资与管理领域, 人们通常提议通过合理的仓位管理的模式来避免大亏损、积累单次的小盈利, 以期做到资产的稳定增值。

在投资领域, 有一个著名的 **Kelly 公式**, 它是 1956 年 John Larry Kelly (凯利) 在《贝尔系统技术期刊》上发表的, 可以用来计算每次赌博游戏中应投注的“最优”资金比例。假定有一个不限制投注金额的赌博游戏, 在投注 M 元后, 有 p_i 的概率获得比例为 $r_i \in [-1, \infty)$ 的回报 (即赚得 $M \cdot r_i$ 元), 其中 $r_i > 0$ 表示正收益, $r_i < 0$ 表示亏损, $i = 1, \dots, n$, $p_1 + \dots + p_n = 1$. 或者说, 这个赌博的单局回报率 ξ 满足 $\xi \sim \begin{pmatrix} r_1 & \cdots & r_n \\ p_1 & \cdots & p_n \end{pmatrix}$. Kelly 受 Shannon 发展的信息论 (Shannon 熵) 的启发, 考虑了赌博时的仓位管理 (持仓策略) 问题: 在总本金为 $M > 0$ 元时, 总是只投注 $f \in [0, 1]$ 比例的资金参与赌局, 目的是最

大化单局的平均对数收益率, 即所谓的 $\mathbb{E}[\Delta \ln M]$, 其中 $\Delta \ln M = \ln(1 + f \cdot \xi)$ 是在策略 f 下单局赌博的总资本的对数收益率。不难知道,

$$\mathbb{E}[\Delta \ln M] = \sum_{i=1}^n p_i \ln(1 + r_i f).$$

因此最佳的 $f \in [0, 1]$ 应满足下面的 Kelly 方程

$$\sum_{i=1}^n \frac{p_i}{f + \frac{1}{r_i}} = 0. \quad (10.19)$$

特别地, 当赌局结果只有输赢两种可能时, 可以假设 $\xi \sim \begin{pmatrix} r_w & -r_L \\ p & q \end{pmatrix}$, 其中 $q = 1 - p, p \in (0, 1)$, $-r_L < 0, r_w > 0$ 分别是赌局输 (Lose)、赢 (Win) 后的收益率; 此时 Kelly 给出如下最优的投注比例公式 (又称 Kelly 公式):

$$f = \frac{p}{r_L} - \frac{q}{r_w}. \quad (10.20)$$

注意, 上述 $f > 0$ 意味着 $p \cdot r_w - q \cdot r_L = \mathbb{E}\xi > 0$, 即赌局平均而言对玩家有利; 只有这种赌局才有必要考虑投注比例的优化问题, 否则总应该选择 $f = 0$, 即我们在现实生活中应当远离不利赌局。下例说明在 Kelly 公式给出的仓位管理策略下, 玩家能从上例中的有利赌局中平均角度稳定获利、并最终积小胜为大胜¹。

例 10.4. 设 $\{\xi_n\}_1^\infty$ 同上一例的设置; 此处 $r_w = r_L = 2/3$, $p = 2/3, q = 1/3$. 根据 Kelly 公式, 最佳的持仓比例/投注比例为

$$f = \frac{p}{r_L} - \frac{q}{r_w} = 1 - \frac{1}{2} = \frac{1}{2}.$$

现在取 $\tilde{X}_i = (1 - f) + f \cdot (1 + \xi_i) = 1 + \frac{1}{2} \cdot \xi_i \sim \begin{pmatrix} \frac{4}{3} & \frac{2}{3} \\ \frac{2}{3} & \frac{1}{3} \end{pmatrix}$, 并令

$$\tilde{M}_n := \tilde{X}_1 \cdots \tilde{X}_n,$$

有 $\mathbb{E}[\tilde{M}_n] = (\frac{10}{9})^n$. 此外

$$\mathbb{E}[\ln \tilde{X}_1] = \frac{2}{3} \ln \frac{4}{3} + \frac{1}{3} \ln \frac{2}{3} = \frac{1}{3} \ln \frac{32}{27} > 0.$$

¹但要注意, Kelly 公式给出的持仓策略是一种理想化的策略。在现实世界中对玩家真正有利的赌局是极其稀少的; 很多情形下, 由于信息不对称等原因, 甚至有些赌局貌似公平而暗含蹊跷, 从而引发玩家的认知错误, 误以为公平或有利。特别地, 赌博本身并不增加社会财富, 因此在此再次劝诫读者珍爱生命、远离赌博。

根据 *Borel* 强大数律, 应有 $\widetilde{M}_n = \exp\{\sum_{k=1}^n \ln \widetilde{X}_k\} \xrightarrow{\text{a.s.}} \infty$. 因此此时

$$\mathbb{E}[\lim_{n \rightarrow \infty} \widetilde{M}_n] = \infty = \lim_{n \rightarrow \infty} \mathbb{E}[\widetilde{M}_n]. \quad \square$$

例 10.5. (赠券收集问题) 任给 $n \geq 2$, 设 $\{X_k^{(n)}\}_{k=1}^\infty \stackrel{\text{i.i.d.}}{\sim} U(\{1, 2, \dots, n\})$. 记 $\tau_k^n := \inf\{m : \#(\{X_j^{(n)} : 1 \leq j \leq m\}) = k\}$, 并记 $T_n := \tau_n^n$. 在现实生活中, 商家在客户消费满一定额度 (比如 100 元) 后赠送一张奖券 (假设一套共 n 张), 集齐一套就可以换取特定奖品, 因而我们关心 $\mathbb{E}T_n$ 的大小. 这个问题也可解释成 *Pólya* 坛子模型: 假定在坛子里面有 n 个编号不同的球. 每次有放回地摸取一球, 并记录下编号. T_n 就是首次全部编号记录齐全时的取球次数. 现在的问题是: $\mathbb{E}T_n = ?$ 当 n 充分大时, 我们能对 T_n 本身的大小规模说些什么?

参考解答: 令 $Y_{n,k} := \tau_k^n - \tau_{k-1}^n$, 约定 $\tau_0^n := 0$; $Y_{n,k}$ 表示在已获得 $k-1$ 个编号的基础上, 要获得新编号额外所需的取球次数. 根据习题 5.28 的 (5), 容易知道 $\{Y_{n,j}\}_{j=1}^n$ 相互独立, 并且 $Y_{n,k} \sim \text{Geo}(1 - \frac{k-1}{n})$. 于是 $T_n = Y_{n,1} + Y_{n,2} + \dots + Y_{n,n}$ 是独立和.

注意到当 $Y \sim \text{Geo}(p)$ 时, $\mathbb{E}Y = \frac{1}{p}$, $\text{Var}(Y) = \frac{1-p}{p^2}$, 我们有 $C > 0$ 使得

$$\begin{aligned} \mathbb{E}T_n &= \sum_{k=1}^n (1 - \frac{k-1}{n})^{-1} = n \sum_{k=1}^n \frac{1}{k} \sim n \ln n, \\ \text{Var}(T_n) &= \sum_{k=1}^n (1 - \frac{k-1}{n})^{-2} \frac{k-1}{n} \leq n^2 \sum_{k=1}^\infty \frac{1}{k^2} \leq Cn^2. \end{aligned}$$

于是 $\text{Var}(\frac{T_n}{\mathbb{E}T_n}) \leq \frac{C}{(\ln n)^2} \rightarrow 0$, 这表明 $\frac{T_n}{\mathbb{E}T_n} \xrightarrow{\mathbb{P}} 1$, 即 $\frac{T_n}{n \ln n}$ 依概率收敛到 1. $\square$

在上面例子中, 敏锐的同学或许会联系起定理 10.3.2 或推论 10.3.1 试图得到几乎处处收敛. 如果随机变量列 $\{T_n\}_{n=1}^\infty$ 具有单调上升性质, 这个企图就能实现. 但不幸的是, $\{T_n\}_{n=1}^\infty$ 某种意义上可以认为定义在不同的概率空间中, 一般来说无法在几乎处处意义下比较 T_n 与 T_{n+1} 的大小关系, 因而无法单纯利用此处的方差分析的方法推断几乎处处收敛. 进一步敏锐的同学也许会想到后文将提及的中心极限定理 (见第十一章的 *Lindeberg Feller* 中心极限定理), 但同样遗憾的是, 此处 *Lindeberg* 条件不成立; 有兴趣的同学可以去验证这一点.

为了介绍下一个例子, 我们回忆一下超几何分布 $H(b, r; n)$, 它可以用 *Pólya* 的坛子模型来解释: 在有 b 个黑球、 r 个红球的坛子里无放回地取 $n \leq b+r$ 个球所获得的蓝球数量记作 X , 则 $X \sim H(b, r; n)$, 概率分布列为

$$\mathbb{P}(X = k) = \frac{\binom{b}{k} \binom{r}{n-k}}{\binom{b+r}{n}}, \ell_1 := (n-r)^+ \leq k \leq \ell_2 := b \wedge n. \quad (10.21)$$

不难通过组合数的技巧论证出:

$$\mathbb{E}X = \frac{nb}{b+r}, \quad \mathbb{E}[X(X-1)] = \frac{n(n-1)b(b-1)}{(b+r)(b+r-1)}. \quad (10.22)$$

由此进一步算出

$$\mathbb{V}\text{ar}(X) = \frac{nbr(b+r-n)}{(b+r)^2(b+r-1)}. \quad (10.23)$$

例 10.6. (估算池塘里的鱼) 在例 5.13 中, 我们考虑了池塘里的鱼数的估计问题。那里提供的估计方法如下: 首先从池塘中捕捞出 M 条成鱼, 都做好标记, 并重新放回池塘。过几天后 (假定期间成鱼数量不改变, 且之前作的标记不会脱落), 再次进行捕捞, 捞出了 n 条成鱼, 其中有 $X = m$ 条是之前做过标记的成鱼。那么池塘里的鱼数 N 的极大似然估计为¹

$$\hat{N} := \frac{nM}{X}.$$

它也可以认为是矩估计, 因为此时 $X \sim H(M, N-M; n)$, 由此可以证明 $\mathbb{E}X = \frac{nM}{N}$.

历史上, 上述估计方法最早是 *Laplace* 在 1786 年为了估计法国人口时提出的。从逻辑上来说, 这个估计方法很巧妙。我们这里的目的是想进一步了解这个估计的效果, 以及得到好的估计效果时参数 M, n 应当满足的要求。

仅供参考的一个解答: 我们定义 $Y := \frac{N}{\hat{N}} = \frac{NX}{nM}$, 它是真实值与估计值的比值。如果这个比值靠近 1, 我们就认为估计效果好。根据关于超几何分布的理论, 我们得到 $\mathbb{E}Y = 1$ 以及

$$\mathbb{V}\text{ar}(Y) = \frac{(N-n)(N-M)}{nM(N-1)} = \frac{(1-\frac{n}{N})(1-\frac{M}{N})}{1-\frac{1}{N}} \cdot \frac{N}{nM}.$$

直观上, 我们在做这个估计方案时, 应该取 $M \ll N, n \ll N$, 否则从成本等方面来说就不合适。但为了得到好的估计效果 (确切地说, $\mathbb{V}\text{ar}(Y) \rightarrow 0$, 从而 $Y \xrightarrow{\mathbb{P}} 1$), 我们应该还额外要求 $N \ll n \cdot M$.

总结以上论述, 为了得到好的估计效果, 我们对估计方案中参数 M, n 的安排应该是: $M \ll N, n \ll N$, 但 $n \cdot M \gg N$. $\square$

对于上面的例子, 读者也可以尝试直接计算 $\hat{N}$ 的数学期望与方差来进行有关讨论。

¹这里的极大似然估计并没有取整数部分, 其目的是方便讨论这个估计量的数学期望与方差。

10.5 本章小结与学习建议

在本章的前三节，我们首先介绍了 Chebyshev 不等式，之后介绍了随机变量列的几种收敛性：几乎处处收敛、依概率收敛、 L^p -收敛和依分布收敛；其中依分布收敛将在第十一章中结合特征函数理论重点讲述。这几种收敛性中，依分布收敛最弱，其他几种收敛性都能导出依分布收敛。而几乎处处收敛和 L^p -收敛也都能导出依概率收敛。在更早的章节，我们介绍了讨论极限与数学期望交换的一个大定理——Lebesgue 控制收敛定理，而本章的 L^1 -收敛性同样能做到极限与数学期望交换的效果；通过引入一致可积这个概念， L^1 -收敛被证明与一致可积且依概率收敛等价，基于此以及随机序我们进一步发展出了随机控制收敛定理。在本章的第四节，我们重点介绍了各种强、弱大数律，其中强大数律是介绍的重点。为此，我们先介绍了概率论中用于讨论几乎处处收敛性的重要工具：B-C 引理和 B-C 第二引理；其中最一般形态的 B-C 第一引理和第二引理分别是定理10.3.5和定理10.3.6。之后我们基于 Chebyshev 不等式给出了 Bernoulli 弱大数律的简单证明，此方法也能建立更一般的 Chebyshev 弱大数律；而通过考虑四阶矩并结合 B-C 引理，也很自然可以建立四阶矩条件下简单样本的 Borel 强大数律。Rajchman 则借助建立一般数列与收敛子列的关系的技巧，巧妙地证明了在 Chebyshev 弱大数律的条件下实际成立强大数律。Khintchine 在一阶矩条件下证明了简单样本的弱大数律；而 Kolmogorov 在前人工作基础上，通过娴熟的截断手术与强悍的分析技巧最终论证了简单样本情形的最强的强大数律——简单样本的强大数律成立当且仅当一阶矩有限的条件成立。在该节，编者还介绍了成对独立或负象限相关条件下的 Etemadi-Matula 强大数律，以及对简单样本的强大数律的进一步加强的结果：Hartman-Wintner 重对数律、Acosta 广义重对数律、Hsu-Robbins 完全收敛定理。最后在本章的第五节，我们给出了一些与现实生活密切联系的应用案例：Kelly 公式的讨论、赠券问题的讨论以及池塘里的鱼的估算问题的讨论。

概率论的初学者在学习本章时，Chebyshev 不等式、推论10.1.1以及一些常见分布的 Chernoff 界的估计技巧应当学习掌握；随机变量列的几种收敛性定义及其它它们之间的简单关系应当掌握，而更复杂的强弱大数律等结果中 Bernoulli 弱大数律及 Kolmogorov 强大数律的表述应当了解，在此过程中经典的 B-C 第一、第二引理也值得关注并略作了解；其余内容在初次学习时可以跳过。本章介绍的强、弱大数律及后续第十一章将介绍的中心极限定理是概率论中的经典理论与研究范式；编者认为，即使是概率论的初学者也理应尽力去学习、了解这些经典理论，感受其中的理性光辉。

习题 10

习题 10.1. 证明: 当 $n \rightarrow \infty$ 时, 数列 $\{a_n\}_{n=1}^\infty$ 以 a 为极限当且仅当:

$$\sum_{n=1}^{\infty} 1_{\{|a_n - a| \geq \varepsilon\}} < \infty, \forall \varepsilon > 0.$$

这是概率论中能利用本章的 $B-C$ 引理证明几乎处处收敛的原因。请类似书写

$\overline{\lim}_{n \rightarrow \infty} a_n \leq a$, $\overline{\lim}_{n \rightarrow \infty} a_n \geq a$, $\underline{\lim}_{n \rightarrow \infty} a_n \leq a$, $\underline{\lim}_{n \rightarrow \infty} a_n \geq a$ 的等价刻画。

习题 10.2. 证明随机变量列 $X_n \xrightarrow{\mathbb{P}} 0$ 当且仅当 $\mathbb{E}[\frac{|X_n|}{1+|X_n|}] \rightarrow 0$.

习题 10.3. 设 X 为非负非退化随机变量。求证: $\lim_{x \rightarrow \infty} x \mathbb{E}[\frac{1}{X} \cdot 1_{\{X > x\}}] = 0$.

习题 10.4. 试证明: 当存在某 $p > 1$ 使得 $\sup\{\mathbb{E}[|X_\alpha|^p] : \alpha \in I\} < \infty$ 时, 随机变量族 $\{X_\alpha\}_{\alpha \in I}$ 是一致可积的。

习题 10.5. 给出定理 10.2.3 的证明。它本质上是上一习题的推广。

习题 10.6. 试证明: 如果 $|X_\alpha| \leq X \in L^1, \forall \alpha \in I$, 那么 $\{X_\alpha\}_{\alpha \in I}$ 一致可积。

习题 10.7. 设 $\{X_n\}_{n=1}^\infty$ 是一列非负的单调递减的随机变量列, $X_n \rightarrow 0$ 依概率收敛, 那么 $X_n \rightarrow 0$ 几乎处处收敛。

习题 10.8. 证明定理 10.2.5.

习题 10.9. 证明定理 10.2.6.

习题 10.10. 证明定理 10.3.3 在 (3) 以外的其他条件下的结论。

习题 10.11. 证明定理 10.3.6 的表述不能改进为如下形式: (10.11) 的充要条件是存在 $n_k \nearrow \infty$, 使得: $\sum_{k=1}^\infty \mathbb{P}(A_{n_k}) = \infty$ 且对 $S_m := 1_{A_{n_1}} + \cdots + 1_{A_{n_m}}$ 方程 (10.12) 成立。

习题 10.12. 证明引理 10.3.1.

习题 10.13. 证明定理 10.3.7.

习题 10.14. 设 $\{F_n\}_{n=0}^\infty$ 都是分布函数, 且 $\lim_{n \rightarrow \infty} F_n(x) = F_0(x)$ 对 F_0 的连续点 x 都成立。求证: $\lim_{n \rightarrow \infty} F_n^{-1}(p) = F_0^{-1}(p)$ 对 F_0^{-1} 的连续点 p 都成立, 其中 F^{-1} 表示分布函数 F 的广义逆。

习题 10.15. 设 $\{U_k\}_{k=1}^n$ 为 $i.i.d.$ 的 $U(0, 1)$ 分布样本; 设它们从小到大排列为 $U_n^{(1)} < U_n^{(2)} < \cdots < U_n^{(n)}$. 证明: $U_n^{(1)} \xrightarrow{\text{a.s.}} 0$, 且 $nU_n^{(1)} \xrightarrow{d} \mathcal{E}(1)$.

习题 10.16. (习题10.15续) 对于固定的正整数 m , 类似讨论 $U_n^{(m)}$ 及 $nU_n^{(m)}$ 的极限行为。

习题 10.17. (习题10.15续) 设正整数 K_n 满足 $1 \leq K_n \leq n$ 且 $K_n \rightarrow \infty$, 求证: $Y_n := nU_n^{(K_n)} \rightarrow \infty$ 依概率成立, 即 $\lim_{n \rightarrow \infty} \mathbb{P}(Y_n \geq M) = 1, \forall M \in \mathbb{R}$.

习题 10.18. 设 $\{U_n\}_{n=1}^\infty$ 是一列 i.i.d. 的服从 $U(0, 1)$ 分布的随机变量列, 设 Y_n 为 $U_1, \dots, U_{2n+1}$ 中的样本中位数. 求证: $Y_n \rightarrow \frac{1}{2}$ 依概率收敛。

习题 10.19. (习题10.15续) 给定 $p \in (0, 1)$, 如果正整数列 $\{K_n\}$ 满足 $1 \leq K_n \leq n$ 且 $\frac{K_n}{n} \rightarrow p$, 求证: $U_n^{(K_n)} \rightarrow p$ 几乎处处成立。

习题 10.20. 当 $\xi_n \xrightarrow{\mathbb{P}} \xi$ 时, 记 $\xi_n = \xi + o_{\mathbb{P}}(1)$; 当 $\forall \varepsilon > 0$ 总有 $M > 0$ 使得 $\sup_n \mathbb{P}(|\xi_n| \geq M) \leq \varepsilon$ 时, 记 $\xi_n = O_{\mathbb{P}}(1)$ (读作: $\{\xi_n\}_{n=1}^\infty$ 依概率有界). 证明:

- (i) $o_{\mathbb{P}}(1) = O_{\mathbb{P}}(1)$;
- (ii) $o_{\mathbb{P}}(1) + o_{\mathbb{P}}(1) = o_{\mathbb{P}}(1)$, $O_{\mathbb{P}}(1) + O_{\mathbb{P}}(1) = O_{\mathbb{P}}(1)$;
- (iii) $o_{\mathbb{P}}(1) \cdot O_{\mathbb{P}}(1) = o_{\mathbb{P}}(1)$, $O_{\mathbb{P}}(1) \cdot O_{\mathbb{P}}(1) = O_{\mathbb{P}}(1)$;
- (iv) 设 $\xi_n \xrightarrow{d} \xi$, 那么 $\xi_n = O_{\mathbb{P}}(1)$;
- (v) 对于连续函数 f , 总有 $f(\xi + o_{\mathbb{P}}(1)) = f(\xi) + o_{\mathbb{P}}(1)$.

以上结论是概率统计中著名的 Δ -method (Δ -方法) 的理论依据。

习题 10.21. 利用上一习题结论, 证明 Slutsky 引理: 如果 $\xi_n \xrightarrow{d} \xi$, $\eta_n \xrightarrow{\mathbb{P}} c \in \mathbb{R}$, 那么 $\xi_n + \eta_n \xrightarrow{d} \xi + c$, $\xi_n \cdot \eta_n \xrightarrow{d} c \cdot \xi$, 且当 $c \neq 0$ 时, $\frac{\xi_n}{\eta_n} \xrightarrow{d} \frac{\xi}{c}$.

习题 10.22. 设 $X_n \sim \rho_n(x)dx$, $n = 0, 1, \dots$, 其中 Leb-a.e. 成立 $\rho_n \rightarrow \rho_0$, $n \rightarrow \infty$. 求证: $X_n \xrightarrow{d} X_0$.

习题 10.23. 设 $X_n \sim \rho_n(x)dx$, 其中 $\rho_n(x) := [1 - \cos(2n\pi x)] \cdot 1_{[0,1]}$. 求证: $X_n \xrightarrow{d} U(0, 1)$, 但 $\rho_n \rightarrow 1_{(0,1)}$ 在 $(0, 1)$ 中不成立。

习题 10.24. 基于上一题, 证明在习题10.18中 $\sqrt{2n+1} \cdot (2Y_n - 1) \xrightarrow{d} N(0, 1)$.

习题 10.25. 设非负随机变量列 $\{X_n\}_{n=1}^\infty \stackrel{\text{i.i.d.}}{\sim} \rho(x)dx$, 记 $Y_n = \min(X_1, \dots, X_n)$.

- (1) 当 ρ 在 $[0, \infty)$ 上是连续函数, 且 $\lambda := \rho(0) > 0$ 时 $n \cdot Y_n \xrightarrow{d} \mathcal{E}(\lambda)$;
- (2) 当 ρ 在 $[0, \infty)$ 上是连续可微函数, 且 $\rho(0) = 0, \rho'(0) > 0$ 时 $\sqrt{n\rho'(0)} \cdot Y_n$ 的极限分布律具有密度函数 $g(x) := xe^{-x^2/2} \cdot 1_{[0, \infty)}(x)$.

习题 10.26. 设 $\{X_k\}_{k=1}^n$ 为 *i.i.d.* 的标准指数分布样本. $X_{(n)}$ 是这些样本中的最大值. 试证明: $X_{(n)} \rightarrow \infty$ 几乎处处成立, 且 $X_{(n)} - \ln n$ 依分布收敛, 极限的分布函数为 $F(x) = e^{-e^{-x}}$ (这是第一类极值分布, 也称为 *Gumbel* 分布). 由此容易知道 $\frac{X_{(n)}}{\ln n} \rightarrow 1$ 依概率收敛.

习题 10.27. 设 $X_n \sim B(n, p_n), n \in \mathbb{N}, n \cdot p_n \rightarrow \lambda > 0$, 求证: $X_n \xrightarrow{d} \text{Poisson}(\lambda)$.

习题 10.28. 考虑 n 个人戴着 n 顶外观相同、帽内带标记区分的帽子参加聚会; 入场脱帽、离场取帽, 假定帽子均匀混合, 取帽时随机抓取. 记 N_n 为离场时拿对了帽子的实际人数. 求证: $N_n \xrightarrow{d} \text{Poisson}(1)$.

习题 10.29. 设 $\{X_n\}_{n=1}^\infty$ 是一列非负的随机变量列, 正数列 $a_n \uparrow \infty$. 那么几乎处处意义下, $\lim_{n \rightarrow \infty} \frac{X_n}{a_n} = 0 \Leftrightarrow \lim_{n \rightarrow \infty} \frac{\max\{X_1, \dots, X_n\}}{a_n} = 0$.

习题 10.30. 设 $\{X_n\}_{n=1}^\infty$ 是一列非负的随机变量列, 正数列 $a_n \uparrow \infty$. 那么几乎处处意义下, $\overline{\lim}_{n \rightarrow \infty} \frac{X_n}{a_n} = 1 \Leftrightarrow \overline{\lim}_{n \rightarrow \infty} \frac{\max\{X_1, \dots, X_n\}}{a_n} = 1$.

习题 10.31. 设 $\{X_n\}_1^\infty \stackrel{\text{i.i.d.}}{\sim} \text{Geo}(p), q := 1 - p$. 证明: $\lim_{n \rightarrow \infty} \frac{Y_n}{-\log_q n} = 1$ 几乎处处成立, 其中 $Y_n := \max_{1 \leq k \leq n} X_k$.

习题 10.32. 对于 *i.i.d.* 的标准指数分布随机变量 $\{X_n\}_1^\infty$, 请按下面步骤证明

$$\lim_{n \rightarrow \infty} \frac{\max\{X_1, \dots, X_n\}}{\ln n} = 1.$$

(1) 先使用 *B-C* 第一、第二引理论证 $\overline{\lim}_{n \rightarrow \infty} \frac{X_n}{\ln n} = 1$;

(2) 根据习题 10.30, 这等价于论证了 $\overline{\lim}_{n \rightarrow \infty} \frac{\max\{X_1, \dots, X_n\}}{\ln n} = 1$. 再使用 *B-C* 第一引理论证 $\lim_{n \rightarrow \infty} \frac{\max\{X_1, \dots, X_n\}}{\ln n} \geq 1$.

二者结合就完成了结论的证明. 请完成有关论证的技术细节.

习题 10.33. 给定 *i.i.d.* 标准 *Cauchy* 分布的随机变量列 $\{X_n\}_1^\infty$ 及正实数序列 $a_n \nearrow \infty$. 那么¹

$$(1) \overline{\lim}_{n \rightarrow \infty} \frac{|X_n|}{a_n} = 0, \text{ a.s. } \Leftrightarrow \sum_{n=1}^{\infty} \frac{1}{a_n} < \infty;$$

$$(2) \overline{\lim}_{n \rightarrow \infty} \frac{|X_n|}{a_n} = \infty, \text{ a.s. } \Leftrightarrow \sum_{n=1}^{\infty} \frac{1}{a_n} = \infty.$$

因此, 此时 $\overline{\lim}_{n \rightarrow \infty} \frac{|X_n|}{a_n} \in \{0, \infty\}$, 不可能出现 $\overline{\lim}_{n \rightarrow \infty} \frac{|X_n|}{a_n} = 1$.

¹在厚尾分布中, 具有类似现象的例子还有很多.

习题 10.34. 沿用习题 10.15 中假定与记号. 设 $a_n \nearrow \infty$. 求证¹:

$$(1) \varliminf_{n \rightarrow \infty} a_n U_n^{(1)} \stackrel{\text{a.s.}}{=} \infty \Leftrightarrow \sum_{n=1}^{\infty} \frac{1}{a_n} < \infty;$$

$$(2) \varliminf_{n \rightarrow \infty} a_n U_n^{(1)} \stackrel{\text{a.s.}}{=} 0 \Leftrightarrow \sum_{n=1}^{\infty} \frac{1}{a_n} = \infty.$$

因此, 此时 $\varliminf_{n \rightarrow \infty} [a_n U_n^{(1)}] \in \{0, \infty\}$, 不可能出现 $\varliminf_{n \rightarrow \infty} [a_n U_n^{(1)}] = 1$.

习题 10.35. 基于例 10.1 中估计, 证明: 如果 $\{X_n\}_{n=1}^{\infty} \stackrel{\text{i.i.d.}}{\sim} N(0, 1)$, 则 $S_n := X_1 + \cdots + X_n$ 满足 $\frac{S_n}{n^\alpha} \xrightarrow{\text{a.s.}} 0, \forall \alpha > \frac{1}{2}$.

习题 10.36. 基于例 10.2 中估计, 证明: 如果 $\{X_n\}_{n=1}^{\infty} \stackrel{\text{i.i.d.}}{\sim} \text{Poisson}(\lambda)$, 则 $S_n := X_1 + \cdots + X_n$ 满足 $\frac{S_n - n\lambda}{n^\alpha} \xrightarrow{\text{a.s.}} 0, \forall \alpha > \frac{1}{2}$.

习题 10.37. 设 $X \sim \text{Poisson}(\lambda)$. 我们约定 $0 \ln 0 := 0$. 证明: 对任意 $\varepsilon > 0$, $\mathbb{E}[\exp\{(1 - \varepsilon)X \ln X\}] < \infty$, $\mathbb{E}[\exp\{(1 + \varepsilon)X \ln X\}] = \infty$.

习题 10.38. 基于例 10.2 中估计以及上一习题中的第二个估计, 证明: 如果 $\{X_n\}_{n=1}^{\infty} \stackrel{\text{i.i.d.}}{\sim} \text{Poisson}(\lambda)$, 则 $\overline{\lim}_{n \rightarrow \infty} \left[\frac{\ln \ln n}{\ln n} \cdot X_n \right] \stackrel{\text{a.s.}}{=} 1$.

习题 10.39. 证明: 如果 $\{X_n\}_{n=1}^{\infty} \stackrel{\text{i.i.d.}}{\sim} N(0, 1)$, 则 $\overline{\lim}_{n \rightarrow \infty} \frac{X_n}{\sqrt{2 \ln n}} \stackrel{\text{a.s.}}{=} 1$.

习题 10.40. 设离散型随机变量列 $\{X_n\}_{n=1}^{\infty}$ 是 i.i.d. 的, 记 $R_n = \#\{X_1, \cdots, X_n\}$. 求证: $\frac{R_n}{n} \xrightarrow{\text{a.s.}} 0$. 更强的结论是 $\lim_{n \rightarrow \infty} \frac{R_n}{\mathbb{E}R_n} = 1$, $\lim_{n \rightarrow \infty} \frac{\mathbb{E}R_n}{n} = 0$.

习题 10.41. 设 $X_n \sim B(1, p_n)$ 相互独立, 令 $S_n := X_1 + \cdots + X_n$. 求证:

$$(1) \sum_{n=1}^{\infty} p_n < \infty \Leftrightarrow \mathbb{P}(S_\infty < \infty) = 1;$$

$$(2) \sum_{n=1}^{\infty} p_n = \infty \Leftrightarrow \mathbb{P}(S_\infty = \infty) = 1, \text{ 此时 } \lim_{n \rightarrow \infty} \frac{S_n}{\mathbb{E}S_n} = 1 \text{ 几乎处处成立.}$$

习题 10.42. 设 $X_n \sim \text{Poisson}(\lambda_n)$ 相互独立. 记 $S_n := X_1 + \cdots + X_n$. 试证:

$$(1) \sum_{n=1}^{\infty} \lambda_n < \infty \Leftrightarrow \mathbb{P}(S_\infty < \infty) = 1;$$

$$(2) \sum_{n=1}^{\infty} \lambda_n = \infty \Leftrightarrow \mathbb{P}(S_\infty = \infty) = 1, \text{ 此时 } \lim_{n \rightarrow \infty} \frac{S_n}{\mathbb{E}S_n} = 1 \text{ 几乎处处成立.}$$

习题 10.43. 设 $X_n \sim \mathcal{E}(\lambda_n)$ 相互独立. 记 $S_n := X_1 + \cdots + X_n$. 试证:

¹ 本题与上一题有对偶的关系.

(1) 当 $\sum_{n=1}^{\infty} \frac{1}{\lambda_n} < \infty$ 时, $\mathbb{P}(S_{\infty} < \infty) = 1$;

(2) 当 $\sum_{n=1}^{\infty} \frac{1}{\lambda_n} = \infty$ 且 $\inf_{n \geq 1} \lambda_n > 0$ 时, $\lim_{n \rightarrow \infty} \frac{S_n}{\mathbb{E}S_n} = 1$ 几乎处处成立, 从而 $\mathbb{P}(S_{\infty} = \infty) = 1$;

(3*) 根据三级数定理探讨 $\mathbb{P}(S_{\infty} < \infty) = 1$ 的充分必要条件。

习题 10.44. 某仙侠游戏中, 两份仙果 A 可以合成一份仙丹 A , 成功概率为 p ; 当合成失败时, 会损耗掉一份仙果 A 。假设某游戏工会有大量的仙果 A , 该工会的药剂师反复合成仙丹 A 。请问该工会平均一份仙果 A 能得到多少份仙丹?

习题 10.45. 本习题说明, 在一定意义下, *Chebyshev* 不等式既是“最优”的, 又不是“最优”的。

(1) 给定 $a > 0, p \in (0, 1)$. 求证:

$$\sup \left\{ \frac{a^2 \mathbb{P}(|X| \geq a)}{\mathbb{E}[X^2]} : \mathbb{E}[X^2] = a^2 \cdot p \right\} = 1,$$

也就是说, 在满足 $\mathbb{E}[X^2] = a^2 \cdot p$ 的随机变量 X 中, *Chebyshev* 不等式 $\mathbb{P}(|X| \geq a) \leq \frac{\mathbb{E}[X^2]}{a^2}$ 能达到最佳界。

(2) 设 $0 < \mathbb{E}[X^2] < \infty$. 当 $a \rightarrow \infty$ 时, $\frac{a^2 \mathbb{P}(|X| \geq a)}{\mathbb{E}[X^2]} \rightarrow 0$.

习题 10.46. 设 $a > 0$. 求证:

$$\inf \{ \mathbb{P}(|X| > a) : \mathbb{E}X = 0, \mathbb{V}\text{ar}(X) = 1 \} = 0,$$

这表明在 $\mathbb{E}X = 0, \mathbb{V}\text{ar}(X) = 1$ 条件下, $\mathbb{P}(|X| > a)$ 没有正下界。

习题 10.47. 设 $a \geq 1, \sigma^2 > 0$. 求证:

$$\inf \{ \mathbb{P}(|X| > a) : \mathbb{E}X = 1, \mathbb{V}\text{ar}(X) = \sigma^2 \} = 0,$$

这表明在 $\mathbb{E}X = 1, \mathbb{V}\text{ar}(X) = \sigma^2$ 条件下, $\mathbb{P}(|X| > a)$ 没有正下界。

习题 10.48. 设随机变量 X 满足: $\mathbb{E}X = 0, \mathbb{V}\text{ar}(X) = 1$. 证明: $\forall x > 0$,

$$\mathbb{P}(X \geq x) \leq \frac{1}{1 + x^2}.$$

上述不等式称为 *Cantelli* 不等式, 它的右端界无法改进: 取 Y 满足

$$\mathbb{P}(Y = -\frac{1}{x}) = \frac{x^2}{1 + x^2}, \quad \mathbb{P}(Y = x) = \frac{1}{1 + x^2}.$$

则显然有 $\mathbb{E}Y = 0, \mathbb{E}Y^2 = 1$.

习题 10.49. 设随机变量 ξ 满足 $\mathbb{E}\xi > 0, \mathbb{E}\xi^2 < \infty, \beta \in (0, 1)$. 求证:

$$\mathbb{P}(\xi > \beta \mathbb{E}\xi) \geq \frac{(1-\beta)^2(\mathbb{E}\xi)^2}{(1-\beta)^2(\mathbb{E}\xi)^2 + \text{Var}(\xi)},$$

进而得到 Paley-Zygmund 不等式: $\mathbb{P}(\xi > \beta \mathbb{E}\xi) \geq (1-\beta)^2 \cdot \frac{(\mathbb{E}\xi)^2}{\mathbb{E}[\xi^2]}$.

习题 10.50. (Kochen-Stone 引理) 假设 $\sum_{n=1}^{\infty} \mathbb{P}(A_n) = \infty$. 求证:

$$\overline{\lim}_{n \rightarrow \infty} \frac{[\sum_{k=1}^n \mathbb{P}(A_k)]^2}{\sum_{1 \leq i, j \leq n} \mathbb{P}(A_i \cap A_j)} = \alpha > 0$$

蕴含了 $\mathbb{P}(\{A_n\}i.o.) \geq \alpha$.

习题 10.51. 设 X, Y, Z 满足 $\max(|X|, |Y|, |Z|) \leq 1$, 证明 Bell (贝尔) 不等式:

$$|\mathbb{E}[(X-Y)Z]| \leq \mathbb{E}|X-Y| \leq 1 - \mathbb{E}[XY].$$

习题 10.52. 本习题的目的是引导读者推导 Hoeffding (霍夫丁) 不等式。

(1) 若 $\mathbb{E}[X] = 0$, 且 $\mathbb{P}(X \in [a, b]) = 1$, 则 $\mathbb{E}[e^{tX}] \leq e^{t^2(b-a)^2/8}, \forall t \in \mathbb{R}$, 这一结果被称为 Hoeffding 引理;

(2) 若 $\{X_i\}_{i=1}^n$ 相互独立, 且 $\mathbb{P}(X_i \in [a_i, b_i]) = 1, i = 1, \dots, n$, 那么对于任意 $\varepsilon > 0$ 和 $S_n := X_1 + \dots + X_n$ 总有

$$\begin{aligned} \mathbb{P}(S_n - \mathbb{E}S_n \geq \varepsilon) &\leq \exp\left\{-\frac{2\varepsilon^2}{\sum_{i=1}^n (b_i - a_i)^2}\right\}, \\ \mathbb{P}(S_n - \mathbb{E}S_n \leq -\varepsilon) &\leq \exp\left\{-\frac{2\varepsilon^2}{\sum_{i=1}^n (b_i - a_i)^2}\right\}. \end{aligned}$$

这被称为 Hoeffding 不等式。

习题 10.53. 设 $S_n \sim B(n, p)$, 其中 $p \in (0, 1)$. 任给 $a \in (p, 1)$, 记

$$r := r(p, a) = \left(\frac{p}{a}\right)^a \cdot \left(\frac{1-p}{1-a}\right)^{1-a},$$

求证: $0 < r < 1$, 且 $\mathbb{P}(\frac{S_n}{n} \geq a) \leq r^n$.

习题 10.54. 利用分析方法证明下面不等式 (参见文献^[29]的 Theorem 1.4)¹:

$$\frac{a \cdot e^{-\frac{a^2}{2}}}{1+a^2} \leq \int_a^\infty e^{-x^2/2} dx \leq \frac{e^{-\frac{a^2}{2}}}{a}, \quad \forall a > 0.$$

¹ 此处, 我们基于文献^[29]的 Theorem 1.4 的证明思想, 对不等式的左端做了改进, 请读者自行对比. 估计式右端因子 $\frac{1}{a}$ 也可以替换为 $\frac{2}{a+\sqrt{1+a^2}}$.

这给出了标准正态随机变量 $Z \sim N(0, 1)$ 的尾部概率的精细估计¹:

$$\frac{a \cdot e^{-\frac{a^2}{2}}}{\sqrt{2\pi}(1+a^2)} \leq \mathbb{P}(Z \geq a) = 1 - \Phi(a) \leq \frac{e^{-\frac{a^2}{2}}}{\sqrt{2\pi}a}, \quad \forall a > 0.$$

习题 10.55. 设 $X = (X_1, \dots, X_n)$ 为 n 维平方可积的随机向量, 均值为 μ , 协方差矩阵为 Σ . 设 Σ 非退化. 证明: 对于 $\mathbb{R}^n$ 中任意的紧凸集 S ,

$$\mathbb{P}(X \in S) \leq \frac{1}{1 + \inf\{(x - \mu)\Sigma^{-1}(x - \mu)^T : x \in S\}}.$$

习题 10.56. 设非负随机变量 ξ 具有正的二阶矩. 求证: $\mathbb{P}(\xi = 0) \leq \frac{\text{Var}(\xi)}{\mathbb{E}[\xi^2]}$.

习题 10.57. 设 $\alpha > 0, \beta \geq 0$ 是常数, X 是随机变量. 试证明:

$$\lim_{x \rightarrow \infty} x^{\alpha+\beta} \cdot \mathbb{P}(|X| > x) = 0 \Leftrightarrow \lim_{x \rightarrow \infty} x^\alpha \cdot \mathbb{E}[|X|^\beta \cdot 1_{\{|X|>x\}}] = 0.$$

对于必要性, $\alpha > 0$ 是必须的。

习题 10.58. 设 $\mathbb{E}[X_1^-] < \infty$ 且 $X_n \nearrow X$. 求证: $\mathbb{E}X_n \nearrow \mathbb{E}X$.

习题 10.59. (控制收敛定理的推广) 设有可积的随机变量序列 $\{X_n\}_1^\infty, \{Y_n\}_1^\infty$ 及可积的随机变量 X, Y . 假设 $X_n \rightarrow X, Y_n \rightarrow Y$ 几乎处处收敛 (或依概率收敛, 或更弱的依分布收敛), 并且 $|X_n| \leq Y_n, \mathbb{E}Y_n \rightarrow \mathbb{E}Y$. 试证明: $\mathbb{E}X_n \rightarrow \mathbb{E}X$.

习题 10.60.² 设 $X_n \xrightarrow{d} X$. 又设连续函数 g, h 满足: (i) $g \geq 0$, 且存在 $M > 0$ 使得 $g(x) > 0, \forall |x| \geq M$; (ii) $\lim_{|x| \rightarrow \infty} \frac{h(x)}{g(x)} = 0$; (iii) $\sup_n \mathbb{E}[g(X_n)] < \infty$. 那么 $\mathbb{E}[h(X_n)] \rightarrow \mathbb{E}[h(X)]$.

习题 10.61. 设 $X_n \xrightarrow{\mathbb{P}} X$, g 为连续函数, 那么 $g(X_n) \xrightarrow{\mathbb{P}} g(X)$.

习题 10.62. 对于随机变量 X, Y , 定义 *Ky Fan* 度量

$$\alpha(X, Y) := \inf\{\delta \geq 0 : \mathbb{P}(|X - Y| > \delta) \leq \delta\}.$$

证明: $\alpha(\cdot, \cdot)$ 是度量, 且诱导了依概率收敛. 这表明依概率收敛可以度量化。

¹我们根据文献^[1]第 19 页 (参见 Laplace 的著作^[67]第 IV 卷第 490–493 页) 还有如下连分数恒等式:

$$\mathbb{P}(Z \geq a) = \frac{e^{-\frac{a^2}{2}}}{\sqrt{2\pi}a} \cdot \frac{1}{1 + \frac{c}{1 + \frac{\frac{c}{2c}}{1 + \frac{3c}{1 + \dots}}}}, \quad \text{其中 } c = \frac{1}{a^2}.$$

²本题来源于文献^[29]的 Theorem 3.8.

习题 10.63. 试证明：一阶随机占优序是一维随机变量的分布族上的一个偏序，即它具有自反性（即 $X \preceq X$ ）、反对称性（即 $X \preceq Y$ 且 $Y \preceq X$ ，则 $X \stackrel{d}{=} Y$ ）和传递性（即 $X \preceq Y$ 且 $Y \preceq Z$ ，则 $X \preceq Z$ ）。

习题 10.64. 一阶随机占优序还有如下性质：

- (1) 设 $X_k \preceq Y_k, k = 1, 2$, 且 X_1, X_2, Y_1, Y_2 相互独立, 那么 $X_1 + X_2 \preceq Y_1 + Y_2$;
- (2) 如果 $X \preceq Y, \xi$ 是一个非负随机变量, 它与 X, Y 都独立, 那么 $\xi \cdot X \preceq \xi \cdot Y$;
- (3) 如果 $X \preceq Y$, 那么 $-Y \preceq -X$;
- (4) 如果 $X \preceq Y_n$, 且 $Y_n \xrightarrow{d} Y$, 那么 $X \preceq Y$.

习题 10.65. 本习题考虑例题 3.7 的推广。设有无穷大的空坛子以及带自然数标记的无穷多的球。给定一个严格单调的函数 $f: \mathbb{N} \rightarrow \mathbb{N}$ (从而 $f(n) \geq n$)。第一步时, 先在坛内放入标号 1 到 $f(1)$ 的球, 再从坛内随机地取一球; 一般地, 在第 $n \geq 2$ 步时, 在坛内放入标号 $f(n-1)+1$ 到 $f(n)$ 的球, 之后从坛内随机地取一球。记事件 E 为“坛子最终是空的”。求证:

$$\sum_{n=1}^{\infty} \frac{1}{f(n)} < \infty \Leftrightarrow \mathbb{P}(E) = 0, \quad \sum_{n=1}^{\infty} \frac{1}{f(n)} = \infty \Leftrightarrow \mathbb{P}(E) = 1.$$

习题 10.66. Borel 的强大数律是在研究所谓的正规数的过程中建立起来的。给定自然数 $b \geq 2$, 一个数 $x \in (0, 1)$ 称为是 b 进制正规数, 如果把 x 表成

$$x = \sum_{n=1}^{\infty} \frac{d_n(x; b)}{b^n}, \text{ 其中 } d_n(x; b) \in \{0, 1, \dots, b-1\}$$

(即 b 进制形式, 不允许从某 n_0 开始 $d_n(x; b) = b-1, \forall n \geq n_0$) 时, 总有

$$\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{k=1}^n 1_{\{d_k(x; b) = j\}} = \frac{1}{b}, \quad \forall j \in \{0, 1, \dots, b-1\}.$$

如果对任意自然数 $b \geq 2$, x 都是 b 进制正规的, 则称 x 是完全正规数。求证: Leb-a.e. 的 $x \in (0, 1)$ 是完全正规数。

习题 10.67. (丢番图逼近, Diophantine Approximation) 对任意 $x \in \mathbb{R}$, 记 $\|x\|$ 为 x 到整数集 $\mathbb{Z}$ 的距离, 即 $\|x\| := \inf\{|x-a| : a \in \mathbb{Z}\}$. 1842 年 Dirichlet 证明了 $\min\{\|qx\| : 1 \leq q \leq Q\} \leq \frac{1}{Q+1}, \forall Q \in \mathbb{N}$, 进而对无理数 x 存在无穷多既约分数 $\frac{p}{q}$ 使得 $|x - \frac{p}{q}| < \frac{1}{q(q+1)}$; 1844 年 Liouville 证明了当 x 是 $d \geq 2$ 次代数数

(从而是无理数) 时, 存在常数 $c = c(x)$, 使得 $\|qx\| > \frac{c}{q^{d-1}}, \forall q \in \mathbb{N}$. 任给单调不减的函数 $\varphi: \mathbb{N} \rightarrow (0, \infty)$, 记

$$B_q := \{x \in (0, 1) : \|qx\| < \frac{1}{\varphi(q)}\}, \quad A_\varphi := \overline{\lim_{q \rightarrow \infty}} B_q.$$

求证:¹ 当 $\sum_{q=1}^{\infty} \frac{1}{\varphi(q)} < \infty$ 时, $\text{Leb}(A_\varphi) = 0$.

习题 10.68. 用概率方法证明 *Wierstrass* 定理: 对任意 $f \in C[0, 1]$, 取 $\{X_n\}_{n=1}^{\infty} \stackrel{\text{i.i.d.}}{\sim} B(1, p)$, 则 $f_n(p) := \mathbb{E}[f(\frac{X_1 + \dots + X_n}{n})]$ 是多项式, 满足 $\lim_{n \rightarrow \infty} \|f - f_n\|_{\infty} = 0$.

习题 10.69. 在习题 1.7 中, 我们介绍了圣彼得堡悖论. 这里我们给出一些讨论. 假设 $\{X_n\}_{n=1}^{\infty}$ 独立同分布, 满足

$$\mathbb{P}(X_1 = 2^m) = \frac{1}{2^m}, \quad m = 1, 2, \dots.$$

令 $S_n := X_1 + \dots + X_n$, 则

(1) 记 $x_k := \log_2[(k+3) \ln^\gamma(k+3)]$; 此处 $\gamma \in (1, 2)$. 定义 $\tilde{X}_k := X_k \cdot 1_{\{X_k \leq 2^{x_k}\}}$, 定义 $\tilde{S}_n := \tilde{X}_1 + \dots + \tilde{X}_n$, 请借助 *B-C* 引理证明 $\lim_{n \rightarrow \infty} \frac{S_n - \tilde{S}_n}{n \log_2 n} \stackrel{\text{a.s.}}{=} 0$;

(2) 请估算 $\mathbb{E}\tilde{S}_n$ 、 $\text{Var}(\tilde{S}_n)$, 论证 $\frac{\tilde{S}_n}{n \log_2 n} \xrightarrow{\mathbb{P}} 1$. 进而结合 (1) 得到 $\frac{S_n}{n \log_2 n} \xrightarrow{\mathbb{P}} 1$;

(3) 现在我们取 $\gamma := 0$, 对 (1) 中定义的 $\tilde{X}_k$ 、 $\tilde{S}_n$, 请估算 $\mathbb{E}\tilde{S}_n$ 、 $\text{Var}(\tilde{S}_n)$, 并利用定理 10.3.2 论证 $\frac{\tilde{S}_n}{n \log_2 n} \xrightarrow{\text{a.s.}} 1$. 注意到 $S_n \geq \tilde{S}_n$ 及 (2) 中结论, 我们实际证明了 $\lim_{n \rightarrow \infty} \frac{S_n}{n \log_2 n} \stackrel{\text{a.s.}}{=} 1$;

(4) 请利用 *B-C* 第二引理论证 $\overline{\lim_{n \rightarrow \infty}} \frac{X_n}{n \log_2 n} \stackrel{\text{a.s.}}{=} \infty$, 进而 $\overline{\lim_{n \rightarrow \infty}} \frac{S_n}{n \log_2 n} \stackrel{\text{a.s.}}{=} \infty$.

作为拓展, 该问题的类似中心极限定理的讨论, 请读者基于下章将要介绍的特征函数理论进行尝试, 亦可参见文献.^[75]

¹ 以下结论也成立: 当 $\sum_{q=1}^{\infty} \frac{1}{\varphi(q)} = \infty$ 时, $\text{Leb}(A_\varphi^c) = 0$. 但它的证明有一定难度.

第十一章 特征函数及其应用

在第五章我们就引入了分布函数、分布测度的概念作为随机变量的分布律的表达形式。在本章我们将介绍特征函数的概念及其有关理论与应用。我们将重点介绍特征函数的三大定理：唯一性定理、连续性定理和刻画定理。特征函数的唯一性定理告诉我们，特征函数是与分布函数/分布测度等价的刻画随机变量的分布律的工具。而特征函数的连续性定理则表明，我们可以通过研究对应的特征函数列的收敛行为来探讨随机变量列的依分布收敛性质，由此特征函数有一个经典且重要的应用：中心极限定理。我们的论述以一维情形为主，因为大部分场合高维的对应命题、对应性质等的表述是类似的，而基于一维的相应结果，高维情形的证明通常也是类似或简单的。

11.1 特征函数与分布测度

特征函数的概念发源于 Laplace 的工作；后来 A. M. Lyapunov（李雅普诺夫，1857/6/6—1918/11/3；俄国）在 1900、1901 年各发表了一篇文章，首创使用特征函数方法，得到了关于独立和的第一个比较一般的中心极限定理（基于 Lyapunov 条件），由此特征函数方法开始了广泛的应用。但这个方法的奠基性工作——特征函数的连续性定理，是在这个方法已经使用较多年后才由 P. Lévy（莱维，1886—1971）完成严格论证的。

注 11.1. A. M. Lyapunov（李雅普诺夫，1857—1918；俄国）是 P. Chebyshev 的学生，以动力系统方向的稳定性理论知名，在数学物理和概率论中也有诸多贡献。他 1876 年入读圣彼得堡大学数学物理系，一个月后转系到数学系。他先是在当时的力学教授 D. K. Bobylev 的指导下完成第一个独立科学研究工作；之后成为 Chebyshev 的学生。1880 年因流体静力学方面的工作获得一枚金质奖章，并于同年毕业。他培养的学生有：Nikola Saltikov（萨尔蒂科夫）和 Vladimir Steklov（斯捷克洛夫；1864—1926；俄罗斯-苏联数学家、力学家、物理学家，以 Poincaré-Steklov 知名）等。

法国数学家 Paul Pierre Lévy（莱维，1886—1971）生于巴黎、卒于巴黎，是 Hadamard（阿达马，1865—1963；法国）和 Vito Volterra（伏特拉，1860—1940；意大利）的学生。他 1904 年考入巴黎高等师范学校，后在巴黎综合理工学院毕业，1913 年在巴黎综合理工学院任教，1920 年升任教授；1950 年起在美国各大学任教，1962 年返回法国，1964 年 Lévy 在 78 岁时当选为巴黎科学院院士。Lévy 在泛函分析、函数论、拓扑学、力学等多方面都有贡献；但他最主要的贡献在概率论研究，他重新发现并完善了特征函数理论，发展了中心



图 11.1: A. M. Lyapunov(1857-1918)




图 11.2: P. Lévy(1886-1971)

极限定理, 提出“分布律”, 独创从样本函数角度研究随机过程, 对 *Brown* 运动和鞅的研究具有高度建设性, 其影响遍及整个概率论。

Lévy 培养的知名学生有: *Wolfgang Doeblin* (杜布林; 1915—1940; 德国-法国数学家, 犹太裔, 另一个指导老师是 *Maurice René Fréchet* (弗雷歇); 马氏链的 *Doeblin* 比值极限定理就是以他的姓氏命名的), *Michel Loève* (姜埃伍; 1907—1979; 法国-美国概率学家、数理统计学家, 犹太裔; 以 *Karhunen-Loève* 定理知名), *Benoît Mandelbrot* (曼德勃罗; 1924—2010; 波兰出生的法国-美国数学家, 在分形几何方向有突出贡献), *Georges Matheron* (马瑟龙; 1930—2000; 法国数学家、工程师, 与 *Jean Serra* (塞拉) 一起创立了数学形态学) 等。

给定分布函数 F (或它诱导的分布测度 μ_F), 它对应的特征函数 (记作 $\hat{\mu}_F$) 定义为

$$\hat{\mu}_F(\lambda) := \int \exp(i\lambda \cdot x) dF(x), \quad \lambda \in \mathbb{R}, \quad (11.1)$$

其中 $i = \sqrt{-1}$ 为虚单位。设随机变量 $X \sim F$. 上面定义也等价于

$$\hat{\mu}_F(\lambda) = \mathbb{E}[\exp(i\lambda \cdot X)]. \quad (11.2)$$

对于高维随机变量或高维随机变量的联合分布函数, 也可类似定义它们的特征函数, 只是相应的变元 λ, x 应视作相应欧氏空间中的向量值变元, 而乘积 $\lambda \cdot x$ 则视作相应欧氏空间中的标准内积。

调和分析中的 Fourier 变换定义为¹: $\mathcal{F}(\rho)(\lambda) := \int \rho(x) \cdot e^{-i\lambda \cdot x} dx$. 容易知道, 当分布 F 具有密度 ρ 时, 相应的特征函数恰好是:

$$\hat{\mu}_F(\lambda) = \hat{\rho}(\lambda) := \int \rho(x) \cdot e^{i\lambda \cdot x} dx.$$

¹也有很多文献把 Fourier 变换定义为 $\mathcal{F}(\rho)(\lambda) := \int \rho(x) \cdot e^{-2\pi i \lambda \cdot x} dx$, 这样定义的好处是 Fourier 变换成为一个 L^2 -等距变换。

对应于上面的符号, 则 $\hat{\rho}(\lambda) = \mathcal{F}(\rho)(-\lambda)$; 因此, 通过适当调整 Fourier 变换定义 (在本章将把 Fourier 变换定义为 $\mathcal{F}(\rho)(\lambda) := \hat{\rho}(\lambda)$), 此处的特征函数可以视作密度函数的 Fourier 变换¹。

有关特征函数的基本性质, 我们提请读者参看课后习题 11.3、11.4、11.8 等习题中的结论。简而言之, 随机变量的特征函数具有如下一些分析性质:

- ◆ 0 处的特征函数值为 1;
- ◆ 特征函数都是复值、有界、一致连续函数;
- ◆ 当对应分布是连续型分布时, 特征函数在无穷远处的极限是 0.

关于特征函数更精确的刻画, 读者可以参见本章 §11.2.3 的 Bochner-Khintchine 定理。而特征函数最重要的概率性质则是:

- ◆ 当随机变量/向量 X, Y 相互独立时, 它们二者联合的特征函数就等于它们各自特征函数的“张量积”, 亦即

$$\mathbb{E}[\exp\{i(a \cdot X + b \cdot Y)\}] = \mathbb{E}[\exp\{i(a \cdot X)\}] \cdot \mathbb{E}[\exp\{i(b \cdot Y)\}], \quad (11.3)$$

其中 X, Y 相互独立, a, b 是相应的实数 (或实数值向量)。

本章的定理 11.2.2 最终告诉我们, 特征函数的这种可乘性完全刻画了随机变量/向量之间的相互独立性。

这里, 我们特别提请读者熟悉正态分布等常见分布的特征函数。

- 例 11.1.** (1) 设 $Z \sim N(0, 1)$, 那么 Z 的特征函数为 $\mathbb{E}[e^{itZ}] = \exp\{-\frac{t^2}{2}\}$;
 (2) 设 $X \sim N(\mu, \sigma^2)$, 那么 X 的特征函数为 $\mathbb{E}[e^{itX}] = \exp\{i\mu t - \frac{\sigma^2 t^2}{2}\}$;
 (3) 设 $Y \sim N(\mu, \Sigma)$, 其中 $\mu \in \mathbb{R}^m, \Sigma = (\sigma_{i,j})_{1 \leq i,j \leq m}$, 那么 Y 的特征函数为 $\mathbb{E}[e^{i\langle t, Y \rangle}] = \exp\{i\langle \mu, t \rangle - \frac{\langle t, \Sigma t \rangle}{2}\}$, 其中 $\langle \cdot, \cdot \rangle$ 是 $\mathbb{R}^m$ 中的标准内积。

证明: 第一条结论最为关键, 其他结论可以在此基础上通过线性变换及借助独立性 (高维情形先考虑高维的标准正态分布) 的办法来完成对相应特征函数的计算; 对应细节留给读者。

当 $\lambda \in \mathbb{R}$ 时, 配方法结合换元容易计算出

$$\mathbb{E}[e^{\lambda Z}] = \int \frac{e^{\lambda x}}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx = e^{\frac{\lambda^2}{2}}.$$

¹在更一般情形则可视作分布测度的“Fourier 变换”。

因此(1)中结论在形式演算下来理解并不难,但数学上严格证明要一定的功夫。借助留数定理来完成计算与论证,是一种方法,细节留给读者;此处我们使用微分的方法。事实上,令

$$\psi(t) := \mathbb{E}[e^{itZ}] = \int \frac{e^{itx}}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx.$$

注意到被积函数的虚部是一个奇函数,对应积分为0,因此

$$\psi(t) = \int \frac{\cos(tx)}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx.$$

我们可以在积分号下关于 t 求导¹:

$$\begin{aligned} \psi'(t) &= \int \frac{-x \sin(tx)}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx = \int \frac{\sin(tx)}{\sqrt{2\pi}} de^{-\frac{x^2}{2}} \\ &= - \int \frac{t \cos(tx)}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx = -t\psi(t). \end{aligned}$$

这表明 $\frac{d}{dt}[\psi(t)e^{\frac{t^2}{2}}] = 0$, 从而 $\psi(t)e^{\frac{t^2}{2}} = \psi(0) = 1$, 即 $\psi(t) = e^{-\frac{t^2}{2}}$. $\square$

在习题11.31中,基于上例中的事实以及后续将介绍的特征函数的唯一性定理和连续性定理,我们讨论了正态分布的推广—Gauss 分布。

例 11.2. 设 $X \sim \text{Cauchy}(0, 1)$, 那么 X 的特征函数为 $\mathbb{E}[e^{itX}] = e^{-|t|}$.

证明: 使用留数定理直接进行计算是一种办法。这里提供另外一种办法。

例8.21告诉我们,如果 $\{Z_k\}_{k=1}^2 \stackrel{\text{i.i.d.}}{\sim} N(0, 1)$, 则 $Z_1/Z_2 \sim \text{Cauchy}(0, 1)$. 我们基于此而进行计算。事实上,不妨设 $t \neq 0$, 则

$$\begin{aligned} \mathbb{E}[e^{itX}] &= \mathbb{E}[e^{itZ_1/Z_2}] \\ &= \mathbb{E}\left[\mathbb{E}[e^{itZ_1/Z_2} | Z_2]\right] = \mathbb{E}[\exp\{-\frac{t^2}{2Z_2^2}\}] \\ &= \int \exp\{-\frac{t^2}{2x^2}\} \cdot \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx \\ &= \frac{2}{\sqrt{2\pi}} \int_0^\infty \exp\{-\frac{1}{2}[x^2 + \frac{t^2}{x^2}]\} dx \quad (\text{换元 } u := x - \frac{|t|}{x}) \\ &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^\infty \exp\{-\frac{1}{2}[u^2 + 2|t|]\} \cdot [1 + \frac{u/2}{\sqrt{(u/2)^2 + |t|}}] du = e^{-|t|}. \quad \square \end{aligned}$$

11.2 特征函数的三大定理

本节我们集中讲述特征函数的三大定理。为了实际论述的方便,我们将按照特征函数的唯一性定理、连续性定理、刻画定理的顺序进行讲述。

¹请读者思考此处能在积分号下求导的原因。

11.2.1 特征函数的唯一性定理

下面的定理给出了从特征函数到分布函数的一些逆转公式/反演公式。

♠ **定理 11.2.1.** (逆转公式) 设 F 是分布函数, $\hat{\mu}_F$ 是其对应的特征函数。

(1) 对于 F 的任意两个连续点 $a < b$, 有

$$F(b) - F(a) = \lim_{T \rightarrow \infty} \frac{1}{2\pi} \int_{-T}^T \frac{e^{-iat} - e^{-ibt}}{it} \cdot \hat{\mu}_F(t) dt; \quad (11.4)$$

(2) 对任意 $\varphi \in C_0(\mathbb{R})$,

$$\int \varphi dF = \lim_{t \downarrow 0} \frac{1}{2\pi} \int \varphi(x) dx \int e^{-ixz} \cdot \hat{\mu}_F(z) \cdot e^{-\frac{t}{2}|z|^2} dz; \quad (11.5)$$

(3) 如果 $\|\hat{\mu}_F\|_1 := \int |\hat{\mu}_F| dt < \infty$, 那么 F 具有密度函数 $\rho(x)$, 且

$$\rho(x) = \frac{1}{2\pi} \int e^{-itx} \cdot \hat{\mu}_F(t) dt, \quad (11.6)$$

并且 $\sup_x \rho(x) \leq \frac{\|\hat{\mu}_F\|_1}{2\pi} < \infty$ (从而 F 是 *Lipschitz* 连续函数)。

(4) ¹ 如果 $\|\hat{\mu}_F\|_2 := \sqrt{\int |\hat{\mu}_F|^2 dt} < \infty$, 那么 F 是 $\frac{1}{2}$ -Hölder 连续的, 并且具有密度函数 $\rho(x)$. 此时

$$\rho(x) = \lim_{T \rightarrow \infty} \frac{1}{2\pi} \int_{-T}^T e^{-itx} \cdot \hat{\mu}_F(t) dt \quad (11.7)$$

在 $L^2(\mathbb{R})$ 中的 L^2 -收敛意义下成立。

证明: 先证明 (2). 假设 $X \sim F, \xi \sim N(0, 1)$ 且二者独立, 那么对任意紧支集连续函数 φ 及 $t > 0$

$$\begin{aligned} \mathbb{E}[\varphi(X + \sqrt{t}\xi)] &= \mathbb{E}\left[\int \varphi(X + \sqrt{t}z) \cdot \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}} dz\right] \\ &= \mathbb{E}\left[\int \varphi(X + \sqrt{t}z) \cdot \frac{1}{\sqrt{2\pi}} \mathbb{E}[e^{-iz\xi}] dz\right] \\ &= \mathbb{E}\left[\frac{1}{\sqrt{2\pi}} \int \varphi(X + \sqrt{t}z) \cdot e^{-iz\xi} dz\right] \\ &= \mathbb{E}\left[\frac{1}{\sqrt{2\pi t}} \int \varphi(x) \cdot e^{-i\xi \cdot \frac{x-X}{\sqrt{t}}} dx\right] = \frac{1}{\sqrt{2\pi t}} \int \varphi(x) \cdot \mathbb{E}\left[e^{-i\xi \cdot \frac{x-X}{\sqrt{t}}}\right] dx \end{aligned}$$

¹ 此条结论在文献^[60]第 299 页有非常简短的描述, 后来编者发现在钟开莱的中文译书^[132]的习题 6.2.11 中也有出现; 较多概率论教科书中缺失这一漂亮结果的论述。此处也感谢李洪全教授介绍参考文献^[46]

$$\begin{aligned}
&= \frac{1}{\sqrt{2\pi t}} \int \varphi(x) \cdot \mathbb{E} \left[e^{-i\xi \cdot \frac{x}{\sqrt{t}}} \cdot \widehat{\mu}_F \left(\frac{\xi}{\sqrt{t}} \right) \right] dx \\
&= \frac{1}{2\pi\sqrt{t}} \int \varphi(x) \cdot \left[\int e^{-iy \cdot \frac{x}{\sqrt{t}}} \cdot \widehat{\mu}_F \left(\frac{y}{\sqrt{t}} \right) e^{-\frac{y^2}{2}} dy \right] dx \\
&= \frac{1}{2\pi} \int \varphi(x) \cdot \left[\int e^{-iz \cdot x} \cdot \widehat{\mu}_F(z) e^{-\frac{1}{2}z^2} dz \right] dx.
\end{aligned}$$

再令 $t \downarrow 0$, 注意到 φ 连续有界, 由控制收敛定理立即得到结论 (2).

再证明 (1). 事实上,

$$\begin{aligned}
&\frac{1}{2\pi} \int_{-T}^T \frac{e^{-iat} - e^{-ibt}}{it} \cdot \widehat{\mu}_F(t) dt \\
&= \frac{1}{2\pi} \int_{-T}^T \frac{e^{-iat} - e^{-ibt}}{it} \cdot \mathbb{E}[e^{itX}] dt \\
&= \mathbb{E} \left[\frac{1}{2\pi} \int_{-T}^T \frac{e^{-iat} - e^{-ibt}}{it} \cdot e^{itX} dt \right] \\
&= \mathbb{E} \left[\frac{1}{2\pi} \int_{-T}^T \frac{\sin[(X-a)t] - \sin[(X-b)t]}{t} dt \right].
\end{aligned}$$

利用 $\int \frac{\sin \alpha t}{t} dt = \pi \cdot \text{sgn}(\alpha)$, 其中 $\text{sgn}(\alpha) := 1_{(0,\infty)}(\alpha) - 1_{(-\infty,0)}(\alpha)$, 结合控制收敛定理¹, 立即得到:

$$\lim_{T \rightarrow \infty} \frac{1}{2\pi} \int_{-T}^T \frac{e^{-iat} - e^{-ibt}}{it} \cdot \widehat{\mu}_F(t) dt = \frac{1}{2} \mathbb{E} [\text{sgn}(X-a) - \text{sgn}(X-b)].$$

简单计算表明

$$\mathbb{E} [\text{sgn}(X-a) - \text{sgn}(X-b)] = [F(b) + F(b-)] - [F(a) + F(a-)].$$

因此当 a, b 为 F 的连续点时定理的结论 (1) 成立。对于一般情况 $a < b$, 有

$$\lim_{T \rightarrow \infty} \frac{1}{2\pi} \int_{-T}^T \frac{e^{-iat} - e^{-ibt}}{it} \cdot \widehat{\mu}_F(t) dt = \mu_F((a, b)) + \frac{\mu_F(\{a, b\})}{2}. \quad (11.8)$$

现在来证明 (3). 我们先论证 μ_F 是绝对连续的。事实上, 假定 $a < b$ 都是 F 的连续点, 那么由 (11.4)

$$|F(b) - F(a)| \leq \frac{1}{2\pi} \int \left| \frac{e^{-iat} - e^{-ibt}}{it} \right| \cdot |\widehat{\mu}_F(t)| dt.$$

¹ 提示: 根据本书第四章例4.8的结论(4.12), 常数 $M := \sup\{|\frac{1}{\pi} \int_{-T}^T \frac{\sin x}{x} dx| : T > 0\} < \infty$ 可以作为控制函数. 文献^[132]指出, $0 \leq \int_0^T \frac{\sin x}{x} dx \leq \int_0^\pi \frac{\sin x}{x} dx, \forall T > 0$, 因而 $M = \frac{2}{\pi} \int_0^\pi \frac{\sin t}{t} dt \leq 2$. 文献^[29]的 Exercise 1.7.5 指出, 对 $T > 0$, $\int_0^T \frac{\sin x}{x} dx = \frac{\pi}{2} - \int_0^\infty \frac{(\cos T + y \sin T) e^{-Ty}}{1+y^2} dy$, 进而 $|\int_0^T \frac{\sin x}{x} dx - \frac{\pi}{2}| \leq \frac{1}{T}, \forall T > 0$.

计算表明, $|\frac{e^{-iat} - e^{-ibt}}{it}| \leq |b - a|$, 从而

$$|F(b) - F(a)| \leq \frac{\|\widehat{\mu}_F\|_1}{2\pi} \cdot |b - a|.$$

由于上述估计对于 F 的所有连续点 a, b 都成立, 很容易推断它实际上对所有 a, b 成立。由此 F 是绝对连续的, 具有密度 ρ . 现在对任意 $a < b$ 都有:

$$\frac{F(b) - F(a)}{b - a} = \frac{1}{2\pi} \int \frac{e^{-iat} - e^{-ibt}}{i(b-a)t} \cdot \widehat{\mu}_F(t) dt.$$

令 $b \downarrow a$, 由控制收敛定理

$$\rho(a) = \frac{1}{2\pi} \int e^{-iat} \cdot \widehat{\mu}_F(t) dt.$$

显然 ρ 具有定理中的上界估计。

最后证明 (4). 对 $L^2(\mathbb{R})$, 我们记其上内积为 $\langle \cdot, \cdot \rangle$, 即

$$\langle f, g \rangle := \int \bar{f}(x)g(x)dx, \quad \forall f, g \in L^2(\mathbb{R}).$$

特别地, Fourier 变换与其逆变换在 $L^2(\mathbb{R})$ 中有定义 (见文献^[46]的 Section 2.2.3—2.2.4), 且如下形式的 Parseval 恒等式成立

$$\langle \widehat{f}, \widehat{g} \rangle = 2\pi \langle f, g \rangle, \quad \forall f, g \in L^2(\mathbb{R}). \quad (11.9)$$

假定 $a < b$ 都是 F 的连续点。注意到

$$\frac{e^{-iat} - e^{-ibt}}{it} = \int e^{-ixt} 1_{(a,b]}(x) dx = \widehat{1}_{(a,b]}(t),$$

有 $\|\widehat{1}_{(a,b]}\|_2 = \sqrt{2\pi} \|1_{(a,b]}\|_2 = \sqrt{2\pi|b-a|}$.

由 (11.4) 以及 Cauchy 不等式,

$$F(b) - F(a) = \frac{1}{2\pi} \langle \widehat{1}_{(a,b]}, \widehat{\mu}_F \rangle \leq \sqrt{\frac{|b-a|}{2\pi}} \cdot \|\widehat{\mu}_F\|_2.$$

因此 F 是 $\frac{1}{2}$ -Hölder 连续的。

由于 $\widehat{\mu}_F \in L^2(\mathbb{R})$, 存在 $\rho \in L^2(\mathbb{R})$ 使得 $\widehat{\mu}_F = \widehat{\rho}$. 下面我们论证 ρ 就是 F 的密度函数。事实上, 对任意 $a < b$, 有

$$\begin{aligned} F(b) - F(a) &= \frac{1}{2\pi} \langle \widehat{1}_{(a,b]}, \widehat{\mu}_F \rangle = \frac{1}{2\pi} \langle \widehat{1}_{(a,b]}, \widehat{\rho} \rangle \\ &= \langle 1_{(a,b]}, \rho \rangle = \int_{(a,b]} \rho(x) dx. \end{aligned}$$

由此, ρ 应为实函数, 且非负, 并且它是分布 F 的密度函数。(11.7)的证明留给读者 (提示: $\|\hat{f}\|_2 = \sqrt{2\pi}\|f\|_2, \forall f \in L^2(\mathbb{R})$). $\square$

上面的逆转公式是一维情形的结论。需要指出的是, 高维情形下上述定理中 (3) 的类似结果仍然成立。基于这个结果容易知道: 随机变量 (或向量) 的分布函数与它的特征函数之间是一一对应的, 也就是说, 特征函数是与分布函数 (或分布测度) 等价的刻画随机变量分布律的工具; 这个结论又称为特征函数的唯一性定理。

在承认特征函数的唯一性定理后, 使用特征函数工具来刻画随机变量的独立性就是很简单的事情了。

♠ 定理 11.2.2. 设 X, Y 的分布测度分别为 μ_X, μ_Y , 联合分布测度记作 $\mu_{(X,Y)}$. 那么 X 与 Y 独立的充分必要条件是

$$\hat{\mu}_{(X,Y)}(u, v) = \hat{\mu}_X(u)\hat{\mu}_Y(v).$$

上式也可以简单记为: $\hat{\mu}_{(X,Y)} = \hat{\mu}_X \otimes \hat{\mu}_Y$, 右端 $\otimes$ 表示函数的张量积。这正好和我们用分布测度描述的独立性对应: X 与 Y 独立的充分必要条件是 $\mu_{(X,Y)} = \mu_X \otimes \mu_Y$.

例 11.3. 设 $\{X_k\}_{k=1}^n \stackrel{\text{i.i.d.}}{\sim} \text{Cauchy}(0, 1)$, $\bar{X} := \frac{X_1 + \cdots + X_n}{n}$, 证明: X_1 和 $\bar{X}$ 的特征函数都是 $e^{-|t|}$, 从而 $\bar{X} \sim \text{Cauchy}(0, 1)$.

证明: 在例11.2中我们用其他方法证明了 $\text{Cauchy}(0, 1)$ 的特征函数是 $e^{-|t|}$. 基于特征函数的唯一性定理, 现在我们也可按如下步骤来给出这一结果的证明: (1) 证明密度函数 $\frac{1}{2} \cdot e^{-|x|}$ 的特征函数 (Fourier 变换) 为 $\frac{1}{1+t^2}$; (2) 利用特征函数的唯一性定理 (见方程(11.6)), 密度 $\rho(x) = \frac{1}{\pi(1+x^2)}$ 的特征函数 (Fourier 变换) 必定形如 $C \cdot e^{-|t|}$, 此时必定有 $C = 1$. 有关细节论证留给读者。

现在, 容易计算 $\bar{X}$ 的特征函数

$$\mathbb{E}[e^{it\bar{X}}] = \mathbb{E}\left[\prod_{k=1}^n e^{itX_k/n}\right] = \prod_{k=1}^n \mathbb{E}[e^{itX_k/n}] = \prod_{k=1}^n e^{-|t|/n} = e^{-|t|}.$$

即 $\bar{X}$ 的特征函数是 $e^{-|t|}$, 进而由特征函数的唯一性定理, $\bar{X} \sim \text{Cauchy}(0, 1)$. $\square$

11.2.2 特征函数的连续性定理

通过特征函数, 我们可以估计分布函数的尾部特征, 具体而言我们下面的重要引理:

◆ **引理 11.2.1.** 设 f 是随机变量 X 的特征函数。那么对任意 $\varepsilon > 0, 0 < \delta \leq 1$, 存在绝对常数 $K = K_\delta > 0$ (仅依赖于 δ), 使得

$$\mathbb{P}(|X| \geq \varepsilon) \leq K \cdot \int_0^1 [1 - \operatorname{Re}(f(t\delta/\varepsilon))] dt \quad (11.10)$$

$$\mathbb{E}[X^2 \cdot 1_{\{|X| \leq \varepsilon\}}] \leq K \cdot \varepsilon^2 \cdot [1 - \operatorname{Re}(f(\frac{\delta}{\varepsilon}))]. \quad (11.11)$$

证明: 补充定义函数 $\frac{\sin x}{x}$ 在 0 处的取值为 1, 则此函数成为 $\mathbb{R}$ 上有界一致连续函数; 类似的, 补充定义 $\frac{1 - \cos x}{x^2}$ 在 0 处的取值为 $\frac{1}{2}$, 此函数也成为 $\mathbb{R}$ 上有界一致连续函数。于是对任意 $\delta \in (0, 1]$, 存在 $K = K_\delta > 0$ 使得

$$1 - \frac{\sin x}{x} \geq \frac{1}{K}, \quad \forall |x| \geq \delta,$$

并且

$$\frac{1 - \cos x}{x^2} \geq \frac{1}{K}, \quad \forall |x| \leq \delta.$$

记 F 为 X 的分布函数, 有 (此处 $M := \delta/\varepsilon$)

$$\begin{aligned} \mathbb{P}(|X| \geq \varepsilon) &= \mathbb{E}[1_{\{|MX| \geq \delta\}}] \leq K \mathbb{E}[1 - \frac{\sin MX}{MX}] \\ &= K \int_0^1 [1 - \operatorname{Re} f(Mt)] dt. \end{aligned}$$

此即引理的第一个不等式。

类似的,

$$\begin{aligned} \mathbb{E}[|X|^2 \cdot 1_{\{|X| \leq \varepsilon\}}] &= \frac{1}{M^2} \mathbb{E}[|MX|^2 \cdot 1_{\{|MX| \leq \delta\}}] \\ &\leq \frac{K}{M^2} \mathbb{E}[1 - \cos MX] = \frac{K}{M^2} \cdot [1 - \operatorname{Re}(f(M))]. \end{aligned}$$

此即引理的第二个不等式。 □

在第十章中, 我们已经介绍过依分布收敛的概念, 再次陈述如下。

定义 11.2.1. 设 $\{X_n\}_{n=0}^\infty$ 为随机变量列。称 $\{X_n\}_{n=1}^\infty$ 依分布收敛到 X_0 , 记作 $X_n \xrightarrow{d} X_0$, 如果 $F_n(x), F_0(x)$ 分别是 X_n, X_0 的分布函数, 且对于 F_0 的任意连续点 x , 总有 $\lim_{n \rightarrow \infty} F_n(x) = F_0(x)$; 有时也记 $F_n \xrightarrow{w} F_0$, 或 $X_n \xrightarrow{d} F_0$ 。注意, 此处诸随机变量 $X_0, X_1, \dots$ 可以定义在不同的概率空间中, 而不必定义在同一个概率空间中。

更一般地, 设 $\{F_n\}_{n=0}^\infty$ 是递增右连续函数的序列。如果在 F_0 的连续点上 F_n 收敛到 F_0 , 就称 F_n 弱收敛到 F_0 , 记作 $F_n \xrightarrow{w} F_0$ 。当 F_n, F_0 都是概率分布函数时, 我们也把 $F_n \xrightarrow{w} F_0$ 称为 F_n 正常地弱收敛到 F_0 。

此外, 设 $\{\mu_n\}_{n=0}^\infty$ 是有限维欧氏空间 $\mathbb{R}^m$ 上的 Borel 概率测度, 设 $X_n \sim \mu_n$, 如果对任意有界连续函数 f , 总成立

$$\mathbb{E}[f(X_n)] \rightarrow \mathbb{E}[f(X_0)],$$

则称 $\{\mu_n\}_{n=1}^\infty$ 弱收敛到 μ_0 , 记作 $\mu_n \xrightarrow{w} \mu_0$.

由 Skorokhod 嵌入定理 (定理10.2.7), 容易知道下面结果成立。

♠ 定理 11.2.3. (Helly-Bray 定理) 设 $X_n \xrightarrow{d} X_0$, 那么

$$\lim_{n \rightarrow \infty} \mathbb{E}[f(X_n)] = \mathbb{E}[f(X_0)]$$

对任意有界连续函数 f 成立。

下面的定理则称为特征函数的连续性定理, 通常也称为 Lévy 连续性定理。它本质上说明了从分布函数到特征函数这个一一映射的双向连续性。这是实际应用中利用特征函数来论证依分布收敛 (特别是中心极限定理) 的理论依据。

♠ 定理 11.2.4. (特征函数的连续性定理) 设 $\{F_n\}_{n=1}^\infty$ 是一列分布函数, $\{f_n\}_{n=1}^\infty$ 是其对应的特征函数列。

- (1) 如果 $F_n \xrightarrow{w} F$, 其中 F 是某一分布函数, 那么 $\hat{\mu}_{F_n} \rightarrow \hat{\mu}_F$ 点点成立;
- (2) 如果对每个 $t \in \mathbb{R}$ 点点极限 $\lim_{n \rightarrow \infty} \hat{\mu}_{F_n}(t) = g(t)$ 存在, 并且 $g(t)$ 在 $t = 0$ 处连续, 那么 g 是某一分布 F 的特征函数, 即 $g = \hat{\mu}_F$, 并且 $F_n \xrightarrow{w} F$.

为了论证上述定理, 我们需要如下结论 (其中 $m \geq 1$ 为整数)。

♠ 定理 11.2.5. (Helly 选择定理) $\mathbb{R}^m$ 上任何分布函数列 $\{F_n\}_{n=1}^\infty$ 都有弱收敛¹的子列 $\{F_{n_k}\}$.

证明: 此定理实际上可以看成点集拓扑理论中 Tychonov 定理的一个推论。这里我们给出另外一个简单的证明。

先证明 $m = 1$ 的情形。任取 $\mathbb{R}$ 的一个可数稠密子集 $D = \{x_n : n \geq 1\}$ (比如可以取 $D = \mathbb{Q}$)。利用对角线法则容易验证,



图 11.3: Helly (1884-1943)

¹注意, 此处的弱收敛可以是非正常的弱收敛, 即收敛到的函数允许不是概率分布函数。

存在子列 $\{n_k\}_{k=1}^\infty$ 使得对任意给定 $i \geq 1$, $\{F_{n_k}(x_i)\}_{k=1}^\infty$ 收敛。令

$$F(r) := \lim_{k \rightarrow \infty} F_{n_k}(r), r \in D.$$

容易知道 $F: D \rightarrow \mathbb{R}$ 是单调不减函数。补充定义

$$F(x) := \lim_{D \ni r \downarrow x} F(r), x \in \mathbb{R} \setminus D.$$

容易知道, 此时 F 成为 $\mathbb{R}$ 上一个递增函数, 并且在 D^c 上右连续 (注意! 未必是概率分布函数). 记 F 的连续点集为 $\mathcal{C}_F$. 并记

$$\overline{F}(x) := \overline{\lim}_{k \rightarrow \infty} F_{n_k}(x), \quad \underline{F}(x) := \underline{\lim}_{k \rightarrow \infty} F_{n_k}(x).$$

那么对任意 $x \in \mathcal{C}_F$, 存在 D 中点列 $r_n \uparrow x, r'_n \downarrow x$, 于是 $r_n < x < r'_n$,

$$\begin{aligned} \overline{F}(x) &\leq \overline{\lim}_{k \rightarrow \infty} F_{n_k}(r'_n) = F(r'_n) \rightarrow F(x), \\ \underline{F}(x) &\geq \underline{\lim}_{k \rightarrow \infty} F_{n_k}(r_n) = F(r_n) \rightarrow F(x) \end{aligned}$$

成立, 这表明 $\lim_{k \rightarrow \infty} F_{n_k}(x) = F(x), \forall x \in \mathcal{C}_F$. 注意, F 未必具有右连左极性质; 但由于 F 是一个单调函数, 我们可以对它进行右连续修正, 这并不会改变它的连续点上的取值; 我们把修正后的函数记作 $\tilde{F}$, 显然 F 与 $\tilde{F}$ 具有相同的连续点集. 那么 $F_{n_k} \xrightarrow{w} \tilde{F}$. 因此定理结论成立。

对于 $m \geq 2$ 的情形类似可证。 □

定理11.2.4的证明: (1) 注意到 Skorokhod 嵌入定理, 我们不妨假设 $X_n \rightarrow X$ 是几乎处处的, 其中 $X_n \sim F_n, X \sim F$. 那么对于任意 $\lambda \in \mathbb{R}$, $e^{i\lambda X_n} \rightarrow e^{i\lambda X}$ 几乎处处成立. 由 Lebesgue 控制收敛定理 (或有界收敛定理),

$$\hat{\mu}_{F_n}(\lambda) = \mathbb{E}[e^{i\lambda X_n}] \rightarrow \mathbb{E}[e^{i\lambda X}] = \hat{\mu}_F(\lambda).$$

(2) 此处我们假设 $X_n \sim F_n$. 由 Helly 定理, $\{F_n\}_{n=1}^\infty$ 有子列 $\{F_{n_k}\}_{k=1}^\infty$ 弱收敛于某个递增右连续的函数 G , 并且容易知道 $0 \leq G(x) \leq 1, \forall x \in \mathbb{R}$. 我们先论证 G 是分布函数. 任取 $T > 0$, 由引理11.2.1 (取 $\varepsilon = T, \delta = 2$, 此时可取 $K = 2$),

$$\mathbb{P}(|X_{n_k}| \geq T) \leq 2 \int_0^1 [1 - \operatorname{Re}(\hat{\mu}_{F_{n_k}}(2\lambda/T))] d\lambda.$$

对固定的 T , 由控制收敛定理,

$$\lim_{k \rightarrow \infty} \int_0^1 [1 - \operatorname{Re}(\hat{\mu}_{F_{n_k}}(2\lambda/T))] d\lambda = \int_0^1 [1 - \operatorname{Re}(g(2\lambda/T))] d\lambda.$$

注意到 g 在 0 处的连续性以及 $g(0) = 1$,

$$\lim_{T \rightarrow \infty} \int_0^1 [1 - \operatorname{Re}(g(2\lambda/T))] d\lambda = 0.$$

注意到当 $\pm T$ 均为 G 的连续点时

$$\mathbb{P}(X_{n_k} \in (-T, T]) = F_{n_k}(T) - F_{n_k}(-T) \rightarrow G(T) - G(-T).$$

记 $\mathcal{D} := \{T : \pm T \text{ 为 } G \text{ 的连续点}\}$, 则 $\mathcal{D}$ 是 $\mathbb{R}$ 中 Lebesgue 满测集, 因而

$$\lim_{\mathcal{D} \ni T \rightarrow \infty} [G(T) - G(-T)] \geq \overline{\lim}_{\mathcal{D} \ni T \rightarrow \infty} \lim_{k \rightarrow \infty} [1 - \mathbb{P}(|X_{n_k}| \geq T)] \geq 1,$$

由此, G 是概率分布函数。

现在我们论证 $g = \hat{\mu}_G$. 事实上, 我们已经论证 $F_{n_k} \xrightarrow{w} G$. 由上面的 (1) 立即知道 $\hat{\mu}_{F_{n_k}} \rightarrow \hat{\mu}_G$ 点点成立, 于是 $g = \hat{\mu}_G$. 由唯一性定理, G 由 g 唯一决定。

现在我们知道, G 是一个概率分布, 且 $\hat{\mu}_{F_n} \rightarrow \hat{\mu}_G$ 点点成立。我们要证明 $F_n \xrightarrow{w} G$. 但是, 由上述证明容易知道, $\{F_n\}_{n=1}^\infty$ 任意子列的弱极限都必定是由 g 所唯一决定的分布函数 $F = G$, 于是上述结论成立。□

注 11.2. *Eduard Helly* (海莱; 1884—1943; 奥地利) 生于维也纳, 卒于美国芝加哥。他 1907 年博士毕业于维也纳大学, 之后到哥廷根大学进修 1 年。他在第一次世界大战中应召入伍, 1915 年中弹被俘, 起初关押在西伯利亚的布列左夫卡集中营; 狱中他组织数学讨论班, 当时的工程师狱友 *Tibor Radó* (拉多; 1895—1965; 匈牙利) 受此影响而对纯粹数学感兴趣, 并在之后成功逃回匈牙利, 1923 年 *Radó* 获得博士学位, 成为数学家, 1929 年移居美国。在转到西伯利亚的尼科利斯克-乌苏里斯克集中营中, *Helly* 继续举办讨论班, 并在泛函分析方面做出重要贡献。他最后在 1920 年重返维也纳, 次年结婚; 1938 年奥地利被纳粹德国占领, 他逃亡到了美国, 在爱因斯坦帮助下, 在新泽西的中学教书, 之后 1941 年与妻子移居芝加哥, 并为美军的通讯部队服务。他在数学中的重要贡献有: *Helly* 定理、*Helly* 族、*Helly* 选择定理、*Helly-Bray* 定理、*Helly* 度量等。

11.2.3 特征函数的刻画定理

下面的 *Böchner-Khintchine* 定理回答了什么样的函数可以作为概率测度的特征函数, 因此我们也把它叫做特征函数的刻画定理。

♠ 定理 11.2.6. (*Böchner-Khintchine* 定理) 设 g 是 $\mathbb{R}$ 上复值连续函数, 且 $g(0) = 1$. 那么 g 是某个概率测度的特征函数的充要条件是: g 是非负定的, 即对任意 $n \geq 2$ 及实数 $\lambda_1, \dots, \lambda_n$, 矩阵 $M_n := (g(\lambda_i - \lambda_j))_{1 \leq i, j \leq n}$ 非负定。

证明： 必要性的证明比较简单，留给读者。

充分性的一个证明思路如下（细节留给读者补充）：对任意 $m > 0$ 定义

$$p_m(x) := \frac{1}{2\pi m} \int_{(0,m)^2} g(t-s) \cdot e^{-i(t-s)x} dt ds.$$

容易验证 p_m 非负，且它是一个密度函数。

定义 $g_m(\lambda) := g(\lambda) \cdot (1 - \frac{|\lambda|}{m}) \cdot 1_{(-m,m)}(\lambda)$. 容易验证 g_m 是 p_m 的 Fourier 变换（或者说特征函数），但是 g_m 点点收敛于 g ，由连续性定理， g 是某个随机变量的特征函数。□



图 11.4: Bochner (1899-1982)

注 11.3. *Salomon Bochner* (博赫纳, 1899—1982; 德国-美国) 生于奥匈帝国克拉科夫城 (今属波兰), 卒于美国休斯敦。他先在克拉科夫和德国的柏林受教育, 后转往哥本哈根大学、牛津大学学习, 于 1921 年获柏林大学博士学位, 后在慕尼黑大学任教多年。1933 年受聘于美国普林斯顿大学, 1938 年入美国籍, 1946 年升任教授。1968 年在退休后又受聘于休斯敦瑞斯大学任数学系主任, 1979 年在该校退休。他是美国科学院院士, 并在 1957—1958 年担任美国数学会副主席。*Bochner* 的数学研究涉及函数论 (傅立叶级数、斯蒂尔切斯积分)、级数论、多元傅立叶积分、函数的积分变换理论、概率论、随机过程论、微分几何学、多复变函数论和泛函分析等方面。他在 1932 年所著《傅里叶积分讲义》中提出了关于正定函数的博赫纳定理和作为广义函数论先导的广义傅里叶变换。他引进的博赫纳积分被广泛运用。多元调和分析中的博赫纳球形和已成为研究多重傅里叶展开的收敛问题及逼近问题的重要工具。在积分法的一般理论中, 他给出了巴拿赫空间的函数积分定义; 复变函数论中有著名的 *Bochner* 定理和表示法等。

11.3 特征函数的几个重要应用

特征函数的主要应用有: (a) 利用特征函数的唯一性定理来计算分布律, 如例 11.3; (b) 利用特征函数的连续性定理来讨论依分布收敛等问题; (c) 综合运用特征函数的唯一性定理、连续性定理、关于特征函数的不等式等来简化有关问题的讨论。

在本节我们主要围绕上述 (b)、(c) 部分给出一些应用案例。

11.3.1 应用 1: Khintchine 弱大数律

对于 i.i.d. 序列的弱大数律, 无论是最初的 Bernoulli 弱大数律, 还是后来的 Chebyshev 弱大数律和 Markov 弱大数律, 都要求分布具有二阶矩。1929 年, Khintchine (1894—1959) 在只要求分布具有一阶矩的条件下证明了下面

的 Khintchine 弱大数律。在概率论的实际发展历史中,它是 Kolmogorov 强大数律的先声。

♠ **定理 11.3.1.** (Khintchine 弱大数律) 设 $\{X_n\}_{n=1}^{\infty}$ 为独立同分布的随机变量序列, 满足 $\mathbb{E}|X_1| < \infty$. 记 $\mu := \mathbb{E}X_1$, 那么 $\bar{X}_n \xrightarrow{\mathbb{P}} \mu$.

证明: 不妨设 $\mu = 0$. 记 f 为 X_1 的特征函数。考察 $\bar{X}_n$ 的特征函数 f_n :

$$f_n(t) := \mathbb{E}[e^{it\bar{X}_n}] = f\left(\frac{t}{n}\right)^n.$$

因为 $\mathbb{E}X_1 = 0$, 容易知道在 0 附近 $f(t) = 1 + o(t)$. 于是

$$|f_n(t) - 1| \leq n|f\left(\frac{t}{n}\right) - 1| \rightarrow 0,$$

即 $\bar{X}_n \xrightarrow{d} 0$. 由定理 10.2.6, $\bar{X}_n \xrightarrow{\mathbb{P}} 0$. $\square$



图 11.5: A. Khintchine (1894–1959)

🔔 **注 11.4.** A. Khintchine (辛钦, 1894—1959) 是前苏联数学家、教育学家。1916 年他毕业于莫斯科大学, 并留校从事教学工作, 1919 年成为教授。1935 年获得数学物理博士学位, 导师是 Nikolai Luzin (1883—1950; 苏联-俄罗斯)。1939 年他被选为苏联科学院通讯院士, 1944 年被选为俄罗斯联邦教育科学院院士。他是前苏联概率论学派的创始人之一, 在概率论的极限定理、平稳随机过程、分析学中的 Denjoy 积分、数论 (特别是连分数) 等方面都有建树。本书第一章中提到的 Markov 过程, 最初 Kolmogorov 起名为无后效过程, 也是 Khintchine 建议改为 Markov 过程。

Khintchine 培养的知名学生有: A. Buchstab (布施塔布; 1905—1990; 苏联数学家, 数论专家, 以 Buchstab 函数知名), A. Gelfand (盖尔范德; 1906—1968; 苏联数学家, 在数论、解析函数、积分方程等方面都有贡献, 以 Gelfand 定理知名, 1934 年彻底解决 Hilbert 第 7 问题) 等。

11.3.2 应用 2: 中心极限定理

最早的中心极限定理是 18 世纪中期 De Moivre 和 Laplace 对 i.i.d. 的 Bernoulli 序列, 基于相应概率分布列的纯粹分析方法建立起来的; 见课后习题 11.40.

Lyapunov 是使用特征函数方法来证明中心极限定理的第一人; 他是 Chebyshev 的学生, 是 Markov 的学弟。在他之前, Chebyshev 和 Markov 是运用“矩方法”来证明一些特殊情形的中心极限定理的。概率理论后来的发展证明, “特征函数是证明最多种多样的极限定理的强有力工具” (见文献^[116]的序言)。

下面这个常见的经典中心极限定理通常也被称为 Lindeberg-Lévy 定理。

♠ **定理 11.3.2.** 设随机变量列 $\{X_n\}_1^{\infty}$ i.i.d., $0 < \sigma^2 := \mathbb{V}\text{ar}(X_1) < \infty$. 记

$$\mu := \mathbb{E}X_1, \quad \bar{X}_n := \frac{X_1 + \cdots + X_n}{n}, \quad Z_n := \frac{\sqrt{n}}{\sigma}(\bar{X}_n - \mu),$$

那么 $Z_n \xrightarrow{d} N(0, 1)$, 即

$$\lim_{n \rightarrow \infty} \mathbb{P}(Z_n \leq x) = \Phi(x) := \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-u^2/2} du, \quad \forall x \in \mathbb{R}. \quad (11.12)$$

证明: 标准正态的特征函数为 $f(t) := e^{-t^2/2}$.

不妨设 $\mu = 0, \sigma^2 = 1$, 即 $\mathbb{E}X_1 = 0, \mathbb{E}[X_1^2] = 1$. 设 X_1 的特征函数为 $g(t) := \mathbb{E}[e^{itX_1}]$. 那么 $Z_n = \sqrt{n}\bar{X}_n$ 的特征函数为

$$f_n(t) := \mathbb{E}[e^{itZ_n}] = g\left(\frac{t}{\sqrt{n}}\right)^n.$$

容易知道,

$$|f_n(t) - f(t)| = \left| g\left(\frac{t}{\sqrt{n}}\right)^n - f\left(\frac{t}{\sqrt{n}}\right)^n \right| \leq n \left| g\left(\frac{t}{\sqrt{n}}\right) - f\left(\frac{t}{\sqrt{n}}\right) \right|.$$

根据 $\mathbb{E}X_1 = 0, \mathbb{E}[X_1^2] = 1$, 有

$$g\left(\frac{t}{\sqrt{n}}\right) = 1 - \frac{t^2}{2n} + o\left(\frac{1}{n}\right).$$

又显然有 $f\left(\frac{t}{\sqrt{n}}\right) = 1 - \frac{t^2}{2n} + o\left(\frac{1}{n}\right)$, 因此

$$n \left| g\left(\frac{t}{\sqrt{n}}\right) - f\left(\frac{t}{\sqrt{n}}\right) \right| = n \cdot o\left(\frac{1}{n}\right) = o(1) \rightarrow 0,$$

即 $f_n \rightarrow f$ 点点成立. 由特征函数的连续性定理, $Z_n \xrightarrow{d} N(0, 1)$ 成立. $\square$

下面给出独立随机变量阵列形式的 Lindeberg-Feller 中心极限定理; 定理的充分性部分归功于 Lindeberg, 必要性部分则归功于 Feller. 本书不提供这个定理的证明, 感兴趣的读者可以参见文献^[40, 105, 132]等著作.



图 11.6: Feller (1906-1970)

♠ **定理 11.3.3.** (Lindeberg-Feller 中心极限定理) 设 $\{X_{n,k} : 1 \leq k \leq k_n, n \geq 1\}$ 为一给定的独立随机变量阵列, 亦即对每个 $n \geq 1$, $X_{n,1}, \dots, X_{n,k_n}$ 是相互独立的. 假设对每个 $n \geq 1$ 及 $k =$

$1, \dots, k_n$, $\mathbb{E}X_{n,k} = 0, \mathbb{E}X_{n,k}^2 =: \sigma_{n,k}^2 < \infty$, 并且 $\sigma_n^2 := \sigma_{n,1}^2 + \dots + \sigma_{n,k_n}^2 > 0$. 那么下面两式

$$\lim_{n \rightarrow \infty} \frac{\max_{1 \leq k \leq k_n} \sigma_{n,k}^2}{\sigma_n^2} = 0, \quad (11.13)$$

$$\frac{1}{\sigma_n} \cdot \sum_{k=1}^{k_n} X_{n,k} \xrightarrow{d} N(0, 1) \quad (11.14)$$

成立的充分必要条件是下面的 *Lindeberg* 条件成立

$$\lim_{n \rightarrow \infty} \frac{1}{\sigma_n^2} \sum_{k=1}^{k_n} \mathbb{E} X_{n,k}^2 \cdot 1_{\{|X_{n,k}| \geq \varepsilon \sigma_n\}} = 0, \quad \forall \varepsilon > 0. \quad (11.15)$$

把上述定理应用于独立随机变量列, 就得到下面的中心极限定理。

♠ **定理 11.3.4.** 设 $\{X_n\}_{n=1}^\infty$ 为一给定的独立随机变量列。假设对每个 $n \geq 1$, $\mathbb{E}X_n = 0, 0 < \mathbb{E}X_n^2 =: \sigma_n^2 < \infty$, 并且 $B_n^2 := \sigma_1^2 + \cdots + \sigma_n^2 > 0$. 那么下面两式

$$\lim_{n \rightarrow \infty} \frac{\max_{1 \leq k \leq n} \sigma_k^2}{B_n^2} = 0, \quad (11.16)$$

$$\frac{1}{B_n} \cdot \sum_{k=1}^n X_k \xrightarrow{d} N(0, 1) \quad (11.17)$$

成立的充分必要条件是下面的 *Lindeberg* 条件成立

$$\lim_{n \rightarrow \infty} \frac{1}{B_n^2} \sum_{k=1}^n \mathbb{E} X_k^2 \cdot 1_{\{|X_k| \geq \varepsilon B_n\}} = 0, \quad \forall \varepsilon > 0. \quad (11.18)$$

在实际使用中, *Lindeberg* 条件验证起来不是那么容易。很多场合, 下面的 *Lyapunov* 中心极限定理更方便使用。

♠ **定理 11.3.5.** (*Lyapunov* 中心极限定理) 设 $\{X_n\}_{n=1}^\infty$ 为一给定的独立随机变量列。假设对每个 $n \geq 1$, $\mathbb{E}X_n = 0, 0 < \mathbb{E}X_n^2 =: \sigma_n^2 < \infty$, 并且 $B_n^2 := \sigma_1^2 + \cdots + \sigma_n^2 > 0$. 如果存在 $\delta > 0$ 使得

$$\lim_{n \rightarrow \infty} \frac{1}{B_n^{2+\delta}} \sum_{k=1}^n \mathbb{E}[|X_k|^{2+\delta}] = 0, \quad (11.19)$$

那么 $\frac{1}{B_n} \cdot \sum_{k=1}^n X_k \xrightarrow{d} N(0, 1)$.

上述定理中的条件(11.19)被称为 *Lyapunov* 条件。

📌 **注 11.5.** *Jarl Waldemar Lindeberg* (林德伯格; 1876—1932; 芬兰) 生于赫尔辛基、卒于赫尔辛基。他是赫尔辛基大学教授, 以中心极限定理方面的工作闻名于世。*Lindeberg* 是赫尔辛基综合理工学院的教师的儿子, 小时候就显露出数学上的天赋与兴趣。他早期的兴趣是偏微分方程和变分, 但 1920 年后兴趣转向了概率与统计。1920 年他发表了他在中心极限定理方面的第一篇论文, 其结果类似于 *Lyapunov* 的工作 (但那时他并不知情), 但所用方法是卷积的方法, 而不是 *Lyapunov* 使用的特征函数方法。两年后他用他的方法得到了更

强的结果—Lindeberg 条件下的中心极限定理。1935 年, Alan Turing (图灵, 1912—1954; 英国数学家、计算机科学家、逻辑学家、密码学家、哲学家、理论生物学家) 在不知道 Lindeberg 的工作的情况下, 在博士论文中也证明了这个中心极限定理。

William Feller (费勒, 1906—1970) 是美籍克罗地亚裔数学家, 他的父亲是波兰籍犹太人, 母亲是奥地利人; 他的博士论文导师是 Richard Courant (库朗; 1888—1972; 美籍德国数学家)。Feller 原本 1928 年在 Kiel 大学拥有临时职位, 到 1933 年他因为拒绝向纳粹宣誓效忠而逃亡到丹麦的哥本哈根。后来他到瑞典的斯德哥尔摩讲学。据 Feller 记载, 那时大学里面的法西斯主义持续扩散; 那时的瑞典数学家、斯德哥尔摩大学教授 Torsten Carleman (卡勒曼; 1892—1949; 以 Carleman 条件、Carleman 不等式、Denjoy-Carleman 定理、平均遍历定理、Carleman 核、Carleman 公式等闻名) 甚至表示, 犹太人和外国人应当被处死。1939 年 Feller 来到美国, 先后在 Brown 大学、Cornell 大学任职。1950 年他成为普林斯顿大学教授。

Feller 是 20 世纪最伟大的概率学家之一。根据瑞典统计学家 Harald Cramér (克萊默; 1893—1985) 的说法, 在 20 世纪中叶, 概率论研究在法国和俄罗斯、数理统计研究在英国和美国各自盛行。Gian-Carlo Rota (罗塔; 1932—1999; 美籍意大利数学家、哲学家) 评价 Feller 的两卷本概率论教材是“概率论方面最成功的专著”。Feller 也培养了很多学生, 如 Patrick Billingsley (比林斯利; 1925—2011; 美国数学家、演员, 美国艺术与科学院院士), George Forsythe (福赛思; 1917—1972; 斯坦福计算机系创立者、系主任, 曾任计算机协会理事长), Henry McKean (麦基恩; 1930—; 美国数学家, 美国科学院院士, 纽约大学教授), Lawrence Shepp (舍普; 1936—2013; 美国数学家, 专长是统计和计算射线成像技术), Hale Trotter (鹤特; 1931—; 美籍加拿大数学家, 以 Lie-Trotter 乘积公式、Steinhaus-Johnson-Trotter 算法、Lang-Trotter 猜测闻名), Benjamin Weiss (外斯; 1941—; 美籍以色列数学家, 在遍历论、拓扑动力系统、概率论、博弈论、描述集合论等方向有贡献), David A. Freedman (弗里德曼; 1938—2008; 著名数理统计学家, UC Berkeley 的统计学教授) 等。

特征函数方法在处理独立和的有关问题(特别是中心极限定理的问题)中非常有效; 但有关求和不是独立和时, 特征函数方法就受到很大限制。近几十年 C. Stein 及其合作者发展出了 Stein 方法用于系统处理非独立和的中心极限定理问题, 感兴趣的读者请参考文献.[12]

设 $\{X_n\}_{n=1}^{\infty} \stackrel{\text{i.i.d.}}{\sim} B(1, \frac{1}{2})$, $S_n = X_1 + \cdots + X_n$. 本小节的理论告诉我们, 中心极限定理

$$2\sqrt{n}\left(\frac{S_n}{n} - \frac{1}{2}\right) \xrightarrow{d} N(0, 1)$$

成立。此处我们附上可用现实实验来演示上述中心极限定理的一个实验装置—Galton (高尔顿) 钉板实验装置的示意图 11.7; 如图所示的钉板装置(正面是透明玻璃、背面是钉板的一个带入口的封闭容器)是英国生物统计学家 Galton 设计的, 其中容器内部背面木板上钉有多层铁钉, 每层相邻铁钉之间的



图 11.7: Galton 钉板实验

间距相同, 且上层每颗铁钉的水平位置恰好位于下层两颗相邻铁钉的正中间, 最顶层则是钉板装置的入口。从入口处放进大量相同材质与直径的玻璃圆球

(其直径略小于铁钉间距), 则在与铁钉的随机弹性碰撞下, 这些玻璃球最终垒积在钉板装置的底部而形成一定的轮廓; 如果钉板层数和玻璃球数目都比较多(相应地, 铁钉间距及玻璃球直径也比较小), 则这个轮廓曲线大致接近于正态分布的密度曲线形态。

11.3.3 应用 3: 随机变量的对称化方法简介

给定一个随机变量 X . 取另一个与 X 独立、同分布的随机变量 X' , 令 $X^s := X - X'$, 我们就称 X^s 是 X 的对称化¹. 设 X 的特征函数为 f , X^s 的特征函数为 f_s , 显然

$$f_s(t) = |f(t)|^2, \forall t \in \mathbb{R}.$$

此时由特征函数的连续性, 在 0 处的小邻域内我们就可以考虑 $\ln f_s$. 在有些问题中, 对随机变量施行对称化操作之后, 有关计算或论证就能带来一些简化。

例 11.4. 设 X, Y 独立同分布, 方差有限且非零. 假定 $X + Y, X - Y$ 也相互独立, 求证: X, Y 都服从正态分布。

证明概要: 在正态分布的推广概念—Gauss 分布(参见习题 11.31)的观点下, 前述条件“方差有限且非零”都是不必要的。

在假定 X, Y 非退化的条件下, 使用对称化方法, 不妨设 X^s, Y^s 是 X, Y 的对称化, 它们仍然同分布, 对应特征函数为 $f_s = |f|^2$, 其中 f 是 X 的特征函数. 此时可以记 $g_s = \ln f_s$. 由 $X + Y$ 与 $X - Y$ 相互独立, 可得

$$\mathbb{E}[\exp\{i u(X + Y) + i v(X - Y)\}] = \mathbb{E}[e^{i u(X+Y)}] \mathbb{E}[e^{i v(X-Y)}], \forall u, v \in \mathbb{R}.$$

利用 X, Y 相互独立、同分布、具有特征函数 f , 可以整理为下面的方程

$$f(u+v)f(u-v) = f(u)^2 |f(v)|^2, \forall u, v \in \mathbb{R}. \quad (11.20)$$

取 $f_s = |f|^2$, 转化为关于 $g_s = \ln f_s$ 的方程如下:

$$g_s(u+v) + g_s(u-v) = 2g_s(u) + 2g_s(v), \forall u, v \in \mathbb{R}, \quad (11.21)$$

并且 $g_s(0) = 0$. 由此, $g_s(2u) = 4g_s(u), \forall u \in \mathbb{R}$. 归纳法证明

$$g_s(ku) = k^2 g_s(u), \forall k \in \mathbb{N}$$

¹对与上述 X^s 同分布的随机变量 Y , 有时我们也称它为随机变量 X 的对称化。

如下: 假设已对 $1 \leq k \leq n$ 完成证明, 在(11.21)中取 $u = nt, v = t$, 利用归纳假设, 我们得到

$$\begin{aligned} g_s((n+1)t) &= 2g_s(nt) + 2g_s(t) - g_s((n-1)t) \\ &= [2n^2 + 2 - (n-1)^2]g_s(t) = (n+1)^2 g_s(t). \end{aligned}$$

于是欲证结论对自然数 $n+1$ 也成立. 注意到 g_s 还是偶函数, 自然就有

$$g_s(r) = r^2 \cdot g_s(1), \forall r = \frac{m}{n} \in \mathbb{Q}.$$

再注意到 g_s 是连续函数 (且非平凡), 存在 $c \in \mathbb{R}$,

$$g_s(x) = -cx^2, \quad f_s(x) = e^{-cx^2}, \quad \forall x \in \mathbb{R}.$$

这也说明了 $\mathbb{E}[|X^s|^2] = 2c < \infty$ 及 $c \geq 0$. 由于 X 非退化, 必定有 $c > 0$.

在上面结论基础上继续论证 f 必定是正态分布的特征函数如下. 由

$$\mathbb{E}[|X^s|^2] = 2c,$$

不难推断 X 的二阶矩有限. 现在不妨假设 $\mathbb{E}X = \mathbb{E}Y = 0$, 那么不难知道 $\mathbb{E}[X^2] = c$. 根据上面结论, 我们已知 X 的特征函数 f 满足

$$f_s(t) = |f(t)|^2 = e^{-ct^2}, \quad \forall t \in \mathbb{R},$$

并且(11.20)成立. 令 $h(x) := f(x) \cdot e^{cx^2/2}$, 立即得到 $h(0) = 1$ 及

$$h(u+v)h(u-v) = h(u)^2, \quad \forall u, v \in \mathbb{R},$$

进而

$$[h(\frac{x+y}{2})]^2 = h(x)h(y), \quad \forall x, y \in \mathbb{R}.$$

取 $y = 0$, 同样立即得到 $h(x) = [h(x/2)]^2, \forall x \in \mathbb{R}$. 由此同样有

$$h(x) = [h(x/2^n)]^{2^n} = [f(x/2^n)]^{2^n} \cdot \exp\{cx^2/2^{n+1}\}, \quad \forall n \in \mathbb{N}.$$

注意到在 0 附近邻域有

$$f(t) := \mathbb{E}[e^{itX}] = 1 - \frac{ct^2}{2} + o(t^2),$$

我们立即得到 $h(x) = 1, \forall x \in \mathbb{R}$, 从而 $f(t) = e^{-ct^2/2}$, 即 $X \sim N(0, c)$. $\square$

利用对称化方法, 我们还可以证明 Kolmogorov 强大数律的某种程度上如下版本的逆命题。

♠ **定理 11.3.6.** 设 $\{X_n\}_1^\infty$ 独立同分布, 如果 $\mathbb{E}|X_1| = \infty$, 那么对于任意数列 $\{b_n\}_1^\infty$, $\overline{\lim}_{n \rightarrow \infty} \frac{|S_n - b_n|}{n} = \infty$ 几乎处处成立。

证明: 令 $A_k := \{\frac{|X_k|}{k} \geq a\}$, 其中 $a > 0, k \geq 1$. 由于 $\mathbb{E}|X_1| = \infty$, 我们知道

$$\sum_{k=1}^{\infty} \mathbb{P}(A_k) = \infty,$$

进而由 B-C 第二引理, $\mathbb{P}(\frac{|X_n|}{n} \geq a \text{ i. o.}) = 1$ 对任意 $a > 0$ 成立。于是 $\{\frac{|X_n|}{n}\}_1^\infty$ 几乎处处无界。但 $\frac{S_n}{n} - \frac{n-1}{n} \cdot \frac{S_{n-1}}{n-1} = \frac{X_n}{n}$, 因此必有随机数列 $\{\frac{S_n}{n}\}_1^\infty$ 几乎处处为无界的。这相当于对于 $b_n = 0$ 的情况证明了定理结论。

对于一般情况, 记 X_n^s 为 X_n 的对称化, 于是 $\mathbb{E}|X_1^s| = \infty$, 进而 $\{\frac{S_n^s}{n}\}_1^\infty$ 几乎处处为无界的随机数列。但 S_n^s 可以由 $S_n - b_n$ 对称化得到, 因此随机数列 $\{\frac{S_n - b_n}{n}\}_1^\infty$ 有界的概率为 0。□

本书第六章的定理 6.4.2 的证明及习题 6.38 的解答也都是通过随机变量的对称化方法来实现的。这一方法值得读者仔细品味。

11.4 本章小结与学习建议

在本章第一节, 我们首先给出了随机变量/随机向量的特征函数的定义, 之后计算了正态分布、标准 Cauchy 分布对应的特征函数。在本章第二节, 我们重点介绍了特征函数的三大定理及其证明, 其中特征函数的唯一性定理和连续性定理是我们利用特征函数工具来探讨独立性和依分布收敛性的依据。在第三节, 我们介绍了 Khintchine 弱大数律和经典中心极限定理及其证明, 也介绍了 Lyapunov 中心极限定理和更一般的 Lindeberg-Feller 中心极限定理, 最后我们还通过两个案例介绍了随机变量的对称化方法。

概率论的初学者在本章的学习中, 特征函数的概念及一些常见分布的特征函数的计算是一个重点, 经典中心极限定理的论述与证明是另一个重点, 而特征函数的三大定理等略作了解即可, 证明等细节可以跳过; 但读者应了解为何我们可以借助特征函数工具来探讨随机变量(列)的相互独立性和依分布收敛性。

习 题 11

习题 11.1. 某报童以 10 美分从报社买进报纸, 并以 15 美分卖出; 然而对于当天没卖出的报纸, 报社规定允许退还的数量不超过购买量的一半。如果对于该报童来说, 报纸的日销售量 $X \sim B(1000, \frac{1}{3})$, 那么:

- (1) 他大约应该买进多少份报纸才能达到期望收益的最大化?
- (2) 以上述购买量报童有多大概率能完全卖光当天报纸?
- (3) 以上述购买量报童有多大概率能够最终没有报纸积压手中?

习题 11.2. 本题来自文献^[6]的 *Lemma 8.0.1*. 设 $(X_n - b_n)/a_n \xrightarrow{d} X$, 其中 $a_n > 0, b_n \in \mathbb{R}$. 则存在 $\alpha_n > 0, \beta_n \in \mathbb{R}$ 及随机变量 Y 使得

$$(X_n - \beta_n)/\alpha_n \xrightarrow{d} Y$$

的充要条件是: $a_n/\alpha_n \rightarrow a \in [0, \infty)$, $(b_n - \beta_n)/\alpha_n \rightarrow b \in \mathbb{R}$. (此时, 如果 $X \sim F$, 则 $Y \stackrel{d}{=} aX + b$. 当 $a > 0$ 时, 我们称 X, Y 是同一分布类型, 即认为

$$\mathcal{D}_F := \{F((\cdot - b)/a) : a > 0, b \in \mathbb{R}\}$$

是由 F 确定的一个分布族类型, b 称为分布族的位置参数, a 称为分布族的尺度参数, X, Y 的分布函数都落入此分布族。)

习题 11.3. 本习题讨论特征函数的连续性、可导性 (或可微性) 与对应随机变量的各阶矩之间的关系。设 X 是随机变量, $f(t) := \mathbb{E}[e^{itX}]$ 为其特征函数。试证明:

- (i) $f: \mathbb{R} \rightarrow \mathbb{C}$ 是一个有界、一致连续的复值函数;
- (ii) 当对某正整数 $n \geq 1, \mathbb{E}[|X|^n] < \infty$ 时, f 具有从一阶直到 n 阶的导函数, 且它们都是一致连续的, 并且具有表达式:

$$f^{(k)}(t) = \mathbb{E}[(iX)^k \cdot e^{itX}], \quad k = 1, \dots, n.$$

特别地, 我们有 $f^{(k)}(0) = i^k \cdot \mathbb{E}[X^k], k = 1, \dots, n$, 并且当 $|t| \rightarrow 0$ 时

$$f(t) = \sum_{k=0}^n \frac{f^{(k)}(0)}{k!} \cdot t^k + o(|t|^n).$$

- (iii) f 在 0 点具有 2 阶导数的充要条件是 $\mathbb{E}[X^2] < \infty$;
- (iv) f 在 0 点具有 $2n$ 阶导数的充要条件是 $\mathbb{E}[X^{2n}] < \infty$;

习题 11.4. 设 f, g 是特征函数。求证: $f \cdot g, pf + (1-p)g$ (其中 $p \in (0, 1)$)、 $\bar{f}$ 、 $\text{Re}(f)$ 、 $|f|^2$ 都是特征函数。本书中, $\text{Re}(z), \text{Im}(z)$ 分别表示复数 z 的实部与虚部。

习题 11.5. 设 $\rho(x, y) := \frac{1+cx y(x^2-y^2)}{4} \cdot 1_{(-1,1)}(x) \cdot 1_{(-1,1)}(y)$, 其中 $0 < |c| \leq 1$. 证明 $\rho \geq 0$ 且 $\int \rho(x, y) dx dy = 1$, 即 ρ 可以作为一个密度函数. 现在设 (X, Y) 的联合密度为 ρ , 证明 $X, Y \sim U(-1, 1)$, 进而证明

$$\mathbb{E}[e^{it(X+Y)}] = \mathbb{E}[e^{itX}] \cdot \mathbb{E}[e^{itY}], \forall t \in \mathbb{R},$$

但 X, Y 不相互独立.

习题 11.6. 设 ξ 的分布函数是 F , 求证:

$$\begin{aligned} \lim_{T \rightarrow \infty} \frac{1}{2T} \int_{-T}^T e^{-ia\lambda} \widehat{\mu}_F(\lambda) d\lambda &= \mathbb{P}(\xi = a), \\ \lim_{T \rightarrow \infty} \frac{1}{2T} \int_{-T}^T |\widehat{\mu}_F(\lambda)|^2 d\lambda &= \sum_{a \in \mathbb{R}} [\mathbb{P}(\xi = a)]^2. \end{aligned}$$

习题 11.7. 如果随机变量 ξ 的密度函数 ρ 是二次连续可微的紧支撑函数, 那么 $\int |\widehat{\rho}| d\text{Leb} < \infty$.

习题 11.8. 如果随机变量 ξ 具有密度函数 ρ , 那么 $\widehat{\rho}$ 在无穷远处趋于 0.

习题 11.9. 随机变量 ξ 服从格分布或格点分布, 如果存在 $a \neq 0, b \in \mathbb{R}$, 使得 $\mathbb{P}(\xi \in a\mathbb{Z} + b) = 1$. 请证明:

(1) ξ 服从格分布当且仅当其特征函数 f 满足: $\exists \lambda_0 \neq 0, s.t. |f(\lambda_0)| = 1$;

(2) 如果 ξ 服从格分布且非退化, 那么存在 $\lambda_0 \neq 0$, 使得

$$\{\lambda \in \mathbb{R} : |f(\lambda)| = 1\} = \lambda_0 \mathbb{Z}.$$

最后这个结论如果改成 $\exists \lambda_0 \neq 0, \{\lambda \in \mathbb{R} : |f(\lambda)| = 1\} \subset \lambda_0 \mathbb{Q}$, 证明是简单的. 本处结论的证明需要用到数论中有关最大公约数的知识.

习题 11.10. 设随机变量 ξ 非退化, 其特征函数为 f . 求证: $\{\lambda \in \mathbb{R} : |f(\lambda)| = 1\}$ 是 Lebesgue 零测集 (实际上是可数集).

习题 11.11. 求证: $f(\lambda) := |\cos \lambda|$ 不是特征函数 (但 $\cos \lambda$ 是特征函数).

习题 11.12. 求 $X \sim U(-1, 1)$ 的特征函数.

习题 11.13. 设 $\mathbb{P}(X = +1) = \mathbb{P}(X = -1) = 1/2$, 求 X 的特征函数.

习题 11.14. 本题来源于 Erdős 的工作, 是一个著名的 Erdős 问题 (随机幂级数问题). 设 $\mathbb{P}(X = +1) = \mathbb{P}(X = -1) = 1/2$, 且 $\{X_n\}_{n=0}^{\infty} \stackrel{\text{i.i.d.}}{\sim} X$. 令 $\lambda = \frac{\sqrt{5}-1}{2}$, 定义

$$Y_{\lambda} := \sum_{n=0}^{\infty} X_n \cdot \lambda^n,$$

求 Y_{λ} 的特征函数, 据此设法说明 Y_{λ} 不可能是连续型随机变量。

习题 11.15. 求 $X \sim \text{Poisson}(\lambda)$ 的特征函数。

习题 11.16. 设 $X_n \sim \text{Poisson}(\lambda_n)$, $\lambda_n \rightarrow \infty$. 证明: $\frac{X_n - \lambda_n}{\sqrt{\lambda_n}} \xrightarrow{d} N(0, 1)$.

习题 11.17. 求证: $\forall a > 0$, $f_a(\lambda) := (1 - \frac{|\lambda|}{a})^+$ 是一个特征函数。它对应的密度函数为 $\frac{1 - \cos(ax)}{\pi ax^2}$, 这个分布被称为参数 a 的 Pólya 分布。

习题 11.18. (Pólya) 设 $f: \mathbb{R} \rightarrow \mathbb{R}$ 是偶函数, $f(0) = 1$, 且在 $[0, \infty)$ 上它是非负连续递减的凸函数。求证: f 是特征函数。

习题 11.19. 利用上一题, 证明: $\forall \alpha \in (0, 1]$, $f(\lambda) := e^{-|\lambda|^{\alpha}}$ 是特征函数。

习题 11.20. 求证: $\forall \alpha \in (0, 2]$, $f(\lambda) := e^{-|\lambda|^{\alpha}}$ 是特征函数。

习题 11.21. 设有密度函数 ρ , 它的特征函数 $\hat{\rho}$ 非负可积, 那么 ρ 在 0 处连续且严格正, 并且 $\frac{\rho(t)}{\rho(0)}$ 也是一个特征函数¹。

习题 11.22. 对 f 是特征函数, 令 $I_f(x) := \int_0^x f(t)dt$. 求证:

$$\begin{aligned} |f(x+\delta) - f(x)|^2 &\leq 2[1 - \operatorname{Re}(f(\delta))], \\ \left| \frac{I_f(x+\delta) - I_f(x-\delta)}{2\delta} \right|^2 &\leq \frac{1 + \operatorname{Re}(f(\delta))}{2}. \end{aligned}$$

习题 11.23. 设 $\{f_n\}_{n=1}^{\infty}$ 为特征函数列, 满足 $f_n \rightarrow g_{\delta}$ 在区间 $(-\delta, \delta)$ 上收敛, 并且 g_{δ} 在 0 处连续。求证:

- (1) $\{f_n\}_{n=1}^{\infty}$ 等度连续, 并且 $f_n \rightarrow g_{\delta}$ 在区间 $(-\delta, \delta)$ 上的收敛是一致的;
- (2) 函数 g_{δ} 可以延拓为一个特征函数 g , 并且当延拓唯一时, 我们有 $f_n \rightarrow g$ 在 $\mathbb{R}$ 上成立。

习题 11.24.² 设 g_{δ} 是特征函数 g 在区间 $(-\delta, \delta)$ 上的限制, 其中 $\delta > 0$. 如果 g_{δ} 是解析函数或解析函数的边界函数, 那么 g_{δ} 唯一决定了 g .

¹这是一个有趣的现象。建议读者自行研究几组经典案例, 比如说: (1) 标准 Cauchy 分布与所谓的标准双侧指数分布, 后者的密度函数为 $\rho(x) := \frac{1}{2}e^{-|x|}$; (2) Pólya 分布 (见习题 11.17) 与所谓的三角形分布 (或帐篷分布), 后者的密度函数形态为: $\rho_a(x) = \frac{1}{a} \cdot (1 - \frac{|x|}{a})^+$ 。

²正态分布的特征函数就是一个满足本习题条件的典型例子。结合上一习题, 在使用特征函数方法论证中心极限定理时, 只需论证收敛在包含 0 的一个有界区间内成立即可。

习题 11.25. 设随机变量列 $\{\xi_n\}_{n=1}^\infty$ 的特征函数列 $\{f_n\}_{n=1}^\infty$ 满足: $f_n(t) \rightarrow 1$ 在区间 $[-\varepsilon, \varepsilon]$ 上成立, 其中 $\varepsilon > 0$ 为某正常数. 试证明: ξ_n 依概率收敛到 0.

习题 11.26. 本习题讨论特征函数与非负定性, 由此给出 *Böchner-Khintchine* 定理充分性部分的另一种证明. 此处只考虑一维情况, 高维类似. 以下设 $f: \mathbb{R} \rightarrow \mathbb{C}$ 是一个非负定函数, 那么

(i) $f(0) \geq 0$, $f(-t) = \bar{f}(t)$, 且 $|f(t)| \leq f(0)$;

(ii) 给定 $c > 0$. 存在支撑在 $[-\frac{\pi}{c}, \frac{\pi}{c}]$ 上的有限测度 μ , 使得它的特征函数 $\hat{\mu}(t) := \int e^{it} d\mu$ 满足: $\hat{\mu}\Big|_{c\mathbb{Z}} = f\Big|_{c\mathbb{Z}}$;

(iii) 基于上面结论立即知道: 如果 f 是在 0 处连续的非负定函数, 那么它是某个有限测度的特征函数. 特别地, 当 $f(0) = 1$ 时, 这也给出了 *Böchner-Khintchine* 定理的另一种证明.

习题 11.27. 设特征函数 f 在 0 处有展开: $f(x) = 1 + o(x^2)$, 求证: $f(x) = 1$.

习题 11.28.¹ 求证: 对于 $\alpha > 2$, $f(\lambda) := e^{-|\lambda|^\alpha}$ 不是特征函数.

习题 11.29. 给出定理 11.2.6 必要性部分的证明.

习题 11.30. 在统计学中有一个著名的 *Cramer-Wold Device*. 它可以有两层含义, 陈述如下:

(1) 设 X, Y 是随机变量. 假设对任意 $\alpha, \beta \in \mathbb{R}$, 有已知的分布函数 $F_{\alpha, \beta}$, 满足 $\alpha X + \beta Y \sim F_{\alpha, \beta}$, 那么 (X, Y) 的联合分布 F 是由分布函数族 $\{F_{\alpha, \beta} : \alpha, \beta \in \mathbb{R}\}$ 唯一确定的;

(2) 设 X_n, Y_n 是随机变量序列. 假设对任意 $\alpha, \beta \in \mathbb{R}$, 有已知的分布函数 $F_{\alpha, \beta}$, 满足 $\alpha X_n + \beta Y_n \xrightarrow{d} F_{\alpha, \beta}$, 那么 (X_n, Y_n) 是依分布收敛到由 (1) 中确定的分布 F .

你能说出 *Cramer-Wold Device* 成立的原因吗?

习题 11.31. 本习题的主要目的是讨论正态分布的推广—*Gauss* 分布, 进而定义所谓的 *Gauss* 系随机变量族. 称一个随机向量 X 服从均值为 μ 、协方差矩阵为 Σ 的 *Gauss* 分布, 如果它的特征函数为

$$\mathbb{E}[\exp\{i \langle t, X \rangle\}] = \exp\{i \langle t, \mu \rangle - \frac{1}{2} \langle t, \Sigma t \rangle\},$$

¹ 本题结论本质上源于 J. Marcinkiewicz (马辛凯维茨) 的工作, 他证明了: 如果 $P(t)$ 是多项式, 且 $e^{P(t)}$ 是特征函数, 那么 P 至多是二次多项式.

其中 t, μ 是列向量, $\langle t, \mu \rangle$ 表示它们之间的欧氏内积. 此时我们在记号上仍然记作 $X \sim N(\mu, \Sigma)$, 只不过此处 Σ 是实对称非负定矩阵, 容许 $\det(\Sigma) = 0$. 请证明:

- (1) 设 $\Sigma_\varepsilon := \Sigma + \varepsilon I$, 其中 $\varepsilon > 0$, 则 Σ_ε 正定, 从而存在 $X_\varepsilon \sim N(\mu, \Sigma_\varepsilon)$ (此处为通常的正态分布). 借此证明, $f(t) := \exp\{i\langle t, \mu \rangle - \frac{1}{2}\langle t, \Sigma t \rangle\}$ 确实是特征函数, 并且当 $\varepsilon \downarrow 0$ 时 $X_\varepsilon \xrightarrow{d} X$;
- (2) 如果 $\det(\Sigma) = 0$, 那么存在 $v \neq 0$ 使得 $\mathbb{P}(\langle X - \mu, v \rangle = 0) = 1$;
- (3) 一维 Gauss 分布族具有封闭性: 设 $Y_n \sim N(\mu_n, \sigma_n^2)$ 满足 $Y_n \xrightarrow{d} Y$, 则存在 $\mu \in \mathbb{R}, \sigma^2 \in \mathbb{R}_+$ 使得 $Y \sim N(\mu, \sigma^2)$;
- (4) 上述结论的高维版本对于高维的 Gauss 分布也成立;
- (5) 给定一维随机变量族 $\{Y_\alpha : \alpha \in I\}$. 称它为 (实) Gauss 系, 如果其中对任意有限多个元素 $Y_{\alpha_1}, Y_{\alpha_2}, \dots, Y_{\alpha_n}$, 它们的联合分布总是 Gauss 分布; 基于上一习题介绍的 Cramer-Wold Device, 这也等价于说该随机变量族群中任何有限多个元素的 (实系数) 线性组合总是服从一维 Gauss 分布. 考虑 $\mathcal{H}$ 是线性空间 $\text{span}\{Y_\alpha : \alpha \in I\}$ 在数学期望诱导的内积下的闭空间. 如果 $\{Y_\alpha : \alpha \in I\}$ 是 Gauss 系, 则 $\mathcal{H}$ 仍然是 Gauss 系.

习题 11.32. 给定 $\{X_n\}_1^\infty \stackrel{\text{i.i.d.}}{\sim} \text{Cauchy}(0, 1)$. 假定 $b_n \nearrow \infty$. 定义 $X_{n,k} := X_k \cdot 1_{\{|X_k| \leq n/b_n\}}$ 以及 $S'_n = \sum_{k=1}^n X_{n,k}$. 求证: $Z_n := \sqrt{\frac{\pi b_n}{2}} \cdot \frac{S'_n}{n} \xrightarrow{d} N(0, 1)$.

习题 11.33. 本习题的目的是想说明, 如果把独立同分布条件修改为两两独立、同分布条件, 则经典的中心极限定理中结论不再成立. 设 $\{\xi_n\}_{n=0}^\infty$ 是 i.i.d. 的随机变量列, 满足 $\mathbb{P}(\xi_0 = 1) = \mathbb{P}(\xi_0 = -1) = \frac{1}{2}$. 令 $X_1 := \xi_0, X_2 := \xi_0 \cdot \xi_1$; 对 $m = 2^{n-1} + j, 1 \leq j \leq 2^{n-1}$, 递归的定义 $X_m := \xi_n X_j$. 求证:

- (1) $\{X_n\}_{n=1}^\infty$ 两两独立且同分布, $\mathbb{E}X_1 = 0, \mathbb{V}\text{ar}(X_1) = 1$;
- (2) $S_{2^n} = \xi_0(1 + \xi_1) \cdots (1 + \xi_n)$, 且它的分布律是

$$\mathbb{P}(S_{2^n} = 0) = 1 - \frac{1}{2^n}, \quad \mathbb{P}(S_{2^n} = \pm 2^n) = \frac{1}{2^{n+1}},$$

从而 $\sqrt{n}\bar{X}_n$ 不可能依分布收敛到正态分布。

习题 11.34. 设 $X \sim F$ 具有二阶矩, $\mathbb{E}X = 0, \sigma^2 := \mathbb{V}\text{ar}(X) > 0$. 求证: 存在随机变量 $X_* \sim F^*$ 使得对任意绝对连续、导数有界的函数 f , 下式成立

$$\mathbb{E}[Xf(X)] = \sigma^2 \mathbb{E}[f'(X_*)].$$

特别地, 当 $X \sim N(0, \sigma^2)$ 时, $X_* \sim N(0, \sigma^2)$. 这样定义的分布之间的变换 $F \mapsto F^*$ 被称为 *zero-biased transformation*, 并且中心化的正态分布是这个变换的不动点¹.

习题 11.35. 证明正态分布 $N(\mu, \sigma^2)$ 的各阶矩唯一确定其分布。

习题 11.36. 证明 *Poisson* 分布的各阶矩唯一确定其分布。

习题 11.37. 证明指数分布的各阶矩唯一确定其分布。

习题 11.38. 证明对数标准正态分布的各阶矩不能唯一确定其分布。

习题 11.39. 记 $Q_X(\lambda) := \sup_x \mathbb{P}(x \leq X \leq x + \lambda) = \sup_x \mathbb{P}(|X - x| \leq \lambda/2)$, 其中 $\lambda \geq 0$. 在文献 [79, Chapter III] 中 Q_X 被称为随机变量 X 的集中度函数 (*concentration function*); 显然它关于 λ 是单调不减的函数. 试证明:

(1) 对独立随机变量 X, Y , $Q_{X+Y}(\lambda) \leq \min\{Q_X(\lambda), Q_Y(\lambda)\}$;

(2) $Q_X(n\lambda) \leq nQ_X(\lambda)$, $n \geq 1$ 为自然数;

(3) 设 f_X 为 X 的特征函数, 那么对任意 $a, \lambda \geq 0$

$$Q_X(\lambda) \leq \frac{1}{aK(\frac{a\lambda}{4})^2} \int_{-a}^a |f_X(t)| dt,$$

其中函数 K 为 $K(\lambda) := \min\{|\frac{\sin x}{x}| : |x| \leq \lambda\}$. 特别地,

$$Q_X(\lambda) \leq (\frac{96}{95})^2 \max(\lambda, \frac{1}{a}) \int_{-a}^a |f_X(t)| dt.$$

(4) 对任意 $a, \lambda \geq 0$ 满足 $a\lambda \leq \frac{\pi}{4}$, 有 $Q_X(\lambda) \geq \frac{3}{8\pi} \cdot K(\frac{a\lambda}{2}) \int_{-a}^a |f_X(t)|^2 dt$. 特

别地, 对任意 $a, \lambda \geq 0$ $Q_X(\lambda) \geq \frac{95\lambda}{256\pi(1+2a\lambda)} \cdot \int_{-a}^a |f_X(t)|^2 dt$.

习题 11.40. 本习题的目的是引导读者温习 *De Moivre* 和 *Laplace* 关于 *Bernoulli* 分布对应的中心极限定理的有关讨论; 这里提供了主要思想框架, 细节就是作为习题留给读者补充的. 以下 $\{X_n\}_1^\infty$ 是 *i.i.d.* 的 $B(1, p)$ 分布随机变量列, 则 $S_n := X_1 + \cdots + X_n \sim B(n, p)$. 此处总假定 $p \in (0, 1)$, $q := 1 - p$, 定义 $P_n(k) := \binom{n}{k} p^k q^{n-k}$. 我们首先论证所谓的“局部极限定理”: 对满足 $|k - np| = o((npq)^{2/3})$ 的所有 k , 一致地成立

$$P_n(k) \sim \frac{1}{\sqrt{2\pi npq}} e^{-\frac{(k-np)^2}{2npq}} =: \bar{P}_n(k),$$

^[12]进一步证明了这个变换在不动点处具有连续性, 这是论证正态逼近的新方法—Stein 方法的理论基础。

其含义是：当 $n \rightarrow \infty$ 时（此处一定程度上容许 $p = p_n, q = q_n$ 与 n 有关），对任意满足 $\varphi(n)/(npq)^{2/3} \rightarrow 0$ 的非负函数 φ 成立下式

$$\sup\{| \frac{P_n(k)}{\bar{P}_n(k)} - 1| : |k - np| \leq \varphi(n)\} \rightarrow 0.$$

这可以按照以下步骤来实现论证：

(a) 记 $\hat{p} := k/n$ ，则根据 *Stirling* 公式，当 $n \rightarrow \infty, k \rightarrow \infty, n - k \rightarrow \infty$ 时，

$$\varepsilon_n := \varepsilon_n(k) = \binom{n}{k} \cdot \sqrt{2\pi n \hat{p}(1-\hat{p})} \hat{p}^k (1-\hat{p})^{n-k} - 1 \rightarrow 0;$$

(b) $P_n(k) = \frac{1+\varepsilon_n}{\sqrt{2\pi n \hat{p}(1-\hat{p})}} e^{-nH_p(\hat{p})}$ ，其中 $H_p(x) := x \ln \frac{x}{p} + (1-x) \ln \frac{1-x}{q}$ ；

(c) 当 n 充分大时， $H_p(\hat{p}) = \frac{1}{2pq}(\hat{p}-p)^2 + O(|\hat{p}-p|^3)$ ；

(d) $P_n(k) = \bar{P}_n(k) \cdot [1 + \bar{\varepsilon}_n]$ ，其中

$$1 + \bar{\varepsilon}_n(k) = [1 + \varepsilon_n(k)] e^{nO(|\hat{p}-p|^3)} \sqrt{\frac{pq}{\hat{p}(1-\hat{p})}};$$

(e) 对于前述 φ ， $\sup\{\bar{\varepsilon}_n(k) : |k - np| \leq \varphi(n)\} \rightarrow 0$.

上述“局部极限定理”结果也可以简单的表述为

$$\mathbb{P}\left(\frac{S_n - np}{\sqrt{npq}} = x\right) \sim \frac{1}{\sqrt{2\pi npq}} e^{-\frac{x^2}{2}}, \quad x = o((npq)^{1/6}).$$

当然上面的实数 x 要求能使得 $np + x\sqrt{npq}$ 成为非负整数。

基于“局部极限定理”就可以进一步论证中心极限定理；此时 $p \in (0, 1)$ 为常数。论证方法如下：记 $t_k := t_k^{(n)} = \frac{k-np}{\sqrt{npq}}$ ， $\Delta t_k := t_{k+1} - t_k = \frac{1}{\sqrt{npq}}$ 。那么“局部极限定理”结果也可以表述为

$$\mathbb{P}\left(\frac{S_n - np}{\sqrt{npq}} = t_k\right) \sim \frac{\Delta t_k}{\sqrt{2\pi}} e^{-\frac{t_k^2}{2}}, \quad t_k = o((npq)^{1/6}).$$

确切的说，

$$P_n(np + t_k \sqrt{npq}) = \frac{\Delta t_k}{\sqrt{2\pi}} e^{-\frac{t_k^2}{2}} \cdot [1 + \bar{\varepsilon}_n(k) \cdot t_k],$$

其中对任意 $T > 0$ ， $\sup\{|\bar{\varepsilon}_n(k) \cdot t_k| : |t_k| \leq T\} \rightarrow 0$ 。记

$$P_n(a, b] := \sum_{t_k \in (a, b]} P_n(np + t_k \sqrt{npq}), \quad \Phi(x) := \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-u^2/2} du.$$

在上述结果基础上，进一步论证： $n \rightarrow \infty$ 时

$$(f) \sup\{|P_n(a, b) - [\Phi(b) - \Phi(a)]| : -T \leq a \leq b \leq T\} \rightarrow 0;$$

(g) 上式对 $T = \infty$ 也成立。

由此就证明了所谓的“*De Moivre-Laplace* 积分定理”(即中心极限定理):

$$\sup\{|P_n(a, b) - \frac{1}{\sqrt{2\pi}} \int_a^b e^{-u^2/2} du| : -\infty \leq a \leq b \leq \infty\} \rightarrow 0.$$

原则上做得更精细一点, 应能估计出如下逼近的速度(这是 *Bernoulli* 分布情形的所谓 *Berry-Esseen* 估计)

$$\sup_x |P_n(-\infty, x] - \Phi(x)| \leq \frac{p^2 + q^2}{\sqrt{npq}}.$$

为了得到 *Bernoulli* 的弱大数律, 只需注意到, 在上述结果的基础上,

$$\mathbb{P}(|\frac{S_n}{n} - p| \leq \varepsilon) = \mathbb{P}(|\frac{S_n - np}{\sqrt{npq}}| \leq \varepsilon \sqrt{\frac{n}{pq}}) \approx 2\Phi(\varepsilon \sqrt{\frac{n}{pq}}) - 1 \rightarrow 1.$$

第十二章 概率建模的有关讨论与检验

在对未知的随机世界的探索中，我们进行概率建模的目的是基于已有历史数据通过理论模型来总结经验并希望这些经验仍然适用于将来的（同样类型的）随机试验，从而可以使用“准确”的理论模型来指导我们对世界的认识与改造等实践活动。因此我们的概率模型是否“适用”于有关随机试验、是否“准确”，非常值得去探索。在实践中我们有必要对有关概率建模进行理论探究和数据检验。前者通常需要考虑“经验的总结”是否符合直观、“经验的外推”（比如“预测”）是否有道理，这是偏理论，甚至哲学层面的考察模型的适用性问题。对于后面提及的数据检验，在实践层面就是通过收集大量来自随机试验的数据进行“假设检验”，这意味着我们将进入现代意义上的《统计学》的有关领域。

事实上，本书的若干章节已经涉及了《统计学》的部分内容，提及了《统计学》中的若干理论思想与方法（如小概率事件原理、极大似然原理等思想，极大似然估计、矩估计、Bayes 方法等方法）。例如，第五章的 §5.3.2 介绍了两个离散分布的参数的极大似然估计；第八章的例8.17、例8.18探讨了基于单个正态分布总体的样本如何给出均值参数、方差参数的极大似然估计，并探寻出这些估计的精确分布律（这同样可以用来检验我们的模型假设），例8.19基于两个不同的正态分布总体的样本数据，探讨了如何构建有关方差参数的统计量并得到它的精确分布律用于检验这两个正态分布总体是否具有相同的方差；例8.22和例8.23则探讨了如何基于均值参数的先验分布进行简单样本的均值的 Bayes 极大似然估计。这些参数估计和假设检验的问题都是现代《统计学》中的典型问题；由于课程安排的原因，我们在本书中对此只做了简单介绍，没有展开详细讨论。

本章分为两个部分。第一部分中¹，我们首先基于两个互相关联的简单模

¹此部分的讨论受到钱纮教授的影响；部分重要文献信息如^[96,97]等也是从他那获知的。

型来讨论“经验的总结与外推”的问题。更确切地说，我们准备通过简单的模型重点讨论赌徒佯谬与热手效应两种现象的存在性问题；之后我们借助一个简单的模型说明：有了基于大样本数据的“热力学测量”（即“平均总能量”给定）后，在“经验的总结”角度，我们很自然地需要对最初模型设定的分布律进行合理的调整，最终调整到的极限分布律恰好是热力学中的 Gibbs 态，见定理 12.1.1. 在第二部分中，我们将主要基于前面两章给出的极限定理发展有关理论，构建对有关模型假设的分布律和独立性这两方面的大样本的检验理论。

12.1 概率论视角下的“经验总结与外推”

12.1.1 关于赌徒佯谬与热手效应的讨论

本小节我们通过投掷硬币的两种不同模型来探讨赌徒佯谬和热手效应现象在相应模型中是否存在。

第一个模型是把每次投掷硬币得到的结果视作 i.i.d. 的 Bernoulli 序列。

例 12.1. 考虑反复投掷一枚有可能不均匀的硬币得到的正反面序列，为方便表示为 1 与 0 的序列，即假设 $\{X_k\}_{k=1}^{n+m} \stackrel{\text{i.i.d.}}{\sim} B(1, p)$ ，其中 $p \in (0, 1)$ 未知。现在已知 $S_n := X_1 + X_2 + \cdots + X_n$ 的取值。计算以下诸概率：

- (1) $\mathbb{P}(X_i = 1 | S_n = k), 1 \leq i \leq n, 0 \leq k \leq n;$
- (2) $\mathbb{P}(X_{i_1} = 1, \cdots, X_{i_r} = 1 | S_n = k), 2 \leq r \leq k \leq n, 1 \leq i_1 < \cdots < i_r \leq n;$
- (3) $\mathbb{P}(X_{n+1} = 1 | S_n = k).$

参考解答：我们只给出 (1)、(3) 的计算；(2) 的计算留给读者。

(1) 的计算方法有多种方式。其中一种方法是用 Pólya 无放回取球模型来解释（取出的球放入一个新的袋子中）：当 $X_i = 1$ 时我们就认为第 i 次放入新袋子中的球是黑球，否则认为放入新袋子中的球是红球。因此， $\mathbb{P}(X_i = 1 | S_n = k)$ 可解释为最后新袋子中总共 k 个黑球、 $n - k$ 的白球的袋子，那么第 i 次放入新袋子中的球（采用“录像倒带”的视角就是从新袋子中取球的操作）是黑球的概率就是 $\frac{k}{n}$ 。直接进行计算也很简单：

$$\begin{aligned} \mathbb{P}(X_i = 1 | S_n = k) &= \frac{\mathbb{P}(X_i = 1, S_n = k)}{\mathbb{P}(S_n = k)} \\ &= \frac{\mathbb{P}(X_i = 1, S_n - X_i = k - 1)}{\mathbb{P}(S_n = k)} \end{aligned}$$

$$= \frac{\binom{n-1}{k-1} p^k (1-p)^{n-k}}{\binom{n}{k} p^k (1-p)^{n-k}} = \frac{k}{n}.$$

(3) 的结果是显然的: 由模型假设, X_{n+1} 与 S_n 独立, 因此

$$\mathbb{P}(X_{n+1} = 1 | S_n = k) = \mathbb{P}(X_{n+1} = 1) = p.$$

由上述解答, 第一章习题中的赌徒佯谬现象在本模型下是错误的行为模式, 而热手效应也是不存在的。

如果把本例中 (1)、(2) 中的结果视作“经验的总结”, 把 (3) 中结果视作结论 (1) 的“类比”与“外推”, 那么此处的这个“外推”在模型假设下就是“无效”的。□

在上例的模型假定下, 在大样本情形也有类似 (1)、(2) 的结论, 请读者参见习题 12.4.

第二个模型是把上一个模型中的参数 p 视作随机变量, 具有特定的先验分布。这可以视作掷硬币实验的 Bayes 模型。

例 12.2. 类似上例中模型。只不过我们说现在已知有 $n+m$ 枚材质相同的均匀硬币, 但这个抛掷硬币的随机试验是“风洞实验”, 其中简单起见, 假定 ξ 是一个与“风洞”环境有关、与硬币无关的随机变量, 它使得抛掷单枚硬币后获得正面 (对应记录为 1, 否则记录为 0) 的实际概率值就是 $\xi \sim U(0, 1)$, 而 $\{X_k\}_{k=1}^{n+m}$ 就是在“风洞”中同时抛掷这 $n+m$ 枚硬币所获得的实验记录。即数学上认为:

$$\{X_k\}_{k=1}^{n+m} \Big| \xi = p \stackrel{\text{i.i.d.}}{\sim} B(1, p), \quad \xi \sim U(0, 1).$$

现在同样已知 $S_n := X_1 + \cdots + X_n = k$. 类似考虑例 12.1 问题, 计算以下概率:

- (1) $\mathbb{P}(X_i = 1 | S_n = k)$, 其中 $1 \leq i \leq n, 0 \leq k \leq n$;
- (2) $\mathbb{P}(X_{i_1} = 1, \cdots, X_{i_r} = 1 | S_n = k)$, 其中 $2 \leq r \leq k \leq n, 1 \leq i_1 < \cdots < i_r \leq n$;
- (3) $\mathbb{P}(X_{n+1} = 1 | S_n = k)$;
- (4) $\mathbb{P}(S_{n+m} = \ell + k | S_n = k)$.

参考解答: 同样我们仅给出 (1)、(3) 的计算, 而把 (2)、(4) 留给读者。

对于 (1) 的计算, 上例中提供的两种计算模式仍然有效。这里我们提供第三种计算方法。注意到模型假设蕴含如下事实: 对任意 $1 \leq j < n$,

$$(X_1, \cdots, X_j, \cdots, X_n, \xi) \stackrel{d}{=} (X_1, \cdots, X_n, \cdots, X_j, \xi).$$

上式两边省略号代表的元素保持不变, 仅 X_j 与 X_n 的位置做了对调。由此立即得到 $(X_n, S_n) \stackrel{d}{=} (X_j, S_n)$, 进而 $\mathbb{P}(X_n = 1 | S_n = k) = \mathbb{P}(X_j = 1 | S_n = k)$, $j = 1, \dots, n-1$. 于是, 注意到 $X_j = 1_{\{X_j=1\}}$,

$$\begin{aligned}\mathbb{P}(X_i = 1 | S_n = k) &= \frac{1}{n} \sum_{j=1}^n \mathbb{P}(X_j = 1 | S_n = k) \\ &= \frac{1}{n} \sum_{j=1}^n \mathbb{E}[1_{\{X_j=1\}} | S_n = k] \\ &= \frac{1}{n} \sum_{j=1}^n \mathbb{E}[X_j | S_n = k] \\ &= \frac{1}{n} \mathbb{E}[S_n | S_n = k] = \frac{k}{n}.\end{aligned}$$

现在直接计算 (3). 注意到

$$\begin{aligned}\mathbb{EP}(S_n = k | \xi) &= \int_0^1 \binom{n}{k} p^k \cdot (1-p)^{n-k} dp \\ &= \binom{n}{k} \cdot B(k+1, n-k+1), \\ \mathbb{EP}(X_{n+1} = 1, S_n = k | \xi) &= \int_0^1 \binom{n}{k} p^{k+1} \cdot (1-p)^{n-k} dp \\ &= \binom{n}{k} \cdot B(k+2, n-k+1),\end{aligned}$$

我们得到¹

$$\begin{aligned}\mathbb{P}(X_{n+1} = 1 | S_n = k) &= \frac{\mathbb{P}(X_{n+1} = 1, S_n = k)}{\mathbb{P}(S_n = k)} \\ &= \frac{\mathbb{EP}(X_{n+1} = 1, S_n = k | \xi)}{\mathbb{EP}(S_n = k | \xi)} \\ &= \frac{B(k+2, n-k+1)}{B(k+1, n-k+1)} = \frac{k+1}{n+2}.\end{aligned}$$

从上述计算结果立即知道, 赌徒佯谬现象在本模型下仍然是错误的行为模式, 但热手效应是存在的。

如果把本例中 (1)、(2) 中的结果视作“经验的总结”, 把 (3) 中结果视作 (1) 中结论的“类比”与“外推”, 那么此处的这个“外推”在模型假设下就是“有效”的。□

¹假设前 n 次 Bernoulli 试验中都获得了相同的试验结果, 则下一次试验仍然获得该试验结果的概率是 $\mathbb{P}(X_{n+1} = 1 | S_n = n) = \frac{n+1}{n+2}$, 这是 Laplace 在 1774 年得到的结果 (Mém. Acad. R. Sci. Paris (Savants Étrangers) 6, 621–656. OC 8, 27–65.), Venn 在他的书^[98]中称之为 Laplace 的继承法则 (Laplace's Rule of Succession)。

在上例的模型假定下，在大样本情形有类似结论，参见习题12.5。

在概率论框架下，如何理解和认识人类认知中“经验的总结与外推”，是一个值得探讨的课题。对此，在下一小节中，我们借助物理学中的 Gibbs 熵¹、自由能等概念结合概率论来对稍微广泛一点的离散模型进行一些讨论。

12.1.2 Gibbs 分布与 Gibbs 条件概率

现在设想一个给定的热力学系统 (假定总物质的量是 1 单位摩尔) 微观上有 N 个 (量子) 态 $1, 2, \dots, N$ ，相应的概率分布列为 $p = \{p_i\}_{i=1}^N$ ，这些 (量子) 态对应的能级序列为 $\{E_i\}_{i=1}^N$ ；当不发生“能级简并” (即 $\{E_i\}_{i=1}^N$ 两两不等) 时，系统的能量服从的分布律为 $\begin{pmatrix} E_1 & E_2 & \dots & E_N \\ p_1 & p_2 & \dots & p_N \end{pmatrix}$ 。物理学中，此系统的 (平均) 总能量为

$$\langle E \rangle = \langle E \rangle_p = \langle p, E \rangle := \sum_{i=1}^N p_i E_i. \quad (12.1)$$

数学上，概率分布列 p 的 **Shannon 熵**² 定义为

$$H(p) := - \sum_{i=1}^N p_i \ln p_i, \quad (12.2)$$

这个系统的 **Gibbs 熵** 定义为

$$S(p) := k_B \cdot H(p) = -k_B \cdot \sum_{i=1}^N p_i \ln p_i, \quad (12.3)$$

其中 k_B 是 **Boltzman 常数**³。而这个系统的 **Helmholtz 自由能**⁴ 定义为

$$F(p) := \langle p, E \rangle - T \cdot S(p), \quad (12.4)$$

其中 T 是系统的温度。此时不难知道，(在给定温度下) 系统的自由能 F 的极小值点为 **Gibbs 分布** (也称 **Gibbs 态**) $q = \{q_i\}_{i=1}^N$ ，其中

$$q_i = \frac{e^{-\beta E_i}}{Z}, \quad \beta = \frac{1}{k_B T}, \quad Z = Z(\beta) = \sum_{j=1}^N e^{-\beta E_j}, \quad (12.5)$$

¹Josiah Willard Gibbs (吉布斯, 1839—1903) 是美国物理化学家、数学物理学家。他奠定了化学热力学的基础，提出了吉布斯自由能与吉布斯相律，创立了向量分析并将其引入数学物理之中。

²Claude Elwood Shannon (香农, 1916—2001) 是美国数学家、发明家、密码学家，信息论创始人。他是美国国家工程院院士、美国国家科学院院士、美国艺术与科学院院士，生前是麻省理工学院名誉教授。Shannon 提出了信息熵的概念，为信息论和数字通信奠定了基础。

³Ludwig Eduard Boltzmann (玻尔兹曼, 1844—1906) 是奥地利物理学家、哲学家，奥地利帝国科学院院士，瑞典皇家科学院院士，英国皇家学会外籍院士，生前是维也纳大学教授。他主要从事热力学、统计物理学方面的研究。

⁴H. L. P. von Helmholtz (赫尔姆霍兹, 1821—1894) 是德国著名的物理学家和生理学家。他曾从师于当时著名的生理学家缪勒，在心理学的多个方面都做出很大的贡献。他的主要著作有《生理光学纲要》等。

此处 $Z = Z(\beta)$ 是归一化常数, 又称为**配分函数**; β 又称为“**倒温度**” (inverse temperature)¹, 对应的最小自由能为 $F(q) = -k_B T \cdot \ln Z$. 物理学中这个结果被称为**最小自由能原理**, 数学上它可以由**相对熵** (又称为 Kullback-Leibler Divergence, K-L 散度)

$$H(p|q) = D_{K,L}(p||q) := \sum_{i=1}^N p_i \ln \frac{p_i}{q_i} \quad (12.6)$$

的非负性保证: $H(p|q) \geq 0$ 总成立, 其中等号成立的充要条件是 $p = q$. 这里只需要注意到如下事实: 对于上述 Gibbs 分布 q , 我们有

$$F(p) = k_B T \cdot [H(p|q) - \ln Z]. \quad (12.7)$$

进一步, 给定参考概率分布列 p (及系统的温度 T), 定义任一概率分布列 ν 相对于参考分布列 p 的**Gibbs 焓**为

$$H_p = H_p(\nu) := \langle \nu, E. \rangle - k_B T \sum_{i=1}^N \nu_i \ln p_i, \quad (12.8)$$

定义**Gibbs 自由能**为

$$G_p = G_p(\nu) := H_p(\nu) - T \cdot S(\nu). \quad (12.9)$$

如果定义概率分布列 $q^* = \{q_i^*\}_{i=1}^N$ 如下

$$q_i^* = \frac{p_i}{Z_*} \cdot e^{-\beta E_i}, \quad i = 1, 2, \dots, N, \quad (12.10)$$

其中 $Z_* = Z_*(\beta)$ 是归一化常数 (亦称为此情形下的**配分函数**), 那么容易知道

$$G_p(\nu) = k_B T \cdot [H(\nu|q^*) - \ln Z_*], \quad (12.11)$$

从而 Gibbs 自由能在 $\nu = q^*$ (仍称之为 Gibbs 分布/Gibbs 态) 处取到最小值 (对应的最小 Gibbs 自由能为 $G_p(q^*) = -k_B T \cdot \ln Z_*$), 这在物理学中被称为**最小 Gibbs 自由能原理**. 此时, 我们有下面的重要事实

$$H(\nu|q^*) = H(\nu|p) + \beta \langle \nu, E. \rangle + \ln Z_*(\beta). \quad (12.12)$$

它表明, 给定参考概率分布列 p , 在约束 $\langle \nu, E. \rangle = E$ 下, 如果 q^* 也满足上述约束 (由此确定系统的倒温度 β), 则 $H(\nu|p)$ 在上述约束下的最小值点就

¹较多文献翻译 inverse temperature 为“逆温度”, 个人认为按照实际公式表现翻译为“倒温度” (或更直接的“倒数温度”) 更妥当, 以暗含温度倒数之意。

是 q^* ; 这可以通过 Lagrange¹ 乘子法来实现论证, 而倒温度参数 β 恰好是约束 $\langle \nu, E \rangle = E$ 的乘子², 请读者自行完成这个分析学中的小习题。习题12.6的(4)是此处小习题的更一般版本。

定义

$$\underline{E} := \min_{1 \leq i \leq N} E_i, \quad \overline{E} := \max_{1 \leq i \leq N} E_i, \quad (12.13)$$

并总假设 $\underline{E} < \overline{E}$. 通过简单的计算, 我们进一步得到下面的数学结果。

◆ 引理 12.1.1. 给定能级列 $\{E_i\}_{i=1}^N$ 及概率分布列 $\{p_i > 0\}_{i=1}^N$. 定义

$$q_i^* = q_i^*(\beta) := \frac{e^{-\beta E_i}}{Z_*(\beta)} \cdot p_i, i = 1, \dots, N,$$

其中 $Z_* = Z_*(\beta) := \sum_{i=1}^N p_i e^{-\beta E_i}$. 进一步定义 $E_* = E_*(\beta) := \langle q^*, E \rangle$. 那么我们有如下结论:

(i) $E_* \in (\underline{E}, \overline{E})$, 且 $-\frac{\partial}{\partial \beta} \ln Z_* = E_*$;

(ii) E_* 是 β 的光滑函数, 并且

$$\frac{\partial E_*}{\partial \beta} = - \sum_{i=1}^N q_i^* \cdot (E_i - E_*)^2 = -\text{Var}_{q^*}(E) < 0,$$

从而 E_* 是 β 的严格单调递减函数³. 因此光滑的单调函数 E_* 具有光滑的反函数 $\beta_* : (\underline{E}, \overline{E}) \rightarrow \mathbb{R}$. 特别地, 记 $E_p := \langle p, E \rangle$, 则 $\beta_*(E_p) = 0$;

(iii) 令 $h_p^* = h_p^*(\beta) := H(q^*|p)$, 其中 $q^* = q^*(\beta)$, 则 $\frac{\partial h_p^*}{\partial \beta} = \beta \cdot \text{Var}_{q^*}(E)$;

(iv) 对任意 $E \in (\underline{E}, \overline{E})$, 记 $\tilde{q} = \tilde{q}(E) := q^*(\beta_*)$, 其中 $\beta_* = \beta_*(E)$. 定义

$$h_p = h_p(E) := H(\tilde{q}|p).$$

则 $\tilde{q}, h_p$ 都是光滑函数, 并且 $\frac{\partial h_p}{\partial E} = -\beta_*$, $\frac{\partial^2 h_p}{\partial^2 E} = \frac{1}{\text{Var}_{\tilde{q}}(E)} > 0$, 因此 h_p 是凸函数。

(v) 特别地, 我们有 $h_p(E_p) = 0$, 且

$$H(\nu|p) \geq h_p(E_\nu), \quad (12.14)$$

等号成立当且仅当 $\nu = \tilde{q}(E_\nu)$.

¹Joseph-Louis Lagrange (拉格朗日, 1736—1813) 是法国著名数学家、物理学家。他在数学、力学和天文学三个学科领域中都有历史性的贡献, 其中尤以数学方面的成就最为突出。

²请务必当心, 这个问题中还有另一个隐蔽的约束。作为本讲义的读者, 你能找到这个隐蔽约束吗?

³这一性质也与我们的物理直观相符: 物体的温度越高 (倒温度越小), 物体的内能越大。

现在假定我们有上述热力学系统的无穷次观测

$$\{X_k\}_{k=1}^{\infty} \stackrel{\text{i.i.d.}}{\sim} \begin{pmatrix} 1 & 2 & \cdots & N \\ p_1 & p_2 & \cdots & p_N \end{pmatrix}. \quad (12.15)$$

通过前 n 次观测, 我们可以得到“样本经验分布列” $\nu^{(n)} := \{\nu_i^{(n)}\}_{i=1}^N$, 其中

$$\nu_i^{(n)} := \frac{1}{n} \sum_{k=1}^n 1_{\{X_k=i\}}. \quad (12.16)$$

给定 $E \in (\underline{E}, \overline{E})$, 我们断言以下“极限”

$$\bar{q}_i = \lim_{n \rightarrow \infty} \mathbb{P}(X_1 = i | \langle \nu^{(n)}, E \rangle = E) \quad (12.17)$$

存在, 并且 $\bar{q} = \{\bar{q}_i\}_{i=1}^N$ 实际上就是上述引理中的 $\tilde{q} := q^*(\beta_*)$, 其中“倒温度”参数 $\beta_* := \beta_*(E)$. 对这一结果的解释需要用到大偏差理论^[26]中的深刻结果. 结论(12.17)的严谨数学陈述与证明如下:

♠ **定理 12.1.1.** 设 $\{X_k\}_{k=1}^{\infty}$ 是独立同分布的离散型随机变量列, 共同分布律为 p ; 设 $\nu^{(n)}$ 是它的经验分布列, 见方程(12.15)、(12.16). 设 $\{E_j\}_{j=1}^N$ 及 E 满足 $\underline{E} < E < \overline{E}$. 那么对任意 $1 \leq i \leq N$, 下面的极限成立:

$$\lim_{\delta \downarrow 0} \lim_{n \rightarrow \infty} \mathbb{P}(X_1 = i | \langle \nu^{(n)}, E \rangle \in [E - \delta, E + \delta]) = q_i^*, \quad (12.18)$$

此处 q^* 是 $H(\nu|p)$ 在约束 $\langle \nu, E \rangle = E$ 下的最小值点, 即

$$q_i^* := \frac{e^{-\beta_* E_i}}{Z_*} \cdot p_i, \quad i = 1, \dots, N, \quad (12.19)$$

其中 $Z_* := \sum_{j=1}^N p_j \cdot e^{-\beta_* E_j}$, β_* 由约束确定. 当 $\langle p, E \rangle = E$ 时, $q_i^* = p_i$.

证明: 我们先基于引理12.1.1做一些准备工作。

为方便, 记 $q_i^{(n)}(\Delta) := \mathbb{P}(X_1 = i | \langle \nu^{(n)}, E \rangle \in \Delta)$, 则仿例12.1中办法易证

$$q_i^{(n)}(\Delta) = \mathbb{E}[\nu_i^{(n)} | \langle \nu^{(n)}, E \rangle \in \Delta].$$

现在取 $\Delta := [E - \delta, E + \delta]$, 其中 $\delta > 0$ 满足 $\underline{E} < E - \delta < E + \delta < \overline{E}$. 记 $\Gamma_\delta := \{\nu : \langle \nu, E \rangle \in \Delta\}$, 则不难证明 $q^{(n)}(\Delta) \in \Gamma_\delta$.

对任意 $t \in \Delta$, 通过引理12.1.1定义概率分布列 $\tilde{q}(t) = \{\tilde{q}_i(t)\}_{i=1}^N$ 如下:

$$\tilde{q}_i(t) := p_i \cdot e^{-\beta_t E_i} / Z_t, \quad i = 1, \dots, N, \quad (12.20)$$

其中 $\beta_t := \beta_*(t)$, $Z_t := Z_*(\beta_t)$; 且 $q^* = \tilde{q}(E)$. 由引理12.1.1, 对任意概率分布列 ν , 我们总记

$$E_\nu := \langle \nu, E \rangle.$$

如果 $\underline{E} < E_p - \delta < E_p < E_p + \delta < \overline{E}$, 则 $\beta_{E_p} = 0, h_p(E_p) = 0$, 并且

$$h'_p(t) = -\beta_t, \quad h''_p(t) = \frac{1}{\text{Var}_{\tilde{q}(t)}(E)},$$

进而 $\inf_{t \notin [E_p - \delta, E_p + \delta]} h_p(t) = \min\{h_p(E_p + \delta), h_p(E_p - \delta)\} > 0$. 事实上,

$$\inf_{t \geq E_p + \delta} h_p(t) = h_p(E_p + \delta), \quad \inf_{t \leq E_p - \delta} h_p(t) = h_p(E_p - \delta).$$

Sanov 定理 [26, Theorem 2.1.10] 告诉我们, 对任意“可测集” Γ (可以视为 $\mathbb{R}^N$ 中可测集)

$$\begin{aligned} -\inf_{\nu \in \Gamma^\circ} H(\nu|p) &\leq \lim_{n \rightarrow \infty} \frac{\ln \mathbb{P}(\nu^{(n)} \in \Gamma)}{n} \\ &\leq \lim_{n \rightarrow \infty} \frac{\ln \mathbb{P}(\nu^{(n)} \in \Gamma)}{n} \leq -\inf_{\nu \in \bar{\Gamma}} H(\nu|p), \end{aligned} \quad (12.21)$$

其中, Γ° 表示 Γ 的内点集, $\bar{\Gamma}$ 表示 Γ 的闭包. 引理12.1.1告诉我们,

$$\inf_{\nu \in \Gamma} H(\nu|p) \geq \inf_{\nu \in \Gamma} h_p(E_\nu). \quad (12.22)$$

下面我们开始定理结论的证明. 不妨假设 $E = 0$, 于是 $E_{q^*} = \langle q^*, E \rangle = 0$.

(I) 先假定 $E_p = E = 0$, 则 $q^* = p$. 不难算出 $\mathbb{E}[\nu_i^{(n)}] = p_i = q_i^*$. 进而

$$\begin{aligned} \mathbb{P}(X_1 = i | \nu^{(n)} \in \Gamma_\delta) &= \mathbb{E}[\nu_i^{(n)} | \nu^{(n)} \in \Gamma_\delta] = \frac{\mathbb{E}[\nu_i^{(n)}; \nu^{(n)} \in \Gamma_\delta]}{\mathbb{P}(\nu^{(n)} \in \Gamma_\delta)} \\ &= \frac{q_i^* - \mathbb{E}[\nu_i^{(n)}; \nu^{(n)} \notin \Gamma_\delta]}{\mathbb{P}(\nu^{(n)} \in \Gamma_\delta)}. \end{aligned}$$

注意到此时 $\mathbb{P}(\nu^{(n)} \in \Gamma_\delta) \rightarrow 1$ 及 $\mathbb{E}[\nu_i^{(n)}; \nu^{(n)} \notin \Gamma_\delta] \rightarrow 0$, 立即得到(12.18).

(II) 现在假定 $E_p \neq E = 0$, 此时 $q^* \neq p$. 类似地,

$$|q_i^{(n)}(\Delta) - q_i^*| \leq \mathbb{E}[|\nu_i^{(n)} - q_i^*| | \nu^{(n)} \in \Gamma_\delta].$$

于是, 若记 $\|\nu - p\|_{\text{TV}} := \sum_{i=1}^N |p_i - \nu_i|$ (它被称为符号测度 $\nu - p$ 的全变差, 参见定理4.2.1中的 (6) 或习题4.2), 则对任意 $\varepsilon > 0$

$$\|q^{(n)}(\Delta) - q^*\|_{\text{TV}} \leq \mathbb{E}[\|\nu^{(n)} - q^*\|_{\text{TV}} | \nu^{(n)} \in \Gamma_\delta]$$

$$\begin{aligned}
&\leq \varepsilon + \mathbb{E}[\|\nu^{(n)} - q^*\|_{\text{TV}} \cdot \mathbf{1}_{\{\|\nu^{(n)} - q^*\|_{\text{TV}} \geq \varepsilon\}} | \nu^{(n)} \in \Gamma_\delta] \\
&\leq \varepsilon + 2 \cdot \frac{\mathbb{P}(\nu^{(n)} \in \Gamma_\delta, \|\nu^{(n)} - q^*\|_{\text{TV}} \geq \varepsilon)}{\mathbb{P}(\nu^{(n)} \in \Gamma_\delta)}.
\end{aligned}$$

以下设 $0 < \delta < |E_p|$, $\varepsilon > 0$. 记 $\Gamma_{\delta, \varepsilon} := \Gamma_\delta \cap \{\nu : \|\nu - q^*\|_{\text{TV}} \geq \varepsilon\}$. 现在我们来估算 $A_n := \mathbb{P}(\nu^{(n)} \in \Gamma_\delta)$ 和 $B_n := \mathbb{P}(\nu^{(n)} \in \Gamma_{\delta, \varepsilon})$.

由(12.21),

$$\begin{aligned}
\lim_{n \rightarrow \infty} \frac{1}{n} \ln \mathbb{P}(\nu^{(n)} \in \Gamma_\delta) &= - \inf_{\nu \in \Gamma_\delta} H(\nu|p) =: a, \\
\overline{\lim}_{n \rightarrow \infty} \frac{1}{n} \ln \mathbb{P}(\nu^{(n)} \in \Gamma_{\delta, \varepsilon}) &\leq - \inf_{\nu \in \Gamma_{\delta, \varepsilon}} H(\nu|p) =: b
\end{aligned}$$

显然 $a \geq b$.

当 $E_p > 0$ 时, 取 $\hat{\delta} := \delta$, 否则取 $\hat{\delta} := -\delta$. 由引理12.1.1,

$$-a = \inf_{|t| \leq \delta} H(\tilde{q}(t)|p) = \inf_{t \in [-\delta, \delta]} h_p(t) = h_p(\hat{\delta}) > 0 = h_p(E_p).$$

特别地, 注意到引理12.1.1(v), 我们有

$$H(\nu|p) > h_p(\hat{\delta}), \forall \nu \neq \tilde{q}(\hat{\delta}), \text{ 且 } \nu \in \Gamma_\delta. \quad (12.23)$$

现在, $E = 0$, 因此 $\tilde{q}(0) = q^*$. 不难知道, 当 $\delta \rightarrow 0$ 时, $\|\tilde{q}(\delta) - q^*\|_{\text{TV}} \rightarrow 0$. 因此对充分小的 δ , $\tilde{q}(\delta) \in \Gamma_\delta \setminus \Gamma_{\delta, \varepsilon}$. 注意到 Γ_δ 与 $\Gamma_{\delta, \varepsilon}$ 可以视作 $\mathbb{R}^N$ 中有界闭集, 从而是紧集, 于是由(12.23)就知道必定有 $b < a$. 从而

$$\overline{\lim}_{n \rightarrow \infty} \frac{1}{n} \ln \frac{B_n}{A_n} \leq b - a < 0,$$

进而 $\frac{B_n}{A_n} \rightarrow 0$. 于是 $\lim_{n \rightarrow \infty} \|q^{(n)}(\Delta) - q^*\|_{\text{TV}} \leq \varepsilon$ 对任意 $\varepsilon > 0$ 及充分小的 δ 成立. 因此定理结论成立. $\square$

在上面定理中, 我们把(12.17)按照(12.18)中的极限方式来理解, 相应的条件概率称为 **Gibbs 条件概率**. 这个结果告诉我们, 给定“实验精度范围内的小误差” $\delta > 0$ 和充分大的样本量(实验次数) n , 当 $\langle p, E \rangle = E$ 时, $\{\langle \nu^{(n)}, E \rangle \in [E - \delta, E + \delta]\}$ 是大概率事件, 因此当此事件发生时我们自然应当认可模型初始假定的 $\{X_k\}_{k=1}^\infty$ 的共同分布律 p ; 但当 $\langle p, E \rangle \neq E$ 时, $\{\langle \nu^{(n)}, E \rangle \in [E - \delta, E + \delta]\}$ 就是小概率事件, 因此当此小概率事件发生后, 我们很自然需要调整模型初始假定的 $\{X_k\}_{k=1}^\infty$ 的共同分布律 p , 合理的调整办法在定理中已经给出.

以上离散模型的讨论参考了论文^{[96]1}; 定理12.1.1的最早论述者似乎是 Lanford, 因此这个定理或许可以称为 Lanford 定理. 连续模型也有对应结果, 感兴趣的读者可以参考文献^[97]及其他相关文献.

¹但论文^[96]中数学论证是有问题的; 在本讲义中, 编者对此给出了自己的证明.

12.2 大样本数据下模型的检验问题

关于模型的检验，本节我们关心的核心问题是以下两个典型问题：

- (1) 给定（一维）大样本数据 $\{x_k\}_{k=1}^n$ ，假定它们是来自分布律 F （此处 F 已知，并记 $X \sim F$ ）的简单样本 $\{X_k\}_{k=1}^n$ ，如何利用数据来检验这些数据来源于同一个分布总体 F ？亦即此处承认 $\{X_k\}_{k=1}^n$ 的相互独立性，考虑如何对假设 $\{X_k\}_{k=1}^n \stackrel{\text{i.i.d.}}{\sim} F$ 中“具有共同分布函数 F ”的这部分总体分布律的假设做检验（对独立性不做检验），从而零假设可记为

$$H_0 : X \sim F;$$

- (2) 给定（二维）大样本数据 $\{(x_k, y_k)\}_{k=1}^n$ ，假定它们是来自分布律 F （此处 F 未知，但记 $(X, Y) \sim F$ ）的独立同分布样本 $\{(X_k, Y_k)\}_{k=1}^n$ ，如何利用数据来检验总体分布律满足 X, Y 之间的相互独立性？亦即此处承认 $\{(X_k, Y_k)\}_{k=1}^n \stackrel{\text{i.i.d.}}{\sim} (X, Y)$ ，考虑如何检验总体的分布律信息中 X, Y 之间的相互独立性的问题，从而零假设可记为

$$H_0 : X, Y \text{ 相互独立.}$$

上述问题（1）是对（一维）简单样本的总体的分布律的检验；问题（2）是对（“二维”简单样本总体两维度间）独立性的检验。这两个检验问题正好覆盖了我们概率论课程中有关随机变量的概念中最重要的两个方面：分布律与独立性。

12.2.1 对（一维）简单样本总体分布律的检验

关于简单样本总体的分布律的检验，我们首先给出定性的检验方法：**P-P 图**或**Q-Q 图**。这两种方法是由 **Glivenko-Cantelli 定理**保证的，它是强大数律在统计学中的一个重要应用。

设 $\{X_k\}_{k=1}^\infty \stackrel{\text{i.i.d.}}{\sim} F$ ，其中 F 是一个概率分布函数。定义

$$\hat{F}_n(x) := \frac{1}{n} \sum_{k=1}^n 1_{\{X_k \leq x\}}. \quad (12.24)$$

它称为前 n 个样本对应的**经验分布函数**。由强大数律易知 $\hat{F}_n(x) \xrightarrow{\text{a.s.}} F(x)$ 对任意固定的 $x \in \mathbb{R}$ 成立。令

$$D_n := \|\hat{F}_n - F\|_\infty = \sup_{x \in \mathbb{R}} |\hat{F}_n(x) - F(x)|, \quad (12.25)$$

它被称为 **Kolmogorov-Smirnov 统计量**。下面的 Glivenko-Cantelli 定理告诉我们, 上述收敛 $\hat{F}_n(x) \xrightarrow{\text{a.s.}} F(x)$ 关于 x 是一致的。

♠ **定理 12.2.1. (Glivenko-Cantelli 定理)** 任给分布函数 F , $\{X_k\}_{k=1}^\infty \stackrel{\text{i.i.d.}}{\sim} F$ 的 Kolmogorov-Smirnov 统计量 D_n 满足 $D_n \xrightarrow{\text{a.s.}} 0$.

上述定理被统计学文献称为“统计基本定理”(fundamental statistical theorem), 是 1933 年 Glivenko (格里汶科) 对连续分布函数 F 、Cantelli 对一般的分布函数 F 给出的。统计学中用来检验样本是否服从给定分布 F 的 P-P 图 (或 Q-Q 图) 的方法本质上就依赖此定理: 当 F 是连续的分布函数时, 只需注意到对于样本 $\{X_k\}_{k=1}^n \stackrel{\text{i.i.d.}}{\sim} F$ 对应的次序统计量 $\{X_n^{(k)}\}_{k=1}^n$, $\hat{F}(X_n^{(k)}) = \frac{k}{n}$, 因此为检验这些样本确实来自于分布 F , 只需在二维平面上作图检验点列 $\{(\frac{k}{n}, F(X_n^{(k)}))\}_{k=1}^n$ (或点列 $\{(F^{-1}(\frac{k}{n}), X_n^{(k)})\}_{k=1}^n$, 其中 F^{-1} 表示广义逆) 近似位于直线 $y = x$ 上¹。P-P 图 (或 Q-Q 图) 的方法对于离散型分布也可以使用, 只是需要略作调整。
定理 12.2.1 的证明: 根据强大数律, 容易知道

$$\hat{F}_n(x) \xrightarrow{\text{a.s.}} F(x), \quad \hat{F}_n(x-) \xrightarrow{\text{a.s.}} F(x-), \quad \forall x \in \mathbb{R}.$$

当 F 是连续函数时, 定理的结论 $\sup\{|\hat{F}_n(x) - F(x)| : x \in \mathbb{R}\} \rightarrow 0$ 证明可以很简单, 留给读者; 但我们现在的分布函数 F 是一般的, 有可能带有跳跃点。为此, 对任意给定正整数 $m \geq 2$, 对任意 $1 \leq j < m$, 定义 $x_m^j := F^{-1}(\frac{j}{m})$. 那么存在 $N_m : \Omega \rightarrow \mathbb{N}$ 使得: 对于几乎处处的 ω 及 $n \geq N_m$, 我们有

$$|\hat{F}_n(x_m^j) - F(x_m^j)| < \frac{1}{m}, \quad |\hat{F}_n(x_m^j-) - F(x_m^j-)| < \frac{1}{m},$$

其中 $j = 1, \dots, m-1$. 我们约定 $x_m^0 := -\infty, x_m^m = +\infty$, 于是上式中 j 可以取到 0 和 m . 现在, 对任意 $x \in \mathbb{R}$, 存在唯一 $j \in [1, m]$, 使得 $x \in (x_m^{j-1}, x_m^j]$, 此时利用 $F(x_m^j-) - F(x_m^{j-1}) \leq \frac{1}{m}$, 我们有

$$\begin{aligned} \hat{F}_n(x) - F(x) &\leq \hat{F}_n(x_m^j) - F(x) \\ &\leq F(x_m^j-) + \frac{1}{m} - F(x) \\ &\leq F(x_m^j-) - F(x_m^{j-1}) + \frac{1}{m} \leq \frac{2}{m}. \end{aligned}$$

同理, $F(x) - \hat{F}_n(x) \leq \frac{2}{m}$. 因此

$$D_n = \sup_x |\hat{F}_n(x) - F(x)| \leq \frac{2}{m}, \quad \forall n \geq N_m.$$

¹在实际应用中, 对应考虑的点列略作了调整, 做 P-P 图时使用点列 $\{(\frac{2k-1}{2n}, F(X_n^{(k)}))\}_{k=1}^n$; 做 Q-Q 图时使用点列 $\{(F^{-1}(\frac{2k-1}{2n}), X_n^{(k)})\}_{k=1}^n$.

先令 $n \rightarrow \infty$, 再令 $m \rightarrow \infty$ 就证明了定理的结论。□

容易知道, 对于任意固定的 x , 经验分布函数 $\hat{F}_n(x)$ 满足中心极限定理:

$$G_n(x) := \sqrt{n}[\hat{F}_n(x) - F(x)] \xrightarrow{d} N(0, F(x)(1 - F(x))). \quad (12.26)$$

此处, $F(x) = 0$ 或 1 时, 上述极限分布理解为退化到 0 的单点分布¹。

注意到用于检验总体分布律的 P-P 图或 Q-Q 图的方法只是一种形象的、定性的检验方法, 我们通常还需要更定量的检验方法, 使得我们有一定的“把握”(比如 95% 的“概率”) ² 确认或否认所谓的零假设 H_0 : 总体的分布律是已知的分布律 F . 这时候我们需要对分布律 F 分两种情况来进行讨论和叙述。

(A) 定量检验: 分布函数 F 连续的情形。

在分布函数 F 连续的情形, Kolmogorov 证明了下面定理中的依分布收敛部分, Smirnov 计算出了对应的极限分布律的表达式(它被称为 Kolmogorov 分布)。

♠ **定理 12.2.2. (Kolmogorov 定理)** 设分布函数 F 连续。对样本 $\{X_k\}_{k=1}^\infty \stackrel{\text{i.i.d.}}{\sim} X \sim F$ 的 Kolmogorov-Smirnov 统计量 D_n , 我们有

$$\sqrt{n}D_n \xrightarrow{d} K := \sup_{t \in [0,1]} |B_t^\circ|, \quad (12.27)$$

其中 $\{B_t^\circ : t \in [0, 1]\}$ 表示 Brown 桥 (满足 $B_0^\circ = B_1^\circ = 0$) ³, 它可以借助某个标准 Brown 运动 $\{B_t : t \in [0, 1]\}$ 表示为 $B_t^\circ = B_t - tB_1$. 从而⁴

$$\lim_{n \rightarrow \infty} \mathbb{P}(\sqrt{n}D_n \leq x) = 1 + 2 \sum_{j=1}^{\infty} (-1)^j \cdot e^{-2(jx)^2}, \forall x > 0. \quad (12.28)$$

本讲义在附录C中对上述定理中的结论(12.27)提供了一个粗线条的证明框架; 读者也可参见文献^[129]§4.2.3 中提供的证明。

当 n 很大时 ($n \geq 100$), 利用上面的定理, 我们可以构建 Kolmogorov 检验: 对指定的显著性水平 $\alpha \in (0, 1)$ (比如 $\alpha = 0.05$), 取 Kolmogorov 分布的 $1 - \alpha$

¹ 极限表达式(12.26)这个细节也部分提示了后续的 Kolmogorov 定理中需要用到 Brown 桥 $\{B_t^\circ : t \in [0, 1]\}$ 来进行描述或论证: 根据 $B_t^\circ = B_t - tB_1$ 不难算出, $\text{Var}(B_t^\circ) = t(1 - t)$, 恰好与(12.26)右端极限分布的方差形态一致 (此处取 $F(x) = 1 \wedge x^+$ 为 $U(0, 1)$ 的分布函数)。

² 但要注意, 类似于“ $1 - \alpha$ 的把握 (或概率) 拒绝 (或接受) 零假设 H_0 ”是非常不规范的讲法, 统计界早在 20 世纪末就已弃用这种讲法, 其原因可参见第三章 §3.4.2; 规范的讲法是: “在 α 的显著性水平下拒绝 (或接受) 零假设 H_0 ”。

³ 一般而言, Brown 桥 $\{B_t^\circ : t \in [0, 1]\}$ 的分布律被定义为标准 Brown 运动 $\{B_t : t \in [0, 1]\}$ 在约束 $B_0 = B_1 = 0$ 条件下的条件分布律; 不难知道标准 Brown 运动 $\{B_t : t \in [0, 1]\}$ 的诱导过程 $\{B_t - tB_1 : t \in [0, 1]\}$ 恰好就满足这个条件分布律。

⁴ K 的分布函数的另一种表达式是 $\mathbb{P}(K \leq x) = \frac{\sqrt{2\pi}}{x} \sum_{k=1}^{\infty} \exp\{-(2k-1)^2\pi^2/(8x^2)\}$ 。

分位数 K_α , 即 $\mathbb{P}(K \leq K_\alpha) = 1 - \alpha$. 当 $\sqrt{n}D_n > K_\alpha$ 时, 就认为在 (差不多) α 的显著性水平下应当拒绝原始假设, 认为 $X \sim F$ 不成立; 而当 $\sqrt{n}D_n \leq K_\alpha$ 时, 就认为在 (差不多) α 的显著性水平下应当接受原始假设, 认为 $X \sim F$ 成立。

当 n 不算太大时 ($n \leq 100$), 注意到 D_n 的精确分布律其实与 F 无关, 因此可以借助 Owen 在 1962 年制作的表格^[78], 同样可对指定的 $\alpha \in (0, 1)$, 取 $\sqrt{n}D_n$ 的分布的 $1 - \alpha$ 分位数 $x_{n,\alpha}$, 即 $\mathbb{P}(\sqrt{n}D_n \leq x_{n,\alpha}) = 1 - \alpha$. 当 $\sqrt{n}D_n > x_{n,\alpha}$ 时, 就认为在 α 的显著性水平下应当拒绝零假设 H_0 , 认为 $X \sim F$ 不成立; 而当 $\sqrt{n}D_n \leq x_{n,\alpha}$ 时, 就认为在 α 的显著性水平下应当接受零假设 H_0 , 认为 $X \sim F$ 成立。

(B) 定量检验: 离散型分布函数 F 的情形。

下面的 Pearson 定理可以视作 Kolmogorov 定理在离散型分布情形的对应。在统计学中, Pearson 定理通常用来进行拟合优度检验。

♠ **定理 12.2.3. (Pearson 定理)** 设 $\{X_k\}_{k=1}^n \stackrel{\text{i.i.d.}}{\sim} \begin{pmatrix} 1 & \cdots & m \\ p_1 & \cdots & p_m \end{pmatrix}$. 记 $n_j := \sum_{k=1}^n 1_{\{X_k=j\}}$, $\hat{p}_j := \frac{n_j}{n}$, 那么

$$Q := \sum_{j=1}^m \frac{n}{p_j} \cdot (\hat{p}_j - p_j)^2 \xrightarrow{d} \chi^2(m-1). \quad (12.29)$$

证明: 首先, 注意到

$$\hat{p}_j = \frac{1}{n} \sum_{k=1}^n 1_{\{X_k=j\}}$$

以及 $\mathbb{E}[1_{\{X_k=j\}}] = p_j$, $\text{Var}(1_{\{X_k=j\}}) = p_j(1 - p_j)$, 根据中心极限定理

$$W_j := \sqrt{\frac{n}{p_j}} \cdot (\hat{p}_j - p_j) \xrightarrow{d} N(0, 1 - p_j).$$

先讨论 $W := (W_1, \dots, W_m)^T$ 的极限分布律。这里可以使用 Cramer-Wold Device (见上一章习题 11.30): 对任意 $a = (a_1, \dots, a_m)^T$,

$$\begin{aligned} a^T W &= \sum_{j=1}^m a_j \cdot W_j = \sum_{j=1}^m a_j \cdot \sqrt{\frac{n}{p_j}} \cdot \frac{1}{n} \sum_{k=1}^n (1_{\{X_k=j\}} - p_j) \\ &= \frac{1}{\sqrt{n}} \sum_{k=1}^n \sum_{j=1}^m \frac{a_j}{\sqrt{p_j}} \cdot (1_{\{X_k=j\}} - p_j) \xrightarrow{d} N(0, a^T B a), \end{aligned}$$

其中 $B = (B_{i,j})_{1 \leq i,j \leq m}$ 是一个矩阵, 此时就可以认为 $W \xrightarrow{d} N(0, B)$. 可以算出

$$a^T B a = \text{Var}\left(\sum_{j=1}^m \frac{a_j}{\sqrt{p_j}} \cdot (1_{\{X_1=j\}} - p_j)\right)$$

$$= \sum_{i=1}^m a_i^2(1-p_j) - 2 \sum_{1 \leq i < j \leq m} a_i a_j \cdot \sqrt{p_i p_j}.$$

即 $B = I - \alpha\alpha^T$, 其中 $\alpha = (\sqrt{p_1}, \dots, \sqrt{p_m})^T$.

定理中要讨论的量为

$$Q := \sum_{j=1}^m \frac{n}{p_j} \cdot (\hat{p}_j - p_j)^2 = \sum_{j=1}^m W_j^2 = \|W\|^2.$$

注意到总有 $\sum_{j=1}^m \sqrt{p_j} W_j = 0$, 存在正交矩阵 A , 使得它的第一行元素如下指定:

$$A = \begin{pmatrix} \sqrt{p_1} & \cdots & \sqrt{p_m} \\ * & \cdots & * \\ \vdots & \ddots & \vdots \\ * & \cdots & * \end{pmatrix}.$$

此时 $A\alpha = (1, 0, \dots, 0)^T, ABA^T = A(I - \alpha\alpha^T)A^T = \text{diag}\{0, I_{m-1}\}$. 令

$$Z = AW.$$

此时 $Z_1 = 0$; $W \xrightarrow{d} N(0, B)$ 意味着 $Z \xrightarrow{d} N(0, ABA^T)$. 于是

$$(Z_2, \dots, Z_m)^T \xrightarrow{d} N(0, I_{m-1}).$$

现在 $Q = \|W\|^2 = \|Z\|^2 = Z_2^2 + \dots + Z_{m-1}^2 \xrightarrow{d} \chi^2(m-1)$. □

12.2.2 对(“二维”简单样本总体两维度间)独立性的检验

为了实现对独立性的检验, 我们需要下面的一些技术准备。

利用特征函数工具, 我们可以进一步讨论 χ^2 -分布。此处, 若

$$\{X_k\}_{k=1}^n \stackrel{\text{i.i.d.}}{\sim} N(\mu, 1),$$

则记 $Y := X_1^2 + \dots + X_n^2 \sim \chi^2(n; \delta)$ (其中 $\delta := \sqrt{n}|\mu|$), 并称 Y 服从 n 个自由度的(非中心)卡方分布, 中心参数为 δ ; 当 $\delta = 0$ (即 $\mu = 0$) 时就简单记作 $Y \sim \chi^2(n)$, 称 Y 服从 n 个自由度的(中心)卡方分布。

♠ **定理 12.2.4.** 设 $a = (a_1, \dots, a_n)^T \in \mathbb{R}^n$, $X = (X_1, \dots, X_n)^T \sim N(a, I_n)$; A, A_1, A_2 都是 n 阶实对称矩阵。关于 χ^2 -分布, 我们有:

- (1) $Y := X^T A X$ 服从 χ^2 -分布, 当且仅当 $A^2 = A$, 即 A 是幂等矩阵. 此时 $Y \sim \chi^2(r; \delta)$, 其中 $r = \text{rank}(A)$, $\delta^2 = a^T A a$;
- (2) 设 $Y := X^T A X, Y_1 := X^T A_1 X$. 如果 Y, Y_1 分别服从自由度为 m, m_1 的 χ^2 -分布 (不必是中心的), 并且 $A_2 := A - A_1 \geq 0$ (即半正定), 且 $A_2 \neq 0$, 那么

$$Y_2 := X^T A_2 X$$

服从自由度为 $m_2 = m - m_1$ 的 χ^2 -分布, 并且 Y_1, Y_2 相互独立;

- (3) 设 $Y_i = X^T A_i X, i = 1, 2$ 都服从 χ^2 -分布¹. 则 Y_1, Y_2 相互独立的充要条件是 $A_1 A_2 = 0$.

♠ **定理 12.2.5.** (Cochran 定理) 设 $X \sim N(a, I_n)$, 并且

$$X^T X = \sum_{i=1}^m X^T A_i X,$$

其中 A_i 均为实对称矩阵. 以下两条之间相互等价:

- (1) 存在 $\{(n_i, \delta_i)\}_{i=1}^m$, 使得 $X^T A_i X \sim \chi^2(n_i; \delta_i), i = 1, \dots, m$, 并且它们相互独立;
- (2) $\{A_i\}_{i=1}^m$ 的秩满足

$$\sum_{k=1}^m \text{rank}(A_k) = n. \quad (12.30)$$

当(12.30)成立时, $n_i = \text{rank}(A_i), \delta_i^2 = a^T A_i a, i = 1, \dots, m$.

以上定理的证明并不太难, 留给读者作为练习; 亦可参见文献.^[104]这几个结果在回归分析课程的方差分析理论中有重要应用价值。

下面的 Pearson-Fisher 定理在实务上用来进行独立性的列联表检验。

♠ **定理 12.2.6.** (Pearson-Fisher 定理) 设 $\{(X_k, Y_k)\}_{k=1}^n$ 是来自离散型分布 (X, Y) 的简单样本, 其中

$$\mathbb{P}(X = i, Y = j) = p_{i,j}, \quad 1 \leq i \leq K, 1 \leq j \leq L,$$

$2 \leq K, L < \infty$. 记 $\mathbb{P}(X = i) = p_i, \mathbb{P}(Y = j) = q_j$, 并令

$$\hat{p}_{i,j} := \frac{1}{n} \sum_{k=1}^n 1_{\{X_k=i, Y_k=j\}}, \quad \hat{p}_i := \frac{1}{n} \sum_{k=1}^n 1_{\{X_k=i\}}, \quad \hat{q}_j := \frac{1}{n} \sum_{k=1}^n 1_{\{Y_k=j\}}.$$

¹ 此处, Y_1, Y_2 都服从 χ^2 -分布这一条件可以去掉. 证明参见 Plackett.^[82]

那么当 X, Y 相互独立 (即 $p_{i,j} = p_i q_j, \forall i, j$) 时

$$V := \sum_{i=1}^K \sum_{j=1}^L \frac{n}{\hat{p}_i \hat{q}_j} \cdot (\hat{p}_{i,j} - \hat{p}_i \hat{q}_j)^2 \xrightarrow{d} \chi^2((K-1)(L-1)). \quad (12.31)$$

证明: 我们基于 Pearson 定理来证明此处结果。这里将使用第十章习题10.20中的 $O_{\mathbb{P}}(1), o_{\mathbb{P}}(1)$ 记号及其性质, 并结合 Cochran 定理来进行论证。

同上, 定义

$$W_{i,j} := \sqrt{\frac{n}{p_{i,j}}} \cdot (\hat{p}_{i,j} - p_{i,j}) \xrightarrow{d} N(0, 1 - p_{i,j}).$$

我们记 $Q_* := \sum_{i,j} \frac{n}{p_{i,j}} \cdot (\hat{p}_{i,j} - \hat{p}_i \hat{q}_j)^2$. 注意到 $n \cdot (\hat{p}_{i,j} - \hat{p}_i \hat{q}_j)^2 = O_{\mathbb{P}}(1)$, $\hat{p}_i = p_i + o_{\mathbb{P}}(1)$, $\hat{q}_j = q_j + o_{\mathbb{P}}(1)$, 容易知道 $V = Q_* + o_{\mathbb{P}}(1)$.

现在定义

$$\begin{aligned} Q_{X,Y} &:= \sum_{i,j} \frac{n}{p_{i,j}} \cdot (\hat{p}_{i,j} - p_{i,j})^2, \\ Q_X &:= \sum_i \frac{n}{p_i} \cdot (\hat{p}_i - p_i)^2, \\ Q_Y &:= \sum_j \frac{n}{q_j} \cdot (\hat{q}_j - q_j)^2. \end{aligned}$$

在独立性假设 $p_{i,j} = p_i q_j, \forall i, j$ 下, 定理12.2.3中结果告诉我们,

$$Q_{X,Y} \xrightarrow{d} \chi^2(KL-1), Q_X \xrightarrow{d} \chi^2(K-1), Q_Y \xrightarrow{d} \chi^2(L-1).$$

现在不难计算出

$$Q_{X,Y} = Q_X + Q_Y + Q_*.$$

其中 Pearson 定理的证明过程中说明了存在线性的一一变换

$$\{W_{i,j} : 1 \leq i \leq K, 1 \leq j \leq L\} \mapsto \{Z_{\alpha}\}_{1 \leq \alpha \leq KL}$$

使得 $Z_1 \equiv 0, (Z_2, \dots, Z_{KL})^T \xrightarrow{d} N(0, I_{KL-1})$, 并且

$$Q_{X,Y} = Z_2^2 + \dots + Z_{KL}^2.$$

于是不难知道 Q_X, Q_Y, Q_* 均可以表达为 $Z_2, \dots, Z_{KL}$ 的二次型。结合 Cochran 定理 (或定理12.2.4的 (3)), 立即知道 $Q_* \xrightarrow{d} \chi^2((K-1)(L-1))$. 进而 $V \xrightarrow{d} \chi^2((K-1)(L-1))$. $\square$

读者在《统计学》的相关课程中将学习到更多假设检验的方法与理论。

在以下两个注记中,我们简要介绍统计学的历史与有关重要人物。有关资料参考了[21,41,45,50,51,93-95,99,123,124]等,并参考了部分网络信息,特别较大比例引用了张晓牟的《统计学的历史与今天》¹。

📌 注 12.1. 此处我们简要介绍统计学的历史。

近代统计学的发展起源于20世纪初,它是在概率论的基础上发展起来的,但统计性质的工作可以追溯到远古的“结绳记事”和《二十四史》中大量的关于我国人口、钱粮、水文、天文、地震等资料的记录。西方则把收集和整理国情资料的活动称为统计,统计一词(Statistics)正是由国家(State)一词演化而来的。从统计学的产生和发展过程来看,可以把统计学大致分为古典统计学、近代统计学、现代统计学三个时期。

(A) 古典统计学时期(17世纪中叶至18世纪中叶) 这一时期被认为是统计学的萌芽时期,当时主要有国势学派和政治算术学派。

国势学派又称记述学派,产生于17世纪的德国。由于该学派主要以文字记述国家的显著事项,故称记述学派。其主要代表人物是H. Conring(康令,1606—1681)和G. Achenwall(阿亨华尔,1719—1772)。Conring第一个在德国黑尔姆斯太特大学以“国势学”为题讲授政治活动家应具备的知识。Achenwall在格丁根大学开设“国家学”课程,其主要著作是《近代欧洲各国国势学纲要》,书中讲述“一国或多数国家的显著事项”,主要用对比分析的方法研究了解国家组织、领土、人口、资源财富和国情国力,比较了各国实力的强弱,为德国的君主政体服务。因在外文中“国势”与“统计”词义相通,后来正式命名为“统计学”。该学派在进行国势比较分析中,偏重事物性质的解释,而不注重数量对比和数量计算,但却为统计学的发展奠定了经济理论基础。但随着资本主义市场经济的发展,对事物量的计算和分析显得越来越重要,该学派后来发生了分裂,分化为图表学派和比较学派。

政治算术学派产生于19世纪中叶的英国,创始人是William Petty(配第,1623—1687),其代表作²是他于1676年完成的《政治算术》一书。这里的“政治”是指政治经济学,“算术”是指统计方法。在这部书中,他利用实际资料,运用数字、重量和尺度等统计方法对英国、法国和荷兰三国的国情国力,作了系统的数量对比分析,从而为统计学的形成和发展奠定了方法论基础。因此马克思说,“威廉·配第—政治经济学之父,在某种程度上也是统计学的创始人”。政治算术学派的另一个代表人物是John Graunt(格朗特,1620—1674;英国统计学家)。他以1604年伦敦教会每周一次发表的“死亡公报”为研究资料,在1662年发表了《关于死亡公报的自然和政治观察》的论著。书中分析了60年来伦敦居民死亡的原因及人口变动的关系,首次提出通过大量观察,可以发现新生儿性别比例具有稳定性和不同死因的比例等人口规律;并且第一次编制了“生命表”,对死亡率与人口寿命作了分析,从而引起了普遍的关注。他的研究清楚地表明了统计学作为国家管理工具的重要作用。

(B) 近代统计学时期(18世纪末到19世纪末期) 这时期的主要统计学派有数理统计学派和社会统计学派。

在18世纪,概率理论日益成熟,为统计学的发展奠定了基础。19世纪中叶,数理统计学派的先驱们把概率论引进统计学而形成数理学派。其奠基人是比利时的Lambert Adolphe Jacques Quetelet(凯特勒,1796—1874),其主要著作有:《论人类》、《概率论书简》、《社会制度》和《社会物理学》等。他主张用研究自然科学的方法研究社会现象,正式把古典概率论引进统计学,使统计学进入一个新的发展阶段。由于历史的局限性,凯特勒在研究过程中混淆了自然现象和社会现象的本质区别,对犯罪、道德等社会问题,用研究自然现象的观点和方法作出一些机械的、庸俗化的解释。但是,他把概率论引入统计学,使统计学在“政治算术”所建立的“算术”方法的基础上,在准确化道路上大大跨进了一步,为数理统计学的形成与发展奠定了基础。之后,Francis Galton(高尔顿,1822—1911)受其表兄Charles Robert Darwin(达尔文,1809—1882;英国生物学家,进化论的奠基人)的进化论思想的影响,把该思想引入到人类研究;他着重研究个别差异,从遗传的角度研究个别差异形成的原因,开创了优生学,进一步影响了后续的统计学家K. Pearson和R. Fisher等。

¹有关信息见 <https://zhuanlan.zhihu.com/p/413005676>、<https://cosx.org/2008/11/statistics-history-and-today/>、<https://wenku.baidu.com/view/39e550518d9951e79b89680203d8ce2f006665ec.html> 等。

²威廉·配第最著名的经济学著作是《赋税论》(1662年,全名是《关于税收与捐献的论文》),他也被认为是英国古典政治经济学之父、最早的宏观经济学者。



图 12.1: Quetelet (1796-1874)



图 12.2: Galton (1822-1911)

社会统计学派产生于 19 世纪后半叶, 创始人是德国经济学家、统计学家克尼斯 (1821—1889), 主要代表人物主要有恩格尔 (1821—1896)、梅尔 (1841—1925) 等人。他们融合了国势学派与政治算术学派的观点, 沿着凯特勒的“基本统计理论”向前发展, 但在学科性质上认为统计学是一门社会科学, 是研究社会现象变动原因和规律性的实质性科学, 以此同数理统计学派通用方法相对立。社会统计学派在研究对象上认为统计学是研究总体而不是个别现象, 而且认为由于社会现象的复杂性和整体性, 必须对总体进行大量观察和分析, 研究其内在联系, 才能揭示现象内在规律。这是社会统计学派的“实质性科学”的显著特点。社会经济的发展, 要求统计学提供更多的统计方法, 社会科学本身也不断地向细分化和定量化发展, 也要求统计学能提供更有有效的调查整理、分析资料的方法。因此, 社会统计学派也日益重视方法论的研究, 出现了从实质性方法论转化的趋势。但是, 社会统计学派仍然强调在统计研究中必须以事物的质为前提和认识事物的重要性, 这同数理统计学派的计量不计质的方法论性质是有本质区别的。

(C) 现代统计学时期 (20 世纪迄今) 这个时期, 数理统计学发展的主流从描述统计学转向推断统计学。

20 世纪初以来, 科学技术迅猛发展, 社会发生了巨大变化, 统计学进入了快速发展时期。归纳起来有以下几个方面的变化。

- (1) 由记述统计向推断统计发展。记述统计是对所搜集的大量数据资料进行加工整理、综合概括, 通过图示、列表和数字, 如编制次数分布表、绘制直方图、计算各种特征数等, 对资料进行分析和描述。而推断统计, 则是在搜集、整理观测的样本数据基础上, 对有关总体作出推断。其特点是根据带随机性的观测样本数据以及问题的条件和假定 (模型), 而对未知事物作出的, 以概率形式表述的推断。目前, 西方国家所指的科学统计方法, 主要就是指推断统计来说的。
- (2) 由社会、经济统计向多分支学科发展。在 20 世纪以前, 统计学的领域主要是人口统计、生命统计、社会统计和经济统计。随着社会、经济和科学技术的发展, 到今天, 统计的范畴已覆盖了社会生活的一切领域, 几乎无所不包, 成为通用的方法论科学。它被广泛用于研究社会和自然界的各个方面, 并发展成为有着许多分支学科的科学。
- (3) 统计预测和决策科学的发展。传统的统计是对已经发生和正在发生的事物进行统计, 提供统计资料和数据。20 世纪 30 年代以来, 特别是第二次世界大战以来, 由于经济、社会、军事等方面的客观需要, 统计预测和统计决策科学有了很大发展, 使统计走出了传统的领域而被赋予新的意义和使命。
- (4) 信息论、控制论、系统论与统计学的相互渗透和结合, 使统计科学进一步得到发展和日趋完善。信息论、控制论、系统论在许多基本概念、基本思想、基本方法等方面有着共同之处, 三者从不同角度、侧面提出了解决共同问题的方法和原则。信息论、控制论、系统论的创立和发展, 彻底改变了世界的科学图景和科学家的思维方式, 也使统计科学和统计工作从中吸取了营养, 拓宽了视野, 丰富了内容, 出现了新的发展趋势。
- (5) 计算技术和一系列新技术、新方法在统计领域不断得到开发和应用。近几十年间, 计算机技术不断发展, 使统计数据的搜集、处理、分析、存贮、传递、印制等过程日益现代化, 提高了统计工作的效能。

计算机技术的发展，日益扩大了传统的和先进的统计技术的应用领域，促使统计科学和统计工作发生了革命性的变化。如今，计算机科学已经成为统计科学不可分割组成部分。

在当今 21 世纪，随着科学技术的发展，统计学在 2011 年从数学和经济学中独立出来，自身成为一级学科，极大地推动了统计学的发展，统计理论在实践的深度和广度方面也不断发展。

注 12.2. 此处我们简要介绍现代统计学早期发展史上的几个重要人物 —K. Pearson、R. Fisher、E. Pearson 和 Neyman.



图 12.3: K. Pearson (1857-1936)



图 12.4: R. Fisher (1890-1962)




图 12.5: E. Pearson (1895-1980)



图 12.6: J. Neyman (1894-1981)

Karl Pearson (卡尔·皮尔逊, 1857—1936; 英国) 生、卒于伦敦, 他被公认为现代统计学之父。K. Pearson 最重要的学术成就, 是为现代统计学打下基础。许多熟悉的统计名词如标准差、成分分析、卡方检验都是他提出的。K. Pearson 1879 年毕业于剑桥大学数学系; 曾参与激进的政治活动。他出版了几本文学作品, 并且做了三年的律师实习。1884 年进入伦敦大学学院 (University College, London), 教授数学与力学, 从此待在该校一直到 1933 年。自从达尔文演化论问世后, 关于演化的本质争论不断, 在这方面他深受 Galton 与 Weldon 影响。Weldon 在 1893 年提出“所谓变异、遗传与天择, 事实上只是‘算术’”的想法。这促使 K. Pearson 在 1893—1912 年间写出 18 篇讨论演化论的数学论文, 而这门“算术”也就是今日的统计。K. Pearson、Galton 与 Weldon 为了推广统计在生物上的应用, 于 1901 年创立统计的元老期刊 *Biometrika*, 由 K. Pearson 主编至死; 但是 K. Pearson 的主观强, 经常对他本人认为有“争议”的文章或删改或退稿, 并因此与英国上世纪最有才华的统计学家 Fisher 结下梁子。1906 年 Weldon 死后, K. Pearson 不再关注生物问题, 而专心致力于将统计发展成一门精确的科学。

Ronald Aylmer Fisher (费雪, 1890—1962; 英国), 生于伦敦, 卒于澳洲的 Adelaide。他是英国统计与遗传学家, 现代统计科学的奠基人之一, 并对达尔文进化论作了基础性的澄清工作。安德斯·哈尔德称他是“一

位几乎独自建立现代统计科学的天才”，理查·道金斯则认为他是“达尔文最伟大的继承者”。他毕业于剑桥大学，教过中学，长期在农业试验站搞生物实验，先后任伦敦大学和剑桥大学教授，1929年当选皇家学会会员。1922年出版了他的现代统计的基础性著作《理论统计的数学基础》，对统计中的多元分析、相关系数、样本分布及其在生物遗传与优生方面的应用等方面进行了系统深入的阐述。他的主要贡献在估计理论、假设检验、实验设计和方差分析等方面。他所领导的伦敦大学数理统计学派在20世纪30年代到40年代，在世界数理统计界占主导地位。*R. Fisher*在统计发展史上地位是显赫的。这位多产作家研究成果特别适用于农业与生物学领域，但其影响已经渗透到一切统计学，由此提炼出来的推断统计学已越来越被广大领域所接受。因此，美国统计学家约翰逊于1959年出版《现代统计出版方法：描述和推断》一书中指出：“从1920年起到今天的这段时间，称之为统计学的*Fisher*时代是恰当的。”

Egon Pearson (埃贡·皮尔逊, 1895—1980; 英国) 是 *K. Pearson* 的儿子, 在统计学中通常称之为小 *Pearson*。因为他有一个各方面都才华横溢的父亲, 某种意义上他完全是在其父亲的阴影下长大的: 小 *Pearson* 的整个成长岁月里都正处在父亲事业的上升期, 那时老 *Pearson* 是统计界里首屈一指、说一不二的大拿。小 *Pearson* 从小体弱多病, 一直在家由其父亲安排他的学习和生活, 直到1914年才离家去剑桥上大学, 不到一年就生病休学, 并因第一次世界大战原因参与了军队服务。后来军方为参战而辍学人员开设了一个特别考试, 小 *Pearson* 于1920年通过这个考试, 被授予了学士学位, 次年在其父亲开创的应用统计系任讲师, 但直到1926年其父亲身体状况恶化才被允许去讲课。小 *Pearson* 与其父亲的性格大相径庭: 老 *Pearson* 才华横溢、才思敏捷, 做事风风火火、过度自信甚至专横跋扈, 一旦有什么新思想, 就匆匆下笔, 立刻发表, 在数学表述上经常有不清楚甚至错误的地方; 小 *Pearson* 则害羞而谦逊、内敛而深沉、自省而谨慎, 做研究非常认真, 仔细推敲计算过程的每一个细节。因迥异的性格, 小 *Pearson* 的研究与其父亲渐行渐远。在1926年小 *Pearson* 结识了从波兰来英国访问的学者 *Neyman*。尽管表面看小 *Pearson* 和 *Neyman* 性格一者内向而寡言, 一者热情而健谈, 但二者都有谦逊而内省的人格, 从此二人成为一生的朋友。*Neyman* 在1926年初由于对统计研究的兴趣而来伦敦访问老 *Pearson*, 但到访后却发现老 *Pearson* 对现代数学知之甚少而非常失望, 同年夏天即往巴黎访问他的另一位偶像 *Lebesgue*, 准备自此投身测度论的研究。由于小 *Pearson* 的来信, 才把 *Neyman* 重新拉回到统计研究中去, 他们的友谊与合作完全靠鸿雁传书——*Neyman* 结束在巴黎的访学后就回到了波兰, 直到1935年 *Neyman* 才再次来到伦敦。*Neyman* 与小 *Pearson* 在1928—1938年期间发表了一系列文章, 建立了假设检验的一种严格的数学理论, 由此二人也奠定了在现代统计学中的宗师地位。

Jerzy Neyman (内曼, 1894—1981) 是波兰裔美国籍统计学家, 生于俄国宾杰里; 卒于美国伯克利。*Neyman* 是假设检验的统计理论的创始人之一; 我国的许宝騄先生 (1910—1970) 在1936—1938年间赴英留学于伦敦大学学院, 其导师就是 *Neyman*。*Neyman* 与小 *Pearson* 合著《统计假设试验理论》, 发展了假设检验的数学理论, 其要旨是把假设检验问题作为一个最优化问题来处理。他们把所有可能的总体分布族看作一个集合, 其中考虑了一个有待检验的零假设相对应的备择假设, 引进了检验功效函数的概念, 以此作为判断检验程序好坏的标准。这种思想使统计推断理论变得非常明确。*Neyman* 还想从数学上定义可信区间, 提出了置信区间的概念, 建立置信区间估计理论。*Neyman* 还对抽样引进某些随机操作, 以保证所得结果的客观性和可靠性, 在统计理论中有以他的姓氏命名的 *Neyman* 置信区间法、*Neyman-Pearson* 引理、*Neyman* 结构等。*Neyman* 将统计理论应用于遗传学、医学诊断、天文学、气象学、农业统计学等方面, 取得丰硕的成果。他获得过国际科学奖, 并在加利福尼亚大学创建了一个研究机构, 后来发展成为世界著名的数理统计中心。

现代统计学的发展史上20世纪的著名统计学家还有 *Hotelling*、*Wald*、*Cramer* 和 *Rao* 等, 篇幅所限, 敬请读者自行搜寻他们的生平介绍与学术贡献等信息。

12.3 本章小结与学习建议

在本章, 我们讨论了两个主题: 其一是概率论视角下“经验的总结与外推”; 其二是大样本数据下模型的检验问题。

通常, 本章的全部内容都作为读者的课外阅读材料, 概率论的初学者只需

对这些内容略作了解即可。但值得注意的是,本章的 Glivenko-Cantelli 定理被称为统计学基本定理,它告诉我们,理论上我们所构建的概率模型中的概率测度实际上可以通过重复试验所收集大量数据来进行估计,并通过 Kolmogorov 定理、Pearson 定理和 Pearson-Fisher 定理来进行检验。因此,正如我们在“前言与导读”中所说,尽管我们对世界的探索与认知是盲人摸象的模式,但最终我们人类能贴近世界的真相。这也印证了 Hilbert 名言“我们必须知道,我们必将知道”:

Wir müssen wissen. Wir werden wissen!

如编者在“前言与导读”中所说,本章中 Kolmogorov 定理这一重要结果的表述与证明都需要随机过程的语言与泛函中心极限定理等更高端的概率理论,定理 12.1.1 的证明则需要使用大偏差理论中的深刻结果;而本书中多处(特别是第四章)内容限于教学安排无法细致展开,因而对概率论真正感兴趣的读者需要进一步阅读、学习初等概率论的后续的“高等”概率论课程的有关内容。

习 题 12

习题 12.1. 给出例 12.1 中 (2) 的解答。

习题 12.2. 给出例 12.2 中 (2)、(4) 的解答。

习题 12.3. (掷硬币实验的 Bayes 模型的 Bayes 估计问题) 对于一个一般的统计模型,在已知数据 $X_1, \dots, X_n$ 的条件下,对(随机)参数 ξ 的极大似然估计方法如下:首先写出条件分布律

$$\xi \mid (X_1 = x_1, \dots, X_n = x_n).$$

如果它是一个连续型分布,特别地如果它的密度函数是单峰的,则对应密度函数的极大值点就作为对应的极大似然 Bayes 估计 $\hat{p}$;如果上述条件分布律是一个离散型分布,则概率分布列中取值概率最大的点就作为对应的极大似然 Bayes 估计 $\hat{p}$. 考虑有关热手效应的模型(见例 12.2),试给出该模型下的极大似然 Bayes 估计 $\hat{p}$.

习题 12.4. 在例 12.1 中的模型假定下,试证明:对任意 $f \in (0, 1), i \geq 1$

$$\lim_{\delta \downarrow 0} \lim_{n \rightarrow \infty} \mathbb{P}(X_i = 1 \mid \frac{S_n}{n} \in [f - \delta, f + \delta]) = f,$$

并且对任意 $k \geq 2, 1 \leq i_1 < i_2 < \dots < i_k$,

$$\lim_{\delta \downarrow 0} \lim_{n \rightarrow \infty} \mathbb{P}(X_{i_1} = 1, X_{i_2} = 1, \dots, X_{i_k} = 1 \mid \frac{S_n}{n} \in [f - \delta, f + \delta]) = f^k.$$

习题 12.5. 在例 12.2 的模型假定下, 试证明: 对任意 $f \in (0, 1)$

- (i) $\lim_{\delta \downarrow 0} \lim_{n \rightarrow \infty} \mathbb{P}(X_1 = 1 \mid \frac{S_n}{n} \in [f - \delta, f + \delta]) = f$;
- (ii) $\lim_{\delta \downarrow 0} \lim_{n \rightarrow \infty} \mathbb{P}(X_{n+1} = 1 \mid \frac{S_n}{n} \in [f - \delta, f + \delta]) = f$;
- (iii) 把假设 $\xi \sim U(0, 1)$ 换为 $\xi \sim \rho(p)dp$, 其中 ρ 是连续函数, 且 $\rho(f) > 0$, 则上述结论 (i)、(ii) 仍然成立。

习题 12.6. 记可测空间 $(E, \mathcal{B}_E)$ 上概率测度的全体为 $\mathcal{M}_+^1(E)$. 任给两个概率测度 $\mu, \nu \in \mathcal{M}_+^1(E)$, 它们之间的相对熵定义为

$$H(\mu|\nu) := \begin{cases} \int \ln \frac{d\mu}{d\nu} d\mu, & \text{如果 } \mu \ll \nu, \\ \infty, & \text{其他.} \end{cases}$$

请证明:

- (1) $H(\mu|\nu) \geq 0$ 总成立;
- (2) $H(\cdot|\nu)$ 是凸函数, 即对 $\alpha \in [0, 1], \mu_1, \mu_2 \in \mathcal{M}_+^1(E)$, 总有

$$H(\alpha\mu_1 + (1 - \alpha)\mu_2|\nu) \leq \alpha H(\mu_1|\nu) + (1 - \alpha)H(\mu_2|\nu);$$

- (3) $H(\mu|\cdot)$ 也是凸函数;
- (4) 给定 $\nu \in \mathcal{M}_+^1(E)$ 及可测函数 $\varphi: E \rightarrow \mathbb{R}$, 在约束 $\int \varphi d\mu = a$ 下, 如果存在常数 β, Z 使得 $\frac{d\nu^*}{d\nu} := \frac{e^{-\beta\varphi}}{Z}$ 定义了一个概率测度 $\nu^* \in \mathcal{M}^1(E)$, 并且 $\int \varphi d\nu^* = a$, 那么

$$H(\mu|\nu^*) = H(\mu|\nu) + \beta \int \varphi d\mu + \ln Z,$$

进而 $H(\mu|\nu)$ 的极小值点恰为 $\mu = \nu^*$.

习题 12.7. 对于离散型随机变量 $X \sim \begin{pmatrix} 1 & \cdots & N \\ p_1 & \cdots & p_N \end{pmatrix}$, 定义熵

$$H(X) = H(p) := - \sum_{i=1}^N p_i \ln p_i.$$

给定两个随机变量 ξ, η , 当条件分布律 $\xi|\eta = x$ 总是几乎处处为离散分布律时, 定义 ξ 关于 η 的条件熵¹为 $H(\xi|\eta) := \mathbb{E}[H(\xi|\eta = x)]$. 求证:

¹这里我们使用了与相对熵相同的记号来表达条件熵; 但需要注意的是条件熵是两个随机变量的泛函, 而相对熵是两个概率测度的泛函, 因此本质上并不会因为记号而产生混乱。

- (1) 总有 $H(X) \geq 0$, 取等条件为: X 几乎处处为常数;
- (2) 总有 $H(X) \leq \ln N$, 当 $N < \infty$ 时取等条件为: X 服从 N 个点上的均匀分布, 即此时离散均匀分布是最大熵分布;
- (3) 在约束: $\mathbb{P}(X \in \mathbb{Z}, X \geq 1) = 1$, 且 $\mathbb{E}X = \frac{1}{p}$ 下, $H(X)$ 的最大值点满足 $X \sim \text{Geo}(p)$, 即此时几何分布是最大熵分布;
- (4) 对任意函数 φ , $H(\varphi(X)) \leq H(X)$, 等号成立当且仅当 φ 是 X 的真实值域 $\text{Range}(X) := \{x : \mathbb{P}(X = x) > 0\}$ 上的单射;
- (5) 当 ξ, η 均服从离散型分布时, $H(\xi|\eta) \leq H(\xi)$, 等号成立当且仅当 ξ, η 相互独立;
- (6) 当 ξ, η 均服从离散型分布时, $H(\xi, \eta) = H(\eta) + H(\xi|\eta) \leq H(\xi) + H(\eta)$.

习题 12.8. 对于连续型随机变量 $X \sim \rho(x)\mathrm{d}x$, 定义“熵”

$$S(X) = S(\rho) := - \int \rho(x) \ln \rho(x) \mathrm{d}x = \mathbb{E}[-\ln \rho(X)].$$

求证:

- (1) 对任意实数 $a, k \neq 0$, $S(X - a) = S(X)$, 但 $S(kX) = S(X) + \ln |k|$;
- (2) 存在连续型随机变量 X, Y , 使得 $S(X) < 0, S(Y) > 0$;
- (3) 在约束: X 是非负随机变量, 且 $\mathbb{E}X = 1$ 下, $S(X)$ 的最大值点满足 $X \sim \mathcal{E}(1)$, 即此时 (标准) 指数分布是最大熵分布;
- (4) 在约束: $\mathbb{E}X = 0, \mathbb{E}[X^2] = 1$ 下, $S(X)$ 的最大值点满足 $X \sim N(0, 1)$, 即此时 (标准) 正态分布是最大熵分布。

习题 12.9. 对于上一题的 (3) 中对应约束条件改为 $\mathbb{E}X = \mu > 0$, 对应的最大熵分布是什么? 上一题的 (4) 中对应约束条件修改为 $\mathbb{E}X = \mu, \text{Var}(X) = \sigma^2$, 对应的最大熵分布是什么?

习题 12.10. 本题用于补充证明定理 12.2.4—12.2.5 所需的有关线性代数理论。

- (1) 设 A 是 $n \geq 2$ 阶方阵, I_n 是 n 阶单位阵, 请证明:

$$A^2 = A \Leftrightarrow \text{rank}(A) + \text{rank}(I_n - A) = n;$$

- (2) 设 A_1, A_2 都是 n 阶实对称、非负定矩阵, $A := A_1 + A_2$. 如果 $A_1^2 = A_1, A^2 = A$, 求证: $A_2^2 = A_2$, 且 $A_1 A_2 = A_2 A_1 = 0$.

附录 A 单调类定理与乘积概率测度的存在唯一性及其应用

在本附录章节，我们将介绍单调类定理，并补充讲义正文中两个结果的证明：（1）乘积概率测度的存在唯一性的证明；（2）随机变量相互独立性的刻画定理（即定理5.1.2）的证明。

为此目的，我们需要在 §A.1 中简单介绍一些重要的集合类，之后在 §A.2 中介绍单调类定理。最后，我们在 §A.3 中给出乘积概率测度的存在唯一性的证明，在 §A.4 中给出定理5.1.2的补充证明。

A.1 集合类简介

下面给出一些集合类的定义，它们通常在某些集合运算下具有封闭性。以下设 Ω 为非空集合， $\mathcal{E} \subset 2^\Omega$ 为其上一集合系/集合类/集族。

在第二章已经给出了 σ -代数的概念，在第四章也给出了 π -系、半环、环、代数等概念（见定义4.2.4—4.2.6）；这里重新陈述如下。

定义 A.1.1. $\mathcal{E}$ 称为 σ -代数 (σ -algebra) 或 σ -域 (σ -field)，如果它满足

(i) $\Omega \in \mathcal{E}$ ；（此条类似于代数学中群等结构的“幺元”的要求；）

(ii) 补运算封闭：如果 $A \in \mathcal{E}$ ，则 $A^c \in \mathcal{E}$ ；

(iii) 可列并运算封闭：如果 $A_n \in \mathcal{E}, n \in \mathbb{N}$ ，则 $\bigcup_{n \in \mathbb{N}} A_n \in \mathcal{E}$ 。

不难知道， σ -代数 $\mathcal{E}$ 也关于可列交运算封闭。

把上述 σ -代数定义中的第三条提及的“可列并运算封闭”减弱为“有限并运算封闭”，就得到代数的概念，叙述如下：

定义 A.1.2. $\mathcal{E}$ 称为代数 (Algebra) 或域 (Field)，如果它满足

(i) $\Omega \in \mathcal{E}$;

(ii) 如果 $A \in \mathcal{E}$, 则 $A^c \in \mathcal{E}$;

(iii) 如果 $A, B \in \mathcal{E}$, 则 $A \cup B \in \mathcal{E}$.

显然代数对集合并、交、补、差运算有限封闭。上述 (i) — (iii) 也等价于

$$\Omega \in \mathcal{E} \text{ 及 } (A, B \in \mathcal{E} \Rightarrow A \setminus B \in \mathcal{E}).$$

事实上, $A^c = \Omega \setminus A$, $A \cup B = (A^c \cap B^c)^c = \Omega \setminus [(\Omega \setminus A) \setminus B]$.

很多场合我们关心的概率/测度只在一些简单的事件/集合上能知道其取值或有计算办法; 复杂事件/集合上的概率/测度值需要复杂的手续才能求出。一个经典例子是我们经常遇到的 $\mathbb{R}$ 上的 Lebesgue 测度 Leb , 它在区间 $(a, b]$ (其中 $a \leq b$) 上的测度值就是区间长度值 $b - a$; 立足于这些特殊集合上的测度取值就能在一定意义下唯一确定 Lebesgue 测度。而区间的全体 $\mathcal{E} := \{(a, b] : a \leq b\}$ 所具有的性质, 可以抽象为下文所谓的“ π 系”及“半环”概念:

定义 A.1.3. $\mathcal{E}$ 称为 π -系 (π -system), 如果 $A, B \in \mathcal{E}$ 蕴含了 $A \cap B \in \mathcal{E}$. 在此基础上, π -系 $\mathcal{E}$ 进一步称为半环 (Semi-ring)¹, 如果 $A, B \in \mathcal{E}$ 蕴含了: 存在 $\mathcal{E}$ 中两两不交的有限集合列 $\{A_k \in \mathcal{E}\}_{k=1}^n$, 使得 $A \setminus B = \biguplus_{k=1}^n A_k$.

注意, 对半环 $\mathcal{E}$, $A, B \in \mathcal{E}$ 时, 未必有 $A \setminus B \in \mathcal{E}$! 即, 对于半环, 集合的差运算未必封闭。

如果半环定义中的后一条修改成“集合的差运算封闭”, 再补充上“集合的并运算封闭”就得到了环的概念, 陈述如下:

定义 A.1.4. $\mathcal{E}$ 称为环 (Ring), 如果它满足

(i) $A, B \in \mathcal{E}$, 则 $A \cap B \in \mathcal{E}$;

(ii) $A, B \in \mathcal{E}$, 则 $A \cup B \in \mathcal{E}$;

(iii) $A, B \in \mathcal{E}$, 则 $A \setminus B \in \mathcal{E}$.

容易知道, 代数就是包含了全空间 Ω 的环; 因此有些文献也称环为预代数 (pre-algebra) .

在求复杂事件/集合的概率/测度过程中, 经常要使用取极限的办法。为此目的, 我们还需引入如下几类集合系的概念。

¹在文献^[29]中有比半环定义略苛刻的半代数 (Semialgebra) 的定义, 其中后一条件替换成了: 集合系中元素的补集可以表达成集合系内部有限个元素的不交并; 这隐含了集合系中存在全空间的有限覆盖的要求。因此, 本书例 A.2 中集合类 $\mathcal{E}_1$ 不满足^[29]中的半代数 (Semialgebra) 的要求。

定义 A.1.5. 称 $\mathcal{E}$ 为单调系 (Monotone System), 如果它满足

- (i) 如果 $A_n \in \mathcal{E}, n \in \mathbb{Z}^+$, 且 $A_n \uparrow A$, 则 $A \in \mathcal{E}$;
- (ii) 如果 $A_n \in \mathcal{E}, n \in \mathbb{Z}^+$, 且 $A_n \downarrow A$, 则 $A \in \mathcal{E}$.

定义 A.1.6. 称 $\mathcal{E}$ 为 λ -系或 D -系 (λ -System/Dynkin System), 如果它满足

- (i) $\Omega \in \mathcal{E}$;
- (ii) 如果 $A \in \mathcal{E}$, 则 $A^c \in \mathcal{E}$;
- (iii) 如果 $A_n \in \mathcal{E}, n \in \mathbb{Z}^+$, 且它们互不相交, 则 $\bigcup_{n=1}^{\infty} A \in \mathcal{E}$.

容易知道, λ -系一定是单调系。

注记 A.1. λ -系 $\mathcal{E}$ 也可等价地定义为具有性质 (i) 及下面性质 (ii'), (iii') 的集合类:

- (ii') 如果 $A, B \in \mathcal{E}$, 且 $B \subset A$, 则 $A \setminus B \in \mathcal{E}$;
- (iii') 如果 $A_n \in \mathcal{E}, n \in \mathbb{Z}^+$, 且 $A_n \uparrow A$, 则 $A \in \mathcal{E}$.

注记 A.2. 设 Ω 是非空集合, $\mathcal{E}$ 是 Ω 上集合系。

- (1) 所有包含 $\mathcal{E}$ 的环的交集仍然是环, 记作 $R(\mathcal{E})$, 称为由 $\mathcal{E}$ 生成的环;
- (2) 所有包含 $\mathcal{E}$ 的代数的交集仍然是代数, 记作 $\mathcal{A}(\mathcal{E})$, 称为由 $\mathcal{E}$ 生成的代数;
- (3) 所有包含 $\mathcal{E}$ 的 σ -代数的交集仍然是 σ -代数, 记作 $\sigma(\mathcal{E})$, 称为由 $\mathcal{E}$ 生成的 σ -代数;
- (4) 所有包含 $\mathcal{E}$ 的 λ -系的交集仍然是 λ -系, 记作 $\lambda(\mathcal{E})$, 称为由 $\mathcal{E}$ 生成的 λ -系;
- (5) 所有包含 $\mathcal{E}$ 的单调系的交集仍然是单调系, 记作 $m(\mathcal{E})$, 称为由 $\mathcal{E}$ 生成的单调系。

有时为强调上述“生成”运算是在全空间 Ω 中进行的, 我们在对应算符 $R, \mathcal{A}, \sigma, \lambda, m$ 上附加下标 Ω , 即有: $R_{\Omega}(\mathcal{E}), \mathcal{A}_{\Omega}(\mathcal{E}), \sigma_{\Omega}(\mathcal{E}), \lambda_{\Omega}(\mathcal{E}), m_{\Omega}(\mathcal{E})$ 等记号。

例 A.1. 设 Ω 为非空集合, $\mathcal{E} := 2^{\Omega}$, 它是 σ -代数。

例 A.2. (同例 4.4) $\Omega = \mathbb{R}$, $\mathcal{E}_1 := \{(a, b] : -\infty < a \leq b < \infty\}$,

$$\mathcal{E}_2 := \{E = \bigcup_{k=1}^n A_k : n \in \mathbb{N}, \{A_k\}_{k=1}^n \subset \mathcal{E}_1 \text{ 是两两不交的集合列}\}.$$

则 $\mathcal{E}_1$ 是 π -系、半环, 但不是环; $\mathcal{E}_2$ 是环, 但不是代数。 $\mathcal{E}_2$ 恰好是 $\mathcal{E}_1$ 生成的环: $\mathcal{E}_2 = R(\mathcal{E}_1)$.

例 A.3. $\Omega = \mathbb{R}$, $\mathcal{E}_1 := \mathbb{R}$ 上 Borel 可测集全体, $\mathcal{E}_2 := \mathbb{R}$ 上 Lebesgue 可测集全体。 $\mathcal{E}_1, \mathcal{E}_2$ 都是 σ -代数, 且 $\mathcal{E}_1 \subset \mathcal{E}_2$.

例 A.4. 设 Ω 为一个无穷集合, $\mathcal{E} := \{A \subset \Omega : A \text{ 可数或 } A^c \text{ 可数}\}$. $\mathcal{E}$ 是 σ -代数。(相关习题: 习题 2.10、2.11.)

定义 A.1.7. 设 Ω 为一拓扑空间。由 Ω 上所有开集生成的 σ -代数, 称为 Ω 上 *Borel* σ -代数, 记作 $\mathcal{B}(\Omega)$.

例 A.5. $\Omega = \mathbb{R}$, $\mathcal{E} := \mathbb{R}$ 上开集全体, $\mathcal{E}_0 := \{(a, b) : -\infty < a < b < \infty\}$, $\mathcal{E}'_0 := \{(a, b) : a < b, a, b \in \mathbb{Q}\}$. 那么 $\sigma(\mathcal{E}) = \sigma(\mathcal{E}_0) = \sigma(\mathcal{E}'_0) = \mathcal{B}(\mathbb{R})$.

注意到例A.5告诉我们, $\mathbb{R}$ 上的 Borel σ -代数可以通过一个可数个元素的集族生成, 为此我们称 $\mathbb{R}$ 上的 Borel σ -代数是可数生成的。我们可以进一步引入一般的 σ -代数的可数生成概念。

定义 A.1.8. 设 $\mathcal{F}$ 是 Ω 上 σ -代数。若存在可数子集 $\mathcal{E} = \{A_n : n \in \mathbb{N}\} \subset \mathcal{F}$, 使得 $\mathcal{F} = \sigma(\mathcal{E})$, 则称 $\mathcal{F}$ 为可数生成的。有时 σ -代数的可数生成也称为可分。

例 A.6. 当 Ω 是不可数集时, 例A.4中定义的 σ -代数 $\mathcal{F}$ 不是可数生成的。

♣ 注记 A.3. 当拓扑空间 Ω 有可数邻域基时, $\mathcal{B}(\Omega)$ 就是可数生成的。

例 A.7. 设 $\bar{\mathbb{R}} := \mathbb{R} \cup \{\pm\infty\}$ 为广义实数集 (把 $\pm\infty$ 视作区别于普通实数的两个不同点), 具有相应的诱导拓扑。记 $\bar{\mathcal{B}} := \mathcal{B}(\bar{\mathbb{R}})$ 为 $\bar{\mathbb{R}}$ 上 Borel σ -代数, 它仍然是可数生成的。我们称 $(\bar{\mathbb{R}}, \bar{\mathcal{B}})$ 为广义实数空间。

A.2 单调类定理

下面我们探讨刚刚定义的几个集合系与更早定义的 σ -代数之间的关系。

♠ 定理 A.2.1. 设 $\mathcal{F}$ 是空间 Ω 上一集合系。

(1) $\mathcal{F}$ 是单调系, 又是代数 $\iff \mathcal{F}$ 是 σ -代数;

(2) $\mathcal{F}$ 是 λ -系, 又是 π -系 $\iff \mathcal{F}$ 是 σ -代数。

证明: 从定义出发即可证明。(留作习题A.1.) □

♠ 定理 A.2.2. (单调类定理) 设 $\mathcal{E}, \mathcal{F}$ 是空间 Ω 上集合系, 且 $\mathcal{E} \subset \mathcal{F}$.

(1) 如果 $\mathcal{E}$ 是代数, $\mathcal{F}$ 是单调系, 那么 $\sigma(\mathcal{E}) \subset \mathcal{F}$;

(2) 如果 $\mathcal{E}$ 是 π -系, $\mathcal{F}$ 是 λ -系, 那么 $\sigma(\mathcal{E}) \subset \mathcal{F}$.

证明: 此处只给出 (1) 的证明。(2) 的证明留作习题A.2. 本质上我们只需要证明: $\sigma(\mathcal{E}) = m(\mathcal{E})$. 显然 $\sigma(\mathcal{E}) \supset \mathcal{E}$, 由定理A.2.1, 应有 $\sigma(\mathcal{E}) \supset m(\mathcal{E})$. 下面证明 $\sigma(\mathcal{E}) \subset m(\mathcal{E})$. 注意到 $\mathcal{E} \subset m(\mathcal{E})$, 同样由定理A.2.1, 只需要证明 $m(\mathcal{E})$ 是一个代数即可。

(i) 令 $\mathcal{E}_1 := \{A \in m(\mathcal{E}) : A^c \in m(\mathcal{E}), A \cup B \in m(\mathcal{E}), \forall B \in \mathcal{E}\}$. 以下验证 $\mathcal{E}_1$ 是一个单调类。设 $A_n \in \mathcal{E}_1$ 且 $A_n \nearrow A$ (或 $A_n \searrow A$). 那么 $A_n, A_n^c \in m(\mathcal{E})$, 此时 $A, A^c \in m(\mathcal{E})$. 进而对任意 $B \in \mathcal{E}$, $A_n \cup B \in m(\mathcal{E})$, $A_n \cup B \nearrow A \cup B \in m(\mathcal{E})$ (或 $A_n \cup B \searrow A \cup B \in m(\mathcal{E})$), 于是 $A \cup B \in m(\mathcal{E})$, 即 $A \in \mathcal{E}_1$. 从而 $\mathcal{E}_1$ 是单调类, 注意到 $\mathcal{E} \subset \mathcal{E}_1 \subset m(\mathcal{E})$, 有 $\mathcal{E}_1 = m(\mathcal{E})$. 这表明: (i) $m(\mathcal{E})$ 关于集合的补运算封闭; (ii) 对任意 $A \in m(\mathcal{E}), B \in \mathcal{E}$, 总有 $A \cup B \in m(\mathcal{E})$.

(ii) 令 $\mathcal{E}_2 := \{A \in m(\mathcal{E}) : A \cup B \in m(\mathcal{E}), \forall B \in m(\mathcal{E})\}$. (i) 中已证明 $\mathcal{E} \subset \mathcal{E}_2$. 同上易证 $\mathcal{E}_2$ 也是一个单调类, 从而类似导出 $\mathcal{E}_2 = m(\mathcal{E})$. 这表明 $m(\mathcal{E})$ 关于集合并运算封闭. 于是 $m(\mathcal{E})$ 是一个代数, 进而是一个 σ -代数. $\square$

注记 A.4. 上面的论证方法称为**范畴法**, 是数学中论证某些族具有某种特殊结构或性质的常用方法。另外, 上面的单调类定理非常重要, 在本讲义有关积分或数学期望等的讨论中读者会看到它的威力。

A.3 乘积概率测度的存在唯一性

本节讨论概率测度的乘积测度的存在唯一性, 分三种情况递进展开存在唯一性的证明: 有限乘积、可列无穷乘积、任意无穷乘积。

A.3.1 概率测度的有限乘积

本小节我们将给出有限个概率测度的乘积测度的存在唯一性的证明。

我们在第三章定义两个概率空间 $\{(\Omega_k, \mathcal{F}_k, \mathbb{P}_k)\}_{k=1}^2$ 的乘积空间时, 定义

$$\mathbb{P}_1 \otimes \mathbb{P}_2(A_1 \times A_2) := \mathbb{P}_1(A_1) \cdot \mathbb{P}_2(A_2), A_1 \in \mathcal{F}_1, A_2 \in \mathcal{F}_2.$$

在那里我们断言 $\mathbb{P}_1 \otimes \mathbb{P}_2$ 可以唯一延拓为 $(\Omega_1 \times \Omega_2, \mathcal{F}_1 \otimes \mathcal{F}_2)$ 上的概率测度, 其中 $\mathcal{F}_1 \otimes \mathcal{F}_2 := \sigma(\mathcal{F}_1 \times \mathcal{F}_2)$. 这里我们需要使用 Carathéodory 扩张定理和它后续的扩张唯一性定理; 在第四章中我们已经看到, 在这两个定理的证明中都需要使用单调类定理, 此处我们补充相关证明细节。

以下将证明: (1) $\mathcal{F}_1 \times \mathcal{F}_2$ 是半环, 记它生成的环为 $\mathcal{E}$ (它实际上是代数); (2) $\mathbb{P}_1 \otimes \mathbb{P}_2$ 在 $\mathcal{E}$ 上具有有限可加性和 σ -可加性, 从而它可以视作 $\mathcal{E}$ 上的预测度; (3) 这个预测度是有限预测度 (从而自然是 σ -有限的). 以上三点就确保了可以应用 Carathéodory 扩张定理和扩张唯一性定理来论证乘积概率测度的唯一确定性。

对 (1) 的验证如下。首先, 对任意 $A = A_1 \times A_2, B = B_1 \times B_2 \in \mathcal{F}_1 \times \mathcal{F}_2$, 容易知道 $A_1 \cap B_1 \in \mathcal{F}_1, A_2 \cap B_2 \in \mathcal{F}_2$, 进而

$$A \cap B = (A_1 \times A_2) \cap (B_1 \times B_2) = (A_1 \cap B_1) \times (A_2 \cap B_2) \in \mathcal{F}_1 \times \mathcal{F}_2.$$

这表明 $\mathcal{F}_1 \times \mathcal{F}_2$ 是 π -系。注意到 $(B_1 \times B_2)^c = (B_1^c \times \Omega_2) \dot{\cup} (B_1 \times B_2^c)$,

$$A \setminus B = [(A_1 \cap B_1^c) \times A_2] \dot{\cup} [(A_1 \cap B_1) \times (A_2 \cap B_2^c)],$$

显然 $(A_1 \cap B_1^c) \times A_2$ 、 $(A_1 \cap B_1) \times (A_2 \cap B_2^c)$ 都是 $\mathcal{F}_1 \times \mathcal{F}_2$ 中元素, 因此 $\mathcal{F}_1 \times \mathcal{F}_2$ 是半环。

现验证 (2). $\mathbb{P}_1 \otimes \mathbb{P}_2$ 的非负性显然, 同时 $\emptyset = \emptyset \times \emptyset$, $\mathbb{P}_1 \otimes \mathbb{P}_2(\emptyset) = 0$. 以下验证 σ -可加性。

先验证 $\mathbb{P}_1 \otimes \mathbb{P}_2$ 在 $\mathcal{F}_1 \times \mathcal{F}_2$ 上的有限可加性, 再由此论证它在 $\mathcal{E}$ 上的有限可加性。设 $A \in \mathcal{F}_1, B \in \mathcal{F}_2$, 且存在 $\{A_k \neq \emptyset\}_{k=1}^N \subset \mathcal{F}_1, \{B_k \neq \emptyset\}_{k=1}^N \subset \mathcal{F}_2$ (其中 $2 \leq N < \infty$) 使得 $A \times B = \biguplus_{k=1}^N (A_k \times B_k)$. 那么, 应有 $A_k \subset A, B_k \subset B, \forall k$, 并且 $\{A_k\}_{k=1}^N, \{B_k\}_{k=1}^N$ 分别是 A 与 B 的覆盖。考察

$$\mathcal{E}_A := \sigma_A(\{A_k : 1 \leq k \leq N\}), \quad \mathcal{E}_B := \sigma_B(\{B_k : 1 \leq k \leq N\}).$$

不难知道: $\mathcal{E}_A$ 中存在 A 的有限分割 $\{C_i \neq \emptyset\}_{i=1}^m$ 生成 σ -代数 $\mathcal{E}_A \subset \mathcal{F}_1$, $\mathcal{E}_B$ 中存在 B 的有限分割 $\{D_j \neq \emptyset\}_{j=1}^n$ 生成 σ -代数 $\mathcal{E}_B \subset \mathcal{F}_2$, 其中 $m, n \leq N$. 于是对任意 $1 \leq k \leq N$, 存在非空指标集 I_k, J_k , 使得

$$A_k = \biguplus_{i \in I_k} C_i, \quad A = \biguplus_{i=1}^m C_i, \quad B_k = \biguplus_{j \in J_k} D_j, \quad B = \biguplus_{j=1}^n D_j.$$

于是 $A_k \times B_k = \biguplus_{(i,j) \in I_k \times J_k} (C_i \times D_j)$, $A \times B = \biguplus_{1 \leq k \leq N} \biguplus_{(i,j) \in I_k \times J_k} (C_i \times D_j)$. 注意到 $A \times B = \biguplus_{1 \leq i \leq m} \biguplus_{1 \leq j \leq n} (C_i \times D_j)$, 且 $C_i \times D_j$ 均非空, 实际上 $\{I_k \times J_k : 1 \leq k \leq N\}$ 形成 $I \times J$ 的分割, 其中 $I := \{i : 1 \leq i \leq m\}, J := \{j : 1 \leq j \leq n\}$. 于是自然有

$$\begin{aligned} \mathbb{P}_1 \otimes \mathbb{P}_2(A \times B) &:= \mathbb{P}_1(A) \cdot \mathbb{P}_2(B) \\ &= \left[\sum_{i=1}^m \mathbb{P}_1(C_i) \right] \cdot \left[\sum_{j=1}^n \mathbb{P}_2(D_j) \right] \\ &= \sum_{1 \leq i \leq m} \sum_{1 \leq j \leq n} \mathbb{P}_1 \otimes \mathbb{P}_2(C_i \times D_j) \\ &= \sum_{k=1}^N \sum_{(i,j) \in I_k \times J_k} \mathbb{P}_1 \otimes \mathbb{P}_2(C_i \times D_j) \\ &= \sum_{k=1}^N \mathbb{P}_1 \otimes \mathbb{P}_2(A_k \times B_k), \end{aligned}$$

即 $\mathbb{P}_1 \otimes \mathbb{P}_2$ 在 $\mathcal{F}_1 \times \mathcal{F}_2$ 上具有有限可加性。注意到 $\mathcal{E}$ 是半环 $\mathcal{F}_1 \times \mathcal{F}_2$ 生成的环, $\mathbb{P}_1 \otimes \mathbb{P}_2$ 在 $\mathcal{E}$ 上的有限可加性是它在 $\mathcal{F}_1 \times \mathcal{F}_2$ 上的有限可加性的简单推论。

同理, 为验证 $\mathbb{P}_1 \otimes \mathbb{P}_2$ 在 $\mathcal{E}$ 上的 σ -可加性, 我们只需验证它在 $\mathcal{F}_1 \times \mathcal{F}_2$ 上的 σ -可加性如下。假定上一段论证中 $N = \infty$, 即 $A \times B = \bigcup_{k=1}^{\infty} (A_k \times B_k)$. 注意到 $\mathcal{F}_1 \times \mathcal{F}_2$ 是半环, $\mathcal{E}$ 是它生成的环, 我们知道对任意 $M \in \mathbb{N}$,

$$(A \times B) \setminus \bigcup_{k=1}^M (A_k \times B_k) \in \mathcal{E},$$

即存在 $M' \in \mathbb{N}, A'_j \in \mathcal{F}_1, B'_j \in \mathcal{F}_2, j = 1, \dots, M'$, 使得

$$\bigcup_{k=M+1}^{\infty} (A_k \times B_k) = \bigcup_{j=1}^{M'} (A'_j \times B'_j).$$

于是由上一段中已论证结果, 对任意 $M \in \mathbb{N}$

$$\mathbb{P}(A \times B) = \sum_{k=1}^M \mathbb{P}(A_k \times B_k) + \mathbb{P}\left(\bigcup_{k=M+1}^{\infty} (A_k \times B_k)\right).$$

此时必定有 $\sum_{k=1}^{\infty} \mathbb{P}(A_k \times B_k) < \infty$, 进而¹

$$\mathbb{P}\left(\bigcup_{k=M+1}^{\infty} (A_k \times B_k)\right) \leq \sum_{k=M+1}^{\infty} \mathbb{P}(A_k \times B_k) \rightarrow 0.$$

即 $\mathbb{P}(A \times B) = \sum_{k=1}^{\infty} \mathbb{P}(A_k \times B_k) < \infty$.

最后验证 (3), 这是显然的, 因为 $\mathbb{P}_1 \otimes \mathbb{P}_2(\Omega_1 \times \Omega_2) = 1 < \infty$.

需要说明的是, 以上证明略作修改也适用于两个 σ -有限测度 μ, ν 的乘积测度 $\mu \otimes \nu$ 的存在唯一性的证明。

A.3.2 概率测度的可列无穷乘积

本小节我们将给出可列无穷个概率测度的乘积测度的存在唯一性的证明; 此处我们参考了程士宏教授的著作.^[106]

我们首先把结果表述如下。设 $\{(\Omega_k, \mathcal{F}_k, \mathbb{P}_k)\}_{k=1}^{\infty}$ 为可列个概率空间。我们按照下面的 (a) —(c) 中方式定义这无穷个概率空间的乘积空间

$$(\Omega, \mathcal{F}, \mathbb{P}) := \bigotimes_{k=1}^{\infty} (\Omega_k, \mathcal{F}_k, \mathbb{P}_k).$$

¹ 此处需要注意, 按照 Carathéodory 扩张的流程, $\mathbb{P}$ 同时被视作预测度诱导的外测度而自动具有 σ -次可加性。

(a) 定义无穷乘积相空间如下。取

$$\Omega = \prod_{k=1}^{\infty} \Omega_k := \{\omega := (\omega_1, \omega_2, \dots) : \omega_k \in \Omega_k, k = 1, 2, \dots\}$$

作为样本空间, 这给出了可列无穷个相空间的乘积相空间; 有时我们也简单记 $(\omega_1, \omega_2, \dots) =: (\omega_k : k \in \mathbb{N})$.

(b) 定义无穷乘积可测结构如下。

(b1) 对任意非空的有限子集 $I \subset \mathbb{N}$, 根据上一节的结果, 我们可以定义乘积概率空间

$$(\Omega^{(I)}, \mathcal{F}^{(I)}, \mathbb{P}^{(I)}) := \bigotimes_{k \in I} (\Omega_k, \mathcal{F}_k, \mathbb{P}_k),$$

其中 $\Omega^{(I)} := \prod_{k \in I} \Omega_k$, $\mathcal{F}^{(I)} := \bigotimes_{k \in I} \mathcal{F}_k$, $\mathbb{P}^{(I)} := \bigotimes_{k \in I} \mathbb{P}_k$. 此外我们还可以定义自然投影 π_I

$$\pi_I : \Omega \rightarrow \Omega^{(I)}, \quad \omega := (\omega_k : k \in \mathbb{N}) \mapsto \pi_I(\omega) = \omega^{(I)} := (\omega_k : k \in I).$$

更一般地, 如果 $J \subset I$, 我们还可以定义自然投影 π_J^I

$$\pi_J^I : \Omega^{(I)} \rightarrow \Omega^{(J)}, \quad \omega^{(I)} := (\omega_k : k \in I) \mapsto \pi_J^I(\omega^{(I)}) = \omega^{(J)} := (\omega_k : k \in J).$$

容易知道, 当 I, J 都是有限的非空指标集时, 如果 $J \subset I$, 则

$$\pi_J^I : (\Omega^{(I)}, \mathcal{F}^{(I)}, \mathbb{P}^{(I)}) \rightarrow (\Omega^{(J)}, \mathcal{F}^{(J)}, \mathbb{P}^{(J)})$$

是保测映射。

(b2) 对任意有限的非空指标集 $I \subset \mathbb{N}$ 及任意 $A \in \mathcal{F}^{(I)}$, 我们称 $\pi_I^{-1}(A) \subset \Omega$ 是以 A 为基底、以 I 为基底指标集的 (有限维) **柱集**; 记

$$\mathcal{E}_I := \{\pi_I^{-1}(A) : A \in \mathcal{F}^{(I)}\} = \pi_I^{-1}(\mathcal{F}^{(I)}),$$

它是 Ω 上的一个 σ -代数。进一步令

$$\mathcal{E} := \bigcup_{\text{有限集 } I \subset \mathbb{N}} \mathcal{E}_I,$$

它是 Ω 中 (有限维) 柱集的全体, 一般而言它不再是 σ -代数, 但不难证明它是 Ω 上的一个代数。此时, 再令

$$\mathcal{F} = \bigotimes_{k=1}^{\infty} \mathcal{F}_k := \sigma(\mathcal{E}).$$

这给出了可列无穷个可测结构的乘积可测结构。

(c) 最后定义可列无穷个概率测度的乘积概率测度如下：对任意 $B \in \mathcal{E}$ ，存在有限的非空指标集 $I \subset \mathbb{N}$ 及可测集 $A \in \mathcal{F}^{(I)}$ 使得 $B = \pi_I^{-1}(A)$. 此时我们就定义 $\mathbb{P}(B) := \mathbb{P}^{(I)}(A)$ ，即

$$\mathbb{P}(\pi_I^{-1}(A)) := \mathbb{P}^{(I)}(A), \quad \text{其中 } I \text{ 是有限集, } A \in \mathcal{F}^{(I)}. \quad (\text{A.1})$$

我们断言：上述方程定义了代数 $\mathcal{E}$ 上的一个预测度，它显然满足 $\mathbb{P}(\Omega) = 1$ ，从而由 Carathéodory 扩张定理和扩张唯一性定理，这也定义了 $\mathcal{F} = \sigma(\mathcal{E})$ 上唯一的概率测度，由此就完成了可列无穷个概率测度的乘积概率测度的定义。

(c) 中断言的证明. 首先要说明的是：按照(A.1)来定义 $\mathbb{P} : \mathcal{E} \rightarrow [0, 1]$ ，这是良定义的。为此我们只需证明：当 $B \in \mathcal{E}$ 有以下两种不同表示

$$B = \pi_{I_1}^{-1}(A_1) = \pi_{I_2}^{-1}(A_2)$$

时，假设其中 I_1, I_2 都是有限集，且 $A_1 \in \mathcal{F}^{(I_1)}, A_2 \in \mathcal{F}^{(I_2)}$ ，那么

$$\mathbb{P}^{(I_1)}(A_1) = \mathbb{P}^{(I_2)}(A_2).$$

而这是因为此时

$$B = \{\omega \in \Omega : \omega^{(I_1)} \in A_1\} = \{\omega \in \Omega : \omega^{(I_2)} \in A_2\}.$$

取 $I := I_1 \cup I_2$ ，则有 $A = (\pi_I^I)^{-1}(A_1) \in \mathcal{F}^{(I)}$ ，满足 $B = \pi_I^{-1}(A)$ ，并且此时同样还有 $A = (\pi_I^I)^{-1}(A_2)$. 于是 $\pi_{I_1}^I, \pi_{I_2}^I$ 的保测性告诉我们

$$\mathbb{P}^{(I_1)}(A_1) = \mathbb{P}^{(I)}(A) = \mathbb{P}^{(I_2)}(A_2).$$

其次我们说明 $\mathbb{P} : \mathcal{E} \rightarrow \mathbb{R}$ 是预测度。我们分成以下几条来证明。

(1) 容易看到 $\mathbb{P}(\Omega) = 1, \mathbb{P}(\emptyset) = 0$.

(2) $\mathbb{P} : \mathcal{E} \rightarrow \mathbb{R}$ 具有有限可加性：设 $B_1 := \pi_{I_1}^{-1}(A_1), B_2 := \pi_{I_2}^{-1}(A_2)$ 互斥，其中 I_1, I_2 都是有限集，且 $A_1 \in \mathcal{F}^{(I_1)}, A_2 \in \mathcal{F}^{(I_2)}$ ，那么

$$\mathbb{P}(B_1 \uplus B_2) = \mathbb{P}(B_1) + \mathbb{P}(B_2).$$

这是因为，我们可以取 $I := I_1 \cup I_2$ 及 $\tilde{A}_1, \tilde{A}_2 \in \mathcal{F}^I$ ，使得

$$B_1 = \pi_I^{-1}(\tilde{A}_1), B_2 := \pi_I^{-1}(\tilde{A}_2).$$

B_1, B_2 互斥也意味着 $\tilde{A}_1, \tilde{A}_2$ 互斥。于是

$$\mathbb{P}(B_1 \uplus B_2) = \mathbb{P}(\pi_I^{-1}(\tilde{A}_1 \uplus \tilde{A}_2))$$

$$\begin{aligned}
&= \mathbb{P}^{(I)}(\tilde{A}_1 \uplus \tilde{A}_2) = \mathbb{P}^{(I)}(\tilde{A}_1) + \mathbb{P}^{(I)}(\tilde{A}_2) \\
&= \mathbb{P}(B_1) + \mathbb{P}(B_2).
\end{aligned}$$

(3) 我们进一步证明 $\mathbb{P}$ 在 $\emptyset$ 处连续: 如果 $B_n \in \mathcal{E}$ 满足 $B_n \downarrow \emptyset$, 则 $\mathbb{P}(B_n) \rightarrow 0$. 我们假设 $\mathbb{P}(B_n) \rightarrow c > 0$, 通过反证法来证明 $B_n \downarrow \emptyset$ 不可能成立. 此时对任意正整数 $1 \leq a \leq b$, 我们简记 $\mathbb{N}$ 中指标集

$$[a, b] := \{k \in \mathbb{N} : a \leq k \leq b\}, [a, \infty) := \{k \in \mathbb{N} : k \geq a\},$$

且不妨假设 $B_n = \pi_{[1, n]}^{-1}(A_n)$, $A_n \in \mathcal{F}^{([1, n])}$, 并且由 $B_n \downarrow$ 得到

$$A_{n+1} \subset A_n \times \Omega_{n+1}, \forall n \geq 1.$$

对 $x_1 \in \Omega_1$ 及 $n \geq 2$, 记

$$B_n^{x_1} := \{y \in \Omega^{([2, \infty))} : (x_1, y) \in B_n\}, A_n^{x_1} := \{y \in \Omega^{([2, n])} : (x_1, y) \in A_n\},$$

则 $B_n^{x_1} = A_n^{x_1} \times \prod_{\ell=1}^{\infty} \Omega_{n+\ell}$, 进而

$$A_{n+1}^{x_1} \subset A_n^{x_1} \times \Omega_{n+1}, \forall n \geq 1.$$

单调类定理告诉我们, 此时 $A_n^{x_1} \in \mathcal{F}^{([2, n])}$, 进而

$$\mathbb{P}^{([2, n+1])}(A_{n+1}^{x_1}) \leq \mathbb{P}^{([2, n])}(A_n^{x_1}), \forall n \geq 1.$$

令 $g_1(x_1) := \lim_{n \rightarrow \infty} \mathbb{P}^{([2, n])}(A_n^{x_1}) = \lim_{n \rightarrow \infty} \int 1_{A_n}(x_1, y) d\mathbb{P}^{([2, n])}(y)$. 注意, 我们有

$$\mathbb{P}(B_n) = \mathbb{P}^{([1, n])}(A_n) = \int \mathbb{P}^{([2, n])}(A_n^{x_1}) d\mathbb{P}_1(x_1).$$

于是控制收敛定理告诉我们 $\int g_1(x_1) d\mathbb{P}_1(x_1) = c > 0$. 因而必定存在 $x_1^* \in \Omega_1$ 使得 $g_1(x_1^*) > 0$. 但显然

$$1_{A_1}(x_1^*) = \mathbb{P}^{([2, 2])}(A_1^{x_1^*} \times \Omega_2) \geq \mathbb{P}^{([2, n])}(A_n^{x_1^*}) \geq g_1(x_1^*) > 0,$$

进而 $x_1^* \in A_1$, 并且

$$\mathbb{P}^{([2, n])}(A_n^{x_1^*}) \geq g_1(x_1^*) > 0, \forall n \geq 1.$$

递归地, 对任意 $k \geq 2$, 我们能定义

$$g_k(x_k) := \lim_{n \rightarrow \infty} \mathbb{P}^{([k+1, n])}(A_n^{(x_1^*, \dots, x_{k-1}^*, x_k)}),$$

并且注意到

$$\lim_{n \rightarrow \infty} \int \mathbb{P}^{([k+1, n])}(A_n^{(x_1^*, \dots, x_{k-1}^*, x_k^*)}) d\mathbb{P}_k(x_k) = g_{k-1}(x_{k-1}^*),$$

我们能类似地证明存在 $x_k^* \in \Omega_k$ 使得 $g_k(x_k^*) > 0$, 从而 $(x_1^*, \dots, x_k^*) \in A_k$. 由此立即得到一个点 $x^* := (x_k^* : k \in \mathbb{N}) \in \Omega$ 满足 $x^* \in B_k = \pi_{[1, k]}^{-1}(A_k), \forall k \geq 1$. 因此 $x^* \in \bigcap_{k=1}^{\infty} B_k$, 矛盾. 这个矛盾说明, $\mathbb{P}$ 在 $\emptyset$ 处具有连续性.

由上述 (1) — (3), $\mathbb{P} : \mathcal{E} \rightarrow \mathbb{R}$ 是一个有限的预测度. $\square$

由此我们就完成了概率测度的可列无穷乘积的存在唯一性证明.

A.3.3 概率测度的任意无穷乘积

设 S 是一个具有无穷多个元素的指标集; 我们不妨设它是不可数集 (并假定它具有某个默认给定的序, 即总假定 S 是一个有序集, 从而乘积空间就是按照这个序结构来完成乘积的).

假设已有概率空间族 $\{(\Omega_\alpha, \mathcal{F}_\alpha, \mathbb{P}_\alpha)\}_{\alpha \in S}$, 本小节我们将给出乘积概率空间

$$(\Omega, \mathcal{F}, \mathbb{P}) := \bigotimes_{\alpha \in S} (\Omega_\alpha, \mathcal{F}_\alpha, \mathbb{P}_\alpha)$$

的存在唯一性的证明.

有关乘积概率空间的相空间 (样本空间) $\Omega := \prod_{\alpha \in S} \Omega_\alpha$ 、乘积可测结构 $\mathcal{F} := \bigotimes_{\alpha \in S} \mathcal{F}_\alpha$ 、乘积概率测度 $\mathbb{P} := \bigotimes_{\alpha \in S} \mathbb{P}_\alpha$ 构造方法完全与上一小节类似, 只需把上一小节中的指标集 $\mathbb{N}$ 替换为此处的 S 即可, 因此在以下的论证中也就直接引用对应推广的完全类似的形式记号与概念, 不再对此进行叙述与说明.

设 $\mathcal{E}$ 是无穷乘积空间 $\bigotimes_{\alpha \in S} (\Omega_\alpha, \mathcal{F}_\alpha, \mathbb{P}_\alpha)$ 的所有有限维柱集组成的集合, 同样不难证明它是一个代数. 集函数 $\mathbb{P} : \mathcal{E} \rightarrow \mathbb{R}$ 的良定义性、有限可加性等的证明也完全类似.

以下仅说明 $\mathbb{P}$ 具有 $\emptyset$ 处的连续性, 但这其实是简单的: 设有 $\mathcal{E} \ni B_n \downarrow \emptyset$, 那么存在有限指标集 $J_n \subset S$ 及可测集 $A_n \in \mathcal{F}^{(J_n)}$ 使得 $B_n = \pi_{J_n}^{-1}(A_n)$, 于是 $I := \bigcup_{n=1}^{\infty} J_n$ 是一个可数集, $\tilde{B}_n := (\pi_{J_n}^I)^{-1}(A_n) \in \mathcal{F}^{(I)}$, 且 $\tilde{B}_n \downarrow \emptyset$. 由概率测度 $\mathbb{P}^{(I)}$ 的连续性, 我们立即得到 $\mathbb{P}(B_n) = \mathbb{P}^{(I)}(\tilde{B}_n) \rightarrow 0$.

由上述结论, 再结合 Carathéodory 扩张定理和扩张唯一性定理就完成了乘积测度的存在唯一性的证明.

A.4 随机变量相互独立性的刻画定理的补充证明

在第五章, 我们曾提到, 定理5.1.2的证明中(5.5) $\Rightarrow$ (5.7)这部分推理可以用单调类定理来实现, 但并未提供相关细节. 在本节我们就来补全此部分的证明; 定理5.1.2的其他部分证明都是完整的, 因此在此节不再重复.

为方便, 我们只考虑 X, Y 都是一维随机变量的情况. 此时, 取

$$\mathcal{E} := \{(A, B) : A, B \in \mathcal{B}, \text{使得 } \mathbb{P}(X \in A, Y \in B) = \mathbb{P}(X \in A)\mathbb{P}(Y \in B)\},$$

及 $\mathcal{E}_A := \{B : (A, B) \in \mathcal{E}\}, \mathcal{E}^B := \{A : (A, B) \in \mathcal{E}\}.$

X, Y 相互独立, 即(5.5)成立, 这意味着对任意 $x, y \in \mathbb{R}$, 取 $A := (-\infty, x], B := (-\infty, y]$ 时, $(A, B) \in \mathcal{E}.$

对任意固定的 $A \in \mathcal{B}$, 不难验证 $\mathcal{E}_A$ 是 $\mathbb{R}$ 上的 λ -系. 当 $A := (-\infty, x]$ 时, 我们已知 $\mathcal{E}_0 := \{(-\infty, y] : y \in \mathbb{R}\} \subset \mathcal{E}_A$. 注意到 $\mathcal{E}_0$ 是一个 π -系, 并且 $\mathcal{B} = \sigma(\mathcal{E}_0)$, 由单调类定理我们立即得到 $\mathcal{B} \subset \mathcal{E}_A \subset \mathcal{B}$, 即 $\mathcal{E}_A = \mathcal{B}.$

现在, 对任意固定的 $B \in \mathcal{B}$, 同样不难验证 $\mathcal{E}^B$ 是 $\mathbb{R}$ 上的 σ -代数. 由上一步骤, 我们已知 $\mathcal{E}_0 \subset \mathcal{E}^B$. 同上逻辑立即得到 $\mathcal{E}^B = \mathcal{B}.$ 由此 $\mathcal{E} = \{(A, B) : A, B \in \mathcal{B}\}$, 即(5.7)成立.

习 题 A

习题 A.1. 证明定理A.2.1.

习题 A.2. 证明定理A.2.2的 (2).

习题 A.3. 令 $\Sigma := \{0, 1\}$, $(\Omega, \mathcal{F}) := (\Sigma, 2^\Sigma)^\mathbb{N}$ 为乘积可测空间. 求证: $(\Sigma, 2^\Sigma)^\mathbb{N}$ 的柱集全体 $\mathcal{E}$ 不是一个 σ -代数.

习题 A.4. 请证明: 在乘积空间 $((0, 1), \mathcal{B}_{(0,1)})^\mathbb{N} =: (\Omega, \mathcal{F})$ 中, 存在互不相交的非空柱集列 $\{B_n\}_{n=1}^\infty$, 使得 $\Omega = \bigcup_{n=1}^\infty B_n$, 且不存在公共的有限指标集 $I \subset \mathbb{N}$, 使得这些柱集 B_n 都以 I 为基底指标.

习题 A.5. 设 $\mathcal{G}_1, \mathcal{G}_2, \mathcal{G}_3$ 为概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 中三个相互独立的子 σ -代数. 记 $\mathcal{G}_1 \vee \mathcal{G}_2$ 为 $\mathcal{G}_1, \mathcal{G}_2$ 生成的 σ -代数, 求证: $\mathcal{G}_1 \vee \mathcal{G}_2$ 与 $\mathcal{G}_3$ 相互独立.

附录 B 矩问题与 Laplace 变换

在本书第五章中,我们已经告诉过大家,分布函数是最主要的刻画随机变量分布律的方式;此外分布测度、特征函数也是与分布函数等价的刻画分布律的重要工具。在一些特殊情况下,还有例如概率分布列(针对离散型随机变量)、概率密度函数(针对连续型随机变量)等刻画分布律的工具。

在这个附录里,我们准备介绍其他一些特殊情况下刻画分布律的工具:矩和 Laplace 变换。为此目的,我们将先介绍矩问题,再介绍 Laplace 变换。

B.1 矩问题

矩问题 (Moment Problem) 是一个古老的问题;该问题的研究起源于人们对于分布的各阶矩能否确定分布的思考与探索。**Moment Problem** 这一术语最早出现在 Stieltjes 在 1894—1895 年间的工作中;但实际上,早在 1873 年 Chebyshev 就提出并解决了这一重要问题的一种特殊情形,之后他的学生 Markov 也在这个问题上有突出的研究成果;他们考虑这一问题的目的在于用矩的方法来探讨中心极限定理。Stieltjes、Hamburger、Nevanlinna、Riesz、Hausdorff、Carleman、Stone 等人在矩问题上也有系统的研究成果。本节只介绍一些基本的矩问题及相应的一般性结果。对这方面更深入的结果感兴趣的读者请参见文献^[89,91]

注 B.1. *T. J. Stieltjes* (斯蒂尔杰斯; 1856—1894) 是荷兰数学家,以 *Lebesgue-Stieltjes* 积分知名。

H. L. Hamburger (哈姆布格尔; 1889—1956) 是德国数学家,以 *Hamburger* 矩问题知名。

R. H. Nevanlinna (奈望林纳; 1895—1980) 是芬兰数学家,以复变函数中的 *Nevanlinna* 理论知名;家族多位成员是数学家。

M. Riesz (里斯; 1886—1969) 是匈牙利数学家,以 *Riesz-Thorin* 定理、*M. Riesz* 扩张定理、*Riesz* 兄弟定理、*Riesz* 位势、*Riesz* 函数、*Riesz* 变换、*Riesz* 平均等知名; *F. Riesz* (里斯; 1880—1956) 是 *M. Riesz* 的哥哥,在泛函分析中有许多重要贡献,以 *Riesz* 表示定理知名。

F. Hausdorff (豪斯多夫; 1868—1942) 是德国数学家,现代拓扑学奠基人之一,以 *Hausdorff* 测度、*Hausdorff* 维数、*Hausdorff* 空间、*Hausdorff* 极大原理、*Hausdorff* 距离、*Hausdorff* 悖论、*Hausdorff* 矩问题、*Hausdorff-Young* 不等式等知名。

T. Carleman (卡莱曼; 1892—1949) 是瑞典数学家,以 *Carleman* 条件、*Carleman* 不等式、*Denjoy-Carleman* 定理、*Carleman* 核、*Carleman* 公式等知名。

Marshall Harvey Stone (斯通; 1903—1989) 是美国数学家, *G. D. Birkhoff* (伯克霍夫; 1884—1944; 美国) 的学生, 曾任教于哈佛大学和芝加哥大学, 在实分析、泛函分析、拓扑、*Bool* 代数等方面有贡献, 以 *Stone-von Neumann* 定理、*Stone-Čech* 紧化、*Stone-Weierstrass* 定理、*Stone* 表示定理知名。另一个容易与之混淆的数学家 *Stone* 是英国数学家 *Arthur Harold Stone* (1916—2000), 他是 *Solomon Lefschetz* (莱夫谢茨; 1884—1972; 俄罗斯出生的美国数学家) 的学生, 研究领域是拓扑, 曾任教于 *Manchester* 大学和 *Rochester* 大学, 与 *P. Erdős* (埃尔德什; 1913—1996) 合作证明了 *Erdős-Stone* 定理。

B.1.1 Hausdorff 矩问题

下面形式的矩问题被称为 **Hausdorff 矩问题**: 给定数列 $\{\mu_n : n \geq 0\}$ (其中 $\mu_0 := 1$), 求解 $[0, 1]$ 上概率分布函数 F , 使得

$$\mu_k = \int_0^1 x^k dF(x), \quad k = 0, 1, \dots \quad (\text{B.1})$$

我们不加证明的引述如下结果: 对有关证明感兴趣的读者, 请参见文献^[101]的 Chapter III 或习题 B.10.

♠ **定理 B.1.1.** (*Hausdorff* 定理) 数列 $\{\mu_n\}_{n=0}^\infty$ (其中 $\mu_0 := 1$) 可以实现为某个集中在 $[0, 1]$ 上的概率分布 F 的各阶矩的充要条件是该数列是完全单调序列, 即: $\mu_n \geq 0, \forall n \geq 1$, 且

$$(-1)^k \Delta^k \mu_n \geq 0, \quad \forall n, k \geq 0, \quad (\text{B.2})$$

其中 $\Delta^k \mu_n := \sum_{\ell=0}^k (-1)^\ell C_k^\ell \cdot \mu_{n+k-\ell}$. 如果上述条件 (B.2) 成立, 那么 (B.1) 中的 F 存在且唯一, 并且

$$(-1)^k \Delta^k \mu_n = \int_0^1 x^n (1-x)^k dF(x), \quad \forall n, k \geq 0. \quad (\text{B.3})$$

B.1.2 Hamburger 矩问题: 可解的条件

下面形式的矩问题被称为 **Hamburger 矩问题**: 给定数列 $\{m_n : n \geq 0\}$ (其中 $m_0 := 1$), 求解 $\mathbb{R}$ 上概率测度 μ , 使得

$$m_k = \int x^k d\mu, \quad k = 0, 1, \dots \quad (\text{B.4})$$

(B.4) 并不总能求解, 因而需要研究可解条件; 在有解时要进一步研究解的唯一性条件、何时有多解 (此时甚至可进一步研究解空间的结构)。

♠ **定理 B.1.2.** (*Hamburger 定理*) (1) 数列 $\{m_n\}_{n=1}^{\infty}$ 可以实现为某个不集中在有限个原子上的分布 μ 的各阶矩的充要条件是: 对任意 $n \geq 1$, 矩阵 $H_n := (m_{i+j})_{0 \leq i, j \leq n}$ (称为 *Hankel 矩阵*) 是正定的, 其中总约定 $m_0 := 1$.
 (2) 数列 $\{m_n\}_{n=1}^{\infty}$ 可以实现为某个集中在恰好 $N \geq 1$ 个原子上分布 μ 的各阶矩的充要条件是: 对任意 $k = 0, 1, \dots, N-1$, *Hankel 矩阵* H_k 是正定的; 而对任意 $k \geq N$, *Hankel 矩阵* H_k 是退化的非负定矩阵.

证明: 我们只给出 (1) 中的充分必要性; (2) 的证明类似.

必要性: 设随机变量 X 的分布为 μ . 对于固定的 $n \geq 1$, 考察数学期望

$$\mathbb{E}_{\mu} \left[\left(\sum_{k=0}^n x_k \cdot X^k \right)^2 \right] = \sum_{0 \leq k, \ell \leq n} m_{k+\ell} x_k x_{\ell} \geq 0.$$

如果对某 n 及非零 $x = (x_0, \dots, x_n)$ 上面数学期望取值为零, 那么随机变量 X 几乎处处满足代数方程 $\sum_{k=0}^n x_k \cdot X^k = 0$, 由此 μ 只能是集中在有限个原子上的离散分布. 矛盾. 因此由各阶矩构造的 *Hankel 矩阵* 应该是正定的.

充分性: 对任意固定的 $n \geq 1$, 考虑“截断矩问题”如下:

$$m_k = \int x^k d\mu, \quad k = 0, 1, \dots, 2n-1. \quad (\text{B.5})$$

在所给条件下, 它总是有解的 (具体证明细节见文献^[3], 此处从略; 也可直接证明, 截断矩问题有一个支撑在至多 $2n$ 个点上的分布测度作为解。), 设 μ_n 就是一个解. 由 *Helly 定理*, 存在测度 μ (现在不知道是否是概率测度), 使得 μ 是 $\{\mu_n : n \geq 1\}$ 的某个子列的弱极限; 不妨设这个子列就是它本身. 下面论证这个 μ 是概率测度, 且是矩问题的解. 任取 $-A < 0, B > 0$ 为 μ 的连续点, 那么对任意 $k \geq 0$,

$$\int_{-A}^B x^k d\mu(x) = \lim_{n \rightarrow \infty} \int_{-A}^B x^k d\mu_n(x).$$

取整数 r 使得 $2r > k$, 对 $n > r$, 有

$$m_k = \int x^k d\mu_n = \left[\int_{-A}^B + \int_{-\infty}^{-A} + \int_B^{\infty} \right] x^k d\mu_n.$$

记 $C = \min(A, B)$, 有

$$\begin{aligned} & \left| \left[\int_{-\infty}^{-A} + \int_B^{\infty} \right] x^k d\mu_n \right| = \left| \left[\int_{-\infty}^{-A} + \int_B^{\infty} \right] \frac{x^{2r}}{x^{2r-k}} d\mu_n \right| \\ & \leq \frac{1}{C^{2r-k}} \left[\int_{-\infty}^{-A} + \int_B^{\infty} \right] x^{2r} d\mu_n \leq \frac{m_{2r}}{C^{2r-k}}, \end{aligned}$$

进而 $A, B \rightarrow \infty$ 时

$$\left| \int_{-A}^B x^k d\mu(x) - m_k \right| \leq \frac{m_{2r}}{C^{2r-k}} \rightarrow 0.$$

这证明了: $\int x^k d\mu(x) = m_k, k = 0, 1, \dots$. 容易知道, 在所给条件下分布 μ 不集中在有限个原子上. $\square$

B.1.3 Hamburger 矩问题: 解的唯一性与不唯一性

上面的 Hamburger 定理给出了矩问题的解存在的充分必要条件. 在补充某些特殊条件的情况下, 给定了各阶矩就能唯一确定分布. 例如, 假设分布是集中在有限区间的, 那么它的各阶矩唯一确定分布. 一般而言, 我们有下面的结果.

♠ **定理 B.1.3.** (Carleman 准则; 证明见文献^[3]) 设数列 $\{m_n\}_{n=0}^\infty$ 是分布 F 的各阶矩. 当

$$\sum_{n=0}^{\infty} \frac{1}{m_{2n}^{1/(2n)}} = \infty$$

时, $\{m_n\}_{n=0}^\infty$ 唯一决定分布 F .

设数列 $\{m_n\}_{n=0}^\infty$ 是分布 F 的各阶矩, 且 F 是集中在 $[0, \infty)$ 上的分布函数 (此时的矩问题称为 Stieltjes 矩问题). 当

$$\sum_{n=0}^{\infty} \frac{1}{m_n^{1/(2n)}} = \infty$$

时, $\{m_n\}_{n=0}^\infty$ 唯一决定分布 F .

下面的结果及证明均引自文献^[29]的 Theorem 3.3.25, 也可参见文献^[116]; 它给出的条件略强于 Carleman 准则, 但更方便使用, 证明也不难.

♠ **定理 B.1.4.** 设数列 $\{m_n\}_{n=0}^\infty$ 是分布 F 的各阶矩. 当

$$\overline{\lim}_{n \rightarrow \infty} \frac{m_{2n}^{1/(2n)}}{2n} = r < \infty$$

时, $\{m_n\}_{n=0}^\infty$ 唯一决定分布 F .

证明: 设 $X \sim F$, 记 $\nu_k := \mathbb{E}[|X|^k]$. 那么 $\nu_{2k+1}^2 \leq \nu_{2k} \nu_{2k+2}$, 因此不难证明

$$\overline{\lim}_{n \rightarrow \infty} \frac{\nu^{1/n}}{n} = r < \infty.$$

进而对任意 $\varepsilon > 0$, $\nu_n \leq [n(r + \varepsilon)]^n$ 对充分大 n 成立。

对任意 $n \geq 0$ 及实数 θ , 我们有下面的估计式:

$$|e^{i\theta} - \sum_{k=0}^{n-1} \frac{(i\theta)^k}{k!}| \leq \min\left(\frac{2|\theta|^{n-1}}{(n-1)!}, \frac{|\theta|^n}{n!}\right). \quad (\text{B.6})$$

那么对任意 $\theta, t \in \mathbb{R}$, $|e^{i\theta X}[e^{itX} - \sum_{k=0}^{n-1} \frac{(itX)^k}{k!}]| \leq \frac{|tX|^n}{n!}$. 这意味着: 如果记 φ 为 F 的特征函数, 那么对充分大的 n

$$|\varphi(\theta + t) - \sum_{k=0}^{n-1} \frac{t^k}{k!} \cdot \varphi^{(k)}(\theta)| \leq \frac{|t|^n}{n!} \cdot \nu_n \leq \frac{|nt(r + \varepsilon)|^n}{n!}.$$

由 Stirling 公式 $n! = \sqrt{2\pi n}(\frac{n}{e})^n e^{\theta_n}$ (其中 $\theta_n = \frac{1+o(1)}{12n}$), 当 $|t| < \frac{1}{e(r+\varepsilon)}$ 时

$$\frac{|nt(r + \varepsilon)|^n}{n!} = \frac{|et(r + \varepsilon)|^n}{\sqrt{2\pi n}} \cdot [1 + o(1)] \rightarrow 0.$$

也就是说

$$\varphi(\theta + t) = \varphi(\theta) + \sum_{k=1}^{\infty} \frac{t^k}{k!} \cdot \varphi^{(k)}(\theta) \quad (\text{B.7})$$

对所有 $\theta \in \mathbb{R}$ 、所有 $|t| < \frac{1}{er} =: \delta$ 成立。易知 $\varphi(0) = 1$, $\varphi^{(k)}(0) = i^k \cdot m_k$, $k = 1, 2, \dots$. 根据(B.7), φ 在 $(-\delta, \delta)$ 上由各阶矩 $\{m_k\}_{k=1}^{\infty}$ 唯一决定; 进而, φ 在 $\mathbb{R}$ 上的取值由各阶矩 $\{m_k\}_{k=1}^{\infty}$ 唯一决定。由特征函数的唯一性定理, 本定理结论成立。□

例 B.1. 对于标准正态分布, $m_{2n+1} = 0, m_{2n} = (2n-1)!! = \frac{(2n)!}{2^n \cdot n!}$, 由 Stirling 公式 (其中 $\theta_n \rightarrow 0$)

$$(m_{2n})^{1/(2n)} = \left[\frac{\sqrt{4\pi n} \cdot (\frac{2n}{e})^{2n} \cdot e^{\theta_{2n}}}{\sqrt{2\pi n}(\frac{n}{e})^n \cdot e^{\theta_n} \cdot 2^n} \right]^{1/(2n)} \rightarrow \sqrt{\frac{2}{e}}.$$

由 Carleman 准则或上面的定理, 它的矩问题具有唯一解。

下面的 Krein 条件则能给出各阶矩不能唯一决定分布的众多例子。

♠ **定理 B.1.5.** (矩问题的 Krein 条件) 设分布 F 具有概率密度 ρ , 它满足

$$\int \frac{-\ln \rho(x)}{1+x^2} dx < \infty,$$

并且具有有限的各阶矩 $\{m_n : n \geq 0\}$. 此时, 矩问题的解不唯一。即存在分布 $G \neq F$, 它具有与 F 相同的各阶矩。

证明： 这是 Mark G. Krein (1907/4/3 — 1989/10/17; 苏联数学家, 犹太裔, 他是当时苏联泛函分析学派的重要人物, 以算子理论等方向的贡献知名, 1982 年获得 Wolf 奖) 在 1940 年左右的工作, 证明参见文献.^[3, 64] $\square$

例 B.2. 对于对数标准正态分布 (即 $X = e^Z$ 的分布, 其中 $Z \sim N(0, 1)$), 请读者验证其各阶矩存在且有限, 并且 Krein 条件成立 (而 Carleman 准则不成立). 因此这个分布的矩问题的解不唯一. 在文献^[29]的 §3.3.5 中给出了一族连续型分布和一族离散型分布, 它们都具有与对数标准正态同样的各阶矩.

B.1.4 矩问题有关理论的应用

讨论矩问题的一个目的是研究用矩方法来论证依分布收敛的可行性. 现在我们可以给出如下的一个答案.

♠ **定理 B.1.6.** 设随机变量 X 的各阶矩都存在, 满足

$$\overline{\lim}_{n \rightarrow \infty} \frac{(\mathbb{E}[X^{2n}])^{1/(2n)}}{2n} = r < \infty$$

或 Carleman 准则中条件. 如果有随机变量序列 $\{X_n\}_{n=1}^\infty$, 使得

$$\lim_{n \rightarrow \infty} \mathbb{E}[X_n^k] = \mathbb{E}[X^k], \quad k = 1, 2, \dots,$$

那么 $X_n \xrightarrow{d} X$.

对于 L^2 可积的随机变量 X, Y , 它们相互独立蕴含了 $\text{Cov}(X, Y) = 0$. 概率论初学者很容易产生这样的直觉: 如果 X, Y 的各阶矩都存在, 那么

$$\text{Cov}(X^m, Y^n) = 0, \quad \forall n, m \in \mathbb{N}$$

也应当蕴含了 X, Y 的相互独立性. 但是很遗憾, 这一直觉判断在一般情况下是错误的. 我们有下面的结论.

♠ **定理 B.1.7.** 设 $X \sim \mu, Y \sim \nu$, 且它们的各阶矩都存在.

(1) 设 μ, ν 的矩问题具有唯一解, 那么 X, Y 相互独立当且仅当

$$\text{Cov}(X^m, Y^n) = 0, \quad \forall m, n \in \mathbb{Z}_+. \quad (\text{B.8})$$

(2) 设 μ, ν 的各阶矩都不能唯一确定它们各自的分布, 对应存在分布测度 $\mu_* \neq \mu, \nu_* \neq \nu$ 具有与之相同的各阶矩. 取

$$(X_0, Y_0) \sim Q := \frac{\mu \otimes \nu + \mu_* \otimes \nu_*}{2},$$

则 X_0, Y_0 不相互独立, 但(B.8)仍然成立;

- (3) 设 μ 的各阶矩不能唯一确定其分布, 存在分布测度 $\mu_* \neq \mu$ 具有与之相同的各阶矩; 设 ν 是非退化的。任取可测集 A , 使得 $0 < \nu(A) < 1$, 取随机变量 X_0, Y_0 满足 $Y_0 \sim \nu$ 及对任意 y

$$(X_0 | Y_0 = y \in A) \sim \mu, \quad (X_0 | Y_0 = y \in A^c) \sim \mu_*.$$

则 X_0, Y_0 不相互独立, 但(B.8)仍然成立。

上述定理的结论 (2)、(3) 的证明不难; 结论 (1) 的证明留作习题, 亦可参见文献^[89]的 Exercise 14.7-4.

B.2 Laplace 变换

在本节, 我们考虑的分布或测度都是 $\mathbb{R}_+ := [0, \infty)$ 上的。这时, 使用 Laplace 变换通常会比特征函数 (或 Fourier 变换) 更简单。由于应用的需要, 我们有必要提供这方面的有关理论论述; 但由于 Laplace 变换的很多性质和证明与特征函数部分的理论类似, 在那样的场景我们将略去有关证明。本节大部分材料来源于文献^[40]; 对更深入的理论感兴趣的读者可以参考文献^[101]等专门讨论 Laplace 变换的文献。

B.2.1 Laplace 变换的定义与基本性质

通常, 如果 $f: \mathbb{R}_+ := [0, \infty) \rightarrow \mathbb{R}$ 是 $L^1(\mathbb{R}_+)$ 中函数, 对任意 $\lambda \geq 0$, 我们可以定义

$$\mathcal{L}f(\lambda) := \int_0^\infty f(x)e^{-\lambda x} dx. \quad (\text{B.9})$$

我们称函数 $\mathcal{L}f: \mathbb{R}_+ \rightarrow \mathbb{R}$ 为 f 的 Laplace 变换。但在此处, 我们可以对非负随机变量的分布函数 F 定义更广的 Laplace 变换 (为了区分, 我们记作 $\mathcal{L}_F$ 或 $\mathcal{L}\mu_F$; 个别场合我们也允许突破仅对非负随机变量的分布谈 Laplace 变换的限制)

$$\mathcal{L}_F(\lambda) := \int_0^\infty e^{-\lambda x} dF(x). \quad (\text{B.10})$$

当 $X \sim F$ 是非负随机变量时, 我们也记 $\mathcal{L}_X = \mathcal{L}_F$. 容易知道,

$$\mathcal{L}_X(\lambda) = \mathbb{E}[e^{-\lambda X}] = \int_0^\infty e^{-\lambda x} dF(x). \quad (\text{B.11})$$

显然, 当 F 具有密度 f 时, $\mathcal{L}_F = \mathcal{L}f$.

更一般地, 我们可以对 $\mathbb{R}_+$ 上非负有限测度 (甚至符号测度) μ 定义 Laplace 变换 $\mathcal{L}\mu: \mathbb{R}_+ \rightarrow \mathbb{R}$ 如下

$$\mathcal{L}\mu(\lambda) := \int_0^\infty e^{-\lambda x} d\mu(x), \quad (\text{B.12})$$

如果上述积分有意义. 这些推广的 Laplace 变换有时也称为 Laplace-Stieltjes 变换. 在本节, 我们重点关注 $\mathbb{R}_+$ 上概率测度或概率分布的 Laplace 变换.

我们把 $\mathbb{R}_+$ 上概率测度的全体记作 $\mathcal{M}^1(\mathbb{R}_+)$, $\mathbb{R}_+$ 上有限 (符号) 测度的全体记作 $\mathcal{M}^f(\mathbb{R}_+)$, $\mathbb{R}_+$ 上有限正测度的全体记作 $\mathcal{M}_+^f(\mathbb{R}_+)$. 一般地, 我们可以把 $\mathbb{R}$ 上有限 (符号) 测度的全体记作 $\mathcal{M}^f(\mathbb{R})$. 对任意 $\nu_1, \nu_2 \in \mathcal{M}^f(\mathbb{R})$, 我们可以定义卷积运算 $\nu_1 * \nu_2$ 如下:

$$\nu_1 * \nu_2(A) := \int \nu_1(A - x) d\nu_2(x) = \int \nu_2(A - x) d\nu_1(x), \quad \forall A \in \mathcal{B}.$$

容易知道此时 $\nu_1 * \nu_2 \in \mathcal{M}^f(\mathbb{R})$.

有时我们需要考虑 $\mathbb{R}_+$ 上 Radon 测度, 其全体记作 $\mathcal{M}_+^R(\mathbb{R}_+)$; 对应地, $\mathcal{M}^R(\mathbb{R}_+)$ 表示 Radon 符号测度的全体.

容易知道, 如果 $\mathbb{R}_+$ 上非负测度 μ 满足: 存在 $a \in \mathbb{R}_+$ 使得

$$\mathcal{L}\mu(\lambda) := \int_0^\infty e^{-\lambda x} d\mu(x)$$

满足 $\mathcal{L}\mu(a) < \infty$, 那么 $\mu([0, x]) \leq e^{ax} \mathcal{L}\mu(a)$, $\forall x \in \mathbb{R}_+$.

反之, 如果 μ 满足: 存在 $a \geq 0, C > 0$ 使得

$$\mu([0, x]) \leq Ce^{ax}, \quad \forall x \in \mathbb{R}_+, \quad (\text{B.13})$$

那么 $\mathcal{L}\mu(\lambda) < \infty, \forall \lambda > a$; 这类测度我们可以称之为指数控制的, 其全体记作 $\mathcal{M}_+^{EC,R}(\mathbb{R}_+)$. 如果 μ 是 $\mathbb{R}_+$ 上符号测度, 且其全变差测度 $|\mu| \in \mathcal{M}_+^{EC,R}(\mathbb{R}_+)$, 则仍然称 μ 为指数控制的, 记作 $\mu \in \mathcal{M}^{EC,R}(\mathbb{R}_+)$.

关于 Laplace 变换 $\mathcal{L}$, 我们有下面一些基本性质 (其中部分性质可以推广到更一般的形态, 留给读者自行思考).

性质 (1) (线性性质) 在 $\mathcal{M}^f(\mathbb{R}_+)$ (或 $\mathcal{M}^{EC,R}(\mathbb{R}_+)$) 上, $\mathcal{L}$ 是线性算子;

性质 (2) (正算子/单调性) 在 $\mathcal{M}^f(\mathbb{R}_+)$ (或 $\mathcal{M}^{EC,R}(\mathbb{R}_+)$) 上, $\mathcal{L}$ 是正算子.

特别地, 对任意 $\mu \in \mathcal{M}_+^f(\mathbb{R}_+)$, $\mathcal{L}\mu$ 是单调非增函数, 并且

$$0 \leq \mathcal{L}\mu(\lambda) \leq \mathcal{L}\mu(0) = \mu(\mathbb{R}_+) < \infty, \quad \forall \lambda \geq 0;$$

性质 (3) (卷积性质) $\mathcal{L}(\nu_1 * \nu_2)(\lambda) = \mathcal{L}\nu_1(\lambda)\mathcal{L}\nu_2(\lambda), \forall \nu_1, \nu_2 \in \mathcal{M}^f(\mathbb{R}_+)$;

性质 (4) (连续可微性与矩) 如果非负随机变量 $X \sim F$, 则 $\mathcal{L}\mu_F$ 是一个连续函数; 对于正整数 $n \in \mathbb{N}$, 如果 $\mathbb{E}[X^n] < \infty$, 那么 $\mathcal{L}\mu_F$ 是 n 阶连续可微函数, 并且对任意 $\lambda \geq 0$ 及 $0 \leq k \leq n$

$$(-1)^k D^k \mathcal{L}\mu_F(\lambda) = \mathbb{E}[e^{-\lambda X} \cdot X^k].$$

特别地, 对于“好的函数” f 以及任意 $k \in \mathbb{N}$

$$(-1)^k D^k \mathcal{L}f(\lambda) = \mathcal{L}[x^k f(x)](\lambda);$$

性质 (5) (分部积分) 设非负随机变量 $X \sim F$, 那么

$$\int_0^\infty e^{-\lambda x} F(x) dx = \frac{\mathcal{L}\mu_F(\lambda)}{\lambda}, \quad \forall \lambda > 0.$$

$$\text{上式也可以改写为 } \int_0^\infty e^{-\lambda x} [1 - F(x)] dx = \frac{1 - \mathcal{L}\mu_F(\lambda)}{\lambda}, \quad \forall \lambda > 0;$$

性质 (6) (尺度变换与平移变换) 如果 X 是非负随机变量, 那么

$$\begin{aligned} \mathcal{L}_X(a\lambda) &= \mathcal{L}_{aX}(\lambda), \forall a > 0, \\ \mathcal{L}_{X+a}(\lambda) &= e^{-a\lambda} \mathcal{L}_X(\lambda), \forall a \in \mathbb{R}. \end{aligned}$$

另外, 对任意 $\mu \in \mathcal{M}_+^{EC,R}(\mathbb{R}_+)$, 如果 $\mathcal{L}\mu(b) < \infty$, 则对任意 $a \in \mathbb{R}$

$$\mathcal{L}\mu(\lambda + a) = \mathcal{L}\mu_a^\#(\lambda), \forall \lambda \geq b - a,$$

$$\text{其中 } \mu_a^\#(A) := \int_A e^{-ax} d\mu(x), \forall A \in \mathcal{B}(\mathbb{R}_+).$$

我们对上面性质 (6) 的后半部分加一点注记。事实上, 如果非负 Radon 测度 μ 满足 $\mathcal{L}\mu(b) < \infty$, 那么容易知道

$$\mu_b^\#(\mathbb{R}_+) = \int_{\mathbb{R}_+} e^{-bx} d\mu(x) = \mathcal{L}\mu(b) < \infty,$$

从而 $\mu_b^\# \in \mathcal{M}^f(\mathbb{R}_+)$, 并且 $\mathcal{L}\mu_b^\#(\lambda) = \mathcal{L}\mu(\lambda + b), \forall \lambda \geq 0$. 此时, 我们还有

$$\frac{d\mu_b^\#}{d\mu}(x) = e^{-bx}, \quad \frac{d\mu}{d\mu_b^\#}(x) = e^{bx}.$$

因此 μ 与 $\mu_b^\#$ 之间是一一对应的关系。由此, 在后文的有关 Laplace 变换的 (连续性、唯一性与刻画等的) 理论讨论中, 仅限于有限测度、特别是概率测度来讨论, 只会使得有关探讨更为简单、表达更为简洁。

B.2.2 Laplace 变换的唯一性定理

与特征函数类似, $\mathbb{R}_+$ 上概率分布的 Laplace 变换能唯一确定对应的分布律。这也被称为 Laplace 变换的唯一性定理; 它也有所谓的反演公式。此处我们给出如下两个反演公式: 一者是有关分布的 Laplace 变换的反演公式, 见(B.14); 一者是有关函数(相当于密度)的 Laplace 变换的反演公式, 这被称为 Widder 逆转公式, 见(B.15).

♠ **定理 B.2.1.** (1) $\mathbb{R}_+$ 上概率测度 μ 由它的 Laplace-Stieltjes 变换 $\mathcal{L}\mu$ 在任一给定区间 $[a, \infty)$ 上的取值唯一决定。事实上, 如果 $F(x) = \mu([0, x]), x \geq 0$, 那么在 F 的连续点 $x > 0$ 上有

$$F(x) = \lim_{\lambda \rightarrow \infty} \sum_{0 \leq n \leq \lambda x} \frac{(-\lambda)^n}{n!} D^n \mathcal{L}\mu(\lambda). \quad (\text{B.14})$$

(2) 设 $\mathbb{R}_+$ 上连续函数 f 存在 Laplace 变换。则 f 由它在某区间 $0 \leq a < \lambda < \infty$ 上的普通 Laplace 变换 $\mathcal{L}f$ 的取值唯一决定。特别地, 如果 f 是有界一致连续函数, 则 $\mathcal{L}f(\lambda)$ 对 $\lambda > 0$ 有意义, 并且

$$f(x) = \lim_{n \rightarrow \infty} \frac{(-1)^{n-1}}{(n-1)!} \left(\frac{n}{x}\right)^n (D^{n-1} \mathcal{L}f)\left(\frac{n}{x}\right) \quad (\text{B.15})$$

证明: 我们只证明 (1), (2) 的证明请参见习题 B.1.

这里, 如果 $X \sim \mu$, 那么对任意 $\lambda > 0$, $\mathcal{L}\mu(\lambda) = \mathbb{E}[e^{-\lambda X}]$, 且

$$(-1)^n D^n \mathcal{L}\mu(\lambda) = \mathbb{E}[e^{-\lambda X} X^n].$$

此外, 对任意给定的 $\theta > 0, \varepsilon > 0$, 注意到如果 $Y_{\lambda, \theta} \sim \text{Poisson}(\lambda\theta)$, 那么当 $\lambda \rightarrow \infty$ 时

$$\mathbb{P}(|Y_{\lambda, \theta} - \lambda\theta| > \lambda\varepsilon) \leq \frac{\text{Var}(Y_{\lambda, \theta})}{\lambda^2 \varepsilon^2} = \frac{\theta}{\lambda \varepsilon^2} \rightarrow 0.$$

由特征函数方法可证明: 当 $\lambda \rightarrow \infty$ 时, $\frac{Y_{\lambda, \theta} - \lambda\theta}{\sqrt{\lambda\theta}} \xrightarrow{d} N(0, 1)$. 这意味着

$$\mathbb{P}(Y_{\lambda, \theta} \leq \lambda x) = e^{-\lambda\theta} \sum_{0 \leq n \leq \lambda x} \frac{(\lambda\theta)^n}{n!} \xrightarrow{\lambda \rightarrow \infty} \begin{cases} 0, & \text{如果 } \theta > x \\ 1, & \text{如果 } \theta < x \\ \frac{1}{2}, & \text{如果 } \theta = x. \end{cases}$$

因此, $\lim_{\lambda \rightarrow \infty} e^{-\lambda X} \sum_{0 \leq n \leq \lambda x} \frac{(\lambda X)^n}{n!} = 1_{\{X < x\}} + \frac{1}{2} \cdot 1_{\{X = x\}}$. 根据控制收敛定理, 对于 F 的连续点 $x > 0$, 我们有(B.14)成立. $\square$

B.2.3 Laplace 变换的连续性定理

在本小节,为了后续应用的需要,我们考虑 $\mathbb{R}_+$ 上比概率测度概念略广泛一点的 Radon 测度的 Laplace 变换。我们列出如下关于 Laplace 变换的连续性定理而不给出证明。此处,对于 Radon 测度列 $\{\mu_n\}_{1 \leq n \leq \infty}$, 定义 $F_n(x) := \mu_n([0, x])$, 如果

$$F_n(x) \rightarrow F_\infty(x)$$

在 F_∞ 的所有连续点上成立, 则认为 $\mu_n \xrightarrow{w} \mu_\infty$; 对于 $\mathbb{R}_+$ 上概率测度列 $\{\mu_n\}_{1 \leq n \leq \infty}$, 这一陈述是显然成立的。

♠ **定理 B.2.2.** (1) 设 $\mathbb{R}_+$ 上 Radon 测度列 $\{\mu_n\}_{1 \leq n \leq \infty}$ 满足 $\mu_n \xrightarrow{w} \mu_\infty$, 且存在 $a \geq 0$ 使得 $\{\mathcal{L}\mu_n(a)\}_{n=0}^\infty$ 有界。那么 $\mathcal{L}\mu_n(\lambda) \rightarrow \mathcal{L}\mu_\infty(\lambda), \forall \lambda > a$ 。

(2) 设 $\mathbb{R}_+$ 上 Radon 测度列 $\{\mu_n\}_{1 \leq n < \infty}$ 满足: 存在 $a \geq 0$, $\mathcal{L}\mu_n(\lambda)$ 对 $\lambda > a$ 有定义, 并且 $\mathcal{L}\mu_n(\lambda) \rightarrow \varphi(\lambda), \forall \lambda > a$ 。那么 φ 是某个 Radon 测度 μ_∞ 的 Laplace 变换, 并且 $\mu_n \xrightarrow{w} \mu_\infty$ 。

上述定理的证明请参见文献^[40]的 Chapter 13. 在那里, Feller 先讨论了概率测度版本的 Laplace 变换的连续性定理, 之后再证明了上面的连续性定理; 在他的著作中, 这个定理被称为广义连续性定理。

读者也可以仿照之前特征函数的连续性定理来完成上述定理(概率测度版本)的证明: 定理中(1)的证明仍然可以基于 Skorodhod 嵌入定理; 定理中(2)的部分则可以基于 Helly 定理来完成。一般 Radon 测度情形下的结论可以基于概率测度情形的结果而给出证明, 也留给读者自行尝试。

B.2.4 Laplace 变换的刻画定理

什么样的函数可以表示为 $\mathbb{R}_+$ 上某概率分布的 Laplace 变换? 下面的 Bernstein 定理回答了这个问题。

♠ **定理 B.2.3.** (Bernstein 定理, 1928) 函数 $\varphi: \mathbb{R}_+ \rightarrow \mathbb{R}$ 是 $\mathbb{R}_+$ 上某概率分布的 Laplace 变换的充分必要条件是:

- (1) $\varphi(0) = 1$;
- (2) φ 是完全单调的, 即: φ 的各阶导数均存在, 且

$$(-1)^n D^n \varphi(\lambda) \geq 0, \quad \forall \lambda > 0. \quad (\text{B.16})$$

证明: 必要性部分的证明很简单, 留给读者; 以下我们只证明充分性部分。为方便, 我们不妨假定 $\varphi(\infty) := \lim_{\lambda \uparrow \infty} \varphi(\lambda) = 0$. 这个条件是用于保证 0 不是对应的分布的原子; 否则, 我们只需考虑 $\tilde{\varphi}(\lambda) := \frac{\varphi(\lambda) - \varphi(\infty)}{1 - \varphi(\infty)}$ 即可。此时, 本定理可以视作 Hausdorff 矩问题的一个应用。

事实上, 不难知道, 在所给条件下, 对任意固定的整数 $m \geq 1$, $\{\varphi(\frac{n}{m})\}_{n=0}^{\infty}$ 是完全单调序列 (见习题 B.8), 于是 $[0, 1]$ 上存在唯一的概率分布函数 F_m 使得

$$\varphi\left(\frac{n}{m}\right) = \int_0^1 t^n dF_m(t), \quad n \geq 0.$$

显然 $\tilde{F}_m(x) := F_m(x^{1/m})$ 也是一个分布函数, 并且

$$\varphi(n) = \int_0^1 t^{mn} dF_m(t) = \int_0^1 x^n d\tilde{F}_m(x), \quad n \geq 0.$$

唯一性说明了 $\tilde{F}_m(t) = F_1(t)$. 现在令 $F(t) = 1 - F_1(e^{-t}), t \geq 0$, 则

$$\varphi\left(\frac{n}{m}\right) = \int_0^1 t^{n/m} dF_1(t) = \int_0^\infty e^{-nt/m} dF(t), \quad n \geq 0, m \geq 1.$$

由连续性, 立即得到 $\varphi(\lambda) = \int_0^\infty e^{-\lambda t} dF(t)$. □

B.2.5 Laplace 变换的 Tauber 定理

给定实数列 $\{a_n\}_{n=0}^\infty$, 我们记

$$s_n := \sum_{k=0}^n a_k.$$

当存在 $A \in \mathbb{R}$ 使得 $s_n \rightarrow A$ 时, 我们称数列 $\{a_n\}_{n=0}^\infty$ (普通) 可和; 而当 $\sigma_n := \frac{1}{n} \sum_{k=0}^{n-1} s_k \rightarrow A$ 时, 则称数列 $\{a_n\}_{n=0}^\infty$ Cesàro 可和。当实数列 $\{a_n\}_{n=0}^\infty$ 的母函数

$$f(x) := \sum_{n=0}^{\infty} a_n x^n \tag{B.17}$$

对 $|x| < 1$ 收敛, 且存在 A 使得 $f(1-) = A$, 则称数列 $\{a_n\}_{n=0}^\infty$ Abel 可和。

分析学中常见的一个 Abel 定理如下:

♠ **定理 B.2.4. (Abel 定理)** (I) 如果数列 $\{a_n\}_{n=0}^\infty$ Cesàro 可和, 那么它也是 Abel 可和的, 并且

$$\lim_{x \rightarrow 1-} \sum_{n=0}^{\infty} a_n x^n = \lim_{n \rightarrow \infty} \frac{1}{n} \sum_{k=0}^{n-1} s_k. \tag{B.18}$$

(2) 如果数列 $\{a_n\}_{n=0}^{\infty}$ 普通可和, 那么它是 *Cesàro* 可和的、进而 *Abel* 可和的, 并且

$$\lim_{x \rightarrow 1^-} \sum_{n=0}^{\infty} a_n x^n = \sum_{n=0}^{\infty} a_n. \quad (\text{B.19})$$

例 B.3. 对数列 $a. = \{a_n\}_{n=0}^{\infty}$, 定义 $f(x) = \sum_{n=0}^{\infty} a_n x^n$ 及 $s_n := \sum_{k=0}^n a_k$.

(a) 当 $a_n := (-1)^n$ 时, $f(x) = \frac{1}{1+x}$, $a.$ 不是普通可和的, 但 $s_n = \frac{1+(-1)^n}{2}$, 从而 $a.$ 的 *Cesàro* 和恰为 $\frac{1}{2}$, 此时 $a.$ 对应的 *Abel* 和为 $f(1-) = \frac{1}{2}$;

(b) 当 $a_n := (-1)^n(n+1)$ 时, $f(x) = \frac{1}{(1+x)^2}$, $s_n = (-1)^n(\lfloor \frac{n}{2} \rfloor + 1)$, $a.$ 不是 *Cesàro* 可和的, 但它是 *Abel* 可和的, 对应的 *Abel* 和为 $\frac{1}{4}$.

一个很自然的问题是: 为了使上述 *Abel* 定理中(B.19)左端极限存在, 我们应该附加什么条件? 亦即, 当 $\{a_n\}_{n=0}^{\infty}$ *Abel* 可和时, 该数列也普通可和且两种求和相等的一个充分条件是什么? *Tauber* 给出的条件是: $a_n = o(\frac{1}{n})$; 这个结果就是分析学中常见的 *Tauber 第一定理*, 具体陈述如下。

♠ **定理 B.2.5.** (*Tauber, 1897*) 若数列 $\{a_n\}_{n=0}^{\infty}$ *Abel* 可和且 $a_n = o(\frac{1}{n})$, 那么数列 $\{a_n\}_{n=0}^{\infty}$ 普通可和, 且(B.19)成立。

Littlewood 在 1910 年证明了条件 $a_n = o(\frac{1}{n})$ 可以进一步减弱为 $a_n = O(\frac{1}{n})$. 这类用来确保 *Abel* 可和蕴含普通可和的充分条件通常称为 *Tauber* 条件。

上述定理的一个证明思路如下: 令 $r = 1 - \frac{1}{N}$, $\epsilon := \sup\{n|a_n| : n \geq N\}$, 作估计

$$\left| \sum_{n=0}^N a_n - \sum_{n=0}^N a_n r^n \right| \leq \sum_{n=1}^N |a_n| [1 - (1 - \frac{1}{N})^n] \leq \sum_{n=1}^N |a_n| \frac{n}{N}$$

以及

$$\begin{aligned} \left| \sum_{n=1}^{\infty} a_n r^n - \sum_{n=1}^N a_n r^n \right| &\leq \sum_{n>N} |a_n| (1 - \frac{1}{N})^n \\ &\leq \sum_{n>N} \frac{n|a_n|}{N} (1 - \frac{1}{N})^n \\ &\leq \sum_{n>N} \frac{\epsilon}{N} (1 - \frac{1}{N})^n = \epsilon (1 - \frac{1}{N})^{N+1}. \end{aligned}$$

由 $na_n \rightarrow 0$ 不难得知 $n|a_n|$ 的前 N 项的算术平均也趋于零, 而 $(1 - \frac{1}{N})^{N+1} \rightarrow e^{-1}$. 综合这两个估计, 就证明了上述定理。

Tauber 进一步在他自己工作的基础上建立了如下的 *Tauber* 第二定理。

♠ **定理 B.2.6.** (*Tauber 第二定理*) $\sum_{n=0}^{\infty} a_n = A \in \mathbb{R}$ 成立的充分必要条件是: 数列 $\{a_n\}_{n=0}^{\infty}$ 的 Abel 和为 A , 并且下面 Tauber 条件成立

$$\sum_{k=0}^n k a_k = o(n). \quad (\text{B.20})$$

上述 Abel 定理和 Tauber 定理的精神是通过构建数列 $\{a_n\}_0^{\infty}$ 的母函数来分析有关临界点处的极限行为。Hardy 和 Littlewood 进一步证明了如下形态的 Tauber 定理¹:

♠ **定理 B.2.7.** 设 $f(x) := \sum_{n=0}^{\infty} a_n x^n$ 对 $|x| < 1$ 收敛, 且存在 $\alpha \geq 0$ 使得

$$(1-x)^{\alpha} f(x) \rightarrow A, \quad x \nearrow 1$$

且 $n a_n \geq O(n^{\alpha})$, 那么 $\frac{s_n}{n^{\alpha}} \rightarrow \frac{A}{\Gamma(1+\alpha)}, \quad n \rightarrow \infty.$

为了给出关于 Laplace 变换的 Tauber 定理, 我们需要引入规则变化函数的概念。设 $U: [0, \infty) \rightarrow (0, \infty)$ 为可测函数, 如果存在 $\rho \in \mathbb{R}$ 使得: 对任意 $x > 0$

$$\lim_{t \rightarrow \infty} \frac{U(tx)}{U(t)} = x^{\rho}, \quad (\text{B.21})$$

则称 U 是以 ρ 为指标的规则变化函数 (**Regularly Varying Function/Function of Regular Variation**), 记作 $U \in R_{\rho}$ 或 $U \in R_{\rho}(\infty)$ ²; $\rho = 0$ 时又称 U 为缓慢变化函数 (**Slowly Varying Function/Function of Slow Variation**) .

规则变化函数的概念是 J. Karamata 于 1930 年引入, 这一概念已经被证明在许多方面富有成效, 且在概率论中的应用越来越广泛; 关于规则变化函数的系统论述, 读者可以参考文献^[6]

现在我们可以陈述关于 Laplace 变换的 Tauber 定理了。

♠ **定理 B.2.8.** 设 μ 是 $\mathbb{R}_+$ 上 Radon 测度, 记 $F(x) = \mu([0, x]), x > 0$. 设

$$\mathcal{L}\mu(\lambda) := \int_0^{\infty} e^{-\lambda x} dF(x)$$

对任意 $\lambda > 0$ 存在。设 $\tau t = 1, \gamma \geq 0$, 那么以下两个关系式

$$\frac{\mathcal{L}\mu(\lambda\tau)}{\mathcal{L}\mu(\tau)} \rightarrow \lambda^{-\gamma}, \quad \tau \searrow 0, \quad (\text{B.22})$$

¹有关 Tauber 理论的更多、更深入讨论, 感兴趣的读者可以阅读文献^[63]等。

²记号 $R_{\rho}(\infty)$ 是用以强调极限 $t \rightarrow \infty$; 我们也可以谈论 $t \rightarrow 0$ 下的规则变化函数, 此时以 ρ 为指标的规则变化函数的全体对应记作 $R_{\rho}(0)$.

$$\frac{F(tx)}{F(t)} \rightarrow x^\gamma, \quad t \nearrow \infty \quad (\text{B.23})$$

之间是等价的, 且都蕴含了

$$\mathcal{L}\mu(\tau) \sim F(t) \cdot \Gamma(1+\gamma), \quad \tau \searrow 0. \quad (\text{B.24})$$

上述结论对 $\tau \nearrow \infty, t \searrow 0$ 也成立。借助有关术语, 这些结论也可表述为:

$$\mathcal{L}\mu \in R_{-\gamma}(0) \Leftrightarrow F \in R_\gamma(\infty), \quad \mathcal{L}\mu \in R_{-\gamma}(\infty) \Leftrightarrow F \in R_\gamma(0).$$

证明: 以下证明思路来自^[40]的 Chapter 13; 读者也可参考^[101]的 Chapter V 中提供的证明方法。

(a) 先讨论 $\gamma > 0$ 的情形。假定(B.22)成立, 它左边对应的是 $G_\tau(x) := \frac{F(tx)}{\mathcal{L}\mu(\tau)}$ (这对应于 $\mathbb{R}_+$ 上一个 Radon 测度) 的 Laplace 变换。由连续性定理, 有

$$G_\tau(x) = \frac{F(tx)}{\mathcal{L}\mu(\tau)} \rightarrow \frac{x^\gamma}{\Gamma(1+\gamma)}.$$

对上式, 取 $x = 1$, 就得到了(B.24). 把它代回上面表达式, 就得到了(B.23).

当 $\gamma = 0$ 时, 容易知道上面讨论仍然成立, 只不过 $G_\tau(x)$ 对应的 Radon 测度收敛到 Dirac 测度 δ_0 .

(b) 假定(B.23)成立, 即 $F_t(x) := \frac{F(tx)}{F(t)} \rightarrow x^\gamma$, 设 F_t 对应的测度为 μ_t . 我们验证 $\frac{\mathcal{L}\mu(\tau)}{F(t)} = \mathcal{L}\mu_t(1)$ 有界。事实上,

$$\mathcal{L}\mu(\tau) = \int_0^\infty e^{-\tau x} dF(x) \leq \sum_{n=0}^\infty e^{-2^{n-1}} F(2^n t).$$

由 F 是单调递增的规则函数, 我们知道 (参见文献^[6]): 存在 $C \geq 1$ 使得

$$\frac{F(xt)}{F(t)} \leq Cx^{1+\gamma}, \quad \forall x \geq 1, t > 0.$$

于是 $\frac{\mathcal{L}\mu(\tau)}{F(t)} \leq C \sum_{n=0}^\infty e^{-2^{n-1}} 2^{n(1+\gamma)} < \infty$. 由连续性定理, 对

$$F_t(x) := \frac{F(tx)}{F(t)} \rightarrow x^\gamma$$

取 Laplace 变换, 就得到 $\frac{\mathcal{L}\mu(\tau\lambda)}{F(t)} \rightarrow \frac{\Gamma(1+\gamma)}{\lambda^\gamma}$. 由此, 同 (a) 部分推理就得到(B.24)和(B.22). □

但更多时候, 我们关心概率分布函数 F 的尾部 $\bar{F}(x) := 1 - F(x)$ 的极限行为. 设 F 诱导分布测度 μ . 定义

$$\bar{\mu}(A) := \int_A \bar{F}(x) dx.$$

则回顾 Laplace 变换的分部积分性质 (5) $\mathcal{L}\bar{\mu}(\lambda) = [1 - \mathcal{L}\mu(\lambda)]/\lambda, \forall \lambda > 0$. 由上面的定理立即得到 (其中 $R_0(\infty)$ 表示缓慢变化函数):

♠ **定理 B.2.9.** 设 μ 是 $\mathbb{R}_+$ 上概率分布测度, 记 $F(x) = \mu([0, x]), x > 0$. 对任意 $\alpha \in [0, 1], \ell \in R_0(\infty)$, 我们有下面的结论 (其中 $\tau \searrow 0, t \nearrow \infty$):

$$(a) \text{ 当 } \alpha \in [0, 1) \text{ 时, } 1 - \mathcal{L}\mu(\tau) \sim \tau^\alpha \ell(1/\tau) \Leftrightarrow 1 - F(t) \sim \frac{\ell(t)}{t^\alpha \Gamma(1 - \alpha)};$$

$$(b) \text{ 当 } \alpha = 1 \text{ 时, } \int_{[0, t]} x dF(x) \sim \ell(t) \Leftrightarrow \int_0^t [1 - F(x)] dx \sim \ell(t).$$

上面定理是编者摘自文献^[6]的 Corollary 8.1.7. 更多相关结果请参见文献^[6]的 §8.3.

🔍 **注 B.2.** *David Vernon Widder* (威德, 1898—1990) 是美国数学家. 他在 *G. Birkhoff* 指导下于 1924 年毕业于哈佛大学, 并留在哈佛任教. 他是 *Duke Mathematical Journal* 杂志的联合创刊人之一, 著有以下有影响力的教材或专著: (1) *Advanced Calculus*; (2) *The Laplace transform* (在此书中他给出了关于 *Dirichlet zeta* 函数的 *Landau* 问题的第一个解答); (3) *An introduction to transform theory*; (4) *The convolution transform* (与 *I. I. Hirschman* 合著).

Alfred Tauber (陶伯, 1866—1942) 是出生在匈牙利的奥地利数学家, 以在数学分析和单复变函数方向的贡献而知名; 以他的名字命名的 *Tauber* 定理有多个, 应用于数学分析、调和分析、数论等多个方向. 他 1884 年就读 *Vienna* 大学, 1889 年获得博士学位. 1892-1908 年作为首席数学家供职于 *Phönix* 保险公司, 之后正式在 *Vienna* 大学任教 (之前从 1901 年起在 *TU Wien* 和 *Vienna* 大学有兼职). 他 1942 年被杀害于 *Theresienstadt* 集中营.

习 题 B

习题 B.1. 本题来自文献.^[132] 设 $f: \mathbb{R}_+ \rightarrow \mathbb{R}_+$ 是连续函数, 且 $f \in L^r(\mathbb{R}_+)$, 其中 $r > 1$. 设 f 的 Laplace 变换为 $\mathcal{L}f(\lambda) := \int_0^\infty e^{-\lambda t} f(t) dt$, 则

$$f(x) = \lim_{n \rightarrow \infty} \frac{(-1)^{n-1}}{(n-1)!} \left(\frac{n}{x}\right)^n (D^{n-1} \mathcal{L}f)\left(\frac{n}{x}\right)$$

在每个有限区间中一致成立. 此处 D 表示求导函数的算子.

习题 B.2. 证明正态分布 $N(\mu, \sigma^2)$ 的各阶矩唯一确定其分布.

习题 B.3. 证明 Poisson 分布的各阶矩唯一确定其分布。

习题 B.4. 证明指数分布的各阶矩唯一确定其分布。

习题 B.5. 证明对数标准正态分布的各阶矩不能唯一确定其分布。

习题 B.6. 设 ξ 的矩问题具有唯一解, 它的特征函数为 f . ξ_n 的特征函数是 f_n , 且 $f_n(t) \rightarrow f(t)$ 在某区间 $[-\varepsilon, \varepsilon]$ 上成立, 那么 $\xi_n \xrightarrow{d} \xi$.

习题 B.7. 任给 $\kappa \in [0, 1]$, 定义 $M_\kappa(t) := \sum_{n=0}^{\infty} \frac{t^n}{\Gamma(1+n\kappa)}$, $\forall t \in (-1, 1)$. 求证: 存在唯一分布函数 F_κ (它是集中在 $[0, \infty)$ 上的分布) 使得

$$M_\kappa(t) = \mathbb{E}[e^{tX}], \quad \text{其中 } X \sim F_\kappa.$$

容易知道, F_0 是标准指数分布函数, F_1 是常数 1 对应的分布函数. 分布函数 $\{F_\kappa : \kappa \in [0, 1]\}$ 称为 **Mittag-Leffler** 分布族^[83], 在 Darling-Kac 理论中它们是占位时在适当尺度变换下的极限分布律 (见文献^[6]的 Theorem 8.11.2).

习题 B.8. 设 φ 是一个光滑函数, Δ, D 分别为差分算子和微分算子, 即

$$\Delta\varphi(t) := \varphi(t+1) - \varphi(t), \quad D\varphi(t) := \varphi'(t).$$

那么 $D\Delta\varphi = \Delta D\varphi$. 基于此, 请用归纳法证明:

$$\Delta^n \varphi(t) = \int_t^{t+1} \left[\int_{t_1}^{t_1+1} \cdots \left[\int_{t_{n-1}}^{t_{n-1}+1} D^n \varphi(t_n) dt_n \right] \cdots dt_2 \right] dt_1, n \geq 1.$$

由此, 当 φ 是完全单调函数时, 对任意固定的 $m \in \mathbb{N}$, $\{\varphi(\frac{n}{m})\}_{n=0}^{\infty}$ 是完全单调序列。

习题 B.9. 证明定理 B.1.7 的结论 (1).

习题 B.10. 本习题的目的是引导读者给出 Hausdorff 定理的一个证明. 必要性部分已经由方程 (B.3) 给出; 以下只证明充分性部分. 这部分只需注意到泛函分析中的 Gelfand 的表示定理: 设 M 为紧空间, 那么 $C(M)$ 上的连续、线性、正泛函与 M 上有限测度一一对应. 显然, 给定一个分布的各阶矩 $\{\mu_n\}_{n=0}^{\infty}$ (约定 $\mu_0 := 1$),

$$t^n \mapsto \mu_n$$

确实能诱导 $C[0, 1]$ 上的一个线性泛函 α . 具体实现可以按照如下步骤. 对任意实系数 n 阶多项式 $P_n(t) := \sum_{k=0}^n a_k t^k$, 我们可以定义

$$\alpha(P_n) := \sum_{k=0}^n a_k \mu_k.$$

下面我们说明 α 可以延拓为 $C[0, 1]$ 中线性泛函:

- (1) 令 $\lambda_{n,\ell}(x) := C_n^\ell x^\ell (1-x)^{n-\ell}$, $n, \ell \geq 0$ (此处, 按照通常的约定, 对整数对 (n, ℓ) , 当 $\ell > n$ 时 $C_n^\ell := 0$), 则

$$\alpha_{n,\ell} := \alpha(\lambda_{n,\ell}) = C_n^\ell \cdot (-1)^{n-\ell} \Delta^{n-\ell} \mu_\ell \geq 0.$$

容易算出 $\sum_{\ell=0}^n \alpha_{n,\ell} = \mu_0 = 1$.

- (2) $\forall f \in C[0, 1]$, 令 $B_n f(x) := \sum_{\ell=0}^n f(\frac{\ell}{n}) C_n^\ell x^\ell (1-x)^{n-\ell}$; 这是 f 对应的 *Bernstein* 多项式, 且当 $n \rightarrow \infty$ 时, $\|f - B_n f\| \rightarrow 0$, 其中 $\|f\| := \sup\{|f(x)| : x \in [0, 1]\}$.

- (3) 不难知道, 对任意正整数 $k \geq 1$, 下式对 $x \in [0, 1]$ 一致收敛:

$$\lim_{n \rightarrow \infty} \prod_{i=0}^{k-1} \frac{x - \frac{i}{n}}{1 - \frac{i}{n}} = x^k.$$

由此不难验证: 如果 $f_k(x) = x^k, \forall k \geq 0$, 那么

$$\mu_k = \lim_{n \rightarrow \infty} \alpha(B_n f_k).$$

进而可以对任意 $f \in C[0, 1]$, 定义

$$\alpha(f) := \lim_{n \rightarrow \infty} \alpha(B_n f).$$

上面极限的定义方式说明了 α 实际上是一个连续的线性泛函; 注意到

$$B_n f(x) = \sum_{\ell=0}^n f(\frac{\ell}{n}) \lambda_{n,\ell}(x), \alpha(B_n f) = \sum_{\ell=0}^n f(\frac{\ell}{n}) \alpha_{n,\ell},$$

α 是正算子。于是存在有限测度 α , 使得

$$\alpha(f) = \int_0^1 f(x) d\alpha(x).$$

进而由 $1 = \mu_0 = \alpha(1)$ 知道 α 是概率测度。

附录 C Kolmogorov 定理的“证明”

在本章，我们基于特征函数方法，给出定理12.2.2的主要结论(12.27)的一个粗线条的证明框架¹。在此过程中，我们需要介绍 Brown 运动、Brown 桥的定义及其特征函数刻画、概率测度的弱收敛理论与泛函中心极限定理等工具。

C.1 Brown 运动、Brown 桥及其特征函数刻画

概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 中的一族随机变量 $\xi_\cdot = \{\xi_t : t \geq 0\}$ 也称为随机过程，它可以视作二元可测函数²

$$\xi : \mathbb{R}_+ \times \Omega \rightarrow \mathbb{R}, (t, \omega) \mapsto \xi_t(\omega),$$

也可以视作抽象的可测映射

$$\xi : \Omega \rightarrow \mathfrak{C}, \omega \mapsto \xi_\cdot(\omega),$$

其中 $\mathfrak{C} \subset \mathbb{R}^{\mathbb{R}_+}$ 是一个合适的函数空间（其上配置了合适的可测结构，以确保映射 $\xi(\cdot)$ 的可测性），使得 $\mathbb{P}(\xi_\cdot \in \mathfrak{C}) = 1$ 。测度论（或概率论）中的 Kolmogorov 相容性定理（见文献^[126]或其他随机过程教材）告诉我们，随机过程的分布律由它的所有有限维联合分布测度族 $\{\mu_{t_1, \dots, t_n} : n \geq 1, t_1, \dots, t_n \in \mathbb{R}\}$ 决定，其中 $(\xi_{t_1}, \dots, \xi_{t_n}) \sim \mu_{t_1, \dots, t_n}$ 。本章我们主要关心 Brown 运动和 Brown 桥等连续过程，在那些场合我们均取 $\mathfrak{C} = C[0, T]$ （其中 $T > 0$ 是一个确定性常数），其上可测结构将取为连续函数的一致范数诱导的 Borel 可测结构；在 Brown 桥的场合，将特取 $T = 1$ 。

以下我们首先介绍 Brown 运动。1827 年，英国生物学家 Robert Brown 用显微镜观察水中的花粉颗粒时，他发现花粉颗粒在做非常不规则的运动；他撰写了论文报告了这一现象。许多年后，1905 年 Albert Einstein 发表了一篇论文

¹其中“胎紧性”的证明比较复杂，因此没有在附录中提供，为此本附录标题中“证明”一词带有引号。

²乘积空间 $\mathbb{R}_+ \times \Omega$ 上的可测结构需要合理配置，以确保二元函数 ξ 的可测性。

指出, Brown 所观察到的花粉的不规则运动是由于水分子不规则热运动撞击导致, 并建立严格的物理模型推导出了这种运动的数学规律, 给出了 Brown 运动的扩散系数 D 的基于模型中有关物理参数的计算公式; 以后这种运动就被称为 Brown 运动。1908 年, Jean B. Perrin 通过实验验证了 Einstein 的这一理论, 他也因此在 1926 年获得 Nobel 物理学奖。数学上, 扩散系数 $D = 1$ 的 Brown 运动被称为标准 Brown 运动¹。

定义 C.1.1. 连续时间随机过程 $B. = \{B_t : t \geq 0\}$ 称为标准 Brown 运动, 如果:

- (i) $B_0 = 0$, 且对几乎处处的样本点, $t \mapsto B_t$ 是连续的;
- (ii) ²对任意 $n \geq 1$ 以及任意 $0 = t_0 < t_1 < \cdots < t_n$, $\{B_{t_k} - B_{t_{k-1}}\}_{k=1}^n$ 是相互独立的;
- (iii) $B_{t+h} - B_t \sim N(0, h), \forall t \geq 0, h > 0$.

一般的 (一维) Brown 运动是上述标准 Brown 运动的平移和尺度变换: $\{B_t(x, \sigma) := x + \sigma B_t : t \geq 0\}$ 就是一个从 $x \in \mathbb{R}$ 出发, 为 $\sigma^2 > 0$ 为扩散系数的 Brown 运动。

以下我们将把标准 Brown 运动的时间区间限定为 $[0, 1]$.

关于标准 Brown 运动 $B.$, 对任意 (右连续函数) f , 如果它在任意有界区间上总是有界变差的³, 我们可以直接使用 Stieljes 积分 (结合分部积分) 的方式来定义 Itô 随机积分 $\{\int_0^t f(s)dB_s : t \in [0, T]\}$ 如下:

$$\int_0^t f(s)dB_s := [f(t)B_t - f(0)B_0] - \int_0^t B_s df(s). \quad (\text{C.1})$$

这里再次强调一下, 由于上式右端积分项理解为 Lebesgue-Stieljes 积分, 上述积分的定义实际上只要求: $B.$ 是几乎处处连续的过程 (可以不是 Brown 运动)、 f 是右连续的有界变差函数。

借助上述积分概念, 我们不难证明标准 Brown 运动的如下特征函数刻画。

♠ **定理 C.1.1.** $B. = \{B_t : t \in [0, 1]\}$ 是一个标准 Brown 运动的充要条件是:

(BM1) $B_0 = 0$, 且对几乎处处的样本点, $t \mapsto B_t$ 是连续的;

¹有时标准 Brown 运动又称为 Wiener 过程, 而其以坐标过程形式存活的那个特殊的概率空间被称为 Wiener 空间 (对应的概率测度称为 Wiener 测度), 以纪念 Norbert Wiener 在 Brown 运动存在性等方面的奠基性工作。

² (标准) Brown 运动 $B.$ 的此条性质也被称为 “ $B.$ 是一个独立增量过程”。

³在随机分析的有关教材中, 被积函数 f 可以是更复杂的、具有随机性的 “过程”。

(BM2) 对任意有界变差的右连续函数 $f: [0, 1] \rightarrow \mathbb{R}$, 我们有

$$\mathbb{E}[\exp\{i \int_0^1 f(s) dB_s\}] = \exp\{-\frac{1}{2} \int_0^1 f(s)^2 ds\}. \quad (\text{C.2})$$

标准 Brown 运动 B 在约束 $B_0 = B_1 = 0$ 条件下的条件分布律也可以对应一个过程, 称之为 (标准) Brown 桥。为了简单起见, 我们也可以直接称

$$B^\circ = \{B_t^\circ := B_t - tB_1 : t \in [0, 1]\} \quad (\text{C.3})$$

为 Brown 桥, 这是因为此时能够证明: 对 $C[0, 1]$ 中的任意可测集 A , 下面方程总成立

$$\mathbb{P}(B^\circ \in A) = \mathbb{P}(B \in A | B_0 = B_1 = 0). \quad (\text{C.4})$$

基于 Brown 桥的表示(C.3), 不难证明 Brown 桥的如下特征函数刻画:

♠ 定理 C.1.2. B° 是一个 Brown 桥的充要条件是:

(BB1) $B_0^\circ = B_1^\circ = 0$, 且对几乎处处的样本点, $t \mapsto B_t^\circ$ 是连续的;

(BB2) 对任意有界变差的右连续函数 $f: [0, 1] \rightarrow \mathbb{R}$, 我们有

$$\mathbb{E}[\exp\{i \int_0^1 f(s) dB_s^\circ\}] = \exp\{-\frac{1}{2} \int_0^1 [f(s) - \bar{f}]^2 ds\}, \quad (\text{C.5})$$

$$\text{其中 } \bar{f} = \int_0^1 f(s) ds.$$

C.2 概率测度的弱收敛与泛函中心极限定理

C.2.1 欧氏空间与一般度量空间中概率测度的弱收敛

设 (E, d) 是一个度量空间, $\{\mu_n\}_{n=0}^\infty$ 是 (E, d) 的一列 Borel 概率测度。称 $\{\mu_n\}_{n=1}^\infty$ 弱收敛到 μ_0 , 记作 $\mu_n \xrightarrow{w} \mu_0$, 如果对任意有界连续函数 $f: E \rightarrow \mathbb{R}$, 总有

$$\lim_{n \rightarrow \infty} \int f d\mu_n = \int f d\mu_0.$$

回到欧氏空间情形, 综合本书中有关论述 (见第十、十一章), 我们下面的定理。

♠ 定理 C.2.1. 设 $m \in \mathbb{N}$. 当 $\{\mu_n\}_{n=0}^\infty$ 是 $\mathbb{R}^m$ 上的 Borel 概率测度列时, 设 $X_n \sim \mu_n, n \geq 0$, 并记 $F_n, \hat{\mu}_n$ 为 X_n 的分布函数和特征函数, 那么以下命题间互相等价:

- (i) $X_n \xrightarrow{d} X_0$;
- (ii) $F_n(x) \rightarrow F_0(x)$ 对 F_0 的连续点 x 都成立;
- (iii) $\hat{\mu}_n(t) \rightarrow \hat{\mu}_0(t)$ 对所有 $t \in \mathbb{R}$ 成立;
- (iv) $\mu_n \xrightarrow{w} \mu_0$.

在一般的度量空间中, 分布函数及特征函数概念一般而言就不再适用。设 (E, d) 为一个距离空间, d 为 E 上距离度量, 记 $\mathcal{B}$ 为 E 上的 Borel 可测集全体, $\mathcal{O}, \mathcal{C}$ 分别为 E 上的开集类和闭集类。关于度量空间上的弱收敛我们有下面的结论, 参见文献.^[126]

♠ 定理 C.2.2. 设 $\{\mu_n\}_{n=0}^\infty$ 为 $(E, \mathcal{B})$ 上概率测度列。以下命题互相等价。

- (1) $\mu_n \xrightarrow{w} \mu_0$;
- (2) 对任意有界连续函数 $f: E \rightarrow \mathbb{R}$, 总有 $\lim_{n \rightarrow \infty} \int f d\mu_n = \int f d\mu_0$;
- (3) 对任意有界一致连续函数 $f: E \rightarrow \mathbb{R}$, 总有 $\lim_{n \rightarrow \infty} \int f d\mu_n = \int f d\mu_0$;
- (4) 对任意 $F \in \mathcal{C}$, 总有 $\overline{\lim}_{n \rightarrow \infty} \mu_n(F) \leq \mu_0(F)$;
- (5) 对任意 $G \in \mathcal{O}$, 总有 $\underline{\lim}_{n \rightarrow \infty} \mu_n(G) \geq \mu_0(G)$;
- (6) 对任意 $B \in \mathcal{B}$ 满足 $\mu_0(\partial B) = 0$, 总有 $\lim_{n \rightarrow \infty} \mu_n(B) = \mu_0(B)$.

♠ 定理 C.2.3. 设 $(E, d), (E_*, d_*)$ 为距离空间, 对应的 Borel 可测集全体分别记为 $\mathcal{B}, \mathcal{B}^*$. 设 $\{\mu_n\}_{n=0}^\infty$ 为 $(E, \mathcal{B})$ 上概率测度列。设

$$T: (E, \mathcal{B}) \rightarrow (E_*, \mathcal{B}^*)$$

为可测变换。如果 T 的不连续点全体 $\mathcal{D}_T$ 满足 $\mu(\mathcal{D}_T) = 0$, 则

$$\mu_n \xrightarrow{w} \mu \text{ 蕴含了 } \mu_n \circ T^{-1} \xrightarrow{w} \mu \circ T^{-1}.$$

给定无穷积空间 $(\mathbb{R}^\infty, \mathcal{B}^\infty)$. 任意 $k \geq 1$, 令

$$\pi_k: \mathbb{R}^\infty \rightarrow \mathbb{R}^k, \omega = (\omega_1, \omega_2, \dots) \mapsto \pi_k(\omega) := (\omega_1, \dots, \omega_k)$$

为自然投影。在可数无穷维乘积欧氏空间上, 有下面类似的结果。

♠ 定理 C.2.4. 设 $\{\mu_n\}_{n=0}^\infty$ 为无穷乘积欧氏空间 $(\mathbb{R}^\infty, \mathcal{B}^\infty)$ 上的概率测度列, 记 $X_n \sim \mu_n$, 则 $\pi_k(X_n) \sim \mu_n \circ \pi_k^{-1}$. 以下三个命题等价:

- (1) $\mu_n \xrightarrow{w} \mu_0$;
- (2) 对每个 $k \geq 1$, $\mu_n \circ \pi_k^{-1} \xrightarrow{w} \mu_0 \circ \pi_k^{-1}$;
- (3) 对每个 $k \geq 1$, $\pi_k(X_n) \xrightarrow{d} \pi_k(X_0)$.

上述结果告诉我们, 为了证明无穷乘积欧氏空间上测度列的弱收敛, 我们只需要论证对应地有限维联合分布族的依分布收敛。

C.2.2 相对紧与胎紧: Prokhorov 定理

在上一小节中, 我们得到了可数无穷维乘积欧氏空间上的概率测度列弱收敛的等价刻画。但这个结果在一般的无穷维乘积空间上并不是永远正确的。为此, 有必要进一步研究无穷维乘积空间或一般的拓扑空间 (或度量空间) 上的弱收敛问题, 最终得到的结论就是 Prokhorov 定理。

定义 C.2.1. 设 (E, d) 为距离空间。 E 上的 Borel 概率测度族 $\mathcal{M}$ 称为是**相对紧**的, 如果对 $\mathcal{M}$ 中任一概率测度列 $\{\mu_n\}_{n=0}^\infty$, 存在其子列 $\{\mu_{n_k} : k \geq 1\}$, 使得 $\mu_{n_k} \xrightarrow{w} \mu_0$ 成立。

定义 C.2.2. 设 (E, d) 为距离空间。 E 上的 Borel 概率测度族 $\mathcal{M}$ 称为是**胎紧**的, 如果对任意 $\varepsilon > 0$, 存在 E 中紧集 K_ε , 使得 $\inf_{\mu \in \mathcal{M}} \mu(K_\varepsilon) > 1 - \varepsilon$ 。

♠ **定理 C.2.5. (Prokhorov 定理)** 对于任意距离空间上的任意概率测度族, 胎紧蕴含了相对紧。而在完备可分距离空间 (又称为 Polish 空间) 中, 相对紧的也蕴含了胎紧。

有关证明可以参见文献.[7, 126]

作为 Prokhorov 定理的应用, 我们有下面的推论。此处, $C_c(E)$ 为 E 上紧支集连续函数全体。

☞ **推论 C.2.1.** 设 E 为非紧的完备度量空间, $\{\mu_n\}_{n=1}^\infty$ 为其上概率测度列, μ 为其上有限测度。如果 $\{\mu_n : n \geq 1\}$ 胎紧, 且

$$\lim_{n \rightarrow \infty} \int f d\mu_n = \int f d\mu, \quad \forall f \in C_c(E),$$

那么 μ 是概率测度, 并且 $\mu_n \xrightarrow{w} \mu$ 。

如果 $Y^{(n)} = \{Y_t^{(n)} : t \geq 0\}$ 和 $Y = \{Y_t : t \geq 0\}$ 都是随机过程, $Y^{(n)}$ 和 Y 的分布测度分别是 μ_n 和 μ (都是某个函数空间 $\mathfrak{C}$ 上概率测度), 如果 $\mu_n \xrightarrow{w} \mu$, 则我们也称过程 $Y^{(n)}$ 弱收敛到 Y 。

C.2.3 泛函中心极限定理

以下我们研究空间 $C[0, 1]$ 上的 Borel 概率测度列的胎紧性；这里，我们提醒读者，在一致范数下， $C[0, 1]$ 是一个完备可分度量空间，因此由 Prokhorov 定理，其中概率测度族的胎紧性与相对紧等价。

对任意函数 $f \in C[0, 1]$ 及 $\delta > 0$ ，定义 f 的连续模如下

$$\text{osc}(f, \delta) := \sup\{|f(s) - f(t)| : s, t \in [0, 1], |s - t| < \delta\}.$$

$C[0, 1]$ 中集合 K 的列紧性可以用 Arzela-Ascoli 定理来刻画： K 是紧集，当且仅当 $\sup\{\|\omega\| : \omega \in K\} < \infty$ 且 $\lim_{\delta \downarrow 0} \sup_{\omega \in K} \text{osc}(\omega, \delta) = 0$ 。

根据上面结果，我们有下面的引理。

◆ 引理 C.2.1. 设 $\{\mu_n\}_{n=1}^\infty$ 是 $D = C[0, 1]$ 上一列 Borel 概率测度。如果它满足下面两个条件

- (i) 存在 $a > 0$ 使得 $\lim_{n \rightarrow \infty} \mu_n(\{\omega \in D : |\omega(0)| > a\}) = 0$;
- (ii) 对任意 $\varepsilon > 0$ ， $\lim_{\delta \downarrow 0} \overline{\lim}_{n \rightarrow \infty} \mu_n(\{\omega \in D : \text{osc}(\omega, \delta) > \varepsilon\}) = 0$,

那么 $\{\mu_n\}_{n=1}^\infty$ 是胎紧的。

现在设 $\{X_k\}_{k=1}^\infty \stackrel{\text{i.i.d.}}{\sim} X_0$ ，满足 $\mathbb{P}(X_0 = \pm 1) = \frac{1}{2}$ 。定义

$$S_n := X_1 + \cdots + X_n, \quad S_0 := 0, \quad (\text{C.6})$$

此时随机过程 $\{S_n : n \geq 0\}$ 称为 $\mathbb{Z}$ 上简单对称随机游动。对于此处的独立和 S_n ，可以证明下面的 Azuma-Hoeffding 不等式

$$\mathbb{P}(|S_n| > a) \leq 2e^{-a^2/(2n)}, \quad \forall a > 0, n \geq 1. \quad (\text{C.7})$$

对满足 $\mathbb{E}X_0 = 0$ 的一般的 i.i.d. 独立和 S_n 成立如下不等式（留作习题 C.5）

$$\mathbb{P}\left(\sup_{1 \leq k \leq n} |S_k| > 3a\right) \leq 3 \max_{1 \leq k \leq n} \mathbb{P}(|S_k| > a), \quad \forall a > 0, n \geq 1. \quad (\text{C.8})$$

由此可以证明：对任意 $\varepsilon > 0$

$$\lim_{\delta \downarrow 0} \overline{\lim}_{n \rightarrow \infty} \mathbb{P}\left(\sup_{\substack{0 \leq \ell \leq n\delta+1 \\ 0 \leq k \leq n-\ell}} |S_{k+\ell} - S_k| > \sqrt{n}\varepsilon\right) = 0. \quad (\text{C.9})$$

对任意 $t \in [0, 1]$ ，定义过程

$$Y_t^{(n)} := \frac{1}{\sqrt{n}} [S_{\lfloor nt \rfloor} + (nt - \lfloor nt \rfloor)X_{\lfloor nt \rfloor + 1}]. \quad (\text{C.10})$$

则显然 $Y^{(n)}$ 轨道连续, $Y_0^{(n)} = 0$. 我们约定 $Y_t^{(n)} := Y_1^{(n)}, \forall t \geq 1$. 由(C.9)立即得到

$$\lim_{\delta \downarrow 0} \lim_{n \rightarrow \infty} \mathbb{P}(\text{osc}(Y^{(n)}, \delta) > \varepsilon) = 0,$$

因此设 $Y^{(n)} \sim \mu_n$, 则 $\{\mu_n : n \geq 1\}$ 是胎紧的。

进一步, 对 $[0, 1]$ 上任意有界变差的右连续函数 f , 容易知道

$$\int_0^1 f(t) dY_t^{(n)} = \sqrt{n} \sum_{k=1}^n X_k \int_{\frac{k-1}{n}}^{\frac{k}{n}} f(t) dt.$$

注意, X_1 的特征函数为 $g(t) := \mathbb{E}[e^{itX_1}] = \cos t$, 它满足

$$g(t) = 1 - \frac{t^2}{2} + o(t^2) = \exp\left\{-\frac{t^2}{2} + o(t^2)\right\}, \text{ 当 } t \rightarrow 0 \text{ 时}.$$

因此不难算出

$$\mathbb{E}\left[\exp\left\{i \int_0^1 f(t) dY_t^{(n)}\right\}\right] = \exp\left\{-\frac{1}{2} \int_0^1 f(t)^2 dt + o(1)\right\},$$

即

$$\lim_{n \rightarrow \infty} \mathbb{E}\left[\exp\left\{i \int_0^1 f(t) dY_t^{(n)}\right\}\right] = \mathbb{E}\left[\exp\left\{i \int_0^1 f(t) dB_t\right\}\right].$$

因此, 结合前述胎紧性, $\mu_n \xrightarrow{w} \mu$, 其中 μ 是 $B|_{[0,1]}$ 的分布测度 (即 Wiener 测度). 于是我们进一步有下面的泛函中心极限定理, 其中我们把条件 $\mathbb{P}(X_0 = \pm 1) = \frac{1}{2}$ 放松为更一般的条件 $\mathbb{E}X_0 = 0, \mathbb{E}[X_0^2] = 1$, 读者可以尝试在此条件下完成此定理的证明。

♠ 定理 C.2.6. 设 $\{X_k\}_{k=1}^\infty \stackrel{\text{i.i.d.}}{\sim} X_0$, 满足 $\mathbb{E}X_0 = 0, \mathbb{E}[X_0^2] = 1$, 则由(C.6)和(C.10)定义的过程 $\{Y_t^{(n)} : t \in [0, 1]\}$ 弱收敛到标准 Brown 运动 $\{B_t : t \in [0, 1]\}$. 特别地, 对 $C[0, 1]$ 上的任意连续泛函 ψ , 总有

$$\psi(Y^{(n)}) \xrightarrow{d} \psi(B).$$

上述定理被称为 Donsker 不变原理, 也称为泛函中心极限定理。

C.3 Kolmogorov 定理的“证明”

在本节, 我们形式地仿照上一小节中泛函中心极限定理的证明, 来“证明”Kolmogorov 定理, 其中我们省略了胎紧性的论证, 因此只能视作一个解释性的不完整证明。

简单样本 $\{X_k\}_{k=1}^n \stackrel{\text{i.i.d.}}{\sim} F$ 的经验分布函数 $\hat{F}_n$ 定义为

$$\hat{F}_n(x) := \frac{1}{n} \sum_{k=1}^n 1_{\{X_k \leq x\}}.$$

当 F 是连续的分布函数时, 我们已经由 Glivenko-Cantelli 定理知道, $\hat{F}_n$ 几乎处处一致地收敛到 F , 即 K-S 统计量 D_n 满足

$$D_n := \sup_x |\hat{F}_n(x) - F(x)| \xrightarrow{\text{a.s.}} 0.$$

并且容易知道, D_n 的分布律实际上不依赖于分布函数 F 的具体形式。因此, 以下证明中我们将特取 F 为 $U(0, 1)$ 的分布函数, 即: $F(x) = x, \forall x \in [0, 1]$, 并且

$$\{X_k\}_{k=1}^n \stackrel{\text{i.i.d.}}{\sim} U(0, 1).$$

现在, 令

$$Y_t^{(n)} := \sqrt{n}[\hat{F}_n(t) - F(t)] = \sqrt{n}[\hat{F}_n(t) - t], \quad t \in [0, 1].$$

上述过程 $Y^{(n)}$ 只是一个右连续的过程。因此引理 C.2.1 不适用于此; 我们也不准备在此提供胎紧性的论证, 而只准备解释分布律方面的对应收敛。

容易知道, $Y_0^{(n)} = Y_1^{(n)} = 0$ 。

对任意有界变差、右连续函数 f , 记 $\bar{f} := \int_0^1 f(t)dt = \mathbb{E}f(X_1)$, 我们可以计算得出

$$\begin{aligned} \int_0^1 f(t) dY_t^{(n)} &= \sqrt{n} \cdot \left[\int_0^1 f(t) d\hat{F}_n(t) - \int_0^1 f(t) dt \right] \\ &= \sqrt{n} \cdot \left[\frac{1}{n} \sum_{k=1}^n f(X_k) - \bar{f} \right] \\ &= \frac{1}{\sqrt{n}} \sum_{k=1}^n [f(X_k) - \bar{f}] \xrightarrow{d} N(0, \sigma_f^2), \end{aligned}$$

其中 $\sigma_f^2 := \mathbb{V}\text{ar}(f(X_1)) = \int_0^1 [f(t) - \bar{f}]^2 dt$. 于是

$$\lim_{n \rightarrow \infty} \mathbb{E}[\exp\{i \int_0^1 f(t) dY_t^{(n)}\}] = \mathbb{E}[\exp\{i \int_0^1 f(t) dB_t^\circ\}].$$

记 $D[0, 1]$ 为 $[0, 1]$ 上定义的右连续、具有左极限的函数全体。如果承认过程列 $Y^{(n)}$ 对应的分布测度列 $\{\mu_n\}_{n=1}^\infty$ (它们是在空间 $D[0, 1]$ 上的概率测度) 的胎紧性, 我们就立即得到过程 $Y^{(n)}$ 弱收敛到 Brown 桥 B° . 定理 C.2.3 则确保了

应的泛函中心极限定理仍然成立, 从而 Kolmogorov 定理的主要结论(12.27)成立。

习 题 C

习题 C.1. 证明定理C.1.1.

习题 C.2. 设 B 为标准 Brown 运动, 证明 $\{B_t - tB_1 : t \in [0, 1]\}$ 的分布律与条件分布律 $\{B_t : t \in [0, 1]\} \Big| B_1 = 0$ 相同。

习题 C.3. 证明定理C.1.2.

习题 C.4. 证明引理C.2.1

习题 C.5. 证明 Etemadi 不等式(C.8).

参考文献

- [1] Adams, W. J.: *The Life and Times of the Central Limit Theorem* (2nd Edition), History of Mathematics Vol. 35, Originally published: New York: Kaedmon Pub. Co., 1974; American Mathematical Society, Providence, RI; London Mathematical Society, London, 2009, xii+195 pp. ISBN: 978-0-8218-4899-9.
- [2] Aigner, M.; Ziegler, G. M.: *Proofs from THE BOOK* (6th Edition), Springer, Berlin, 2018, viii+326 pp. ISBN: 978-3-662-57264-1; 978-3-662-57265-8.
- [3] Akhizer, N. I.: *The Classical Moment Problem and Some Related Questions in Analysis*, Classics Appl. Math. **82**, Society for Industrial and Applied Mathematics (SIAM), Philadelphia, PA, 2021, xiii+252 pp. ISBN: 978-1-611976-38-0.
- [4] Athreya, Krishna B.; Lahiri, Soumendra N.: *Measure Theory and Probability Theory*, Springer Texts Statist. Springer, New York, 2006, xviii+618 pp. ISBN: 978-0387-32903-1; 0-387-32903-X.
- [5] Berkes, I.: *A remark to the law of the iterated logarithm*, Studia Sci. Math. Hungar. **7** (1972), No. 1-2, 189–197.
- [6] Bingham, N. H.; Goldie, C. M.; Teugels, J. L.: *Regular Variation*, Encyclopedia Math. Appl. **27**, Cambridge University Press, Cambridge, 1989, xx+494 pp. ISBN: 0-521-37943-1.
- [7] Billingsley, P.: *Probability and Measure* (Anniversary Edition), John Wiley & Sons, Inc., ISBN: 978-1-118-12237-2.

- [8] Birkel, T.: *A note on the strong law of large numbers for positively dependent random variables*, Statist. Probab. Lett. **7** (1989), 17–20.
- [9] Birkel, T.: *Law of large numbers under dependence assumptions*, Statist. Probab. Lett. **14** (1992), 355–362.
- [10] Breiman, L.: *Probability*, Classics Appl. Math. **7**, Society for Industrial and Applied Mathematics (SIAM), Philadelphia, PA, 1992, xiv+421 pp. ISBN: 0-89871-296-3.
- [11] Chandra, T. K.: *The Borel-Cantelli Lemmas*, Springer Briefs in Statistics, Springer, Heidelberg, 2012, xii+106 pp. ISBN: 978-81-322-0676-7
- [12] Chen, Louis H. Y.; Goldstein L., Shao, Q.-M.: *Normal Approximation by Stein's Method*, Probab. Appl. (N. Y.) Springer, Heidelberg, 2011, xii+405 pp. ISBN: 978-3-642-15006-7
- [13] Chen, X.-X.; Xie, J.-S.; Ying, J.-G.: *Range-renewal processes: SLLNs and power laws*, Chinese Ann. Math. Ser. B **43** (2022), no. 1, 63–78.
- [14] Chernov, N.; Kleinbock, D.: *Dynamical Borel – Cantelli lemmas for Gibbs measures*. Israel J. Math. **122** (2001), 1–27.
- [15] Chung, K.-L.: *Note on Some Strong Laws of Large Numbers*, Amer. J. Math. **69**, no. 1 (Jan., 1947), 189–192.
- [16] Chung, K.-L.: *Markov Chains with Stationary Transition Probabilities*, 2nd edition, Die Grundlehren der mathematischen Wissenschaften, Band **104**, Springer-Verlag New York, Inc., New York, 1967, xi+301 pp.
- [17] Chung, K.-L.: *A Course in Probability Theory*, 3rd edition, Academic Press, Inc., San Diego, CA, 2001, xviii+419 pp. ISBN: 0-12-174151-6.
- [18] Chung, K. L.; Erdős, P.: *On the application of the Borel-Cantelli lemma*, Trans. Amer. Math. Soc. **72** (1952), 179–186.
- [19] Csörgő, S.; Tandori, K.; Totik, V.: *On the strong law of large numbers for pairwise independent random variables*, Acta Math. Hungar. **42** (1983), no. 3-4, 319–330.

- [20] DasGupta, Anirban: *Probability for Statistics and Machine Learning: Fundamentals and Advanced Topics*, Springer Texts in Statistics, Springer 2011.
- [21] David, F. N.: *Games, Gods and Gambling*, Dover Publications, Inc., Mineola, NY, 1998, xvi+275 pp. ISBN: 0-486-40023-9
- [22] Davie, G.: *The Borel-Cantelli lemmas, probability laws and Kolmogorov complexity*. Ann. Probab. **29** (2001), no. 4, 1426–1434.
- [23] Dedecker, J.; Merlevède, F.; Rio, E.: *Criteria for Borel-Cantelli Lemmas with Applications to Markov Chains and Dynamical Systems*, Chapter 7 of *Séminaire de Probabilités LI*, Lecture Notes in Mathematics **2301**.
- [24] De Finetti, B.: *Foresight: Its Logical Laws, Its Subjective Sources*, Annales de l' Institut Henri Poincaré **7** (1937): 1–68. English translation by H. E. Kyburg Jr. and H. E. Smokler, eds., in *Studies in Subjective Probability*. Huntington, NY: Krieger, 1964; 2nd ed. 1980.
- [25] DeGroot, M. H.; Schervish, M. J.: *Probability and Statistics* (4nd Edition), Pearson Education Inc., 2012, ISBN: 978-0-321-50046-5.
- [26] Dembo, A.; Zeitouni, O.: *Large Deviations Techniques and Applications* (3rd Edition), Stoch. Model. Appl. Probab. **38**, Springer-Verlag, Berlin, 2010, xvi+396 pp. ISBN: 978-3-642-03310-0.
- [27] Diaconis, P.; Skyrms, B.: *Ten Great Ideas about Chance*, Princeton University Press, Princeton, NJ, 2018, x+255 pp. ISBN: 978-0-691-17416-7.
- [28] Dubins, Lester E.; Freedman, David A.: *A sharper form of the Borel-Cantelli lemma and the strong law*. Ann. Math. Statist. **36** (1965), 800–807.
- [29] Durrett, R.: *Probability: Theory and Examples* (5th Edition), Camb. Ser. Stat. Probab. Math. **49**, Cambridge University Press, Cambridge, 2019, xii+419 pp. ISBN: 978-1-108-47368-2.
- [30] Dvoretzky, A.; Erdős, P.: *Some problems on random walk in space*. Proceedings of the Second Berkeley Symposium on Mathematical Statistics and Probability, 1950, pp. 353–367. University of California Press, Berkeley-Los Angeles, Calif., 1951.

- [31] Eckhardt, William: *Paradoxes in Probability Theory*, SpringerBriefs Philos. Springer, Dordrecht, 2013, xvi+79 pp. ISBN: 978-94-007-5139-2; 978-94-007-5140-8.
- [32] Erdős, P.: *On the strong law of large numbers*, Trans. Amer. Math. Soc. **67** (1949), 51–56.
- [33] Erdős, P.: *On a theorem of Hsu and Robbins'*, Ann. Math. Statist. **20** (1949), 286–291.
- [34] Erdős, P.: *Remark on my paper "On a theorem of Hsu and Robbins"'*, Ann. Math. Statist. **21** (1950), 138.
- [35] Erdős, P.; Rennyi, A.: *On Cantor's series with convergent $1/q_n$* , Ann. Univ. Sci. Budapest Eötvös Sect. Math. **2** (1959), 93–109.
- [36] Estrada, L. F.; Högele, M. A.: *Moment estimates in the first Borel – Cantelli Lemma with applications to mean deviation frequencies*, Stat. Probab. Lett. **190** (2022), Paper No. 109636.
- [37] Etemadi, N.: *An Elementary Proof of the Strong Law of Large Numbers*, Z. Wahrscheinlichkeitstheorie verw. Gebiete **55** (1981), 119–122.
- [38] Feller, W.: *A limit theorem for random variables with infinite moments*, Amer. J. Math., vol. **68** (1946), pp. 257–262.
- [39] Feller, W.: *An Introduction to Probability Theory and Its Applications* (Vol. I), John Wiley & Sons, Inc., New York-London-Sydney, 1968, xviii+509 pp.
- [40] Feller, W.: *An Introduction to Probability Theory and Its Applications* (Vol. II), John Wiley & Sons, Inc., New York-London-Sydney, 1971, xxiv+669 pp.
- [41] Fischer, Hans: *A History of the Central Limit Theorem: From Classical to Modern Probability Theory*, Sources Stud. Hist. Math. Phys. Sci. Springer, New York, 2011. xvi+402 pp. ISBN: 978-0-387-87856-0.
- [42] Fréchet, M.: *Exposé et discussion de quelques recherches récentes sur les fondements du calcul des probabilités*, Actualités Scientifiques et In-

- dustrielles **735**, 23–55. Hermann, Paris. In Wavre (1938–1939), second fascicle, entitled Les fondements du calcul des probabilités.
- [43] Freedman, David: *Another note on the Borel-Cantelli lemma and the strong law, with the Poisson approximation as a by-product*, Ann. Probability **1** (1973), 910–925.
- [44] Frolov, A. N.: *On strong forms of the Borel – Cantelli lemma and intermittent interval maps*, J. Math. Anal. Appl. **504** (2021), Paper No. 125425.
- [45] Gorroochurn, P.: *Classic Topics on the History of Modern Mathematical Statistics: From Laplace to More Recent Times*, John Wiley & Sons, Inc., Hoboken, NJ, 2016. xxi+754 pp. ISBN: 978-1-119-12792-5.
- [46] Grafakos, L.: *Classical Fourier Analysis* (Third Edition), Grad. Texts in Math. **249**. Springer, New York, 2014, xviii+638 pp. ISBN: 978-1-4939-1193-6; 978-1-4939-1194-3.
- [47] Grimmett, G.; Stirzaker, D.: *Probability and Random Processes* (4th Edition) , Oxford University Press, Oxford, 2020, xii+669 pp. ISBN: 978-0-19-884759-5; 978-0-19-884760-1.
- [48] Grimmett, G.; Stirzaker, D.: *One Thousand Exercises in Probability*, Oxford University Press, 2004.
- [49] Grimmett, Geoffrey; Welsh, Dominic: *Probability—an introduction* (2nd Edition) , Oxford University Press, Oxford, 2014, x+270 pp. ISBN: 978-0-19-870997-8.
- [50] Hald, A.: *A History of Probability and Statistics and Their Applications before 1750*, Wiley Ser. Probab. Math. Statist. Probab. Math. Statist. Wiley-Intersci. Publ. John Wiley & Sons, Inc., New York, 1990, xvi+586 pp. ISBN: 0-471-50230-8.
- [51] Hald, A.: *A History of Mathematical Statistics from 1750 to 1930*, Wiley Ser. Probab. Stat. Texts Ref. Sect. Wiley-Intersci. Publ. John Wiley & Sons, Inc., New York, 1998, xx+795 pp. ISBN: 0-471-17912-4.

- [52] Hald, A.: *A History of Parametric Statistical Inference from Bernoulli to Fisher, 1713—1935*, Sources Stud. Hist. Math. Phys. Sci. Springer, New York, 2007, xiv+223 pp. ISBN: 978-0-387-46408-4; 0-387-46408-5.
- [53] Hoover, Donald R.: *First Borel-Cantelli equalities incorporating known dependency structure*. (English, Italian summary) *Metron* **60** (2002), no.3-4, 21–30.
- [54] Hsu, P. L.; Robbins, Herbert: *Complete convergence and the law of large numbers*, *Proc. Nat. Acad. Sci. U.S.A.* **33** (1947), 25–31.
- [55] Hussain, M.; Li, B.; Simmons, D.; Wang, B.: *Dynamical Borel–Cantelli lemma for recurrence theory*, *Ergod. Th. & Dynam. Sys.* **42** (2022), 1994–2008.
- [56] Jacobson, Nathan: *Basic Algebra I* (Second Edition), Dover Publications 2009, ISBN: 978-0-48647-189-1.
- [57] Jaynes, E. T.: *Probability Theory: The Logic of Science*, Cambridge University Press, Cambridge, 2003, xxx+727 pp. ISBN: 0-521-59271-2.
- [58] Keynes, John Maynard: *A Treatise on Probability*. (Originally written as a Fellowship Dissertation for King’s Colledge, Cambridge, between 1906 and 1909, then rewritten for publication during 1909-12 and 1902-1.) The collected writings of John Maynard Keynes. Vol. VIII, Macmillan Press Ltd., London; Cambridge University Press, New York, 1988, xxvi+514 pp.
- [59] Kifer, Y.: *The Strong Borel – Cantelli Property in Conventional and Nonconventional Setups*, *Lecture Notes in Math.* Vol **2290**. CIRM Jean-Morlet Ser. Springer, Cham, 2021, 235–261. ISBN: 978-3-030-74862-3; 978-3-030-74863-0.
- [60] Klenke, Achim: *Probability Theory: A Comprehensive Course*, Springer-Verlag, Berlin Heidelberg 2006. ISBN: 978-1-84800-047-6.
- [61] Kochen, S. B., Stone, C. J.: *A note on the Borel-Cantelli lemma*, *Illinois J. Math.* **8** (1964), 248–251.

- [62] Kolmogorov, A. N.: *Grundbegriffe der Wahrscheinlichkeitsrechnung*, Springer, Berlin (1933). An English translation by N. Morrison appeared under the title *Foundations of the Theory of Probability* (Chelsea, New York) in 1950, with a second edition in 1956.
- [63] Korevaar, Jacob: *Tauberian Theory: A Century of Developments*, 科学出版社, 国外数学名著系列 (影印版) **36**.
- [64] Kreĭn, M. G.; Nudelman, A. A.: *The Markov moment problem and extremal problems. Ideas and problems of P. L. čebyšev and A. A. Markov and their further development*. Translated from the Russian by D. Louvish. Translations of Mathematical Monographs, Vol. **50**. American Mathematical Society, Providence, R.I., 1977. v+417 pp. ISBN: 0-8218-4500-4.
- [65] Lagrange, Joseph Louis: *Mémoire sur l'utilité de la méthode de prendre le milieu entre les résultats de plusieurs observations; dans lequel on examine les avantages de cette méthode par le calcul des probabilités; et où l'on résoud différents problèmes relatifs à cette matière*, Miscellanea Taurinensia, Vol. **5** (1770–1773), pp. 167–232 of Mathematics portion. Reprinted in *Oeuvres de Lagrange*, Vol. **2**, pp. 173–234, Gauthier-Villars, Paris, 1868.
- [66] Lamperti, J.: *Wieners test and Markov chains*. J. Math. Anal. Appl. **6** (1963), 58–66.
- [67] Laplace, Pierre Simon de: *Traité de mécanique céleste*, 5 volumes, Paris: Vols I and II (1799), Vol. III (1802), Vol. IV (1805), Vol. V (1825). Volumes I – IV were translated into English (Celestial Mechanics) by Nathaniel Bowditch, with an extensive running commentary. This English translation was reprinted by the Chelsea Publishing Co. in 1967. Volume V in the original French contains historical material and commentary on the earlier volumes. For the most part, this material is incorporated into Bowditch's commentary. Volume V was reprinted by Chelsea in 1969.
- [68] Lehman, E. L.: *Some concepts of dependence*, Ann. Math. Statist. **37** (1966), 1137–1153.

- [69] Littlewood, J.: *Littlewood's Miscellany*. Edited by Bèla Bollobás. First published in 1953 as 'A Mathematician's Miscellany'. *Cambridge University Press*, Cambridge, 1986. p. 26. ISBN: 0-521-33058-0 (hard covers); 0-521-33702-X (paperback).
- [70] Loève, M.: *Probability Theory* (3rd Edition), D. Van Nostrand Co., Inc., Princeton, N.J.-Toronto, Ont.-London, 1963, xvi+685 pp.
- [71] Loève, M.: *Probability theory. I* Grad. Texts in Math., Vol. **45**. Springer-Verlag, New York-Heidelberg, 1977, xvii+425 pp.
- [72] Loève, M.: *Probability theory. II* Grad. Texts in Math., Vol. **46**. Springer-Verlag, New York-Heidelberg, 1978, xvi+413 pp. ISBN: 0-387-90262-7.
- [73] Luzia, N.: *A Borel-Cantelli lemma and its applications*, Trans. Amer. Math. Soc. **366** (2014), no. 1, 547–560.
- [74] Marcinkiewicz, J.; Zygmund, A.: *Sur les fonctions indépendantes*, Fundamenta Mathematicae, vol. **29** (1937), pp. 60–90.
- [75] Martin-Löf, Anders: *A limit theorem which clarifies the "Petersburg paradox"*. J. Appl. Probab. **22** (1985), no. 3, 634–643.
- [76] Matuła, P.: *A note on the almost sure convergence of sums of negatively dependent random variables*, Statist. Probab. Lett. **15** (1992), 209–213.
- [77] Newman, C. M.: *Asymptotic independence and limit theorems for positively and negatively dependent random variables*, in: Y. L. Tong, ed., *Inequalities in Statistics and Probability* (Institute of Mathematical Statistics, Hayward, CA) pp. 127–140.
- [78] Owen, D. B.: *Handbook of Statistical Tables*, Addison-Wesley Publishing Co., Inc., Reading, Mass.-London, 1962, xii + 580 pp.
- [79] Petrov, V.V.: *On a relation between an estimate of the remainder in the central limit theorem and the law of the iterated logarithm*, Teor. Veroyatn. Primen. **11**, No. 3, 514–518. Engl. transl.: Theory Probab. Appl. **11** (1966), No. 3, pp. 454–458.
- [80] Petrov, Valentin V.: *A note on the Borel-Cantelli lemma*, Statist. Probab. Lett. **58** (2002), no. 3, 283–286.

- [81] Philipp, W.: *Some metrical theorems in number theory*, Pacific J. Math. **20** (1967), 109–127.
- [82] Plackett, R. L.: *Principles of Regression Analysis*, Clarendon Press, Oxford, 1960, ix + 173 pp.
- [83] Pollard, H.: *The completely monotonic character of the Mittag-Leffler law $E_a(-x)$* , Bulletin Amer. Math. Soc. **54** (1948), 1115–1116.
- [84] Pollard, H.: *The representation of e^{-x^λ} as a Laplace integral*, Bulletin Amer. Math. Soc. **52** (1946), 908–910.
- [85] Ross, Sheldon M.: *Introduction to Probability Models* (11th Edition), ISBN 978-0124079489, 2014.
- [86] Ross, Sheldon M.: *A First Course in Probability* (9th Edition). 中文翻译本《概率论基础教程》(原书第9版), 童行伟、梁宝生译, 机械工业出版社出版。
- [87] Ross, Sheldon M.; Peköz, Erol A.: *A Second Course in Probability*, ISBN 0-9795704-0-9, 2007.
- [88] Schilling, R. L.: *Measures, Integrals and Martingales*, Cambridge University Press, 2005.
- [89] Schmüdgen, K.: *The Moment Problem*, Grad. Texts in Math. Vol. **277**. Springer, Cham, 2017, xii+535 pp. ISBN: 978-3-319-64545-2; 978-3-319-64546-9.
- [90] Shafer, Glenn; Vovk, Vladimir: *The Sources of Kolmogorov's Grundbegriffe*, Statistical Science Vol. **21** (2006), No. 1, 70–98.
- [91] Shohat, J. A.; Tamarkin, J. D.: *The Problem of Moments*, Mathematical Surveys and Monographs Volume **1**, American Mathematical Society, (Revised edition issued in 1950) Fourth printing of revised edition,
- [92] Simon, Barry: *Functional Integration and Quantum Physics* (2nd Edition), AMS Chelsea Publishing, Providence, RI, 2005, xiv+306 pp. ISBN: 0-8218-3582-3.

- [93] Stigler, Stephen M.: *Statistics on the Table: the History of Statistical Concepts and Methods*, Harvard University Press, 2002. ISBN:0-674-83601-4 (cloth), 0-674-00979-7 (pbk.).
- [94] Stigler, Stephen M.: *The Seven Pillars of Statistical Wisdom*, Harvard University Press, 2016. ISBN:0-674-83601-4 (cloth), 0-674-00979-7 (pbk.).
- [95] Tabak, J.: *Probability and Statistics: the Science Of Uncertainty (History of Mathematics)*, Facts On File, Inc., 2004. ISBN: 0-8160-4956-4.
- [96] Van Campenhout, J.; Cover, T.: *Maximum entropy and conditional probability*, IEEE Trans. Inf. Theory **27** (1981), no. 4, 483–489.
- [97] Vasicek, O. A.: *A conditional law of large numbers*, Ann. Probab. **8** (1980), no. 1, 142–147.
- [98] Venn, J.: *The Logic of Chance*, London, 1866. 2nd ed. 1876, 3rd ed. 1888. Reprinted by Chelsea, New York, 1962.
- [99] von Plato, J.: *Creating Modern Probability: Its Mathematics, Physics and Philosophy in Historical Perspective*, Cambridge University Press, 1994. ISBN: 0-521-44403-9.
- [100] Whittle, Peter: *Probability via Expectation* (4th Edition), Springer Texts Statist. Springer-Verlag, New York, 2000, xxii+352 pp. ISBN: 0-387-98955-2.
- [101] Widder, D. V.: *The Laplace Transform*, Princeton Math. Ser., vol. **6**, Princeton University Press, Princeton, NJ, 1941, x+406 pp.
- [102] Xie, Jiansheng; Zhou, Ruisong: *A Note on an SLLN of Dvoretzky-Erdős Type*, Statist. Probab. Lett. **195** (2023), Paper No. 109769, 5 pp.
- [103] 陈家鼎, 郑忠国: 概率与统计, 北京大学出版社, 2006.
- [104] 陈希孺: 数理统计引论, 科学出版社, 1981 年 11 月.
- [105] 程士宏: 高等概率论, 北京大学出版社, 1996.
- [106] 程士宏: 测度论与概率论基础, 北京大学出版社, 2004.

- [107] 格罗斯 (B. Gross), 哈里斯 (J. Harris), 里尔 (E. Riehl): 哈佛概率论公开课 (Fat Chance: Probability from 0 to 1), 薄立军、李本崇译, 机械工业出版社, 2020.
- [108] 何书元: 概率论, 北京大学出版社, 2006.
- [109] 何书元: 概率论基础, 高等教育出版社, 2021.
- [110] 靳志辉: 正态分布的前世今生 (上), 数学文化, 4 (2013), pp. 36–47.
- [111] 靳志辉: 正态分布的前世今生 (下), 数学文化, 4 (2013), pp. 54–62.
- [112] 李心灿: 当代数学大师—沃尔夫数学奖得主及其建树与见解 (第四版), 高等教育出版社, 2013.
- [113] 梁宗巨 (主编): 数学家传略辞典, 山东教育出版社, 1989; 杜瑞芝、王青建、陈一心等参与合编。
- [114] 彼得·欧弗森 (Peter Olofsson): 生活中的概率趣事, 赵莹译 (第2版), 机械工业出版社, 2021.
- [115] 齐民友 (主编): 概率论与数理统计 (第二版), 刘禄勤、王文祥、龚小庆编, 高等教育出版社, 2011年8月。
- [116] A. H. 施利亚耶夫: 概率 (第一卷), 周概容译, 高等教育出版社, 2007.
- [117] A. H. 施利亚耶夫: 概率 (第二卷), 周概容译, 高等教育出版社, 2008.
- [118] 苏淳, 冯群强: 概率论 (第三版), 科学出版社, 2020年4月。
- [119] (美) 塔巴克著; 杨静译: 概率论和统计学: 不确定的科学, 商务印书馆, 2007. ISBN: 7-100-05158-4.
- [120] 特伦鲍姆 (G. Tenenbaum) 著; 陈华一译: 解析与概率数论导引, 高等教育出版社, 2011. ISBN: 978-7-04-029467-5.
- [121] 汪嘉冈: 现代概率论基础, 复旦大学出版社, 1988.
- [122] 王丽霞: 概率论与随机过程: 理论、历史及应用, 清华大学出版社, 2012.

- [123] 维恩堡 (G. H. Weinberg)、休麦克 (J. A. Schumaker)、奥尔特曼 (D. Oltman) 著; 常学军、胡文明、王明生、詹森、刘兰亭译: 数理统计初级教程 (原著《Statistics: An Intuitive Approach》), 山西人民出版社, 1986. ISBN: 978-7-04-029467-5.
- [124] 韦来生: 数理统计 (第二版), 科学出版社, 2015 年 12 月。
- [125] 吴文俊 (主编): 世界著名科学家传记 I, 科学出版社, 1990.
- [126] 谢践生: 现代概率论基础, 电子讲义, 待出版。
- [127] 徐传胜: 从博弈问题到方法论学科: 概率论发展史研究, 科学出版社, 2009.
- [128] 严加安: 测度论讲义, 科学出版社, 1998.
- [129] 杨振海: 拟合优度检验, 合肥, 安徽教育出版社, 1994.
- [130] 应坚刚, 何萍: 概率论, 复旦大学出版社, 2006.
- [131] 张奠宙: 20 世纪数学经纬, 华东师范大学出版社, 2002.
- [132] 钟开莱: 概率论教程, 刘文、吴让泉译, 上海科学技术出版社, 1989 年 6 月。